Japanese Generative AI Technical Survey

2026-W42

2026-10-18

記憶・回路

フロンティア実行、推論の経済学。

NONCANONICAL DIAGNOSTIC
NOT A PUBLICATION PREVIEW
NOT FOR HUMAN APPROVAL

Editorial cutoff	2026-10-09 18:00 - 2026-10-16 18:00 America/New_York
Repository	eariver/japanese-generative-ai-survey
Build	LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey（診断用・非正準・未承認）。

1 フロンティアエージェント:Wonder と Argon の実行と記憶

記憶して働き続けるエージェント——Wonder と Argon の実行力

Wonder の例示タスクを具体的に読む。保険請求、賃貸契約、家計管理、ゲームやアプリの構築といった個人・業務の作業が挙げられている。いずれも一度の指示で終わらない継続作業であり、記憶の持ち越しと遂行の注意が要る領域だ。例示の選び方が、機構の設計意図を物語っている。[?, ?, ?, ?, ?, ?]

失敗の内訳も監査口になる。605 回の死亡の多くは怪物によるもので、終盤のエンダードラゴン戦だけで 69 回・約 14 時間を費やした。プログラムの 22%は誤り終了し、詰まりには無への跳躍で初期化するという運用で切り抜けた。失敗の記録と立直しの手順が残ることが、実行主張の検証口になる。[?, ?, ?, ?, ?, ?]

表 1　比較表：Wonder と Argon の読み分け

Wonder	発表：10 月 12 日（Meta）	核：Active Memory（会話またぎ文脈の保持）・Active Focus（遂行中の注意維持と確認）	評価：Harvey LAB・FocusBench・SWE-Marathon 等を図表化（数値本体は報告書、未刊の安全報告あり）	料金：API 4/20 ドル、Full は上位プラン限定（開発者ページ）[?, ?, ?, ?]	
Argon	提供開始：10 月 13 日 全世界一般提供	料金：導入 2/10 ドル→11 月 30 日 4/20 ドル、出力 100 万トークン	事例：Chrome 改修等（発行元報告）	長時間：Minecraft 27 時間 14 分・ランダム生成・単一試行・構造化情報のみ（条件明示、固定シードなし）	流通：Copilot 一般提供（10 月 13 日変更履歴）[?, ?, ?, ?]

実演と検証の区別も読む。5 千行レイトレーサの実演はベンチマークではなく実演であり、発行者の位置づけを保って読む。実演の記録と検証の記録は別の事柄だ。[?, ?, ?, ?, ?, ?]

二つの発表の非対称が今週の要点だ。Wonder は機構の定義が厚く、Argon は事例の厚みが目立つ。定義の厚さは検証の出発点になり、事例の厚さは利用の出発点になる。定義・測定・未公開を切り分け、価格と流通の条件を性能の証拠と混ぜずに記録することが、今週の読み方だ。[?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?]

2 推論の経済学:Maia 300 と LFM2.5

推論の経済学——Maia 300 の回路と LFM2.5 の効率開示

比較不能の方法論を確認する。Maia の数字はラック級の推論基盤の改善率、LFM の数字は単一モデルのベンチ表であり、測定対象も単位も違う。温度・バッチ・ハードを添えた LFM の表し方は、分母つき開示の手本になる。手本の流儀で Maia を読むと、欠けているのは基準の詳細だと分かる。[?, ?, ?, ?, ?, ?, ?, ?]

16 種ベンチを温度条件つきで示す流儀は分母の開示だ。AutomationBench 27.69 対次点 8.72 という差も、温度・ベンチ名とセットで読む。条件つきの表が、効率主張の監査口になる。[?, ?, ?]

表 2　比較表：効率主張の読み分け

Maia 300	実体：SDLA・NUMA チップレット・HBM4 288GB・18TB/s・MXFP4・24 トレイ・96 加速器 167kW	効率主張：公表 200 比の改善率（基準詳細は非公開、発行者のみ、未検証）	再現：ハード上独立再現なし [?, ?, ?, ?]
LFM2.5	実体：24B/2B 推論専用 CoT・131K 文脈・33T 事前学習・総 36T 訓練予算・能動 24.5 億	効率主張：16 種ベンチ表（温度つき、発行者計測）・スタック依存スループット	開示：報酬ハッキング自己開示（独立検証ではない）・商用上限 1000 万ドル [?, ?, ?]

温度の個別開示も読む。BFCLv4 は T0.001、道具砂場は T0、実働爪は T1.0、指示追従は掃引で 96.75・74.69・84.38。知識系の遅れ（GPQA・HLE・全知・SWE-V・SciCode）と、道具砂場の利用者模擬 GPT-4o・τ の GPT-5.2 ＋ BM25 という模擬交絡が併記されている。条件の粒が、表の監査口になる。[?, ?, ?]