# Japanese Generative AI Technical Survey

**2026-W42**

2026-10-18

## 重み・生産性

オープンウェイト、エージェント工学。

NONCANONICAL DIAGNOSTIC
NOT A PUBLICATION PREVIEW
NOT FOR HUMAN APPROVAL

| | |
|---|---|
| **Editorial cutoff** | 2026-10-09 18:00 - 2026-10-16 18:00 America/New_York |
| **Repository** | eariver/japanese-generative-ai-survey |
| **Build** | LuaLaTeX / jlreq / LuaTeX-ja |

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey（診断用・非正準・未承認）。

MiniCPM-V 4.7（35B-A3B 初の MoE、LES による非可逆なしオンデバイス MoE、iPhone 17 Pro Max で 3GB・毎秒 13 トークン超）は、携帯端末実装の事例だ。BF16・FP8・int4・AWQ・GPTQ・GGUF と日付つき README（12 日・15 日）、SGLang・vLLM・llama.cpp・Ollama 対応、SRFT 微調整。使う側の選択肢が具体的に並んでいる。Apache 2.0 はこちらもタグ確認のみであり、ファイル未確認の限界を Granite と同様に明記する。[?, ?, ?]

FLUX 3 Image Klein（5.6B、Qwen3-VL-4B エンコーダ、蒸留 16 ステップと基盤 50 ステップの使い分け、4K・BBox、ComfyUI・NVFP4 で 8GB GPU 可）は、制限的ライセンスの事例として欠かせない。FLUX Kommmunity v1.0 の全文が確認でき、非商用＋ 500 万ドル未満の適格商用のみが出力利用可、派生物に蒸留・合成学習を含み、軍事・監視・生体認証の禁止、同種モデルの改善禁止といった運用条項がある。制限と実装量（BF16 11.1GB・NVFP4 5.3GB、9B アップスケーラは別体）が表裏一体になっており、画像モデルの実装可否を左右する。[?, ?, ?]

Granite の提供形態を確認する。一つのエンドポイントでほぼ基盤と同等の VRAM、共有 KV キャッシュ、vLLM と llama.cpp 対応、入れ替え可能な構成。合成の思想が、提供の形に表れている。30B 同型カードは未確認であり、あるものとないものを分ける。[?, ?, ?, ?]

重みの公開は進んだが、条件はまちまちである。Beam は全文確認の許容条件、FLUX は用途と派生を縛る条件、Spark は表示と収益門の計算が必要な条件、Nemotron は学習開示の厚さと未確認ファイルの留保、Granite と MiniCPM は合成と端末用途の試用に適したタグ確認の条件。実装の可否は重みの有無ではなく条件で決まる。使う側は自分の用途が表のどの行に属するかを確認し、契約判断の前に四つの確認水準（全文・条項・タグ・未確認）を照合してほしい。[?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?]

**表 1　比較表：重み・実装・ライセンス**

| | | | | |
|---|---|---|---|---|
| Spark Open | 816B/42B MoE・文脈 100 万・マルチモーダル入力 | 2×M5 Ultra 実装像（発行者） | Muse 条項：表示義務・2000 万ドル MaaS 門（ページ/鏡/解説で確認、原本完全バイトではない。個別配布物への適用は別途要確認）・OSI 非該当 [?, ?, ?, ?] | |
| Beam | 501B/23B MoE・文脈 100 万 | LICENSE 全文確認（最も許容的。独自表示バッジ義務なし。ただし Apache 2.0 の再配布条件＝ライセンス複製・著作権/帰属/NOTICE 保持・変更明示・特許・第三者条項は残る） | 安全報告は社内評価、第三者保証は未検証 [?, ?, ?, ?] | |
| Nemotron 3.5 | 120B/12B Mamba-2 ＋視覚 | MOPD/MTP/QAD 開示（発行者） | Bolt 74B 今・E4B 未来 | OpenMDW：Super VL 未開封、OSI 主張不可、EXO 不採用 [?, ?, ?, ?] |

# 1 エージェント工学:Codex・Scion・HydraFusion と運用ゲート

## 作る現場の生産性――Codex の実践、Scion の統合、HydraFusion の編成

OpenAI の Codex GPT-6 に関する保守実践の報告は、数字の出し方が珍しいほど具体的だ。1400 超のプルリクエスト、80 万行、Slack・Statsig・テレメトリを根拠にした死コード除去、コンテナ 3.31GB から 1.72GB（マイナス 48%）、400 件のスナップショット変種の削除。CI 中央値 10 分から 4.5 分、モック 592.6 秒から 29.8 秒（マイナス 95%、63 件のテスト維持）。ここまで書かれると実務の手触りがある。ただし単一チームの社内実践であり、発行者計測である。普遍的な開発加速の証拠として引用してはならない。[?]

Anthropic の Scion は、ソース管理の拡張という地味で巨大な主題だ。5 月 2500 件から 9 月には日 3 万超のマージ、7 人のチームによる 5 か月の移行。履歴 100GB 超、1 日 2500 万チェックアウト、単純な Git 実装では 1 日 600PB という規模感が示される。設計原則（常時オンラインのクライアント、非対称、API 問合せ、水平拡張、ロックフリーの増分コミット、疎な仮想チェックアウト）、変更セット WAL と派生データ、9 割超ヒットの階層キャッシュ、200 分の 1 の占有、秒単位の CI と 25%増の CI 処理能力。Mythos と Tag が共同で構築したという来歴も含めて、完全な工学物語になっている。[?, ?]

GitHub の HydraFusion（＋ Max）は、複数モデルの編成という一段抽象度の高い主題だ。タスクごとに選択させず、Opus 5.5・Astra・Sol・Luna のプールから経路づける。草案は軽め・査読は重めの労力調整、Cascade の判定段階、Critique の作業空間と並列批評。Max は労力を上げて編成効率で回収する位置づけで、VSCode・アプリ・CLI に研究プレビューとして提供され、上位プラン以上と組織方針が条件になる。プレビューであること、発行者の効率主張であることを留保つきで読む。[?, ?]

納品と検出のゲートは、混同してはならない二つだ。agentic autofix（10 月 15 日一般提供）は、ファイル横断の調査から修正案、CodeQL 再実行、ドラフト PR までの一連であり、Assign-to-Copilot が Generate Fix を置き換える。1PR あたり上限 25 件、既定ブランチのみ（PR・他ブランチ対象外）、REST の担当割当、Enterprise の方針ゲートと組織・リポジトリの有効化、Copilot 課金と AI Credit・Actions 分の消費。25 件・単一 PR・既定枝のみという制約は、無制限の自動化ではないことの宣言であり、使う現場を決める条件の束だ。[?, ?]

AI Scan for PRs（同日一般提供）は CodeQL の届かない言語（PHP・Shell・HCL・Dockerfile・JSP・Blazor 等）を補い、PR で自動実行、説明と修正提案を添える。ただし助言であり、チェックを失敗させず、マージを止められない。フォーク・Dependabot 対象外、個人・公開組織は可、非公開は Code Security 系が必要、Copilot ライセンス不要、AI Credit 消費。変更履歴の製品文書が根拠であり、第三者検証でも法文引用でもない。検出の助言と修正の PR を一つの「自動修正」の物語に畳んではならない。[?, ?]

Perplexity の Decider v1.2（10 月 16 日）は、版管理の手本として P4 を締める。Qwen3.8-27B 系統の 27B、v1.1 からの結合要求形式と学習データ変更、文脈 25.6 万、入力 100 万トークン 2 セント・出力無料、Decisions API（対話端点ではない）、v1.1 名の v1.2 課金、ネイティブのチェックポイント配置と pip 導入可能なソース。W41 の v1.1 からの継承が閉じている。精度の主張は発行者記載である。なお基盤名の Qwen3.8 表記は命名上の注意として添えられており、断定の根拠にはしない。[?, ?, ?]

表 2　比較表：生産性とゲートの条件

| | | | | |
|---|---|---|---|---|
| Codex 実践 | 社内単一チーム（発行者計測） | 容器-48%・CI 中央値 10 → 4.5 分 | 実験費表つき | 普遍加速の証拠ではない [?] |
| Scion | 社内システム（非公開、Git 代替ではない） | 日 3 万超マージ・占有 200 分の 1・秒級 CI | WAL・ロックフリー・階層キャッシュ | 来歴・版固定あり [?, ?] |
| HydraFusion | 研究プレビュー | 多モデル編成・経路づけ | 上位プラン・組織方針 [?, ?] | |
| AutoFix | 一般提供 | 調査→修正→再検査→ PR、上限 25・既定枝のみ | 課金・方針ゲート [?, ?] | |
| AI Scan | 一般提供 | 助言のみ、止められない | 製品文書が根拠 [?, ?] | |
| Decider v1.2 | 版継承閉鎖 | 2 セント/M 入力・出力無料 | 精度は発行者 [?, ?, ?] | |

# 2　安全性と透明性: 開示・蒸留・検証アクセス

## 開示・防御・解明・接近――安全の四つの局面

安全の四つの局面は、対象が違う。開示は起きた出来事、防御は効いたとされる仕組み、解明は閉じた謎、接近は評価に近づく仕組みである。三つに畳むと、評価アクセスが出来事の列に混ざってしまう。本節は四つを分けて読む。[?, ?, ?, ?, ?, ?, ?, ?]