Japanese Generative AI Technical Survey

2026-W42

2026-10-18

重み・生産性

オープンウェイト、エージェント工学。

NONCANONICAL DIAGNOSTIC
NOT A PUBLICATION PREVIEW
NOT FOR HUMAN APPROVAL

Editorial cutoff	2026-10-09 18:00 - 2026-10-16 18:00 America/New_York
Repository	eariver/japanese-generative-ai-survey
Build	LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey（診断用・非正準・未承認）。

MiniCPM-V 4.7（35B-A3B 初の MoE、LES による非可逆なしオンデバイス MoE、iPhone 17 Pro Max で 3GB・毎秒 13 トークン超）は、携帯端末実装の事例だ。BF16・FP8・int4・AWQ・GPTQ・GGUF と日付つき README（12 日・15 日）、SGLang・vLLM・llama.cpp・Ollama 対応、SRFT 微調整。使う側の選択肢が具体的に並んでいる。Apache 2.0 はこちらもタグ確認のみであり、ファイル未確認の限界を Granite と同様に明記する。[?, ?, ?]

FLUX 3 Image Klein（5.6B、Qwen3-VL-4B エンコーダ、蒸留 16 ステップと基盤 50 ステップの使い分け、4K・BBox、ComfyUI・NVFP4 で 8GB GPU 可）は、制限的ライセンスの事例として欠かせない。FLUX Kommmunity v1.0 の全文が確認でき、非商用＋ 500 万ドル未満の適格商用のみが出力利用可、派生物に蒸留・合成学習を含み、軍事・監視・生体認証の禁止、同種モデルの改善禁止といった運用条項がある。制限と実装量（BF16 11.1GB・NVFP4 5.3GB、9B アップスケーラは別体）が表裏一体になっており、画像モデルの実装可否を左右する。[?, ?, ?]

Granite の提供形態を確認する。一つのエンドポイントでほぼ基盤と同等の VRAM、共有 KV キャッシュ、vLLM と llama.cpp 対応、入れ替え可能な構成。合成の思想が、提供の形に表れている。30B 同型カードは未確認であり、あるものとないものを分ける。[?, ?, ?, ?]

重みの公開は進んだが、条件はまちまちである。Beam は全文確認の許容条件、FLUX は用途と派生を縛る条件、Spark は表示と収益門の計算が必要な条件、Nemotron は学習開示の厚さと未確認ファイルの留保、Granite と MiniCPM は合成と端末用途の試用に適したタグ確認の条件。実装の可否は重みの有無ではなく条件で決まる。使う側は自分の用途が表のどの行に属するかを確認し、契約判断の前に四つの確認水準（全文・条項・タグ・未確認）を照合してほしい。[?, ?]

表 1　比較表：重み・実装・ライセンス

Spark Open	816B/42B MoE・文脈 100 万・マルチモーダル入力	2×M5 Ultra 実装像（発行者）	Muse 条項：表示義務・2000 万ドル MaaS 門（ページ/鏡/解説で確認、原本完全バイトではない。個別配布物への適用は別途要確認）・OSI 非該当 [?, ?, ?, ?]	
Beam	501B/23B MoE・文脈 100 万	LICENSE 全文確認（最も許容的。独自表示バッジ義務なし。ただし Apache 2.0 の再配布条件＝ライセンス複製・著作権/帰属/NOTICE 保持・変更明示・特許・第三者条項は残る）	安全報告は社内評価、第三者保証は未検証 [?, ?, ?, ?]	
Nemotron 3.5	120B/12B Mamba-2＋視覚	MOPD/MTP/QAD 開示（発行者）	Bolt 74B 今・E4B 未来	OpenMDW：Super VL 未開封、OSI 主張不可、EXO 不採用 [?, ?, ?, ?]
Granite Switch 4.1	8B+30B 合成・共有 KV	Decision Index 42.9	Apache タグのみ（ファイルなし） [?, ?, ?, ?]	
MiniCPM-V 4.7	35B-A3B MoE・端末毎秒 13 トークン超	Apache タグのみ（ファイルなし） [?, ?, ?]		
FLUX 3 Klein	5.6B・蒸留 16 段階	Kommunity 全文：非商用＋ 500 万未満適格商用のみ、蒸留派生含む、軍事等禁止 [?, ?, ?]		

1　エージェント工学:Codex・Scion・HydraFusion と運用ゲート

作る現場の生産性――Codex の実践、Scion の統合、HydraFusion の

編成

OpenAI の Codex GPT-6 に関する保守実践の報告は、数字の出し方が珍しいほど具体的だ。1400 超のプルリクエスト、80 万行、Slack・Statsig・テレメトリを根拠にした死コード除去、コンテナ 3.31GB から 1.72GB（マイナス 48%）、400 件のスナップショット変種の削除。CI 中央値 10 分から 4.5 分、モック 592.6 秒から 29.8 秒（マイナス 95%、63 件のテスト維持）。ここまで書かれると実務の手触りがある。ただし単一チームの社内実践であり、発行者計測である。普遍的な開発加速の証拠として引用してはならない。[?]

Perplexity の Decider v1.2（10 月 16 日）は、版管理の手本として P4 を締める。Qwen3.8-27B 系統の 27B、v1.1 からの結合要求形式と学習データ変更、文脈 25.6 万、入力 100 万トークン 2 セント・出力無料、Decisions API（対話端点ではない）、v1.1 名の v1.2 課金、ネイティブのチェックポイント配置と pip 導入可能なソース。W41 の v1.1 からの継承が閉じている。精度の主張は発行者記載である。なお基盤名の Qwen3.8 表記は命名上の注意として添えられており、断定の根拠にはしない。[?, ?, ?]

表 2　比較表：生産性とゲートの条件

Codex 実践	社内単一チーム（発行者計測）	容器-48%・CI 中央値 10 → 4.5 分	実験費表つき	普遍加速の証拠ではない [?]
Scion	社内システム（非公開、Git 代替ではない）	日 3 万超マージ・占有 200 分の 1・秒級 CI	WAL・ロックフリー・階層キャッシュ	来歴・版固定あり [?, ?]
HydraFusion	研究プレビュー	多モデル編成・経路づけ	上位プラン・組織方針 [?, ?]	
AutoFix	一般提供	調査→修正→再検査→ PR、上限 25・既定枝のみ	課金・方針ゲート [?, ?]	
AI Scan	一般提供	助言のみ、止められない	製品文書が根拠 [?, ?]	
Decider v1.2	版継承閉鎖	2 セント/M 入力・出力無料	精度は発行者 [?, ?, ?]	

【読み方の注意】Codex・Scion・HydraFusion の数値は社内発行者計測であり、対照実験ではない。AI Scan の変更履歴は製品文書であり、検証や法文ではない。Decider の基盤名表記は命名注意つきである。

[?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?]

2　安全性と透明性: 開示・蒸留・検証アクセス

開示・防御・解明・接近――安全の四つの局面

安全の四つの局面は、対象が違う。開示は起きた出来事、防御は効いたとされる仕組み、解明は閉じた謎、接近は評価に近づく仕組みである。三つに畳むと、評価アクセスが出来事の列に混ざってしまう。本節は四つを分けて読む。[?, ?, ?, ?, ?, ?, ?, ?]