
Japanese Generative AI Technical Survey

SP-2023-Y

Special / Coverage 2023-01-01 – 2023-12-31 / Retrospective as of 2026-08-16

モデルから、生成 AI システムの時代へ

2023 年、生成 AI の競争はモデル単体の性能から、長文脈とマルチモーダルな利用、公開モデルの生態系、外部機能への接続、学習・推論を支える実装層までを組み合わせる多層の設計競争へ広がった。

フロンティア競争は性能表から長文脈・マルチモーダルなインタラクションへ / LLaMA から Mixtral へ——open weights が単一モデルではなく生態系になった / 生成から行動へ——Plugin、Function Calling、Tool Use が API 層を作った

Editorial cutoff

Coverage window: 2023-01-01 – 2023-12-31 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Retrospective

Survey。

Retrospective Signals

フロンティア競争の軸がインタラクションへ広がった 長い入力や画像を含む入力、提供形態までが同時に設計対象となり、単一の性能指標では捉えにくい競争へ移った。 [p. 4](#)

公開モデルは単発の配布物から生態系へ変わった 公開範囲、利用条件、専門化、規模、言語、効率の異なる系列が並走し、用途と計算資源に応じた選択肢が増えた。 [p. 8](#)

生成の外側に実行と運用の層が立ち上がった 外部機能を選ぶ仕組みと安全に実行する境界、限られた資源で適応・推論・配信する仕組みが、モデル能力とは別の設計問題として前面に出た。

[p. 12](#) / [p. 15](#)

設計空間と生成メディアが同時に分岐した 推論時探索、学習後最適化、検索制御、代替アーキテクチャが別々の研究面を広げる一方、画像・動画生成はモデル公開、製品統合、制作工程へと展開した。 [p. 18](#) / [p. 21](#)

能力を測り、制御する仕組みが技術史の一部になった 共通の比較基盤と、人間の選好を含む評価、能力向上と運用条件を結び付ける制御の枠組みが、強いモデルを扱う独立した技術層として現れた。 [p. 24](#) / [p. 31](#)

Retrospective scope

本号は 2023 年を後日確認可能になった一次情報も用いて再構成する Retrospective Special である。Coverage Period と制作時点を同一視せず、vendor / project / author claim の境界は各記事と Technical Notes で明示する。

目次

Retrospective Signals	2
1 フロンティア競争は、性能表からインタラクション設計へ	4
Theme at a glance	5
2 LLaMA から Mixtral へ——open weights は生態系になった	8
Theme at a glance	9
3 生成から行動へ——Tool Use が API 層を作った	12
Theme at a glance	13
4 モデルを動かす技術が競争軸になった	15
Theme at a glance	15
5 推論・検索・学習後最適化、そして Transformer の外側へ	18
Theme at a glance	18
6 生成メディアが、独立した製品・モデルスタックになった	21
Theme at a glance	21

7	能力を測り、制御する層が追いつき始めた	24
	Theme at a glance	25
8	Detailed Chronology——圧縮した物語の外側に、出来事を残す	27
	Theme at a glance	30
9	2023 年総括——「モデル」から「システム／生態系」へ	31
	Theme at a glance	31

1 フロンティア競争は、性能表からインタラクション設計へ

2023 年のフロンティアモデル競争では、単一の能力指標だけでなく、長い入力、画像を含む入力、API や製品を介した利用形態までが同時に設計対象になった。GPT-4 系、Claude 系、PaLM 2 から Gemini への流れを、モデルそのものとユーザーが触れるインタラクション層を分けて読む。[1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14]

2023 年の重要な変化は、フロンティアモデルの比較対象が「どのモデルが最も賢いか」という一軸から外れたことである。GPT-4 系、Claude 系、Google の PaLM 2 から Gemini への展開は、モデル能力だけでなく、入力可能な情報の種類、扱える文脈、API や製品への配置を含む複合的な競争を可視化した。[1, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14]

長い context window は、それだけで長文脈を一様に有効利用できることを意味しない。年内には長文脈を前面に出す製品更新が続く一方、Lost in the Middle のような研究は、入力長の上限と情報を実際に取り出して使えることを区別すべきだという技術的境界を示した。[1, 2, 4, 6, 7, 9, 10, 12, 14]

multimodal という語も、モデル内部の表現と製品インターフェースを分けて扱う必要がある。GPT-4V や Gemini のようなモデル系列

の展開と、画像・音声を受け付ける製品機能は同じ時点・同じ提供範囲とは限らない。本稿では「モデルが何を扱えると発表されたか」と「利用者がどの形で使えたか」を別の状態として記述する。[3, 5, 6, 7, 8, 10, 13, 14]

研究発表、モデル発表、preview、API 提供、端末や製品への配置は別々の出来事である。2023 年のフロンティア競争を後知恵で一本化せず、それぞれの時点で公開されていた提供形態を保存することで、技術的能力と実利用可能性を混同しない。[1, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14]

Claim boundary

各社や著者が提示した性能・能力評価は一次資料に帰属する主張であり、本稿はそれを独立再現した比較順位へ換算しない。ここで比較するのは、2023 年にどの設計面が競争軸として現れたかである。[3, 5, 8, 13]

SOURCE-BACKED TECHNICAL NOTES

フロンティア競争は性能表から長文脈・マルチモーダルなインタラクションへ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
GPT-4 / GPT-4V 2023 lifecycle	主要資料	モデル更新	—
Claude 2023 model family	主要資料	モデル更新	—
Gemini 2023 launch family	主要資料	モデル	—
PaLM 2	補足資料	モデル	—
Lost in the Middle	補足資料	論文	—

GPT-4 / GPT-4V 2023 lifecycle

主要資料

組織 OpenAI

種別 モデル更新

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「GPT-4 / GPT-4V 2023 lifecycle」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2303.08774v6>
- <https://openai.com/index/chatgpt-can-now-see-hear-and-speak>
- <https://openai.com/index/gpt-4-research>
- <https://openai.com/index/gpt-4v-system-card>

Claude 2023 model family

主要資料

組織 Anthropic

種別 モデル更新

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「Claude 2023 model family」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://www.anthropic.com/news/100k-context-windows>
- <https://www.anthropic.com/news/claude-2>
- <https://www.anthropic.com/news/claude-2-1>
- <https://www.anthropic.com/news/introducing-claude>

Gemini 2023 launch family

主要資料

組織 Google

種別 モデル

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Gemini 2023 launch family」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2312.11805v5>
- <https://blog.google/innovation-and-ai/products/gemini-api-developers-cloud/>
- <https://blog.google/innovation-and-ai/technology/ai/google-gemini-ai/>
- <https://blog.google/products-and-platforms/devices/pixel/pixel-feature-drop-december-2023/>

PaLM 2

補足資料

組織 Google

種別 モデル

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「PaLM 2」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://blog.google/innovation-and-ai/products/google-palm-2-ai-large-language-model/>

Lost in the Middle**補足資料**

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Lost in the Middle」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2307.03172v3>

2 LLaMA から Mixtral へ——open weights は生態系になった

2023 年は、公開された weights を起点に、規模、言語、専門化、効率、配布条件の異なるモデル系列が並走し始めた年だった。LLaMA/Llama 2、Falcon、Qwen、Mistral/Mixtral を通じて、open weights を open source や open training と同一視せず、その多様化を追う。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

open という一語で括られがちなモデル群の公開範囲は同じではない。weights が取得できること、利用条件が広いこと、学習データや学習手順まで再現可能であることは別の軸である。2023 年の open-weight 拡大は、単一の公開モデルが現れたというより、異なる公開境界を持つ複数の系列が競争可能になった出来事として読む方が正確である。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

モデルの技術的特徴だけでなく、license と access の条件が利用可能性を規定する。Llama 2 以降の広い利用、Falcon や Qwen など他系列の登場、Mistral 系の公開は、weights 公開の有無だけでは説明できない実装・再配布上の差を伴う。したがって本稿では「open」という形容ではなく、公開された成果物と利用条件を分けて記述する。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

年の進行とともに、open-weight モデルは単

発の base model から family へ拡張した。汎用モデルに加え、instruction tuning、code などの専門化、複数サイズ、複数言語への展開が進み、利用者は一つの代表モデルを選ぶのではなく、用途と計算資源に合わせて系列内外を比較するようになった。[15, 17, 18, 19, 22, 23, 24, 25, 26, 27, 28]

年末の Mixtral は、この多様化に architecture の選択肢をさらに加えた。ここで重要なのは MoE が既存方式を置き換えた結論ではなく、公開 weights の世界でも parameter count だけでない効率設計が主要な比較軸へ入った点である。[15, 27, 28]

Claim boundary

各プロジェクトや著者による性能比較は、その評価条件に基づく主張として扱う。公開範囲が広いことも、性能や再現性が自動的に保証されることを意味しない。[17, 18, 22, 23, 24, 25]

SOURCE-BACKED TECHNICAL NOTES

LLaMA から Mixtral へ——open weights が単一モデルではなく生態系になった: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
LLaMA / Llama 2 / Code Llama 2023	主要資料	オープンウェイト	—
Mistral 7B / Mixtral	主要資料	オープンウェイト	—
Falcon 40B / 180B	補足資料	オープンウェイト	—
Qwen 2023 family	補足資料	オープンウェイト	—

LLaMA / Llama 2 / Code Llama 2023		主要資料
組織	Meta	
種別	オープンウェイト	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「LLaMA / Llama 2 / Code Llama 2023」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		
読む際の境界		
分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。		
一次資料		
http://arxiv.org/abs/2302.13971v1 http://arxiv.org/abs/2307.09288v2 http://arxiv.org/abs/2308.12950v3 https://ai.meta.com/blog/code-llama-large-language-model-coding/ https://ai.meta.com/blog/large-language-model-llama-meta-ai/ https://ai.meta.com/blog/llama-2/		

Mistral 7B / Mixtral		主要資料
組織	Mistral AI	
種別	オープンウェイト	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「Mistral 7B / Mixtral」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2310.06825v1>
- <https://mistral.ai/news/announcing-mistral-7b/>
- <https://mistral.ai/news/mixtral-of-experts/>

Falcon 40B / 180B

補足資料

組織 Technology Innovation Institute

種別 オープンウェイト

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Falcon 40B / 180B」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2311.16867v2>
- <https://www.tii.ae/index.php/news/uaes-technology-innovation-institute-launches-open-source-falcon-40b-large-language-model>
- <https://www.tii.ae/news/technology-innovation-institute-introduces-worlds-most-powerful-open-llm-falcon-180b>

Qwen 2023 family

補足資料

組織 Qwen Team

種別 オープンウェイト

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Qwen 2023 family」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2309.16609v1>
- <https://qwenlm.github.io/blog/qwen/>

3 生成から行動へ——Tool Use が API 層を作った

2023 年には、言語モデルが文章を返すだけでなく、外部機能を選び、構造化された呼び出しへ接続する設計が製品・API の中心へ入った。Toolformer の研究的発想と OpenAI の Plugins、Function Calling、GPTs/Assistants の展開を、tool selection と実行主体を分けて整理する。[\[29, 30, 31, 32, 33\]](#)

tool use では、モデルが「何と呼ぶべきか」を決めることと、外部システムが実際に副作用を伴う処理を実行することを分ける必要がある。自然言語の生成能力が高くても、実行権限、引数検証、失敗時の扱いは別の system layer である。[\[29, 30, 31, 32, 33\]](#)

Toolformer はモデルが外部ツール利用を学習する研究方向を示した。一方、Plugins や Function Calling は開発者が接続先と構造を定義する製品・API 面の仕組みである。両者は同じ「tool use」という語で呼べても、研究上の問いと配備上の責任分界は異なる。[\[29, 30, 31, 32, 33\]](#)

Function Calling のような構造化インターフェースは、自由文から外部実行へ直接飛ぶのではなく、モデル出力を機械可読な境界へ落とし込む考え方を前面に出した。この境界は利便性だけでなく、検証、再試行、権限管理を実装する場所にもなる。[\[30, 31, 32, 33\]](#)

年末までに GPTs や Assistants へ連なる製品面が現れたことで、tool access は個別デモではなく application-facing layer として認識されやすくなった。2023 年の転換は「モデルが何でも自律実行できるようになった」ことではなく、生成と実行の間に明示的な interface が必要だと広く実装されたことである。[\[30, 31, 32, 33\]](#)

Claim boundary

tool-use の信頼性や有効性に関する評価は、研究・プロジェクト・vendor の条件に依存する。本稿では機構の成立と公開形態を扱い、それらの性能主張を独立再現済みの事実とはみなさない。[\[30, 31, 32, 33\]](#)

SOURCE-BACKED TECHNICAL NOTES

生成から行動へ——Plugin、Function Calling、Tool Use が API 層を作った: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
OpenAI tool/action surface 2023	主要資料	API	—
Toolformer	補足資料	論文	—

OpenAI tool/action surface 2023

主要資料

組織 OpenAI

種別 API

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「OpenAI tool/action surface 2023」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://openai.com/index/chatgpt-plugins>
- <https://openai.com/index/function-calling-and-other-api-updates>
- <https://openai.com/index/introducing-gpts>
- <https://openai.com/index/new-models-and-developer-products-announced-at-devday>

Toolformer

補足資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Toolformer」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2302.04761v1>

4 モデルを動かす技術が競争軸になった

2023 年には、モデルの規模や能力だけでなく、限られた memory でどう適応させ、attention をどう高速化し、同時要求をどう捌くかが実用性を左右する独立した技術面になった。QLoRA、FlashAttention-2、vLLM/PagedAttention、Phi-2 を、学習・推論・serving の異なる制約への応答として読む。[34, 35, 36, 37, 38, 39]

QLoRA が向き合うのは主として既存モデルを限られた計算資源で fine-tuning する側の制約であり、FlashAttention-2 は attention 計算の効率、vLLM/PagedAttention は推論時の memory 管理と serving を主眼とする。同じ「効率化」でも、最適化する段階とボトルネックは異なる。[34, 35, 37, 38, 39]

モデルが一度応答できることと、多数の要求を安定して処理できることも別問題である。vLLM/PagedAttention の登場は、KV-cache を含む runtime 側の資源管理が、モデル選定と同じ程度に deployment 設計へ影響しうることを可視化した。[34, 38, 39]

Phi-2 のような小型モデルへの関心は、parameter scale だけを増やす以外の設計空間も示した。ここでは小型であること自体を優位性と断定せず、data quality や用途、hardware

制約と組み合わせて「必要な能力をどの資源予算で実現するか」という問いが強まったことを重視する。[36]

Claim boundary

QLoRA、FlashAttention-2、vLLM、Phi-2 に関する速度・memory・品質などの数値は、それぞれの著者や project/vendor が設定した実験条件に依存する。異なる hardware・workload・benchmark を横断して一つの優劣表へ変換しない。[34, 35, 36, 37, 38, 39]

2023 年の systems 面の変化は、モデル能力を「学習済み weights の属性」だけで語れなくなった。適応コスト、kernel、cache、serving、モデルサイズが相互に作用し、同じモデルでも運用可能性が大きく変わるという認識が、研究と実装の両側で前面に出た。[34, 35, 36, 37, 38, 39]

SOURCE-BACKED TECHNICAL NOTES

モデルを動かす技術が競争軸になった——QLoRA、FlashAttention-2、vLLM: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
vLLM / PagedAttention	主要資料	Framework	—
QLoRA	主要資料	論文	—
FlashAttention-2	主要資料	論文	—
Phi-2	補足資料	モデル	—

vLLM / PagedAttention		主要資料
組織	vLLM Project	
種別	Framework	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「vLLM / PagedAttention」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		
読む際の境界		
分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。		
一次資料		
http://arxiv.org/abs/2309.06180v1 https://github.com/vllm-project/vllm/releases/tag/v0.1.3 https://vllm.ai/blog/2023-06-20-vllm		

QLoRA		主要資料
組織	authors	
種別	論文	
時系列	—	
一次資料から整理した technical points		
Author claim: 一次資料で「QLoRA」が2023年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。		
読む際の境界		
分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。		
一次資料		
http://arxiv.org/abs/2305.14314v1		

FlashAttention-2		主要資料
組織	authors	
種別	論文	
時系列	—	
一次資料から整理した technical points		
Author claim: 一次資料で「FlashAttention-2」が2023年の技術動向として記録されて		

いることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2307.08691v1>

Phi-2

補足資料

組織 Microsoft Research

種別 モデル

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Phi-2」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://www.microsoft.com/en-us/research/blog/phi-2-the-surprising-power-of-small-language-models/>

5 推論・検索・学習後最適化、そして Transformer の外側へ

2023 年の研究は、一つの「次世代 LLM 手法」へ収束したのではない。Tree of Thoughts、DPO、Self-RAG、Mamba は、それぞれ推論時探索、post-training、retrieval-control、sequence architecture という異なる層を広げた。設計空間の拡張として並べることで、何が同じ問題で何が別問題かを明確にする。[40, 41, 42, 43]

Tree of Thoughts は、単一の逐次生成だけでなく、複数の候補状態を探索・評価する推論時の計算構造を研究対象にした。この方向は「モデルそのものを大きくする」以外に、推論プロセスの編成で結果を変える設計余地があることを示す。[42]

DPO は pretraining や推論時探索とは異なり、人間の選好情報を用いる post-training の設計を簡素化する方向に位置する。ここで扱うのはモデルが推論中に考える方法ではなく、どの応答傾向を学習後に選好させるかという別レイヤである。[40]

Self-RAG は retrieval を常時付加する固定 pipeline ではなく、生成過程と検索・自己評価を結び付ける制御問題として扱う方向を示した。retrieval の有無、参照結果の使い方、生成

の自己点検を一つの system loop として設計する発想である。[43]

Mamba は年末に、attention 中心の Transformer とは異なる sequence modeling の選択肢として注目を集めた。ただし 2023 年時点の Evidence から「Transformer が置き換えられた」と結論することはできない。重要なのは、長い sequence と計算効率をめぐる architecture 探索が再び広がったことである。[41]

Claim boundary

各論文・project が報告する性能向上は、それぞれの課題設定と評価条件に基づく。ここでは互いに異なるレイヤの研究を共通

ランキングへ置かず、2023 年に設計可能な場所が増えたという年次的意味を抽出する。[42]

SOURCE-BACKED TECHNICAL NOTES

推論・検索・学習後最適化、そして Transformer の外側へ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Tree of Thoughts	主要資料	論文	—
Direct Preference Optimization (DPO)	主要資料	論文	—
Self-RAG	主要資料	論文	—
Mamba	主要資料	論文	—

Tree of Thoughts

主要資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Tree of Thoughts」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2305.10601v2>

Direct Preference Optimization (DPO)

主要資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Direct Preference Optimization (DPO)」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2305.18290v3>

Self-RAG

主要資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Self-RAG」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2310.11511v1>

Mamba**主要資料**

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Mamba」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://arxiv.org/abs/2312.00752>

6 生成メディアが、独立した製品・モデルスタックになった

2023 年の画像・動画生成では、単発の研究デモだけでなく、open model、API、会話 UI、既存制作ソフトへの統合という複数の公開形態が並んだ。DALL-E 3、SDXL/Turbo、Stable Video Diffusion、Adobe Firefly/Generative Fill を通じて、生成メディアが独立した技術・製品層へ分岐した過程を追う。[44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55]

生成メディアの進歩は「新しい画像モデルが出た」という一列の出来事ではない。DALL-E 3 は会話型製品との接続、SDXL 系は model release と高速化、Stable Video Diffusion は動画生成、Firefly は既存クリエイティブツールとの統合という異なる surface を持つ。[44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55]

研究・モデル公開、API 提供、製品機能への統合は区別すべきである。ユーザーが利用できる生成機能の価値は model quality だけでなく、prompt 作成支援、編集 workflow、配布形態、既存アプリケーションとの接続によっても変わる。[44, 47, 48, 50, 51, 52, 53, 54, 55]

画像生成と動画生成も同じ成熟度として扱えない。Stable Video Diffusion の登場は、画像で進んだ生成モデルの公開・利用パターンが

動画へ拡張され始めたことを示すが、対象となる出力、計算量、評価方法、製品化の境界は異なる。[44, 45, 46, 47, 49, 50, 52, 55]

SDXL Turbo のような高速化方向や Generative Fill のような編集統合は、生成品質だけでなく iteration time と workflow への組み込みが競争軸になることを示した。生成モデルは単体アプリではなく、制作工程の一部として評価され始めた。[44, 47, 48, 50, 52, 53, 55]

Claim boundary

画質、速度、創造性、安全性などの比較値は、各 vendor/project/author の条件に依存する。本稿は release 形態と技術方向を整

理し、異なる評価条件を独立した共通ランキングへ換算しない。[51, 54]

SOURCE-BACKED TECHNICAL NOTES

生成メディアが独立した製品・モデルスタックへ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
DALL-E 3 2023 lifecycle	主要資料	モデル	—
Stable Diffusion XL / SDXL Turbo 2023	主要資料	モデル更新	—
Stable Video Diffusion 2023	主要資料	モデル	—
Adobe Firefly / Generative Fill	主要資料	PRODUCT	—

DALL-E 3 2023 lifecycle

主要資料

組織 OpenAI

種別 モデル

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「DALL-E 3 2023 lifecycle」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://openai.com/index/dall-e-3-is-now-available-in-chatgpt-plus-and-enterprise>
- <https://openai.com/index/dall-e-3-system-card>

Stable Diffusion XL / SDXL Turbo 2023

主要資料

組織 Stability AI

種別 モデル更新

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「Stable Diffusion XL / SDXL Turbo 2023」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2307.01952v1>
- <http://arxiv.org/abs/2311.17042v1>
- <https://stability.ai/news-updates/stability-ai-sdxl-turbo>
- <https://stability.ai/news-updates/stable-diffusion-sdxl-1-announcement>
- <https://stability.ai/news-updates/stable-diffusion-xl-beta-available-for-api-customers-and-dreamstudio-users>

Stable Video Diffusion 2023

主要資料

組織 Stability AI

種別 モデル

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「Stable Video Diffusion 2023」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2311.15127v1>
- <https://stability.ai/news-updates/introducing-stable-video-diffusion-api>
- <https://stability.ai/news-updates/stable-video-diffusion-open-ai-video-model>

Adobe Firefly / Generative Fill

主要資料

組織 Adobe

種別 製品

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「Adobe Firefly / Generative Fill」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://news.adobe.com/news/news-details/2023/adobe-unveils-firefly-a-family-of-new-creative-generative-ai>
- <https://news.adobe.com/news/news-details/2023/adobe-unveils-future-of-creative-cloud-with-generative-ai-as-a-creative-co-pilot-in-photoshop>

7 能力を測り、制御する層が追いつき始めた

強いモデルが増えるほど、「何が強いのかをどう比較するか」と「どの能力をどの条件で運用するか」が独立した問題になった。Chatbot Arena/MT-Bench と、OpenAI・Anthropic の alignment / governance 面の取り組みを、evaluation layer と control layer の形成として並べる。[56, 57, 58, 59, 60, 61, 62, 63, 64]

Chatbot Arena と MT-Bench は、モデル比較を個々の発表資料だけに閉じず、複数モデルを同じ評価 surface へ載せる方向を押し出した。とくに人間の選好を含む比較は、単一の自動 benchmark とは異なる情報を与える一方、それ自体が絶対的な能力真値になるわけではない。[56, 57, 63]

OpenAI と Anthropic の年内の alignment / governance 関連の取り組みは、モデルの能力向上とは別に、利用・評価・scale-up の条件を定義する control surface が必要だという問題設定を明示した。研究結果、内部評価、公開 policy は同じ証拠種別ではないため、本稿では区別して扱う。[58, 59, 60, 61, 62, 64]

benchmark score や human preference は、task 設計、prompt、比較対象、評価者構成などに依存する。Arena/MT-Bench を共通比較基盤として評価しても、そこから全用途の総合順位を導くことはしない。[56, 57, 63]

年末に向かうにつれ、将来のより強い能力をどの threshold で評価し、どの運用条件と結び付けるかが公開 policy の論点として前面に出た。ここで重要なのは具体的な安全性が達成済みとみなすことではなく、capability growth と control obligation を結び付ける枠組み自体が明示されたことである。[58, 59, 60, 61, 62, 64]

Claim boundary

評価結果と安全・alignment 上の主張は、それぞれの project/vendor が示した条件と範囲に帰属する。本稿は policy の存在や問題設定を一次資料で確認するが、有効性を独立に実証したとは扱わない。[58, 61, 62, 64]

SOURCE-BACKED TECHNICAL NOTES

能力を測り、制御する層が追いつき始めた: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Chatbot Arena / MT-Bench	主要資料	評価ベンチマーク	—
OpenAI 2023 alignment and agent-governance work	主要資料	安全性関連	—
Anthropic Constitutional AI / Responsible Scaling Policy	主要資料	安全性関連	—

Chatbot Arena / MT-Bench		主要資料
組織	LMSYS Org	
種別	評価ベンチマーク	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「Chatbot Arena / MT-Bench」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		
読む際の境界		
分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。		
一次資料		
http://arxiv.org/abs/2306.05685v4 https://www.lmsys.org/blog/2023-05-03-arena/ https://www.lmsys.org/blog/2023-06-22-leaderboard/		

OpenAI 2023 alignment and agent-governance work		主要資料
組織	OpenAI	
種別	安全性事象	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「OpenAI 2023 alignment and agent-governance work」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://openai.com/index/frontier-risk-and-preparedness>
- <https://openai.com/index/improving-mathematical-reasoning-with-process-supervision>
- <https://openai.com/index/practices-for-governing-agentic-ai-systems>
- <https://openai.com/index/weak-to-strong-generalization>

Anthropic Constitutional AI / Responsible Scaling Policy

主要資料

組織

Anthropic

種別

安全性事象

時系列

—

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Anthropic Constitutional AI / Responsible Scaling Policy」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://www.anthropic.com/news/anthropics-responsible-scaling-policy>
- <https://www.anthropic.com/news/claudes-constitution>

8 Detailed Chronology—圧縮した物語の外側に、出来事を残す

年間本文は story と trajectory へ圧縮するが、歴史記録としては release、paper initial publication、preview、API/product availability、policy/control milestone を同一視できない。本節では、年次叙述で失われやすい event-level の差を読むための基準を明示する。

日付は一次資料または論文メタデータで確認できた公開時点を採用し、後年の提供状態を遡及して補わない。

1 月

2023-01-30

BLIP-2: Bootstrapping Language-Image
Pre-training with Frozen Image Encoders and
Large Language Models

2 月

2023-02-09

Toolformer: Language Models Can Teach
Themselves to Use Tools

2023-02-24

Introducing LLaMA

2023-02-27

LLaMA: Open and Efficient Foundation
Language Models

3 月

2023-03-14

Introducing Claude

2023-03-14

GPT-4

2023-03-15

GPT-4 Technical Report

2023-03-20

Reflexion: Language Agents with Verbal
Reinforcement Learning

2023-03-21

Adobe Firefly

2023-03-23

ChatGPT plugins

2023-03-30

Vicuna

4 月

2023-04-13

Stable Diffusion XL beta

2023-04-17

Visual Instruction Tuning

5 月

2023-05-03

Chatbot Arena

2023-05-09

Claude's Constitution

2023-05-10

PaLM 2

2023-05-11

Introducing 100K Context Windows

2023-05-17

Tree of Thoughts: Deliberate Problem Solving
with Large Language Models

2023-05-18

LIMA: Less Is More for Alignment

2023-05-23

Generative Fill in Photoshop

2023-05-23

QLoRA: Efficient Finetuning of Quantized LLMs

2023-05-24

Gorilla: Large Language Model Connected with Massive APIs

2023-05-25

Falcon 40B open-source release

2023-05-29

Direct Preference Optimization: Your Language Model is Secretly a Reward Model

2023-05-31

Improving mathematical reasoning with process supervision

6 月**2023-06-05**

Orca: Progressive Learning from Complex Explanation Traces of GPT-4

2023-06-08

Simple and Controllable Music Generation

2023-06-09

OpenAI-compatible local API server with open models

2023-06-09

Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena

2023-06-13

Function calling and other API updates

2023-06-20

vLLM: Easy, Fast, and Cheap LLM Serving with PagedAttention

2023-06-22

MT-Bench and Chatbot Arena leaderboard

7 月**2023-07-04**

SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis

2023-07-06

Lost in the Middle: How Language Models Use Long Contexts

2023-07-11

Claude 2

2023-07-17

FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning

2023-07-18

Llama 2

2023-07-18

Llama 2: Open Foundation and Fine-Tuned Chat Models

2023-07-26

Stable Diffusion XL 1.0

8 月**2023-08-02**

AudioCraft

2023-08-02

vLLM v0.1.3

2023-08-24

Code Llama

2023-08-24

Code Llama: Open Foundation Models for Code

9 月**2023-09-06**

Falcon 180B

2023-09-12Efficient Memory Management for Large
Language Model Serving with PagedAttention**2023-09-19**

Anthropic's Responsible Scaling Policy

2023-09-19

Baichuan 2: Open Large-scale Language Models

2023-09-25

ChatGPT can now see, hear, and speak

2023-09-25

GPT-4V(ision) system card

2023-09-27

Announcing Mistral 7B

2023-09-28

Qwen Technical Report

10 月**2023-10-03**

DALL · E 3 system card

2023-10-05Improved Baselines with Visual Instruction
Tuning**2023-10-10**

Mistral 7B

2023-10-17Self-RAG: Learning to Retrieve, Generate, and
Critique through Self-Reflection**2023-10-19**DALL · E 3 is now available in ChatGPT Plus
and Enterprise**2023-10-26**

Frontier risk and preparedness

11 月**2023-11-06**

Introducing GPTs

2023-11-06New models and developer products announced
at DevDay**2023-11-21**

Claude 2.1

2023-11-21

Stable Video Diffusion

2023-11-25Stable Video Diffusion: Scaling Latent Video
Diffusion Models to Large Datasets**2023-11-28**

SDXL Turbo

2023-11-28

The Falcon Series of Open Language Models

2023-11-28

Adversarial Diffusion Distillation

12 月**2023-12-01**Mamba: Linear-Time Sequence Modeling with
Selective State Spaces**2023-12-06**

Gemini Nano on Pixel

2023-12-06

Introducing Gemini	Practices for Governing Agentic AI Systems
2023-12-11	2023-12-19
Mixtral of Experts	Gemini: A Family of Highly Capable Multimodal Models
2023-12-12	2023-12-20
Phi-2: The surprising power of small language models	Stable Video Diffusion API
2023-12-13	
Gemini API for developers	
2023-12-14	
Weak-to-strong generalization	
2023-12-14	

日付精度の境界

公開日の精度を一次記録から確定できなかった retained record が 3 件ある。Chronology では推測日を補わず、監査記録に未解決として残す。

SOURCE-BACKED TECHNICAL NOTES

Detailed Chronology――2023 年のイベント解像度を保存する: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
----	------	----	-----

9 2023 年総括——「モデル」から「システム／生態系」へ

2023 年を一つの年として読むと、生成 AI の設計対象はモデル weights だけに留まらなくなった。インタラクション、公開モデル群、tool/action、runtime、retrieval/post-training、生成メディア、evaluation/control が別々の層として立ち上がり、相互の制約を受けるシステムとして見えるようになった。

年初には「より強い基盤モデル」が議論の中心に見えやすかったが、年を通じて利用形態と実装層が増えた。年末を同じ尺度で見ると、モデルの出力品質だけでなく、どの入力を扱い、どの外部機能へ接続し、どの資源で運用し、どう評価・制御するかまでが設計問題として分化している。

この変化は、2023 年の出来事を「モデル発表」「論文」「画像生成」といった媒体別に並べるだけでは捉えにくい。annual scale では、同じモデル系列でも interface、deployment、runtime、control の異なる層にまたがるため、生成 AI を多層 system/ecosystem として再分類する方が技術的な因果を説明しやすい。

open weights の拡大は runtime・fine-tuning 効率への需要を強め、tool interface の整備は reliability と governance の境界を明確にし、長

文脈や multimodal 化は評価方法を複雑にした。各層は独立に発展したのではなく、別の層へ新しい制約を渡しながらか設計空間を広げた。

一方、2023 年末でも未解決の境界は多い。公称 context 長と実効利用、vendor benchmark と独立評価、open weights と再現可能な open training、tool selection と安全な実行、生成品質と権利・安全性、capability 評価と実効的な governance は同一視できない。

したがって 2023 年の年次的な転換は「ある一つのモデルが勝った」ことではなく、生成 AI がモデル単体の競争から、多層の技術スタックと生態系を設計する競争へ移ったことにある。この見取り図が、翌年以降の on-device、agent、serving、multimodal、control の加速を理解する基準になる。

SOURCE-BACKED TECHNICAL NOTES

2023 年総括——「モデル」から「システム／生態系」へ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
----	------	----	-----

References / Source Notes

- [1] *Primary source 3*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/claude-2-1> (visited on 08/16/2026).
- [2] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2307.03172v3> (visited on 08/16/2026).
- [3] *Primary source 3*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/gpt-4-research> (visited on 08/16/2026).
- [4] *Primary source 2*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/claude-2> (visited on 08/16/2026).
- [5] *Primary source 1*. Primary source used for chronology and technical verification. OpenAI. URL: <http://arxiv.org/abs/2303.08774v6> (visited on 08/16/2026).
- [6] *Primary source 3*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/innovation-and-ai/technology/ai/google-gemini-ai/> (visited on 08/16/2026).
- [7] *Primary source 2*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/innovation-and-ai/products/gemini-api-developers-cloud/> (visited on 08/16/2026).
- [8] *Primary source 4*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/gpt-4v-system-card> (visited on 08/16/2026).
- [9] *Primary source 1*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/100k-context-windows> (visited on 08/16/2026).
- [10] *Primary source 4*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/products-and-platforms/devices/pixel/pixel-feature-drop-december-2023/> (visited on 08/16/2026).
- [11] *Primary source 1*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/innovation-and-ai/products/google-palm-2-ai-large-language-model/> (visited on 08/16/2026).
- [12] *Primary source 4*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/introducing-claude> (visited on 08/16/2026).
- [13] *Primary source 2*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/chatgpt-can-now-see-hear-and-speak> (visited on 08/16/2026).
- [14] *Primary source 1*. Primary source used for chronology and technical verification. Google. URL: <http://arxiv.org/abs/2312.11805v5> (visited on 08/16/2026).
- [15] *Primary source 2*. Primary source used for chronology and technical verification. Mistral AI. URL: <https://mistral.ai/news/announcing-mistral-7b/> (visited on 08/16/2026).

- [16] *Primary source 2*. Primary source used for chronology and technical verification. Technology Innovation Institute. URL: <https://www.tii.ae/index.php/news/uaes-technology-innovation-institute-launches-open-source-falcon-40b-large-language-model> (visited on 08/16/2026).
- [17] *Primary source 6*. Primary source used for chronology and technical verification. Meta. URL: <https://ai.meta.com/blog/llama-2/> (visited on 08/16/2026).
- [18] *Primary source 5*. Primary source used for chronology and technical verification. Meta. URL: <https://ai.meta.com/blog/large-language-model-llama-meta-ai/> (visited on 08/16/2026).
- [19] *Primary source 1*. Primary source used for chronology and technical verification. Qwen Team. URL: <http://arxiv.org/abs/2309.16609v1> (visited on 08/16/2026).
- [20] *Primary source 1*. Primary source used for chronology and technical verification. Technology Innovation Institute. URL: <http://arxiv.org/abs/2311.16867v2> (visited on 08/16/2026).
- [21] *Primary source 3*. Primary source used for chronology and technical verification. Technology Innovation Institute. URL: <https://www.tii.ae/news/technology-innovation-institute-introduces-worlds-most-powerful-open-llm-falcon-180b> (visited on 08/16/2026).
- [22] *Primary source 1*. Primary source used for chronology and technical verification. Meta. URL: <http://arxiv.org/abs/2302.13971v1> (visited on 08/16/2026).
- [23] *Primary source 4*. Primary source used for chronology and technical verification. Meta. URL: <https://ai.meta.com/blog/code-llama-large-language-model-coding/> (visited on 08/16/2026).
- [24] *Primary source 2*. Primary source used for chronology and technical verification. Meta. URL: <http://arxiv.org/abs/2307.09288v2> (visited on 08/16/2026).
- [25] *Primary source 3*. Primary source used for chronology and technical verification. Meta. URL: <http://arxiv.org/abs/2308.12950v3> (visited on 08/16/2026).
- [26] *Primary source 2*. Primary source used for chronology and technical verification. Qwen Team. URL: <https://qwenlm.github.io/blog/qwen/> (visited on 08/16/2026).
- [27] *Primary source 1*. Primary source used for chronology and technical verification. Mistral AI. URL: <http://arxiv.org/abs/2310.06825v1> (visited on 08/16/2026).
- [28] *Primary source 3*. Primary source used for chronology and technical verification. Mistral AI. URL: <https://mistral.ai/news/mixtral-of-experts/> (visited on 08/16/2026).
- [29] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2302.04761v1> (visited on 08/16/2026).
- [30] *Primary source 3*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/introducing-gpts> (visited on 08/16/2026).
- [31] *Primary source 2*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/function-calling-and-other-api-updates> (visited on 08/16/2026).

- [32] *Primary source 1*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/chatgpt-plugins> (visited on 08/16/2026).
- [33] *Primary source 4*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/new-models-and-developer-products-announced-at-devday> (visited on 08/16/2026).
- [34] *Primary source 2*. Primary source used for chronology and technical verification. vLLM Project. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.1.3> (visited on 08/16/2026).
- [35] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2307.08691v1> (visited on 08/16/2026).
- [36] *Primary source 1*. Primary source used for chronology and technical verification. Microsoft Research. URL: <https://www.microsoft.com/en-us/research/blog/phi-2-the-surprising-power-of-small-language-models/> (visited on 08/16/2026).
- [37] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2305.14314v1> (visited on 08/16/2026).
- [38] *Primary source 1*. Primary source used for chronology and technical verification. vLLM Project. URL: <http://arxiv.org/abs/2309.06180v1> (visited on 08/16/2026).
- [39] *Primary source 3*. Primary source used for chronology and technical verification. vLLM Project. URL: <https://vllm.ai/blog/2023-06-20-vllm> (visited on 08/16/2026).
- [40] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2305.18290v3> (visited on 08/16/2026).
- [41] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <https://arxiv.org/abs/2312.00752> (visited on 08/16/2026).
- [42] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2305.10601v2> (visited on 08/16/2026).
- [43] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2310.11511v1> (visited on 08/16/2026).
- [44] *Primary source 5*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stable-diffusion-xl-beta-available-for-api-customers-and-dreamstudio-users> (visited on 08/16/2026).
- [45] *Primary source 1*. Primary source used for chronology and technical verification. Stability AI. URL: <http://arxiv.org/abs/2311.15127v1> (visited on 08/16/2026).
- [46] *Primary source 3*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stable-video-diffusion-open-ai-video-model> (visited on 08/16/2026).
- [47] *Primary source 2*. Primary source used for chronology and technical verification. Stability AI. URL: <http://arxiv.org/abs/2311.17042v1> (visited on 08/16/2026).

- [48] *Primary source 1*. Primary source used for chronology and technical verification. Adobe. URL: <https://news.adobe.com/news/news-details/2023/adobe-unveils-firefly-a-family-of-new-creative-generative-ai> (visited on 08/16/2026).
- [49] *Primary source 2*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/introducing-stable-video-diffusion-api> (visited on 08/16/2026).
- [50] *Primary source 1*. Primary source used for chronology and technical verification. Stability AI. URL: <http://arxiv.org/abs/2307.01952v1> (visited on 08/16/2026).
- [51] *Primary source 1*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/dall-e-3-is-now-available-in-chatgpt-plus-and-enterprise> (visited on 08/16/2026).
- [52] *Primary source 3*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stability-ai-sdxl-turbo> (visited on 08/16/2026).
- [53] *Primary source 2*. Primary source used for chronology and technical verification. Adobe. URL: <https://news.adobe.com/news/news-details/2023/adobe-unveils-future-of-creative-cloud-with-generative-ai-as-a-creative-co-pilot-in-photoshop> (visited on 08/16/2026).
- [54] *Primary source 2*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/dall-e-3-system-card> (visited on 08/16/2026).
- [55] *Primary source 4*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stable-diffusion-sdxl-1-announcement> (visited on 08/16/2026).
- [56] *Primary source 1*. Primary source used for chronology and technical verification. LMSYS Org. URL: <http://arxiv.org/abs/2306.05685v4> (visited on 08/16/2026).
- [57] *Primary source 3*. Primary source used for chronology and technical verification. LMSYS Org. URL: <https://www.lmsys.org/blog/2023-06-22-leaderboard/> (visited on 08/16/2026).
- [58] *Primary source 3*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/practices-for-governing-agentic-ai-systems> (visited on 08/16/2026).
- [59] *Primary source 1*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/anthropics-responsible-scaling-policy> (visited on 08/16/2026).
- [60] *Primary source 2*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/claudes-constitution> (visited on 08/16/2026).
- [61] *Primary source 1*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/frontier-risk-and-preparedness> (visited on 08/16/2026).
- [62] *Primary source 4*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/weak-to-strong-generalization> (visited on 08/16/2026).

- [63]*Primary source 2*. Primary source used for chronology and technical verification. LMSYS Org.
URL: <https://www.lmsys.org/blog/2023-05-03-arena/> (visited on 08/16/2026).
- [64]*Primary source 2*. Primary source used for chronology and technical verification. OpenAI.
URL: <https://openai.com/index/improving-mathematical-reasoning-with-process-supervision> (visited on 08/16/2026).