
Japanese Generative AI Technical Survey

SP-2023-Y

Special / Coverage 2023-01-01 – 2023-12-31 / Retrospective as of 2026-08-16

モデルから、生成 AI システムの時代へ

2023 年、生成 AI の競争はモデル単体の性能から、長文脈とマルチモーダルな利用、公開モデルの生態系、外部機能への接続、学習・推論を支える実装層までを組み合わせる多層の設計競争へ広がった。

フロンティア競争は性能表から長文脈・マルチモーダルなインタラクションへ / LLaMA から Mixtral へ——open weights が単一モデルではなく生態系になった / 生成から行動へ——Plugin、Function Calling、Tool Use が API 層を作った

Editorial cutoff

Coverage window: 2023-01-01 – 2023-12-31 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Retrospective

Survey。

Retrospective Signals

フロンティア競争の軸がインタラクションへ広がった 長い入力や画像を含む入力、提供形態までが同時に設計対象となり、単一の性能指標では捉えにくい競争へ移った。 [p. 5](#)

公開モデルは単発の配布物から生態系へ変わった 公開範囲、利用条件、専門化、規模、言語、効率の異なる系列が並走し、用途と計算資源に応じた選択肢が増えた。 [p. 10](#)

生成の外側に実行と運用の層が立ち上がった 外部機能を選ぶ仕組みと安全に実行する境界、限られた資源で適応・推論・配信する仕組みが、モデル能力とは別の設計問題として前面に出た。

[p. 15](#) / [p. 18](#)

設計空間と生成メディアが同時に分岐した 推論時探索、学習後最適化、検索制御、代替アーキテクチャが別々の研究面を広げる一方、画像・動画生成はモデル公開、製品統合、制作工程へと展開した。 [p. 22](#) / [p. 26](#)

能力を測り、制御する仕組みが技術史の一部になった 共通の比較基盤と、人間の選好を含む評価、能力向上と運用条件を結び付ける制御の枠組みが、強いモデルを扱う独立した技術層として現れた。 [p. 30](#) / [p. 38](#)

Retrospective scope

本号は 2023 年を後日確認可能になった一次情報も用いて再構成する Retrospective Special である。Coverage Period と制作時点を同一視せず、vendor / project / author claim の境界は各記事と Technical Notes で明示する。

目次

Retrospective Signals	2
1 フロンティア競争は、性能表からインタラクション設計へ	5
1.1 モデル能力と利用面を分けて読む	5
1.2 長文脈は「入る長さ」と「使える長さ」が違う	5
1.3 multimodal はモデルと製品の二つの意味を持つ	5
1.4 発表と利用可能性を同じ日付にしない	6
Theme at a glance	6
2 LLaMA から Mixtral へ——open weights は生態系になった	10
2.1 「open」を一つの属性にしない	10
2.2 単発モデルから family と派生用途へ	10
2.3 規模・言語・効率という複数の差別化軸	10
2.4 open-weight 化が変えたのは比較可能性の範囲	11
Theme at a glance	12

3	生成から行動へ——Tool Use が API 層を作った	15
3.1	文章を返すモデルから、外部処理を選ぶモデルへ	15
3.2	研究上の tool use と、配備された API は同じではない	15
3.3	structured output は信頼性の境界になる	15
3.4	tool access が application-facing layer へ広がる	15
	Theme at a glance	16
4	モデルを動かす技術が競争軸になった	18
4.1	training・adaptation・inference・serving は別の予算を持つ	18
4.2	adaptation cost を下げると用途別モデルが作りやすくなる	18
4.3	同じモデルでも kernel で実行特性は変わる	18
4.4	一件の推論と、多数の要求を捌く serving は違う	18
4.5	小型モデルは別の制約条件を選ぶ設計	19
	Theme at a glance	20
5	推論・検索・学習後最適化、そして Transformer の外側へ	22
5.1	同じ「賢くする研究」でも操作する場所が違う	22
5.2	推論時に探索を増やすという設計	22
5.3	post-training は推論方法ではなく behavior を変える	22
5.4	検索を固定 pipeline から制御 loop へ	22
5.5	sequence architecture の探索が再び広がる	23
	Theme at a glance	23
6	生成メディアが、独立した製品・モデルスタックになった	26
6.1	同じ生成でも公開 surface が違う	26
6.2	model quality から制作 workflow へ	26
6.3	画像から動画へ——同じ生成でも制約は増える	26
6.4	生成メディアも多層 system として見る	27
	Theme at a glance	27
7	能力を測り、制御する層が追いつき始めた	30
7.1	強いモデルが増えると比較方法そのものが問題になる	30
7.2	評価と control policy は役割が違う	30
7.3	能力の増加と運用条件を結び付ける	30
7.4	能力競争と evaluation/control は同時に進む	31
	Theme at a glance	32
8	Detailed Chronology——圧縮した物語の外側に、出来事を残す	34
	Theme at a glance	37
9	2023 年総括——「モデル」から「システム／生態系」へ	38
9.1	一年の前半と後半で、同じ言葉の指す範囲が広がった	38
9.2	媒体別の出来事を、設計 layer へ再分類する	38
9.3	layer 間の依存関係が生成 AI を system にした	38

9.4	2023 年末に残った境界は、翌年以降の設計課題になる	39
9.5	年間 thesis——モデル競争から多層 system 設計へ	39
Theme at a glance		40

1 フロンティア競争は、性能表からインタラクション設計へ

2023 年のフロンティアモデル競争では、単一の能力指標だけでなく、長い入力、画像を含む入力、API や製品を介した利用形態までが同時に設計対象になった。GPT-4 系、Claude 系、PaLM 2 から Gemini への流れを、モデルそのものとユーザーが触れるインタラクション層を分けて読む。[1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14]

1.1 モデル能力と利用面を分けて読む

2023 年の重要な変化は、フロンティアモデルの比較対象が「どのモデルが最も賢いか」という一軸から外れたことである。GPT-4 系、Claude 系、Google の PaLM 2 から Gemini への展開は、モデル能力だけでなく、入力可能な情報の種類、扱える文脈、API や製品への配置を含む複合的な競争を可視化した。[1, 3, 4, 5, 6, 7, 8, 9, 10, 12, 13, 14]

この競争を技術的に読むときは、少なくとも三つの面を分離すると整理しやすい。第一はモデルが扱える情報と推論能力、第二は利用者が実際に入力・出力できるインターフェース、第三は API や製品としての提供範囲である。同じモデル系列の名称が使われていても、この三面が同時に更新されるとは限らない。[1, 3, 4, 5, 6, 7, 8, 9, 10, 12, 13, 14]

したがって、年次比較の単位も単純なモデル名ではなくなる。ある系列が長い入力を前面に出し、別の系列が画像入力や端末配置を強調した場合、それらを一つのベンチマーク順位だけで並べると設計上の差が消える。2023 年は「何点取るモデルか」に加えて「どの情報を、どの場所で、どの形で扱わせるか」が競争軸になった年として読むべきである。[3, 5, 6, 7, 8, 10, 11, 13, 14]

1.2 長文脈は「入る長さ」と「使える長さ」が違う

長い context window は、それだけで長文脈を一様に有効利用できることを意味しない。年内には長文脈を前面に出す製品更新が続く一方、Lost in the Middle のような研究は、入力長の上限と情報を実際に取り出して使えることを区別すべきだという技術的境界を示した。[1, 2, 4, 6, 7, 9, 10, 12, 14]

この区別は application 設計にも影響する。入力上限が伸びれば、分割・検索・要約の必要性がただ消えるわけではなく、重要情報の配置、検索との併用、長い履歴をどこまで保持するかという設計判断が残る。長文脈は RAG 等の周辺技術を単純に不要にする機能ではなく、system 側が選べる情報供給戦略を増やしたと捉える方が安全である。[1, 2, 4, 9, 12]

評価も同様に、最大 token 数と実用上の成功率を分けなければならない。長い入力を受け付けること、途中で置かれた情報を見つけること、複数箇所の証拠を統合することは別の課題である。2023 年の長文脈競争は、仕様表に新しい数字を追加しただけでなく、「文脈能力をどう測るか」という評価問題を前景化した。[1, 2, 4, 9, 12]

1.3 multimodal はモデルと製品の二つの意味を持つ

multimodal という語も、モデル内部の表現と製品インターフェースを分けて扱う必要がある。GPT-4V や Gemini のようなモデル系列

の展開と、画像・音声を受け付ける製品機能は同じ時点・同じ提供範囲とは限らない。本稿では「モデルが何を扱えると発表されたか」と「利用者がどの形で使えたか」を別の状態として記述する。[3, 5, 6, 7, 8, 10, 13, 14]

利用面から見ると、画像を受け付けられることは単に入力形式が一つ増えることではない。利用者が文字で説明していた対象を直接提示できるため、interaction の設計そのものが変わる。一方で、画像を見られることと、画像中のすべての情報を安定して解釈できることは同義ではないため、製品 UI が能力の不確実性を吸収する役割も大きくなる。[3, 5, 6, 7, 8, 10, 13, 14]

Gemini の年末の展開では、同じ family 名の下でもクラウド側のフロンティアモデルと端末側の小型配置を分けて考える必要があることも明瞭になった。これは「最大能力のモデルをどこでも使う」という発想から、latency、privacy、計算資源などの制約に応じて model tier を配置する発想への広がりとして読める。[6, 7, 10, 11, 14]

1.4 発表と利用可能性を同じ日付にしない

研究発表、モデル発表、preview、API 提供、端末や製品への配置は別々の出来事である。2023 年のフロンティア競争を後知恵で一本化せず、それぞれの時点で公開されていた提供形態を保存することで、技術的能力と実利用可能性を混同しない。[1, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14]

この lifecycle 分離は、年次史では特に重要である。ある family が後の時点で広く利用可能になっていても、その状態を初回発表日に遡らせると、当時の開発者が実際に選べた技術を誤って再構成してしまう。Detailed Chronology では family の物語を保ちながら、公開状態の遷移を独立イベントとして残す。[1, 3, 4, 5, 6, 7, 8, 9, 10, 12, 13, 14]

Claim boundary

各社や著者が提示した性能・能力評価は一次資料に帰属する主張であり、本稿はそれを独立再現した比較順位へ換算しない。ここで比較するのは、2023 年にどの設計面が競争軸として現れたかである。[3, 5, 8, 13]

SOURCE-BACKED TECHNICAL NOTES

フロンティア競争は性能表から長文脈・マルチモーダルなインタラクションへ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
GPT-4 / GPT-4V 2023 lifecycle	主要資料	モデル更新	—
Claude 2023 model family	主要資料	モデル更新	—
Gemini 2023 launch family	主要資料	モデル	—
PaLM 2	補足資料	モデル	—
Lost in the Middle	補足資料	論文	—

GPT-4 / GPT-4V 2023 lifecycle

主要資料

組織 OpenAI

種別 モデル更新

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「GPT-4 / GPT-4V 2023 lifecycle」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2303.08774v6>
- <https://openai.com/index/chatgpt-can-now-see-hear-and-speak>
- <https://openai.com/index/gpt-4-research>
- <https://openai.com/index/gpt-4v-system-card>

Claude 2023 model family

主要資料

組織 Anthropic

種別 モデル更新

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「Claude 2023 model family」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://www.anthropic.com/news/100k-context-windows>
- <https://www.anthropic.com/news/claude-2>
- <https://www.anthropic.com/news/claude-2-1>
- <https://www.anthropic.com/news/introducing-claude>

Gemini 2023 launch family

主要資料

組織 Google

種別 モデル

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「Gemini 2023 launch family」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2312.11805v5>
- <https://blog.google/innovation-and-ai/products/gemini-api-developers-cloud/>
- <https://blog.google/innovation-and-ai/technology/ai/google-gemini-ai/>
- <https://blog.google/products-and-platforms/devices/pixel/pixel-feature-drop-december-2023/>

PaLM 2

補足資料

組織 Google

種別 モデル

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「PaLM 2」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://blog.google/innovation-and-ai/products/google-palm-2-ai-large-language-model/>

Lost in the Middle

補足資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- Author claim: 一次資料で「Lost in the Middle」が 2023 年の技術動向として記録され

ていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2307.03172v3>

2 LLaMA から Mixtral へ——open weights は生態系になった

2023 年は、公開された weights を起点に、規模、言語、専門化、効率、配布条件の異なるモデル系列が並走し始めた年だった。LLaMA/Llama 2、Falcon、Qwen、Mistral/Mixtral を通じて、open weights を open source や open training と同一視せず、その多様化を追う。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

2.1 「open」を一つの属性にしない

open という一語で括られがちなモデル群の公開範囲は同じではない。weights が取得できること、利用条件が広いこと、学習データや学習手順まで再現可能であることは別の軸である。2023 年の open-weight 拡大は、単一の公開モデルが現れたというより、異なる公開境界を持つ複数の系列が競争可能になった出来事として読む方が正確である。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

モデルの技術的特徴だけでなく、license と access の条件が利用可能性を規定する。Llama 2 以降の広い利用、Falcon や Qwen など他系列の登場、Mistral 系の公開は、weights 公開の有無だけでは説明できない実装・再配布上の差を伴う。したがって本稿では「open」という形容ではなく、公開された成果物と利用条件を分けて記述する。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

この区別は再現性の議論でも重要になる。weights が入手できれば推論や fine-tuning の実験はしやすくなるが、元の pretraining を追試できることまでは保証しない。反対に、学習工程の透明性を高めるには data、code、recipe、checkpoint など別の成果物が必要になる。open-weight ecosystem は再現性を完成させたのではなく、どこまで公開されれば何を検証できるかという段階差を明確にした。[17, 18, 19, 22, 23, 24, 25, 26]

2.2 単発モデルから family と派生用途へ

年の進行とともに、open-weight モデルは単発の base model から family へ拡張した。汎用モデルに加え、instruction tuning、code などの専門化、複数サイズ、複数言語への展開が進み、利用者は一つの代表モデルを選ぶのではなく、用途と計算資源に合わせて系列内外を比較するようになった。[15, 17, 18, 19, 22, 23, 24, 25, 26, 27, 28]

選択肢が増えたことで、モデル選定の問いも変わった。最大規模のモデルを使うかどうかだけでなく、対象言語、用途、hardware 予算、再配布条件、fine-tuning の必要性を合わせて判断する必要がある。これは open-weight の価値を単純な「無料で使えるモデル」に還元せず、deployment 設計の自由度として捉える視点につながる。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

weights が手元に来ると、次に問題になるのは動かし方である。量子化、fine-tuning、serving、API 互換性などの周辺実装が価値を左右し、open-weight の拡大は runtime/adaptation layer の需要を強くした。2023 年の open ecosystem はモデル配布だけで閉じず、その周辺にある tooling や deployment 技術と結び付いて初めて実利用の選択肢になった。[15, 17, 18, 22, 23, 24, 25, 27, 28]

2.3 規模・言語・効率という複数の差別化軸

Falcon、Qwen、Mistral などが加わることで、open-weight 側にも単一企業・単一地域だけではない多様な family が並んだ。この多様化は性能順位だけでなく、扱う言語や model size、利用条件といった異なる差別化軸を持ち込んだ。open ecosystem の競争は「誰が最強モデルを公開したか」より、どの制約条件に対して選択肢を提供したかを見る方が実態に近い。

[15, 16, 19, 20, 21, 26, 27, 28]

年末の Mixtral は、この多様化に architecture の選択肢をさらに加えた。ここで重要なのは MoE が既存方式を置き換えた結論ではなく、公開 weights の世界でも parameter count だけでない効率設計が主要な比較軸へ入った点である。[15, 27, 28]

MoE のような設計が注目されると、モデル規模の表記だけでは計算コストや利用特性を説明しにくくなる。総 parameter 数、実際に使われる計算、memory、serving 方法は別の変数であり、open-weight 側でも model architecture と runtime を一緒に評価する必要性が生まれる。これは次章の「モデルを動かす技術」が独立した競争軸になったこととも接続する。[15, 27, 28]

2.4 open-weight 化が変えたのは比較可能性の範囲

2023 年の変化を年次的にまとめると、open-weight の重要性は「閉じたモデルの代替品ができた」ことだけではない。複数 family を同じ hardware や toolchain 上で比較し、用途別に adapt し、local/deployment 条件を選ぶ余地が増えたことで、モデルの価値が周辺 stack との組み合わせで決まる生態系へ移った点にある。[15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28]

Claim boundary

各プロジェクトや著者による性能比較は、その評価条件に基づく主張として扱う。公開範囲が広いことも、性能や再現性が自動的に保証されることを意味しない。[17, 18, 22, 23, 24, 25]

LLaMA から Mixtral へ——open weights が単一モデルではなく生態系になった: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
LLaMA / Llama 2 / Code Llama 2023	主要資料	オープンウェイト	—
Mistral 7B / Mixtral	主要資料	オープンウェイト	—
Falcon 40B / 180B	補足資料	オープンウェイト	—
Qwen 2023 family	補足資料	オープンウェイト	—

LLaMA / Llama 2 / Code Llama 2023		主要資料
組織	Meta	
種別	オープンウェイト	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「LLaMA / Llama 2 / Code Llama 2023」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		
読む際の境界		
分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。		
一次資料		
http://arxiv.org/abs/2302.13971v1 http://arxiv.org/abs/2307.09288v2 http://arxiv.org/abs/2308.12950v3 https://ai.meta.com/blog/code-llama-large-language-model-coding/ https://ai.meta.com/blog/large-language-model-llama-meta-ai/ https://ai.meta.com/blog/llama-2/		

Mistral 7B / Mixtral		主要資料
組織	Mistral AI	
種別	オープンウェイト	
時系列	—	
一次資料から整理した technical points		

- **一次情報で確認できる事実:** 一次資料で「Mistral 7B / Mixtral」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2310.06825v1>
- <https://mistral.ai/news/announcing-mistral-7b/>
- <https://mistral.ai/news/mixtral-of-experts/>

Falcon 40B / 180B

補足資料

組織 Technology Innovation Institute

種別 オープンウェイト

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Falcon 40B / 180B」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2311.16867v2>
- <https://www.tii.ae/index.php/news/uaes-technology-innovation-institute-launches-open-source-falcon-40b-1arge-language-model>
- <https://www.tii.ae/news/technology-innovation-institute-introduces-worlds-most-powerful-open-llm-falcon-180b>

Qwen 2023 family

補足資料

組織 Qwen Team

種別 オープンウェイト

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Qwen 2023 family」の 2023 年における公開・

リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2309.16609v1>
- <https://qwenlm.github.io/blog/qwen/>

3 生成から行動へ——Tool Use が API 層を作った

2023 年には、言語モデルが文章を返すだけでなく、外部機能を選び、構造化された呼び出しへ接続する設計が製品・API の中心へ入った。Toolformer の研究的発想と OpenAI の Plugins、Function Calling、GPTs/Assistants の展開を、tool selection と実行主体を分けて整理する。[\[29, 30, 31, 32, 33\]](#)

3.1 文章を返すモデルから、外部処理を選ぶモデルへ

tool use では、モデルが「何を呼ぶべきか」を決めることと、外部システムが実際に副作用を伴う処理を実行することを分ける必要がある。自然言語の生成能力が高くても、実行権限、引数検証、失敗時の扱いは別の system layer である。[\[29, 30, 31, 32, 33\]](#)

実装を抽象化すると、model output から外部 action へは少なくとも「候補 tool の選択」「machine-readable な引数生成」「host 側の検証」「実行」「結果の観測」「次の生成」という段階がある。この分解を持つと、モデルの誤りと実行基盤の誤り、権限設計の誤りを別々に扱える。tool use が system design として重要なのは、この境界が明示的に設計できるためである。[\[29, 30, 31, 32, 33\]](#)

3.2 研究上の tool use と、配備された API は同じではない

Toolformer はモデルが外部ツール利用を学習する研究方向を示した。一方、Plugins や Function Calling は開発者が接続先と構造を定義する製品・API 面の仕組みである。両者は同じ「tool use」という語で呼べても、研究上の問いと配備上の責任分界は異なる。[\[29, 30, 31, 32, 33\]](#)

研究側が「どの tool をいつ使うか」を学習問題として扱うのに対し、product 側では、開発者が schema、権限、呼び出し先を定義し、モデルを制御された interface へ閉じ込めるこ

とが重要になる。この差は、agent という語を使うときにも残る。自律性を高めることと、安全に外部機能へ接続することは別の設計目標である。[\[29, 30, 31, 32, 33\]](#)

3.3 structured output は信頼性の境界になる

Function Calling のような構造化インターフェースは、自由文から外部実行へ直接飛ぶのではなく、モデル出力を機械可読な境界へ落とし込む考え方を前面に出した。この境界は利便性だけでなく、検証、再試行、権限管理を実装する場所にもなる。[\[30, 31, 32, 33\]](#)

構造化された呼び出しでも、引数が妥当とは限らない。そのため host 側は型だけでなく、許容範囲、対象 resource、実行権限、confirmation の要否を判断する必要がある。モデルを「tool を呼べる主体」として扱うほど、validation や authorization をモデル外へ置く設計原則が重要になる。[\[30, 31, 32, 33\]](#)

tool の戻り値を次の prompt context へ戻す設計では、外部世界の観測と生成を反復できる。これは静的な質問応答から一歩進む一方、失敗した実行結果や不完全な観測を次の判断材料にする危険も生む。loop を長くするほど、stop condition、error handling、human confirmation をどこに置くかが system behavior を左右する。[\[30, 31, 32, 33\]](#)

3.4 tool access が application-facing layer へ広がる

年末までに GPTs や Assistants へ連なる製品面が現れたことで、tool access は個別デモではなく application-facing layer として認識されやすくなった。2023 年の転換は「モデルが何でも自律実行できるようになった」ことではなく、生成と実行の間に明示的な interface が必要だと広く実装されたことである。[30, 31, 32, 33]

この interface があると、application 側はモデルを万能なブラックボックスとして扱わず、「利用可能な tool 集合」と「許可された回数」を契約として持てる。結果として model provider の API 設計と application architecture が接続され、tool schema は prompt engineering

だけでなく software interface design の一部になる。[30, 31, 32, 33]

ここから agent 的な system へ発展するとしても、2023 年の Evidence から無制限な自律実行を一般化するべきではない。むしろ tool/action layer の成立は、model reasoning、external execution、permission、observation を分けて組み合わせる必要性を示した。後の agent 設計を理解する土台は、まずこの責任分界にある。[29, 30, 31, 32, 33]

Claim boundary

tool-use の信頼性や有効性に関する評価は、研究・プロジェクト・vendor の条件に依存する。本稿では機構の成立と公開形態を扱い、それらの性能主張を独立再現済みの事実とはみなさない。[30, 31, 32, 33]

SOURCE-BACKED TECHNICAL NOTES

生成から行動へ——Plugin、Function Calling、Tool Use が API 層を作った: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
OpenAI tool/action surface 2023	主要資料	API	—
Toolformer	補足資料	論文	—

OpenAI tool/action surface 2023

主要資料

組織 OpenAI

種別 API

時系列 —

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「OpenAI tool/action surface 2023」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://openai.com/index/chatgpt-plugins>
- <https://openai.com/index/function-calling-and-other-api-updates>
- <https://openai.com/index/introducing-gpts>
- <https://openai.com/index/new-models-and-developer-products-announced-at-devday>

Toolformer**補足資料**

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Toolformer」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2302.04761v1>

4 モデルを動かす技術が競争軸になった

2023 年には、モデルの規模や能力だけでなく、限られた memory でどう適応させ、attention をどう高速化し、同時要求をどう捌くかが実用性を左右する独立した技術面になった。QLoRA、FlashAttention-2、vLLM/PagedAttention、Phi-2 を、学習・推論・serving の異なる制約への応答として読む。[34, 35, 36, 37, 38, 39]

4.1 training・adaptation・inference・serving は別の予算を持つ

QLoRA が向き合うのは主として既存モデルを限られた計算資源で fine-tuning する側の制約であり、FlashAttention-2 は attention 計算の効率、vLLM/PagedAttention は推論時の memory 管理と serving を主眼とする。同じ「効率化」でも、最適化する段階とボトルネックは異なる。[34, 35, 37, 38, 39]

model lifecycle を分解すると、pretraining の巨大な一回費用だけでなく、用途別の adaptation、各 request の inference、継続的な serving capacity が別々に現れる。ある手法が一つの段階を安くしても、別の段階の cost を自動的に下げるわけではない。この分解があると、効率化技術を「速いモデル」という一語で混ぜずに比較できる。[34, 35, 37, 38, 39]

4.2 adaptation cost を下げると用途別モデルが作りやすくなる

QLoRA が示した方向の意味は、巨大モデルの pretraining そのものを安価にすることではなく、既存 weights を用途に合わせて調整する際の memory pressure を下げることにある。adaptation の入口が広がれば、単一の汎用モデルをそのまま使う以外に、domain や task ごとの調整を検討しやすくなる。[37]

ただし、memory 効率が改善しても、data preparation、evaluation、deployment まで自動化されるわけではない。fine-tuning を実行可能にする技術と、望ましい behavior を得るた

めの学習設計は別問題である。2023 年は「調整できること」と「調整後に何が良くなるか」を分ける必要性も強めた。[37]

4.3 同じモデルでも kernel で実行特性は変わる

FlashAttention-2 が属する層では、model architecture を変えずに attention computation の実装を改善する。これは algorithm 名や parameter 数だけ見ても分からない差である。GPU 上の memory movement や parallelism の扱いが変われば、同じ数学的処理でも実行時間と利用可能な sequence 長に影響しうる。[35]

この種の最適化は、モデル研究と systems 研究の境界を曖昧にする。新しい model capability を提案していなくても、既存モデルを現実的な latency や memory budget で動かせる範囲を変えるからである。2023 年には「モデルの論文」と「実装の論文」を別世界として扱いにくくなった。[35]

4.4 一件の推論と、多数の要求を捌く serving は違う

モデルが一度応答できることと、多数の要求を安定して処理できることも別問題である。vLLM/PagedAttention の登場は、KV-cache を含む runtime 側の資源管理が、モデル選定と同じ程度に deployment 設計へ影響しうることを可視化した。[34, 38, 39]

serving では throughput と latency、memory occupancy、request 長、同時実行数が相互に影響する。そのため project が示す throughput 改

善を model capability の向上として読むべきではない。runtime optimization は「同じ能力を何人に、どの待ち時間で提供できるか」という別の性能面を扱う。[34, 38, 39]

serving layer が成熟すると、application 側は巨大モデルの内部実装より API surface を意識するようになる。同時に provider 側では cache、batching、scheduler などが economics を左右する。tool/action layer が application interface を作ったのに対し、serving layer はその interface を継続的に成立させる裏側の基盤である。[34, 38, 39]

4.5 小型モデルは別の制約条件を選ぶ設計

Phi-2 のような小型モデルへの関心は、parameter scale だけを増やす以外の設計空間も示した。ここでは小型であること自体を優位性と断定せず、data quality や用途、hardware 制約と組み合わせて「必要な能力をどの資源予算で実現するか」という問いが強まったことを重視する。[36]

フロンティア最大モデルと小型モデルは、必ずしも同じ役割を競う必要がない。cloud で最大能力を使う設計、端末や局所環境で小さなモデルを使う設計、task に応じて複数 tier を組み合わせる設計は別々に成立する。model portfolio という見方をすると、runtime と model size は一体の deployment decision になる。[36]

2023 年の systems 面の変化は、モデル能力を「学習済み weights の属性」だけで語れなくなった。適応コスト、kernel、cache、serving、モデルサイズが相互に作用し、同じモデルでも運用可能性が大きく変わるという認識が、研究と実装の両側で前面に出た。[34, 35, 36, 37, 38, 39]

Claim boundary

QLoRA、FlashAttention-2、vLLM、Phi-2 に関する速度・memory・品質などの数値は、それぞれの著者や project/vendor が設定した実験条件に依存する。異なる hardware・workload・benchmark を横断して一つの優劣表へ変換しない。[34, 35, 36, 37, 38, 39]

SOURCE-BACKED TECHNICAL NOTES

モデルを動かす技術が競争軸になった——QLoRA、FlashAttention-2、vLLM: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
vLLM / PagedAttention	主要資料	Framework	—
QLoRA	主要資料	論文	—
FlashAttention-2	主要資料	論文	—
Phi-2	補足資料	モデル	—

vLLM / PagedAttention

主要資料

組織	vLLM Project
種別	Framework
時系列	—

一次資料から整理した technical points

- 一次情報で確認できる事実: 一次資料で「vLLM / PagedAttention」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- 分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2309.06180v1>
- <https://github.com/vllm-project/vllm/releases/tag/v0.1.3>
- <https://vllm.ai/blog/2023-06-20-vllm>

QLoRA		主要資料
組織	authors	
種別	論文	
時系列	—	
一次資料から整理した technical points		
• Author claim: 一次資料で「QLoRA」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。		

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2305.14314v1>

FlashAttention-2**主要資料**

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「FlashAttention-2」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2307.08691v1>

Phi-2**補足資料**

組織 Microsoft Research

種別 モデル

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Phi-2」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://www.microsoft.com/en-us/research/blog/phi-2-the-surprising-power-of-small-language-models/>

5 推論・検索・学習後最適化、そして Transformer の外側へ

2023 年の研究は、一つの「次世代 LLM 手法」へ収束したのではない。Tree of Thoughts、DPO、Self-RAG、Mamba は、それぞれ推論時探索、post-training、retrieval-control、sequence architecture という異なる層を広げた。設計空間の拡張として並べることで、何が同じ問題で何が別問題かを明確にする。[40, 41, 42, 43]

5.1 同じ「賢くする研究」でも操作する場所が違う

Tree of Thoughts、DPO、Self-RAG、Mamba を横並びにすると、まず操作対象を分ける必要がある。Tree of Thoughts は推論時の探索、DPO は学習後の選好調整、Self-RAG は生成と検索の制御、Mamba は sequence を処理する architecture そのものに焦点を置く。これらを一つの性能トレンドとして混ぜると、どの層を変えて結果を得ているのかが見えなくなる。[40, 41, 42, 43]

この分解が 2023 年を読むうえで重要なのは、scale だけが改良手段ではなくなったからである。学習済みモデルを固定して推論過程を変える、preference data で behavior を調整する、外部知識との往復を設計する、sequence operator を変えるという複数の入口が同時に見えるようになった。競争は parameter count だけでなく、どの layer へ計算と制御を置くかへ広がった。[40, 41, 42, 43]

5.2 推論時に探索を増やすという設計

Tree of Thoughts は、単一の逐次生成だけでなく、複数の候補状態を探索・評価する推論時の計算構造を研究対象にした。この方向は「モデルそのものを大きくする」以外に、推論プロセスの編成で結果を変える設計余地があることを示す。[42]

推論時探索を導入すると、品質だけでなく計算予算の配分が問題になる。候補を増やす、

途中評価を入れる、探索を打ち切るといった選択は、latency と計算量を増やしまう。つまり reasoning method は model capability の上に乗る runtime policy でもあり、常に最大限探索することが実用上の最適解とは限らない。[42]

探索を使う場合、どの候補を良いと判定するかという評価器も必要になる。その評価が同じモデルの自己評価であれ外部規則であれ、生成と選択を分けることで system 側に control point が生まれる。tool/action layer と同じく、強い生成能力だけでなく、途中状態を観測して次の処理を選ぶ構造が重要になる。[42]

5.3 post-training は推論方法ではなく behavior を変える

DPO は pretraining や推論時探索とは異なり、人間の選好情報を用いる post-training の設計を簡素化する方向に位置する。ここで扱うのはモデルが推論中に考える方法ではなく、どの応答傾向を学習後に選好させるかという別レイヤである。[40]

preference optimization では、何を好ましい応答とみなすかが学習 interface になる。algorithm を簡素化しても、preference data の品質、比較基準、対象 domain が消えるわけではない。post-training の進歩は「alignment が解決した」ことではなく、base model の後段で behavior を設計する技術が独立した研究領域になったことを示す。[40]

5.4 検索を固定 pipeline から制御 loop へ

Self-RAG は retrieval を常時付加する固定 pipeline ではなく、生成過程と検索・自己評価を結び付ける制御問題として扱う方向を示した。retrieval の有無、参照結果の使い方、生成の自己点検を一つの system loop として設計する発想である。[43]

検索を使う system では、検索するかどうか、何を query にするか、得た document をどこまで信用するか、回答に反映できたかという判断が連鎖する。context window が伸びても、この判断連鎖が自動的に不要になるわけではない。long context と retrieval は代替関係だけでなく、情報供給の異なる制御手段として併存する。[43]

5.5 sequence architecture の探索が再び広がる

Mamba は年末に、attention 中心の Transformer とは異なる sequence modeling の選択肢として注目を集めた。ただし 2023 年時点の Evidence から「Transformer が置き換えられた」と結論することはできない。重要なのは、長い sequence と計算効率をめぐる architecture 探索が再び広がったことである。[41]

新しい sequence architecture を評価するときも、論文上の計算量だけでなく kernel や hardware との相性、学習安定性、既存 toolchain との統合を考える必要がある。architecture innovation と runtime engineering は分離できず、Mamba の登場は「モデルの構造」と「モデルを動かす実装」の境界を改めて意識させる出来事でもあった。[41]

四つの方向をまとめると、2023 年の研究は「より大きな Transformer を作る」以外の設計変数を増やした。推論時に計算を使う、post-training で behavior を変える、外部検索との loop を作る、sequence operator 自体を変える。それぞれの成果を同じランキングに押し込むのではなく、どの layer を操作する手法かを識別することが、その後の組み合わせを理解する前提になる。[40, 41, 42, 43]

Claim boundary

各論文・project が報告する性能向上は、それぞれの課題設定と評価条件に基づく。ここでは互いに異なるレイヤの研究を共通ランキングへ置かず、2023 年に設計可能な場所が増えたという年次的意味を抽出する。[42]

SOURCE-BACKED TECHNICAL NOTES

推論・検索・学習後最適化、そして Transformer の外側へ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Tree of Thoughts	主要資料	論文	—
Direct Preference Optimization (DPO)	主要資料	論文	—
Self-RAG	主要資料	論文	—
Mamba	主要資料	論文	—

Tree of Thoughts

主要資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Tree of Thoughts」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2305.10601v2>

Direct Preference Optimization (DPO)

主要資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Direct Preference Optimization (DPO)」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2305.18290v3>

Self-RAG

主要資料

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Self-RAG」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2310.11511v1>

Mamba**主要資料**

組織 authors

種別 論文

時系列 —

一次資料から整理した technical points

- **Author claim:** 一次資料で「Mamba」が 2023 年の技術動向として記録されていることを確認できる。技術内容や評価結果は、原著者による主張として扱い、独立再現済みの結果とはみなさない。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://arxiv.org/abs/2312.00752>

6 生成メディアが、独立した製品・モデルスタックになった

2023 年の画像・動画生成では、単発の研究デモだけでなく、open model、API、会話 UI、既存制作ソフトへの統合という複数の公開形態が並んだ。DALL-E 3、SDXL/Turbo、Stable Video Diffusion、Adobe Firefly/Generative Fill を通じて、生成メディアが独立した技術・製品層へ分岐した過程を追う。[44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55]

6.1 同じ生成でも公開 surface が違う

生成メディアの進歩は「新しい画像モデルが出た」という一列の出来事ではない。DALL-E 3 は会話型製品との接続、SDXL 系は model release と高速化、Stable Video Diffusion は動画生成、Firefly は既存クリエイティブツールとの統合という異なる surface を持つ。[44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55]

研究・モデル公開、API 提供、製品機能への統合は区別すべきである。ユーザーが利用できる生成機能の価値は model quality だけでなく、prompt 作成支援、編集 workflow、配布形態、既存アプリケーションとの接続によっても変わる。[44, 47, 48, 50, 51, 52, 53, 54, 55]

配布形態の違いは、誰がどこで generation pipeline を制御できるかにも関係する。API や統合製品では provider 側の更新がそのまま利用体験へ反映されやすい。一方、download 可能な model では実行環境や workflow を利用者側が組み替えられる余地が大きい。2023 年は画像生成でこの二つの経路が明確に並走した。[44, 47, 48, 50, 51, 52, 53, 54, 55]

6.2 model quality から制作 workflow へ

DALL-E 3 のように会話 UI と接続されると、画像生成は一回の prompt から画像を返すだけでなく、意図の言語化、修正指示、再生成という対話 loop の中へ入る。ここでは language model と image model の役割を同一視せず、

prompt を組み立てる層と画像を生成する層が連携する system として見るのが重要になる。[51, 54]

Firefly/Generative Fill のような既存編集環境への統合では、生成は完成画像を一から作る機能だけではなく、局所編集や制作工程の一操作になる。生成 AI が「専用サイトで使うモデル」から「既存 software の中に埋め込まれた機能」へ移ることで、評価対象も単体 output から workflow 全体へ広がる。[48, 53]

SDXL Turbo のような高速化方向や Generative Fill のような編集統合は、生成品質だけでなく iteration time と workflow への組み込みが競争軸になることを示した。生成モデルは単体アプリではなく、制作工程の一部として評価され始めた。[44, 47, 48, 50, 52, 53, 55]

制作では一回の最高品質より、試行回数と待ち時間が重要な場面も多い。生成が速くなれば、prompt や編集条件を変えて複数案を比較する loop を短くできる。そのため fast generation は単なる benchmark 上の速度ではなく、人間が model output を評価し次の指示を出す interaction cadence を変える技術でもある。[44, 47, 50, 52, 55]

6.3 画像から動画へー同じ生成でも制約は増える

画像生成と動画生成も同じ成熟度として扱えない。Stable Video Diffusion の登場は、画像で進んだ生成モデルの公開・利用パターンが動画へ拡張され始めたことを示すが、対象と

なる出力、計算量、評価方法、製品化の境界は異なる。[44, 45, 46, 47, 49, 50, 52, 55]

動画では個々の frame 品質だけでなく、時間方向の一貫性や motion を扱う必要があるため、静止画と同じ評価軸だけでは足りない。さらに sequence が増えるほど計算・memory・出力 size も大きくなる。2023 年の video generation は完成された代替手段というより、生成メディア stack が時間軸を持つ出力へ拡張し始めた段階として位置付ける。[45, 46, 49]

6.4 生成メディアも多層 system として見る

年末までの流れをまとめると、生成メディアは model weights だけでなく、prompt/interface、runtime、編集 workflow、distribution を含む stack へ広がった。open model、hosted API、会話型製品、desktop application integration は

同じ技術を別の場所に載せただけではなく、利用者が制御できる範囲と iteration loop を変える異なる product architecture である。[44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55]

この多層化により、比較の仕方も難しくなる。model output の好み、生成速度、編集しやすさ、tool integration は別の指標であり、一つの score へまとめると製品の違いを見失う。年間史では「どのモデルが最も高品質か」ではなく、生成能力がどの workflow へ組み込まれたかを軸に変化を追う。[44, 47, 48, 50, 51, 52, 53, 54, 55]

Claim boundary

画質、速度、創造性、安全性などの比較値は、各 vendor/project/author の条件に依存する。本稿は release 形態と技術方向を整理し、異なる評価条件を独立した共通ランキングへ換算しない。[51, 54]

SOURCE-BACKED TECHNICAL NOTES

生成メディアが独立した製品・モデルスタックへ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
DALL-E 3 2023 lifecycle	主要資料	モデル	—
Stable Diffusion XL / SDXL Turbo 2023	主要資料	モデル更新	—
Stable Video Diffusion 2023	主要資料	モデル	—
Adobe Firefly / Generative Fill	主要資料	PRODUCT	—

DALL-E 3 2023 lifecycle

主要資料

組織	OpenAI
種別	モデル
時系列	—
一次資料から整理した technical points	

- **一次情報で確認できる事実:** 一次資料で「DALL-E 3 2023 lifecycle」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://openai.com/index/dall-e-3-is-now-available-in-chatgpt-plus-and-enterprise>
- <https://openai.com/index/dall-e-3-system-card>

Stable Diffusion XL / SDXL Turbo 2023

主要資料

組織 Stability AI

種別 モデル更新

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Stable Diffusion XL / SDXL Turbo 2023」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2307.01952v1>
- <http://arxiv.org/abs/2311.17042v1>
- <https://stability.ai/news-updates/stability-ai-sd-xl-turbo>
- <https://stability.ai/news-updates/stable-diffusion-sd-xl-1-announcement>
- <https://stability.ai/news-updates/stable-diffusion-xl-beta-available-for-api-customers-and-dreamstudio-users>

sers

Stable Video Diffusion 2023

主要資料

組織 Stability AI

種別 モデル

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Stable Video Diffusion 2023」の2023年におけ

る公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <http://arxiv.org/abs/2311.15127v1>
- <https://stability.ai/news-updates/introducing-stable-video-diffusion-api>
- <https://stability.ai/news-updates/stable-video-diffusion-open-ai-video-model>

Adobe Firefly / Generative Fill

主要資料

組織 Adobe

種別 製品

時系列 —

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Adobe Firefly / Generative Fill」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://news.adobe.com/news/news-details/2023/adobe-unveils-firefly-a-family-of-new-creative-generative-ai>
- <https://news.adobe.com/news/news-details/2023/adobe-unveils-future-of-creative-cloud-with-generative-ai-as-a-creative-co-pilot-in-photoshop>

7 能力を測り、制御する層が追いつき始めた

強いモデルが増えるほど、「何が強いのかをどう比較するか」と「どの能力をどの条件で運用するか」が独立した問題になった。Chatbot Arena/MT-Bench と、OpenAI・Anthropic の alignment / governance 面の取り組みを、evaluation layer と control layer の形成として並べる。[56, 57, 58, 59, 60, 61, 62, 63, 64]

7.1 強いモデルが増えると比較方法そのものが問題になる

Chatbot Arena と MT-Bench は、モデル比較を個々の発表資料だけに閉じず、複数モデルを同じ評価 surface へ載せる方向を押し出した。とくに人間の選好を含む比較は、単一の自動 benchmark とは異なる情報を与える一方、それ自体が絶対的な能力真値になるわけではない。[56, 57, 63]

共通の比較 surface が重要なのは、vendor ごとの発表値だけでは条件を揃えにくいからである。同じ prompt を与える、複数 model を blind に比較する、一定形式の task を使うといった仕組みは、少なくとも比較の入口を共有できる。ただし、その入口を共有しても全用途の能力を一つの数字にまとめられるわけではない。[56, 57, 63]

benchmark score や human preference は、task 設計、prompt、比較対象、評価者構成などに依存する。Arena/MT-Bench を共通比較基盤として評価しても、そこから全用途の総合順位を導くことはしない。[56, 57, 63]

人間の選好を使う評価には、正解ラベルを作りにくい会話品質を比較できる利点がある一方、評価者が何を好むかという別の変数が入る。文章の自然さ、慎重さ、詳細さ、task 達成度は同じ尺度ではない。human preference を取り入れることは評価を完全にするのではなく、能力測定に人間側の目的関数を明示的に加えることである。[56, 57, 63]

7.2 評価と control policy は役割が違う

OpenAI と Anthropic の年内の alignment / governance 関連の取り組みは、モデルの能力向上とは別に、利用・評価・scale-up の条件を定義する control surface が必要だという問題設定を明示した。研究結果、内部評価、公開 policy は同じ証拠種別ではないため、本稿では区別して扱う。[58, 59, 60, 61, 62, 64]

evaluation は model behavior を観測する仕組みであり、policy は観測結果や想定 risk をどの運用判断へ結び付けるかを定める仕組みである。両者を混同すると、score が高いことを安全性の証明とみなしたり、policy が存在することを技術的有効性の証明とみなしたりする。2023 年は測定と運用判断をつなぐ interface が必要だと認識され始めた段階である。[56, 57, 58, 59, 60, 61, 62, 63, 64]

7.3 能力の増加と運用条件を結び付ける

年末に向かうにつれ、将来のより強い能力をどの threshold で評価し、どの運用条件と結び付けるかが公開 policy の論点として前面に出た。ここで重要なのは具体的な安全性が達成済みとみなすことではなく、capability growth と control obligation を結び付ける枠組み自体が明示されたことである。[58, 59, 60, 61, 62, 64]

threshold 型の考え方では、すべての model release へ同じ control を適用するのではなく、

能力や risk の水準に応じて評価・配備条件を強めることを目指す。これは計測が control の前提になることを意味する一方、どの能力を測るか、threshold をどう定義するか、想定外の能力をどう扱うかという未解決問題を残す。[58, 59, 60, 61, 62, 64]

tool/action layer が広がるほど、出力 content だけでなく外部 action を伴う behavior をどう評価するかも重要になる。agentic risk を考える場合、モデルが何を生成したかだけでなく、何を選択し、どの権限で実行し、失敗からどう続行したかという system-level observation が必要になる。control layer は model card の付録ではなく application architecture へ近づいていく。[58, 59, 60, 61, 62, 64]

7.4 能力競争と evaluation/control は同時に進む

2023 年の evaluation/control を能力向上の「後処理」とみなすと、年内の構造変化を見誤る。フロンティア model、open-weight family、tool-using system が増えるほど、比較対象と運用条件も増えた。評価基盤と control policy は強い model の後に追いついたというより、多様化した system を運用可能な対象として扱うための別 layer として同時に形成された。[56, 57, 58, 59, 60, 61, 62, 63, 64]

年末時点で残った問いは、どの benchmark を信頼するかだけではない。用途別評価をどう組み合わせるか、human preference の偏りをどう理解するか、capability 評価をどの配備条件へ結び付けるか、policy が想定していない新しい behavior をどう扱うか。evaluation/control layer の成立は問題の解決ではなく、管理すべき変数を明示したことに意味がある。[56, 57, 58, 59, 60, 61, 62, 63, 64]

SOURCE-BACKED TECHNICAL NOTES

Claim boundary

評価結果と安全・alignment 上の主張は、それぞれの project/vendor が示した条件と範囲に帰属する。本稿は policy の存在や問題設定を一次資料で確認するが、有効性を独立に実証したとは扱わない。[58, 61, 62, 64]

能力を測り、制御する層が追いつき始めた: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Chatbot Arena / MT-Bench	主要資料	評価ベンチマーク	—
OpenAI 2023 alignment and agent-governance work	主要資料	安全性関連	—
Anthropic Constitutional AI / Responsible Scaling Policy	主要資料	安全性関連	—

Chatbot Arena / MT-Bench		主要資料
組織	LMSYS Org	
種別	評価ベンチマーク	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「Chatbot Arena / MT-Bench」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		
読む際の境界		
分析上の留意点: 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。		
一次資料		
http://arxiv.org/abs/2306.05685v4 https://www.lmsys.org/blog/2023-05-03-arena/ https://www.lmsys.org/blog/2023-06-22-leaderboard/		

OpenAI 2023 alignment and agent-governance work		主要資料
組織	OpenAI	
種別	安全性事象	
時系列	—	
一次資料から整理した technical points		
一次情報で確認できる事実: 一次資料で「OpenAI 2023 alignment and agent-governance work」の 2023 年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。		

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://openai.com/index/frontier-risk-and-preparedness>
- <https://openai.com/index/improving-mathematical-reasoning-with-process-supervision>
- <https://openai.com/index/practices-for-governing-agentic-ai-systems>
- <https://openai.com/index/weak-to-strong-generalization>

Anthropic Constitutional AI / Responsible Scaling Policy

主要資料

組織

Anthropic

種別

安全性事象

時系列

—

一次資料から整理した technical points

- **一次情報で確認できる事実:** 一次資料で「Anthropic Constitutional AI / Responsible Scaling Policy」の2023年における公開・リリースの経緯を確認できる。能力や性能に関する評価は、提供元・プロジェクト・著者の主張として扱う。

読む際の境界

- **分析上の留意点:** 一次資料で確認できる範囲の事実を記録しており、提供元・プロジェクト・著者による評価を独立再現済みの結果として扱わない。

一次資料

- <https://www.anthropic.com/news/anthropics-responsible-scaling-policy>
- <https://www.anthropic.com/news/claudes-constitution>

8 Detailed Chronology——圧縮した物語の外側に、出来事を残す

年間本文は story と trajectory へ圧縮するが、歴史記録としては release、paper initial publication、preview、API/product availability、policy/control milestone を同一視できない。本節では、年次叙述で失われやすい event-level の差を読むための基準を明示する。

日付は一次資料または論文メタデータで確認できた公開時点を採用し、後年の提供状態を遡及して補わない。

1 月

2023-01-30

BLIP-2: Bootstrapping Language-Image
Pre-training with Frozen Image Encoders and
Large Language Models

2 月

2023-02-09

Toolformer: Language Models Can Teach
Themselves to Use Tools

2023-02-24

Introducing LLaMA

2023-02-27

LLaMA: Open and Efficient Foundation
Language Models

3 月

2023-03-14

Introducing Claude

2023-03-14

GPT-4

2023-03-15

GPT-4 Technical Report

2023-03-20

Reflexion: Language Agents with Verbal
Reinforcement Learning

2023-03-21

Adobe Firefly

2023-03-23

ChatGPT plugins

2023-03-30

Vicuna

4 月

2023-04-13

Stable Diffusion XL beta

2023-04-17

Visual Instruction Tuning

5 月

2023-05-03

Chatbot Arena

2023-05-09

Claude's Constitution

2023-05-10

PaLM 2

2023-05-11

Introducing 100K Context Windows

2023-05-17

Tree of Thoughts: Deliberate Problem Solving
with Large Language Models

2023-05-18

LIMA: Less Is More for Alignment

2023-05-23

Generative Fill in Photoshop

2023-05-23

QLoRA: Efficient Finetuning of Quantized LLMs

2023-05-24

Gorilla: Large Language Model Connected with Massive APIs

2023-05-25

Falcon 40B open-source release

2023-05-29

Direct Preference Optimization: Your Language Model is Secretly a Reward Model

2023-05-31

Improving mathematical reasoning with process supervision

6 月**2023-06-05**

Orca: Progressive Learning from Complex Explanation Traces of GPT-4

2023-06-08

Simple and Controllable Music Generation

2023-06-09

OpenAI-compatible local API server with open models

2023-06-09

Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena

2023-06-13

Function calling and other API updates

2023-06-20

vLLM: Easy, Fast, and Cheap LLM Serving with PagedAttention

2023-06-22

MT-Bench and Chatbot Arena leaderboard

7 月**2023-07-04**

SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis

2023-07-06

Lost in the Middle: How Language Models Use Long Contexts

2023-07-11

Claude 2

2023-07-17

FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning

2023-07-18

Llama 2

2023-07-18

Llama 2: Open Foundation and Fine-Tuned Chat Models

2023-07-26

Stable Diffusion XL 1.0

8 月**2023-08-02**

AudioCraft

2023-08-02

vLLM v0.1.3

2023-08-24

Code Llama

2023-08-24

Code Llama: Open Foundation Models for Code

9 月**2023-09-06**

Falcon 180B

2023-09-12Efficient Memory Management for Large
Language Model Serving with PagedAttention**2023-09-19**

Anthropic's Responsible Scaling Policy

2023-09-19

Baichuan 2: Open Large-scale Language Models

2023-09-25

ChatGPT can now see, hear, and speak

2023-09-25

GPT-4V(ision) system card

2023-09-27

Announcing Mistral 7B

2023-09-28

Qwen Technical Report

10 月**2023-10-03**

DALL · E 3 system card

2023-10-05Improved Baselines with Visual Instruction
Tuning**2023-10-10**

Mistral 7B

2023-10-17Self-RAG: Learning to Retrieve, Generate, and
Critique through Self-Reflection**2023-10-19**DALL · E 3 is now available in ChatGPT Plus
and Enterprise**2023-10-26**

Frontier risk and preparedness

11 月**2023-11-06**

Introducing GPTs

2023-11-06New models and developer products announced
at DevDay**2023-11-21**

Claude 2.1

2023-11-21

Stable Video Diffusion

2023-11-25Stable Video Diffusion: Scaling Latent Video
Diffusion Models to Large Datasets**2023-11-28**

SDXL Turbo

2023-11-28

The Falcon Series of Open Language Models

2023-11-28

Adversarial Diffusion Distillation

12 月**2023-12-01**Mamba: Linear-Time Sequence Modeling with
Selective State Spaces**2023-12-06**

Gemini Nano on Pixel

2023-12-06

Introducing Gemini	Practices for Governing Agentic AI Systems
2023-12-11	2023-12-19
Mixtral of Experts	Gemini: A Family of Highly Capable Multimodal Models
2023-12-12	2023-12-20
Phi-2: The surprising power of small language models	Stable Video Diffusion API
2023-12-13	
Gemini API for developers	
2023-12-14	
Weak-to-strong generalization	
2023-12-14	

日付精度の境界

公開日の精度を一次記録から確定できなかった retained record が 3 件ある。Chronology では推測日を補わず、監査記録に未解決として残す。

SOURCE-BACKED TECHNICAL NOTES

Detailed Chronology――2023 年のイベント解像度を保存する: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
----	------	----	-----

9 2023 年総括——「モデル」から「システム／生態系」へ

2023 年を一つの年として読むと、生成 AI の設計対象はモデル weights だけに留まらなくなった。インタラクション、公開モデル群、tool/action、runtime、retrieval/post-training、生成メディア、evaluation/control が別々の層として立ち上がり、相互の制約を受けるシステムとして見えるようになった。

9.1 一年の前半と後半で、同じ言葉の指す範囲が広がった

年初には「より強い基盤モデル」が議論の中心に見えやすかったが、年を通じて利用形態と実装層が増えた。年末を同じ尺度で見ると、モデルの出力品質だけでなく、どの入力を扱い、どの外部機能へ接続し、どの資源で運用し、どう評価・制御するかまでが設計問題として分化している。

1～3 月の段階では、フロンティア側の能力拡張と open-weight 側の追試・派生利用が並行して見え始めた。この時点では両者を「閉鎖モデル対公開モデル」という対立で読むこともできたが、年が進むにつれて両陣営とも runtime、tool、evaluation など共通の system 課題へ直面する。

4～6 月になると、fine-tuning、evaluation、tool interface、serving のような周辺技術が独立した名前と実装を持ち始める。ここで重要なのは、モデル本体の進歩が止まったのではなく、強いモデルを利用可能な system へ変換する作業が別の技術課題として可視化されたことである。

後半では open-weight family の多様化、長文脈、生成メディアの製品統合、tool/action の拡張が同時に進み、年末には MoE や代替 sequence architecture、capability-aware な control policy までは同じ技術史の中に現れる。年内の出来事を四半期ごとに切るより、model を中心に複数 layer が増殖した過程として見る方が

連続性を保てる。

9.2 媒体別の出来事を、設計 layer へ再分類する

この変化は、2023 年の出来事を「モデル発表」「論文」「画像生成」といった媒体別に並べるだけでは捉えにくい。annual scale では、同じモデル系列でも interface、deployment、runtime、control の異なる層にまたがるため、生成 AI を多層 system/ecosystem として再分類する方が技術的な因果を説明しやすい。

本版が採用した七つの trajectory は、それぞれ独立した流行一覧ではない。frontier interaction は入力と利用面、open-weight ecosystem は model choice、tool/action は外部実行、runtime/adaptation は resource、reasoning/retrieval/architecture は algorithmic control、generative media は出力 workflow、evaluation/control は測定と運用条件を扱う。違いは「何を最適化する layer か」にある。

一つの artifact が複数 layer へ影響することもある。長文脈 model は interface だけでなく serving memory と evaluation を難しくし、open-weight model は runtime tooling と adaptation を活性化し、tool-using application は control policy に新しい観測対象を加える。したがって「一つの出来事を一つの章に分類する」のではなく、章ごとに同じ system を異なる断面から見る方がよい。

9.3 layer 間の依存関係が生成 AI を system にした

open weights の拡大は runtime・fine-tuning 効率への需要を強め、tool interface の整備は reliability と governance の境界を明確にし、長文脈や multimodal 化は評価方法を複雑にした。各層は独立に発展したのではなく、別の層へ新しい制約を渡しながらか設計空間を広げた。

能力面が進歩すると、runtime 側にはより大きな memory、長い sequence、複数 modality を扱う要求が生まれる。runtime 側の効率が上がると、今度は model をより多くの application へ配置できる。能力と systems は主従関係ではなく、片方の改善がもう片方の利用可能な設計領域を広げる循環を持つ。

tool/action layer では、生成した文章が外部世界への操作へ接続されることで、control の対象が content から behavior へ広がる。評価も「回答が正しいか」だけでなく「どの tool を選び、どの権限で何を実行したか」を観測する必要がある。agent 的 system を理解するには、model reasoning だけでなく interface と control を同時に見る必要がある。

生成メディアでも同じ構造が見える。画像 model の品質が上がるだけでなく、会話 UI、編集 software、低 latency generation が結びつくことで、model output は制作 workflow の一要素になる。application integration が進むほど、model 単体の benchmark だけでは価値を説明できなくなる。

SOURCE-BACKED TECHNICAL NOTES

9.4 2023 年末に残った境界は、翌年以降の設計課題になる

一方、2023 年末でも未解決の境界は多い。公称 context 長と実効利用、vendor benchmark と独立評価、open weights と再現可能な open training、tool selection と安全な実行、生成品質と制作 workflow、capability 評価と実効的な governance は同一視できない。

これらの境界を「まだ解決していない欠点」として消すのではなく、技術史の状態として残すことが重要である。2023 年の発表を後の知識で補正して完成品のように見せると、当時どの問題が開いていたかが分からなくなる。annual retrospective は進歩の列挙だけでなく、年末時点で未解決だった interface を保存する役割を持つ。

9.5 年間 thesis——モデル競争から多層 system 設計へ

したがって 2023 年の年次的な転換は「ある一つのモデルが勝った」ことではなく、生成 AI がモデル単体の競争から、多層の技術スタックと生態系を設計する競争へ移ったことにある。この見取り図が、次の時期に現れる on-device、agent、serving、multimodal、control の議論を読むための座標系になる。

この座標系では、新しい model release だけを追っても全体像はつかめない。model family の更新に加えて、どの interface が追加されたか、どの runtime 制約が緩和されたか、どの外部 action へ接続されたか、どの評価/control が導入されたかを見る必要がある。2023 年は、その読み方を要求するほど生成 AI の技術面が多層化した最初の一年として位置付けられる。

2023 年総括——「モデル」から「システム／生態系」へ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
----	------	----	-----

References / Source Notes

- [1] *Primary source 3*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/claude-2-1> (visited on 08/16/2026).
- [2] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2307.03172v3> (visited on 08/16/2026).
- [3] *Primary source 3*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/gpt-4-research> (visited on 08/16/2026).
- [4] *Primary source 2*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/claude-2> (visited on 08/16/2026).
- [5] *Primary source 1*. Primary source used for chronology and technical verification. OpenAI. URL: <http://arxiv.org/abs/2303.08774v6> (visited on 08/16/2026).
- [6] *Primary source 3*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/innovation-and-ai/technology/ai/google-gemini-ai/> (visited on 08/16/2026).
- [7] *Primary source 2*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/innovation-and-ai/products/gemini-api-developers-cloud/> (visited on 08/16/2026).
- [8] *Primary source 4*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/gpt-4v-system-card> (visited on 08/16/2026).
- [9] *Primary source 1*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/100k-context-windows> (visited on 08/16/2026).
- [10] *Primary source 4*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/products-and-platforms/devices/pixel/pixel-feature-drop-december-2023/> (visited on 08/16/2026).
- [11] *Primary source 1*. Primary source used for chronology and technical verification. Google. URL: <https://blog.google/innovation-and-ai/products/google-palm-2-ai-large-language-model/> (visited on 08/16/2026).
- [12] *Primary source 4*. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/introducing-claude> (visited on 08/16/2026).
- [13] *Primary source 2*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/chatgpt-can-now-see-hear-and-speak> (visited on 08/16/2026).
- [14] *Primary source 1*. Primary source used for chronology and technical verification. Google. URL: <http://arxiv.org/abs/2312.11805v5> (visited on 08/16/2026).
- [15] *Primary source 2*. Primary source used for chronology and technical verification. Mistral AI. URL: <https://mistral.ai/news/announcing-mistral-7b/> (visited on 08/16/2026).

- [16] *Primary source 2*. Primary source used for chronology and technical verification. Technology Innovation Institute. URL: <https://www.tii.ae/index.php/news/uaes-technology-innovation-institute-launches-open-source-falcon-40b-large-language-model> (visited on 08/16/2026).
- [17] *Primary source 6*. Primary source used for chronology and technical verification. Meta. URL: <https://ai.meta.com/blog/llama-2/> (visited on 08/16/2026).
- [18] *Primary source 5*. Primary source used for chronology and technical verification. Meta. URL: <https://ai.meta.com/blog/large-language-model-llama-meta-ai/> (visited on 08/16/2026).
- [19] *Primary source 1*. Primary source used for chronology and technical verification. Qwen Team. URL: <http://arxiv.org/abs/2309.16609v1> (visited on 08/16/2026).
- [20] *Primary source 1*. Primary source used for chronology and technical verification. Technology Innovation Institute. URL: <http://arxiv.org/abs/2311.16867v2> (visited on 08/16/2026).
- [21] *Primary source 3*. Primary source used for chronology and technical verification. Technology Innovation Institute. URL: <https://www.tii.ae/news/technology-innovation-institute-introduces-worlds-most-powerful-open-llm-falcon-180b> (visited on 08/16/2026).
- [22] *Primary source 1*. Primary source used for chronology and technical verification. Meta. URL: <http://arxiv.org/abs/2302.13971v1> (visited on 08/16/2026).
- [23] *Primary source 4*. Primary source used for chronology and technical verification. Meta. URL: <https://ai.meta.com/blog/code-llama-large-language-model-coding/> (visited on 08/16/2026).
- [24] *Primary source 2*. Primary source used for chronology and technical verification. Meta. URL: <http://arxiv.org/abs/2307.09288v2> (visited on 08/16/2026).
- [25] *Primary source 3*. Primary source used for chronology and technical verification. Meta. URL: <http://arxiv.org/abs/2308.12950v3> (visited on 08/16/2026).
- [26] *Primary source 2*. Primary source used for chronology and technical verification. Qwen Team. URL: <https://qwenlm.github.io/blog/qwen/> (visited on 08/16/2026).
- [27] *Primary source 1*. Primary source used for chronology and technical verification. Mistral AI. URL: <http://arxiv.org/abs/2310.06825v1> (visited on 08/16/2026).
- [28] *Primary source 3*. Primary source used for chronology and technical verification. Mistral AI. URL: <https://mistral.ai/news/mixtral-of-experts/> (visited on 08/16/2026).
- [29] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2302.04761v1> (visited on 08/16/2026).
- [30] *Primary source 3*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/introducing-gpts> (visited on 08/16/2026).
- [31] *Primary source 2*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/function-calling-and-other-api-updates> (visited on 08/16/2026).

- [32] *Primary source 1*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/chatgpt-plugins> (visited on 08/16/2026).
- [33] *Primary source 4*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/new-models-and-developer-products-announced-at-devday> (visited on 08/16/2026).
- [34] *Primary source 2*. Primary source used for chronology and technical verification. vLLM Project. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.1.3> (visited on 08/16/2026).
- [35] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2307.08691v1> (visited on 08/16/2026).
- [36] *Primary source 1*. Primary source used for chronology and technical verification. Microsoft Research. URL: <https://www.microsoft.com/en-us/research/blog/phi-2-the-surprising-power-of-small-language-models/> (visited on 08/16/2026).
- [37] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2305.14314v1> (visited on 08/16/2026).
- [38] *Primary source 1*. Primary source used for chronology and technical verification. vLLM Project. URL: <http://arxiv.org/abs/2309.06180v1> (visited on 08/16/2026).
- [39] *Primary source 3*. Primary source used for chronology and technical verification. vLLM Project. URL: <https://vllm.ai/blog/2023-06-20-vllm> (visited on 08/16/2026).
- [40] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2305.18290v3> (visited on 08/16/2026).
- [41] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <https://arxiv.org/abs/2312.00752> (visited on 08/16/2026).
- [42] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2305.10601v2> (visited on 08/16/2026).
- [43] *Primary source 1*. Primary source used for chronology and technical verification. authors. URL: <http://arxiv.org/abs/2310.11511v1> (visited on 08/16/2026).
- [44] *Primary source 5*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stable-diffusion-xl-beta-available-for-api-customers-and-dreamstudio-users> (visited on 08/16/2026).
- [45] *Primary source 1*. Primary source used for chronology and technical verification. Stability AI. URL: <http://arxiv.org/abs/2311.15127v1> (visited on 08/16/2026).
- [46] *Primary source 3*. Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stable-video-diffusion-open-ai-video-model> (visited on 08/16/2026).
- [47] *Primary source 2*. Primary source used for chronology and technical verification. Stability AI. URL: <http://arxiv.org/abs/2311.17042v1> (visited on 08/16/2026).

- [48] *Primary source 1.* Primary source used for chronology and technical verification. Adobe. URL: <https://news.adobe.com/news/news-details/2023/adobe-unveils-firefly-a-family-of-new-creative-generative-ai> (visited on 08/16/2026).
- [49] *Primary source 2.* Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/introducing-stable-video-diffusion-api> (visited on 08/16/2026).
- [50] *Primary source 1.* Primary source used for chronology and technical verification. Stability AI. URL: <http://arxiv.org/abs/2307.01952v1> (visited on 08/16/2026).
- [51] *Primary source 1.* Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/dall-e-3-is-now-available-in-chatgpt-plus-and-enterprise> (visited on 08/16/2026).
- [52] *Primary source 3.* Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stability-ai-sdxl-turbo> (visited on 08/16/2026).
- [53] *Primary source 2.* Primary source used for chronology and technical verification. Adobe. URL: <https://news.adobe.com/news/news-details/2023/adobe-unveils-future-of-creative-cloud-with-generative-ai-as-a-creative-co-pilot-in-photoshop> (visited on 08/16/2026).
- [54] *Primary source 2.* Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/dall-e-3-system-card> (visited on 08/16/2026).
- [55] *Primary source 4.* Primary source used for chronology and technical verification. Stability AI. URL: <https://stability.ai/news-updates/stable-diffusion-sdxl-1-announcement> (visited on 08/16/2026).
- [56] *Primary source 1.* Primary source used for chronology and technical verification. LMSYS Org. URL: <http://arxiv.org/abs/2306.05685v4> (visited on 08/16/2026).
- [57] *Primary source 3.* Primary source used for chronology and technical verification. LMSYS Org. URL: <https://www.lmsys.org/blog/2023-06-22-leaderboard/> (visited on 08/16/2026).
- [58] *Primary source 3.* Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/practices-for-governing-agentic-ai-systems> (visited on 08/16/2026).
- [59] *Primary source 1.* Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/anthropics-responsible-scaling-policy> (visited on 08/16/2026).
- [60] *Primary source 2.* Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news/claudes-constitution> (visited on 08/16/2026).
- [61] *Primary source 1.* Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/frontier-risk-and-preparedness> (visited on 08/16/2026).
- [62] *Primary source 4.* Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/weak-to-strong-generalization> (visited on 08/16/2026).

- [63]*Primary source 2*. Primary source used for chronology and technical verification. LMSYS Org.
URL: <https://www.lmsys.org/blog/2023-05-03-arena/> (visited on 08/16/2026).
- [64]*Primary source 2*. Primary source used for chronology and technical verification. OpenAI.
URL: <https://openai.com/index/improving-mathematical-reasoning-with-process-supervision> (visited on 08/16/2026).