
Japanese Generative AI Technical Survey

SP-2026-M05

Special / Coverage 2026-05-01 – 2026-05-31 / Retrospective as of 2026-08-11

2026 年 5 月 — Agent は実行環境を持ち始めた

GPT-5.5 Instant や Claude Opus 4.8 などのモデル更新と並行して、sandbox、CLI / MCP、serving、memory security、evaluation まで実行系が広がった 1 か月を振り返る。

Frontier Models & Voice — モデル更新が利用面へ広がった 5 月 / Agents & Runtime — Codex を安全に長く動かす実行環境

Editorial cutoff

Coverage window: 2026-05-01 – 2026-05-31 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Retrospective

Survey。

Monthly Signals

Frontier Models & Voice model 更新は default experience、API lifecycle、voice という利用 surface の更新と一体化した。 p. 5

Agents & Runtime agent を長く動かすため、sandbox、approval、network policy、CLI / MCP 統合が実行環境の主要設計項目になった。 p. 11

Inference & Serving KV cache、MoE、kernel、runtime の各層が同時に更新され、推論最適化が stack 全体の問題として見えるようになった。 p. 16

Agent Safety & Security 攻撃面は prompt だけでなく workspace、long-term memory、retrieval、monitoring policy へ広がった。 p. 21

Capability & Evaluation benchmark 外の研究成果と third-party evaluation 設計が、frontier capability をどう確かめるかという問題を前景化した。 p. 25 / p. 28

Retrospective scope

本号は 2026 年 7 月を後日確認可能になった一次情報も用いて再構成する Retrospective Special である。Coverage Period と制作時点を同一視せず、vendor / project / author claim の境界は各記事と Technical Notes で明示する。

目次

Monthly Signals	2
1 Frontier Models & Voice — 5 月、モデル更新は「使い方」の更新へ広がった	5
1.1 5 月の変化を一つの system として読む	5
1.2 GPT-5.5 Instant: smarter, clearer, and more personalized	5
1.3 Anthropic May 2026 technical releases	5
1.4 Gemini API May 2026 lifecycle	5
1.5 Google DeepMind May 2026 releases	5
1.6 Advancing voice intelligence with new models in the API	5
1.7 Alibaba Model Studio May 2026 model lifecycle	6
1.8 How OpenAI delivers low-latency voice AI at scale	6
1.9 Theme Synthesis	6
Theme at a glance	7
2 Agents & Runtime — 「賢い Agent」より先に、どこで何を許すか	11
2.1 5 月の変化を一つの system として読む	11
2.2 Running Codex safely at OpenAI	11
2.3 Building a safe, effective sandbox to enable Codex on Windows	11

2.4	Kimi Code CLI May 2026 lifecycle	11
2.5	Mistral May 2026 technical releases	11
2.6	Agentic AI Workload Characteristics	11
2.7	Theme Synthesis	11
	Theme at a glance	12
3	Inference & Serving — 5 月、最適化は cache ・ MoE ・ kernel ・ runtime をまたいだ	16
3.1	5 月の変化を一つの system として読む	16
3.2	vllm-project/vllm May 2026 release series	16
3.3	sgl-project/sglang May 2026 release series	16
3.4	Release v0.6.12	16
3.5	Adaptive KV Cache Reuse for Fast Long-Context LLM Serving	16
3.6	ReMoE: Boosting Expert Reuse through Router Fine-Tuning in Memory-Constrained MoE LLM Inference	16
3.7	Theme Synthesis	17
	Theme at a glance	18
4	Agent Safety & Security — 攻撃は prompt から記憶と workspace へ伸びる	21
4.1	5 月の変化を一つの system として読む	21
4.2	From Prompt Injection to Persistent Control: Defending Agentic Harness Against Trojan Backdoors	21
4.3	Hijacking Agent Memory: Stealthy Trojan Attacks Through Conversational Interaction	21
4.4	Relevance as a Vulnerability: How Web Retrieval Degrades Safety Alignment in LLM Agents	21
4.5	Send a SCOUT First: Pre-hoc Reasoning for Adaptive Detector Allocation in Prompt-Injection Defense	21
4.6	Theme Synthesis	21
	Theme at a glance	22
5	Capability & Evaluation — benchmark の外で起きた成果をどう読むか	25
5.1	5 月の変化を一つの system として読む	25
5.2	An OpenAI model has disproved a central conjecture in discrete geometry	25
5.3	A shared playbook for trustworthy third party evaluations	25
5.4	Theme Synthesis	25
	Theme at a glance	26
6	Paper Watch — Agent を測る、測定器を疑う、modal の壁を外す	28
6.1	5 月の変化を一つの system として読む	28
6.2	AgenticVBench: Can AI Agents Complete Real-World Post-Production Tasks?	28
6.3	Identifying and Mitigating Systemic Measurement Bias in Production LLM Inference Benchmarks	28

6.4	Representation Forcing for Bottleneck-Free Unified Multimodal Models	28
6.5	Theme Synthesis	28
	Theme at a glance	29

1 Frontier Models & Voice — 5 月、モデル更新は「使い方」の更新へ広がった

GPT-5.5 Instant、Claude Opus 4.8、Gemini API、DeepMind の研究系更新、そして Realtime voice。2026 年 5 月は、モデル名の世代交代だけでなく、API lifecycle、agent 利用、音声対話という提供面が同時に動いた。[1, 2, 3, 4, 5, 6, 7]

1.1 5 月の変化を一つの system として読む

5 月の frontier model 競争を一系列の benchmark 表へ縮めると、今月の変化を見落とす。実際に一次資料へ並んだのは、ChatGPT の default model 更新、Anthropic の Opus 級モデル更新、Gemini API の GA と Managed Agents、DeepMind の複数研究・モデル発信、そして voice API の更新だった。利用者にとって重要なのは、能力の大小だけでなく「どの surface から、どの modal で、どの更新速度で使えるか」である。[1, 2, 3, 4, 5, 6, 7]

1.2 GPT-5.5 Instant: smarter, clearer, and more personalized

OpenAI は 5 月 5 日、ChatGPT の default model に関する GPT-5.5 Instant 更新を公表した。一次資料で確認できるのは更新の存在と日付であり、回答品質、hallucination 低減、personalization 改善といった効果は OpenAI 自身の説明として読む必要がある。重要なのは、frontier model の更新が新しい model ID の追加だけでなく、日常的に使われる default experience の更新として現れた点だ。[1]

1.3 Anthropic May 2026 technical releases

Anthropic の newsroom snapshot では 5 月 28 日に Claude Opus 4.8 が記録され、coding、agentic task、professional work、long-running work 向けの Opus 級 upgrade として説明されている。ここでも capability 評価は Anthropic による主張であり、本稿では release chronology と利用領域の広がりを実層から分けて扱う。[7]

1.4 Gemini API May 2026 lifecycle

Gemini API の 5 月は、5 日の multimodal File Search、7 日の Gemini 3.1 Flash-Lite GA、19 日の Gemini 3.5 Flash GA と Managed Agents public preview、28 日の native visual model GA など、model と API 機能の lifecycle が複数回動いた。API 利用者にとっては「新モデルが出た」ことと同じくらい、GA / preview / feature 追加の状態遷移が設計条件になる。[4]

1.5 Google DeepMind May 2026 releases

Google DeepMind の 5 月 snapshot には Gemini 3.5、Gemini Omni、Gemini for Science、Co-Scientist が並ぶ。ただしこの Evidence は月単位の chronology であり、日付を補完してはいけない。個々の性能優位を断定するより、frontier model と AI-for-science が同じ月の研究面で並行して更新されたことを確認する材料として使う。[5]

1.6 Advancing voice intelligence with new models in the API

OpenAI は 5 月 7 日、API 向けの新しい realtime voice model を公表し、speech reasoning、translation、transcription などの用途を説明した。音声 AI では model quality だけでなく turn-taking や latency が UX を直接左右するため、voice model の更新は serving architecture と切り離して評価しにくい。[2]

1.7 Alibaba Model Studio May 2026 model lifecycle

Alibaba Model Studio の May lifecycle は、中国系 model ecosystem でも model catalog が継続的に更新されることを示す補助線になる。本稿では個別 benchmark の比較には使わず、region や model family を含む managed model surface が動いていたという chronology context に限定して用いる。[6]

1.8 How OpenAI delivers low-latency voice AI at scale

OpenAI の low-latency voice infrastructure に関する説明は、realtime voice を単なる model release ではなく serving problem として読む材料になる。低遅延化の仕組みや効果は first-party の説明であり、独立した performance 保証ではないが、voice UX が model と infrastructure の共同設計であることは明確だ。[3]

1.9 Theme Synthesis

5 月の frontier 領域では、モデル本体と利用 surface を切り分けて評価する必要がさらに強まった。closed/API 提供では lifecycle 変更が設計条件になり、voice ではモデル能力と低遅延配信の両方が体験を決める。したがって本稿では各社の性能表現を横断ランキングへ変換せず、公開形態・利用経路・更新単位の差を中心に読む。[1, 2, 3, 4, 5, 6, 7]

Claim boundary

Claim Boundary: first-party source は公開日と source owner が説明した scope を確認する一次資料だが、capability・benchmark・safety・performance の優位性まで独立検証したものではない。[1, 2, 3, 4, 5, 6, 7]

Claim boundary

Claim Boundary: first-party index は掲載された chronology を確認する資料だが、capability や benchmark 表現は vendor claim である。また月精度の日付は日単位へ補完しない。[1, 2, 3, 4, 5, 6, 7]

SOURCE-BACKED TECHNICAL NOTES

Frontier Models & Voice — モデル更新が利用面へ広がった 5 月: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
GPT-5.5 Instant: smarter, clearer, and more personalized	主要資料	モデル更新	2026-05-05 (OFFICIAL_PUBLICATION)
Anthropic May 2026 technical releases	主要資料	OTHER	2026-05-28 (モデル_RELEASE)
Gemini API May 2026 lifecycle	主要資料	OTHER	2026-05-19 (モデル_RELEASE); 2026-05-19 (AGENT_RELEASE); 2026-05-07 (モデル_RELEASE); 2026-05-05 (API_UPDATE); 2026-05-28 (モデル_RELEASE)
Google DeepMind May 2026 releases	主要資料	OTHER	2026-05 (モデル_RELEASE); 2026-05 (モデル_RELEASE); 2026-05 (研究_RELEASE); 2026-05 (研究_RELEASE)
Advancing voice intelligence with new models in the API	主要資料	API	2026-05-07 (OFFICIAL_PUBLICATION)
Alibaba Model Studio May 2026 model lifecycle	補足資料	OTHER	2026-05-21 (モデル_RELEASE); 2026-05-25 (モデル_RELEASE); 2026-05-19 (モデル_RELEASE)
How OpenAI delivers low-latency voice AI at scale	補足資料	OTHER	2026-05-04 (OFFICIAL_PUBLICATION)

GPT-5.5 Instant: smarter, clearer, and more personalized

主要資料

組織

OpenAI

種別

モデル更新

時系列

2026-05-05 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

• 一次情報で確認できる事実: The preserved primary source identifies “GPT-5.5 Instant: smarter, clearer, and more personalized” on 2026-05-05.

• Vendor claim: OpenAI’s official feed records GPT-5.5 Instant as a May 5 update to ChatGPT’s default model and describes improvements in answer quality, hallucination reduction, and personalization controls.

読む際の境界

• 分析上の留意点: The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

• <https://openai.com/index/gpt-5-5-instant>

Anthropic May 2026 technical releases

主要資料

組織 Anthropic
種別 OTHER
時系列 2026-05-28 (モデル_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “anthropic-news” .
- **Vendor claim:** The Anthropic newsroom snapshot records the May 28 introduction of Claude Opus 4.8, described by Anthropic as an Opus-class upgrade for coding, agentic tasks, professional work, and long-running work.

読む際の境界

- **分析上の留意点:** The preserved first-party index is authoritative for the listed chronology, but capability/benchmark descriptions remain vendor claims and month-only dates retain month precision.

一次資料

- <https://www.anthropic.com/news>

Gemini API May 2026 lifecycle

主要資料

組織 Google
種別 OTHER
時系列 2026-05-19 (モデル_RELEASE); 2026-05-19 (AGENT_RELEASE);
2026-05-07 (モデル_RELEASE); 2026-05-05 (API_UPDATE); 2026-
05-28 (モデル_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “google-gemini-api-release-notes” .
- **Vendor claim:** The Gemini API changelog records May releases including Gemini 3.5 Flash GA and Managed Agents public preview on May 19, Gemini 3.1 Flash-Lite GA on May 7, multimodal File Search on May 5, and native visual model GA releases on May 28.

読む際の境界

- **分析上の留意点:** The preserved first-party index is authoritative for the listed chronology, but capability/benchmark descriptions remain vendor claims and month-only dates retain month precision.

一次資料

- <https://ai.google.dev/gemini-api/docs/changelog>

Google DeepMind May 2026 releases

主要資料

組織 Google DeepMind
種別 OTHER
時系列 2026-05 (モデル_RELEASE); 2026-05 (モデル_RELEASE); 2026-05 (研究_RELEASE); 2026-05 (研究_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “google-deepmind-blog” .
- **Vendor claim:** The DeepMind blog snapshot lists May 2026 entries for Gemini 3.5, Gemini Omni, Gemini for Science, and Co-Scientist, providing a month-level primary chronology across frontier models and AI-for-science.

読む際の境界

- 分析上の留意点: The preserved first-party index is authoritative for the listed chronology, but capability/benchmark descriptions remain vendor claims and month-only dates retain month precision.

一次資料

- <https://deepmind.google/blog/>

Advancing voice intelligence with new models in the API

主要資料

組織 OpenAI
種別 API
時系列 2026-05-07 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Advancing voice intelligence with new models in the API” on 2026-05-07.
- **Vendor claim:** OpenAI’s official feed records new realtime voice models in the API for speech reasoning, translation, and transcription.

読む際の境界

- 分析上の留意点: The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

- <https://openai.com/index/advancing-voice-intelligence-with-new-models-in-the-api>

Alibaba Model Studio May 2026 model lifecycle

補足資料

組織 Alibaba Cloud

種別 OTHER

時系列 2026-05-21 (モデル_RELEASE); 2026-05-25 (モデル_RELEASE);
2026-05-19 (モデル_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “alibaba-model-studio-model-lifecycle” .
- **Vendor claim:** The official Model Studio lifecycle snapshot contains multiple May 2026 model events, including qwen3.7-max on May 21, qwen3.7-max-preview on May 25, and qwen3.5-livetranslate-flash-realtime on May 19.

読む際の境界

- **分析上の留意点:** The preserved first-party index is authoritative for the listed chronology, but capability/benchmark descriptions remain vendor claims and month-only dates retain month precision.

一次資料

- <https://www.alibabacloud.com/help/en/model-studio/newly-released-models>

How OpenAI delivers low-latency voice AI at scale

補足資料

組織 OpenAI

種別 OTHER

時系列 2026-05-04 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “How OpenAI delivers low-latency voice AI at scale” on 2026-05-04.
- **Vendor claim:** OpenAI’s official feed describes a rebuilt WebRTC stack for low-latency, globally scaled realtime voice AI and conversational turn-taking.

読む際の境界

- **分析上の留意点:** The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

- <https://openai.com/index/delivering-low-latency-voice-ai-at-scale>

2 Agents & Runtime — 「賢い Agent」より先に、どこで何を許すか

Codex の sandbox、Windows 上の隔離、Kimi Code CLI、Mistral の MCP / workflow 更新。5 月は agent を単発の tool call ではなく、権限・network・state・長時間 task を抱える実行環境として設計する動きが前面に出た。[8, 9, 10, 11, 12]

2.1 5 月の変化を一つの system として読む

Agent が長く動くほど、モデルの推論能力だけではシステムを説明できなくなる。file system へ何を見せるか、network をどこまで許可するか、どの操作で approval を要求するか、CLI や MCP を通じて何を接続するか。5 月の一次資料は、こうした runtime 側の条件が agent capability と同じくらい重要になっていることを示している。[8, 9, 10, 11, 12]

2.2 Running Codex safely at OpenAI

OpenAI は 5 月 8 日、内部で Codex を運用する際の sandbox、approval、network policy、agent-native telemetry を説明した。これは「agent に何ができるか」より「実行時に何を許し、何を観測し、どこで人間承認を入れるか」を中心にした資料であり、agent 運用が control-plane 設計へ移ったことを示す。[9]

2.3 Building a safe, effective sandbox to enable Codex on Windows

5 月 13 日の Windows 向け Codex sandbox では、file access と network access を制御する設計が説明された。OS が変われば利用できる isolation primitive も変わるため、agent sandbox は抽象的な安全機能ではなく、host platform 固有の engineering 問題でもある。[8]

2.4 Kimi Code CLI May 2026 lifecycle

Kimi Code CLI は 5 月中に product release と複数 update を重ねた。日単位で確定できる更新と月精度に留まる項目が混在するため、本稿では無理に一つの release day へ束ねず、coding agent が CLI surface で継続更新されていた May lifecycle として扱う。[10]

2.5 Mistral May 2026 technical releases

Mistral の May snapshot では、22 日の MCP-enabled Studio tooling と Workflows public preview、23 日の remote agents、28 日の Vibe long-horizon Work/Code modes などが並ぶ。agent feature が chat UI の追加機能ではなく、workflow、remote execution、MCP 接続へ広がる方向が見える。[12]

2.6 Agentic AI Workload Characteristics

この論文は ReAct 型 agent workload を end-to-end で観測し、反復する model call、tool execution、増大する context を一体の workload として特徴づける。結果は著者報告だが、serving 側から見ても agent request が単発 inference とは異なる stateful workload になるという論点を補強する。[11]

2.7 Theme Synthesis

共通項は「agent を実行主体として扱う」ことにある。sandbox や approval は能力を下げるための付属物ではなく、長時間 task を現実の開発環境へ接続するための control plane である。一方、ReAct 型 workload の特性に関する研究結果は著者報告であり、特定 benchmark や model 構成を超えた一般則としては扱わない。[8, 9, 10, 11, 12]

Claim boundary

Claim Boundary: first-party source は公開日と source owner が説明した scope を確認する一次資料だが、capability ・ benchmark ・ safety ・ performance の優位性まで独立検証したものではない。[8, 9, 10, 11, 12]

Claim boundary

Claim Boundary: first-party index は掲載された chronology を確認する資料だが、capability や benchmark 表現は vendor claim である。また月精度の日付は日単位へ補完しない。[8, 9, 10, 11, 12]

Claim boundary

Claim Boundary: 原論文は研究内容を確認する一次資料だが、benchmark 結果 ・ speedup ・ attack success ・ quality 比較は著者報告であり、本稿で独立再現した結果ではない。[8, 9, 10, 11, 12]

SOURCE-BACKED TECHNICAL NOTES

Agents & Runtime — Codex を安全に長く動かす実行環境: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Running Codex safely at OpenAI	主要資料	AGENT	2026-05-08 (OFFICIAL_PUBLICATION)
Building a safe, effective sandbox to enable Codex on Windows	主要資料	AGENT	2026-05-13 (OFFICIAL_PUBLICATION)
Kimi Code CLI May 2026 lifecycle	主要資料	OTHER	2026-05 (PRODUCT_RELEASE); 2026-05-26 (PRODUCT_UPDATE); 2026-05-27 (PRODUCT_UPDATE); 2026-05-28 (PRODUCT_UPDATE); 2026-05-29 (PRODUCT_UPDATE)
Mistral May 2026 technical releases	主要資料	OTHER	2026-05-23 (AGENT_RELEASE); 2026-05-22 (PRODUCT_RELEASE); 2026-05-28 (AGENT_RELEASE); 2026-05-27 (研究_RELEASE)
Agentic AI Workload Characteristics	補足資料	論文	2026-05-25 (論文_RELEASE)

Running Codex safely at OpenAI

主要資料

組織 OpenAI

種別 AGENT

時系列 2026-05-08 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Running Codex safely at OpenAI” on 2026-05-08.
- **Vendor claim:** OpenAI’s official feed describes its internal Codex safety setup using sandboxing, approvals, network policies, and agent-native telemetry.

読む際の境界

- **分析上の留意点:** The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

- <https://openai.com/index/running-codex-safely>

Building a safe, effective sandbox to enable Codex on Windows

主要資料

組織 OpenAI

種別 AGENT

時系列 2026-05-13 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Building a safe, effective sandbox to enable Codex on Windows” on 2026-05-13.
- **Vendor claim:** OpenAI’s official feed describes a Windows Codex sandbox with controlled file access and network limits.

読む際の境界

- **分析上の留意点:** The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

- <https://openai.com/index/building-codex-windows-sandbox>

Kimi Code CLI May 2026 lifecycle

主要資料

組織 Moonshot AI

種別 OTHER

時系列 2026-05 (PRODUCT_RELEASE); 2026-05-26 (PRODUCT_UPDATE); 2026-05-27 (PRODUCT_UPDATE); 2026-05-28 (PRODUCT_UPDATE); 2026-05-29 (PRODUCT_UPDATE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “kimi-code-whats-new” .
- **Vendor claim:** The Kimi Code changelog records its initial May release and rapid May 26–29 iteration, including OpenAI-compatible reasoning-model support, a plugin system, scheduled tasks, automatic permission handling, GitHub plugin installation, and removal of the default step limit.

読む際の境界

- **分析上の留意点:** The preserved first-party index is authoritative for the listed chronology, but capability/benchmark descriptions remain vendor claims and month-only dates retain month precision.

一次資料

- <https://www.kimi.com/code/docs/en/kimi-code/whats-new.html>

Mistral May 2026 technical releases

主要資料

組織 Mistral AI

種別 OTHER

時系列 2026-05-23 (AGENT_RELEASE); 2026-05-22 (PRODUCT_RELEASE); 2026-05-28 (AGENT_RELEASE); 2026-05-27 (研究_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “mistral-news” .
- **Vendor claim:** The Mistral news snapshot records May technical releases including remote agents powered by Mistral Medium 3.5 on May 23, MCP-enabled Studio tooling and Workflows public preview on May 22, Vibe long-horizon Work/Code modes on May 28, and Physics AI announcements on May 27–28.

読む際の境界

- **分析上の留意点:** The preserved first-party index is authoritative for the listed chronology, but capability/benchmark descriptions remain vendor claims and month-only dates retain month precision.

一次資料

- <https://mistral.ai/news/>

Agentic AI Workload Characteristics

補足資料

組織

-

種別

論文

時系列

2026-05-25 (論文_RELEASE)

一次資料から整理した technical points

- **一次情報で確認できる事実:** The preserved primary source identifies “Agentic AI Workload Characteristics” on 2026-05-25.
- **Author claim:** The paper characterizes ReAct-style agent workloads end-to-end, tracing repeated model calls, tools, and growing context across multiple benchmarks and model configurations.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.26297v1>

3 Inference & Serving — 5 月、最適化は cache・MoE・kernel・runtime をまたいだ

vLLM、SGLang、FlashInfer の release が続く一方、研究側では KV cache 再利用や MoE expert reuse が掘り下げられた。モデルの外側にある serving stack は、単一 kernel ではなく複数 layer の協調問題になっている。[13, 14, 15, 16, 17, 18, 19, 20]

3.1 5 月の変化を一つの system として読む

同じモデルでも、どの runtime・attention backend・cache 方針・parallelism・kernel で動かすかによって実運用の制約は大きく変わる。5 月は vLLM、SGLang、FlashInfer がそれぞれ継続的に更新され、研究側でも long-context KV reuse や memory-constrained MoE inference が別の角度から扱われた。[13, 14, 15, 16, 17, 18, 19, 20]

3.2 vllm-project/vllm May 2026 release series

vLLM は 5 月 4 日の v0.20.1、15 日の v0.21.0、29 日の v0.22.0 と更新を重ねた。release notes では DeepSeek V4 hardening、KV/offload、attention backend、Model Runner V2、speculative/disaggregated serving などが扱われており、serving engine が複数の model family と runtime technique を同時に吸収している。[17, 18, 20]

3.3 sgl-project/sglang May 2026 release series

SGLang は 5 月 5 日の v0.5.11 と 16 日の v0.5.12 で、speculative decoding、disaggregated prefix caching、model support、DeepSeek V4 inference pathなどを更新した。個別の throughput 値ではなく、prefix/cache と model-specific execution が同じ release series で進んでいる点に注目したい。[14, 15]

3.4 Release v0.6.12

FlashInfer v0.6.12 は 5 月 29 日に公開され、release notes には NVFP4 quantization、MoE kernel、GQA/MLA path、model/backend support が並ぶ。kernel layer でも quantization・attention・MoE が密接に結び付いており、frontier model 対応が低 level runtime へ波及している。[16]

3.5 Adaptive KV Cache Reuse for Fast Long-Context LLM Serving

CacheTune は、厳密な prefix 一致だけに頼らず、attention 関係を保つため必要な context を適応的に再計算しながら KV cache を再利用する設計を提案する。これは著者による研究結果であり、一般的な speedup 保証ではないが、long-context serving で「何を再利用できるか」自体を最適化対象にする方向を示す。[13]

3.6 ReMoE: Boosting Expert Reuse through Router Fine-Tuning in Memory-Constrained MoE LLM Inference

ReMoE は memory-constrained な MoE inference で expert reuse を高めるため router fine-tuning を利用する。MoE serving では計算量だけでなく expert weight の resident / transfer cost が問題になるため、model architecture と runtime memory 制約の境界を跨ぐ研究として位置付けられる。[19]

3.7 Theme Synthesis

ここで重要なのは、個々の project benchmark を一つの勝敗表へ混ぜないことだ。release note は実装変更の一次資料だが性能値は project 条件に依存し、論文の speedup も著者が選んだ model・hardware・workload・baseline に依存する。5 月の意味は、最適化対象が cache から expert、kernel、runtime まで stack 全体へ広がった点にある。[13, 14, 15, 16, 17, 18, 19, 20]

Claim boundary

Claim Boundary: GitHub release notes は release chronology と記載された実装変更を確認する一次資料だが、project が示す performance や cross-hardware な一般化は本稿で独立再現していない。[13, 14, 15, 16, 17, 18, 19, 20]

Claim boundary

Claim Boundary: 原論文は研究内容を確認する一次資料だが、benchmark 結果・speedup・attack success・quality 比較は著者報告であり、本稿で独立再現した結果ではない。[13, 14, 15, 16, 17, 18, 19, 20]

SOURCE-BACKED TECHNICAL NOTES

Inference & Serving — cache・MoE・kernel・runtime の最適化: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
vllm-project/vllm May 2026 release series	主要資料	FRAMEWORK	2026-05-04 (FRAMEWORK_RELEASE); 2026-05-15 (FRAMEWORK_RELEASE); 2026-05-29 (FRAMEWORK_RELEASE)
sgl-project/sglang May 2026 release series	主要資料	FRAMEWORK	2026-05-05 (FRAMEWORK_RELEASE); 2026-05-16 (FRAMEWORK_RELEASE)
Release v0.6.12	主要資料	FRAMEWORK	2026-05-29 (FRAMEWORK_RELEASE)
Adaptive KV Cache Reuse for Fast Long-Context LLM Serving	補足資料	論文	2026-05-20 (論文_RELEASE)
ReMoE: Boosting Expert Reuse through Router Fine-Tuning in Memory-Constrained MoE LLM Inference	補足資料	論文	2026-05-26 (論文_RELEASE)

vllm-project/vllm May 2026 release series主要資料

組織vllm-project/vllm

種別FRAMEWORK

時系列2026-05-04 (FRAMEWORK_RELEASE); 2026-05-15 (FRAMEWORK_RELEASE); 2026-05-29 (FRAMEWORK_RELEASE)

一次資料から整理した technical points

• 一次情報で確認できる事実: The preserved primary source identifies “v0.20.1” on 2026-05-04.

• 一次情報で確認できる事実: The preserved primary source identifies “v0.21.0” on 2026-05-15.

• 一次情報で確認できる事実: The preserved primary source identifies “v0.22.0” on 2026-05-29.

• **Project claim:** vLLM’s May releases v0.20.1, v0.21.0, and v0.22.0 form a coherent serving series centered on DeepSeek V4 hardening, KV/offload evolution, attention backends, Model Runner V2, and speculative/disaggregated serving.

読む際の境界

• **分析上の留意点:** Official repository release notes verify release chronology and listed implementation changes; project performance claims and cross-hardware generalization were not independently reproduced.

一次資料

• <https://github.com/vllm-project/vllm/releases/tag/v0.20.1>

• <https://github.com/vllm-project/vllm/releases/tag/v0.21.0>

• <https://github.com/vllm-project/vllm/releases/tag/v0.22.0>

18

sgl-project/sglang May 2026 release series

主要資料

組織 sgl-project/sglang

種別 FRAMEWORK

時系列 2026-05-05 (FRAMEWORK_RELEASE); 2026-05-16 (FRAMEWORK_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “v0.5.11” on 2026-05-05.
- 一次情報で確認できる事実: The preserved primary source identifies “v0.5.12” on 2026-05-16.
- **Project claim:** SGLang’s May releases v0.5.11 and v0.5.12 form a coherent serving series covering speculative decoding, disaggregated prefix caching, broad model support, and a substantial DeepSeek V4 inference path.

読む際の境界

- **分析上の留意点:** Official repository release notes verify release chronology and listed implementation changes; project performance claims and cross-hardware generalization were not independently reproduced.

一次資料

- <https://github.com/sgl-project/sglang/releases/tag/v0.5.11>
- <https://github.com/sgl-project/sglang/releases/tag/v0.5.12>

Release v0.6.12

主要資料

組織 flashinfer-ai/flashinfer

種別 FRAMEWORK

時系列 2026-05-29 (FRAMEWORK_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Release v0.6.12” on 2026-05-29.
- **Project claim:** FlashInfer v0.6.12 adds inference-kernel work including NVFP4 quantization, MoE kernels, GQA/MLA paths, and model/backend support relevant to low-level serving.

読む際の境界

- **分析上の留意点:** Official repository release notes verify release chronology and listed implementation changes; project performance claims and cross-hardware generalization were not independently reproduced.

一次資料

- <https://github.com/flashinfer-ai/flashinfer/releases/tag/v0.6.12>

Adaptive KV Cache Reuse for Fast Long-Context LLM Serving

補足資料

組織

-

種別

論文

時系列

2026-05-20 (論文_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Adaptive KV Cache Reuse for Fast Long-Context LLM Serving” on 2026-05-20.
- **Author claim:** CacheTune extends KV-cache reuse beyond strict prefixes by adaptively recomputing context needed to preserve attention relationships in long-context serving.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.24022v1>

ReMoE: Boosting Expert Reuse through Router Fine-Tuning in Memory-Constrained MoE LLM Inference

補足資料

組織

-

種別

論文

時系列

2026-05-26 (論文_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “ReMoE: Boosting Expert Reuse through Router Fine-Tuning in Memory-Constrained MoE LLM Inference” on 2026-05-26.
- **Author claim:** ReMoE fine-tunes MoE routing to increase expert reuse when only a subset of experts can remain cached under memory-constrained inference.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.27081v1>

4 Agent Safety & Security — 攻撃は prompt から記憶と workspace へ伸びる

persistent control、agent memory poisoning、retrieval 経由の alignment 低下、adaptive detector allocation。5 月の研究は、長時間 agent では「一度の危険な prompt」だけを守ればよいわけではないことを示した。[21, 22, 23, 24]

4.1 5 月の変化を一つの system として読む

tool-using agent の安全性を prompt injection だけで語ると、長時間化によって増える状態を取りこぼす。workspace へ残る control-like content、会話から選択的に書き込まれる long-term memory、retrieval 結果、detector をどこへ配分するかという runtime 判断は、それぞれ異なる attack surface である。[21, 22, 23, 24]

4.2 From Prompt Injection to Persistent Control: Defending Agentic Harness Against Trojan Backdoors

ClawTrojan は local agentic harness を対象に、prompt injection を一度きりの指示改変ではなく、workspace へ残る情報を介した multi-step persistent control としてモデル化する。著者は DASGuard による untrusted control-like content の trace / removal も提案し、simulated workspace で高い ASR を報告しているが、その数値は特定環境での著者評価に限定される。[22]

4.3 Hijacking Agent Memory: Stealthy Trojan Attacks Through Conversational Interaction

MemPoison は会話を通じて selective long-term memory pipeline へ trigger と payload を結び付け、後続 interaction で悪性挙動を誘発する攻撃を扱う。著者は複数 domain・memory mechanism で高い attack success を報告するが、重要なのは数値そのものより、memory write が新しい trust boundary になるという点だ。[24]

4.4 Relevance as a Vulnerability: How Web Retrieval Degrades Safety Alignment in LLM Agents

この研究は、retrieval で「関連性の高い」情報を取り込むことが必ずしも safety alignment と一致しないという問題を扱う。retriever が有用性を最大化するほど、安全性の低い context も強く注入され得るという構造は、RAG / web agent で relevance と trust を別軸に設計する必要性を示す。[21]

4.5 Send a SCOUT First: Pre-hoc Reasoning for Adaptive Detector Allocation in Prompt-Injection Defense

SCOUT は、すべての input へ同じ防御 cost を掛けるのではなく、pre-hoc reasoning で risk を見積もって detector allocation を適応させる方向を提案する。防御性能は著者評価に依存するが、agent security を static filter ではなく runtime resource allocation として考える点が特徴的だ。[23]

4.6 Theme Synthesis

これらの研究をまとめて「agent は危険」と一般化するのは不正確だ。ClawTrojan、MemPoison、retrieval degradation、SCOUT は攻撃者能力・対象 component・評価環境が異なる。共通して見えるのは、長時間 agent では権限だけでなく provenance、state 更新、retrieval、monitoring policy まで control boundary として扱う必要がある、という設計上の問いである。[\[21, 22, 23, 24\]](#)

Claim boundary

Claim Boundary: 原論文は研究内容を確認する一次資料だが、benchmark 結果・speedup・attack success・quality 比較は著者報告であり、本稿で独立再現した結果ではない。[\[21, 22, 23, 24\]](#)

SOURCE-BACKED TECHNICAL NOTES

Agent Safety & Security — 記憶・retrieval・harness が新しい攻撃面になる: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
From Prompt Injection to Persistent Control: Defending Agentic Harness Against Trojan Backdoors	主要資料	論文	2026-05-29 (論文_RELEASE)
Hijacking Agent Memory: Stealthy Trojan Attacks Through Conversational Interaction	主要資料	論文	2026-05-28 (論文_RELEASE)
Relevance as a Vulnerability: How Web Retrieval Degrades Safety Alignment in LLM Agents	補足資料	論文	2026-05-28 (論文_RELEASE)
Send a SCOUT First: Pre-hoc Reasoning for Adaptive Detector Allocation in Prompt-Injection Defense	補足資料	論文	2026-05-29 (論文_RELEASE)

From Prompt Injection to Persistent Control: Defending Agentic Harness Against Trojan Backdoors

主要資料

組織

-

種別

論文

時系列

2026-05-29 (論文_RELEASE)

一次資料から整理した technical points

- **一次情報で確認できる事実:** The preserved primary source identifies “From Prompt Injection to Persistent Control: Defending Agentic Harness Against Trojan Backdoors” on 2026-05-29.
- **Author claim:** ClawTrojan models multi-step persistent prompt-injection attacks in local agentic harnesses, while DASGuard traces and removes untrusted control-like workspace content.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.31042v1>

Hijacking Agent Memory: Stealthy Trojan Attacks Through Conversational Interaction

主要資料

資料

組織

-

種別

論文

時系列

2026-05-28 (論文_RELEASE)

一次資料から整理した technical points

- **一次情報で確認できる事実:** The preserved primary source identifies “Hijacking Agent Memory: Stealthy Trojan Attacks Through Conversational Interaction” on 2026-05-28.
- **Author claim:** MemPoison attacks selective long-term memory pipelines through conversational interactions using trigger/payload binding, entity masquerading, and embedding optimization.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.29960v1>

Relevance as a Vulnerability: How Web Retrieval Degrades Safety Alignment in LLM Agents

補足資料

組織

-

種別

論文

時系列

2026-05-28 (論文_RELEASE)

一次資料から整理した technical points

- **一次情報で確認できる事実:** The preserved primary source identifies “Relevance as a Vulnerability: How Web Retrieval Degrades Safety Alignment in LLM Agents” on 2026-05-28.
- **Author claim:** AgentREVEAL analyzes how web retrieval integration and retrieved-content relevance can degrade safety alignment in LLM agents.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.29224v1>

Send a SCOUT First: Pre-hoc Reasoning for Adaptive Detector Allocation in Prompt-Injection Defense

補足資料

組織

-

種別

論文

時系列

2026-05-29 (論文_RELEASE)

一次資料から整理した technical points

- **一次情報で確認できる事実:** The preserved primary source identifies “Send a SCOUT First: Pre-hoc Reasoning for Adaptive Detector Allocation in Prompt-Injection Defense” on 2026-05-29.
- **Author claim:** SCOUT dynamically allocates heterogeneous prompt-injection detectors and optional LLM judging based on predicted per-request reliability and latency.

読む際の境界

- **分析上の留意点:** The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.30837v2>

5 Capability & Evaluation — benchmark の外で起きた成果をどう読むか

OpenAI は 5 月、モデルが離散幾何の長年の予想を反証したと報告した。同じ月には第三者評価の playbook も公開された。単一の印象的成果を一般能力へ拡張せず、何をもって能力の証拠とするかを考える。[25, 26]

5.1 5 月の変化を一つの system として読む

standard benchmark は比較可能性を与える一方、実際の研究課題で現れる能力をすべて覆うわけではない。5 月 20 日に OpenAI が公表した離散幾何の事例は、その意味で強い attention を集めるタイプの成果である。しかし、一次資料は OpenAI 自身の説明であり、そこから「数学全般で人間を超えた」といった広い結論を導くことはできない。[25, 26]

5.2 An OpenAI model has disproved a central conjecture in discrete geometry

OpenAI は 5 月 20 日、同社 model が unit-distance problem に関する長年の予想を反証したと報告した。公開日と「OpenAI がそう報告した」ことは確認できるが、数学的成果の意味や model の寄与範囲は first-party 説明に依存する。本稿ではこの事例を、benchmark 外の real research task で現れる capability をどう検証するかという問題設定へつなげる。[25]

5.3 A shared playbook for trustworthy third party evaluations

5 月 29 日、OpenAI は frontier model の third-party evaluation について、capability、safeguard、evaluation validity を扱う playbook を公表した。評価者の独立性だけでなく、test condition や measurement validity まで設計対象にする考え方は、印象的な単発成果を一般能力へ拡張しないための補助線になる。[26]

5.4 Theme Synthesis

重要なのは成果の派手さより、評価の chain of custody である。誰が課題を設定し、model output をどう検証し、第三者がどこまで再評価できるか。5 月末の third-party evaluation playbook は、capability だけでなく safeguard や evaluation validity を評価対象に含める方向を示す。個別の成功例と一般的な能力評価を分離することが、frontier model を読むうえでますます重要になっている。[25, 26]

Claim boundary

Claim Boundary: first-party source は公開日と source owner が説明した scope を確認する一次資料だが、capability・benchmark・safety・performance の優位性まで独立検証したものではない。[25, 26]

SOURCE-BACKED TECHNICAL NOTES

Capability & Evaluation — benchmark の外で能力をどう確かめるか: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
An OpenAI model has disproved a central conjecture in discrete geometry	主要資料	OTHER	2026-05-20 (OFFICIAL_PUBLICATION)
A shared playbook for trustworthy third party evaluations	補足資料	安全性事象	2026-05-29 (OFFICIAL_PUBLICATION)

An OpenAI model has disproved a central conjecture in discrete geometry 主要資料

組織 OpenAI

種別 OTHER

時系列 2026-05-20 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “An OpenAI model has disproved a central conjecture in discrete geometry” on 2026-05-20.
- **Vendor claim:** OpenAI’s official feed reports that an OpenAI model disproved a long-standing conjecture in the unit-distance problem in discrete geometry.

読む際の境界

- **分析上の留意点:** The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

- <https://openai.com/index/model-disproves-discrete-geometry-conjecture>

A shared playbook for trustworthy third party evaluations

補足資料

組織 OpenAI

種別 安全性事象

時系列 2026-05-29 (OFFICIAL_PUBLICATION)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “A shared playbook for trustworthy third party evaluations” on 2026-05-29.
- **Vendor claim:** OpenAI’s official feed publishes a playbook for third-party frontier-model

evaluations covering capabilities, safeguards, and evaluation validity.

読む際の境界

- **分析上の留意点:** The preserved first-party feed item is authoritative for publication chronology and vendor-described scope; detailed capability, benchmark, or safety claims were not independently reproduced.

一次資料

- <https://openai.com/index/trustworthy-third-party-evaluations-foundations>

6 Paper Watch — Agent を測る、測定器を疑う、modal の壁を外す

AgenticVBench、production inference benchmark の measurement bias、Representation Forcing。5 月の論文から、agent 評価、serving 測定、unified multimodal という三つの研究方向を短く追う。[27, 28, 29]

6.1 5 月の変化を一つの system として読む

Paper Watch では、今月の主軸記事と重なるが独立した論点を持つ 3 本を取り上げる。いずれも原論文は一次資料だが、ここで紹介する性能・比較・有効性は著者報告であり、独立再現済みの結論ではない。[27, 28, 29]

6.2 AgenticVBench: Can AI Agents Complete Real-World Post-Production Tasks?

AgenticVBench は text、image、audio、video、planning、tool use を組み合わせる real-world post-production workflow を 100 task で評価する benchmark を提案する。著者報告では最良 stack も約 30%をわずかに超える程度で、現実的な multimodal workflow が依然難しいことを示すが、model ranking 自体は評価構成に依存する。[29]

6.3 Identifying and Mitigating Systemic Measurement Bias in Production LLM Inference Benchmarks

この論文は production LLM inference benchmark の client-side measurement に systemic bias が入り得ると指摘し、Python GIL が TTFT / TPOT 観測へ与える影響を queueing analysis で扱う。serving 性能を比較するとき、server だけでなく measurement tool 自身を検証対象にする必要があるという方法論的警告である。[27]

6.4 Representation Forcing for Bottleneck-Free Unified Multimodal Models

Representation Forcing は unified multimodal model で modal 間の representation bottleneck を減らす設計を提案する。ここでは著者の性能比較を独立事実とは扱わず、text・vision などの一つの model へ統合する際に intermediate representation 設計が重要な研究対象になっていることを紹介する。[28]

6.5 Theme Synthesis

3 本に共通するのは、モデルそのものだけでなく「どう測るか」「どこで表現を分けるか」が system capability を左右する点である。agent task の現実性、benchmark client の測定 bias、multimodal representation の bottleneck はいずれも、数字だけでは見えにくい設計条件を前景化している。[27, 28, 29]

Claim boundary

Claim Boundary: 原論文は研究内容を確認する一次資料だが、benchmark 結果・speedup・attack success・quality 比較は著者報告であり、本稿で独立再現した結果ではない。[27, 28, 29]

SOURCE-BACKED TECHNICAL NOTES

Paper Watch — agent 評価・測定 bias・unified multimodal: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
AgenticVBench: Can AI Agents Complete Real-World Post-Production Tasks?	主要資料	論文	2026-05-26 (論文_RELEASE)
Identifying and Mitigating Systemic Measurement Bias in Production LLM Inference Benchmarks	主要資料	論文	2026-05-22 (論文_RELEASE)
Representation Forcing for Bottleneck-Free Unified Multimodal Models	主要資料	論文	2026-05-29 (論文_RELEASE)

AgenticVBench: Can AI Agents Complete Real-World Post-Production Tasks? 主要資料

組織

-

種別

論文

時系列

2026-05-26 (論文_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “AgenticVBench: Can AI Agents Complete Real-World Post-Production Tasks?” on 2026-05-26.
- Author claim: AgenticVBench evaluates multimodal agents on real post-production workflows requiring text, image, audio, video, planning, and tool use.

読む際の境界

- 分析上の留意点: The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.27705v1>

Identifying and Mitigating Systemic Measurement Bias in Production LLM Inference Benchmarks

主要資料

資料

組織 -
 種別 論文
 時系列 2026-05-22 (論文_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Identifying and Mitigating Systemic Measurement Bias in Production LLM Inference Benchmarks” on 2026-05-22.
- **Author claim:** The paper argues that production LLM inference benchmarks can acquire systemic client-side measurement bias and models Python GIL effects on TTFT/TPOT using queueing analysis.

読む際の境界

- 分析上の留意点: The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.24217v2>

Representation Forcing for Bottleneck-Free Unified Multimodal Models

主要資料

組織 -
 種別 論文
 時系列 2026-05-29 (論文_RELEASE)

一次資料から整理した technical points

- 一次情報で確認できる事実: The preserved primary source identifies “Representation Forcing for Bottleneck-Free Unified Multimodal Models” on 2026-05-29.
- **Author claim:** Representation Forcing makes visual representations explicit autoregressive intermediate targets inside a unified multimodal model, avoiding a separately pretrained generative VAE.

読む際の境界

- 分析上の留意点: The preserved original arXiv metadata/abstract is primary-paper evidence, but experimental results and generalization are author-reported and were not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2605.31604v4>

References / Source Notes

- [1] *GPT-5.5 Instant: smarter, clearer, and more personalized*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 5, 2026. URL: <https://openai.com/index/gpt-5-5-instant> (visited on 08/11/2026).
- [2] *Advancing voice intelligence with new models in the API*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 7, 2026. URL: <https://openai.com/index/advancing-voice-intelligence-with-new-models-in-the-api> (visited on 08/11/2026).
- [3] *How OpenAI delivers low-latency voice AI at scale*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 4, 2026. URL: <https://openai.com/index/delivering-low-latency-voice-ai-at-scale> (visited on 08/11/2026).
- [4] *google-gemini-api-release-notes*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. Google. URL: <https://ai.google.dev/gemini-api/docs/changelog> (visited on 08/11/2026).
- [5] *google-deepmind-blog*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. Google DeepMind. URL: <https://deepmind.google/blog/> (visited on 08/11/2026).
- [6] *alibaba-model-studio-model-lifecycle*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. Alibaba Cloud. URL: <https://www.alibabacloud.com/help/en/model-studio/newly-released-models> (visited on 08/11/2026).
- [7] *anthropic-news*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. Anthropic. URL: <https://www.anthropic.com/news> (visited on 08/11/2026).
- [8] *Building a safe, effective sandbox to enable Codex on Windows*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 13, 2026. URL: <https://openai.com/index/building-codex-windows-sandbox> (visited on 08/11/2026).
- [9] *Running Codex safely at OpenAI*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 8, 2026. URL: <https://openai.com/index/running-codex-safely> (visited on 08/11/2026).
- [10] *kimi-code-whats-new*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. Moonshot AI. URL: <https://www.kimi.com/code/docs/en/kimi-code/whats-new.html> (visited on 08/11/2026).

- [11] *Agentic AI Workload Characteristics*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 25, 2026. URL: <http://arxiv.org/abs/2605.26297v1> (visited on 08/11/2026).
- [12] *mistral-news*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. Mistral AI. URL: <https://mistral.ai/news/> (visited on 08/11/2026).
- [13] *Adaptive KV Cache Reuse for Fast Long-Context LLM Serving*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 20, 2026. URL: <http://arxiv.org/abs/2605.24022v1> (visited on 08/11/2026).
- [14] *v0.5.11*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. sgl-project/sglang. May 5, 2026. URL: <https://github.com/sgl-project/sglang/releases/tag/v0.5.11> (visited on 08/11/2026).
- [15] *v0.5.12*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. sgl-project/sglang. May 16, 2026. URL: <https://github.com/sgl-project/sglang/releases/tag/v0.5.12> (visited on 08/11/2026).
- [16] *Release v0.6.12*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. flashinfer-ai/flashinfer. May 29, 2026. URL: <https://github.com/flashinfer-ai/flashinfer/releases/tag/v0.6.12> (visited on 08/11/2026).
- [17] *v0.20.1*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. vllm-project/vllm. May 4, 2026. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.20.1> (visited on 08/11/2026).
- [18] *v0.22.0*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. vllm-project/vllm. May 29, 2026. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.22.0> (visited on 08/11/2026).
- [19] *ReMoE: Boosting Expert Reuse through Router Fine-Tuning in Memory-Constrained MoE LLM Inference*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 26, 2026. URL: <http://arxiv.org/abs/2605.27081v1> (visited on 08/11/2026).
- [20] *v0.21.0*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. vllm-project/vllm. May 15, 2026. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.21.0> (visited on 08/11/2026).
- [21] *Relevance as a Vulnerability: How Web Retrieval Degrades Safety Alignment in LLM Agents*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 28, 2026. URL: <http://arxiv.org/abs/2605.29224v1> (visited on 08/11/2026).

- [22] *From Prompt Injection to Persistent Control: Defending Agentic Harness Against Trojan Backdoors*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 29, 2026. URL: <http://arxiv.org/abs/2605.31042v1> (visited on 08/11/2026).
- [23] *Send a SCOUT First: Pre-hoc Reasoning for Adaptive Detector Allocation in Prompt-Injection Defense*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 29, 2026. URL: <http://arxiv.org/abs/2605.30837v2> (visited on 08/11/2026).
- [24] *Hijacking Agent Memory: Stealthy Trojan Attacks Through Conversational Interaction*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 28, 2026. URL: <http://arxiv.org/abs/2605.29960v1> (visited on 08/11/2026).
- [25] *An OpenAI model has disproved a central conjecture in discrete geometry*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 20, 2026. URL: <https://openai.com/index/model-disproves-discrete-geometry-conjecture> (visited on 08/11/2026).
- [26] *A shared playbook for trustworthy third party evaluations*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. OpenAI. May 29, 2026. URL: <https://openai.com/index/trustworthy-third-party-evaluations-foundations> (visited on 08/11/2026).
- [27] *Identifying and Mitigating Systemic Measurement Bias in Production LLM Inference Benchmarks*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 22, 2026. URL: <http://arxiv.org/abs/2605.24217v2> (visited on 08/11/2026).
- [28] *Representation Forcing for Bottleneck-Free Unified Multimodal Models*. Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 29, 2026. URL: <http://arxiv.org/abs/2605.31604v4> (visited on 08/11/2026).
- [29] *AgenticVBench: Can AI Agents Complete Real-World Post-Production Tasks?* Primary source used for chronology and technical verification; reported capability/performance remains attributed to the source owner/authors. May 26, 2026. URL: <http://arxiv.org/abs/2605.27705v1> (visited on 08/11/2026).