
Japanese Generative AI Technical Survey

SP-2026-M06

Special / Coverage 2026-06-01 – 2026-06-30 / Retrospective as of 2026-08-11

2026 年 6 月 — Agent は実行系へ広がった

モデル競争の一方で、memory、scheduling、serving、authorization、そして科学実験 workflow まで、生成 AI の agent 化がモデルの外側へ広がった 1 か月を振り返る。

Frontier Models — モデル競争から利用形態の競争へ / AI for Science — Agent が実験ワークフローへ入る

Editorial cutoff

Coverage window: 2026-06-01 – 2026-06-30 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Retrospective。

Monthly Signals

Frontier Models 性能順位だけでなく、open-weight、multimodal、API lifecycle、computer-use、coding/agent 統合という提供形態の違いが競争軸として前景化した。 p. 4

長時間 Agent の実行と安全 長時間 task では model 能力に加えて、scheduling、persistent memory、context transformation、per-call authorization、複数 tool をまたぐ trust boundary が system 設計の中心課題になった。 p. 9 / p. 18

Inference & Serving custom accelerator、kernel、parallelism、serving runtime が同時に更新され、推論最適化が単一 component ではなく stack 全体の問題として見えるようになった。 p. 13

AI for Science near-autonomous chemistry workflow は、AI が提案だけでなく実験工程を含む長時間 workflow へ入り始めたことと、human-in-the-loop の責任境界を同時に示した。 p. 22

Paper Watch execution-time safety kernel、context rot、memory evaluation confound が、長時間 Agent を制御し正しく測るための研究課題として立ち上がった。 p. 25

Retrospective scope

本号は 2026 年 7 月を後日確認可能になった一次情報も用いて再構成する Retrospective Special である。Coverage Period と制作時点を同一視せず、vendor / project / author claim の境界は各記事と Technical Notes で明示する。

目次

Monthly Signals	2
1 Frontier Models — 6 月、競争は「モデル性能」から提供形態へ広がった	4
1.1 6 月の流れを、提供形態の変化として読む	4
1.2 open-weight と computer operation を同じモデル面に置く MiniMax M3	4
1.3 同じ「frontier」でも、採用判断の物差しは異なる	4
横断比較 — 6 月のモデル競争は「何を出したか」だけでは測れない	5
Theme at a glance	6
2 Agents & Memory — 長時間動作は「モデルの賢さ」だけでは成立しない	9
2.1 Agent を一回の推論ではなく実行系として捉える	9
2.2 永続 memory は context 長とは別の設計問題	9
2.3 context transformation を先回りする	9
横断比較 — 長時間 Agent では状態をどこで持つかが設計になる	10
Theme at a glance	11
3 Inference & Serving — 6 月、最適化競争は chip から runtime まで積み上がった	13
3.1 hardware: inference 専用 chip が engineering sample へ	13

3.2	runtime: 新モデル対応と execution engine の更新	13
3.3	parallelism: 実行中に構成を切り替える	13
3.4	memory: HBM だけを前提にしない serving	13
	横断比較 — accelerator から runtime まで最適化層が連動する	14
	Theme at a glance	15
4	Agent Safety & Security — 「使える」と「許される」を分ける	18
4.1	Capability gate は Authorization ではない	18
4.2	防御を知った attack で評価する	18
4.3	persistent agent は computer system として攻撃面が増える	18
4.4	MCP では tool 集合そのものが trust boundary になる	18
4.5	本番前に、過去の会話を候補 model へ再生する	18
	横断比較 — 『Agent security』を権限・注入・接続面・評価へ分解する	19
	Theme at a glance	20
5	AI for Science — Agent が「提案」から実験 workflow へ踏み込む	22
5.1	「near-autonomous」の中身を見る	22
5.2	結果は「11/14」だが、独立再現ではない	22
5.3	科学特化 model の評価面も広がる	22
	横断比較 — 科学 Agent の価値は『完全自律』ではなく workflow 境界で読む	23
	Theme at a glance	24
6	Paper Watch — 長時間 Agent を「守る・止めない・正しく測る」	25
	Theme at a glance	26
7	総括 — 6 月の Agent 化を『モデル』から『実行系』までつなぐ	28
7.1	Frontier Models — model 名より delivery surface を見る	28
7.2	Agents & Memory — 長時間化すると状態管理が表面化する	28
7.3	Inference & Serving — model 進化を受け止める stack も動いている	28
7.4	Agent Safety & Security — 実行系が広がれば trust boundary も増える	28
7.5	AI for Science — 実世界 workflow では human boundary が消えない	28
7.6	Paper Watch — 長時間 Agent の測定と制御もまだ研究途上	29
	各章はどうつながるか	29
	6 月をどう位置づけるか	29

1 Frontier Models — 6 月、競争は「モデル性能」から提供形態へ広がった

2026 年 6 月は MiniMax M3、Claude Sonnet 5、Qwen 系更新、Gemini API、Kimi Code が相次いで動いた。重要なのは一列の性能順位ではなく、open-weight、multimodal、API lifecycle、computer-use、coding/agent 統合という提供形態の違いである。月末の GPT-5.6 は limited preview であり、7 月の本格展開とは分けて読む必要がある。[1, 2, 3, 4, 5]

1.1 6 月の流れを、提供形態の変化として読む

6 月 1 日の MiniMax M3 と Alibaba Model Studio の更新から始まり、Kimi Code の Goal mode や/swarm、月後半の Gemini API の computer-use 系更新、6 月 30 日の Anthropic のモデル・科学・安全性関連発表へと、モデルそのものと利用面の更新が並行した。月末には GPT-5.6 series の limited preview も公表されたが、これは一般提供ではない。[6, 1, 2, 3, 4, 5]

1.2 open-weight と computer operation を同じモデル面に置く MiniMax M3

MiniMax は M3 について、MSA sparse attention、最大 1M context、画像・動画入力、desktop-computer operation、open weights を組み合わせたモデルとして説明した。ここで注目すべきなのは、長文脈や multimodal だけでなく、モデル配布と computer-use 志向が一つの製品像にまとめられている点である。[3]

Anthropic の 6 月 30 日の newsroom には Claude Sonnet 5、Claude Science、Fable 5 の再展開と安全性 framework 更新が同日に並ぶ。モデル更新を単独で見ると、agentic use、科学用途、安全性運用を一つの product lifecycle として束ねていることが 6 月末の特徴だった。[5]

Alibaba Model Studio の 6 月は Qwen3.7-Plus の更新から始まり、Qwen3.7-Max snapshot、video 系、image 系へと複数 modal の model lifecycle が続いた。さらに Kimi K2.7 Code の地域 availability も記録され、model catalog 自体が静的な一覧ではなく、能力・modal・地域提供を継続更新する surface になっている。[4]

Gemini API でも、model shutdown や deprecation と並行して streaming speech、computer-use、月末の新 preview/GA が進んだ。新モデルだけでなく、終了・移行・機能追加を含む API lifecycle が利用者の設計条件を変える。[2]

Kimi Code は 6 月に Goal mode、/swarm、Kimi K2.7 Code の release/open-source を段階的に投入した。coding model の更新を、単発の chat 補助ではなく goal-driven・multi-agent な開発 workflow へ接続しようとする動きとして読める。[1]

Google DeepMind 側でも DiffusionGemma、Gemma 系更新、computer-use や voice、agent-safety roadmap が 6 月の公式発信に並んだ。個別 model の優劣より、multimodal 生成と agent 操作、安全性設計が並行して開発面へ出てきたことが重要である。[7]

Claim boundary

OpenAI が 6 月 26 日に示した GPT-5.6 series は limited preview であり、Sol は小規模な trusted partner 向けを含む限定段階だった。7 月の一般提供を 6 月へ遡及させてはならない。6 月号では、翌月の本格展開へつながる chronology bridge としてのみ位置付ける。[6]

1.3 同じ「frontier」でも、採用判断の物差しは異なる

open-weight で持ち込めるモデル、managed API として更新され続けるモデル、coding/agent 環境と一体化したモデルでは、利用者が評価すべきリスクと便益が違う。6 月は「最高性能は何か」より、「どの実行環境へ、どの更新速度で、どの操作能力まで持ち込めるか」が競争軸として前景化した月だった。[1, 2, 3, 7, 4]

Claim boundary

各社の公式 release page や newsroom は、公開日・availability・記載機能を確認する一次資料である一方、capability や benchmark の優位性まで独立検証したものではない。本稿では vendor の性能表現をそのまま横断ランキングへ変換しない。[1, 2, 3, 7, 4, 5]

Claim boundary

GPT-5.6 に関する 6 月時点の capability、efficiency、performance 表現も OpenAI の first-party claim として扱う。limited preview という availability の事実と、性能評価の主張は分離して読む。[6]

THEME SYNTHESIS

横断比較 — 6 月のモデル競争は「何を出したか」だけでは測れない

6 月の主要 release を並べると、model capability の主張そのものより、open-weight か managed API か、multimodal/computer-use/coding へどう接続したか、preview・GA・deprecation を含む提供状態が採用判断を左右していたことが見える。

観察軸	6 月の一次資料・論文から読めること
配布・提供形態	MiniMax M3 は open weights を伴う release として提示された一方、Anthropic、Alibaba Model Studio、Gemini API は managed product/API lifecycle の更新として確認される。Kimi K2.7 Code は code model の release/open-source と Kimi Code 側の workflow 更新が接続した。[3, 5, 4, 2, 1]
agent / computer-use 接続	MiniMax M3 は desktop operation を vendor claim として掲げ、Gemini API では Computer Use、Kimi Code では Goal mode と/swarm が同月に更新された。モデル単体の公開と、実行環境へ接続する機能が同じ競争面へ寄っている。[3, 2, 1]
availability / lifecycle	Gemini では preview、GA、deprecation、shutdown が同じ月次 changelog に並び、Alibaba でも snapshot や region 別 availability が更新された。GPT-5.6 は 6 月 26 日時点では limited preview であり、翌月の一般的な展開と同一視しないことが重要である。[2, 4, 6]
modalities と用途	MiniMax M3 の image/video input、Alibaba の visual/video 系更新、Google DeepMind の DiffusionGemma 等、Kimi の coding workflow は同じ『frontier』でも用途面が異なる。単一 benchmark 順位だけでは 6 月の差分を表しにくい。[3, 4, 7, 1]

この比較の境界

この表は本号で既に検証・参照している一次資料と論文を横断比較の形へ再配置したものである。vendor / project / author が報告した性能値や優位性は独立再現済みの一般則へ変換せず、本文と Source Notes の帰属境界をそのまま維持する。

SOURCE-BACKED TECHNICAL NOTES

Frontier Models — モデル競争から利用形態の競争へ: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
MiniMax M3	主要資料	モデル	2026-06-01 (モデル_RELEASE)
Anthropic June 2026 technical releases	主要資料	モデル更新	2026-06-30 (モデル_RELEASE); 2026-06-30 (PRODUCT_RELEASE); 2026-06-30 (SAFETY_UPDATE)
Alibaba Model Studio June 2026 model lifecycle	主要資料	モデル更新	2026-06-01 (モデル_RELEASE); 2026-06-10 (モデル_UPDATE); 2026-06-22 (モデル_RELEASE); 2026-06-25 (モデル_RELEASE); 2026-06-26 (モデル_AVAILABILITY)
Gemini API June 2026 lifecycle	主要資料	モデル更新	2026-06-30 (モデル_PREVIEW); 2026-06-30 (モデル_RELEASE); 2026-06-24 (TOOL_PREVIEW); 2026-06-17 (API_UPDATE); 2026-06-15 (DEPRECATION); 2026-06-01 (モデル_SHUTDOWN)
Kimi Code June 2026 releases	主要資料	モデル更新	2026-06-02 (AGENT_FEATURE); 2026-06-09 (MULTI_AGENT_FEATURE); 2026-06-12 (モデル_RELEASE)
GPT-5.6 series limited preview	補足資料	モデル	2026-06-26 (LIMITED_PREVIEW)
Google DeepMind June 2026 model and agent-safety releases	補足資料	モデル更新	2026-06-10 (モデル_RELEASE); 2026-06-18 (SAFETY_研究); 2026-06 (モデル_RELEASE)

MiniMax M3

主要資料

組織

MiniMax

種別

モデル

時系列

2026-06-01 (モデル_RELEASE)

一次資料から整理した technical points

• Vendor claim: MiniMax officially released M3 on June 1, describing MSA sparse attention, up to 1M context, native image/video input and desktop-computer operation, with open weights.

読む際の境界

• 分析上の留意点: This card is derived from the collected first-party index/release-note snapshot. Capability or benchmark language on vendor pages is not independently reproduced.

一次資料

• <https://www.minimax.io/news>

Anthropic June 2026 technical releases

主要資料

組織	Anthropic
種別	モデル更新
時系列	2026-06-30 (モデル_RELEASE); 2026-06-30 (PRODUCT_RELEASE); 2026-06-30 (SAFETY_UPDATE)

一次資料から整理した technical points

- **Vendor claim:** Anthropic's June 30 newsroom records Claude Sonnet 5, Claude Science, and the Fable 5 redeployment/safety-framework announcement.

読む際の境界

- **分析上の留意点:** This card is derived from the collected first-party index/release-note snapshot. Capability or benchmark language on vendor pages is not independently reproduced.

一次資料

- <https://www.anthropic.com/news>

Alibaba Model Studio June 2026 model lifecycle

主要資料

組織	Alibaba Cloud
種別	モデル更新
時系列	2026-06-01 (モデル_RELEASE); 2026-06-10 (モデル_UPDATE); 2026-06-22 (モデル_RELEASE); 2026-06-25 (モデル_RELEASE); 2026-06-26 (モデル_AVAILABILITY)

一次資料から整理した technical points

- **Vendor claim:** Alibaba Cloud's June lifecycle log records Qwen3.7-Plus, a Qwen3.7-Max snapshot with added visual understanding, HappyHorse1.1 video generation, Qwen Image 2.0 Pro, and Singapore-region availability for Kimi K2.7 Code.

読む際の境界

- **分析上の留意点:** This card is derived from the collected first-party index/release-note snapshot. Capability or benchmark language on vendor pages is not independently reproduced.

一次資料

- <https://www.alibabacloud.com/help/en/model-studio/newly-released-models>

Gemini API June 2026 lifecycle

主要資料

組織	Google
種別	モデル更新
時系列	2026-06-30 (モデル_PREVIEW); 2026-06-30 (モデル_RELEASE); 2026-06-24 (TOOL_PREVIEW); 2026-06-17 (API_UPDATE); 2026-06-15 (DEPRECATION); 2026-06-01 (モデル_SHUTDOWN)

一次資料から整理した technical points

- **Vendor claim:** The Gemini API June changelog adds Gemini Omni Flash preview and Gemini 3.1 Flash Lite Image GA on June 30, Computer Use for Gemini 3.5 Flash on June 24, streaming speech generation on June 17, and several lifecycle shutdown/deprecation events.

読む際の境界

- **分析上の留意点:** This card is derived from the collected first-party index/release-note snapshot. Capability or benchmark language on vendor pages is not independently reproduced.

一次資料

- <https://ai.google.dev/gemini-api/docs/changelog>

Kimi Code June 2026 releases

主要資料

組織 Moonshot AI / Kimi

種別 モデル更新

時系列 2026-06-02 (AGENT_FEATURE); 2026-06-09 (MULTI_AGENT_FEATURE); 2026-06-12 (モデル_RELEASE)

一次資料から整理した technical points

- **Vendor claim:** Kimi Code's changelog records autonomous Goal mode on June 2, /swarm multi-agent parallel tasks on June 9, and the released/open-sourced Kimi K2.7 Code model on June 12.

読む際の境界

- **分析上の留意点:** This card is derived from the collected first-party index/release-note snapshot. Capability or benchmark language on vendor pages is not independently reproduced.

一次資料

- <https://www.kimi.com/code/docs/en/kimi-code/whats-new.html>

GPT-5.6 series limited preview

補足資料

組織 OpenAI

種別 モデル

時系列 2026-06-26 (LIMITED_PREVIEW)

一次資料から整理した technical points

- **Vendor claim:** OpenAI began a limited preview of GPT-5.6 Sol, Terra and Luna on June 26; Sol was limited to a small group of trusted partners, with broader availability planned later.

読む際の境界

- **分析上の留意点:** The source is first-party OpenAI material. Capability, benchmark, efficiency, or performance statements remain vendor claims unless explicitly described as

externally reproduced.

一次資料

- <https://openai.com/index/previewing-gpt-5-6-sol>

Google DeepMind June 2026 model and agent-safety releases

補足資料

組織 Google DeepMind

種別 モデル更新

時系列 2026-06-10 (モデル_RELEASE); 2026-06-18 (SAFETY_研究); 2026-06 (モデル_RELEASE)

一次資料から整理した technical points

- **Vendor claim:** Google DeepMind's June index includes DiffusionGemma, Gemma 4 12B, computer-use/voice model updates, and agent-safety research.

読む際の境界

- **分析上の留意点:** This card is derived from the collected first-party index/release-note snapshot. Capability or benchmark language on vendor pages is not independently reproduced.

一次資料

- <https://deepmind.google/blog/>

2 Agents & Memory — 長時間動作は「モデルの賢さ」だけでは成立しない

6 月の agent 研究と製品更新では、複数の model call と tool 実行をどう schedule するか、過去の情報をどう memory として保持するか、長い context の再処理をどう抑えるかが前面に出た。長時間 agent は、model intelligence に runtime・memory・context engineering を重ねた system として見る必要がある。[8, 9, 10]

2.1 Agent を一回の推論ではなく実行系として捉える

SwarmX の著者らは、agentic workload を独立した推論 request の集合ではなく、model call と tool execution が連鎖する workload として扱い、その前提で scheduler を設計した。agent が長く動くほど、GPU 計算だけでなく CPU 側 tool や依存関係を含む schedule が latency へ

効いてくるという問題設定である。[10]

2.2 永続 memory は context 長とは別の設計問題

OpenAI は ChatGPT の memory を「dreaming」を用いる新 architecture へ移し、reviewable な memory summary と staged rollout を組み合わせたと説明している。ここで扱われているのは単なる context window 延長ではなく、継続利用の履歴をどの形で再構成し、次の会話へ持ち越すかという product-level の state management である。[9]

2.3 context transformation を先回りする

SmoothAgent の著者らは、長時間 agent で context transformation が起きるたびに KV cache が無効化され、re-prefill が発生する over-

head へ着目した。提案手法は context 変換を ahead-of-time で進め、TTFT を抑えることを狙う systems research であり、報告された効果は著者の evaluation 条件に依存する。[8]

層	6 月に見えた課題	代表例
Scheduling	model/tool を含む複数 step の資源配分	SwarmX
Persistent state	過去情報の選別・再構成・reviewability	ChatGPT Dreaming
Context serving	context 変換後の再処理と latency	SmoothAgent

[8, 9, 10]

この 3 つをまとめると、agent 性能を model benchmark だけで予測することは難しい。長時間 task では、何を覚えるか、いつ tool を動かすか、context をどのタイミングで変換

するかが system-level の失敗率や応答性を左右する。model intelligence と runtime/memory quality は別の評価軸として持つべきである。[8, 9, 10]

Claim boundary

SwarmX と SmoothAgent の性能・latency 評価は論文著者が構成した環境での報告であり、production 一般で同じ改善幅を保証するものではない。問題設定と mechanism を重視し、数値は独立再現済みとして扱わない。[8, 10]

Claim boundary

ChatGPT Dreaming の能力や compute efficiency に関する説明は OpenAI の first-party 報告である。staged rollout や reviewable summary という製品挙動と、効率改善の主張は分離して読む必要がある。[9]

THEME SYNTHESIS

横断比較 — 長時間 Agent では状態をどこで持つかが設計になる

SwarmX、ChatGPT Dreaming、SmoothAgent は同じ agent 研究・機能ではないが、長時間実行を一回の model call として扱えない点で共通する。scheduler、persistent memory、context transformation という別々の状態管理層へ分けると関係が見えやすい。

観察軸	6 月の一次資料・論文から読めること
実行スケジューリング	SwarmX は multi-call / tool-using agent workload を scheduler の対象として扱い、単一 inference request ではなく依存を持つ実行列として serving 問題を定義する。[10]
persistent memory	ChatGPT Dreaming は reviewable memory summary と staged rollout を伴う memory architecture として説明され、長期 context を単純に prompt へ積み続ける以外の product-level state management を示した。[9]
context transformation	SmoothAgent は long-horizon serving で context transformation を先回りして実行する systems research であり、context そのものを runtime 側で加工・準備する設計を扱う。報告性能は author claim の範囲に留める。[8]
model intelligence との境界	3 件を横断すると、長時間 Agent の品質は model capability だけでなく、いつ実行するか、何を記憶するか、どの context を渡すかという runtime/state 設計にも依存する。各資料は異なる層を扱うため性能値を直接比較しない。[10, 9, 8]

この比較の境界

この表は本号で既に検証・参照している一次資料と論文を横断比較の形へ再配置したものである。vendor / project / author が報告した性能値や優位性は独立再現済みの一般則へ変換せず、本文と Source Notes の帰属境界をそのまま維持する。

SOURCE-BACKED TECHNICAL NOTES

Agents & Memory — 長時間動作を支える状態とスケジューリング: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
SwarmX: Agentic Scheduling for Low-Latency Agentic Systems	主要資料	論文	2026-06-19 (論文_RELEASE)
ChatGPT Dreaming memory architecture	主要資料	PRODUCT	2026-06-04 (PRODUCT_ROLLOUT)
SmoothAgent: Efficient Long-Horizon LLM-Based Agent Serving with Lookahead Context Engineering	補足資料	論文	2026-06-30 (論文_RELEASE)

SwarmX: Agentic Scheduling for Low-Latency Agentic Systems

主要資料

組織

Paper authors

種別

論文

時系列

2026-06-19 (論文_RELEASE)

一次資料から整理した technical points

• Author claim:

The authors propose SwarmX, a scheduler designed around multi-call and tool-using agent workloads rather than independent inference requests.

読む際の境界

• 分析上の留意点:

The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

•

<http://arxiv.org/abs/2606.21401v2>

ChatGPT Dreaming memory architecture

主要資料

組織 OpenAI**種別** PRODUCT**時系列** 2026-06-04 (PRODUCT_ROLLOUT)

一次資料から整理した technical points

- **Vendor claim:** OpenAI launched a more capable and compute-efficient ChatGPT memory architecture built on dreaming, with a reviewable memory summary and staged rollout.

読む際の境界

- **分析上の留意点:** The source is first-party OpenAI material. Capability, benchmark, efficiency, or performance statements remain vendor claims unless explicitly described as externally reproduced.

一次資料

- <https://openai.com/index/chatgpt-memory-dreaming>

SmoothAgent: Efficient Long-Horizon LLM-Based Agent Serving with Lookahead Context Engineering

補足資料

組織 Paper authors**種別** 論文**時系列** 2026-06-30 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors propose SmoothAgent to execute context transformations ahead of time so long-horizon agent serving can preserve low TTFT.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2607.00151v1>

3 Inference & Serving — 6 月、最適化競争は chip から runtime ま で積み上がった

モデルの大型化と agent 化の裏側では、accelerator、kernel、parallelism、serving runtime が同時に更新されていた。Jalapeño、vLLM、SGLang、FlashInfer に、Moebius と HMA-Serve を重ねると、推論性能は単一の chip や framework ではなく stack 全体で決まることが見えてくる。[11, 12, 13, 14, 15, 16]

3.1 hardware: inference 専用 chip が engineering sample へ

OpenAI と Broadcom は 6 月 24 日に custom LLM inference processor 「Jalapeño」を紹介した。一次資料では engineering sample が target frequency/power で ML workload を動かしている一方、最終的な performance measurement は進行中とされている。したがって、chip の存在と開発段階は確認できても、performance-per-watt の最終評価はまだ固定できない。[15]

3.2 runtime: 新モデル対応と execution engine の更新

層	6 月の主な更新
vLLM	MiniMax-M3 対応、Model Runner V2、expert-parallel 等の継続開発
SGLang	GLM-5.2、Kimi K2.7 Code 等の model support と serving/kernel 更新
FlashInfer	Blackwell/GQA decode、attention/MoE、quantization/autotuning 周辺の更新

[11, 13, 14]

vLLM v0.24.0 では MiniMax-M3 support に加え、DeepSeek-V4、Model Runner V2、diffusion model、expert-parallel serving に関する作業が

release note へ並んだ。新 model を受け入れる互換層と、execution engine 側の再設計が同じ release train で進んでいる。[14]

SGLang v0.5.14 も GLM-5.2 や Kimi K2.7 Code など新しい model family への対応と、serving/kernel 側の変更を同時に含む。frontier model の更新頻度が高いほど、serving framework は model adapter だけでなく kernel や parallel execution を継続的に追従させる必要がある。[13]

FlashInfer v0.6.13 は Blackwell/GQA decode を含む attention・MoE、quantization、autotuning 周辺を更新した。framework より下層の kernel/backend 側でも、model architecture と hardware 世代に合わせた最適化が独立した release cadence を持っている。[11]

3.3 parallelism: 実行中に構成を切り替える

Moebius の著者らは Mixture-of-Experts serving で tensor parallelism と expert parallelism を runtime に切り替える仕組みを提案した。workload や phase に応じて固定 parallelism の非効率を避ける狙いで、Qwen3-235B-A22B などを用いた評価は著者報告として扱う。[12]

3.4 memory: HBM だけを前提にしない serving

HMA-Serve の著者らは、memory capacity の異なる accelerator を分離・組み合わせて LLM serving を行う設計を提示した。HBM 容量が均一な cluster だけを前提にせず、memory-heterogeneous な資源をどう使うかを serving 問題として扱う点が特徴である。[16]

6 月の動きを stack として並べると、inference 最適化は chip 単体の話では終わらな

い。hardware の電力・memory、kernel の実装、parallelism の切替、runtime の model support までは相互依存する。新しい model を実運用へ持ち込む速度は、この stack 全体の更新速度に左右される。[11, 12, 13, 14, 15, 16]

Claim boundary

Jalapeño の performance-per-watt などの優位性は最終測定前の first-party 説明である。engineering sample が存在することと、量産時の性能・効率を一般化することは分ける。[15]

Claim boundary

vLLM、SGLang、FlashInfer の release note は、何が追加・変更されたかを確認する一次 project 資料である。一方、そこに含まれる性能表現を独立 benchmark の保証へ拡張しない。[11, 13, 14]

Claim boundary

Moebius と HMA-Serve の性能結果は著者が設定した evaluation であり、別 hardware・別 workload でも同じ改善が得られることを意味しない。本稿では mechanism と設計上の trade-off を中心に読む。[12, 16]

THEME SYNTHESIS

横断比較 — accelerator から runtime まで最適化層が連動する

6 月の inference/serving 更新は一つの高速化技法へ収束していない。custom accelerator、serving engine、kernel、MoE parallelism、memory-heterogeneous serving が別々の層で進み、model architecture と hardware の変化が stack 全体へ伝播している。

観察軸	6 月の一次資料・論文から読めること
hardware layer	Jalapeño は LLM inference 向け custom processor として engineering sample 到達が報告されたが、最終 performance measurement は継続中であり、性能・performance-per-watt の表現は vendor の予備的報告として読む。[15]
serving engine	vLLM v0.24.0 と SGLang v0.5.14 はいずれも新 model family 対応だけでなく runner、serving、kernel 周辺を更新しており、frontier model 追加が runtime 実装の更新を伴うことを示す。[14, 13]
kernel / MoE parallelism	FlashInfer は attention/MoE/quantization/autotuning を更新し、Moebius は runtime で TP/EP を切り替える研究を提示した。project release と author-evaluated research は Evidence class を分けたまま扱う。[11, 12]
memory placement	HMA-Serve は memory-heterogeneous accelerator 間の disaggregated serving を扱い、HBM 容量だけを前提にしない配置問題を研究対象にした。6 月の serving 論点は compute kernel だけでなく memory topology へ広がっている。[16]

この比較の境界

この表は本号で既に検証・参照している一次資料と論文を横断比較の形へ再配置したものである。vendor / project / author が報告した性能値や優位性は独立再現済みの一般則へ変換せず、本文と Source Notes の帰属境界をそのまま維持する。

SOURCE-BACKED TECHNICAL NOTES

Inference & Serving — モデルの外側で進む最適化: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Jalapeño inference chip	主要資料	OTHER	2026-06-24 (HARDWARE_ANNOUNCEMENT)
vLLM v0.24.0	主要資料	FRAMEWORK	2026-06-29 (PROJECT_RELEASE)
SGLang v0.5.14	主要資料	FRAMEWORK	2026-06-26 (PROJECT_RELEASE)
FlashInfer v0.6.13	主要資料	FRAMEWORK	2026-06-24 (PROJECT_RELEASE)
Moebius: Serving Mixture-of-Expert Models with Seamless Runtime Parallelism Switch	補足資料	論文	2026-06-25 (論文_RELEASE)
HBM Is Not All You Need: Efficient Disaggregated LLM Serving across Memory-heterogeneous Accelerators	補足資料	論文	2026-06-29 (論文_RELEASE)

Jalapeño inference chip

主要資料

組織

OpenAI & Broadcom

種別

OTHER

時系列

2026-06-24 (HARDWARE_ANNOUNCEMENT)

一次資料から整理した technical points

- **Vendor claim:** OpenAI and Broadcom introduced Jalapeño, a custom LLM inference processor; engineering samples were running ML workloads at target frequency/power while final performance measurement was still underway.

読む際の境界

- **分析上の留意点:** The source is first-party OpenAI material. Capability, benchmark, efficiency, or performance statements remain vendor claims unless explicitly described as externally reproduced.

一次資料

- <https://openai.com/index/openai-broadcom-jalapeno-inference-chip>

vLLM v0.24.0

主要資料

組織

vLLM Project

種別

FRAMEWORK

時系列

2026-06-29 (PROJECT_RELEASE)

一次資料から整理した technical points

- **Project claim:** The release adds MiniMax-M3 support and continues DeepSeek-V4, Model Runner V2, diffusion-model and expert-parallel serving work.

読む際の境界

- **分析上の留意点:** GitHub release notes are primary project evidence for release contents, but project performance claims are not independently reproduced here.

一次資料

- <https://github.com/vllm-project/vllm/releases/tag/v0.24.0>

SGLang v0.5.14

主要資料

組織 SGLang Project**種別** FRAMEWORK**時系列** 2026-06-26 (PROJECT_RELEASE)**一次資料から整理した technical points**

- **Project claim:** The release adds support for GLM-5.2, Kimi K2.7 Code and other new models, together with serving/kernel changes including DeepSeek-family work.

読む際の境界

- **分析上の留意点:** GitHub release notes are primary project evidence for release contents, but project performance claims are not independently reproduced here.

一次資料

- <https://github.com/sgl-project/sglang/releases/tag/v0.5.14>

FlashInfer v0.6.13

主要資料

組織 FlashInfer Project**種別** FRAMEWORK**時系列** 2026-06-24 (PROJECT_RELEASE)**一次資料から整理した technical points**

- **Project claim:** The release contains Blackwell/GQA decode, attention/MoE, quantization and autotuning kernel/backend changes.

読む際の境界

- **分析上の留意点:** GitHub release notes are primary project evidence for release contents, but project performance claims are not independently reproduced here.

一次資料

- <https://github.com/flashinfer-ai/flashinfer/releases/tag/v0.6.13>

Moebius: Serving Mixture-of-Expert Models with Seamless Runtime Parallelism Switch

補足資料

組織 Paper authors

種別 論文

時系列 2026-06-25 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors propose Moebius to switch MoE serving between expert and tensor parallel layouts at runtime without restarting the engine.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.26607v1>

HBM Is Not All You Need: Efficient Disaggregated LLM Serving across Memory-heterogeneous Accelerators

補足資料

組織 Paper authors

種別 論文

時系列 2026-06-29 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors propose HMA-Serve for disaggregated LLM serving across memory-heterogeneous accelerators.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.29986v1>

4 Agent Safety & Security — 「使える」と「許される」を分ける

agent が tool、memory、外部 service へ接続するほど、security は prompt injection だけでは説明できなくなる。6 月の研究は capability exposure、per-call authorization、MCP tool poisoning、persistent-agent attack surface、adaptive evaluation を別々の問題として切り分けた。安全性評価も、固定 attack suite から実行系全体へ広がっている。[\[17, 18, 19, 20, 21\]](#)

4.1 Capability gate は Authorization ではない

Capability Gates Are Not Authorization の著者らは、agent に tool capability を見せる／隠す制御と、実際の各 tool call で値や scope を検証する authorization は別物だと整理した。一般的な agent framework を対象に confused-deputy risk を示し、fail-closed な per-call control の必要性を論じている。[\[17\]](#)

4.2 防御を知った attack で評価する

prompt injection 防御の評価では、固定 attack を同じ形で当て続けるだけでは防御の実力を測りにくい。Adaptive Evaluation の著者らは、defense-aware な attack へ適応させる評価を主張し、Progent/AgentDojo を用いた検証を行った。防御を公開した後の攻撃者適応まで評価 model へ入れる考え方である。[\[21\]](#)

4.3 persistent agent は computer system として攻撃面が増える

SafeClawArena の著者らは Claw-like な persistent agent を computer system として捉え、単一 prompt だけでなく複数 component にまたがる attack surface を評価対象にした。長時間稼働し、tool や state を持つ agent では、model input だけを守っても system 全体の security を

説明できないという問題設定である。[\[18\]](#)

4.4 MCP では tool 集合そのものが trust boundary になる

ShareLock の著者らは MCP 環境で、複数 tool に分散した poisoning 情報を組み合わせる threshold-style attack を提示した。個々の tool を単独で検査して安全に見えても、agent が複数 tool を横断して情報を統合した時に attack が成立し得るという threat assumption が重要である。[\[19\]](#)

4.5 本番前に、過去の会話を候補 model へ再生する

OpenAI は Deployment Simulation として、過去の conversation を candidate model と simulated tool 環境へ replay し、pre-deployment で振る舞いを観察する方法を紹介した。これは運用前評価の一つの手法としての first-party 報告であり、すべての failure を捕捉する保証と同義ではない。[\[20\]](#)

問題	主な境界	代表的な 6 月材料
Confused deputy	tool を使えること vs 呼出しを許可すること	Capability Gates
Prompt injection	固定 attack vs defense-aware attack	Adaptive Evaluation
Persistent agent	model input vs system 全体の attack surface	Safe-ClawArena
MCP poisoning	単一 tool 検査 vs 複数 tool の合成	ShareLock
Pre-deployment safety	offline test vs 実際の利用履歴に近い simulation	Deployment Simulation

[\[17, 18, 19, 20, 21\]](#)

これらを一括して「agent は危険」と結論づけるのは粗すぎる。権限設計、入力汚染、tool 間の合成、persistent state、評価方法は failure mode が異なり、必要な control も異なる。共通するのは、model output を信用するか否かではなく、実行前後に独立した policy boundary を置く発想である。[17, 18, 19, 21]

Claim boundary

4 本の security paper で示された attack、benchmark、防御効果はそれぞれ著者の threat model と evaluation 環境に依存する。別 framework や実運用へそのまま成功率・防御率を一般化せず、何を攻撃者へ許し、どの境界を検証したかを先に確認する。
[17, 18, 19, 21]

Claim boundary

Deployment Simulation の有効性は OpenAI による first-party safety method の報告である。実運用への近さは評価設計上の利点になり得るが、独立した再現や完全な risk coverage を意味しない。[20]

THEME SYNTHESIS

横断比較 — 『Agent security』を権限・注入・接続面・評価へ分解する

6 月の Agent security 資料は同じ failure mode を測っているわけではない。capability exposure と authorization、adaptive prompt injection、MCP multi-tool poisoning、persistent-agent attack surfaces、deployment simulation を別の threat/evaluation model として分ける必要がある。

観察軸	6 月の一次資料・論文から読めること
capability と authorization	Capability Gates Are Not Authorization は tool を見せる/隠すことと per-call authorization を区別する。ShareLock は MCP の複数 tool をまたぐ poisoning 例を扱い、接続可能性そのものを権限保証とみなせないことを別角度から示す。[17, 19]
adaptive prompt injection	Out-of-Band Defenses の研究は defense-aware な adaptive attack で評価する必要性を提示し、固定 attack suite だけで防御性能を判断する危険を扱う。[21]
persistent-agent attack surface	SafeClawArena は Claw-like agent を computer system として捉え、複数 component/attack surface を横断する adversarial task を構成する。単一 prompt の安全性評価より広い system boundary が対象である。[18]
pre-deployment evaluation	Deployment Simulation は candidate model と simulated tools で過去 conversation を再生する operational safety method として説明された。研究 benchmark とは異なる評価層であり、vendor-reported method として帰属を維持する。[20]

この比較の境界

この表は本号で既に検証・参照している一次資料と論文を横断比較の形へ再配置したものである。vendor / project / author が報告した性能値や優位性は独立再現済みの一般則へ変換せず、本文と Source Notes の帰属境界をそのまま維持する。

SOURCE-BACKED TECHNICAL NOTES

Agent Safety & Security — 能力、権限、接続面を分けて考える: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Capability Gates Are Not Authorization: Confused-Deputy Failures in LLM Agent Frameworks	主要資料	論文	2026-06-27 (論文_RELEASE)
Adaptive Evaluation of Out-of-Band Defenses Against Prompt Injection in LLM Agents	主要資料	論文	2026-06-25 (論文_RELEASE)
Understanding and Evaluating Claw-like Agent Security Through a Computer-Systems Lens	主要資料	論文	2026-06-29 (論文_RELEASE)
ShareLock: A Stealthy Multi-Tool Threshold Poisoning Attack Against MCP	補足資料	論文	2026-06-25 (論文_RELEASE)
Deployment Simulation	補足資料	安全性事象	2026-06-16 (SAFETY_METHOD_RELEASE)

Capability Gates Are Not Authorization: Confused-Deputy Failures in LLM Agent Frameworks

主要資料

組織

Paper authors

種別

論文

時系列

2026-06-27 (論文_RELEASE)

一次資料から整理した technical points

• **Author claim:** The authors distinguish tool capability exposure from per-call authorization and demonstrate confused-deputy risks in common agent frameworks.

読む際の境界

• **分析上の留意点:** The evidence is the authors’ arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

• <http://arxiv.org/abs/2606.28679v1>

Adaptive Evaluation of Out-of-Band Defenses Against Prompt Injection in LLM Agents 主要資料

組織 Paper authors

種別 論文

時系列 2026-06-25 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors argue prompt-injection defenses must be evaluated with adaptive, defense-aware attacks rather than a fixed attack suite.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.26479v1>

Understanding and Evaluating Claw-like Agent Security Through a Computer-Systems Lens 主要資料

組織 Paper authors

種別 論文

時系列 2026-06-29 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors frame persistent Claw-like agents as computer systems and introduce SafeClawArena for cross-component security evaluation.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.30755v1>

ShareLock: A Stealthy Multi-Tool Threshold Poisoning Attack Against MCP 補足資料

組織 Paper authors

種別 論文

時系列 2026-06-25 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors introduce ShareLock, a threshold-based multi-tool poisoning attack for MCP ecosystems.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.27027v1>

Deployment Simulation

補足資料

組織 OpenAI

種別 安全性事象

時系列 2026-06-16 (SAFETY_METHOD_RELEASE)

一次資料から整理した technical points

- **Vendor claim:** OpenAI introduced Deployment Simulation, which replays prior conversations with a candidate model and simulates tool behavior to estimate pre-deployment behavior in more realistic contexts.

読む際の境界

- **分析上の留意点:** The source is first-party OpenAI material. Capability, benchmark, efficiency, or performance statements remain vendor claims unless explicitly described as externally reproduced.

一次資料

- <https://openai.com/index/deployment-simulation>

5 AI for Science — Agent が「提案」から実験 workflow へ踏み込む

6月17日に OpenAI と Molecule.one が報告した AI chemist は、化学反応の改善を長時間の agent workflow として扱った。ただし完全自律ではない。人間が proposal selection、lab operation、代表反応の validation を担う構成であり、この境界こそ実世界 scientific workflow へ AI を接続する現在地を示している。[22]

5.1 「near-autonomous」の中身を見る

OpenAI と Molecule.one は GPT-5.4 を用いた near-autonomous chemistry workflow で Chan-Lam reaction の改善を試みたと報告した。agent が研究 task の長い連鎖へ入った一方、人

間は proposal の選択、実験室の operation、代表的 reaction の validation を担っている。したがって、これは fully autonomous laboratory の実証ではない。[22]

5.2 結果は「11/14」だが、独立再現ではない

一次資料では、bench で試験した 14 の substrate pair のうち 11 組で yield が高くなったと報告されている。この数値は OpenAI/Molecule.one による実験報告であり、独立 lab による再現結果ではない。成果の大きさだけでなく、どの主体が実験を設計・実行・検証したかを併記する必要がある。[22]

5.3 科学特化 model の評価面も広がる

OpenAI は 6 月 3 日に GPT-Rosalind の medicinal chemistry、genomics、lab-work capability 更新を報告し、MedChemBench、GeneBench、Lab-WorkBench を評価面として示した。science 向け AI が knowledge question だけでなく、実験計画や lab work を意識した評価へ広がっていることを示す材料である。[23]

| 層 | AI が担う範囲 | 人間・外部系に残る範囲 |
Scientific reasoning | proposal 生成、条件探索、知識統合 | 問題設定・採否判断 |
Experimental workflow | 長時間の探索・提案 loop | lab equipment の operation |
Validation | 結果解釈の支援 | 代表反応の実測・妥当性確認 |[22, 23]

6 月の重要点は、frontier model の能力更新が software 内の tool use に留まらず、物理的な実験工程を含む workflow へ接続されたこと

THEME SYNTHESIS

横断比較 — 科学 Agent の価値は『完全自律』ではなく workflow 境界で読む

6 月の AI for Science では、near-autonomous chemistry workflow と GPT-Rosalind 更新を、単なる benchmark 向上ではなく、人間・model・実験操作・検証がどこで分担されるかという workflow 境界から読むことが重要である。

観察軸	6 月の一次資料・論文から読めること
自律性の境界	OAI-M1-03 の chemistry workflow では human が proposal selection、lab operation、validation を担った。したがって near-autonomous という表現を fully autonomous へ拡張しない。[22]
実験結果の帰属	tested substrate pair の 11/14 で yield improvement が報告されたが、これは OpenAI/Molecule.one による一次報告であり、一般的な化学実験性能へ拡張しない。[22]
対象領域の広がり	GPT-Rosalind の June update は medicinal chemistry、genomics、lab-work 能力を benchmarks や vendor evaluation とともに提示した。chemistry workflow とは証拠形態が異なり、domain breadth の補助線として扱う。[23]
workflow への接続	2 件を合わせると、6 月の科学応用は『model が科学問題へ回答する』だけでなく、proposal、実験計画、lab work、validation へどこまで接続できるかを問う段階へ進んでいる。ただし実世界の責任境界は human-in-the-loop として残る。[22, 23]

にある。agent の長時間化を語る時、実世界では latency や tool permission だけでなく、実験安全、再現性、人間の責任分界まで system boundary に含まれる。[22, 23]

Claim boundary

GPT-Rosalind の benchmark 結果は OpenAI の評価であり、LabWorkBench には proprietary data が含まれる。公開された benchmark 名や capability scope と、外部から同条件で再現可能な性能評価は分けて扱う。[23]

Claim boundary

AI chemist の yield 改善や workflow effectiveness は OpenAI/Molecule.one の first-party 報告である。11/14 という結果を一般的な化学 agent 性能へ外挿せず、対象 reaction と human-in-the-loop 条件を保ったまま読む。[22]

この比較の境界

この表は本号で既に検証・参照している一次資料と論文を横断比較の形へ再配置したものである。vendor / project / author が報告した性能値や優位性は独立再現済みの一般則へ変換せず、本文と Source Notes の帰属境界をそのまま維持する。

SOURCE-BACKED TECHNICAL NOTES

AI for Science — Agent が実験ワークフローへ入る: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
Near-autonomous AI chemist / OAI-M1-03	主要資料	AGENT	2026-06-17 (研究_RESULT)
GPT-Rosalind June capability update	補足資料	モデル更新	2026-06-03 (RELEASE)

Near-autonomous AI chemist / OAI-M1-03

主要資料

組織 OpenAI & Molecule.one
種別 AGENT
時系列 2026-06-17 (研究_RESULT)
一次資料から整理した technical points

- **Vendor claim:** OpenAI and Molecule.one reported a near-autonomous GPT-5.4-driven chemistry workflow that improved a Chan–Lam reaction; humans selected proposals, operated the lab and validated representative reactions.

読む際の境界

- **分析上の留意点:** The source is first-party OpenAI material. Capability, benchmark, efficiency, or performance statements remain vendor claims unless explicitly described as externally reproduced.

一次資料

- <https://openai.com/index/ai-chemist-improves-reaction>

GPT-Rosalind June capability update

補足資料

組織 OpenAI
種別 モデル更新
時系列 2026-06-03 (RELEASE)
一次資料から整理した technical points

- **Vendor claim:** OpenAI reported stronger medicinal-chemistry, genomics and lab-work

capabilities for GPT-Rosalind, including MedChemBench, GeneBench and LabWorkBench evaluations.

読む際の境界

- **分析上の留意点:** The source is first-party OpenAI material. Capability, benchmark, efficiency, or performance statements remain vendor claims unless explicitly described as externally reproduced.

一次資料

- <https://openai.com/index/introducing-new-capabilities-to-gpt-rosalind>

6 Paper Watch — 長時間 Agent を「守る・止めない・正しく測る」

6 月末の研究では、agent runtime の外側に安全 kernel を置く設計、長い context で探索が早期終了する context rot、memory system 比較を歪める hidden confound が相次いで論点になった。共通するのは、長時間 agent の品質を model 能力だけで説明できないという問題意識である。[24, 25, 26]

The Unfireable Safety Kernel の著者らは、agent 自身の変更できる runtime の外側に execution-time safety kernel を置く設計を提案した。Rust prototype と formal/implementation checks で制御 property を検討しており、alignment を model 内部だけでなく実行時の外部 control として扱う。[25]

Diagnosing and Mitigating Context Rot の著者らは、long-horizon search で context が長くなるにつれて premature termination が増える failure mode を報告した。複数 model・benchmark と context-management 手法を比較し、単純に context window を長くするだけでは探索の持続性を保証できないことを問題化している。[26]

SOURCE-BACKED TECHNICAL NOTES

MemDelta の著者らは agent memory の比較で、model、embedding、retrieval 条件の違いが memory system 自体の差と混ざることを指摘した。component を一つずつ変える controlled baseline を重視し、ranking が実装以外の条件で反転し得るという evaluation confound を示している。[24]

3 本は対象が異なるが、長時間 agent を成立させるために「実行時の外部 control」「task を途中で止めない context 運用」「比較条件を固定した memory 評価」という model 外的设计を求めている。agent 研究の焦点が能力追加から、制御可能性と測定可能性へ広がっていることを示す。[24, 25, 26]

Claim boundary

いずれも prototype または author-controlled benchmark による研究結果である。production での安全性・latency・memory quality を保証するものではなく、異なる model や workload をまたぐ普遍的 ranking として扱わない。[24, 25, 26]

Paper Watch — 長時間 Agent を測る・守る: Technical Notes

本欄は記事本文で圧縮した一次資料上の情報を、比較・再検証しやすい形で整理したものである。時系列、確認済みの主張、留意点、一次資料 URL を掲載する。

Theme at a glance

資料	位置づけ	種別	時系列
The Unfireable Safety Kernel: Execution-Time AI Alignment for AI Agents and Other Escapable AI Systems	主要資料	論文	2026-06-24 (論文_RELEASE)
Diagnosing and Mitigating Context Rot in Long-horizon Search	主要資料	論文	2026-06-29 (論文_RELEASE)
MemDelta: Controlled Baselines and Hidden Confounds in Agent Memory Evaluation	主要資料	論文	2026-06-29 (論文_RELEASE)

The Unfireable Safety Kernel: Execution-Time AI Alignment for AI Agents and Other Escapable AI Systems 主要資料

組織 Paper authors

種別 論文

時系列 2026-06-24 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors propose an execution-time safety kernel that remains outside an agent's own mutable runtime.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.26057v1>

Diagnosing and Mitigating Context Rot in Long-horizon Search 主要資料

組織 Paper authors

種別 論文

時系列 2026-06-29 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors identify premature termination as a long-context failure mode in long-horizon search.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.29718v2>

MemDelta: Controlled Baselines and Hidden Confounds in Agent Memory Evaluation

資料 主要

組織 Paper authors

種別 論文

時系列 2026-06-29 (論文_RELEASE)

一次資料から整理した technical points

- **Author claim:** The authors show that uncontrolled model, embedding, and retrieval changes can confound comparisons between agent-memory systems.

読む際の境界

- **分析上の留意点:** The evidence is the authors' arXiv paper/model card and reported evaluations; results are not independently reproduced in this Evidence review.

一次資料

- <http://arxiv.org/abs/2606.29914v1>

JUNE CHRONOLOGY

6 月の変化を時系列で束ねる

各章を横断して主要な転換点だけを日付順に置き直す。これは因果関係を示す年表ではなく、モデル、Agent runtime、serving、安全境界、科学 workflow の変化が同じ月にどのように重なったかを読むための索引である。

日付	層	観測点
06-01	Frontier Models	MiniMax が M3 を公開し、open weights、画像・動画入力、desktop operation を発表した。[3]
06-04	Agents & Memory	OpenAI が ChatGPT Dreaming の memory architecture を発表し、persistent memory を product-level の設計対象として前面化した。[9]
06-17	AI for Science	OpenAI と Molecule.one が near-autonomous chemistry workflow を報告した。human selection、lab operation、validation は残されている。[22]
06-19	Agents & Memory	multi-call / tool workload 向け agentic scheduling 研究が公開され、長時間 Agent の実行順序を runtime 側の設計問題として扱った。[10]
06-24	Inference & Serving	custom inference chip の engineering sample と FlashInfer の Blackwell/GQA decode 等の update が同日に現れ、hardware から kernel までの更新が並行した。[15, 11]
06-26	Models / Serving	GPT-5.6 series の limited preview と SGLang v0.5.14 が同日。frontier model の提供状態と serving 側の support を分けて追う必要がある。[6, 13]
06-27	Agent Safety	capability exposure と per-call authorization を同一視できないことを、agent framework の実装監査から提起した研究が公開された。[17]
06-29	Serving / Safety / Paper	vLLM v0.24.0、persistent-agent security 評価、long-context search failure の研究が月末に集中し、実行系・安全性・評価の更新が重なった。[14, 18, 26]
06-30	Frontier Models	Anthropic の June technical releases と Gemini API の lifecycle update が月末を締め、model/API の提供面が引き続き動いた。[5, 2]

日付は各 Evidence card で確認した first-announced chronology に従う。複数資料を同じ行へ置くことは同日性または近接した観測を示すだけで、資料間の因果関係や性能優位を意味しない。

7 総括 — 6 月の Agent 化を『モデル』から『実行系』までつなぐ

本号で追った 6 テーマを重ねると、2026 年 6 月の変化は単なる model release の増加では捉えきれない。提供形態と agent 機能を持つモデル、長時間動作を支える memory と scheduler、それを実行する serving stack、権限と接続面を守る security boundary、そして人間と実験系を含む scientific workflow まで、生成 AI の設計対象が実行系全体へ広がった月として読むことができる。ここでは各章の結論を再接続し、一次資料が直接示すことと編集上の構造的な関係を分けて整理する。

7.1 Frontier Models — model 名より delivery surface を見る

第 1 章の MiniMax M3、Anthropic、Alibaba Model Studio、Gemini API、Kimi Code を横断すると、6 月の model competition は単純な能力順位ではなく、open-weight か managed API か、multimodal や computer-use をどう提供するか、coding や agent workflow へどう接続するかという delivery surface まで含んでいた。GPT-5.6 は月末時点で limited preview であり、提供状態を release 名と分離して読む必要がある。[3, 5, 2, 1, 6]

7.2 Agents & Memory — 長時間化すると状態管理が表面化する

第 2 章では SwarmX が multi-call/tool workload を scheduler の対象へ広げ、ChatGPT Dreaming が persistent memory を product-level architecture として扱い、SmoothAgent が context transformation を serving 側の仕事として扱った。3 件は同じ手法ではないが、agent を一回の model call として閉じず、実行順序、記憶、context preparation を system behavior の一部として設計する必要がある点で接続する。[10, 9, 8]

7.3 Inference & Serving — model 進化を受け止める stack も動いている

第 3 章の Jalapeño、vLLM、SGLang、FlashInfer、Moebius、HMA-Serve は、model を載せる

実行基盤が固定された土台ではないことを示した。custom accelerator、runner、kernel、MoE parallelism、memory placement は別の層に属するが、新しい model architecture と hardware target を運用可能にするため同時に更新される。性能値は vendor/project/author claim の境界を維持し、共通の優劣表へまとめない。[15, 14, 13, 11, 12, 16]

7.4 Agent Safety & Security — 実行系が広がれば trust boundary も増える

第 4 章で分けた capability exposure、per-call authorization、adaptive prompt injection、MCP multi-tool poisoning、persistent-agent attack surface、pre-deployment simulation は同一の脅威モデルではない。一方、agent が tool や外部 service へ接続し、長時間状態を持つほど、何を呼べるか、誰の権限で呼ぶか、入力をどこまで信頼するか、実行履歴をどう評価するかという境界が増える。これは構造上の接続であり、各研究の attack result を相互に一般化するものではない。[17, 21, 18, 19, 20]

7.5 AI for Science — 実世界 workflow では human boundary が消えない

第 5 章の near-autonomous chemistry workflow は、生成 AI が proposal から長時間の科学 workflow へ入り得る一方、人間が proposal selection、lab operation、validation を担ったことを明示している。GPT-Rosalind の medicinal

chemistry、genomics、lab-work 更新も含め、科学応用では model capability だけでなく、実験操作と検証を誰が担うかを設計境界として追う必要がある。[22, 23]

7.6 Paper Watch — 長時間 Agent の測定と制御もまだ研究途上

第 6 章の execution-time safety kernel、context rot、MemDelta は、長時間 Agent の外部制御、

長い context での探索停止、memory evaluation の confound という異なる課題を扱った。いずれも product-level の確立した解ではなく、長時間動作を測り、守り、比較する方法自体がまだ設計対象であることを示す研究上の観測点として位置づける。[25, 26, 24]

CROSS-CHAPTER SYNTHESIS

各章はどうつながるか

接続する章	本号で見える構造的な関係
Frontier Models → Agents & Memory	model 提供が computer-use、coding、agent workflow へ広がるのと並行して、長時間実行では scheduler、persistent memory、context preparation が独立した設計対象になる。model release と agent runtime は同一ではないが、利用経路を含めた system として接続して読む必要がある。[2, 1, 10, 9]
Agents & Memory → Inference & Serving	長時間 agent は multi-call、長い context、状態再利用を伴うため、serving 側でも scheduler、parallelism、memory placement の設計が実行コストへ影響する。各資料が直接同じ workload を比較したわけではなく、これは stack 上の構造的な関係として整理する。[10, 8, 12, 16]
Agents & Memory → Agent Safety & Security	agent が長時間状態を持ち複数 tool へ接続するほど、authorization、prompt injection、MCP trust、persistent-agent attack surface など複数の security boundary が現れる。研究 setup は別々であり、危険度や攻撃成功率を一つの尺度へ統合しない。[9, 17, 19, 18]
Agents → AI for Science	scientific workflow は長時間の計画・実行・検証を必要とし、agent 的な workflow 設計が実世界へ接続する例として読める。ただし化学実験では human selection、lab operation、validation が残り、software agent の自律性をそのまま実験自律性へ拡張できない。[10, 22]
Paper Watch → Agents / Safety	context rot、memory evaluation confound、execution-time safety kernel は、長時間 agent を成立させるだけでなく、どの条件で性能を測り、どこで外部制御するかを問う。現時点では研究上の設計論点であり、production での解決済みパターンを意味しない。[25, 26, 24]

この総括の境界

この総括は本号で既に選定・検証した一次資料と論文の配置関係を編集上の system stack として整理したものである。個別資料の vendor/project/author claim を独立再現済みの一般則へ変換せず、異なる研究 setup 間の直接的な因果関係や性能優位を主張しない。

6 月をどう位置づけるか

6 月を一つの変化として捉えるなら、本号が観測したのは生成 AI の競争単位が model artifact だけでは閉じなくなったことである。model の提供形態、agent runtime、memory、serving、

authorization、実世界 workflow までを一続きの実行系として見なければ、実際の技術差を取りこぼす。一方で各層の成熟度と Evidence class は異なる。今後の Weekly と Special でも、system-level の接続を追いつつ、一次事実と vendor/project/author claim、研究上の可能性を分離して観測することが重要になる。 [3, 10, 14, 17, 22, 26]

References / Source Notes

- [1] *Primary source 1:* <https://www.kimi.com/code/docs/en/kimi-code/whats-new.html>. Primary source used for chronology and technical verification. Moonshot AI / Kimi. URL: <https://www.kimi.com/code/docs/en/kimi-code/whats-new.html> (visited on 08/11/2026).
- [2] *Primary source 1:* <https://ai.google.dev/gemini-api/docs/changelog>. Primary source used for chronology and technical verification. Google. URL: <https://ai.google.dev/gemini-api/docs/changelog> (visited on 08/11/2026).
- [3] *Primary source 1:* <https://www.minimax.io/news>. Primary source used for chronology and technical verification. MiniMax. URL: <https://www.minimax.io/news> (visited on 08/11/2026).
- [4] *Primary source 1:* <https://www.alibabacloud.com/help/en/model-studio/newly-released-models>. Primary source used for chronology and technical verification. Alibaba Cloud. URL: <https://www.alibabacloud.com/help/en/model-studio/newly-released-models> (visited on 08/11/2026).
- [5] *Primary source 1:* <https://www.anthropic.com/news>. Primary source used for chronology and technical verification. Anthropic. URL: <https://www.anthropic.com/news> (visited on 08/11/2026).
- [6] *Primary source 1:* <https://openai.com/index/previewing-gpt-5-6-sol>. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/previewing-gpt-5-6-sol> (visited on 08/11/2026).
- [7] *Primary source 1:* <https://deepmind.google/blog/>. Primary source used for chronology and technical verification. Google DeepMind. URL: <https://deepmind.google/blog/> (visited on 08/11/2026).
- [8] *Primary source 1:* <http://arxiv.org/abs/2607.00151v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2607.00151v1> (visited on 08/11/2026).
- [9] *Primary source 1:* <https://openai.com/index/chatgpt-memory-dreaming>. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/chatgpt-memory-dreaming> (visited on 08/11/2026).
- [10] *Primary source 1:* <http://arxiv.org/abs/2606.21401v2>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.21401v2> (visited on 08/11/2026).

- [11] *Primary source 1*: <https://github.com/flashinfer-ai/flashinfer/releases/tag/v0.6.13>. Primary source used for chronology and technical verification. FlashInfer Project. URL: <https://github.com/flashinfer-ai/flashinfer/releases/tag/v0.6.13> (visited on 08/11/2026).
- [12] *Primary source 1*: <http://arxiv.org/abs/2606.26607v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.26607v1> (visited on 08/11/2026).
- [13] *Primary source 1*: <https://github.com/sgl-project/sglang/releases/tag/v0.5.14>. Primary source used for chronology and technical verification. SGLang Project. URL: <https://github.com/sgl-project/sglang/releases/tag/v0.5.14> (visited on 08/11/2026).
- [14] *Primary source 1*: <https://github.com/vllm-project/vllm/releases/tag/v0.24.0>. Primary source used for chronology and technical verification. vLLM Project. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.24.0> (visited on 08/11/2026).
- [15] *Primary source 1*: <https://openai.com/index/openai-broadcom-jalapeno-inference-chip>. Primary source used for chronology and technical verification. OpenAI & Broadcom. URL: <https://openai.com/index/openai-broadcom-jalapeno-inference-chip> (visited on 08/11/2026).
- [16] *Primary source 1*: <http://arxiv.org/abs/2606.29986v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.29986v1> (visited on 08/11/2026).
- [17] *Primary source 1*: <http://arxiv.org/abs/2606.28679v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.28679v1> (visited on 08/11/2026).
- [18] *Primary source 1*: <http://arxiv.org/abs/2606.30755v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.30755v1> (visited on 08/11/2026).
- [19] *Primary source 1*: <http://arxiv.org/abs/2606.27027v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.27027v1> (visited on 08/11/2026).
- [20] *Primary source 1*: <https://openai.com/index/deployment-simulation>. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/deployment-simulation> (visited on 08/11/2026).
- [21] *Primary source 1*: <http://arxiv.org/abs/2606.26479v1>. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.26479v1> (visited on 08/11/2026).
- [22] *Primary source 1*: <https://openai.com/index/ai-chemist-improves-reaction>. Primary source used for chronology and technical verification. OpenAI & Molecule.one. URL: <https://openai.com/index/ai-chemist-improves-reaction> (visited on 08/11/2026).

- [23] *Primary source 1: <https://openai.com/index/introducing-new-capabilities-to-gpt-rosalind>*. Primary source used for chronology and technical verification. OpenAI. URL: <https://openai.com/index/introducing-new-capabilities-to-gpt-rosalind> (visited on 08/11/2026).
- [24] *Primary source 1: <http://arxiv.org/abs/2606.29914v1>*. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.29914v1> (visited on 08/11/2026).
- [25] *Primary source 1: <http://arxiv.org/abs/2606.26057v1>*. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.26057v1> (visited on 08/11/2026).
- [26] *Primary source 1: <http://arxiv.org/abs/2606.29718v2>*. Primary source used for chronology and technical verification. Paper authors. URL: <http://arxiv.org/abs/2606.29718v2> (visited on 08/11/2026).