
Japanese Generative AI Technical Survey Special

SP001

Thematic history / as of 2026-08-22 14:21:44 UTC

中国 Generative AI の台頭

DeepSeek・Qwen・GLM・Kimi を中心に、効率化、reasoning、agentic workload、long context、Open Weight がどのように別々の系譜から現在の競争軸へ接続したかを、2026 年 8 月 22 日時点の一次資料と検証済み資料から再構成する。

[Four lineages](#) / [Reasoning](#) / [Agentic](#) / [Efficiency](#) / [Serving](#) / [Open Weight](#) / [License](#)

Editorial cutoff

As-of boundary: 2026-08-22 14:21:44 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Thematic Longform Special。

本号について

本号は、中国発の Generative AI を一つの技術潮流として平板化せず、GLM、Qwen、DeepSeek、Kimi の 4 系統をそれぞれの version-specific な一次資料から追う Thematic Special である。MiniMax、Yi、Baichuan は、4 系統だけでは捉えきれない並行線・歴史的 bridge として扱い、Open Weight は技術仕様ではなく distribution と権利条件を分けて読む。

Scope / attribution boundary

調査・記述の as-of boundary は 2026 年 8 月 22 日。後発 version の性質を過去 version へ遡及して帰属しない。

vendor / project / author が報告する性能・効率値は、記載された artifact と条件に限定して帰属する。異なる benchmark や serving stack を横断した勝敗表には再構成しない。

community 由来の観測は調査上の手掛かりとして保持するが、一次資料による裏付けのない runtime 性能、普及度、license 解釈を技術的事実へ昇格させない。

Open Source と Open Weight を同義語として扱わず、weights、code、license、commercial conditions、Model-as-a-Service 条件を artifact 単位で区別する。

目次

本号について	2
1 前史と分岐点：一つの『中国モデル』ではなく、複数の系譜が立ち上がった	3
2 GLM：ローカルで動く対話モデルから、All Tools、ARC、1M context へ	4
3 Qwen：広い family/platform を、hybrid reasoning と agentic coding へ接続する	6
4 DeepSeek：効率を architecture で作り、reasoning RL と agentic serving へ伸ばす	8
5 Kimi：long context を起点に、reasoning RL、open agentic MoE、native multimodal へ	10
6 主要 4 系統の外側：MiniMax、Yi、Baichuan が示す競争と分化	13
7 Open Weight は一枚岩ではない：配布されることと、同じ権利で使えることは別問題	15
8 4 系統は何に収斂し、どこで分岐したか	17
9 この号の総括	18

1 前史と分岐点：一つの『中国モデル』ではなく、複数の系譜が立ち上がった

THEMATIC LINEAGE 1/7 — FOUNDATIONS

GLM-130B、初期 Qwen、DeepSeek LLM をそれぞれの一次資料が直接支える範囲で置くと、後年の中国発 Frontier AI は単一戦略の派生ではなく、異なる設計・公開・用途の系譜が並走し始めた過程として見えてくる。[1, 2, 3]

Theme at a glance

GLM の初期座標	130B 級の英中バイリンガルモデルを公開可能性と deployment まで含めて論じた。 [1]
Qwen の初期座標	base/chat family と RLHF だけでなく、tool use・planning・code-interpreter 型 agent を早期から扱った。[2]

同じ『公開モデル』でも、出発点は同じではなかった

GLM-130B の論文は、英中バイリンガルの 130B モデルを 100B 級モデルを開く試みとして位置付け、学習安定化と INT4 deployment までを主要論点に置いた。ここで見えるのは、後年の agentic 機能ではなく、大規模モデルを研究成果として公開し、実際に動かすための条件を同時に考える初期の問題設定である。

[1]

後年の特徴を過去へ投影しない

DeepSeek LLM は、V2 以降の MLA や DeepSeekMoE を特徴とする系譜より前の baseline である。初期 family の存在と release context は一次論文で確認できるが、後年の効率 architecture や reasoning RL をこの段階へ遡及させる根拠にはならない。[3]

Transition timeline

2022	GLM-130B が 130B 級英中モデルと学習・deployment 上の課題を一次論文で提示。[1]
2023	Qwen 技術報告が family 構成、RLHF、tool use・planning を一体の研究・応用線として提示。[2]

前史から見える分岐

この 3 つの seed だけでも、後年の中国発 frontier model を単一 recipe の競争として説明することはで

きない。公開規模と deployment、family/platform と tool use、後に architecture を大きく変える baseline という異なる問題設定が並行していた。[1, 2, 3]

Claim boundary

GLM-130B の deployment 記述は論文が報告した条件に限定する。初期 Qwen から後年の Qwen3 の license や reasoning 設計を推論しない。DeepSeek LLM についても、V2 以降の MLA・MoE・reasoning 特性を初期 baseline へ遡及させない。[1, 2, 3]

Source-backed Technical Notes

GLM-130B

Chronology: 2022 年の GLM 系譜の初期技術座標。 [1]

Technical points:

- 英中バイリンガルの 130B モデルとして提示され、100B 級モデルを開く試みとして位置付けられた。 [1]
- 学習安定化の工夫と、論文条件下での INT4 deployment path が報告された。 [1]

Limitation / attribution: deployment 容易性は論文の条件に束縛し、後年の ChatGLM/GLM-4/5 の設計をここへ遡及させない。

Primary URL: <https://arxiv.org/abs/2210.02414>

Qwen Technical Report

Chronology: 2023 年の初期 Qwen family を定義する技術報告。 [2]

Technical points:

- base/chat family と RLHF による chat alignment を説明する。 [2]
- tool use、planning、code-interpreter 型 agent application をすでに扱う。 [2]

Limitation / attribution: 後年の Qwen3 の thinking mode、architecture、license 条件はこの初期報告からは導出しない。

Primary URL: <https://arxiv.org/abs/2309.16609>

DeepSeek LLM

Chronology: 2024 年初頭の DeepSeek 初期 family baseline。 [3]

Technical points:

- 後の MLA/DeepSeekMoE 中心の V2 系譜より前の language-model family を確認できる。 [3]
- 初期 family と release context を置くための historical baseline として使う。 [3]

Limitation / attribution: 全 model size や distribution detail を本号では再確定していない。後年の効率・reasoning 特性は別 artifact へ帰属させる。

Primary URL: <https://arxiv.org/abs/2401.02954>

2 GLM：ローカルで動く対話モデルから、All Tools、ARC、1M context へ

THEMATIC LINEAGE 2/7 — GLM

GLM 系譜では、ChatGLM-6B の consumer deployment、GLM-4 All Tools、GLM-4.5 の ARC、GLM-5.2 の長文脈 serving が、それぞれ別 version の資料で確認できる。公開や license も含め、同じ family の中で戦略が段階的に変わった。 [4, 5, 6, 7]

Theme at a glance

Local deployment	ChatGLM-6B は INT4 で約 6GB という consumer-GPU 向け経路を project 側が示した。[4]
Tool-using system	GLM-4 All Tools は web、Python、画像生成、user-defined function を選択して使う。[5]

動かせる対話モデルから、tool を選ぶ system へ

ChatGLM-6B は 6.2B の英中対話モデルとして、INT4 で約 6GB の memory を使う consumer-GPU 向け経路を repository が示した。ここではモデル能力だけでなく、ローカル環境へ持ち込めるサイズと実装経路が developer-facing な価値の一部になっている。[4]

ARC と長文脈 serving は、同じ変化ではない

GLM-4.5 では 355B total / 32B active の MoE と hybrid thinking/direct response が示され、Agentic・Reasoning・Coding をまとめる ARC が明示的な戦略語になった。これは capability と post-training を含む family positioning の変化であり、すべての中国モデルが同じ recipe へ収斂したことを意味しない。[6]

Transition timeline

ChatGLM-6B	consumer GPU へ届く INT4 local deployment と、model-use 権利の分離が重要になった。[4]
GLM-4	All Tools によって web/Python/画像生成/function 利用を統合する system へ拡張。[5]

GLM 系譜の技術的な重心移動

GLM の変化は『モデルが大きくなった』という一本線ではない。ChatGLM-6B では local deployment、

GLM-4 では tool orchestration、GLM-4.5 では ARC、GLM-5.2 では long-context serving efficiency と、競争の層が順に増えている。[4, 5, 6, 7]

Claim boundary

GLM-4.5 の ARC は同 version 固有の framing であり、他 family の共通 recipe とは扱わない。GLM-5.2 の 2.9 倍という効率値は official model card が報告する条件付き値で、独立再現結果とはみなさない。[6, 7]

Source-backed Technical Notes

ChatGLM-6B

Chronology: GLM-130B 後に広がった consumer-facing 対話モデル期。[4]

Technical points:

- 6.2B の英中対話モデルとして project が説明する。[4]
- INT4 で約 6GB の memory を使う local deployment path を repository が示す。[4]

Limitation / attribution: historical な model-use/commercial permission と repository code の license は別々に読む。

Primary URL: https://github.com/zai-org/ChatGLM-6B/blob/main/README_en.md

GLM-4 All Tools family report

Chronology: GLM-4 世代で tool use を system capability へ拡張。 [5]

Technical points:

- 約 10T token 規模の pretraining と multi-stage post-training を family report が説明する。 [5]
- All Tools は web browsing、Python、text-to-image、user-defined function から必要な tool を選ぶ。 [5]

Limitation / attribution: paper 内 benchmark は author evaluation であり、他 family との非互換な横断順位へ使わない。

Primary URL: <https://arxiv.org/abs/2406.12793>

GLM-4.5

Chronology: 2025 年の ARC-centered family pivot。 [6]

Technical points:

- 355B total / 32B active の MoE architecture を paper が示す。 [6]
- hybrid thinking/direct response と Agentic・Reasoning・Coding の ARC framing を明示する。 [6]

Limitation / attribution: ARC framing は GLM-4.5 固有であり、中国モデル一般の共通 training recipe を意味しない。

Primary URL: <https://arxiv.org/abs/2508.06471>

GLM-5.2

Chronology: 2026 年 as-of 境界内の GLM current endpoint。 [7]

Technical points:

- 1M context、thinking effort control、IndexShare を official model card が説明する。 [7]
- vLLM/SGLang deployment を示し、IndexShare について 1M context で 2.9 倍 per-token FLOP reduction を報告する。 [7]

Limitation / attribution: 効率数値は vendor/model-card claim。model artifact と関連 repository code の license は同一とは限らない。

Primary URL: <https://huggingface.co/zai-org/GLM-5.2>

3 Qwen：広い family/platform を、hybrid reasoning と agentic coding へ接続する

THEMATIC LINEAGE 3/7 – QWEN

Qwen の強みは単一の旗艦モデルではなく、specialized branch を含む広い family/platform を継続的に更新し、Qwen3 で thinking/non-thinking を統合し、Qwen3.6 で agentic coding へ比重を移してきた点にある。 [8, 9, 10]

Theme at a glance

Platform breadth	Qwen2.5 は 18T token 規模へ corpus を拡張し、Math・Coder・QwQ・multimodal へ広がる family を形成。 [8]
Hybrid reasoning	Qwen3 は thinking/non-thinking を一 family へ統合し、thinking budget を制御可能にした。 [9]

単一旗艦ではなく、用途別 branch を持つ platform

Qwen2.5 technical report は training corpus を 7T から 18T token へ拡大し、SFT と multi-stage RL を組み合わせたと説明する。重要なのは規模だけではなく、Math、Coder、QwQ、multimodal 系へつながる広い family を持つことで、general model 一つを更新するより用途別 branch を抱える platform として発展した点にある。[8]

2026 年の endpoint は、長い作業履歴を扱う coding foundation へ

Qwen3.6-27B の official model card は、agentic coding、repository-level reasoning、過去 message をまたぐ thinking context の保持、multimodal family scope を強調する。ここでの変化は単発の code benchmark ではなく、repository と会話履歴をまたぐ長い作業を agent に継続させる方向へ family の用途を伸ばしていることにある。[10]

Transition timeline

Qwen2.5	18T token 規模の corpus、SFT + multi-stage RL、specialized branch を持つ platform breadth。[8]
Qwen3	dense/MoE family 全体で thinking/non-thinking と thinking budget を統合。[9]

Qwen の強みは family を更新し続ける distribution 設計にある

Qwen の技術線では、Qwen2.5 の family breadth、Qwen3 の hybrid reasoning、Qwen3.6 の agentic coding

が連続している。各段階で新しい用途を別 product へ切り離すより、広い family/platform へ組み込みながら公開・deployment 経路を維持する姿勢が見える。[8, 9, 10]

Claim boundary

Qwen3.6 の capability 記述は official model card の vendor claim である。異なる version・benchmark・evaluation 条件を横断して他 family より優れるという順位付けには使わない。[10]

Source-backed Technical Notes

Qwen2.5

Chronology: Qwen の platform breadth を明確にした 2024 年末の family transition。[8]

Technical points:

- technical report は training corpus を 7T から 18T token へ拡大し、SFT と multi-stage RL を組み合わせたと説明する。[8]
- Math、Coder、QwQ、multimodal を含む specialized branch へ広がる family 構成が、単一旗艦ではない platform strategy を示す。[8]

Limitation / attribution: hosted proprietary variants と open-weight variants は distribution と rights を論じる際に別 artifact として扱う。

Primary URL: <https://arxiv.org/abs/2412.15115>

Qwen3

Chronology: 2025 年に hybrid reasoning を family-level の利用形態へ統合した節目。[9]

Technical points:

- technical report は 0.6B から 235B までの dense/MoE family を説明する。[9]

- thinking/non-thinking mode と thinking-budget control を一つの family へ統合し、public distribution を Apache-2.0 として記載する。 [9]

Limitation / attribution: benchmark 値は report 固有の evaluation として扱い、異なる family との横断順位へ正規化しない。

Primary URL: <https://arxiv.org/abs/2505.09388>

Qwen3.6-27B

Chronology: 2026 年 as-of 境界内の Qwen current endpoint。 [10]

Technical points:

- official model card は agentic coding と repository-level reasoning を主要用途として位置付ける。 [10]
- 過去 message をまたぐ thinking context の保持、multimodal family scope、Apache-2.0 distribution を説明する。 [10]

Limitation / attribution: capability 記述は official model card に帰属する。Qwen3.5 からの architecture inheritance を独立した cross-family superiority へ変換しない。

Primary URL: <https://huggingface.co/Qwen/Qwen3.6-27B>

4 DeepSeek：効率を architecture で作り、reasoning RL と agentic serving へ伸ばす

THEMATIC LINEAGE 4/7 — DEEPSEEK

DeepSeek の転換は、V2 の MLA/DeepSeekMoE、R1/R1-Zero の reasoning RL、V4-Flash-0731 の agentic serving という別々の節目で追える。benchmark 順位ではなく、各 version で何が設計・学習・deployment の焦点になったかを見る。 [11, 12, 13]

Theme at a glance

Efficiency architecture	architec-	DeepSeek-V2 は 236B total / 21B active の MoE で MLA と DeepSeekMoE を導入し、memory と serving efficiency を architecture 課題として前面化した。 [11]
Reasoning training	post-	DeepSeek-R1 は R1-Zero の large-scale RL と、cold-start data を加えた R1 の multi-stage path を明確に分けた。 [12]
Agentic serving point	end-	V4-Flash-0731 は agentic positioning と vLLM + DSpark deployment support を official model card で示す。 [13]

MLA と MoE は、parameter 増大とは別の競争軸を作った

DeepSeek-V2 は 236B total / 21B active の MoE として、Multi-head Latent Attention (MLA) と DeepSeekMoE を導入した。paper が報告する KV-cache 削減や generation throughput の改善は評価 setup に依存するが、frontier model を成立させるために memory と serving cost を architecture の設計対象へ組み込んだこと自体が、初期 DeepSeek LLM からの重要な分岐

である。 [11]

この効率化は単に『小さいモデル』を作る話ではない。多数の total parameters を持ちながら active parameters を抑える MoE と、attention 側の state を圧縮する MLA を組み合わせ、学習・推論の費用構造を変える方向にある。したがって後年の DeepSeek を理解する際も、benchmark score だけでなく、どの architecture が serving 制約へ答えているかを分離して読む必要がある。 [11]

R1 では、reasoning capability の帰属先が post-training へ移る

DeepSeek-R1 paper は R1-Zero を preliminary SFT なしの large-scale reinforcement learning として説明し、R1 では cold-start data と multi-stage training を追加する。ここでは reasoning を一つの opaque な能力として扱うのではなく、どの training path がどの model subject に対応するかが技術史上の焦点になる。[12]

同じ release には Qwen/Llama 系 base を使う distilled variants も含まれるため、native R1/R1-Zero と distill を同一 model として数えると architecture と post-training の帰属が崩れる。本号では、distillation が distribution を広げた事実と、native model の training path を明示的に分離する。[12]

Transition timeline

DeepSeek-V2	MLA と DeepSeekMoE を family-defining な効率 architecture として導入し、128K context と paper-bound serving efficiency を提示。[11]
DeepSeek-R1	R1-Zero の RL-only path と、cold-start + multi-stage training を持つ R1 を分離して reasoning post-training を提示。[12]
V4-Flash-0731	agentic positioning を強め、vLLM と DSpark speculative decoding を使う official deployment path を示す。[13]

DeepSeek の系譜は、効率・reasoning・serving を別レイヤとして積み上げる

DeepSeek の転換を一本の性能曲線で表すより、V2 で architecture-level efficiency、R1 で reasoning-oriented post-training、V4-Flash-0731 で agentic serving というレイヤが順に追加されたと読む方が source 境界に忠実である。各段階の claim は異なる artifact に属し、

2026 年の current endpoint は、確認できる serving 面だけを接続する

DeepSeek-V4-Flash-0731 の official model card から直接確認できるのは、agentic capability の強化という positioning と、vLLM deployment、DSpark speculative decoding を使う serving support である。これにより DeepSeek の競争軸が reasoning model 単体から、agentic workload を実際に serve する runtime 経路へ伸びていることは確認できる。[13]

一方、この 0731 artifact だけから broader V4 preview の context architecture 全体を再構成することはしない。V2 の MLA/MoE、R1 の reasoning RL、V4-Flash-0731 の agentic serving という各 source が直接支える節目だけをつなぐことで、version 境界を越えた specification の混入を避ける。[11, 12, 13]

後続 version の仕様を前段へ逆算しない。[11, 12, 13]

この見方では、DeepSeek の競争力は単一 benchmark の首位ではなく、model architecture と post-training、さらに runtime/deployment までを別々に最適化してきたことにある。ただし効率値や capability 値はそれぞれ paper/model card の条件付き報告であり、他 family との合成スコアには変換しない。[11, 12, 13]

Claim boundary

DeepSeek-V2 の KV-cache や throughput 比較は paper の setup に限定する。R1-Zero、R1、distilled Qwen/Llama variants は別 model subject として帰属させ、V4-Flash-0731 から broader V4 architecture を補完しない。[11, 12, 13]

Source-backed Technical Notes

DeepSeek-V2

Chronology: 2024 年に DeepSeek 系譜の efficiency architecture を定義した節目。 [11]

Technical points:

- 236B total / 21B active の MoE 構成と 128K context を paper が説明する。 [11]
- Multi-head Latent Attention (MLA) と DeepSeekMoE を導入し、paper 条件下で KV-cache・generation throughput の効率改善を報告する。 [11]

Limitation / attribution: 数値比較は paper の comparison setup に束縛し、別 serving stack へ一般化しない。

Primary URL: <https://arxiv.org/abs/2405.04434>

DeepSeek-R1

Chronology: 2025 年の reasoning-RL transition。 [12]

Technical points:

- R1-Zero は preliminary SFT なしの large-scale RL として説明される。 [12]
- R1 は cold-start data と multi-stage training を追加し、release には Qwen/Llama-based distilled variants も別 subject として含まれる。 [12]

Limitation / attribution: native R1/R1-Zero と distilled variants の base-model・license・architecture 属性を相互転記しない。

Primary URL: <https://arxiv.org/abs/2501.12948>

DeepSeek-V4-Flash-0731

Chronology: 2026 年 as-of 境界内の DeepSeek agentic-serving endpoint。 [13]

Technical points:

- official model card は agentic capability の強化を positioning として示す。 [13]
- vLLM deployment と DSpark speculative decoding の support を official material が説明する。 [13]

Limitation / attribution: 0731 card だけでは broader V4 preview の context architecture 全体を再確定できないため、未確認部分を補完しない。

Primary URL: <https://huggingface.co/deepseek-ai/DeepSeek-V4-Flash-0731>

5 Kimi : long context を起点に、reasoning RL、open agentic MoE、native multimodal へ

THEMATIC LINEAGE 5/7 — KIMI

Kimi の 2023 年 launch chronology は二次資料の制約を残す一方、2025 年以降は k1.5、K2、K3 の一次・official material によって、long-context research から agentic・multimodal frontier へ伸びる技術線を確認できる。 [14, 15, 16]

Theme at a glance

Long-context reasoning	Kimi k1.5 は multimodal reasoning を scaled RL で扱い、long-context scaling と policy/infrastructure optimization を結び付けた。[14]
Open agentic MoE	Kimi K2 は 1T total / 32B active の MoE、MuonClip、15.5T-token pretraining から agentic data synthesis と joint RL へ進む。[15]
Native multimodal endpoint	Kimi K3 は 2.8T total / 104B active、1M context、KDA + gated MLA を備える native-multimodal/agentic endpoint として公開される。[16]

Kimi の確実な technical lineage は、2025 年の long-context RL から組み立てる

Kimi の 2023 年 launch と初期 context-window chronology には secondary-source の限界が残るため、本号は historical priority をそこへ依存させない。一次 paper で確実に追える k1.5 は、multimodal reasoning model を scaled reinforcement learning で訓練し、long-context scaling、policy optimization、infrastructure optimization、long-to-short transfer を一つの研究線として提示する。[14]

k1.5 paper の公開時期は DeepSeek-R1 と近接するが、開示された technique と training path は同一ではない。chronology の近さを模倣や単純な先後関係へ変換せず、Kimi が long context を reasoning RL の問題設定へ接続した独立の節目として扱う。[14]

K2 で research branch が open agentic MoE へ接続する

Kimi K2 paper は 1T total / 32B active の MoE、MuonClip optimization、15.5T-token pretraining を説明し、さらに agentic data synthesis と real/synthetic environments をまたぐ joint reinforcement learning を扱う。ここで long-context reasoning の研究線が、tool-using workload を意識した open agentic model へ

接続する。[15]

この変化は『reasoning model を大きくした』だけではない。pretraining optimization、sparse activation、agentic data generation、post-training environment を同じ release で扱うことで、モデル能力と agent training infrastructure の境界が近づいている。performance claim は paper 評価に限定し、他 family の benchmark と直接順位付けしない。[15]

K3 では long context、multimodal、agentic workload が一つの current endpoint へ集約する

Kimi K3 の official material は 2.8T total / 104B active、native multimodal、1M context、KDA と gated MLA を説明し、long-horizon coding や agentic knowledge work を想定した current endpoint として位置付ける。K2 の agentic MoE に対して、K3 では context length と multimodal input を長い作業へ組み込む architecture 側の主張が強くなる。[16]

ただし model card から license の意味を推論しない。

K3 の distribution と architecture は D017、commercial use や Model-as-a-Service 条件などの exact legal text は D021 へ分離する。この分離によって、技術的に download 可能であることと、どの条件で事業利用できるかを同一の『open』ラベルで潰さない。[16]

Transition timeline

Kimi k1.5	multimodal reasoning を scaled RL で扱い、long-context scaling と long-to-short transfer を一次 paper で提示。[14]
Kimi K2	1T total / 32B active MoE、MuonClip、15.5T-token pretraining から agentic data synthesis と joint RL へ拡張。[15]
Kimi K3	2.8T total / 104B active、1M context、KDA + gated MLA、native multimodal/agentic positioning へ到達。[16]

Kimi では long context が、reasoning・agentic・multimodal をつなぐ持続的な軸になる

k1.5、K2、K3 を並べると、Kimi は long context を単なる最大 token 数ではなく、reasoning RL、agentic environment、native multimodal、long-horizon work へ段階的に接続している。2023 年の product chronology が完全に一次資料で閉じていなくても、2025

年以降の technical lineage はそれぞれの paper/model material から source-bounded に追える。[14, 15, 16]

同時に Kimi は Open Weight の境界問題を可視化する family でもある。K2/K3 の technical release と、K3 固有の license text を分けて扱うことで、architecture の開放性と commercial condition が別レイヤであることが明確になる。[15, 16]

Claim boundary

2023 年 Kimi の初期 launch/context chronology は本 package の一次資料として昇格させない。k1.5 と DeepSeek-R1 の近接 chronology から模倣・priority を推論せず、K3 の license 意味は model material ではなく exact LICENSE artifact へ委ねる。[14, 15, 16]

Source-backed Technical Notes

Kimi k1.5

Chronology: 2025 年 1 月の long-context reasoning / RL bridge。[14]

Technical points:

- multimodal reasoning model を scaled reinforcement learning で訓練したと paper が説明する。[14]
- long-context scaling、policy optimization、infrastructure optimization、long-to-short transfer を主要要素として扱う。[14]

Limitation / attribution: DeepSeek-R1 との公開時期の近さだけから priority や simple imitation を主張しない。

Primary URL: <https://arxiv.org/abs/2501.12599>

Kimi K2

Chronology: 2025 年の open agentic MoE transition。[15]

Technical points:

- 1T total / 32B active の MoE、MuonClip、15.5T-token pretraining を paper が説明する。[15]
- agentic data synthesis と real/synthetic environments をまたぐ joint RL を扱う。[15]

Limitation / attribution: performance 値は paper evaluation に限定し、他 family の非互換 benchmark へ正規化しない。

Primary URL: <https://arxiv.org/abs/2507.20534>

Kimi K3

Chronology: 2026 年 as-of 境界内の Moonshot current endpoint。[16]

Technical points:

- 2.8T total / 104B active、native multimodal、1M context を official material が説明する。[16]
- KDA + gated MLA と、long-horizon coding / agentic knowledge work の positioning を示す。[16]

Limitation / attribution: exact commercial/license conditions はこの model material から推論せず、Kimi K3 LICENSE の別 source へ委ねる。

Primary URL: <https://huggingface.co/moonshotai/Kimi-K3>

6 主要 4 系統の外側：MiniMax、Yi、Baichuan が示す競争と分化

THEMATIC LINEAGE 6/7 — PARALLEL

中国発 AI の競争史を主要 4 系統だけで閉じると、agentic frontier の別経路、2023-24 年の open-weight/local wave、domain specialization への分化を見落とす。MiniMax、Yi、Baichuan はその補助線になる。[17, 18, 19]

Theme at a glance

Parallel agentic frontier	MiniMax M2.7 は Agent Teams、skills、dynamic tool search を掲げ、主要 4 系統以外にも agentic frontier の競争線があることを示す。[17]
Open/local bridge	Yi-1.5 は 34B/9B/6B variants、Ollama local use、fine-tuning integrations を通じて 2023~2024 年の developer-facing open-weight wave を示す。[18]
Specialization derivation	/ Baichuan-M3-235B は medical specialization と Qwen3-MoE ancestry を明示し、競争が独立 family だけでなく派生・専門化へ分化する例になる。[19]

MiniMax は、2026 年の agentic frontier を 4family だけで閉じないための対照線になる

MiniMax M2.7 の official announcement は Agent Teams、skills、dynamic tool search、model が自身の development workflow の一部へ参加するという方向を打ち出す。これは MiniMax を 5 番目の central lineage へ機械的に格上げする根拠ではないが、2026 年の agentic competition が GLM/Qwen/DeepSeek/Kimi だけで完結していないことを示す material な parallel branch である。[17]

この source から確定できるのは agentic positioning までであり、別の official model card で観測された open-weight serving や exact license をこの一 source へ合成しない。parallel line を残す目的は coverage を広げることであって、source 境界を弱めることではない。[17]

Yi-1.5 は local deployment と fine-tuning ecosystem を結ぶ historical bridge になる

Yi-1.5 repository は 34B/9B/6B variants、Ollama を含む local use、fine-tuning ecosystem integrations、Apache-2.0 code/weights を示す。2023~2024 年の open-weight wave では、weights を公開するだけでなく、developer が local runtime や fine-tuning toolchain

へ接続できることが distribution の実効性を左右した。[18]

一方、2024 年の repository から 2026 年にも同じ brand が general frontier を継続していると推論することはできない。本号で Yi を使うのは、主要 4 系統の前後に存在した open/local deployment の別経路を示すためであり、current frontier rank を与えるためではない。[18]

Baichuan は、独立 family から specialized/derivative ecosystem へ分化する例を示す

Baichuan-M3-235B の official model card は medical-enhanced clinical inquiry への specialization、Qwen3-MoE ancestry/acknowledgement、Apache-2.0 licensing を示す。これは中国発 model competition が独立した foundation-model family の数だけで進むのではなく、他 family の base を取り込み、domain-specific product へ派生する経路を持つことを可視化する。[19]

ただし M3 card だけから、より初期の Baichuan2 系統がどのように現在へ移行したかを historical fact として埋めない。current specialization と ancestry は直接確認できるが、過去の独立 lineage との連続性は別 source が必要な論点として残す。[19]

Transition timeline

Yi-1.5 / 2024 複数 size、Ollama local use、fine-tuning integrations、Apache-2.0 code/weights を repository が示す。 [18]

MiniMax M2.7 / 2026 Agent Teams、skills、dynamic tool search を前面に出す parallel agentic frontier。 [17]

Baichuan-M3 medical specialization と Qwen3-MoE ancestry を明示する derivative/specialized endpoint。 [19]

競争は『独立 family の数』から、agentic branch・local ecosystem・specialized derivation へ広がる

MiniMax、Yi、Baichuan を補助線として置くと、中国発 frontier AI の歴史は主要 4family の success story だけでは説明できない。parallel な agentic strategy、developer local ecosystem、domain specialization という異なる競争様式が同時に存在し、どの線を central

に置くかは as-of 時点と source strength に依存する。 [17, 18, 19]

このため本号では MiniMax を competing frontier、Yi/Baichuan を bridge/context として役割分離する。各 source が直接支える範囲を越えて current frontier rank や historical continuity を補完せず、それでも主要 4 系統だけで閉じた物語を避ける。 [17, 18, 19]

Claim boundary

MiniMax M2.7 announcement から exact open-weight/license 条件を補完しない。Yi-1.5 repository から 2026 年の current frontier status を推論せず、Baichuan-M3 card から初期 Baichuan family との完全な historical continuity を導出しない。 [17, 18, 19]

Source-backed Technical Notes

MiniMax M2.7

Chronology: 2026 年の parallel agentic frontier branch。 [17]

Technical points:

- official announcement は Agent Teams、skills、dynamic tool search を主要方向として説明する。 [17]
- model が自身の development workflow の一部へ参加するという positioning を打ち出す。 [17]

Limitation / attribution: この announcement 単体では open-weight serving integrations や exact license term を確定しない。

Primary URL: <https://www.minimax.io/news/minimax-m27-en>

Yi-1.5

Chronology: 2024 年の open-weight / local-deployment bridge。 [18]

Technical points:

- repository は 34B/9B/6B variants と Ollama を含む local use を案内する。 [18]
- fine-tuning ecosystem integrations と Apache-2.0 code/weights を project が示す。 [18]

Limitation / attribution: この repository だけでは 2026 年の独立 general-frontier endpoint の有無を確定しない。

Primary URL: <https://github.com/01-ai/Yi-1.5>

Baichuan-M3-235B

Chronology: domain-specialized / derivative ecosystem を示す current example。 [19]

Technical points:

- official model card は medical-enhanced clinical inquiry への specialization を説明する。 [19]
- Qwen3-MoE ancestry/acknowledgement と Apache-2.0 licensing を示す。 [19]

Limitation / attribution: 初期 Baichuan2 から現在までの historical transition 全体はこの M3 card 単体では確定しない。

Primary URL: <https://huggingface.co/baichuan-inc/Baichuan-M3-235B>

7 Open Weight は一枚岩ではない：配布されることと、同じ権利で使えることは別問題

THEMATIC LINEAGE 7/7 — WEIGHT

公開 weights は developer adoption を加速しうるが、code、weights、commercial use、attribution、Model-as-a-Service 条件は artifact ごとに異なる。Kimi K3 の exact license と Yi/Baichuan の Apache-2.0 artifacts を並べると、その差が具体的になる。 [20, 18, 19]

Theme at a glance

Artifact-specific rights	Kimi K3 License は広い use/modification/distribution grant と、特定の Model-as-a-Service ・ display 条件を同じ license 本文に持つ。 [20]
Apache-2.0 examples	Yi-1.5 と Baichuan-M3 はそれぞれの official repository/model card で Apache-2.0 を示すが、model lineage や distribution 形態は同じではない。 [18, 19]

download 可能な weights と、同じ権利で使える weights は別概念である

Open Weight を技術的な distribution 状態として読むだけでは、事業利用時の条件を説明できない。Kimi K3 License は covered software/weights について use、copy、modify、distribute、 sublicense、sell、deploy、fine-tune を含む広い grant を置きつつ、定義された Model-as-a-Service business に別条件を設けている。公開されていることと、無条件に同じ商用形態で使えることは同義ではない。 [20]

license 本文は、定義された Model-as-a-Service business が連続 12 か月の aggregate revenue で 2000 万米ドルを超える場合に commercial use 前の separate agreement を求める。また covered large commercial product/service について 100M MAU または月間 revenue 2000 万米ドル超を条件とする表示条項と、本文上の exclusions を置く。ここで重要なのは threshold の大小を評価することではなく、権利境界が artifact 固有の text で決まる点である。 [20]

Apache-2.0 という同じ label でも、技術的な役割は同じではない

Yi-1.5 は repository 上で Apache-2.0 code/weights と local/fine-tuning integrations を示し、Baichuan-M3 も official model card で Apache-2.0 を掲げる。両者は license label 上の共通点を持つが、Yi は historical open/local bridge、Baichuan-M3 は medical-specialized かつ Qwen3-MoE ancestry を持つ current artifact であり、同じ distribution strategy を意味しない。 [18, 19]

したがって license comparison は『どれが最も open か』という一軸 rank ではなく、weights、repository code、commercial conditions、attribution/display、derivative use、Model-as-a-Service などの項目を artifact ごとに確認する必要がある。本号の Open Weight という語は、権利条件を省略する shortcut ではなく、むしろその分離を促すラベルとして使う。 [20, 18, 19]

community 上の license friction は、法的結論へ昇格させない

community 上では license friction や adoption boundary を示す signal が観測されても、本号では一次資料で裏付けられていない third-party compliance、derivative provenance、infringement、適用 version を確定する材料には使わない。法的意味を論じる際は、

対象 version の exact license text へ戻る。 [20]

この制約は technical history にも重要である。model が download できること、runtime で動くこと、派生 model を作れること、商用 service として提供できることはそれぞれ別の問いであり、Open Source と Open Weight を無条件に同義語として使うと distribution 史そのものを誤って単純化する。 [20, 18, 19]

Transition timeline

Yi-1.5	Apache-2.0 code/weights と local/fine-tuning integrations を repository が示す open/local distribution example。 [18]
Baichuan-M3	Apache-2.0 を掲げる一方、medical specialization と Qwen3-MoE ancestry を持つ derivative example。 [19]
Kimi K3 License	broad grant に加えて Model-as-a-Service revenue condition と large-product display condition を exact text で定義。 [20]

Open Weight は architecture ではなく、distribution と rights を分離して読むための境界概念である

Kimi K3、Yi-1.5、Baichuan-M3 を並べると、weights が利用可能であるという技術的事実だけでは rights regime を一意に説明できない。license text、code repository、commercial service 条件、attribution/display 義務を version/artifact 単位で追う必要がある。 [20, 18, 19]

この分離は developer ecosystem の理解にもつながる。local runtime や fine-tuning integration は adoption 経路を作る一方、business model によって追加条件が生じる artifact もある。distribution の広さと法的・商用上の条件を一つの『open さ』score へ畳み込まないことが、本号の cross-cutting な結論である。 [20, 18, 19]

Claim boundary

本 package は technical distribution を理解するための license 境界整理であり、法的助言ではない。Kimi K3 の条件を K2 や Moonshot の全 artifact へ移さず、Yi/Baichuan の Apache-2.0 表記も各 source が示す対象に限定する。 [20, 18, 19]

Source-backed Technical Notes

Kimi K3 License

Chronology: Kimi K3 に適用される 2026 年の exact license boundary。 [20]

Technical points:

- use、copy、modify、distribute、 sublicense、sell、deploy、fine-tune を含む broad grant を本文が定める。 [20]
- 定義された Model-as-a-Service business の 12 か月 aggregate revenue 条件と、100M MAU または月間 revenue 条件に結び付く display clause を本文が定める。 [20]

Limitation / attribution: Kimi K3 という covered artifact の text を要約するもので、Kimi K2 や third party の compliance へ一般化せず、法的助言とも扱わない。

Primary URL: <https://huggingface.co/moonshotai/Kimi-K3/blob/main/LICENSE>

Yi-1.5 distribution

Chronology: 2024 年の open/local distribution example。 [18]

Technical points:

- repository は Apache-2.0 code/weights を示す。 [18]
- Ollama local use と fine-tuning ecosystem integrations を案内し、weights の配布と developer toolchain を接続する。 [18]

Limitation / attribution: 2024 repository の条件を later Yi artifacts へ自動的に継承させない。

Primary URL: <https://github.com/01-ai/Yi-1.5>

Baichuan-M3 distribution

Chronology: current specialized / derivative distribution example。 [19]

Technical points:

- official model card は Apache-2.0 licensing を示す。 [19]
- medical specialization と Qwen3-MoE ancestry/acknowledgement を同じ artifact で示す。 [19]

Limitation / attribution: Apache-2.0 という label から earlier Baichuan family の license ・ architecture ・ continuity を推論しない。

Primary URL: <https://huggingface.co/baichuan-inc/Baichuan-M3-235B>

8 4 系統は何に収斂し、どこで分岐したか

CROSS-FAMILY SYNTHESIS

GLM、Qwen、DeepSeek、Kimi は 2026 年までに reasoning、coding/tool use、agentic workload、long context、serving efficiency という似た課題へ接近した。しかし収斂しているのは problem set であって、implementation recipe ではない。GLM は ARC と long-context serving、Qwen は family-wide hybrid reasoning と agentic coding、DeepSeek は MLA/MoE efficiency と reasoning RL、Kimi は long-context RL から agentic MoE・native multimodal へ進んでいる。 [6, 7, 9, 10, 11, 12, 14, 15, 16]

distribution についても一様ではない。Qwen3/Qwen3.6 は Apache-2.0 public/open-weight distribution を明示し、GLM は version ごとに model-use/commercial permission と repository code の境界を確認する必要がある。Kimi は K2/K3 の technical distribution と K3 固有 license を分離し、DeepSeek も native/distilled model subject を混同しないことが重要になる。 [4, 9, 10, 12, 15, 16, 20]

したがって cross-family comparison は benchmark score を一枚の順位表へ畳み込むのではなく、各 family がどの layer を競争軸へしたかを比べる方が再現可能である。architecture、post-training、serving、distribution/license を別 dimension として見ることで、近い capability vocabulary の背後にある技術経路の違いを保持できる。 [6, 9, 11, 12, 14, 15, 20]

Cross-family comparison

観点	GLM	Qwen	DeepSeek	Kimi
Architecture / efficiency	GLM-4.5 の MoE と GLM-5.2 の IndexShare・1M-context serving。	Qwen3 の dense/MoE family を広い model portfolio として展開。	DeepSeek-V2 の MLA + DeepSeekMoE で memory/serving efficiency を設計課題化。	K2 の 1T/32B-active MoE から K3 の 2.8T/104B-active、KDA + gated MLA へ。 [6, 7, 9, 11, 15, 16]
Reasoning / post-training	GLM-4.5 が hybrid thinking/direct response を ARC framing へ統合。	Qwen3 が thinking/non-thinking と thinking-budget control を family-wide に統合。	R1-Zero の large-scale RL と R1 の cold-start + multi-stage path を分離。	k1.5 の scaled RL / long-context reasoning から K2 の agentic joint RL へ。 [6, 9, 12, 14, 15]
Agentic / coding	All Tools から ARC へ、tool orchestration と coding/reasoning を family strategy へ接続。	Qwen3.6 で repository-level reasoning と agentic coding、thinking-history retention を強調。	V4-Flash-0731 で agentic positioning と vLLM/DSPark serving support を確認。	K2 の agentic data/RL から K3 の long-horizon coding・knowledge work へ伸長。 [5, 6, 10, 13, 15, 16]
Distribution / rights	ChatGLM-6B では model-use/commercial permission と repository code license を分離して読む。	Qwen3/Qwen3.6 は Apache-2.0 public/open-weight distribution を明示。	native R1/R1-Zero と Qwen/Llama-based distills を別 model subject として扱う。	technical model material と K3 exact license を分離し、MaaS/display 条件を artifact-specific に確認。 [4, 9, 10, 12, 16, 20]

9 この号の総括

ISSUE SYNTHESIS

本号を通して見えるのは、『中国モデル』という単一の architecture や学習 recipe ではなく、異なる出発点を持つ複数の系譜である。GLM は公開・ローカル展開から tool use、ARC、長文脈 serving へ、Qwen は広い family / platform から hybrid reasoning と agentic coding へ、DeepSeek は MLA / MoE による効率設計から reasoning RL と agentic serving へ、Kimi は long context を起点に reasoning RL、open agentic MoE、native multimodal へ進んだ。相互に近い課題へ向かっていても、その技術的な道筋を一つにまとめることはできない。

一方で、2025 年から 2026 年にかけて競争課題そのものは重なってきた。reasoning をどのように利用形態へ組み込むか、coding や tool use を長時間の agentic workload へどう接続するか、long context を実際に serve できる効率へ落とすか、そして weights を公開したモデルを developer がどの runtime や distribution 経路で使えるようにするかである。収斂しているのは一つの実装方法ではなく、frontier model に求められる問題設定の側だと捉える方が、本号で確認した資料には整合的である。

MiniMax、Yi、Baichuan を併記すると、4 主要系統だけで中国の open-weight 史を閉じることさえできない。MiniMax は agentic frontier の並行線として、Yi は 2023～2024 年の open distribution を示す bridge として、Baichuan は現在の specialized / derivative な位置を示す例として機能する。そして Open Weight という言葉も一つの制度ではない。weights の取得可能性、repository code、再配布、商用利用、表示義務、Model-as-a-Service 条件は artifact ごとに異なり、技術的な『開放性』と法的・商用上の条件を分離して確認する必要がある。

なお、本号には意図的に残した境界がある。Kimi の 2023 年初期 chronology は一次資料で完全には閉じておらず、確実な technical lineage は 2025 年以降を中心に構成した。community の runtime 採用や license friction も、技術仕様や普及度を確定する根拠には使っていない。また、各社・各論文の benchmark 値を異なる条件のまま横断順位へ変換していない。したがって本号が示すのは『どのモデルが絶対に最強か』ではなく、2026 年 8 月 22 日までに各系譜が何を競争課題として選び、どの公開・serving・権利境界を伴って frontier へ到達したか、という技術史である。

References / Source Notes

- [1]Tsinghua University / Zhipu AI. *GLM-130B*. URL: <https://arxiv.org/abs/2210.02414> (visited on 08/22/2026).
- [2]Alibaba Cloud. *Qwen Technical Report*. URL: <https://arxiv.org/abs/2309.16609> (visited on 08/22/2026).
- [3]DeepSeek. *DeepSeek LLM*. URL: <https://arxiv.org/abs/2401.02954> (visited on 08/22/2026).
- [4]THUDM / Zhipu AI. *ChatGLM-6B*. URL: https://github.com/zai-org/ChatGLM-6B/blob/main/README_en.md (visited on 08/22/2026).
- [5]Zhipu AI / THUDM. *ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools*. URL: <https://arxiv.org/abs/2406.12793> (visited on 08/22/2026).
- [6]Z.ai. *GLM-4.5*. URL: <https://arxiv.org/abs/2508.06471> (visited on 08/22/2026).
- [7]Z.ai. *GLM-5.2*. URL: <https://huggingface.co/zai-org/GLM-5.2> (visited on 08/22/2026).
- [8]Alibaba Cloud. *Qwen2.5*. URL: <https://arxiv.org/abs/2412.15115> (visited on 08/22/2026).
- [9]Alibaba Cloud. *Qwen3*. URL: <https://arxiv.org/abs/2505.09388> (visited on 08/22/2026).
- [10]Qwen / Alibaba. *Qwen3.6-27B*. URL: <https://huggingface.co/Qwen/Qwen3.6-27B> (visited on 08/22/2026).
- [11]DeepSeek. *DeepSeek-V2*. URL: <https://arxiv.org/abs/2405.04434> (visited on 08/22/2026).
- [12]DeepSeek. *DeepSeek-R1*. URL: <https://arxiv.org/abs/2501.12948> (visited on 08/22/2026).
- [13]DeepSeek. *DeepSeek-V4-Flash-0731*. URL: <https://huggingface.co/deepseek-ai/DeepSeek-V4-Flash-0731> (visited on 08/22/2026).
- [14]Moonshot AI. *Kimi k1.5*. URL: <https://arxiv.org/abs/2501.12599> (visited on 08/22/2026).
- [15]Moonshot AI. *Kimi K2*. URL: <https://arxiv.org/abs/2507.20534> (visited on 08/22/2026).
- [16]Moonshot AI. *Kimi K3*. URL: <https://huggingface.co/moonshotai/Kimi-K3> (visited on 08/22/2026).
- [17]MiniMax. *MiniMax M2.7*. URL: <https://www.minimax.io/news/minimax-m27-en> (visited on 08/22/2026).
- [18]01.AI. *Yi-1.5*. URL: <https://github.com/01-ai/Yi-1.5> (visited on 08/22/2026).
- [19]Baichuan. *Baichuan-M3-235B*. URL: <https://huggingface.co/baichuan-inc/Baichuan-M3-235B> (visited on 08/22/2026).
- [20]Moonshot AI. *Kimi K3 License*. URL: <https://huggingface.co/moonshotai/Kimi-K3/blob/main/LICENSE> (visited on 08/22/2026).