
Japanese Generative AI Technical Survey Special

SP001

中国発 Open-Weight AI の技術史 / Thematic survey as of 2026-08-24

複数の系譜が、Frontier を形づくる

中国発の生成 AI は、一つのモデルや一つの組織から伸びたのではない。DeepSeek、Qwen、GLM、Kimi を中心に、効率化、reasoning、long context、agentic execution、distribution がどのように別々の経路から収束したかを追う。

Plural Foundations / DeepSeek / Qwen / GLM / Kimi / Frontier Synthesis

Editorial cutoff

Open history, evidence observed through 2026-08-24 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Thematic Longform Technical

Survey。

本巻の問いと読み方

本巻の問いは、中国発の Generative AI が、どのような技術的・ecosystem 上の発展を経て、2026 年時点の Frontier AI 競争における主要な構成要素となったのかである。対象は DeepSeek、Qwen、GLM、Kimi を中心とし、Baichuan 2 などは歴史的な補助線として扱う。観測時点は 2026 年 8 月 24 日であり、それ以後の更新は本巻の authority には含めない。

重要なのは、ここで「中国勢」を一つの model family のように扱わないことである。2022 年の GLM-130B、2023 年の Baichuan 2、2024 年初頭の DeepSeek LLM、同年の Qwen2 は、異なる組織・設計・公開経路から現れた。後年、long context、sparsity、reasoning/post-training、agentic execution、hub/runtime distribution といった共通の設計圧力が見えるようになって、それは単一の技術系譜を意味しない。[1, 2, 3, 4]

また、本巻では open source と open weight を同義語として扱わない。repository の code license、checkpoint の weight/model license、再配布、商用利用、training recipe の再現可能性は別々の条件である。一次資料で確認できない条件は、family 全体へ一般化しない。benchmark も同様で、異なる model version、evaluation harness、条件を正規化せずに横断ランキングへ変換しない。

Evidence boundary

技術史上の chronology は一次資料の公開日・release identity で固定する。一方、公開日の近さ、似た architecture、同じ用語の使用だけから、組織間の直接的影響、institutional ancestry、技術継承を推定しない。2026 年の current endpoint については、各 source が直接裏づける claim だけを採用し、license や benchmark 条件に未解決事項が残る場合はそのまま境界として残す。

目次

1	中国 open-model 史は、最初から複数の系譜だった	3
2	DeepSeek: foundation から効率化、reasoning、agentic frontier へ	3
3	Qwen: 単一 checkpoint より model breadth と distribution	4
4	GLM: bilingual foundation から agentic systems engineering へ	4
5	Kimi: long context と multimodal reasoning から open-weight agent へ	5
6	Frontier で収束したのは「一つの中国モデル」ではなく、設計圧力だった	6

1 中国 open-model 史は、最初から複数の系譜だった

2026 年の frontier だけを見ると、DeepSeek、Qwen、GLM、Kimi が同じ競争空間で long context や agentic workload を掲げている。しかし、その到達点から過去を逆算して「一つの中国 LLM 系譜」を作ると、初期の多様性を失う。最初に置くべきなのは、複数の独立した anchor である。

1.1 2022–2024: plural foundations

2022 年 10 月の GLM-130B は、large bilingual pre-trained model という明確な研究対象を提示した。これは後年の GLM family を読むための早期 anchor になるが、ここから後続の個別技術や他組織への直接的な系譜を導くことはできない。一次資料が確定するのは、公開時点とその研究対象である。[1]

2023 年 9 月の Baichuan 2 は、7B/13B 級を含む open large-scale language model family として、主要 4family へ収束する前の ecosystem がすでに plural だったことを示す補助線になる。本巻では Baichuan 2 を 2026 frontier 性能の代理にせず、2023 年の open-model environment を示す context evidence として使う。[2]

2024 年 1 月の DeepSeek LLM は、7B/67B、約 2T-token の中国語・英語 pretraining、scaling-law、SFT/DPO を含む foundation baseline を提示した。後の DeepSeek-V2 や R1 を理解する際に重要なのは、最初から reasoning 専用 system だったと読むことなく、foundation family から何を競争軸として切り出していったかを追うことである。[3]

同じ 2024 年、Qwen2 は dense と MoE を含む広い model range、multilingual/coding/math/reasoning、Hugging Face と ModelScope を通じた distribution、quantization/fine-tuning/deployment 資源を同じ technical report の射程に入れた。ここでは model architecture だけでなく、取得・調整・配備の経路まで family strategy に含まれている。[4]

1.2 「open」を一語で済ませない

この時期の各 artifact が公開されていたことと、それらが同じ license 条件だったことは別問題である。weights が取得できること、code が open-source license であること、training recipe が再現可能であること、商用再配布が許されることは独立した条件で

ある。本巻で「open-weight ecosystem」という語を使うのは、model artifact の利用可能性と distribution が競争構造に組み込まれたことを指すためであり、OSI 的な意味での open source を一括認定するためではない。

1.3 歴史を「勝者の前史」にしない

GLM-130B、Baichuan 2、DeepSeek LLM、Qwen2 を並べる意味は、2026 年の有力 family の祖先を一行に並べることではない。むしろ、異なる組織が foundation model、bilingual capability、model range、distribution など別の問題設定を持っていたことを保つためである。後に同じ技術圧力へ接近しても、起点と developer-facing strategy の違いは残る。

2 DeepSeek: foundation から効率化、reasoning、agentic frontier へ

DeepSeek の変化は、family 内で競争軸がどのように移ったかを最も追いやすい。DeepSeek LLM の foundation baseline、V2 の efficiency architecture、R1 の reasoning/post-training、V4 の long-context/agentic endpoint は、同じ family の中で重点が段階的に変わった例として読める。[3, 5, 6, 7]

2.1 V2: parameter count ではなく active computation を見る

DeepSeek-V2 は MoE、Multi-head Latent Attention (MLA)、DeepSeekMoE を前面に出した。一次資料は 236B total parameters に対して 21B activated parameters、128K context を報告する。ここで重要なのは、単純な総 parameter 増大ではなく、token あたりに active になる計算量や attention/serving 効率が設計上の第一級の問題になったことである。[5]

MoE を「大きいのに軽い」という一語に縮約すると、本来の比較境界を失う。total parameter、activated parameter、context length、training/inference cost は同じ尺度ではない。本巻では V2 の数値を source-local specification として扱い、他 family の異なる計測条件と一つの効率ランキングにしない。

2.2 R1: reasoning を post-training の独立軸にする

DeepSeek-R1 は reasoning 能力を、単なる foundation scale の副産物ではなく post-training 設計の独立した競争軸として可視化した。R1-Zero では large-scale reinforcement learning を前面に置き、その後の R1 で

は cold-start data と multi-stage training を組み合わせる。一次資料が示す価値は、reasoning を評価結果だけでなく training sequence の問題として記述した点にある。[6]

ここでも license 境界は重要である。R1 primary weights と distilled derivative には upstream model 由来の条件が入り得るため、「DeepSeek-R1」という family label だけで全 checkpoint の license を同一視しない。

2.3 V4: model から system endpoint へ

2026 年 4 月の DeepSeek V4 official release/transparency material は、1M context、sparse/token-compression mechanism、thinking/non-thinking operation、agentic coding、API/deployment を同じ endpoint の説明に集約する。これは性能表の順位よりも、long context、efficiency、reasoning mode、agentic execution が一つの system design へ束ねられたことを示す。[7]

一方、V4 について本巻が確定しないものもある。exact checkpoint license や cross-family benchmark comparability、source-local な performance claim を、別 harness の model と横断比較することはしない。current release detail は official source が直接支える範囲に限定する。

2.4 DeepSeek を一本の直線にしない

DeepSeek LLM から V4 への chronology は確認できる。しかし、V2 の efficiency design、R1 の RL-centered post-training、V4 の agentic endpoint は、それぞれ別の設計問題への応答である。family continuity は技術要素がすべて直線的に継承されたことを意味しない。ここで見えるのは、foundation model 競争から system-level optimization へ焦点が広がったという family 内の転換である。

3 Qwen: 単一-checkpoint より model breadth と distribution

Qwen を特徴づけるとき、一つの flagship checkpoint だけに注目すると重要な部分を落とす。Qwen2 の technical report は dense/MoE を含む幅広い model range と、Hugging Face/ModelScope、quantization、fine-tuning、deployment を同じ開発者経路に置く。2026 年の Qwen3.8 official repository では agent/cod-

ing/research line と distribution がさらに前面に出る。[4, 8]

3.1 Qwen2: model family と利用経路を同時に設計する

Qwen2 は multilingual、coding、math、reasoning を横断する family として提示され、dense と MoE の複数構成を含む。ここでの breadth は単なる model 一覧の多さではなく、developer が用途・計算資源・deployment 条件に応じて選択できる surface を作ることに結びついている。[4]

また、distribution は公開後の付随作業ではない。Hugging Face と ModelScope への配布、quantization/fine-tuning/deployment 資源が一次資料の中で扱われていることは、model の能力と利用可能性が同じ ecosystem strategy に入っていることを示す。これは「最高性能の単一 model」を中心に語る競争観とは別の軸である。

3.2 Qwen3.8: agent/coding/research と distribution の接続

2026 年 8 月の Qwen3.8 official repository は open-weight agent/coding/research line と Hugging Face/ModelScope distribution を主要な位置づけとして示す。本巻が注目するのは、能力項目が増えたというより、model 取得から agentic workload へ接続するまでの developer path が frontier competition の一部になったことである。[8]

ただし Qwen3.8 Evidence Card には release identity、checkpoint-specific license、performance 条件に未解決項目が残る。repository license から weight/model license を自動的に導かず、family 全体へ同一条件を一般化しない。benchmark についても source-local position に留める。

3.3 distribution-first という別の frontier

Frontier という語を純粋な benchmark 順位だけに限定すると、Qwen のような breadth/distribution 型の戦略を過小評価する。model hub、quantization、fine-tuning、serving との接続は、利用者が model を実際の software stack に組み込むまでの摩擦を下げる。SP001 が ecosystem を技術史の一部として扱うのは、この distribution layer が model architecture と独立ではなくっているためである。

4 GLM: bilingual foundation から agentic systems engineering へ

GLM の長い時間軸では、2022 年の GLM-130B を bilingual foundation の anchor として置き、2026 年の GLM-5 を architecture、RL infrastructure、serving までは含む system engineering の endpoint として読む。両者の間を、単純な「同じ技術の大型化」とは扱わない。[1, 9]

4.1 GLM-130B: chronology の anchor

GLM-130B は large bilingual pre-trained model として 2022 年に公開された。本巻にとっての役割は、後年の agentic GLM を「突然現れた 2026 年 model」として扱わないための歴史的 anchor である。ただし、公開時点と研究対象が確認できることから、後続の個別 sparse mechanism や RL infrastructure への直接的な技術継承まで推定することはできない。[1]

4.2 GLM-5: architecture、post-training、serving を同じ system に束ねる

GLM-5 official repository/technical report は、744B total / 40B active、28.5T tokens、sparse-attention reuse、asynchronous RL infrastructure、long-horizon agentic engineering、複数の local-serving recipe をまとめて提示する。model architecture、post-training infrastructure、deployment が別工程ではなく、一つの systems problem として扱われている。[9]

ここで 744B/40B active という値は source-local specification であり、他 model の parameter accounting や FLOP accounting と無条件に比較できない。28.5T tokens についても dataset composition や counting convention を跨いだ単純比較には使わない。sparse attention について source が他技術への参照を行っていても、それを organization 間の institutional ancestry へ拡張しない。

4.3 local serving が frontier の内側に入る

GLM-5 で複数の local-serving recipe が technical material に含まれることは、frontier capability を API 上の model score だけで理解できなくなっていることを示す。実際にどの runtime で、どの hardware 条件で、どの precision や parallelism を使うかは利用可能性を決める。ここでも本巻は serving recipe の存在を確認するに留め、異なる hardware での cost

advantage を未検証のまま定量比較しない。

GLM-5 の repository/model license terms は Evidence 上の未解決境界として残る。したがって「repository が公開されている」ことを、その checkpoint の全利用条件の確定と読み替えない。

5 Kimi: long context と multimodal reasoning から open-weight agent へ

Kimi family では long context と reasoning を早い段階から主要テーマとして読める。Kimi k1.5 は long-context multimodal reasoning と reinforcement learning を結びつけ、2026 年の Kimi K3 は 1M context、sparse MoE、native multimodality、long-horizon coding/agentic focus を一つの open-weight release line へまとめる。[10, 11]

5.1 k1.5: long context と RL を reasoning へ接続する

Kimi k1.5 は long-context multimodal reasoning と RL を扱う。ここで重要なのは、long context を単なる最大 token 数としてではなく、reasoning workload と結びついた設計対象として扱っていることである。[10]

一方、k1.5 から K2/K3 への直接的な技術継承を一次資料がすべて証明しているわけではない。本巻では k1.5 を family 内の歴史的 bridge として使い、後続 model の個別 mechanism を遡及的に k1.5 由来と断定しない。

5.2 K3: 1M context を agentic system property として読む

2026 年 7 月の Kimi K3 official repository は、2.8T open-weight native multimodal model、efficient-attention/residual mechanisms、1M context、sparse MoE、long-horizon coding/agentic focus を同じ release line に置く。ここでは long context が単独の機能ではなく、multimodal input と長時間の agentic execution を支える system property として位置づけられる。[11]

ただし 2.8T、1M context、sparse MoE といった仕様を、他 family の異なる parameter accounting や context evaluation と直接順位づけすることはしない。K3 の artifact-specific license terms と source-local benchmark conditions も未解決境界として残す。

5.3 長文脈競争の意味が変わる

初期の long-context 競争は「どれだけ長い input を入れられるか」という上限値で語られがちだった。SP001 の accepted Evidence から見える 2026 年 endpoint では、long context は reasoning、multimodality、coding、agentic workload と組み合わせられている。したがって context length だけを切り出した比較では、system としての設計意図を捉えにくい。

6 Frontier で収束したのは「一つの中国モデル」ではなく、設計圧力だった

2022–2024 年の GLM-130B、Baichuan 2、DeepSeek LLM、Qwen2 が示すのは、後の frontier competition が単一の起源から伸びたのではなく、複数 family と distribution 経路の並存から形成されたということである。[1, 2, 3, 4]

6.1 2026 endpoint に見える共通圧力

2026 年の endpoint を見ると、DeepSeek V4 は 1M context と sparse/token-compression、thinking/non-thinking、agentic coding/API deployment をまとめる。Qwen3.8 は open-weight agent/coding/research と hub distribution を接続する。GLM-5 は sparse attention、asynchronous RL、local serving を systems engineering として束ね、Kimi K3 は 1M context、sparse MoE、native multimodality、long-horizon agentic focus をまとめる。[7, 8, 9, 11]

この並行性から読めるのは、model 単体の score だけでなく、**計算効率、post-training、context、agentic execution、distribution/runtime** へ競争軸が広がったことである。だが、共通圧力への応答が似ていることは、同じ系譜になったことを意味しない。

6.2 収束は同一化ではない

DeepSeek では V2 の efficiency design と R1 の RL-centered reasoning が強い転換点になる。Qwen では model breadth と hub/deployment distribution が一貫した developer-facing axis として見える。GLM-5 は RL/serving infrastructure を model design と同じ system 問題として提示し、Kimi は long-context multimodal reasoning から agentic system へ軸を伸

ばす。[5, 6, 4, 9, 10, 11]

この差を保つことが、本巻の「中国発 open-weight ecosystem」という言葉を国家単位の単純な性能ランキングにしないための条件である。組織ごとの technical strategy、artifact の配布経路、license 境界を維持したまま、共通の design pressure だけを横断して読む。

6.3 なぜ恒常的な frontier 構成要素になったのか

SP001 の Evidence から導ける結論は、単一 benchmark で恒常的に首位になったから、ではない。複数 family が architecture、post-training、long context、agentic workload、model hub、serving を別々の強みとして積み上げ、それらを developer が利用可能な artifact として継続的に配布する競争構造を形成したことが重要である。

これは model quality が重要でないという意味ではない。むしろ frontier の評価対象そのものが、checkpoint の静的な性能から、training/post-training、runtime、tool use、context management、deployment までを含む system へ広がった。その広がり of 複数箇所 DeepSeek、Qwen、GLM、Kimi が異なる強みを持つため、一つの release で優劣が入れ替わっても ecosystem 全体が frontier から消える構造ではなくなった、と読むことができる。

6.4 残る境界

本巻は 2026 年 8 月 24 日までの accepted Evidence で閉じる。Qwen3.8、GLM-5、Kimi K3、DeepSeek V4 について、checkpoint-specific license や benchmark comparability、current release detail の一部は artifact-specific boundary として残る。これらを埋めるために二次報道や X 投稿だけで仕様を確定せず、次回更新時には各 primary artifact を再検証する必要がある。[8, 9, 11, 7]

Technical Notes / 検証上の境界

1. **Chronology is not ancestry.** 公開日・release date は時系列 authority として使うが、近接した公開日や類似 architecture だけから直接的な技術継承を推定しない。
2. **Open weight is not automatically open source.** code license、weight/model license、redistribution、commercial use、training recipe/reproducibility を分離する。
3. **Benchmarks remain source-local.** model version、evaluation harness、prompting、tool availability、context 条件が異なる結果を正規化せず、横断順位を作らない。
4. **Parameter and compute accounting remain local.** total/active parameter、token count、FLOP/cost accounting は定義が異なり得るため、source が直接支える仕様以上の効率比較をしない。
5. **Current endpoint is as-of bounded.** 2026 年の official repository/release material は 2026-08-24 観測時点で固定し、それ以降の更新を遡及的に本巻へ混ぜない。

References / Source Notes

- [1]Tsinghua KEG and Zhipu AI. *GLM-130B: An Open Bilingual Pre-trained Model*. Primary paper; SP001 accepted Evidence source. Oct. 5, 2022. URL: <https://arxiv.org/abs/2210.02414> (visited on 08/24/2026).
- [2]Baichuan Intelligence. *Baichuan 2: Open Large-scale Language Models*. Primary paper; SP001 accepted Evidence source. Sept. 18, 2023. URL: <https://arxiv.org/abs/2309.10305> (visited on 08/24/2026).
- [3]DeepSeek AI. *DeepSeek LLM: Scaling Open-Source Language Models with Longtermism*. Primary paper; SP001 accepted Evidence source. Jan. 5, 2024. URL: <https://arxiv.org/abs/2401.02954> (visited on 08/24/2026).
- [4]Alibaba Cloud / Qwen. *Qwen2 Technical Report*. Primary paper; SP001 accepted Evidence source. July 15, 2024. URL: <https://arxiv.org/abs/2407.10671> (visited on 08/24/2026).
- [5]DeepSeek AI. *DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model*. Primary paper; SP001 accepted Evidence source. May 7, 2024. URL: <https://arxiv.org/abs/2405.04434> (visited on 08/24/2026).
- [6]DeepSeek AI. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. Primary paper; SP001 accepted Evidence source. Jan. 22, 2025. URL: <https://arxiv.org/abs/2501.12948> (visited on 08/24/2026).
- [7]DeepSeek AI. *DeepSeek V4 official release/transparency material*. Primary official source; performance, license and current-detail claims remain source-local. Apr. 24, 2026. URL: <https://www.deepseek.com/en/transparency/> (visited on 08/24/2026).
- [8]Qwen. *Qwen3.8 official repository*. Primary repository; exact checkpoint license, release identity and performance conditions remain artifact-specific. Aug. 12, 2026. URL: <https://github.com/QwenLM/Qwen3.8> (visited on 08/24/2026).
- [9]Z.ai. *GLM-5 official repository and technical report*. Primary repository; license and benchmark boundaries remain artifact-specific. Feb. 18, 2026. URL: <https://github.com/zai-org/GLM-5> (visited on 08/24/2026).
- [10]Moonshot AI. *Kimi k1.5: Scaling Reinforcement Learning with LLMs*. Primary paper; SP001 accepted Evidence source. Jan. 21, 2025. URL: <https://arxiv.org/abs/2501.12599> (visited on 08/24/2026).
- [11]Moonshot AI. *Kimi K3 official repository*. Primary repository; checkpoint license and benchmark conditions remain artifact-specific. July 16, 2026. URL: <https://github.com/MoonshotAI/Kimi-K3> (visited on 08/24/2026).