
Japanese Generative AI Technical Survey Special

SP001

中国発 Open-Weight AI の技術史 / Thematic survey as of 2026-08-24

複数の系譜が、Frontier を形づくる

中国発の生成 AI を一つの系譜に畳み込まず、DeepSeek、Qwen、GLM、Kimi が architecture、post-training、long context、agentic execution、distribution と serving をどのように別々の経路から競争力へ変えたかを追う。

[Plural Foundations](#) / [DeepSeek](#) / [Qwen](#) / [GLM](#) / [Kimi](#) / [Final Synthesis](#)

Editorial cutoff

Open history, evidence observed through 2026-08-24 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Thematic Longform Technical Survey。

本巻の問いと読み方

本巻の問いは、中国発の Generative AI が、どのような技術的・ecosystem 上の発展を経て、2026 年時点の Frontier AI 競争における恒常的な構成要素となったのかである。対象は DeepSeek、Qwen、GLM、Kimi を中心とし、GLM-130B、Baichuan 2、DeepSeek LLM、Qwen2 を初期の anchor として置く。観測時点は 2026 年 8 月 24 日であり、それ以後の更新は本巻の authority に含めない。

重要なのは、ここで「中国勢」を一つの model family のように扱わないことである。2022 年の GLM-130B、2023 年の Baichuan 2、2024 年初頭の DeepSeek LLM、同年の Qwen2 は、異なる組織・設計・公開経路から現れた。後年、long context、sparsity、reasoning/post-training、agentic execution、hub/runtime distribution といった共通の設計圧力が見えるようになって、それは単一の技術系譜を意味しない。[1, 2, 3, 4]

また、本巻では open source と open weight を同義語として扱わない。repository の code license、checkpoint の weight/model license、再配布、商用利用、training recipe の再現可能性は別々の条件である。一次資料で確認できない条件は family 全体へ一般化しない。benchmark も同様で、異なる model version、evaluation harness、prompting、tool availability、context 条件を一つの横断 league table へ正規化しない。

確認範囲と主張境界

技術史上の chronology は一次資料の公開日・release identity で固定する。一方、公開日の近さ、似た architecture、同じ用語の使用だけから、組織間の直接的影響、institutional ancestry、技術継承を推定しない。2026 年の current endpoint については、各 source が直接裏づける claim だけを採用し、license や benchmark 条件に未解決事項が残る場合はそのまま境界として残す。

この巻で比較するもの

本巻が横断的に比較するのは、model の絶対順位ではなく、どの設計問題が family 内で第一級の競争軸になったかである。具体的には、foundation model の scale、active computation と attention、reasoning の post-training、long-context の使われ方、agentic workload、model hub と local/API serving、そして artifact の license/distribution 境界を追う。これにより、異なる family を一つの score へ潰さずに、2026 年の frontier で何が共通化し、何が違ったまま残ったかを説明する。

目次

1	中国 open-model 史は、最初から複数の系譜だった	4
1.1	Source-specific chronology: 2022–2024	4
1.2	GLM-130B と Baichuan 2 が残す前史	4
1.3	DeepSeek LLM と Qwen2: 同じ 2024 年でも異なる起点	4
1.4	「open」を一語で済ませない	4
1.5	Technical reading: 歴史を「勝者の前史」にしない	5
2	DeepSeek: foundation から効率化、reasoning、agentic frontier へ	5
2.1	Foundation baseline: 何がまだ主役ではなかったか	5
2.2	V2: total parameter ではなく active computation を見る	5
2.3	V2 から R1 へ: architecture と post-training を分けて読む	6
2.4	R1-Zero: reasoning を RL の問題として露出させる	6
2.5	R1: cold-start と multi-stage training	6
2.6	V4: model から system endpoint へ	6

2.7	DeepSeek の family transition をどう要約するか	6
3	Qwen: 単一 checkpoint より model breadth と distribution	7
3.1	Qwen2: breadth は単なる model 数ではない	7
3.2	Distribution: Hugging Face / ModelScope を技術史へ入れる	7
3.3	Qwen3.8: agent/coding/research line へ	7
3.4	License: repository と checkpoint を分ける	8
3.5	Qwen の frontier は「breadth x distribution」で読む	8
4	GLM: bilingual foundation から agentic systems engineering へ	8
4.1	GLM-130B: chronology の anchor	8
4.2	GLM-5: scale と active computation	8
4.3	Sparse attention: provenance を保ったまま読む	9
4.4	Asynchronous RL: post-training を infrastructure として見る	9
4.5	Local serving: frontier の内側へ	9
4.6	GLM の trajectory: model から systems endpoint へ	9
5	Kimi: long context と multimodal reasoning から open-weight agent へ	9
5.1	k1.5: long context を reasoning workload へ接続する	10
5.2	K3: 2.8T と sparse MoE をどう読むか	10
5.3	1M context: 長さから system property へ	10
5.4	Multimodality と agentic execution の結合	10
5.5	K3 の license と benchmark 境界	10
5.6	Kimi の frontier: long context を単独機能にしない	10
6	最終総括: 2026 年の frontier で収束したもの、残った差	11
6.1	収束したのは model family ではなく system-level の設計圧力	11
6.2	Cross-family structured comparison	11
6.3	DeepSeek: efficiency と reasoning を別々の転換として持つ	12
6.4	Qwen: breadth と distribution を競争力へする	12
6.5	GLM: RL と serving を systems engineering へ入れる	12
6.6	Kimi: long context の意味を multimodal agent へ広げる	12
6.7	「open」は競争力だが、一つの license category ではない	12
6.8	なぜ恒常的な frontier 構成要素になったのか	13
6.9	残る差と未解決境界	13

1 中国 open-model 史は、最初から複数の系譜だった

2026 年の frontier だけを見ると、DeepSeek、Qwen、GLM、Kimi が同じ競争空間で long context や agentic workload を掲げている。しかし、その到達点から過

去を逆算して「一つの中国 LLM 系譜」を作ると、初期の多様性を失う。最初に置くべきなのは、複数の独立した anchor である。

1.1 Source-specific chronology: 2022–2024

時点	Artifact	本巻での役割
2022-10	GLM-130B	large bilingual pre-trained model という早期 anchor。後年の GLM を読む chronology を与えるが、後続 mechanism への直接継承までは主張しない。
2023-09	Baichuan 2	主要 4family へ議論を絞る前から、中国発 open-model ecosystem が plural だったことを示す context evidence。
2024-01	DeepSeek LLM	7B/67B、約 2T-token の中英 pretraining、scaling-law、SFT/DPO を持つ foundation baseline。後の efficiency/reasoning 転換を読む起点。
2024-07	Qwen2	dense/MoE の model breadth と、Hugging Face/ModelScope、quantization、fine-tuning、deployment を一つの family strategy へ含めた anchor。

[1, 2, 3, 4]

この表は「祖先表」ではない。一次資料から確定できる公開時点と artifact の役割を並べたものであり、隣接する release 間の直接的な影響を表現していない。むしろ、後の frontier competition が複数の独立した問題設定から始まったことを読者に固定するための chronology である。

1.2 GLM-130B と Baichuan 2 が残す前史

GLM-130B は large bilingual pre-trained model という明確な研究対象を提示した。これは 2026 年の GLM-5 を「突然現れた agentic model」として読むことを避けるための歴史的 anchor になる。一方で、GLM-130B の存在だけから GLM-5 の sparse attention や RL infrastructure が直接そこから継承されたと断定することはできない。[1]

Baichuan 2 は 2023 年の open large-scale language model family として、主要 4family が frontier を占める以前から公開 model ecosystem に複数の branch が存在したことを示す。本巻で Baichuan 2 を扱う目的は 2026 年の性能を代理させることではなく、技術史を後年の勝者だけで再構成しないためである。[2]

1.3 DeepSeek LLM と Qwen2: 同じ 2024 年でも異なる起点

DeepSeek LLM は 7B/67B、約 2T-token の中国語・英語 pretraining、scaling-law、SFT/DPO を含む foundation baseline を提示した。重要なのは、この時点か

ら DeepSeek を reasoning 専用 family とみなすのではなく、後続で何が独立した設計軸へ切り出されたかを追うことである。[3]

Qwen2 は同じ 2024 年でも異なる面を強く見せる。dense と MoE を含む広い model range、multilingual/coding/math/reasoning、Hugging Face と ModelScope への distribution、quantization、fine-tuning、deployment 資源が同じ technical report の射程に入る。ここでは能力だけでなく、model を取得し、調整し、動かすまでの developer path が family strategy に含まれている。[4]

1.4 「open」を一語で済ませない

この時期の各 artifact が公開されていたことと、それらが同じ license 条件だったことは別問題である。weights が取得できること、repository code が open-source license であること、training recipe が再現可能であること、商用再配布が許されることは独立した条件である。本巻で「open-weight ecosystem」という語を使うのは、model artifact の利用可能性と distribution が競争構造に組み込まれたことを指すためであり、OSI 的な意味での open source を一括認定するためではない。

Baichuan 2 では license/commercial-use boundary が source-local に検証され、DeepSeek LLM でも open-source/open-weight terminology と license boundary が

検証対象になっている。ここから導けるのは「公開には条件差がある」ということまでであり、異なる artifact の条件が同一だという結論ではない。[2, 3]

1.5 Technical reading: 歴史を「勝者の前史」にしない

GLM-130B、Baichuan 2、DeepSeek LLM、Qwen2 を並べる意味は、2026 年の有力 family の祖先を一系列に

並べることではない。むしろ、異なる組織が bilingual foundation、plural open-model publication、foundation scale、model breadth/distribution など別の問題設定を持っていたことを保つためである。後に同じ技術圧力へ接近しても、起点と developer-facing strategy の違いは残る。

Source-backed verification / 前史の anchor

Artifact	一次資料で確認する technical point	読解上の境界
GLM-130B	2022 年の large bilingual pre-trained model として chronology を固定する。	後年の sparse attention や RL infrastructure への直接継承までは推定しない。
Baichuan 2	2023 年時点ですでに複数の open large-model branch が存在したことを示す。	2026 年の主要 family の性能や license を代理させない。
DeepSeek LLM	7B/67B、約 2T-token 中英 pretraining、scaling-law、SFT/DPO を foundation baseline として置く。	後の V2/R1 の設計をこの段階へ遡及させない。
Qwen2	dense/MoE の model breadth と hub distribution、quantization、fine-tuning、deployment を同じ family surface として確認する。	family label を単一 architecture や単一 license へ縮約しない。

[1, 2, 3, 4]

2 DeepSeek: foundation から効率化、reasoning、agentic frontier へ

DeepSeek の trajectory は、同じ family の中で競争軸がどのように移ったかを比較的明瞭に追える。DeepSeek LLM の foundation baseline、V2 の efficiency architecture、R1 の reasoning/post-training、V4 の long-context/agentic endpoint は、単純な世代更新ではなく、model 競争が system design へ広がる過程として読める。[3, 5, 6, 7]

2.1 Foundation baseline: 何がまだ主役ではなかったか

DeepSeek LLM は 7B/67B、約 2T-token の中国語・英語 pretraining、scaling-law、SFT/DPO を含む foundation family として位置づく。この段階の記述を残しておく、後の V2 や R1 を「最初から決まっていた一本道」と誤読しにくい。V2 で efficiency が、R1 で reasoning post-training が前景化したこと自体が family 内の転換だからである。[3]

2.2 V2: total parameter ではなく active computation を見る

DeepSeek-V2 は MoE、Multi-head Latent Attention (MLA)、DeepSeekMoE を前面に出した。一次資料は

236B total parameters に対して 21B activated parameters、128K context を報告する。ここで重要なのは、総 parameter を増やすことと、token ごとに実際に active になる計算を分離して考える設計が中心に入ったことである。[5]

236B と 21B は「大きさの二つの言い方」ではない。total parameter は model が保持する capacity の一側面を示し、activated parameter は各 token で選択的に使われる計算の一側面を示す。さらに context length は別軸である。これらを同じ効率指標へ足し合わせることはできない。本巻では source が直接支える仕様を維持し、他 family の異なる accounting と横断ランキングにはしない。

MLA と DeepSeekMoE も、単に mechanism 名を列挙するために扱うのではない。確認済みの一次資料では MLA/DeepSeekMoE の mechanism description と training/inference efficiency framing が個別に検証されている。したがって V2 の転換は、parameter count だけでは説明できない attention/serving と active-compute の問題を architecture の中心へ置いたことに

ある。[5]

2.3 V2 から R1 へ: architecture と post-training を分けて読む

V2 の efficiency architecture と R1 の reasoning improvement を一つの「性能向上」の言葉へまとめると、何が変わったのかが見えなくなる。V2 で前景化したのは model 内部の計算配分と attention/serving 効率であり、R1 で前景化したのは reasoning behavior を獲得する training sequence である。family 内の連続性を保ちつつ、設計対象が違うことを区別する必要がある。

2.4 R1-Zero: reasoning を RL の問題として露出させる

DeepSeek-R1 は reasoning 能力を、foundation scale の副産物ではなく post-training 設計の独立した競争軸として可視化した。確認済みの一次資料では、R1-Zero が preliminary SFT なしの large-scale RL として記述される点が検証されている。重要なのは benchmark score そのものより、reasoning behavior をどの training process から引き出すかが first-class な研究問題になったことである。[6]

2.5 R1: cold-start と multi-stage training

R1 本体では cold-start data と multi-stage training sequence が検証されている。これは「RL だけで reasoning が完成した」という単純化を避けるために重要である。R1-Zero の位置づけと、cold-start を含む R1 の工程を分けて読むことで、reasoning post-training が複数 stage から成る engineering problem として提示されていることが分かる。[6]

ここでも license 境界は技術史の一部である。R1 primary weights と distilled derivatives では upstream model 由来の条件が関係し得るため、「DeepSeek-R1」という family label だけで全 checkpoint の license を同一視しない。確認済みの一次資料でも primary versus distilled model license boundaries が独立の確認事項に

なっている。

2.6 V4: model から system endpoint へ

2026 年 4 月の DeepSeek V4 official release/transparency material は、1M context、sparse/token-compression mechanism、thinking/non-thinking operation、agentic coding、API/deployment を同じ endpoint の説明に集約する。ここでは long context、efficiency、reasoning mode、agentic execution が一つの system surface へ束ねられる。[7]

1M context は長さの記録だけではない。確認済みの一次資料では sparse/token-compression mechanism wording、thinking/non-thinking、agentic-coding、API/deployment details がそれぞれ検証されているため、本巻では V4 を「長文脈 model」ではなく、long context を reasoning mode と agentic workload へ接続した system endpoint として読む。[7]

一方、exact checkpoint license、cross-family benchmark comparability、current release detail の一部は artifact-specific boundary として残る。V4 の performance claim を他 family の異なる harness へ移し替えて横断順位にすることはしない。

2.7 DeepSeek の family transition をどう要約するか

DeepSeek の変化は、foundation scale から V2 の active-compute/attention efficiency へ、さらに R1 の RL-centered post-training へ、そして V4 の long-context/agentic deployment へと、競争対象が model 内部から system 全体へ広がった過程として整理できる。ただし、これは全 mechanism が一本の直線で継承されたという主張ではない。chronology と family continuity を保持しつつ、各 stage で第一級になった engineering problem を分けて読むのが本巻の立場である。

Source-backed Technical Notes / DeepSeek

Artifact	Technical point	Boundary / limitation
DeepSeek LLM	7B/67B、約 2T-token の中国語・英語 pretraining、scaling-law、SFT/DPO を foundation baseline として確認する。	後の efficiency architecture や RL reasoning を最初から内包した family とは扱わない。
DeepSeek-V2	236B total / 21B activated、128K context、MLA、DeepSeekMoE。capacity と active computation、attention/serving cost を別軸として読む。	total/active parameter を他 family の異なる accounting へそのまま正規化しない。
DeepSeek-R1	R1-Zero の preliminary SFT なし large-scale RL と、最終 R1 の cold-start + multi-stage sequence を分けて確認する。	primary weights と distilled derivatives の license authority を混同しない。
DeepSeek V4	1M context、sparse/token-compression、thinking/non-thinking、agentic coding、API/deployment を system endpoint として確認する。	checkpoint-specific license、benchmark comparability、current detail は artifact-local のまま残す。

[3, 5, 6, 7]

3 Qwen: 単一 checkpoint より model breadth と distribution

Qwen を特徴づけるとき、一つの flagship checkpoint だけに注目すると重要な部分を落とす。Qwen2 の technical report は dense/MoE を含む幅広い model range と、Hugging Face/ModelScope、quantization、fine-tuning、deployment を同じ開発者経路に置く。2026 年の Qwen3.8 official repository では agent/coding/research line と distribution がさらに前面に出る。
[4, 8]

3.1 Qwen2: breadth は単なる model 数ではない

Qwen2 は multilingual、coding、math、reasoning を横断する family として提示され、dense と MoE の複数構成を含む。ここでの breadth は単なる model 一覧の多さではなく、developer が用途・計算資源・deployment 条件に応じて選択できる surface を作ることに結びついている。確認済みの一次資料では dense/MoE model range 自体が独立に検証されている。
[4]

model family が広いということは、単一の parameter count で Qwen 全体を代表させにくいことも意味する。dense と MoE、異なる size、異なる用途を同じ family label の下で扱うとき、比較は checkpoint 単位で行い、family label を一つの architecture 仕様へ縮約しない。

3.2 Distribution: Hugging Face / ModelScope を技術史へ入れる

Qwen2 では Hugging Face と ModelScope への distribution が検証され、quantization、fine-tuning、deployment resources も独立した確認事項になっている。これは distribution が公開後の事務作業ではなく、developer が model を実際に利用するまでの技術 surface として first-party material の中に入っていることを示す。
[4]

quantization や fine-tuning resource の存在は、それだけで特定 hardware 上の performance advantage を証明するものではない。しかし、取得した weight を用途や resource constraint へ合わせる経路が整備されること自体は、model adoption の摩擦を下げる。本巻で distribution を競争力の一部として扱うのはこのためである。

3.3 Qwen3.8: agent/coding/research line へ

2026 年 8 月の Qwen3.8 official repository は open-weight agent/coding/research line と Hugging Face/ModelScope distribution を主要な位置づけとして示す。確認済みの一次資料で確定できるのは、この agent/coding/research positioning と hub distribution である。
[8]

この変化は「Qwen2 より能力項目が増えた」とだけ読むより、distribution-first な family strategy が agen-

tic workload への接続へ伸びたと読むほうが整合的である。model を取得し、tool-using/coding/research workflow へ組み込むまでの developer path が frontier competition の一部になっている。

3.4 License: repository と checkpoint を分ける

Qwen3.8 では release dates/checkpoint identities、repository versus weight-license distinction、source-local performance conditions に未解決項目が残る。したがって repository の license を見て、すべての checkpoint の weight/model license を同一だと推定しない。Qwen2 で artifact-specific license terms が検証されて

いても、その条件を Qwen3.8 へ自動継承させない。[\[4, 8\]](#)

3.5 Qwen の frontier は「breadth x distribution」で読む

Frontier という語を純粋な benchmark 順位だけに限定すると、Qwen のような breadth/distribution 型の戦略を過小評価する。model hub、quantization、fine-tuning、deployment との接続は、利用者が model を software stack へ組み込むまでの摩擦を下げる。本巻では Qwen を、単一 checkpoint の性能だけでなく、model family と developer ecosystem を一体で広げる trajectory として位置づける。

Source-backed Technical Notes / Qwen

Artifact	Technical point	Boundary / limitation
Qwen2	dense/MoE を含む model range、multilingual/coding/math/reasoning、Hugging Face/ModelScope distribution を確認する。	family label を一つの parameter count や architecture へ縮約しない。
Qwen2 engineering surface	quantization、fine-tuning、deployment resource が first-party technical surface に含まれ、weight 取得後の developer path を形成する。	resource の存在だけから特定 hardware 上の cost/performance advantage を推定しない。
Qwen3.8	2026 年の official repository で agent/coding/research positioning と Hugging Face/ModelScope distribution を確認する。	Qwen2 からの chronology を特定 mechanism の直接継承とはみなさない。
License / performance	repository と checkpoint-specific weight/model license を分離し、performance は source-local 条件に止める。	repository metadata から全 checkpoint の再配布・商用利用条件を一括推定しない。

[\[4, 8\]](#)

4 GLM: bilingual foundation から agentic systems engineering へ

GLM の長い時間軸では、2022 年の GLM-130B を bilingual foundation の anchor として置き、2026 年の GLM-5 を architecture、RL infrastructure、serving まで含む system engineering の endpoint として読む。両者の間を、単純な「同じ技術の大型化」とは扱わない。[\[1, 9\]](#)

4.1 GLM-130B: chronology の anchor

GLM-130B は large bilingual pre-trained model として 2022 年に公開された。確認済みの一次資料では release chronology、bilingual/pretraining scope、open-model/access claim が検証されている。本巻にとっての役割は、後年の agentic GLM を「突然現れた 2026 年 model」として扱わないための歴史的 anchor である。[\[1\]](#)

ただし、GLM-130B から後続の sparse mechanism や RL infrastructure への直接的な技術継承までは一次資料から確定しない。chronology を保つことと、mechanism ancestry を主張することは別である。

4.2 GLM-5: scale と active computation

GLM-5 official repository/technical report は 744B total / 40B active、28.5T tokens を提示する。ここでも total parameter と active parameter を区別する必要がある。744B という model capacity の一側面と、40B active という token-level computation の一側面を分けることで、単純な「最大 parameter 競争」ではない設計意図が見える。[\[9\]](#)

28.5T-token claim も source-local specification として扱う。training token count は dataset composition や

counting convention を跨いで同じ意味になるとは限らないため、他 family の token 数とそのまま training efficiency ランキングへ変換しない。

4.3 Sparse attention: provenance を保ったまま読む

確認済みの一次資料では GLM-5 の sparse-attention provenance wording が検証されている。重要なのは、source が他技術を参照する場合、その参照範囲を越えて institutional ancestry や包括的な技術継承を推定しないことである。similar mechanism の存在と、organizational lineage は別の主張である。[9]

4.4 Asynchronous RL: post-training を infrastructure として見る

GLM-5 では asynchronous RL infrastructure claim が独立に検証されている。ここで post-training は単なる recipe ではなく、長時間の agentic behavior を改善するための実行 infrastructure として system design へ組み込まれている。DeepSeek-R1 が reasoning training sequence を前面に出したのに対し、GLM-5 では RL infrastructure と serving まで同じ technical endpoint の構成要素として現れる。[9, 6]

この比較は「どちらが優れているか」ではなく、同じ post-training 領域でも family がどこを reader-facing technical surface として強調しているかを見るためのものである。

4.5 Local serving: frontier の内側へ

GLM-5 で複数の local-serving recipe が technical material に含まれることは、frontier capability を API 上の model score だけで理解できなくなっていることを示す。実際にどの runtime で、どの hardware 条件で、どの precision や parallelism を使うかは model を利用可能にする engineering layer である。確認済みの一次資料は serving recipe の存在を支えるが、異なる hardware での cost advantage までは確定しない。[9]

GLM-5 の repository/model license terms は、一次資料だけでは確定できない利用条件として残る。repository が公開されていることを、その checkpoint の全利用条件の確定と読み替えない。

4.6 GLM の trajectory: model から systems endpoint へ

GLM-130B と GLM-5 の間に、本巻が確実に置けるのは chronology 上の family anchor と 2026 endpoint である。その上で GLM-5 を見ると、sparse architecture、RL infrastructure、long-horizon agentic engineering、local serving が同じ system problem として束ねられている。GLM の 2026 frontier を特徴づけるのは、単一 mechanism より、この systems engineering の広がりである。

Source-backed Technical Notes / GLM

Artifact	Technical point	Boundary / limitation
GLM-130B	2022 年の large bilingual pre-trained model を family chronology の anchor として確認する。	GLM-5 の sparse mechanism や RL infrastructure への直接的 mechanism ancestry は主張しない。
GLM-5 scale	744B total / 40B active、28.5T tokens を source-local specification として扱う。	token count や parameter accounting を他 family との単純 efficiency ranking へ変換しない。
GLM-5 systems	sparse-attention provenance wording、asynchronous RL infrastructure、long-horizon agentic engineering を同じ 2026 endpoint で確認する。	類似 mechanism の存在から organizational lineage を推定しない。
Local serving	複数の local-serving recipe が technical material へ含まれることを deployment surface として扱う。	未検証 hardware 上の cost superiority や repository/model license 条件を補完しない。

[1, 9]

5 Kimi: long context と multimodal reasoning から open-weight agent へ

Kimi family では long context と reasoning を早い段階から主要テーマとして読める。Kimi k1.5 は long-

context multimodal reasoning と reinforcement learning を結びつけ、2026 年の Kimi K3 は 1M context、sparse

MoE、native multimodality、long-horizon coding/agent focus を一つの open-weight release line へまとめる。
[10, 11]

5.1 k1.5: long context を reasoning workload へ接続する

Kimi k1.5 は long-context multimodal reasoning と RL を扱う。確認済みの一次資料では long-context/multimodal scope と RL method claim がそれぞれ検証されている。ここで重要なのは、long context を単なる最大 token 数としてではなく、reasoning workload と結びつけた設計対象として扱っていることである。[10]

k1.5 から K2/K3 への chronological relation は検証されている一方、後続 model の個別 mechanism をすべて k1.5 由来とする直接的な技術継承は確定しない。本巻では k1.5 を family 内の bridge として使い、後続仕様を遡及的に投影しない。

5.2 K3: 2.8T と sparse MoE をどう読むか

2026 年 7 月の Kimi K3 official repository は 2.8T open-weight native multimodal model、sparse MoE を提示する。確認済みの一次資料では model size/sparsity details が個別に検証されている。ここでも 2.8T という total scale と、sparse routing が意味する active computation は同じ尺度ではない。[11]

他 family の total/active parameter accounting と K3 を一つの efficiency ranking へ変換しないのは、この定義差を保持するためである。K3 の大きさ自体ではなく、sparsity を native multimodality や agentic workload と一緒に system へ組み込む点を読む。

5.3 1M context: 長さから system property へ

K3 では 1M context が検証済みの仕様として現れる。同時に efficient-attention/residual mechanism names、long-horizon coding/agent focus も確認済みの一次資料に含まれる。したがって 1M context を単

独の「長さ記録」として切り出すより、multimodal input と長時間の agentic execution を支える system property として位置づけるほうが、source が示す release 全体と整合する。[11]

この点は DeepSeek V4 の 1M context とも表面的には似るが、同じ context evaluation や同じ mechanism を意味するわけではない。本巻は「1M」という数値の一致から技術系譜を推定しない。

5.4 Multimodality と agentic execution の結合

Kimi の trajectory では、k1.5 の long-context multimodal reasoning/RL から、K3 の native multimodal・long-horizon coding/agent focus へ関心が伸びている。ここで multimodality は入力形式の追加だけではなく、長い context を保持しながら reasoning し、agentic workload を継続する system design と結びついている。[10, 11]

5.5 K3 の license と benchmark 境界

K3 の artifact-specific license terms、source-local benchmark conditions は未解決境界として残る。model size、1M context、mechanism name、release chronology は検証できても、その事実から checkpoint 固有 license や cross-family performance comparability を導くことはできない。open-weight という配布形態と、利用条件の全体を同一視しない。

5.6 Kimi の frontier: long context を単独機能にしない

Kimi の 2026 endpoint が示すのは、long context が reasoning、multimodality、coding、agentic workload の共通基盤へ変わっていることである。context window の上限だけを比較しても、何のために長い context が必要なのかは分からない。本巻では k1.5 と K3 を、long-context 競争の意味が「長さ」から「長時間 system execution」へ広がる bridge として読む。

Source-backed Technical Notes / Kimi

Artifact	Technical point	Boundary / limitation
Kimi k1.5	long-context multimodal reasoning と RL method を family 内の bridge として確認する。	後続 K3 の個別 mechanism を k1.5 由来と遡及的に決めない。
Kimi K3 scale	2.8T open-weight native multimodal model、sparse MoE を同じ release line で確認する。	total scale と sparse routing が示す active computation を同じ尺度にしない。
Kimi K3 system	1M context、efficient-attention/residual mechanism、long-horizon coding/agent focus を system property として読む。	DeepSeek V4 との「1M」一致から同一 mechanism や技術系譜を推定しない。
License / benchmark	技術仕様を記述する一次資料と、checkpoint 固有の利用条件・性能条件を別 authority として扱う。	open-weight という配布形態から商用利用や cross-family benchmark comparability を自動推定しない。

[10, 11]

6 最終総括: 2026 年の frontier で収束したもの、残った差

この最終節では、前 5 節で一次資料に結び付けて確認した内容だけを再構成する。新しい cross-family benchmark 順位や未検証の技術系譜を追加するのではなく、何が共通の設計圧力になり、何が family 固有のまま残ったかを reader-facing に答える。

6.1 収束したのは model family ではなく system-level の設計圧力

2026 年の endpoint を見ると、DeepSeek V4 は 1M context と sparse/token-compression、thinking/non-thinking、agent focus coding/API deployment をまとめる。Qwen3.8 は open-weight agent/coding/research と hub distribution を接続する。GLM-5 は 744B total / 40B active、sparse attention、asynchronous RL、local serving を一つの systems endpoint へ束ね、Kimi K3 は 2.8T open-weight native multimodal、sparse MoE、1M context、long-horizon coding/agent focus をまとめる。[7, 8, 9, 11]

共通しているのは、model 単体の score だけでなく、**計算効率、post-training、context、agent focus execution、distribution/runtime** を同時に解く必要が出てきたことである。Frontier の評価対象が checkpoint 内部の静的能力から、training と runtime を含む system へ広がった、と読むことができる。

6.2 Cross-family structured comparison

設計と post-training の比較

Family	強い転換点	Architecture / compute	Post-training / behavior
DeepSeek	LLM → V2 → R1 → V4	V2 の MoE/MLA/DeepSeekMoE、236B total / 21B active。V4 では sparse/token-compression へ展開。	R1-Zero の large-scale RL、R1 の cold-start + multi-stage。V4 では thinking/non-thinking と agent focus coding へ接続。
Qwen	Qwen2 → Qwen3.8	dense/MoE を含む model breadth を、単一 checkpoint ではなく family 設計として維持。	coding/math/reasoning を広い family surface として扱い、2026 には agent/coding/research line を前面化。
GLM	GLM-130B → GLM-5	744B total / 40B active、sparse attention。	asynchronous RL infrastructure と long-horizon agent focus engineering を systems endpoint へ統合。
Kimi	k1.5 → K3	K3 は 2.8T、sparse MoE、efficient-attention/residual、1M context。	k1.5 の multimodal reasoning/RL から、K3 の long-horizon coding/agent focus へ展開。

Distribution / serving と公開境界

Family	Distribution / serving	License / comparison boundary
DeepSeek	V4 では agentic coding を API/deployment へ接続し、context・推論 mode・tool-oriented workload を同じ運用 surface へ束ねる。	checkpoint license と benchmark comparability は artifact-local。R1 primary weights と distilled derivatives も分ける。
Qwen	Hugging Face/ModelScope、quantization、fine-tuning、deployment を developer path として継続し、Qwen3.8 では agent/coding/research 用途へ接続。	repository license と各 checkpoint の weight/model license を同一視しない。
GLM	GLM-5 は複数 local-serving recipe を technical material へ含め、post-training と deployment を同じ systems engineering へ入れる。	repository/model license は未解決境界。hardware 間の cost superiority は未検証。
Kimi	open-weight native multimodal release として、1M context を long-horizon coding/agentic workload へ接続する。	checkpoint 固有 license と source-local benchmark 条件を、open-weight という語だけで補完しない。

二つの表は順位表ではない。上段は各 family で第一級になった設計問題を、下段は model artifact を利用可能にする distribution/runtime と公開境界を分離している。parameter accounting、context evaluation、benchmark harness が異なるため、数値を一つの横断 score へ正規化しない。

6.3 DeepSeek: efficiency と reasoning を別々の転換として持つ

DeepSeek では V2 の active-compute/attention efficiency と、R1 の RL-centered reasoning が強い転換点として分離できる。V4 はそれらを 1M context、thinking mode、agentic coding/API へ接続する。つまり DeepSeek の trajectory は、model architecture と post-training の両方で独立した転換を経験し、最終的に system endpoint へ収束した形である。[5, 6, 7]

6.4 Qwen: breadth と distribution を競争力へする

Qwen では単一 flagship の architecture より、dense/MoE を含む model breadth と、Hugging Face/ModelScope、quantization、fine-tuning、deployment を組み合わせる developer-facing surface が一貫して重要である。Qwen3.8 の agent/coding/research line は、その distribution surface が agentic workload へ伸びた endpoint として読める。[4, 8]

6.5 GLM: RL と serving を systems engineering へ入れる

GLM-5 は sparse architecture だけでなく、asynchronous RL infrastructure、long-horizon agentic engineering、local-serving recipe までを同じ technical material へ入れる。これは post-training と deployment を model の外側に追い出さず、frontier system を成立させる engineering stack として扱う trajectory である。[9]

6.6 Kimi: long context の意味を multimodal agent へ広げる

Kimi では k1.5 の long-context multimodal reasoning/RL が bridge となり、K3 では 1M context、sparse MoE、native multimodality、long-horizon coding/agentic focus が同じ release line へ集約される。長文脈は最大 token 数ではなく、長時間の multimodal/agentic execution を支える system property になっている。[10, 11]

6.7 「open」は競争力だが、一つの license category ではない

2026 年の frontier を open-weight ecosystem として論じるとき、公開されていること自体は重要な競争条件である。developer が weights や repository へアクセスし、model hub や local serving へ接続できることは、研究結果を利用可能な artifact へ変える。しかし、code license、weight/model license、redistribution、commercial use、training recipe/reproducibility は別 authority である。

この区別は Qwen3.8、GLM-5、Kimi K3、DeepSeek V4 のような current endpoint で特に重要になる。確認済みの一次資料で確認できた release、distribution、technical claim は採用できるが、exact checkpoint license や一部 current detail が未解決なら、その不確実性を family 全体へ上書きしない。[7, 8, 9, 11]

6.8 なぜ恒常的な frontier 構成要素になったのか

本巻で確認した一次資料から導ける結論は、単一 benchmark で恒常的に首位になったから、ではない。複数 family が architecture の効率、reasoning の post-training、long context と multimodality、agentic workload、model hub、local/API serving という異なる層で独立に改善を積み重ね、それらを利用可能な artifact と developer path として継続的に外へ出す競争構造を作ったことが重要である。

その結果、ある release の benchmark 順位が入れ替わっても、ecosystem 全体が frontier から消える構造ではなくなった。競争の場所が一つではなく、model architecture、post-training、runtime、distribution、license という複数の technical layer へ分散したからである。DeepSeek、Qwen、GLM、Kimi は同じ答えを持つのではなく、同じ system-level 制約へ異なる強みで応答している。

6.9 残る差と未解決境界

収束は同一化ではない。似た sparsity、long context、agentic という語が現れても、organization や institutional ancestry が同じになるわけではない。また、2026 frontier の performance は evaluation condition、harness、version が一致しないため source-local reported position としてのみ扱う。

本巻は 2026 年 8 月 24 日までの確認済みの一次資料で閉じる。Qwen3.8、GLM-5、Kimi K3、DeepSeek V4 について、checkpoint-specific license や benchmark comparability、current release detail の一部は artifact-specific boundary として残る。これらを二次報道だけで埋めず、次回更新では primary artifact を再検証する必要がある。[8, 9, 11, 7]

Technical Notes / 検証上の境界

1. **Chronology is not ancestry.** 公開日・release date は時系列 authority として使うが、近接した公開日や類似 architecture だけから直接的な技術継承を推定しない。
2. **Family continuity is not mechanism identity.** 同じ family 内でも、世代間で第一級的设计問題が変わる。DeepSeek V2 の efficiency と R1 の reasoning、Kimi k1.5 と K3 の mechanism を一つの直線的継承へ縮約しない。
3. **Open weight is not automatically open source.** code license、weight/model license、redistribution、commercial use、training recipe/reproducibility を分離する。
4. **Repository license is not checkpoint license.** 特に Qwen3.8、GLM-5、Kimi K3 のような current repository では、repository metadata だけから全 checkpoint 条件を一般化しない。
5. **Benchmarks remain source-local.** model version、evaluation harness、prompting、tool availability、context 条件が異なる結果を正規化せず、横断順位を作らない。
6. **Parameter accounting remains source-local.** total parameter と activated parameter を分離し、236B/21B、744B/40B、2.8T などと同じ意味の「model size」として単純順位づけしない。
7. **Context length is not an isolated capability score.** 128K や 1M という window は、attention、memory/compression、reasoning、multimodality、agentic workload と組み合わせて読む。
8. **Serving claims stop at verified scope.** API/deployment、local-serving recipe、hub/quantization/fine-tuning resource の存在は採用するが、未検証 hardware 上の cost/performance advantage へ拡張しない。
9. **Current endpoint is as-of bounded.** 2026 年の official repository/release material は 2026-08-24 観測時点

で固定し、それ以降の更新を遡及的に本巻へ混ぜない。

10. **Final synthesis introduces no new comparison claim.** 最終総括は前 5 節で一次資料に基づいて確認した内容を再構成し、未検証の cross-family 性能主張や institutional lineage を新たに導入しない。

Reader verification matrix

論点	本巻が言えること	本巻が言わないこと
Chronology	primary artifact の公開/release 時点と family 内の順序	公開日の近さから直接影響を推定すること
Architecture	source が明示する MoE/MLA/sparse attention、total/active parameter、context specification	異なる accounting を一つの efficiency score へ正規化すること
Post-training	R1-Zero/R1 sequence、GLM-5 asynchronous RL、k1.5 RL などの source-local claim	RL recipe が family 間で同一または直接継承されたこと
Distribution	Hugging Face/ModelScope、API/deployment、local-serving recipe 等の verified surface	特定 hardware での未検証 cost superiority
License	artifact ごとの確認済み条件と未解決境界	repository から全 weight/checkpoint 条件を推定すること
Performance	source-local reported position	異なる harness/version を横断 league table へ変換すること

References / Source Notes

- [1]Tsinghua KEG and Zhipu AI. *GLM-130B: An Open Bilingual Pre-trained Model*. Primary paper used in this survey. Oct. 5, 2022. URL: <https://arxiv.org/abs/2210.02414> (visited on 08/24/2026).
- [2]Baichuan Intelligence. *Baichuan 2: Open Large-scale Language Models*. Primary paper used in this survey. Sept. 18, 2023. URL: <https://arxiv.org/abs/2309.10305> (visited on 08/24/2026).
- [3]DeepSeek AI. *DeepSeek LLM: Scaling Open-Source Language Models with Longtermism*. Primary paper used in this survey. Jan. 5, 2024. URL: <https://arxiv.org/abs/2401.02954> (visited on 08/24/2026).
- [4]Alibaba Cloud / Qwen. *Qwen2 Technical Report*. Primary paper used in this survey. July 15, 2024. URL: <https://arxiv.org/abs/2407.10671> (visited on 08/24/2026).
- [5]DeepSeek AI. *DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model*. Primary paper used in this survey. May 7, 2024. URL: <https://arxiv.org/abs/2405.04434> (visited on 08/24/2026).
- [6]DeepSeek AI. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. Primary paper used in this survey. Jan. 22, 2025. URL: <https://arxiv.org/abs/2501.12948> (visited on 08/24/2026).
- [7]DeepSeek AI. *DeepSeek V4 official release/transparency material*. Primary official source; performance, license and current-detail claims remain source-local. Apr. 24, 2026. URL: <https://www.deepseek.com/en/transparency/> (visited on 08/24/2026).
- [8]Qwen. *Qwen3.8 official repository*. Primary repository; exact checkpoint license, release identity and performance conditions remain artifact-specific. Aug. 12, 2026. URL: <https://github.com/QwenLM/Qwen3.8> (visited on 08/24/2026).
- [9]Z.ai. *GLM-5 official repository and technical report*. Primary repository; license and benchmark boundaries remain artifact-specific. Feb. 18, 2026. URL: <https://github.com/zai-org/GLM-5> (visited on 08/24/2026).
- [10]Moonshot AI. *Kimi k1.5: Scaling Reinforcement Learning with LLMs*. Primary paper used in this survey. Jan. 21, 2025. URL: <https://arxiv.org/abs/2501.12599> (visited on 08/24/2026).
- [11]Moonshot AI. *Kimi K3 official repository*. Primary repository; checkpoint license and benchmark conditions remain artifact-specific. July 16, 2026. URL: <https://github.com/MoonshotAI/Kimi-K3> (visited on 08/24/2026).