

---

# Japanese Generative AI Technical Survey Special

SP-vision-multimodal-2026

Vision & Multimodal AI — 視覚表現から接地・推論・行動へ / Thematic survey as of  
2026-09-30

## Vision & Multimodal AI

視覚表現から接地・推論・行動へ。分類から位置・構造・時間・空間の表現へ、言語への  
接地と複数モダリティの統合を経て、推論・予測・行動へ至る技術史。

[Representation](#) / [Detection](#) / [Dense Perception](#) / [Alignment](#) / [Grounding](#) / [Fusion](#) / [Reasoning](#) / [Video](#) / [Action](#) / [Prediction](#)

**Editorial cutoff**

Open history, evidence observed through 2026-09-30 UTC

**Repository**

eariver/japanese-generative-ai-survey

**Build**

LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Thematic Longform Special。

## 本巻の問いと読み方

本巻の問いは、画像や映像を単に分類する段階から、対象の位置・構造・時間関係を認識し、言語概念へ接地し、複数モダリティを統合して推論し、予測や行動へ利用できる内部表現を形成する段階へ、どのように発展してきたのか、である。各段階で問うのは、次の計算に十分な世界の表現は何か、何が失われ、何が新たに操作可能になったかである。

### 層の見方

本巻は単一のモデル年代記ではなく、相互に関わる技術的問題の層として読む。すなわち表現、認識、位置特定と構造、言語アライメント、接地、マルチモーダル融合、時間と空間の状態、推論、行動と予測である。これらは時代ではなく、相互作用する問題層である。

### 比較の規律

条件の異なる数値を並べて優劣をつける読みは採らない。数値は測定条件・版・日付・測り手と組で読む。ベンダーの主張は帰属づきで引用し、独立した再現を待つ。未解決の事項は推測で補わない。

### 読者への道案内

第1節から第11節が知覚・接地・融合・推論・時間の歴史、第12節から第14節が画面操作・身体動作・予測という到達点の領域、第15節が評価の方法と収束の問いを扱う。各節末の読解上の境界が、その節の射程と留保を示す。

## 目次

|                                |    |
|--------------------------------|----|
| 本巻の問いと読み方                      | 2  |
| 1 手作り特徴から学習する視覚表現へ             | 3  |
| 2 分類から位置特定へ、仮説と後処理の解体          | 4  |
| 3 ボックスを超える密な知覚と指示応答            | 6  |
| 4 ラベルにない幾何と空間状態                | 8  |
| 5 文字の読み取りから配置と構造の理解へ           | 9  |
| 6 画像をトークン列に直し目的ごと学ぶ基盤表現        | 11 |
| 7 決められた分類から言葉で指し示す理解へ          | 13 |
| 8 任意の言葉を位置と領域と座標へ結びつける連鎖       | 14 |
| 9 凍結した構成要素を保ち視覚と言語を接続する方式の世代交代 | 17 |
| 10 画像と映像と音声トークン列へ変換する方式と費用の設計  | 19 |
| 11 合成得点を属性ごとに分解し誤りの帰属を定める      | 22 |
| 12 短尺分類から長時間保持と選択的取得までの契約の分離   | 23 |
| 13 操作の成否と位置特定を分け、長時間の状態保持を問う   | 25 |
| 14 計画の分離から行動の符号化と生成へ           | 27 |
| 15 予測と生成を四つの極で切り分ける            | 28 |
| 16 何をどの条件で測ったかを分けて読む           | 30 |
| 17 結び                          | 33 |

# 1 手作り特徴から学習する視覚表現へ

## REPRESENTATION

ImageNet 規模の教師あり学習が再利用可能な階層を築き、残差 reformulation が超深度の最適化を切り開いた。[1, 2]

畳み込みの階層が学習で獲得されるという発想は、ImageNet 時代より前の Neocognitron にさかのぼる。S 細胞が特徴抽出を担い、C 細胞が位置ずれを吸収する二層の積み重ねにより、最終層の C 細胞が位置によらず刺激パターンへ選択的に応答し、小さな形状や大きさの変化への耐性が生まれることが、著者の主張として示されている。根拠の利用は抄録水準に留まり、全文は有料壁の背後にあるため機構の細部には立ち入らない。本節では性能の起点ではなく、畳み込みとプーリング構造の概念上の先行形態としてのみ扱い、比較数値は一切引き継がない。[3]

ネットワーク全体を勾配で一貫して学習させる実践は、文書の文字認識ですでに稼働していた。LeNet は誤差勾配による畳み込みネットワークの end-to-end 学習を文書文字認識へ適用し、手作り特徴ではなく学習された特徴階層が実務課題を解くことを示した。これを本書では、ImageNet 期の規模転換を発明ではなく拡張として読むための存在証明に位置づける。ただし著者 PDF は独自フォント符号化のため本文の機械読解が阻まれ、根拠は要旨水準の裏付けに留まる。文書領域の範囲を超える主張は行わず、規模化の議論は ImageNet 期の資料に委ねる。[4]

当時の壁は二重だった。小さなラベル付きデータでは汎化する階層が築けず、大きく高解像の CNN は計算負担が重かった。AlexNet はこの隘路に対し、データ規模とモデル容量、効率的な GPU 二次元畳み込み実装、飽和しないニューロン、過学習を抑えるドロップアウトを束ねた学習レシピで応えた。具体的には約 6 千万パラメータと約 65 万ニューロン、5 層の畳み込み層と 3 層の全結合層、1000 クラス softmax から成る大規模 CNN を 120 万枚の ImageNet 画像で学習し、5 日から 6 日かけて 2 枚の GTX 580 上で訓練したことが、原論文の主張として記録されている。入力から出力への変化は、画素から直接学ばれる再利用可能な基盤表現の成立である。[1]

評価の契約は単一データセット ImageNet に結びつけて読む。LSVRC-2010 における top-1 誤り 37.5 パーセントと top-5 誤り 17.0 パーセント、ILSVRC-2012 の優勝時の top-5 誤り 15.3 パーセントに対する次点 26.2 パーセントという数値は、いずれも原論文の測定として条件付きで引く。論文自身が計算機の高高速化とデータ拡大で結果はさらに伸びると結んでいる点に、本書は規模レシピとしての読み筋を見出す。一方で転移の主張は後継資料の裏付けを要し、単独では ImageNet の外へ一般化しない。構造の新規性と調理法の双方の読みを保つのが本節の規律である。[1]

初期化と正規化を整えても、素朴なネットワークを深くするほど学習誤差が増える劣化は残った。ResNet の診断はこれを過学習ではなく最適化の問題と捉える。深い側は恒等写像を組めば浅い場合より悪くならないはずだという構成的議論を置き、求める写像  $H(x)$  そのものではなく差分  $F(x)$  イコール  $H(x)$  マイナス  $x$  を学ぶ残差 reformulation へ切り替えた。次元が合う箇所ではパラメータを持たない恒等ショートカット接続を用い、次元整合が必要な箇所に限って射影を添える。経済化のための 1 かける 1 と 3 かける 3 と 1 かける 1 のボトルネック区画により、152 層でも 11.3 GFLOPs と VGG-19 を下回る計算量に収まること、著者の主張として示されている。[2]

数値は条件を切り離さない。152 層単体モデルで検証 top-5 誤り 4.49 パーセント、アンサンブルでテスト 3.57 パーセントを記録し ILSVRC 2015 の第 1 位を得たこと、ImageNet の検出と位置特定および COCO セグメンテーションでも第 1 位に立ったことが、原論文の測定として伝えられている。COCO 検出の 6.0 ポイント改善は、同一の検出枠組みでバックボーンだけを交換する統制された比較の範囲で、学習された表現の寄与として報告されたものであり、一般的因果として拡張しない。CIFAR 上の 1202 層モデルが学習誤差 0.1 パーセント未満まで訓練できながらテストで悪化する点は正則化の境界として開かれている。Highway 網との対比は同時代の枠づけであり、DeiT や Swin 以降のレシピ読解が構造凱歌を限定する。[2]

表現の側から整理すると、欠けていたのは手作り特徴では保持できない大規模階層であり、AlexNet がデータ規模と容量と実装と正則化の組合せでそれを築き、ResNet が超深度の最適化障壁を取り除いて転移可能な深さを与えた。残された限界は、単一データセットの範囲、文書領域資料が要旨水準に留まる点、後継レ

シビによる限定の三点である。本節は深層化以前の歴史を文脈に留め、効率の語彙は TS-001 の用法を引き継ぐにとどめて語り直さない。ここで得られた再利用可能な基盤表現が、次節以降の位置特定と密な予測の素材になる。[1, 2]

### 本節の読解上の境界

深層化以前の歴史は文脈に限定し、ImageNet 単一データセットの範囲を超える転移主張は後継資料に委ねる。Neocognitron は抄録水準、LeNet は要旨水準の裏付けとして機構細部に立ち入らない。検出改善は同一枠組みのバックボーン交換という統制比較の範囲で読む。[1, 2, 3, 4]

## 2 分類から位置特定へ、仮説と後処理の解体

### DETECTION

領域提案から one-stage の動作点、集合予測、そして並行に収束する改良群を経て、検出は言語対応への接続口を開く。[5, 6, 7, 8, 9, 10, 11, 12]

何がどこにあるかを結ぶ演算は、画像一枚の分類だけではまかなえない。手作り特徴の複雑な集成が VOC 検出で停滞するなか、R-CNN はボトムアップの領域提案に大容量 CNN を適用し、位置特定への CNN 利用と、分類の事前学習に検出領域へのファインチューニングを続ける手順の二点で VOC 2012 の mAP 53.3 パーセント、相対 30 パーセント超の改善を示したことが、原論文の主張として記録されている。古典的 CV と深層学習の融合という読みも論文自身の枠づけである。多段パイプラインの速度は将来課題として残され、後年基準では遅いこと、誤り分析が当時の Hoiem らの道具立てによることが限界として付随する。[5]

どこを見るべきかという仮説作り自体が重い工程として残っていた。Faster R-CNN は画像全体の畳み込み特徴を検出器と共有する Region Proposal Network を導入し、ほぼ追加負担なしに提案を生成した。全畳み込みの RPN が位置ごとに物体らしさと境界を予測する入出力の契約は、どこへ注意を向けるかという枠づけで述べられている。VGG-16 で毎秒 5 フレーム、画像あたり 300 提案で VOC 2007 と 2012 および COCO の当時最先端精度を示し、ILSVRC と COCO の 2015 年第 1 位の基盤になったことが著者の測定として伝えられている。アンカー設計と NMS は手設計のまま残

り、小物体や縁の振る舞いは後継資料の領分である。ここで固まった手続きが、後に DETR が取り除く化石化した前提になる。[6]

two-stage 処理の速度上限に対し、YOLO は空間的に分かれたボックスへの回帰とクラス確率の予測を one-stage の単一評価へまとめ直した。基準モデルで毎秒 45 フレーム、高速版で毎秒 155 フレームに達し、他のリアルタイム検出器の 2 倍の mAP を示すこと、R-CNN 系より背景の誤検出が少なく位置特定誤差が多いことが、原論文の主張として記録されている。格子セルあたり 2 ボックスと 1 クラスの制約が近接物体の数に上限を与え、群れた小物体や unusual な縦横比、粗い特徴、小ボックスの IOU 感度が弱さとして論文自身に挙げられ、主誤差源は位置特定にある。自然画像から美術画像への転移の良さも動作点の一般性として報告された。一方で同時代最先端への精度遅れは論文自身が認め、後継 YOLO 製品は別物として版に結びつけて扱う。[13]

one-stage 化の系譜を YOLO だけに還元しない。SSD はボックス空間をスケールと縦横比の異なる既定ボックスへ離散化し、解像度の異なる特徴マップ上に配置して単一評価で検出する。SSD300 で VOC 2007 の mAP 74.3 から 77.2 パーセントを Titan X 上で毎秒 59 フレーム、SSD512 で 76.9 から 79.8 パーセントを示すことが、著者の測定として条件付きで伝えられている。既定ボックスの敷き詰めと受容野の対応づけは論文自身が将来課題として残し、本書では系譜補完の薄

い扱いに留める。以後の数値比較は条件をそろえたものだけを対照し、世代をまたぐ優劣づけには使わない。[14]

one-stage の精度不足に対し、RetinaNet は極端な前景背景不均衡を中心原因と診断した。容易な負例の寄与を抑える focal loss により、one-stage の速度を保ちながら two-stage の精度を超えることが著者の主張として示されている。寄与は損失関数に属し、検出器構成の主張は検出器側の資料に委ねるため、本書では系譜上の位置づけに必要な範囲の薄い扱いに留める。異なる条件の数値を並べて順位づけることはしない。[15]

重なる仮説を後処理なしに個体へ数え上げられない段階に対し、DETR は検出を直接の集合予測へ置き換えた。割当てを決める照合コストと、割り当て済み対を訓練するハンガリアン損失は区別して読む。前者はクラス確率と L1 ボックスとスケール不変な GIoU のコストをハンガリアン法で最適割当てし、後者はクラス負対数尤度と L1 と GIoU の損失を組み合わせる。Transformer のエンコーダとデコーダが学習される物体クエリと並列復号で集合を吐き出し、アンカーも NMS も専用ライブラリも要しない。各中間デコーダ層後に置く補助復号損失は訓練レシピ上の定番であり、構成上必須ではない。層ごとのアブレーション条件では NMS が初層に効く一方で深層では効きが減り最終出力では害になることが示され、重複抑制がデコーダ相互作用で生じるという解釈が添えられている。[7]

評価の契約は同等パラメータの比較に結びつけて読む。COCO 検証で入念に調整された Faster R-CNN と同等となり、R50 で 42 AP、DC5-R101 で 44.9 AP であることが原論文の測定として示されている。大物体の 7.8 ポイント上振れは大域自己アテンションの寄与として述べられ、小物体の 5.5 ポイント不足と 300 から 500 エポックに及ぶ AdamW 日程、16 枚の V100 で 3 日という訓練負担が論文自身の開かれた課題である。パノプティック拡張ではテスト 46 PQ でとくに stuff 側に強いことも同条件の報告として添えられる。小物体と学習負担の修復は FPN 流の後継の領分であり、本資料の外に置く。[7]

DETR の遅い収束と画像特徴マップ上のアテンション制約による空間解像度の限界に応える移行点が Deformable DETR である。参照点の周囲にある少数のキー標本点だけに注意を向ける deformable アテン

ションにより、FPN の助けを借りず高解像マップ由来の小物体を扱い、DETR の 10 分の 1 のエポック数で上回る性能を示すことが、COCO 条件の著者主張として記録されている。二次元参照点をクエリとする機構、符号器特徴の上位 K 件を事前分布とする two-stage クエリ選択、反復的なボックス精緻化が備わるが、後二者は任意拡張であり単一スケールと多スケールの適用範囲も区別する。一般の deformable 注意の概説には広げず、DINO への注意とクエリ選択の供給という中継役割に留める。[10]

クエリを 4 次元ボックス座標そのものとして定式化する短い補助が DAB-DETR である。層ごとに動的アンカーを更新し、明示的な位置事前分布がクエリと特徴の類似計算と収束を助け、幅と高さが位置アテンションを変調する。層ごとのカスケードとして柔らかな RoI プーリングになぞらえた読みも論文の枠づけである。ResNet50-DC5 で 50 エポックの COCO 45.7 AP という数値は、同一設定の DETR 流のなかでの最良として条件付きで引く。単一スケールの DETR 基準という範囲に留まり、アンカー系や条件付き系の分類学には踏み込まない。DINO のアンカークエリ定式への供給という補助役割に徹する。[11]

遅い収束の診断を二部グラフ照合の不安定性に見た移行点が DN-DETR である。初期の最適化目標の揺れに対し、ノイズを加えた正解ボックスとラベルを照合部とは別のノイズ除去部としてデコーダへ入れ、元の目標を再構成させる。漏えい防止のアテンションマスクを伴う。DAB-DETR の 4 次元アンカー定式の上に立ち、同一設定で DAB-DETR を 1.9 ポイント上回ること、R50 で 12 エポック 43.4 と 50 エポック 48.6 の AP、約半分のエポックでの同等到達が著者の測定として示されている。一様分布ノイズ標本の範囲であり、クエリのノイズ除去訓練であって拡散モデルのノイズ除去ではない点を取り違えない。Deformable DETR や Anchor DETR 等への適用可能性も同資料の範囲として添えられる。[12]

集合予測の収束点として検出器 DINO を読む。ノイズ除去アンカーボックスの改良により、R50 と COCO で 12 エポック 49.4 と 24 エポック 51.3 の AP を示し、DN-DETR を 6.0 と 2.7 ポイント上回ること、Objects365 事前学習の SwinL で検証と test-dev の 63.2 と 63.3 に達しつつ模型とデータ規模を抑えたことが、著者の測定として条件付きで伝えられている。

論文自身の系譜記述は DN-DETR と DAB-DETR と Deformable DETR を基盤とする新しい DETR 流モデルであり、層別精緻化の動的アンカー、対照ノイズ除去への改善、計算効率のための deformable アテンションと位置クエリ初期化の継承に、対照ノイズ除去や混合クエリ選択や先読み二重予測という独自改良を加えた構成である。前継統合の記述は検出器 DINO の論文自身の系譜記述に属し、Deformable DETR・DAB-DETR・DN-DETR の各資料へ遡及配置しない。自己教師あり DINO とは別物として検出器 DINO と呼び分け、グラウンディングの振る舞いは Grounding DINO 側の資料に委ねる。各枝は一段の直系ではなく並行に収束する関係として読む。[8]

閉じた語彙のままでは未知語彙への対応づけが保てな

い。YOLO-World は再パラメータ化できる視覚言語集約と領域テキスト対照損失により、検出をオープンボキャブラリー側へ開きながら YOLO の動作点を保つ。LVIS 35.4 AP を V100 上で毎秒 52 フレームのゼロショットで示すこと、ファインチューニング派生が検出とオープンボキャブラリーのインスタンスセグメンテーションへ伸びることが、著者の測定として条件付きで伝えられている。一方で 365 カテゴリ級の閉語彙ファインチューニングがゼロショット一般性を損なう trade-off と、粗い注釈と疑似注釈の併用が優れるというデータ契約の知見も同資料の主張である。YOLO 製品群との混同を避けて版に結びつけ、辺縁実行の負担は動機であって確立した結果ではないと記す。ここが P07B の言語対応への接続口になる。[9]

### 本節の読解上の境界

one-stage 史を単一製品系に還元せず、YOLO 主張は版に結びつける。アンカーと NMS は手設計のまま残し、小物体と縁の振る舞いは後継に委ねる。照合コストと訓練損失を区別し、補助復号損失は必須構成としない。単一と多スケールの適用範囲、任意拡張の位置づけ、一様ノイズ標本の範囲を守る。各 DETR 後継枝は並行収束であり一段直系としない。グラウンディングの振る舞いは Grounding DINO 側の資料に委ねる。[5, 6, 13, 7, 8, 9, 10, 12, 14, 15, 11]

## 3 ボックスを超える密な知覚と指示応答

### DENSE PERCEPTION

画素と領域の構造化から、語ではなく指示で応答するセグメンテーション、そして概念単位の追跡へ。[16, 17, 18, 19, 20]

画像一枚への札付けでは、どの画素が何に属するかは決まらない。FCN は同時代の分類ネットワークを全畳み込みの形に作り替え、分類で培った表現を引き継いだまま画素単位の予測へファインチューニングする契約を敷いた。深い粗い層と浅い細かい層のスキップ融合により、VOC 2012 で平均 IU 62.2 パーセント、相対 2 割の上積みをも 5 分の 1 秒未満の推論で示したことが、原論文の測定として条件付きで伝えられている。分類網が FCN の特殊例として読み替えられるという歴史上の位置づけも同資料の枠づけである。境界の粗さは後年基準で残り、精緻化は後継資料の領分として切り分ける。[16]

注釈が乏しい条件で画素単位の位置決めをどう果たすかが次の問いだった。U-Net は縮む経路と対称に広が

る経路をスキップ接続でつなぎ、弾性変形のデータ拡張と合わせてごく少ない注釈画像から正確な位置特定を果たす。スライディングウィンドウ CNN を神経細胞スタックで上回り、ISBI 2015 の細胞追跡部門を大差で制し、512 かける 512 のセグメンテーションを 1 秒未満で返すこと、Titan での 10 時間学習という条件が著者の測定として添えられている。本書では生体医用画像の領域に留め、一般場面への転移は他資料に委ねる。拡散モデルのバックボーン史は TS-002 の領分であり、本カードでは引き継がない。[21]

検出と密な予測のあいだを結ぶ移行点が Mask R-CNN である。Faster R-CNN へ並列のマスク枝を添え、RoIAlign 流の位置合わせとともに検出と個体別マスクを小さな上乘せで同時に求める。毎秒 5 フレームで COCO 2016 の個体とボックスと人物キーポイントの三部門を飾りなく制したことが、著者の測定として条件付きで伝えられている。人物姿勢への伸びも同

一枠組みの一般性として添えられる。構成上ボックス依存であり、ボックス不要の密な極は FCN や SAM 側の資料に委ねる。検出系譜と密予測系譜を結ぶ要点に絞る。[17]

セマンティックセグメンテーションとインスタンスセグメンテーションが別課題のままだでは、場面全体の整合した読みは得られない。パノプティックセグメンテーションは stuff と things を統一課題へ束ね、全クラスを覆う解釈可能な PQ 指標とともに提示された。三データセットでの人と機械の比較が統一場面解釈を呼び戻すことも同資料の枠づけである。本書では契約明確化の深さに留め、アモーダル拡張は論文自身が将来課題としたことを記す。機構の深掘りは手法資料に委ね、定義と引用の層に徹する。[22]

固定課題の対話型セグメンテーションのままだでは、設計時に見込まない用途へ広がらない。SAM はプロンプトで指示できるセグメンテーションという課題とモデルとデータエンジン一体の体系を敷いた。11M 枚の許諾画像に 10 億超のマスクを築いた SA-1B の規模、新分布や新課題へのゼロショット転移が従来の完全教師あり結果と競合ししばしば上回ることが、著者の主張として条件付きで示されている。指示と合成により一つのモデルが拡張可能な用途に仕え、設計時未知の課題にも組み込まれるという構論は論文自身の議論であり、DALL-E における CLIP への言及も同資料の比喩である。入力点やボックスや文など多様な指示を取り、出力はマスクであるという入出力の変化が要点になる。[18]

SAM の読み筋は二本立てで保つ。基盤モデルの出来事という側面と、課題に区切られた体系という側面である。下流の課題ごとに優劣を裁くのではなく、評価側の記録に委ねるという立場が本書の規律になる。ゼ

ロショットの一般性は課題に区切られた範囲であり、専門特化との対立例は評価側の資料に属する。学習表現が変わったのか、評価契約が変わったのかを混ぜない。SA-1B 規模の主張は論文報告として受け、独立再現の有無を言い添える。[18]

指示に応じるセグメンテーションを映像へ伸ばしたのが SAM 2 である。指示と予測にわたるストリーミング型メモリと、最大級の映像セグメンテーションデータ SA-V のデータエンジンにより、映像では対話回数を 3 分の 1 に減らし、画像では SAM より 6 倍速く正確であることが、著者の測定として条件付きで伝えられている。モデルとデータと学習コードの公開も同資料の主張である。本書では時間状態へのアーキテクチャ上の指し示しとして読み、運用システムとしての位置づけは Flash-VStream 側の資料に委ねる。オンライン配置の遅延主張は system 側の裏付けを要する。[19]

指示が画素や既知対象の範囲では、概念を画像と短い映像にわたり追えない。SAM 3 は Promptable Concept Segmentation という約束を掲げ、視覚概念の全個体を検出してセグメンテーションし追跡して、マスクと一意な同一性を返す。指示は平易な名詞句と画像例の肯定否定ボックス、SAM 2 流の視覚クリックであり、DETR 流の画像検出器とメモリ型映像追跡器が一つの知覚エンコーダを共有し、存在トークンの分離が認識と位置特定を分ける。SAM と SAM 2 の指示と記憶の機構を引き継ぎ、新味は画像と映像の規模の上に載る言語接地の概念界面にある。SAM 3D は範囲外であり、3.1 は後継文脈に留める。細粒度の分布外ゼロショットは弱く、長い指示表現は扱えず、映像負担は物体数に線形という限界が著者の主張として付随する。[20]

### 本節の読解上の境界

拡散バックボーン史は語り直さず、パノプティックは契約明確化の深さに留める。ボックス依存の範囲を守り、SAM の二本立て読解を保つ。ゼロショット一般性は課題区切りとし、SAM 2 はアーキテクチャ上の指し示しに留めて運用主張は system 側に委ねる。SAM 3 は平易名詞句と線形負担の範囲で読む。[16, 17, 18, 19, 20, 21, 22]

## 4 ラベルにない幾何と空間状態

### SPATIAL SUBSTRATE

奥行きと姿勢と関係構造と無姿勢再構成の四点だけが、後の推論の仮定する世界を支える。[23, 24, 25, 26]

対象の名前だけでは画面の奥行きは定まらない。MiDaS は互換性のない深度データ群、すなわちステレオ撮影とレーザー測距と構造化光に 3D 映画由来の素材までを、スケールとシフトに不変な頑健目的で混ぜ合わせる多目的混合で束ねた。素朴な混合に対するパレート最適な混合の優位、補助課題でのエンコーダ事前学習の寄与、モデルの公開が著者の主張として記録されている。入力が多様な由来の画像と深度であり、出力は相対深度であって計量深度ではないという入出力の区切りが要点になる。学習表現の変化は、単一データの作法から非互換集合の混合作法への移行にある。[23]

測り方の約束は、一部のデータで学習し残りの未知データで試すゼロショット横断にある。DIW や ETH3D や Sintel や KITTI や NYU や TUM を含む未知データでの転移を野外代理とする設計が、頑健さ測定の exhibits として示されている。既存の深度データこそが制約要因になりうるという開かれた問題は論文自身の境界である。本書では相対深度の範囲を守り、計量深度の主張は他資料に委ね、比較対象の 2019 年当時の基線という条件を切り離さない。後継の追加は新しい契約を生まないものとして cap の外に置く。[23]

分類特徴だけでは身体関節の並びと人物同士の対応づけは残らない。OpenPose は四肢の位置と向きを運ぶ二次元ベクトル場の Part Affinity Fields と貪欲な二部照合により、多人数の二次元ポーズを人数によらずリアルタイムに組み立てる。部位と場の同時精緻化ではなく場のみの精緻化が実行性能を倍化しつつ精度を約 7 パーセント押し上げ、身体と足部の統合検出が速度と部品精度を保つこと、135 キーポイント体系の公開が著者の主張として記録されている。分類では駆動できない行動側の状態として、対象中心の空間状態と対応づけ自体の表現化を示す exhibits である。二次元姿勢の範囲に留まり、三次元持ち上げは cap により扱

わず、実行時間の基線は 2019 年当時の hardware に結びつけて読む。[24]

対象名だけでは関係と属性の構造は残らない。Visual Genome は 10 万枚を超える画像に、1 画像あたり約 21 の対象と約 18 の属性と約 18 の関係、42 を超える領域記述と約 17 の問答対を集め、WordNet synset へ正準化した。関係と属性を一級ならぬ明示的な構成要素として据え、シーングラフ定式が検索とキャプション生成を改善することが、著者の主張として示されている。クラウドソーシング由来の雑音と正準化の限界が付随し、規模の数値は資料収集時点の条件に結びつけて読む。後の接地データ作法への連なりは次ブロックで切り分ける。[25]

関係構造の来歴として、Visual Genome は領域記述データの先行形態にも位置づけられる。後の検出とグラウンディング (grounding) の統一学習における接地データ作法がこのデータ条件を受け継ぐという見立ては、本書の比較判断として述べるものであり、資料に裏付けられた直接の因果継承としては扱わない。以後はグラウンディングと記す。GoldG 級の組成主張は GLIP 側の資料に委ね、ここでは先行形態の位置づけに留める。関係構造ノードと言語対応データ先行の二重役割を保つのが本節の規律である。[25]

カメラ内部パラメータも姿勢も未知の画像対から立体を起こせないという欠落に対し、DUST3R はキャリブレーション不要かつ姿勢不要の画像対からポイントマップ回帰で再構成する。単眼と両眼の再構成を統一し、多視点では大域位置合わせで共通座標へ載せ、カメラと深度と対応を下流で取り出せる。単眼と多視点の深度および相対姿勢で当時最先端を示すこと、標準 Transformer のエンコーダとデコーダに事前学習済みモデルを活かすことが、著者の主張として記録されている。較正パイプラインへの入力ではなく、幾何を網の出力状態として得る転換が要点であり、後の融合や身体系への受け渡し exhibits になる。[26]

論文自身の境界として、ポイントマップは不定スケールまでの回帰であり、汎用構成が幾何制約を明示的に強制することはなく、事前知識は幾何整合な学習ポイ

ントマップからのみ来る。スケール不定と学習事前分布への依存が限界として残り、後継の追加は新しい契約を生まないものとして cap の外に置く。下流の推論や行動への接続は、資料が直接の因果継承を支える

ものではなく、本サーベイの編集上の比較判断として明示する。四ノードの上限を守り、NeRF や 3DGS や SLAM や MVS や三次元検出や骨格模型やベンチマーク集への拡張は行わない。[26]

### 本節の読解上の境界

四ノードの上限を守り、NeRF や 3DGS や SLAM や MVS や三次元検出や骨格模型や評価集への拡張は行わない。相対深度と二次元姿勢の範囲を守り、計量や三次元持ち上げは他資料に委ねる。DUS3R の下流接続は編集上の比較判断として明示し、資料由来の直接因果としない。[23, 24, 25, 26]

## 5 文字の読み取りから配置と構造の理解へ

### DOCUMENT INTELLIGENCE

テキストと二次元配置を同時に学ぶ手法から、文書画像を直接構造化出力へ写す手法へ。スクリーンショットの解析、科学文書のマークアップ化、光学信号の捉え直し、検索性埋め込みまでを、条件の異なる数値で序列化せず、入出力と教師信号と評価条件の違いで比べる。[27, 28, 29]

テキストだけを取り出しても、ページ上のどこに置かれ見出しとどう対応するかは残らない。LayoutLM はテキストと二次元レイアウトを同時に学ぶ事前学習でこの欠落に応えた。入力語の 15% を 80/10/10 の方策でマスクし、 $x_0/y_0/x_1/y_1$  を 0 から 1000 へ換算した位置埋め込みは保持したまま、言語と配置の文脈から復元する。IIT-CDIP の 600 万超文書・1100 万超画像を Tesseract の hOCR 付きで学び、BERT 起点の BASE 113M と LARGE 343M を備え、IIT-CDIP タグによる多ラベル文書分類 MDC を任意に選べる。三つの明示的な構成要素として、MVLM による言語と配置の学習、MDC による文書分類、Faster R-CNN による画像特徴の利用がある。Visual Genome で学んだ ResNet-101 背景の Faster R-CNN 領域特徴と画像全体の [CLS] 埋め込みは FUNSD・SROIE・RVL-CDIP でファインチューニングと評価に加わるが、事前学習の目的関数には含まれない。この条件で 160M 規模は FUNSD 0.7927、SROIE LARGE 0.9524、RVL-CDIP 94.42% と論文著者が報告する。画像埋め込みを事前学習に含める作業は論文末尾の今後の課題に属し、基本版の範囲外である。[30]

学習済み CNN や Faster R-CNN に依存する構成に対し、LayoutLMv3 は線形パッチ埋め込みだけで組み立

てる設計へ変えた。核はマスク言語モデリングへマスク画像モデリングと言葉・パッチのアライメントを並置した統一目的にある。画像側の再構成先はコードブック由来の離散トークンであり、視覚語彙 8192、約 40% のブロック単位マスクを交差エントロピーで解くため、生画素や領域特徴ではなく高水準の配置構造が身につく。アブレーションでは、線形パッチだけでは画像側の学習目的なしに成立しないこと、色再構成やトークン再構成のアブレーション条件が下流を落とすことが確かめられた。異なるアブレーションバリエーションの比較が目的設計の根拠になる。大規模なデータと計算への拡張と few-shot やゼロショット対応は確立した成果ではなく、今後の課題として残ると論文著者が述べる。[31]

活字認識を別工程に分ける構成では、処理の重さと硬直に加え、前段の誤りが後段へ伝わる難点が避けられなかった。Donut は文書画像を構造化出力へ直接写す OCR フリーのエンコーダ・デコーダ型 Transformer として、この連鎖を切った。画素から文字列や構造を起こす経路で文書理解を一段にまとめ、合成生成器 SynthDoG で言語や領域の柔軟性を補い、コードとモデルを公開した。事前学習とファインチューニングの振る舞いは入力解像度に強く依存し、高解像度では系列長が膨らむため、画素だけで読む方式に共通する隘路が表れると論文著者が述べる。この解像度とトークン量の関係は文書系の入力経済を考える手がかりになる。合成学習への依存と解像度感受性が領域転移を縛り、実環境での転移能力は別途の検証を要する。[27]

活字文書に絞った理解だけでは、図解や操作画面や自

然画像が別システムの処理に残る。Pix2Struct はマスクしたウェブのスクリーンショットから簡略化 HTML を起こす事前学習で、光学文字認識と言語モデルと画像説明の信号を一つの視覚理解にまとめた論文著者が説明する。可変解像度の入力と、画像面上に言語を描いて指示する方式を採り、文書と図解と UI と自然画像にまたがる 9 課題のうち 6 課題で単一モデルとしての到達を示したと論文著者が報告する。携帯端末の応用やボタンや様式を同じ純粹視覚の枠組みで扱える点の変化である。UI 理解は Computer Use 側の検討に委ねる前提でここでは文書の延長として置く。解像度の隘路は Donut 系統の画素だけの方式と共通し、論文自身の考察として残るとされる。数値は論文著者の自己報告に属し、独立した第三者再現ではない。[28]

科学論文の PDF を相手にする局面では、数式や表をテキストとして正しく起こす表現が足りなかった。Nougat は Donut 系統の Swin エンコーダとデコーダで、科学系 PDF のページ画像から本文と数式 LaTeX や表を含むマークアップを起こす専門手法として位置づけられると論文著者が説明する。arXiv や PMC や IDL 由来の学習対を用い、モデルとコードを公開した。ページ画像から構造付きマークアップへの直接変換がここで開かれた。一方で繰り返し生成の失敗様式、研究論文構造への偏り、ほぼ英語中心の学習でラテン系言語の確認が小規模に限られる点が論文自身の記述として残る。評価は独自のマークアップ一致と GROBID や PDF テキスト抽出との比較に限られ、条件の異なるモデル間の数値優劣には踏み込まないことが比較上の規律として明記される。[29]

文字読みを活字認識に狭める枠組みでは、数式や表や楽譜や図形や図表を同じ対象として扱えなかった。GOT は人工的な光学信号をすべて文字と捉える OCR-2.0 の考えと 580M の統一エンドツーエンドモデルを掲げると論文著者が説明する。80M の高圧縮エンコーダが 1024 画素画像を 256 トークンへ変換し、長いコンテキストのデコーダがプレーン出力と整形出力を担い、markdown や tikz や smiles や kern を起こせる。領域指定による対話的 OCR や動的解像度や複数ページ処理も同じ枠組みに入る。学習は PaddleOCR 由来の疑似正解や数式・表・音楽・図形・図表の描画手段や合成中心のデータエンジンと Common-Crawl の PDF 抽出に支えられ、描画・疑似中心であって完全合成のみではないとされる。評価は独自系列に限ら

れ、汎用モデルとの同一条件比較は確認されていないという G03 の欠落が残る。[32]

生成や抽出に傾いた文書理解だけでは、大量文書から該当箇所を探す検索が別の経路として要った。Qwen3-VL-Embedding と Reranker は視覚言語モデルを基盤とする検索用構成で、埋め込みモデルとクロスエンコーダ型の再順位づけを組にすると論文著者が説明する。埋め込みは多段階の対照事前学習から再順位づけ蒸留へ進み、Matryoshka 次元と 32K 入力に対応し、2B と 8B の規模で用意される。8B は MMEB-V2 で 77.8 を示し、2026 年 1 月 8 日時点で第一位だったことが著者測定として残る。多言語 30 言語以上の対応は Qwen3-VL から受け継がれる。本記録は著者測定でプレプリント段階であり、独立した第三者再現は未確認である。文書検索の入力インターフェースという限定的な副経路であり、文書理解の中核とは別の評価軸で扱う。[33]

文書の質問応答を測るには、配置に依存した問いを系統的に評価する基盤が要った。DocVQA は 12K 超の文書画像に約 50K の質問を集め、9 種の推論類型と 80 対 10 対 10 の区分で組み立て、ANLS を主指標とし正解率を併せるとベンチマーク論文著者が報告する。LoRRA や M4C や BERT-QA を起点に置き、人間の 94.36%が参照点として示される。ANLS は ST-VQA 由来の平均正規化レーベンシュタイン類似度で、軽微な OCR 誤差を過度に罰しない設計である。データセットとコードとリーダーボードが公開されている。抜き出し型回答への近道の脆さは資料に裏づけられた設計上の懸念であり、後の大規模事前学習モデルの評価では学習データの重なりを別途監査すべきである。原論文は混入率を測定せず危険度判定を付与しない。[34]

実写のグラフや図表を問う評価は、合成図版中心の時代には手薄だった。ChartQA は人手作成 9.6K 件と自動生成 23.1K 件を束ねずに組み合わせ、見ることに論理操作の両方を問う構成を採るとベンチマーク論文著者が説明する。FigureQA や DVQA や PlotQA の合成系列を背景とし、実世界の図表を扱う点に位置がある。報告時点で VisionTaPas が参照点として示され、リポジトリが公開されている。指標は relaxed accuracy であり、許容の意味を切り離して数値を読むことはできない。CoT のような外部の段階的推論手順を仮定せず、画像と言語の対応と論理操作を一体で

評価する点に特徴がある。合成由来の先行研究は背景情報に留まり、許容条件と抽出規則とともに数値を扱うことが求められる。[35]

文書系の流れは、配置を学ぶ方式から画素から直接読む方式へ進み、科学文書のマークアップ化と統一 OCR の構想へ分岐し、検索への接続が副経路として整った。共通の論点は次の演算に見合う文書表現は何かであり、画素列か配置埋め込みかマークアップか検索用埋め込みかは用途で異なる。本節では専門手法と

汎用モデルを対象文書と出力形式と教師信号と解像度とトークン量と評価条件の違いで質的に比べ、条件の異なる数値を並べて優劣を決めない。テキスト LLM を基盤とする汎用 VLM と文書専門モデルは教師の契約が異なり、同一条件の直接比較は確認されていない。画面操作は Computer Use 側の課題であり、ここで完結させない。単一構成への収束を結論とせず、残る課題を残したまま次の融合の議論へ引き継ぐ。[30, 28, 32]

### 本節の読解上の境界

数値はすべて論文著者またはベンチマーク論文著者の自己報告に属し、条件の異なる評価を並べて序列化しない。専門家と汎用の同一条件比較は確認されていない欠落として保つ。抜き出し型回答への近道の脆さは資料に裏づけられた設計上の懸念であり、ウェブ文書との事前学習の重なりは版レベルの監査事項であって論文測定の混入率ではない。検索の接続は文書検索の副経路に留め、画面操作は Computer Use 側の課題としてここでは完結させない。[30, 31, 27, 28, 29, 32, 33, 34, 35]

## 6 画像をトークン列に直し目的ごと学ぶ基盤表現

### VISUAL FOUNDATIONS

畳み込みの前提を外して画像をトークン列に直す定式から、再構成と自己蒸留と対応づけの目的を分けて読む。手順と規模の切り分けを保ち、長期化した密な蒸留と段階的な整合や自己回帰の分岐を経て、視覚言語モデルへ受け継がれる条件を確かめる。[36, 37, 38]

畳み込みを前提に置く時代には、画像を言語モデルと同じトークン列の形で扱う定式が欠けていた。Vision Transformer は画像パッチの系列へ素の Transformer を適用し、パッチ化を除く画像固有の帰納バイアスを抑えたと論文著者が説明する。大規模な事前学習と転移で CNN の到達点に肩を並べ、同等水準では CNN 相手より少ない学習計算で済む点が論文著者の自己報告として示された。画像をトークン列に直して扱う道が開け、後の視覚と言語のトークン融合の前提が整った。大規模事前学習への依存は残り、系列化が次の計算に見合うかが本節の焦点になる。効率の一般論は TS-001 の範囲であり、ここでは表現の契約として読む。[36]

ViT が大量のデータを求める段階では、手順と階層の手当てが残されていた。DeiT は練り上げた学習手順と Transformer 専用の蒸留トークンにより、外部データを用いず 86M の学習可能パラメータで単一計算機

3 日以内に ImageNet で 83.1%、蒸留により 85.2% へ到達し、転移でも競争力を保つと示したと論文著者が報告する。一方 Swin Transformer はシフトウィンドウアテンションでウィンドウ内の局所性とウィンドウをまたぐ接続を両立し、画像規模に線形の計算量で階層性を取り戻した。ImageNet で 87.3%、COCO でボックス AP58.7・マスク AP51.1、ADE20K で 53.5mIoU が著者測定として示され、実装とモデルが公開された。二者は移行期の仲介であり、ここでは要点に絞る。データ拡張と正則化の再利用が手順の読みを支える。[39, 40]

注釈なしに視覚表現を得るには、再構成と表現の読みを分ける設計が要った。MAE は可視パッチだけを通す非対称エンコーダと軽量デコーダで、75%のマスクにより 3 倍超の学習高速化と水準向上を両立させたと論文著者が説明する。再構成先は隠したパッチ画素への平均二乗誤差であり、既定のアブレーションでは非正規化画素を用い、最終手順ではパッチ単位で正規化した画素を用いる。PCA や dVAE トークンのバリエーションはほぼ同等で、離散化は必須ではない。デコーダ深度 1 から 8 で線形プロープは 65.5 から 73.5 へ上がる一方、ファインチューニングは 84.9 前後で平坦で

あり、マスク率の最適は 75%前後、線形は約 20 ポイント敏感でファインチューニングは 40 から 80%で平坦である。既定手順は 8 層 512 次元デコーダ・非正規化画素・800 エポック、最終手順は正規化画素・1600 エポックで 1600 まで飽和せず、両者を混同しないことがアブレーション条件の読みに含まれる。[41]

注釈なし蒸留から表現を引き出すには、教師と生徒の関係を崩壊なく保つ仕掛けが要った。自己教師あり DINO は注釈なしに ViT を学び、教師あり ViT や畳み込みには見られない創発的性質を示したと論文著者が説明する。CLS アテンションがセマンティックセグメンテーションの情報を含み、小規模 ViT で kNN により ImageNet で 78.3%、ViT-Base で線形評価 80.1%とされる。教師は勾配を止めたモーメントエンコーダで生徒のみ確率的勾配で動かし、マルチクロップと小パッチが効く。崩壊回避には教師出力へのセンタリングと低い教師温度による先鋭化の両方が要り、片方を欠くと崩壊するとアブレーションで確かめられた。教師温度は 0.04 から 0.07 への線形ウォームアップ、生徒温度 0.1 固定、運動量係数 0.996 から 1 への余弦変化であり、向きを逆にしない。本節の DINO は検出器の DINO とは別物であり、自己教師あり DINO として呼ぶ。[37]

自己教師あり特徴を実用にするには、精選データと規模拡大の手順が要った。DINOv2 は自動化された精選データの収集手順と拡張学習で 10 億規模の ViT を小規模モデルへ蒸留し、ファインチューニングなしに弱教師ありの代替に迫る汎用特徴を得たと論文著者が説明する。画像や画素の評価で OpenCLIP を上回るとされる範囲が示された。凍結したまま転移する汎用特徴の利用が新たに開けた。一方で SAM との対比が重要であり、汎用特徴とプロンプトで指示できるインターフェースは基盤という語の別義である。評価は凍結転移の範囲であり、課題固有の限界は評価側の資料に委ねられる。DINOv2 や iBOT のマスク予測は画素再構成ではなく、マスクされたトークンの予測であり、MAE 型の画素再構成と同一視しない。[42]

画像と言語の対応づけを広げるには、全体正規化がバッチ規模と損失を結びつける点が重かった。SigLIP は対ごとのシグモイド損失で全体正規化を外し、バッチ規模と損失を切り離したと論文著者が説明する。100 万バッチまで広げても収穫は逡減し、32K で十分なことが示され、小バッチでも有効である。凍結し

た画像エンコーダを調整する Locked-image Tuning である SigLiT は 4 基の TPUv4 で 2 日、ImageNet ゼロショット 84.5%とされる。損失機構の記述は抄録水準に留まる。コードとモデルを公開した完全オープン版として提供された。小規模計算での対照学習の拡張が開かれた。Qwen3-VL との接続は、Qwen3-VL 技術報告が明示する視覚エンコーダの再利用に限って扱う。すなわち SigLIP2-SO-400M の継続が Qwen3-VL と Qwen3-Omni のエンコーダに含まれるとの報告内容が結びつけの根拠である。詳しくは第 10 節で扱い、ここでは接続の記述に留める。[38, 43]

自己蒸留を長期学習に耐える密な表現へ進めるには、特徴マップの劣化が残されていた。DINOv3 は 70 億規模の自己教師あり視覚モデルで、16.89 億画像の階層サンプリングによる LVD-1689M で学ぶと論文著者が説明する。目的は L\_DINO と L\_iBOT に 0.1 倍の L\_DKoleo を加えた構成で、センタリングに代えて Sinkhorn-Knopp を用い、axial RoPE と 100 万反復の一定計画を採る。ここで iBOT は隠したパッチトークンの予測であり、MAE の画素再構成とは別の目的である。長期学習での mIoU 低下に対し、早期の Gram 教師に対する Gram 固定でパッチ一貫性を保ち、特徴固定にはしない。事後適応として解像度拡張と多生徒蒸留と凍結視覚に対する dino.txt の言語対応が再学習なしに可能である。計算や炭素費用、公平性差、OCR 含有の難しさ、中間層利用の条件が限界として述べられる。[44]

対照学習の改良だけでは、位置や密な転移が十分にならなかった。SigLIP 2 は対ごとシグモイド損失を保ちつつ、段階的手順として説明デコーダ LocCa によるキャプション生成学習、SILC による局所全体間の自己蒸留、TIPS や DINO 系統のマスク予測、オンライン精選を組み合わせたと論文著者が説明する。WebLI の 109 言語多言語混合と偏り除去選別、元解像度を保つ NaFlex による縦横比保持と多解像度学習が用いられ、改善は新損失ではなく組合せに帰される。RefCOCO のグラウンディングや OWL-ViT によるオープンボキャブラリー検出や密な探索で SigLIP を上回り、PaliGemma 型の凍結エンコーダ転移でも改善が示された。一方 NaFlex は自己蒸留やマスク損失を含まず外挿が弱いこと、RefCOCO が英語専用 LocCa に届かない多言語の代償、小規模モデルの改善が蒸留段階に依存することが限界である。位置への対

応づけ自体の評価契約は P07B の範囲であり、指標を混ぜない。[45]

マスクや対照や蒸留とは別の目的が要る局面で、自己回帰による視覚学習が提示された。AIMv2 は接頭辞付き ViT と因果的マルチモーダルデコーダで、生パッチ列の後にテキストトークンを生成し、大バッチ対照を要しない密なトークン単位の信号を得ると論文著者が説明する。凍結した基盤の転移でマスク系や対

照系や蒸留系と競争力を持つことが示された。生成順序による密な学習信号の利用が開かれた。ただし単一論文の範囲であり、報告条件を超える規模拡大や頑健性は未確定である。列化と目的の分岐が再利用可能な基盤表現の条件を残し、視覚言語モデルへ受け継がれるが、一本化の勝利ではなく次の演算に見合う表現の条件が残る。テキスト LLM との結合は後段の架橋の範囲であり、ここでは視覚側の目的の違いに留める。[46]

### 本節の読解上の境界

大規模事前学習への依存は残り、効率の一般論は扱わない。損失機構の記述は抄録水準に留まる。Qwen3-VL との接続は技術報告が明示する視覚エンコーダの再利用に限り、検出器の DINO と自己教師あり DINO を混ぜない。密な転移の伸びは画像水準の対応の延長として読み、位置特定の評価契約は別節の指標で測る。[36, 41, 37, 42, 38, 44, 45, 39, 40, 46]

## 7 決められた分類から言葉で指し示す理解へ

### ALIGNMENT

定められた分類名から自然文で画像を指す方式への転換を扱う。ゼロショット転移と画像文検索の再現率を契約とし、位置へのグラウンディングとは指標も機構も切り離して、画像全体のアライメントに見合う表現を問う。[47, 48]

画像と言語を結ぶ初期には、画像全体から文を起こす手段自体が欠けていた。Show and Tell すなわち NIC は CNN エンコーダから RNN デコーダへ尤度学習で説明文を起こすエンドツーエンドの構成であり、Pascal で BLEU-1 が 59、従来 25、人間約 69、Flickr30k で 66、SBU で 28、COCO で BLEU-4 が 27.7 と伝えられると論文著者が報告する。コンパクトな視覚表現から生成が成り立つことを示した点が先行事例としての意義である。画像内容の言語化が新たに開かれた。生成側の作り込みは TS-002 の領域であり、本節では画像と言語の対応の起点としてのみ扱う。[49]

説明文の生成だけでは、画像理解と推論を分けて測る指標が足りなかった。VQA は約 25 万画像、約 76 万質問、約 1000 万回答からなる自由形式の質問応答であり、短答や選択式による自動評価で汎用的な説明より細かな画像理解と込み入った推論を求めたとベンチマーク論文著者が説明する。質問や答えの事前分布だけに頼る近道をあぶり出す評価族の起点になったこと

が位置づけである。後の VQA v2 では同一の質問に外見の近い画像対を添え、正解が異なる相補的な組により、質問や答えの偏りだけでは解けない条件を整えた。同じ質問と見た目の近い相補的画像と異なる正答の組が偏りを抑え、画像根拠の利用を強く求めるが、言語の事前分布を消し去るものではない。CoT のような段階的推論の明示化は前提とせず、版や区分と答え抽出規則を明示して数値を扱う必要がある。[48]

固定分類が概念を定める枠組みでは、自然文で概念を示す使い方がなかった。CLIP は 4 億のウェブ画像文対から説明予測の事前学習を行い、自然文で指定できる転移可能なアライメント表現を学んだと論文著者が説明する。ImageNet の約 128 万件の学習例を用いず教師あり ResNet-50 に匹敵し、光学文字認識や動画行動認識や地理的位置推定や細粒度分類を含む 30 以上のデータセット群へゼロショット転移することが示され、コードとモデルの重みが公開された。所定分類による教師から画像文教師へ変わり、言語が概念参照のアライメントインターフェースになった点が転換である。画像全体の意味を言語で指定する利用が開かれた。論文著者が記す弱さは、車種や花種や航空機変種の細粒度分類の弱さ、CLEVRCounts の数え上げの弱さ、KITTI 距離の新規系統課題でほぼ偶然水準に留

まる点、分布外の脆さとして MNIST 88%で画素基準を下回る点、全体首位へは約 1000 倍の計算が要ると見積もられ現行機では非現実的な点に限って扱い、これ以外の作り話を足さない。グラウンディングの AP とは別の契約で測る。[47]

整えた資料が前提のままで、雑音の多い大規模代替文で足りるかが確かめられなかった。ALIGN は 10 億超の代替文対に最小限の頻度洗浄だけを行い、規模が雑音を補うことを示したと論文著者が説明する。デュアルエンコーダによる対照アライメントで表現学習とゼロショット分類、Flickr30K や MSCOCO の検索で交差注意型を上回るとされる。精選を前提としない規模拡大の実践が開かれた。本節ではバリエーションとしての位置づけに留め、記述は簡潔にする。画像全体と言語のアライメントという契約は CLIP と共通し、位置や領域へのグラウンディングとは別の評価で測られる。[50]

CLIP が開いた画像文アライメントの系譜を段階的な教師で強めるのが SigLIP 2 である。対ごとシグモイド損失を保ったまま、キャプション生成と言語対応の自己蒸留とマスク予測を組み合わせ、WebLI の 109 言

語混合と NaFlex の縦横比保持で学ぶと論文著者が説明する。RefCOCO のグラウンディングや OWL-ViT の検出や密な探索、PaliGemma 型凍結転移の伸びは、画像水準の対応の延長として読む。NaFlex の外挿の弱さや多言語の代償など限界は論文著者の報告の範囲に残る。位置や領域へのグラウンディングそのものは次節の契約であり、指標を混ぜない。SigLIP 2 の段階的手順の詳細は第 6 節の範囲である。[47, 45]

画像水準の流れは、説明生成から質問応答の評価を経て、固定分類から言語指定できるアライメントへ進み、雑音規模の実践で補強された。共通の論点は次の演算に見合う画像全体のアライメント表現は何かであり、文生成か問い答えか対照アライメント表現かは別の演算に対応する。本節の契約はゼロショット分類と画像文検索の再現率であり、語句グラウンディングや検出の AP とは別の指標で測る。テキスト LLM との結合は後段の架橋に属し、ここでは大規模画像テキスト対による教師信号の系譜に位置づける。単一構成の勝利を結論とせず、細粒度や数え上げや新規系統課題の弱さを残したままグラウンディング側の議論へ引き継ぐ。[49, 48, 47, 50]

### 本節の読解上の境界

生成側の作り込みは扱わず、画像と言語の対応の起点に限定する。数値は論文著者の自己報告であり、領域グラウンディングや位置特定とは別の評価で測る。CLIP の弱さは論文著者の限定報告に属し、構成的一般化の議論は本節の CLIP 主張としない。版や区分と答え抽出規則を切り離さない。[47, 49, 48, 50]

## 8 任意の言葉を位置と領域と座標へ結びつける連鎖

### GROUNDING

任意の言語概念をボックスやマスクや座標や根拠に対応づける連鎖を扱う。語句グラウンディングと指示参照、オープンボキャブラリー検出とグラウンディング検出、セグメンテーション分岐を指標ごとに切り離して、次の演算に見合うグラウンディング表現を問う。[51, 52, 53]

固定分類の検出だけでは、裾の長い語句空間を位置へ結びつけられなかった。Flickr30k Entities は 15.8 万説明文に 24.4 万共参照鎖と 27.6 万ボックスを付与し、領域と言語の対応を大規模に整えた最初の事例であると論文著者が説明する。課題は語句グラウンディング (phrase grounding) であり、検出に似るが、多数の語

句が希少で一部は学習時に未観測となる開かれた語句空間が条件に置かれた。CCA 埋め込みの基準で再現率の第一位が Fast R-CNN 特徴により約 25%から約 50%へ上がり、教師あり領域語句学習が弱教師ありを上回る知見が示された。学習時に未観測の語句を含む条件での的中率という読み留め、すべて未知とする誇張はしない。固定分類からオープンボキャブラリーの語句集合への位置特定が可能になった。人物や動物に偏る領域差と二値検索への利用には全体照合の拡張が必要という限界が残る。[51]

語句グラウンディングの次に足りなかったのは、指示の曖昧さを解く評価と希少カテゴリを測る評価の切り

分けであった。RefCOCO 系列の REC 契約は関係記述や曖昧記述のもとで単一対象を切り分けるものであり、構成的文脈のモデル化とグラウンディング正解率の指標の起点となったと論文著者が説明する。指示表現による単一対象の指定が入力であり、ボックスによる位置特定が出力である。ファインチューニングとゼロショットの REC は手順の違いであり、別の節点ではない。一方 LVIS は 16.4 万画像に 1000 超の基本水準カテゴリと約 200 万マスクを Zipf 分布で整え、希少と通常と頻出の区分により LVIS-rare の AP を OVD 評価の起点にしたとベンチマーク論文著者が説明する。ODinW は実世界・多様ドメイン評価の補完として位置づけられ、独立記録ではない。希少区分の手順は利用ごとに明示し、ウェブ事前学習の近接が未知の読みに影響する点に注意する。[54, 55]

認識と位置特定の教師を分けて検出を組み立てる方式として、オープンボキャブラリー検出が命名された。OVR-CNN は認識を説明文から学び、位置特定を基本分類ボックスから学ぶ two-stage 構成で両者を分けたと論文著者が説明する。視覚言語投影とグラウンディングやマスク言語モデルや画像文照合の事前学習をオープンボキャブラリー条件で行い、27% mAP と 10% のゼロショット基準の差、基本分類正解率が教師ありに近いことが示された。語彙を埋め込みに開いた検出の定式化が与えられた。一方でオープン性は実用上は事前学習済み単語埋め込みに縛られると論文自身が限定し、埋め込み品質の差は ViLD 側の資料に委ねられる。グラウンディング (grounding) への言い換えではなく、検出の語彙拡張という契約で読む。[56]

画像水準の教師を蒸留で検出器へ移す方式として、ViLD による OVD が示された。ViLD は CLIP や ALIGN の教師を two-stage の生徒に蒸留し、領域言語蒸留と領域画像蒸留を組にすると論文著者が説明する。LVIS-rare でマスク AP16.1、教師あり対応比で 3.8 上回り、ALIGN 教師で 26.3、VOC 直接転移 72.2AP50、COCO36.6、Objects365 で 11.8 とされ、COCO で OVR-CNN を新規 4.8、全体 11.4 上回るとされる。コードが公開された。教師モデルの出力に依存する検出器のオープンボキャブラリー化が果たされ、LVIS-rare 手順の起点として後の評価に引き継がれる。限界は教師モデルに制約されることであり、領域事前学習の RegionCLIP とは機構が異なる別系統として保つ。教師モデルと生徒モデルを標準用語で書く。[57]

画像全体の照合では領域水準の対応が足りない。疑似領域文対で領域表現を学ぶ方式として、RegionCLIP が示された。RegionCLIP は CLIP 教師と定型文説明から疑似領域文対を築き、領域表現を対照事前学習すると論文著者が説明する。COCO と LVIS で新規 AP50 が 3.8、新規 AP が 2.2 上回るとされ、ゼロショット推論が可能でコードが公開された。領域水準の事前学習による OVD 基盤の強化が図られた。ViLD の検出器蒸留とは機構が異なり、両者は重複ではなく別契約として保つ。疑似ラベルの雑音と定型文依存が限界であり、雛形の範囲を超える主張は行わない。[58]

ボックス注釈なしの語彙拡張を画像水準教師の素朴な割り当てで果たす方式として、Detic が示された。Detic は ImageNet-21K の画像水準教師により、最大規模提案への割り当てという素朴な方式で検出器分類器を学んだと論文著者が説明する。オープンボキャブラリーの LVIS で全体 2.4mAP、新規 8.3mAP の改善、標準 LVIS で 41.7mAP とされ、ファインチューニングなしに 21K 分類の検出器として汎化する最初の事例とされる。コードが公開された。込み入った割り当てを要しない語彙拡張が果たされた。限界は全画像ラベルを同じ領域に教師づける点であり、データ統計のモデル化を含まない割り当て発見的手法の範囲として記録する。ID は受入時に修正済みである。[59]

検出を語句グラウンディングへ書き直す再定式化として、GLIP は検出とグラウンディングの統一事前学習を行ったと論文著者が説明する。27M 件のグラウンディングデータ、すなわち人手 3M とウェブ由来 24M から自己学習で起こしたグラウンディングボックスを用い、COCO ゼロショット 49.8、LVIS26.9AP とされる。COCO 画像を見ない条件で教師あり基準を上回るとされ、ファインチューニングで COCO 検証 60.8 AP、test-dev 61.5 AP、13 転移課題で 1-shot が教師あり Dynamic Head に匹敵するとされる。コードが公開された。大規模グラウンディングデータを用いた統一事前学習が検出の再定式化を支えた。規模主張は論文報告として扱う。GoldG の構成の詳細は根拠深度の確認に委ねる。[52]

文と画像を早期に融合させる言語条件づけの方式として、MDETR は自然言語クエリで DETR を条件づけ、言語画像の早期融合によりエンドツーエンドの条件付き検出器を構成したと論文著者が説明する。語句と対

象の対応データ 130 万対の事前学習により、Flickr30k の語句グラウンディングや RefCOCO 系列の REC や PhraseCut の参照セグメンテーションで到達点を示し、GQA や CLEVR の VQA でも競争力を持ち、少数例の長尾検出が可能とされる。コードとモデルが公開された。多課題を一つの調整構成で扱えるようになった。GLIP の大規模グラウンディングデータと統一事前学習による再定式化とは異なり、両者は重複ではなく別系統として保つ。早期融合の設計という契約で読む。[60]

密な融合を足さない最小構成の転移手順として、OWL-ViT が示された。OWL-ViT は標準 ViT と画像文対照事前学習にエンドツーエンドの検出ファインチューニングを組み合わせ、適応策と正則化で追加モジュールなしに検出へ適応すると論文著者が説明する。画像水準事前学習の規模とモデル規模が一貫して検出を改善し、強いゼロショットの言語条件づけ検出と 1-shot の画像条件づけ検出が可能とされる。コードとモデルが公開された。追加の構成要素なしの検出適応が可能になった。GLIP や MDETR の早期融合に対する後段融合の最小主義として対比される。最小主義は到達点の一つであって終点ではなく、拡張手順は OWL-ST 側の資料に委ねられる。[61]

グラウンディング学習と検出器を三つの明示的な構成要素で密に融合させる設計として、Grounding DINO が示された。特徴強化と言語誘導クエリ選択とクロスモダリティデコーダの三つの機構で密に融合し、DINO 検出器とグラウンディング学習を結合して検出とグラウンディングと説明文のデータで事前学習すると論文著者が説明する。検出器 DINO は技術的基盤として区別され、集合予測系の系譜に属する。COCO ゼロショット 52.5AP とされ、ここでのゼロショットは学習に検証区分を使わない論文定義である。ODinW ゼロショット平均 26.1AP が記録され、チェックポイントと推論コードが公開された。密な融合によるオープンボキャブラリー検出が実現された。GLIP の再定式とは契約が異なり、融合設計としての位置が保たれる。REC のゼロショット性能は今後の注目を要すると論文自身が述べており、言い切らない。[53]

人手ボックスなしの拡張をウェブ規模の自己学習で果たす手順として、OWL-ST と OWLv2 が示された。OWL-ST と OWLv2 は N-gram 機械ラベル空間と弱選

別と学習効率改善により、人手の希少ボックス注釈なしに LVIS-rare を 31.2 から 44.6%へ改善し、相対 43%とされると論文著者が説明する。希少区分の自己学習による拡張が果たされた。ただし未知の主張はラベル空間に依存し、機械と人手のラベル空間分析とともに数値を扱う必要がある。ウェブデータ依存が限界であり、条件結合を明示して利用する。コードとモデルを公開した完全オープン版のバリエーションとして提供された点も記録する。[62]

固定ラベルに縛られない密な予測を言語埋め込みで果たす方式として、LSeg によるセグメンテーションが示された。LSeg は文エンコーダのラベル埋め込みと Transformer の密な画素埋め込みを対照学習し、意味的に近いラベルが埋め込み領域を共有することで再学習や追加の学習データなしのゼロショット汎化を可能にしたと論文著者が説明する。固定ラベルのセグメンテーションモデルと競争力を持つとされる。起点の範囲であり、より広い統合は後述する X-Decoder で扱う。一方 OpenSeg はマスク提案を先行させる視覚グルーピング優先の OVS であり、語からマスクへの対応づけの前に提案を置くことで説明文規模の教師を利用し、PASCAL で LSeg を 19.9mIoU 上回るとされる。限定的なバリエーションであり、グルーピング品質への依存が残る。[63, 64]

汎用セグメンテーションと指示参照セグメンテーションを一般化デコーディングで統合する方式として、X-Decoder が示された。X-Decoder は疑似ラベルなしに汎用と指示参照のセグメンテーションと言語視覚課題を一般化デコーディングで統合し、7 データセット群のオープンボキャブラリーで到達点を示すと論文著者が説明する。一方 ODISE は凍結したテキスト画像拡散モデルと CLIP 識別基盤によりオープンボキャブラリーパノプティックセグメンテーションを行い、COCO 学習のみで ADE20K に 23.4PQ と 30.0mIoU、従来比 8.3 と 7.9 の改善とされる。拡散モデルのバックボーンとしての来歴ではなく、オープンボキャブラリーセグメンテーションに利用される表現としての役割に限定する。拡散内部表現の意味的まとまりは K-means 探索で示され、コードとモデルが公開された。拡散特徴への依存が限界であり、TS-002 との境界を保つ。[65, 66]

本節の系譜は、語句と領域の対応づけを担う Flickr30k Entities の領域語句対応データから、検出を語句グラ

ウンディングへ書き直す大規模グラウンディングデータ構築、検出器とグラウンディング学習を三段階で結ぶ密な融合へ進んだ。教師信号の構成と融合の位置と出力で系統が分かれる。すなわち ViLD の蒸留か GLIP の大規模グラウンディングデータ構築か、MDETR の早期融合か後段融合か、ボックスか語句グラウンディングかである。LVIS-rare の AP と語句グラウンディングの再現率を別指標で測り、画像水準のゼロショットや検索再現率とも混ぜない点が共通の規律である。希少区分の手順は利用ごとに明示し、ウェブ由来データへの依存という限界を条件づける。単一構成の勝利ではなく、粒度と代償の未解決を残す。P07A の画像全体のアライメント指標とは切り離して読む。[51, 57, 52, 60, 61, 53, 55]

画像と言葉の大規模対応づけが位置特定や密な転移へ

伸びることを示したのが SigLIP 2 の段階的手順である。キャプション生成と自己蒸留とマスク予測の組合せによる伸びが、RefCOCO のグラウンディングや OWL-ViT のオープンボキャブラリー検出で確かめられ、オープンボキャブラリーの知覚系譜への継承を裏づけると論文著者が説明する。段階レシピや NaFlex の詳細は P06 の範囲であり、ここでは転移の成立のみを扱う。一方 SAM 3 は言語と概念による指示を個体の検出とセグメンテーションと追跡へ直結させる後発のグラウンディング拡張である。単純な名詞句と画像例の正負ボックスと SAM 2 型の視覚クリックで指示し、存在トークンの分離が認識と位置特定を分ける。細粒度の領域外ゼロショットは弱く、長い指示表現は扱わず、映像の負担は対象数に線形という限定が述べられる。SigLIP 2 の詳細は第 6 節、SAM 3 の機構の詳細は第 3 節の範囲である。[45, 20]

### 本節の読解上の境界

未知の主張はラベル空間と手順に依存し、条件結合を明示して用いる。ウェブデータ依存が限界であり、画像水準の指標とは混ぜない。版や区分と抽出規則を切り離さない。REC のゼロショットは論文自身が今後の注目を要すると述べており、言い切らない。拡散特徴の利用はオープンボキャブラリーセグメンテーションの役割に限定し、生成側の機構には踏み込まない。[51, 54, 56, 57, 58, 59, 52, 60, 61, 53, 62, 63, 65, 55, 64, 66]

## 9 凍結した構成要素を保ち視覚と言語を接続する方式の世代交代

### BRIDGES

個別に事前学習した視覚エンコーダと大規模言語モデルをいかに一つの視覚言語モデル (VLM) として動かすか。凍結した言語モデルへの前置きから gated cross-attention による密な接続、二段階の起動手順、指示形式への変換、最小限の写像、合成指示集合、オープンデータによる接続へ至る経緯を、画像全体のアライメントと位置へのグラウンディング (grounding) の契約を分けてたどる。数値は各論文著者の測定に属し、条件の異なる評価と横並びで優劣をつけない。[67, 68]

出発点は、学習済みの自己回帰言語モデルを凍結したまま動かし、視覚エンコーダが作る連続埋め込みを前置き列として渡す構想だった。Frozen では、この前置きを受け取った凍結言語モデルが説明文生成や少数例からの学習、未知語の取り込み、画像とテキストが

交互に並ぶ事例からの質問応答や外部知識を要する応答をこなすと論文著者は述べる。入力画像と交互配置のテキスト、出力は言語モデルの生成文であり、学習対象は視覚側の写像に限られる。ただし論文自身がこの到達を概念実証の範囲に置く点が境界であり、多課題への拡張や学習集合の設計は後継の課題として残る。固定を崩さずに使える可能性を示した点に、この前史の位置がある。[69]

Flamingo は、別々に事前学習した視覚側モデルと言語側モデルを、gated cross-attention の密な層を明示的な構成要素として加えることで接続し、画像と映像を単一モデルで受け取れるようにした。学習には画像とテキストが交互に配置されたウェブ由来の集合を用いる。オープンエンドとクローズドエンドの質問応答や説明文生成を少数例条件でこなし、一部の評価では

課題別に調整した従来手法を 1000 倍規模の課題データなしに上回ったと論文著者は報告する。評価条件は論文が定めた少数例手順の範囲であり、条件の異なる数値と並べて優劣はつけない。論文自身の限定として、事前学習した言語モデルの弱さ、とりわけ言語の先取りに起因するハルシネーションを受け継ぐ点が明記され、診断を扱う節の言語先行分析へつながる。接続の形と交互配置学習と少数例評価と限界をそろえて読むことが、この事例の扱いである。[67]

BLIP-2 は凍結の節約を二段階の起動手順として定式化した。第一段階では画像エンコーダを凍結したまま Q-Former が表象学習を担い、第二段階では大規模言語モデルを凍結した方向へ生成学習を適合させる。Q-Former は学習対象のクエリが凍結した画像特徴に作用し、言語モデルが消費できるトークン列へ集約するリサンプラであり、単なる圧縮器ではない。学習可能パラメータを大幅に抑えながら視覚言語課題の従来値を更新し、ゼロショット VQAv2 の報告条件で Flamingo80B を 8.7 ポイント上回り、学習可能パラメータ数は 54 分の 1 だったと論文著者は測定として報告する。比較は同一報告内の著者測定であり、条件の異なる評価との優劣づけには使わない。画像からテキストへの指示追従に似た生成が現れた点も報告される。反面、二段階ゆえの計算負担と複雑さは残り、指示への調整は InstructBLIP と LLaVA に委ねられる。[68]

InstructBLIP は BLIP-2 の基盤に指示チューニングの整備を加えた。26 件の公開データセットを指示形式へ書き直し、指示文を読み取る構造の Q-Former で調整する。入力画像と指示文、出力は指示に沿った応答であり、教師集合の作り方が新規性の重心にある。13 件の held-out 集合すべてでゼロショット首位に立ち、BLIP-2 や規模で上回る Flamingo を超えたと著者らは測定として述べる。画像付き ScienceQA では調整後に 90.7%を示し、モデルはオープンソースとして公開された。held-in と held-out を分ける手順のもとで指示集合の構成が汎化を支える契約となり、多様な指示への追従という空白が埋まった。数値は held-in と held-out の手順の範囲に属し、手順の異なる評価と横並びで順位づけない。[70]

MiniGPT-4 は最小限の接続でどこまで組成的振る舞いが現れるかを確かめる文脈的事例である。BLIP-2 由来の ViT-G/14 と学習済み Q-Former は学習全期間

を通じて凍結され、Vicuna も凍結したまま保たれる。MiniGPT-4 自身が学習するのは、Q-Former 出力を Vicuna 空間へ変換する単一線形層だけであり、独自のクエリ選択や重い cross-attention は付加されない。クエリの処理は再利用される凍結 Q-Former の内部で完結する。二段階の選別、すなわち約 500 万件の短い説明対による位置合わせ事前学習と、手入れした数千件の詳述による仕上げが反復や断片化を抑える。Q-Former を外して ViT 出力を直接変換する形は主系ではなくアブレーション条件であり、AOK-VQA や GQA では主系とほぼ同等で、論文は高度な振る舞いに必須ではないと結論づける。3 層線形や Q-Former 自体の調整は劣るとされる。短い扱いに留め、接続の脆さの診断は評価側の記録に委ねる。[71]

LLaVA は教師集合の作り方を転換した。画像を見ないテキスト LLM（言語専用の GPT-4）が指示集合を記述し、画像側は多視点の説明文とボックス座標  $[x1,y1,x2,y2]$  の記号列へ変換して教師へ渡される。COCO 起点で 15 万 8000 件の固有例、内訳は会話 5 万 8000 件と詳述 2 万 3000 件と複雑推論 7 万 7000 件が生成され、人手は種となる少数例に限られると論文著者は述べる。視覚内容を言語モデル向け指示形式へ落とす手順がここで開かれ、機械生成の視覚指示追従集合が規模化の支えとなった。ボックスの記号は位置へのグラウンディングの代理をテキストで表すものであり、画像全体のアライメントとは別の契約として扱う。合成依存という性格は限界として残る。[72]

接続と更新範囲の線引きは段階ごとに厳密である。CLIP ViT-L/14 の視覚エンコーダと Vicuna は学習対象の単一 projection 行列  $W$  一枚で接続される。第一段階の特徴合わせでは視覚と言語をともに凍結し、学習対象は  $W$  だけとして CC3M 由来の約 59 万 5000 件を用いる。第二段階の指示調整でも視覚は依然として凍結のままであり、動くのは projection 層と大規模言語モデルである。視覚自体を最後まで動かす同時更新ではなく、系全体の end-to-end 表記は調整系と対比した系水準の呼称であり、構成要素水準の同時更新を指すものではない。測定では LLaVA-Bench で言語専用 GPT-4 参照に対する相対 85.1%、実環境画像で 67.3 対 BLIP-2 の 38.1、ScienceQA で単独 90.92%と GPT-4 併用 92.53%を論文著者は伝え、判定手順への依存とともに読む。知識・多言語・インターネット検索・高解像度知覚の限界は論文の限定事項として残る。[72]

Molmo と PixMo はデータの開かれ方を接続の条件へ繰り上げた。PixMo は密な説明文と自由形式の質問応答と指し出力 (pointing) と 4 種の合成集合から構成され、外部の視覚言語モデルを用いずに組み立てられたと論文著者は述べる。72B 規模の比較値は、論文が定めた学術ベンチマーク群と大規模な人間評価という二つの範囲に限って、Claude 3.5 Sonnet や Gemini 1.5 Pro や Flash を上回り GPT-4o に次ぐと著者ら自身の測定として示される。ここからモデル一般の優劣へ敷衍しない。MetaCLIP と OLMo による完

全オープン版も用意される。コードとモデルの重みとデータはいずれも公開されると論文は述べるが、コードの許諾と重みの許諾とデータの利用条件は別の区分であり、個別の第三者条件の全文確認は融合を扱う節の Molmo 2 側の記録に委ねる。対象は画像中心の v1 であり、動画の主張は Molmo 2 の記録で扱う。指し出力は位置へのグラウンディングを直接の出力とするもので、画像全体のアライメントとは別の契約である。[73]

### 本節の読解上の境界

この節を読む際の区切りは次の通り。end-to-end 表記は系水準の呼称であり、構成要素の同時更新を意味しない。数値は各論文著者の測定に属し、実環境での汎化は別根拠に委ねる。凍結した構成要素を再利用可能な基盤表現として保つ読みは TS-001 の効率の語彙を引き継ぎ、Qwen 系列の積み重ねが分業の持続を示す。再標準化の論点は解像度と融合を扱う節で扱う。[67, 68, 70, 72, 69, 71, 73]

## 10 画像と映像と音声トークン列へ変換する方式と費用の設計

### FUSION

画像と映像と音声をモデルが消費できるトークン列へ変換する過程をたどる。元の解像度の保持と切り出し、融合の深さ、時刻の対応づけ、問いに応じた選択的取得が、トークンとコンテキストの費用を左右する。ここでのネイティブは共通トークナイザではなく学習と統合の提供契約を指す。Qwen3-VL と Qwen3-Omni と InternVL3 と Molmo2 の論文数値は著者と開発元の自己報告、Gemini のカードとエージェント型映像の上限値は提供元とベンダーの報告、独立した第三者再現は未確認として区別する。[43, 74, 75, 76]

Qwen2.5-VL は前史として置く。一から学習した可変解像度対応の動的 ViT を基盤とし、ウィンドウアテンションにより本来の解像度を保ったまま計算負担を抑える。可変解像度と絶対時刻の符号化により、長時間の映像を秒単位の出来事特定とともに扱い、ボックスと点による位置の対応づけや構造化抽出を支えると論文著者は述べる。課題ごとの作り替えなしに計算機操作や携帯端末操作へ接続された点も伝えられる。固定解像度から可変解像度への転換と時刻の明示化がこの世代の寄与であり、性能の主張は Qwen3-VL 側の評価に譲り、本節では機構の系譜に範囲を限って数値の

優劣には立ち入らない。[77]

Qwen3-VL は三つの更新で前史の構成を置き換える。空間と時間を同時に扱う interleaved-MRoPE、複数層の ViT 特徴で視覚と言語の対応づけを強める DeepStack、T-RoPE を発展させたテキスト形式の時刻合わせがそれである。視覚エンコーダは SigLIP 2 (dense モデルの既定は SO-400M、2B・4B 規模は Large-300M) で、可変のネイティブ解像度入力と 2D-RoPE、大きさの補間を伴う絶対埋め込みを採用する。視覚から言語モデルへの写像は 2x2 の視覚特徴を 1 トークンにまとめる 2 層 MLP の merger が担い、DeepStack は三つの ViT 層から専用 merger で視覚トークンを射影し、残差接続で最初の三つの大規模言語モデル層へ加える。文脈長を余分に食わない点が要点である。dense モデルの 2B から 32B、Mixture-of-Experts (MoE) の 30B-A3B と 235B-A22B、指示調整版と思考版を取りそろえる。いずれも論文と開発元の自己報告の範囲であり、独立した第三者再現は未確認である。[43]

時刻合わせと学習手順が融合の中身を定める。映像の時刻は各時間パッチの直前に置くテキスト形式のタイムスタンプトークンとして符号化され、秒表記と時分

秒表記の両方で学習されるため多様な時刻表示を読み解ける。Qwen2.5-VL の絶対時刻の位置合わせを置き換えるもので、長時間でまばらになる巨大な時刻位置 ID や一様な多 fps 標本化を避け、わずかなコンテキスト増で映像の位置特定と密な字幕付けを狙う。事前学習は四段階で、S0 ではエンコーダと大規模言語モデルを凍結して merger のみ約 670 億トークン・長さ 8192 で学び、S1 で約 1 兆トークン・長さ 8192 の全パラメータ同時学習、S2 で約 1 兆トークン・長さ 32768 の長文脈学習、S3 で 1000 億トークン・長さ 262144 の超長適応を行う。言語能力保持のためテキストのみのデータを加えて学び、平方根重みづけでテキストとマルチモーダルに寄与をならす。トークン数と構成の数値は設定に依存し、評価の主張は著者と開発元の自己報告である。[43]

Qwen3-Omni は視覚とテキストから音声を含む入力側への拡張を担う。知覚を統一する Thinker-Talker の MoE を採り、音声エンコーダは一から作った AuT である。16kHz へ再標本化した 128 次元メルスペクトログラムを約 0.6B のアテンション機構付きエンコーダ・デコーダへ入れ、2000 万時間の教師あり音声で学習する。Conv2D で 8 分の 1 に間引き 12.5Hz 相当のトークン列とし、1 秒から 8 秒の可変窓で flash attention を用いる。事前学習 S1 では固定した大規模言語モデルのもとで音声と視覚のアダプタを先に学ぶ。時刻合わせは TM-RoPE で回転埋め込みを時間と高さ・幅へ分け、音声 80 ミリ秒ごとに一つの時間 ID を与え、映像フレームも実時刻で同粒度に刻み、方式間で連番とする。Qwen2.5-Omni の 2 秒固定チャンクに代えて絶対時刻 ID の直接対応づけで合わせる。理論上のコールドスタート初回パケット遅延は同時実行 1 で音声 234 ミリ秒・映像 547 ミリ秒と著者らは算出する。234 ミリ秒は理論値であり実運用の確約ではない。生成側の合成の詳細は TS-002 側に属し、本節は入力エンコーダと時刻同期とストリーミング入力の契約だけを扱う。[74]

音声入力の三つの系譜がオムニ統合の下地となる。Whisper は 68 万時間の多言語多課題の弱教師あり学習でゼロショット転移を示し、完全教師ありに匹敵して人間に近い頑健さに迫ったと論文著者は測定として伝える。役割は音声からトークンへの入力側契約に限られ、音声認識の範囲である。BEATs は音響トークナイザと音声の自己教師あり学習の反復同時最適化で

あり、再構成ではなくマスクされた離散ラベル予測で学ぶ。トークナイザは各周回で教師モデルの意味を蒸留し、AudioSet-2M で 50.6% mAP、ESC-50 で 98.1% と論文著者は測定として伝える。分類評価の範囲であり、融合の振る舞いはオムニ側の記録に委ねる。CLAP は言語音声のデュアルエンコーダの対照学習を 12 万 8000 対で行い、16 課題 8 領域のゼロショットと 5 件の教師あり到達を報告する。CLIP との対比は音声側の対応づけを開いた点にあり、規模の違いは後のオムニエンコーダが限定する。各数値は各論文著者の測定であり、手順の異なる評価と横並びで優劣をつけない。[78, 79, 80]

InternVL3 は段階的接続と対置される同時学習の対照軸である。テキスト用言語モデルへの事後的な付け替えではなく、マルチモーダルとテキストの単一段階同時事前学習で複雑さを解くと主張する。構成は ViT-MLP-LLM であり、InternViT-300M (1B から 14B 規模) や 6B (38B・78B 規模) と Qwen2.5 系列や InternLM3-8B を無作為初期化 2 層 MLP の射影で接合する。pixel-unshuffle で視覚トークンを 4 分の 1 にし、448 四方のタイルあたり 256 トークンとして可変解像度タイリングを複数画像と映像へ延ばす。可変視覚位置符号化 V2PE はテキスト 1 トークンに 1 ずつ、視覚 1 トークンに 1 未満の  $\delta$  を割り当て、学習時は画像ごとに  $\delta$  を集合から抽選し、推論時は系列長で選ぶことで、トークンを落とさずに位置予算を節約する。SFT は 1630 万件から 2170 万件ヘッセル・3D・GUI・長文脈・映像・図解・CoT を追加して育て、MPO は約 30 万対で選好・品質・生成の重みつき損失を学び、テスト時は VisualPRM-8B による Best-of-N を用いる。78B の MMMU72.2 は報告時点のオープン最高と開発元と著者の自己測定で伝えられる。1B から 78B のモデル群という数え方は規模の記述であり、人気の根拠にはしない。[75]

Molmo2 は位置特定で測る映像評価を持ち込む対照軸である。論文自身の三つの区分でオープンウェイトと蒸留なしのオープンデータとオープンコードを掲げる。8B 規模のモデル群は短尺映像や計数や字幕付けのオープンモデル群で先頭に立ち、長尺では競合すると論文著者は同一手順内の測定として伝える。映像計数 35.5 対 Qwen3-VL29.6、指さし出力 F1 で 38.4 対 Gemini 3 Pro20.0、追跡 J&F56.2 対 41.1 はいずれも同一手順内の著者測定であり、モデル一般の優劣へ

敷衍しない。他方で画像エンコーダには SigLIP 2 の非公開データを用い、データ生成にも非公開テキストモデルを用いたと論文自身が開示し、MathVista や MMMU の推論や 10 分超の長尺は遅れると認める。Qwen3 の基盤を 8B・4B 規模で再利用する点も開示され、依存の度合いは読み手が割り引いて読む。解像度処理は縮小した全体像に重なり合うタイリングを重ね、映像は毎秒 2 フレーム・上限 128 フレームで単一切り出しを並べる。接続部は ViT の後ろから 3 層目と 9 層目の特徴を 2x2 窓（映像は 3x3）でマルチヘッドアテンションにより集約し、テキストのタイムスタンプと交互に言語モデルへ渡す。学習は画像のみの軽い事前学習、映像・画像の同時 SFT、長文脈 SFT の三段階である。9 種の公開データ群と完全オープン版の Olmo 向けバリエーションを備える。[81]

非公開モデル側の到達点は能力と評価と提供形態の範囲で置く。Gemini 3.1 Pro は 100 万コンテキストでテキストと画像と音声と映像を入力し、MMMU-Pro と Video-MMMU の主張を方法論ページ付きで示すと 2026 年 2 月モデルカードの提供元測定で伝えられる。機構開示はなく、構成の根拠にはしない。Gemini 3.6 Flash は 2026 年 7 月カードのトークン効率寄りのネイティブマルチモーダルであり、効率寄りの比較軸である。ここでのネイティブは共通トークナイザを意味せず、複数モダリティを一つのモデルで受けて長期コンテキストで扱う提供契約を指す。いずれも提供元測定の手で扱い、版と日付で限定して読み、総合点として一括せず契約ごとに読む。独立した第三者再現は未確認である。[82, 83]

確認可能性はリポジトリ側の記録で支える。Qwen3-VL リポジトリは dense と MoE のエッジデバイスからクラウドまでの提供形態を示し、FP8 バリエーションや Transformers と vLLM 対応、指示調整版と思考版、視覚エージェント操作、2 次元と 3 次元の位置特定、25 万 6000 のネイティブコンテキストから 100 万への拡張をプロジェクト主張として記す。三つの構成要素の積み重ねはコードで確認できるが、モデルの重み自体が評価主張を自立させない。コードは Apache 2.0 であり、8B-Instruct のモデルの重みも確認済みカード範囲で Apache 2.0 の適用として束縛される。Qwen3-Omni リポジトリはストリーミング対応の提供内容と事例集を示し、Thinker のみ動作が文書化される。コードは Apache 2.0、30B-A3B-Instruct の重みは

確認済みカード範囲で Apache 2.0 であり、確認範囲を超える一般化はしない。README の宣伝的記述は構成の根拠とせず、公開リポジトリは版固定と日付で読む。[84, 85]

第二の系譜の開放性はモデルの重みとデータの提供で示される。InternVL リポジトリはモデルの重みと InternVL-Data の公開、1.0 から 3.5 までの報告系譜と論文対応、3.5-GPT-OSS 系の学習コード公開を確認できる範囲で示す。3.5 世代への言及は系譜注記に留める。公開範囲を超える提供内容までは確認できないため、本節の主張は公開リポジトリで確認できる範囲に留まる。molmo2 リポジトリはデータ準備と事前学習や SFT や長文脈 SFT、評価ツール群、vLLM 推論、チェックポイント変換、MolmoPoint 拡張をコード水準で確認する。コードの許諾は Apache 2.0 である。モデルの重みの許諾は別の区分であり、Molmo2-8B や O-7B の確認済みカード範囲で Apache 2.0 に束縛される。公開データ群の有無は第一者コレクションで確認できるが、個別第三者データの許諾文書と Source Attribution の中身は未確認であり、学習データの混合条件は学術・非商用の区分と手続き要の項目の範囲づけに留まり、個別文書の確認は後の確認課題として残る。[86, 87]

選択的取得がトークンとコンテキストの経済を変える。静止的处理は既定で毎秒 1 フレームをコンテキストへ一括投入し、音声は単一チャンネル毎秒 1 キロビットで秒ごとに時刻を付すため、速い動きの細部が落ちる場合がある。エージェント型理解は事前の全時間軸取り込みをやめ、推論とツールの循環で映像フレームと音声と書き起こしを質問ごとに必要な区間のみ取り寄せ、必要な区間の検索が費用を決める。モデルは目的に沿って何をどの速度でどのモダリティで見るかを決め、内部ツールで該当部分を読み込み、関心区間はフレームレートと解像度を上げて再標本化する。長尺条件で最大 88% 少ないトークン、標準映像分析評価で最大 66% 低い分析費用、3.7 Flash で最大約 7% 高い正解率は、いずれも提供元測定の上限であり、トークンと費用と品質の区分を区別する。短尺（5 分未満）では内部推論とツール往復で初回トークンまでの時間が延びる場合があり、静止処理が遅延重視の用途に残る。推論トークンは思考トークン、読み込み分はツール利用トークンとして数え、内容と取得方針で変動する。対象は蓄積済み投稿と YouTube の時間軸

であり、連続取り込みのオンライン状態ではない。診断としての意味は診断を扱う節、移動の契約としての

位置づけは移動の契約を扱う節に委ね、本節は機構とトークン経済と提供元測定の範囲を担う。[76]

### 本節の読解上の境界

この節の読解上の境界は次の通り。論文と開発元の数値主張は著者と開発元自身の自己報告であり、独立した第三者の再現を待つ。非公開モデル側の到達点と選択的取得の効率値は提供元とベンダーの報告で上限表示であり、版と日付で限定して読む。トークンと構成の数値は設定に依存する。コードの Apache 2.0 と確認済みカード範囲のモデルの重みの Apache 2.0 と公開データ群と混合物の第三者条件は別の区分であり、個別第三者データの全文は未確認である。生成側の合成詳細は扱わない。更新が続く資料であり、版と日付の対応づけを維持する。[43, 74, 78, 79, 80, 75, 81, 77, 82, 83, 84, 85, 86, 87, 76]

## 11 合成得点を属性ごとに分解し誤りの帰属を定める

### REASONING

合成得点を汎用知能の代理に置かず、知覚と言語の先取りと推論に分けて読む。MMMU を起点にポーリング方式と制御ペアと選択肢回転と視覚数学を区別し、scaffold（補助の手順）とツール利用の区別を添えて誤りの所在を診断する読み方を示す。判定への依存と混入の不透明さは条件として残す。[88, 89, 90]

この節では合成得点を知的能力一般の代理とはみなさず、視覚による知覚の分と、蓄えた知識で解く推論の分と、言語の癖で正答する分とを分けて読む。MMMU は大学の試験・小テスト・教科書から専門家が集めた 1.15 万の質問を、6 分野と 30 科目と 183 細分野、図表・ダイアグラム・地図や表・楽譜・化学構造を含む 30 種の画像型で組み立てた評価である。論文著者の測定では GPT-4V が 56%、Gemini Ultra が 59%とされ、余白が大きい。教科書のページ上の図表の読み取りと専門用語の知識とを混同せず、画像型ごとの振る舞いと組で見る。合成得点の高低を競わず、後のポーリング方式や制御ペアや選択肢回転の評価へつなげる見方を定める。閉じたモデルの学習データ混入の不透明さは条件として残し、汚染の有無を断定しない。[88]

POPE は物体のハルシネーションを体系的に問う最初の評価として、ポーリング方式の yes-no 形式の質問で安定した評価の道を開いた。現れやすい物や共に現れやすい対象がハルシネーションを生みやすいという所見は、言語と共起の偏りが知覚の判定に紛れ込む過程を示す。評価はポーリングの範囲に留まり、自由記述の忠実さまでは届かない。ポーリングの数値をそ

のまま忠実さ一般と読まない。判定の条件と質問の仕方を添えて読むことがこの評価の作法であり、制御ペアの評価への準備になる。[91]

HallusionBench は手作りの小さな規模を逆に生かし、言語の偏りによるハルシネーションと視覚入力を読み誤りとを区別する制御ペアの評価を築いた。165 枚の元画像と 181 枚の人間が編集した画像を合わせた 346 枚と、専門家が作った 1129 の質問から成り、画像なしでも答えられる質問と画像の読み誤りを誘う質問の対で、何が言語の偏りによるもので何が知覚の誤りかを区別する。著者らの測定では 15 モデル中 GPT-4V が 31.42%のペア正解率で、他は 16%に届かない。ペア正解率は厳しい指標であり、順位表ではなく診断として読む。誤りを一つの言語の偏りへ還元しないことがこの制御の要点であり、ポーリング方式の評価と組で読む理由である。小規模手作りという性格は限界として残し、一般化の主張には使わない。[89]

MMBench は 3000 を超える英語と中国語の選択式の質問を、20 の能力の観点と品質管理の下に組み立てた二言語の評価である。選択肢の回転に対する一貫性を求める CircularEval と、GPT-4 による選択肢の抽出が人手と 91.5%で一致することの確認とで、指示への追従が弱い場合の揺れを抑える。版の改訂を経た v1.1 と ECCV2024 の報告、VLMEvalKit への統合がこの評価の位置づけを示す。GPT-4 への判定の依存は点と切り離さず、二言語の範囲は英語と中国語に留まる。英語と中国語の評価範囲を超えた多言語の主張はしない。能力の区分ごとの読みを保ち、合成得点へ

直接還元しない。[92]

MathVista は 6141 例の視覚数学の質問を、28 のデータ群と新たに作られた IQTest や FunctionQA や PaperQA とで集めた評価であり、7 種の推論と 5 種の課題の掛け合わせで整理される。著者らの測定では GPT-4V が 49.9%、Bard が 34.8%、人が 60.3%とされる。知覚の誤りと推論の誤りとを分けるには、CoT や PoT（プログラムによる推論）やツール使用のアブレーション条件が要る。ツールの有無で何が変わったかを示さない限り、推論の伸びとは呼ばない。知覚の誤りと推論の誤りを混同しない姿勢が診断を支える。[90]

知覚に推論の補助を足す効果は、空間を扱う別の評価が区別する。VSI-Bench は 288 本の一人称映像と 5131 の質問を用い、配置と計測と時空間の三つの型に 8 課題を置き、MCA と MRA の指標と何も見ない条件との比較を備える。CoT を足すと下がり、認知地図を与えると上がるという scaffold（補助的手順）

の所見が報告される。記述は論文要旨の水準の確認に留まり、偏りを補正した部分集合の分析には踏み込まない。補助手順の効果はこの範囲に限定され、推論一般の到達とは呼ばない。素の知覚から補助手順の介入、ツール利用の知覚、誤りの帰属へ進む順序の第二段である。[93]

知覚を道具で助ける循環は、蓄積済み映像を問いに応じて探す第三の方式である。エージェント型理解は全時間軸の事前取り込みをやめ、問いごとの区間取り寄せと関心窓の取り直しで費用を変える。効率値（長尺で最大 88% 少ないトークン等）は提供元測定の上限であり、対象は蓄積済み投稿と YouTube の時間軸に限る。自律的推論一般の根拠でも、オンライン状態の根拠でもない。ツール利用の有無を区別するアブレーション条件なしに推論の伸びとは呼ばない。素の知覚から補助手順を経て道具利用へ至り、誤りの帰属を定める第三段である。トークン経済の詳細は機構と経済を扱う節、移動の契約としての位置づけは移動の契約を扱う節に委ね、本節は診断の意味だけを担う。[76]

### 本節の読解上の境界

本節の読解上の境界：合成得点を汎用知能の代理としない。ポーリング方式の範囲、制御ペアの厳密さ、判定依存と二言語の範囲、アブレーション条件の不足を条件として残す。補助手順とツール利用の効果は範囲を限定して読む。閉じたモデルの学習データ混入の不透明さは条件として残す。[89, 88, 91, 92, 90]

## 12 短尺分類から長時間保持と選択的取得までの契約の分離

### VIDEO

短い分類から順序と一人称と長尺へ進み、オフラインの広さとオンラインの状態と蓄積済み時間軸の選択的取得を分けて読む。ストリーミング中の質問と記憶の方式を区別し、数値は契約ごとに読む。因果や物理の推論、出来事の位置特定、音と映像の理解は選定された評価と仕組みの記録の範囲で扱い、対象外の網羅には広げない。[94, 95, 96]

Kinetics は 400 の行動カテゴリに 400 本超の 10 秒断片を集め、分類の規模と比較の基準を作ったデータ群である。時間的な位置を切り出す課題ではなく、分類の課題として設計され、大規模に一から学習することと構成の比べ合いに使われ、不均衡の偏りの分析を伴う。読みの境界として、短い断片の分類の範囲に留まり、時間の順序や因果や物理の理解は後継研究の根拠

に委ねる。切り取られた振る舞いの見分けが到達であり、長い時間の状態の理解ではない。[97]

Something-Something V1 は 10 万 8499 本の群衆実演動画を 174 種の雛形カテゴリへ分類するデータセットである。物体操作の時間的な進行を区別する必要がある、静的な外観だけでは捉えにくい時間順序への感度を評価する。雛形の範囲での扱いに留め、短い振る舞いの分類を超える時間の推論一般の主張はしない。Kinetics の分類の広さと比べると、時間順序への感度が要点になる。[98]

Ego4D は 931 人の装着者が 74 の場所と 9 の国で暮らしの中で撮った 3670 時間の一人称視点の映像を、同意と匿名化の手続きと組で記録した資料である。音声と 3D メッシュや視線やステレオや複数カメラの部分

集合を備え、出来事の記憶や手と物の関わりや音と映像の会話や未来の予測を、過去と現在と未来の課題群として用意する。読みは資料の範囲に留まり、仕組みの主張は別の根拠が担う。一人称の長さとは多様さは実環境での適用を考える材料ではあるが、この資料だけをもって仕組みの到達とは呼ばない。[99]

Video-MME は 900 本と 254 時間と 2700 の質問を、6 領域と 30 細分野と 11 秒から 1 時間の長さの幅で組み立てた広範な動画理解評価である。字幕と音声のモダリティと専門家の注釈を備え、画像と言語のモデルにも映像と言語のモデルにも適用される。論文著者測定 of v3 では商用で最良の Gemini 1.5 Pro が平均 75% で GPT-4o の 71.9% を上回るとされる。読みはオフライン長文脈の広さの契約であり、ストリーミングを受け続ける状態の契約とは別の評価軸に置く。商用の数値は論文著者の測定であり、版と日付と出所と切り離さない。[94]

LongVideoBench は 3763 本の映像と字幕に 6678 の人手の選択式の質問を集めた長尺の評価であり、17 の細かなカテゴリで整理される。長い文脈のうち指示された部分を取り出して推論する referring reasoning が要点であり、取り出しと推論を分けて測る。報告の所見は、フレームを増やして初めて検索と推論が伸びるというフレーム数への敏感さであり、将来の長文脈のモデルへの位置づけを示す。契約は指示された文脈の取り出しであり、長さの広さだけを測る評価とは取り替えない。[100]

StreamingBench は 900 本と 4500 の質問と 18 課題を、実時間の視覚と言語、音声を含む方式、対話と能動応答を含む文脈の三つの区分で組み立てた包括的なストリーミングの評価である。ストリーミングの途中で時刻を打った質問を置き、途中の応答を問う。著者らの測定では最良の Gemini 1.5 Pro が 67.07% で人が 91.66% とされる。契約はオンラインの途中の質問であり、オフライン長文脈とは別の評価軸に置く。多くのモデルはオフライン変換で測られており、真のオンラインの仕組みの点は Flash-VStream 側の記録が担う。[95]

Flash-VStream は人の記憶の仕組みに倣い、極めて長いストリーミングを受けながら時間的な状態を保ち、非同期の質問に同時に答える映像と言語のモデルである。遅延と VRAM の大幅な削減が論文著者の報告として伝えられ、オンライン問答用の VStream-QA を

伴い、オフラインの評価での適用の広さの確認を添える。限りある記憶と状態管理と遅延や記憶量の折り合いがこの仕組みの要点であり、オンライン入力と上限つき記憶と持続状態と遅延・記憶量の折り合いの到達点として置く。数値は論文著者の報告に留まり、それを超える運用の数値は未確定として残す。指示付きセグメンテーションの記憶構成は構成上の参照点に留め、実運用時の遅延は本節の対象外とする。[96]

空間の理解を助ける手順の効果は、VSI-Bench が 288 本の一人称映像と 5131 の質問で示す。CoT を足すと下がり認知地図を与えると上がる所見は、補助手順の区別が本節の時間契約とは別の評価軸にあることを示す。記述は論文要旨の水準の確認に留め、偏りを補正した部分集合の分析には踏み込まない。診断の意味づけは診断を扱う節に委ね、本節は映像側の配置として置く。[93]

Agentic Video Understanding は蓄積済み動画と YouTube の時間軸を問いに応じてたどる第三の契約であり、オンラインのストリーミングを受け続ける状態とは別の評価軸に置く。静止処理（既定で毎秒 1 フレーム・単一音声チャンネル毎秒 1 キロビット）では速い動きの細部が落ちる場合があり、道具利用の処理は問いごとの区間取り寄せと関心窓の取り直しで費用を変える。長尺で最大 88% 少ないトークン等の効率値は提供元測定の上限である。対象は蓄積済みの時間軸であり、連続取り込みも上限つきストリーミング記憶も途中質問への非同期応答も持たない。機構と経済の詳細は機構と経済を扱う節に委ね、本節は移動の契約としての位置づけを担う。[76]

SAM 3 は概念プロンプトに基づく動画内の検出・セグメンテーション・追跡を扱い、記憶に基づく追跡器によって時間方向の対象対応を維持する。DETR 流の画像検出器と記憶型の映像追跡器が一つの知覚エンコーダを共有し、存在トークンの分離が認識と位置特定を分ける。指示は単純なテキスト名詞句と画像例の正負ボックス、SAM 2 流の視覚クリックであり、新規性は言語グラウンディング (grounding) の概念接点にあるとされる。細粒度の領域外ゼロショットは弱く、長い指示表現は扱わず、映像の負担は対象数に線形という限定が述べられる。これは映像の時間的グラウンディングと追跡の補助例であり、蓄積済み時間軸を問いに応じて取得する契約とは別の契約である。両者を同一の取得契約へ畳まない。[20]

### 本節の読解上の境界

本節の読解上の境界：短い断片の分類と資料の範囲を超える主張はしない。商用の数値は論文著者の測定であり、版と日付で限定して読む。真のオンライン体系の評価は別の資料に委ねる。空間評価の記述は論文要旨の水準に留まる。効率値は提供元測定の上限である。SAM 3 の時間的グラウンディングと問いに応じた取得の契約は別の契約として読む。[99, 95, 96, 97, 98, 94, 100, 93, 76]

## 13 操作の成否と位置特定を分け、長時間の状態保持を問う

### COMPUTER USE

Computer Use ではスクリーンショットから要素を座標に対応づけるグラウンディングが起点になる。ただし作業全体の成否と純粋な位置特定は別の評価契約に属する。vision-only の座標特定と高解像度の専門評価を挟み、OSWorld 2.0 は制約追跡と途中到着情報の扱いへ論点を移す。[101, 102]

実 OS 上で動作するエージェントを測る前提が欠けていた。OSWorld は Ubuntu と Windows と macOS にまたがる実 OS 環境を整え、369 件の作業を実在のウェブとデスクトップ応用、ファイル入出力、複数応用にまたがる手順として用意し、作業ごとの設定と実行結果で判定する評価スクリプトを備えた。観察の契約はマウス位置と形状を含む完全なスクリーンショットに、XML 形式のアクセシビリティツリーとターミナル出力を含む補助ストリームを加えた形であり、スクリーンショットのみ、ツリーのみ、併用、Set-of-Marks の条件が比較された。行動の契約は moveTo や click や write や press や hotkey や scroll や dragTo を含む pyautogui のコード行動と、構造化された COMPUTER\_13 の行動空間であり、文法として正しいコード予測と手続き構造への組合せが求められる。人間が 72.36% に対し最良モデルが 12.24% という結果は、GUI 要素のグラウンディングと操作知識が隘路であることを示した。論文著者による測定に属し、NeurIPS 2024 の報告とコードと環境の公開が裏付けの範囲である。[101]

この帰結がもたらしたのは、クリック精度の向上だけでは作業成功に届かないという切り分けである。スクリーンショット観察とツリー観察と構造化行動の組合せが明示的な構成要素として整理され、後の比較はどの入力を入れ、どの行動空間で出すかという入出力の契約で読めるようになった。限界として残るのは手順の長さであり、短い作業の範囲では操作と符号化の正

確さが主因に見えるが、制約を保ちながら進む長い作業の負荷はこの資料だけでは測れない。後継の長時間評価への継承は、観察と行動の契約定義が再利用可能な基盤表現として引き継がれる点にある。評価専用の範囲を超えて方策一般の主張には広げず、ウェブ段階の先行は文脈に置く。数値は条件に結びつけて読み、条件の異なる測定で順位づけしない。[101]

短い手順の成否では見えない欠落が残っていた。OSWorld 2.0 は中央値で 1.6 人間時間に相当する 108 件の長時間ワークフローを用意し、ストリーミング的な相互作用、動的に変わる環境、複数出所にまたがる推論、暗黙の状態の推定、視覚と空間に関わる精密さという現象を課題化した。真正な成果物と状態をもつ利用者プロファイルと安全性の監査記録を備え、失敗の重心が GUI 操作や符号化から、制約追跡、作業途中の情報到着への対応、暗黙状態からの回復、検証省略へ移るという主張が立てられた。1.0 のグラウンディング契約に対し、2.0 は長時間の状態管理契約に属し、別の列として扱うことが本節の規律である。安全性の監査は評価の付随情報にとどめ、方策の安全性一般には広げない。[102]

相互作用の長さを示す事実として、Claude Opus 4.7 を最大思考設定と単一行動設定で動かした場合に 108 件平均で 318.4 回のツール呼び出しが生じ、OSWorld 1.0 側の約 30 回と桁が異なることが論文著者により報告されている。この回数は相互作用の地平と状態管理の負荷を示す代理としてのみ用い、トークン数、コンテキスト利用、KV キャッシュやメモリ負荷、遅延、計算コストの直接測定には読み替えない。トークンや記憶や遅延の主張は、対応する効率項目を直接測った根拠がある場合にのみ述べる。500 ステップ構成の別条件では Claude Opus 4.8 を最大思考とバッチ処理で動かした結果が二値で 20.6%、部分成功で 54.8%、呼

び出し回数 481.8 回、GPT-5.5 はトークン効率型の頭打ちとして約 13%という論文著者の測定が報告されている。比較はモデルと思考とツールと手順と公開版を一体にして読み、版と日付の結合を外さない。[102]

作業成功の前に位置特定だけを取り出す診断が欠けていた。SeeClick と ScreenSpot はスクリーンショットのみのエージェントが要素の位置特定で詰まることを診断し、グラウンディングの事前学習と自動収集の手順を整えた。ScreenSpot は 600 件超のスクリーンショットと 1200 件超の指示をモバイルとデスクトップとウェブにまたがって集め、テキストとアイコンやウィジェットを対象に純粋な位置特定の契約を定めた。位置特定の精度向上が MiniWob や AITW や Mind2Web のエージェント作業へ転移することが示され、要素のグラウンディングと作業成功の列が分けられた。ACL 2024 の報告であり、モデルとデータとコードの公開が裏付けの範囲である。限界として ScreenSpot-Pro 級の高解像度専門課題は別資料に委ねられ、未査読の後継を本節に取り込まない。[103]

ツリーや DOM に頼らない座標特定の経路が欠けていた。UGround は 130 万枚のスクリーンショットから得た 1000 万要素のウェブ合成によるグラウンディング学習手順で訓練された汎用のスクリーンショットグラウンダーであり、画像のみの入力から画素行動へ出すインターフェースの転換を示した。アクセシビリティツリーや DOM の道具立てに対する vision-only の対置が技術的に区別される点であり、SeeAct-V 級の文脈は独立節ではなく界面の文脈として畳まれる。帰結として、ツリーが取れない画面でも座標特定が可能な経路が得られた。限界としてウェブ合成の領域に由来する偏りが残り、実 OS 上の長時間状態は OSWorld

側の資料に委ねられる。エージェント方策の主張はこの資料を根拠にしない。[104]

切り抜き中心の易しい位置特定では測れない欠落が残っていた。ScreenSpot-Pro は全画面の作業で面積比 0.07%級の微小対象を扱う専門性の高い高解像度グラウンディング評価であり、切り抜き課題とは別の契約に属する。計画に導かれるカスケード型の推論時探索の契約が方法文脈として畳まれ、粗い位置から細部へ絞る手続きが評価条件に含まれる。帰結として、専門画面での微小要素の扱いが測定可能になった。限界として評価専用の範囲に属し、エージェント方策の主張は OSWorld 側の資料を要する。後継の評価が増えても本節の版固有性を保ち、条件の異なる数値を混ぜて順位づけしない。[105]

五件を通して読むと、入力側の観察と出力側の行動空間の組合せが系統的に変わってきた。OSWorld は完全なスクリーンショットとツリーとターミナル出力を入れ、pyautogui と COMPUTER\_13 で出す。UGround と SeeClick 系は画像のみから座標へ出す vision-only の契約に絞り、ScreenSpot と ScreenSpot-Pro は作業成功から位置特定精度を分離した評価契約に絞る。OSWorld 2.0 はその上に長時間の状態保持を載せ、ツール呼び出し回数の増大を状態管理負荷の代理として読む。1.0 のグラウンディング契約と 2.0 の状態管理契約を混ぜず、呼び出し回数をトークンやコンテキストや KV キャッシュや遅延の直測に読み替えないことが本節の境界である。CoT の有無やバリエーション条件を変えた場合のアブレーションは条件つきで読み、ページ上の座標と作業全体の成否を同一指標に混ぜない。[101, 102, 103, 104, 105]

### 本節の読解上の境界

本節は汎用エージェント構成の調査に広げない。短い手順と長い手順の評価は別の契約であり、数値はモデルと思考設定とツールと手順数と公開版に結びつけて読む。ツール呼び出し回数は相互作用の地平と状態管理負荷の代理にとどめ、トークン数やコンテキスト長や KV キャッシュやメモリ負荷や遅延や計算コストの直接測定には用いない。安全性の監査は評価の付随情報であり、方策一般の主張には用いない。[101, 102, 103, 104, 105]

## 14 計画の分離から行動の符号化と生成へ

### VLA

言語モデルを計画側に置く分離から、視覚と言語と行動を一体に扱う表象と離散トークン化へ進み、連続生成と周波数空間の符号化が行動インターフェースの分岐を作る。実機の実証とデータ契約を軸に読み、独立評価の不足を残す。[106, 107]

言語の知識と身体の技能をどう結ぶかが定まっていなかった。SayCan は凍結した LLM の意味知識を Say とし、事前学習済み技能の affordance 値関数を Can として掛け合わせ、LLM をプランナに、ロボット技能を手足と目に割り当てた。実機の移動マニピュレータによる 101 件の台所作業で、グラウンディングが非グラウンディング条件のほぼ 2 倍に達することが示された。言語と行動の対応づけを計画側に置く分離が転換の核心であり、一体の表象学習には踏み込まない点が境界である。CoRL 2022 の論文著者による測定に属し、後の一体表象との対比で PaLM-E 側の変化が読み取れるようになる。[108]

軌道を条件づけて学習できる実機データの土台が欠けていた。RT-1 は実ロボットの多様な実演を課題非依存に集め、高容量アーキテクチャで吸収し、データとモデルと多様性の関数として汎化を実機で調べた。政策機構の詳細ではなくデータ範囲の主張に属する。Open X-Embodiment は 22 台のロボットと 527 技能と 16 万件超の作業を 21 機関から集めた標準化された cross-embodiment のデータ契約を定め、RT-X 級の高容量モデルが機体をまたぐ転移で複数のロボットを改善することを示した。異なる機体にまたがる学習という契約が新たに計算可能になった点が継承の核心である。いずれも操作対象はマニピュレーション領域に属し、方策の主張は RT-2 側の資料に委ねられる。[109, 110]

計画と言語と知覚が別々のままでは、視覚と言語の知識を身体の判断に直接使えないという隘路があった。PaLM-E は連続したセンサモダリティである視覚と状態推定を、交互に挿入したマルチモーダル文として LLM へ入れ、操作計画と VQA とキャプション生成にまたがって端から端まで学習した。凍結から一体学習への移行という訓練形態の変化が機構の核心であり、

視覚エンコーダと LLM を別々に事前学習して接続する構成から、身体の文脈を含む文を一体で扱う表象へ変わった。562B 規模ではテキスト LLM としての言語能力を保ちながら、インターネットの視覚と言語とロボットの領域間で正の転移が生じることが示された。視覚入力から行動出力までを一つのモデルで扱う一体性が、この系譜の分岐点である。[106]

帰結として PaLM-E-562B は汎用の視覚言語の側でも OK-VQA 級の課題で強い結果を示し、言語能力の保持と身体課題の両立が確認された。すべて論文著者による測定に属し、562B 級の共同学習は費用と複雑さの点で再現可能性を限定する。限界として運動学や動力学や歩行やハードウェアや移動や安全方策の中身には踏み込まず、表象と行動の界面に限定する。継承は一体のマルチモーダル文という定式が RT-2 の行動トークン化へ受け継がれる点にある。SayCan の計画分離との対比で、一体表象の変化が明確になる。数値の横並び順位づけは行わず、条件付きの報告として読む。[106]

ウェブ規模の知識を身体の出力にどう接続するかが欠けていた。RT-2 はウェブ規模の VLM をロボット軌道とインターネットの視覚言語課題で共同ファインチューニングし、行動を言語と同じ形式のテキストトークンとして表す VLA 定式を示した。観察から行動への写像を単一の端から端までのモデルで扱い、6000 試行の評価で新規物体や数や図形配置を含む未見指示への汎化の萌芽が報告された。離散的で言語的な行動トークンという界面が転換の核心であり、画像と言語の対応づけを身体の出力へ拡張した点の変化である。定式の役割に限定され、実運用の評価範囲は端点側の資料に委ねられる。すべてモデル論文著者による測定に属する。[107]

閉じた大規模 VLA の結果を検証できる開かれた実装が欠けていた。OpenVLA は Llama 2 に DINOv2 と SigLIP を融合した視覚エンコーダを組み合わせた 70 億パラメータの VLA を 97 万件の実演で学習し、複数の機体にまたがる 29 件の作業で閉じた RT-2-X の 550 億パラメータを成功率で 16.5 ポイント上回り、7 分の

1 の規模で新規作業への効率的ファインチューニングと複数作業の汎化を示したと論文著者が報告した。オープンウェイトにより群衆の評価が可能になった点は継承であるが、このカードが結びつける独立したベンチマークはなく、独立評価の不足は G01 として残る。調整効率の主張は論文報告の域であり、独立した第三者再現とは区別する。著者であるモデル開発者自身の測定を独立再現に読み替えない。[111]

離散トークンとは別の行動界面が欠けていた。pi-zero は PaliGemma の VLM 基盤に 3 億パラメータの flow-matching 行動エキスパートを組み合わせた 33 億規模で、地平 H=50 の連続行動チャンクを出力する契約を示した。条件つき flow-matching のベクトル場を 10 段階の Euler 積分で解き、時間的アンサンブルを用いない開ループのチャンク実行を採る。制御周期は機体依存であり、UR5e と Franka では 20Hz、その他の評価機体では 50Hz、再推論は 20Hz 機で 16 行動後、50Hz 機で 25 行動後に行われ、地平と周期と再計画周期は別の量として区別される。FAST は高周波行動で次元ごと時刻ごとの離散化が破綻する欠落に対し、離散コサイン変換による周波数空間表現と分位正規化と BPE-1024 で可逆な符号化を示し、50Hz で最

大 13.2 倍の圧縮と 1 チャンクあたり片腕約 30 トークンを報告した。拡散同等の性能を 5 分の 1 の GPU 時間で得る一方、チャンクあたり約 750ms と 100ms の推論速度差が残る。いずれも論文著者の測定であり、静止マニピュレータの評価範囲に属し、代替圧縮や FAST と拡散の併用の未検証が残る。[112, 113]

実運用形態の上限を示す記録が欠けていた。Gemini Robotics 2 は両腕から全身のヒューマノイドまでを対象にした VLA と、実世界の理解と多段階計画を担う embodied 推論モデル ER 2 と、端末実行の効率型 VLA である On-Device 2 の分業を製品形態として示した。いずれも提供元であるベンダーによる測定に属し、機構開示はなく、遅延や価格やトークン量の事実は公開されていない。On-Device 2 のモデルカードはテキストと画像と固有受容を入力し行動を出力する端末 VLA を記し、場面と指示と行動の汎化を模擬と実機で評価したと述べるが、分布外汎化と高自由度制御の限界、両腕中心の安全範囲、階層安全の推奨がカード範囲の条件として残る。カードは更新されうるため版と日付に結びつけて読む。計画と方策の分業は能力段階の区別であり、機構の断定には用いない。[114, 115]

### 本節の読解上の境界

本節は運動学や動力学や歩行やハードウェアや移動や安全方策の中身に踏み込まない。データ契約の主張と方策の主張を混ぜず、調整効率の主張は論文報告の域として扱う。独立評価の不足は G01 として残し、モデル論文著者自身の測定を独立した第三者再現に読み替えない。非公開モデルは提供元の能力範囲に限り、機構や遅延や価格やトークン量を断定しない。CoT を用いた条件では思考条件を明示し、アプレーション条件やバリエーションの違いを混ぜない。[108, 109, 106, 110, 107, 111, 112, 114, 115, 113]

## 15 予測と生成を四つの極で切り分ける

### WORLD MODELS

歴史的定式と潜在ダイナミクスと非生成的予測と生成的対話環境を四つの極として並べ、状態と目標と条件づけと画素や潜在や報酬と用途の違いで読む。概念の類似と資料に裏づけられた継承を分ける。[116, 117]

環境の模型を学習するという方向づけ自体が欠けていた。World Models は教師なしで圧縮した時空間の表現を VAE と RNN で学び、想像した潜在軌道の内部で方策を訓練して実環境へ戻す手順を示した。対話版も公開され、夢の中での訓練という定式が後の議論に

用語として受け継がれた。ここで得られたのは歴史的な定式のアンカーであり、後の Dreamer 系の潜在ダイナミクスと決定の枝、JEPA と V-JEPA 系の予測表現の枝、Genie 系の生成的対話環境の枝を束ねる来歴の起点ではない。いかなる方向にも直接の技術的祖先関係は主張せず、Ha 2018 から Dreamer や Genie への直接継承は述べない。概念の類似を継承に読み替えないことが本節の境界である。用語史の掘り下げには広げない。[118]

潜在で先を読む決定の一般手順が欠けていた。DreamerV3 は RSSM のワールドモデルと想像に基づく方策改善を正規化と均衡化と変換の頑健化と組み合わせ、単一設定で 150 件超の作業にまたがって専門手法を上回り、人間のデータやカリキュラムなしに Minecraft でダイヤモンド収集に至ったと論文著者が報告した。視覚の忠実さではなく作業収益の伸びがこの極の証拠であり、制御に使える尺度と画像の見た目の尺度を混ぜないことが崩壊を防ぐ条件である。限界として強化学習ベンチマークの範囲に属し、視覚忠実度の読みには用いない。継承は潜在ダイナミクスと模型内決定という枝に属し、生成的環境の枝とは別の極として保つ。[119]

生成せずに予測する自己教師あり学習の経路が欠けていた。I-JEPA は単一の文脈ブロックから目標ブロックの表現を予測する非生成的な画像の自己教師あり学習を示し、意味的規模の目標と分散した文脈を設計の鍵とした。ViT-H/14 を ImageNet で 16 枚の A100 により 72 時間未満で学習し、線形評価や数え上げや深度の転移で生成的先行より少ない計算で強い結果を示したことが論文著者により報告されている。画素を再構成せず表現を予測する点が機構の核心であり、再利用可能な基盤表現としての性格が強い。限界として画像側の極に属し、動画への継承は V-JEPA 側の資料に委ねられる。崩壊を防ぐ条件として、再構成の有無と評価が凍結 probe であることを明示する。[116]

動画で同じ予測の規律を保つ経路と、行動条件づけへ進む経路の区別が欠けていた。V-JEPA は事前学習済みエンコーダもテキストも負例も再構成も用いない特徴予測のみの動画の自己教師あり学習を 200 万件の公開動画で示し、凍結した基盤の転移で K400 が 81.9、SSv2 が 72.2、IN1K が 77.9 に達したと論文著者が報告した。拡散の画素デコーダはエンコーダ凍結の事後的な接地 probe にすぎず、生成的デコーダなしの凍結評価がこの極の証拠である。V-JEPA 2 と V-JEPA 2-AC は同一極内の移行として、VideoMix22M の 100 万時間超での行動なし JEPA 事前学習と、62 時間の DROID での凍結エンコーダ上の行動条件つき 300M 級予測器の事後学習と、MPC のエネルギー最小化と CEM の後退地平制御による画像目標の計画利用を加え、Franka へのゼロショット実証を示した。EMA 教師とマスク予測と凍結 probe の手順は受け継がれるが、3D-RoPE の安定化と規模と行動条件づけと計画

利用と VideoQA 向け配列が新規である。画像目標のみで言語目標は将来課題、RGB のみ推定によるカメラ位置鋭敏性、長期展開の誤差蓄積によるサブゴールの必要、台所の閉じた語彙という条件が残る。[120, 121]

行動で操作できる生成的環境そのものが欠けていた。Genie はラベルなしインターネット動画で学習した 110 億パラメータの生成的対話環境であり、時空間トークナイザと自己回帰ダイナミクスと拡張可能な潜在行動モデルを組み合わせ、真の行動ラベルなしにフレーム単位の行動制御を可能にした。未見動画からの模倣でエージェントを訓練できる点が機構の核心であり、基盤的なワールドモデルの主張が立てられた。すべて論文著者の測定に属し、教師なし動画の範囲に属する。限界として制御粒度の主張は Genie 3 側の資料に委ねられる。継承是对話的生成という枝に属し、潜在ダイナミクスや予測表現の枝とは別の極として保つ。画素の忠実さと制御可能性を同一指標に混ぜない。[117]

実時間の対話世界の上限を示す記録が欠けていた。Genie 3 はテキスト指示から毎秒 24 フレームで 720p の対話世界を分規模の一貫性と 1 分規模の視覚記憶で生成し、指示可能な世界イベントと SIMA 版の互換実行をうたう。5 件の提供元による限定、すなわち行動空間の限定、複数エージェントの未解決、実地の非対応、条件つき文字描画の限界、分規模持続の上限が明示されている。いずれも提供元であるベンダーによる測定に属し、アーキテクチャ非開示のため能力と提供形態の記録に限る。独立したダイナミクス利用の評価は G02 として残る。製品形態の記録は別位置づけの資料と重ねて結びつけ、版と日付を外さない。NeRF や 3DGS との対比は提供元の枠組みとして帰属つきで引用し、採用しない。[122, 123]

四つの極を通して見ると、状態と目標と条件づけと画素や潜在や報酬と用途の違いが明確になる。歴史的定式は想像した潜在環境での学習という定式のアンカー、潜在ダイナミクスは報酬に結びつく模型内決定、予測表現は生成せず表現を予測する再利用可能な基盤、生成的環境は行動で操作できる対話生成という用途に分かれる。各極の崩壊防止条件は、歴史定式を直接祖先にしないこと、潜在系を視覚忠実度で読まないこと、予測系を生成的復号の有無と凍結評価で読むこと、生成系を制御粒度と独立評価の不在で読むこと

である。概念の比較と資料に裏づけられた継承を分け、似ていることと受け継いだことの区別を保つ。V-JEPA から V-JEPA 2 への同一極内の移行のみが行

動条件づけの継承として認められ、他の極またぎは並立として残す。[118, 119, 116, 120, 117, 122, 123, 121]

### 本節の読解上の境界

本節は歴史的定式を後続の直接祖先とは読まない。用語来歴の掘り下げに広げず、概念の類似を継承に読み替えない。制御に使える生成世界の共有測定は G02 として残し、提供元的能力上限の記録は独立測定を伴わないものとして扱う。画素の忠実さと作業収益と凍結 probe の転移を同一指標に混ぜない。[118, 119, 116, 120, 117, 121, 122, 123]

## 16 何をどの条件で測ったかを分けて読む

### MEASUREMENT

課題ごとの評価契約を先に定め、モデル論文著者自身の測定と提供元ベンダーの測定とベンチマーク論文著者による第三者測定と独立した第三者再現を分けて読む。教師信号と界面とトークンと来歴の四つの軸で横断し、群をまたぐ順位づけをしない。[124, 89, 55]

測定の読み方を先に定める。同一の数値でも測り手が違えば意味が変わる。本節は測定の出所を四つの役割に分ける。第一はモデルや開発者自身による自己評価であり、OpenVLA の論文著者が OpenVLA を測る場合が該当する。第二は提供元やベンダーによる測定であり、モデルカードの数値が該当する。第三はベンチマーク論文著者による第三者測定であり、Video-MME の著者が Gemini を測る場合が該当する。第四は独立した第三者再現であり、いずれの利害からも離れて条件を再現する測定である。bare の著者報告を独立再現に読み替えない。LVIS のレア分割のように評価手順が定める契約と、OCR Bench v2 のように私的集合で汚染規律を定める契約を例に、数値は版と構成と判定とツールと予算に結びつけて読む。群をまたぐ順位表は作らない。[89, 55, 124]

文書と図表の測定で認識と位置特定の分離を示す錨が欠けていた。OCR Bench v2 は 23 課題と 31 場面と 1 万件の検証済み設問と 6 種の指標に 1500 枚の私的集合を備え、公開と私的で傾向が一致することで汚染への規律を示した。5 種の限界区分を備え、認識できても位置特定できない隔たりが核心である。InternVL3-14B で位置つき VQA が 78.3% に対し IoU が 12.9% という結果は、ベンチマーク論文著者による第三者測定に属し、多くの LMM が 100 点換算で 50

点を下回ることが報告されている。初版の後継として位置づけられる。私的集合の詳細は設計上非開示であり、数値はベンチマーク論文著者の測定として読む。本節を OCR Bench 中心の章にはせず、横断の一つの錨として扱う。[124]

文書と図表の個別契約を切り分ける。DocVQA は 1 万 2000 件超の文書画像に 5 万件の設問を 9 種の推論類型で集め、80 対 10 対 10 の分割と ANLS を主指標に据えた。ANLS は ST-VQA 由来の平均正規化レーベンシュタイン類似度であり、軽微な OCR 誤差を強く罰しない。BER T-QA 級の基準に対し人間が 94.36% という結果はベンチマーク論文著者の測定に属する。抜粋型の近道への脆弱性は資料に裏づけられた設計上の懸念であり、ウェブ文書の事前学習重なるの可能性は論文が測った汚染率ではなく版横断の監査懸念として扱う。ChartQA は 9600 件の人間作成と 2 万 3100 件の生成を視覚と論理に分け、緩和正解の意味を条件として実世界図表を扱った。Nougat は科学 PDF をマークアップへ変換する専門手法として、反復失敗と言語と構造の偏りを論文自身が限定として述べた。GOT は OCR-2.0 の理論と 5.8 億規模の一体モデルをうたい、80M の高圧縮エンコーダで 1024 画素を 256 トークンに納めるが、独自系列での報告に属し、汎用比較には用いない。[34, 35, 29, 32]

複合得点を根拠利用と推論とハルシネーションに分解する。MMMU は大学の試験と教科書由来の 1 万 1500 件を 6 分野 30 科目 183 細目と 30 種の画像類型で集め、GPT-4V が 56%、Gemini Ultra が 59% という余白を示した。いずれもベンチマーク論文著者による第三

者測定に属し、総合得点を一般知能に読み替えない。思考条件の異なるアブレーションと汚染の不透明性への目配りが条件として残る。POPE は投票型の設問で物体ハルシネーションを安定に測る範囲に属し、頻出や共起の対象が作られやすいという知見を示したが、開かれた生成の忠実さは制御対照の器具を要する。HallusionBench は 346 枚の画像と 1129 件の設問を対照群つきで集め、言語先行と視覚誤読を分け、GPT-4V が対精度で 31.42%、他が 16%未満という診断を示した。小規模手作りの診断であり、順位表には用いない。MMBench は 3000 件超の日英設問を 20 能力軸で整え、選択肢回転の CircularEval と GPT-4 による選択抽出で頑健化したが、判定依存と英中の言語範囲が条件として残る。CoT の条件差は明示して読む。[88, 91, 89, 92]

動画の時間契約を蓄積済みと時系列と状態保持に分ける。Video-MME は 900 本と 254 時間と 2700 問を 6 領域で集めた全域評価であり、版結合の上では Gemini 1.5 Pro が平均 75%に対し GPT-4o が 71.9%というベンチマーク論文著者による第三者測定が報告されている。LongVideoBench は 3763 本と 6678 問を 17 細目で集め、参照内容の想起と推論を一体に問う参照推論の契約に属し、フレーム増加でのみ伸びるという枠数鋭敏性が長英文脈の証拠である。持続幅の評価と参照文脈の評価を混ぜない。StreamingBench は 900 本と 4500 問を 18 作業 3 区分で集め、途中到着の時刻つき設問と能動応答を問うが、多くはオフライン変換での測定であり、真のオンライン系の得点は別資料を要する。最良でも 67.07%に対し人間 91.66%という第三者測定が報告されている。Flash-VStream は非同期照会への応答と有界記憶と持続状態を備えたオンライン系のアンカーであり、遅延と VRAM の削減は論文著者自身の報告に属し、実運用の根拠は G04 として残る。ストリーミング時のメモリ管理を評価軸として明示する。[94, 100, 95, 96]

画面操作の測定を作業成否と位置精度に分ける。OSWorld は 369 件の実 OS 作業の成否を問う契約であり、人間 72.36%に対し最良 12.24%という論文著者の測定が接地の隘路を示した。OSWorld 2.0 は 108 件の長時間契約であり、Claude Opus 4.7 の最大思考と単一行動条件での平均 318.4 回という呼び出し回数は相互作用の地平と状態管理負荷の代理としてのみ読み、トークンやコンテキストや KV キャッシュや遅

延に直結させない。別条件の 500 段階構成で Claude Opus 4.8 の最大思考とバッチ処理が二値 20.6%と部分 54.8%と 481.8 回という報告も、モデルと思考とツールと手順と公開版の一体として読む。ScreenSpot は 600 件超の画面と 1200 件超の指示での純粋な位置特定契約であり、ScreenSpot-Pro は全画面で面積比 0.07%級を扱う専門評価の契約である。作業成功と純粋な位置特定を同一指標に混ぜない。[101, 102, 103, 105]

身体行動の測定上限を役割で分ける。OpenVLA の 29 作業での 16.5 ポイント上回りは、モデル論文著者自身による自己評価の第一役割に属し、独立した第三者再現ではない。オープンウェイトで群衆評価が可能になった点と独立に測られたことは区別し、G01 の不足は残る条件として保つ。Gemini Robotics 2 の最先端 VLA の主張と ER 2 の多段階計画の主張は提供元ベンダーによる第二役割の測定に属し、機構開示がなく遅延や価格やトークン量の事実は公開されていない。On-Device 2 の場面と指示と行動の汎化の記録はモデルカード範囲の第二役割に属し、分布外と全身の扱いは範囲外、両腕中心の安全範囲と階層安全の推奨が条件として残る。カード更新の可能性を版と日付に結びつけて読む。[111, 114, 115]

予測と生成の測定上限を極ごとに分ける。I-JEPA の線形評価と数え上げと深度の転移は表象 probe の範囲に属し、計画利用の主張は動力学側の資料を要する。V-JEPA の凍結評価の転移は生成的復号なしの証拠であり、計画利用は V-JEPA 2-AC 側の画像目標と MPC と CEM の条件つきである。Genie の対話制御は教師なし動画の範囲に属し、制御粒度の上限は Genie 3 側に委ねられる。Genie 3 の毎秒 24 フレームと 720p と分規模一貫性の主張と 5 件の限定は提供元ベンダーによる測定に属し、アーキテクチャ非開示のため能力と提供形態の記録に限る。独立した動力学利用の評価は G02 として残る。製品形態の記録は別位置づけの資料と重ねて結びつけ、写真写真のみを根拠に制御性能を断定しない。[116, 120, 117, 122, 123]

教師信号の来歴を時系列で束ねる。X01 の軸では、大規模教師ありの契約を ImageNet と AlexNet が示し、整備済みデータでの自己教師ありスケールングを DINOv2 が示し、ウェブ規模の弱い教師信号での自己訓練を OWL-ST と OWLHard 系が示し、言語のみの教師から視覚指示データを生成する手順を

LLaVA が示し、機体をまたぐ実演の標準契約を Open X-Embodiment が示した。いずれも教師信号の出所が違い、密な注釈とウェブ規模の弱い信号と合成指示の得失は条件で変わる。LVIS-rare のように希少区分の扱いを定める契約と、GoldG のように接地データ規模をうたう報告を混ぜず、ラベル空間の限定は条件として保つ。スケールを規模の拡大に還元せず、教師信号と学習レシピの変化として読む。[1, 42, 62, 72, 110]

入出力の契約の変化を束ねる。X02 の軸では、DETR が割当て費用と学習損失を分けた集合予測を示し、アンカーと NMS を外した直接予測の契約を定めた。GLIP が検出を語句グラウンディングへ言い換え、検出と接地の統一事前学習でゼロショット転移を示した。ScreenSpot が位置特定精度の契約を作業成功から分離し、RT-2 が行動を言語と同じテキストトークンで表す VLA 定式を示し、V-JEPA が特徴予測のみで生成を排する契約を示した。いずれも何を入力し何を出し何で測るかが違い、ボックスとマスクと座標と行動トークンを同一指標に混ぜない。明示的な構成要素としてのクエリやアテンションマップや特徴マップの扱いは資料の用語に従い、独自の比喩に置き換えない。[7, 52, 103, 107, 120]

トークンと文脈と記憶と遅延の軸を束ねる。X03 の軸では、BLIP-2 が画像エンコーダと LLM の凍結と Q-Former の二段階学習で学習可能量を抑える経済性を示し、Qwen3-VL が 256K の長的文脈と画像と言語と時刻の統合を 2x2 圧縮と明示的なテキスト時刻で示し、Flash-VStream がオンラインの有界記憶と非同期応答の遅延と VRAM の取引を示した。OSWorld 2.0 の呼び出し回数はこの軸の直測ではなく状態管理の代理であり、トークンやコンテキスト長や KV キャッシュやメモリ負荷や遅延や計算コストの主張には用いない。On-Device 2 の効率の位置づけは能力と提供形態の記録に限り、遅延や価格やトークン量の事実が公開されていない点を条件として保つ。提供元が

示す上限値は版と日付と構成に結びつけて読み、独立再現までは上限つき記録として扱う。[68, 43, 96, 102, 115]

測定の出所を融合系の事例で束ねる。Qwen3-VL の多段階学習と長期文脈と MMMU 級の推論の主張はモデル開発者自身による自己評価の第一役割に属し、トークンや構成の数値は版固有として読む。InternVL3 の単一段階の joint 事前学習と V2PE による文脈拡張と 78B での MMMU 72.2 という開放側最先端の主張も第一役割に属し、Qwen 段階手順との対置は構造の違いとして読む。Molmo 2 の完全オープン版の振舞いと映像計数 35.5 対 29.6 や指さし出力 38.4 対 20.0 や追跡 56.2 対 41.1 という比較は論文著者自身の測定であり、Qwen 基盤への部分的依存と SigLIP 2 エンコーダの閉鎖依存の開示と一体に読む。Gemini 3.1 Pro と Gemini 3.6 Flash の文脈と効率の主張は提供元ベンダーによる第二役割に属し、機構開示がなく手法記載と版と日付に結びつけて読む。重みの公開を測定の存在に読み替えない。[43, 75, 81, 82, 83]

収束の判定は一本化を急がない。一体の事前学習と個別に事前学習した構成要素の接続、専門手法と汎用モデル、密な注釈とウェブ規模の弱い教師信号、早期と後段と密な融合、凍結の再利用と共同学習、蓄積済み動画とオフライン時系列とオンライン状態の保持、計画分離と一体の行動表現、潜在ダイナミクスと予測表現と生成的環境の四つの極が並立する。X01 の教師信号と X02 の界面と X03 の費用と X04 の来歴で読む限り、万能の勝者は定まらず、条件と装置と費用と対象で損得が変わる。G01 の身体行動の独立評価不足、G02 の制御利用の共有測定不在、G03 の同一条件での専門と汎用の直接対決不在、G04 の実運用の遅延と記憶の根拠不足、G05 の最新第一者報告の独立再現不足を残し、G06 解決済みは引き継がない。未決を未決として残すことが本節の結論である。[1, 42, 62, 72, 110, 7, 52, 68, 43, 96, 102, 115, 55, 89, 111, 124]

### 本節の読解上の境界

本節は群をまたぐ順位表を作らず、数値比較は同一契約内に限る。モデル論文著者自身の測定と提供元ベンダーの測定とベンチマーク論文著者による第三者測定と独立した第三者再現の四区分を保ち、bare の著者報告を独立再現に読み替えない。提供元測定は版と日付と手法記載と一体であり、独立再現までは上限つき記録として扱う。私的集合の非開示や判定依存や言語範囲や対象外の扱いは条件として残す。独立測定の不足は欠陥ではなく残る条件である。[124, 34, 35, 88, 91, 92, 94, 100, 82, 83, 114, 115, 122, 123]

## 17 結び

### SYNTHESIS

本巻の系譜は一本の前進ではなく並立する枝の移行の束である。学習表現と転移を起点に、検出の集合予測、密な構造化とプロンプト指示、文書の構造理解、系列としての視覚と自己教師あり学習、画像全体のアライメントからオープンボキャブラリーのグラウンディングへ、個別に事前学習した構成要素の接続、解像度と融合と時刻の統合、ハルシネーションと根拠利用の診断、蓄積済み動画とオフライン時系列とオンライン状態の保持の分離、画面操作のグラウンディングと状態保持、身体行動の離散と連続の界面、歴史的定式と潜在ダイナミクスと予測表現と生成的環境の四つの極へ分かれ、課題ごとの評価契約の整理へ集まる。教師信号の出所と入出力の契約の変化が全巻の流れをなす。版と日付と所在の結合を保ち、条件を外した順位づけはしない。

一体の事前学習と個別構成の接続、専門手法と汎用モデル、密な注釈とウェブ規模の弱い教師信号、早期と後段と密な融合、凍結の再利用と共同学習、蓄積済み動画とオフライン時系列とオンライン状態の保持、計画分離と一体の行動表現、潜在ダイナミクスと予測表現と生成的環境、モデル開発者自身の測定と提供元ベンダーの測定とベンチマーク論文著者による第三者測定と独立した第三者再現が並行する。いずれも条件と装置と費用と対象で損得が変わり、一本化の圧力と分

業の圧力を両方残す。開かれていることと独立に測られていることの区別を保ち、重みの公開を測定の存在に読み替えない。どちらが勝つかの断定には届かず、未決を未決として残す。

身体行動の独立評価の不足を G01、制御に使える生成世界の共有測定の不在を G02、同一条件での専門手法と汎用モデルの直接対決の不在を G03、実運用の遅延とメモリ負荷の根拠不足を G04、最新第一者報告の独立再現の不足を G05 として残す。G06 は解決済みとして引き継がない。概要水準の記録は概要の範囲に留め、要求に応じて調べる動画方式の上限は提供元側の示値として行単位の結合を残す。測定の出所の四区分を保ち、全巻の測定の章への接続を欠かさない。

概要や断片水準の記録は概要の範囲に留め、語りで格上げしない。閉じた製品は能力と提供形態のみで構成を推測しない。条件の異なる数値の横断順位づけはしない。モデル開発者と提供元の主張は帰属つきで引用し独立再現を待つ。要旨水準の事実はその水準でのみ用いる。歴史的定式から生成環境への直接継承は主張せず、似ていることと受け継いだことの区別を保つ。ツール呼び出し回数をトークンやコンテキストや KV キャッシュや遅延の直測に読み替えない。内部の作業用語は読者文に出さない。測ったことだけを語り、測っていないことは語らない。

## References

- [1]Krizhevsky, Sutskever, Hinton. *ImageNet Classification with Deep CNNs* (Krizhevsky, Sutskever, Hinton). Sept. 2012. URL: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks> (visited on 09/30/2026).
- [2]He et al. *Deep Residual Learning for Image Recognition* (He et al.) Dec. 2015. URL: <https://arxiv.org/abs/1512.03385> (visited on 09/30/2026).
- [3]Fukushima. *Neocognitron* (Fukushima). 1980. URL: <https://doi.org/10.1007/BF00344251> (visited on 09/30/2026).
- [4]LeCun et al. *Gradient-Based Learning Applied to Document Recognition* (LeCun et al.) Nov. 1998. URL: <http://yann.lecun.com/exdb/publis/pdf/lecun-98.pdf> (visited on 09/30/2026).
- [5]Girshick et al. *Rich feature hierarchies (R-CNN)* (Girshick et al.) Nov. 2013. URL: <https://arxiv.org/abs/1311.2524> (visited on 09/30/2026).
- [6]Ren et al. *Faster R-CNN* (Ren et al.) June 2015. URL: <https://arxiv.org/abs/1506.01497> (visited on 09/30/2026).
- [7]Carion et al. *End-to-End Object Detection with Transformers / DETR* (Carion et al.) May 2020. URL: <https://arxiv.org/abs/2005.12872> (visited on 09/30/2026).
- [8]Zhang et al. *DINO: DETR with Improved DeNoising Anchor Boxes* (Zhang et al.) Mar. 2022. URL: <https://arxiv.org/abs/2203.03605> (visited on 09/30/2026).
- [9]Cheng et al. *YOLO-World: Real-Time Open-Vocabulary Object Detection* (Cheng et al.) Jan. 2024. URL: <https://arxiv.org/abs/2401.17270> (visited on 09/30/2026).
- [10]*Deformable DETR: Deformable Transformers for End-to-End Object Detection*. Oct. 2020. URL: <https://arxiv.org/abs/2010.04159> (visited on 10/08/2026).
- [11]*DAB-DETR: Dynamic Anchor Boxes are Better Queries for DETR*. Jan. 2022. URL: <https://arxiv.org/abs/2201.12329> (visited on 10/08/2026).
- [12]*DN-DETR: Accelerate DETR Training by Introducing Query DeNoising*. Mar. 2022. URL: <https://arxiv.org/abs/2203.01305> (visited on 10/08/2026).
- [13]Redmon et al. *You Only Look Once* (Redmon et al.) June 2015. URL: <https://arxiv.org/abs/1506.02640> (visited on 09/30/2026).
- [14]Liu et al. *SSD: Single Shot MultiBox Detector* (Liu et al.) Dec. 2015. URL: <https://arxiv.org/abs/1512.02325> (visited on 09/30/2026).
- [15]Lin et al. *Focal Loss / RetinaNet* (Lin et al.) Aug. 2017. URL: <https://arxiv.org/abs/1708.02002> (visited on 09/30/2026).
- [16]Long et al. *Fully Convolutional Networks for Semantic Segmentation* (Long et al.) Nov. 2014. URL: <https://arxiv.org/abs/1411.4038> (visited on 09/30/2026).
- [17]He et al. *Mask R-CNN* (He et al.) Mar. 2017. URL: <https://arxiv.org/abs/1703.06870> (visited on 09/30/2026).
- [18]Kirillov et al. *Segment Anything* (Kirillov et al.) Apr. 2023. URL: <https://arxiv.org/abs/2304.02643> (visited on 09/30/2026).
- [19]Ravi et al. *SAM 2: Segment Anything in Images and Videos* (Ravi et al.) Aug. 2024. URL: <https://arxiv.org/abs/2408.00714> (visited on 09/30/2026).
- [20]Meta Superintelligence Labs, 2025. *SAM 3* (Meta Superintelligence Labs, 2025). Nov. 2025. URL: <https://arxiv.org/abs/2511.16719> (visited on 10/05/2026).

- [21]Ronneberger et al. *U-Net (Ronneberger et al.)* May 2015. URL: <https://arxiv.org/abs/1505.04597> (visited on 09/30/2026).
- [22]Kirillov et al. *Panoptic Segmentation (Kirillov et al.)* Jan. 2018. URL: <https://arxiv.org/abs/1801.00868> (visited on 09/30/2026).
- [23]Ranftl et al. *Towards Robust Monocular Depth Estimation / MiDaS (Ranftl et al.)* July 2019. URL: <https://arxiv.org/abs/1907.01341> (visited on 09/30/2026).
- [24]Cao et al. *OpenPose: Realtime Multi-Person 2D Pose (Cao et al.)* Dec. 2018. URL: <https://arxiv.org/abs/1812.08008> (visited on 09/30/2026).
- [25]Krishna et al. *Visual Genome (Krishna et al.)* Feb. 2016. URL: <https://arxiv.org/abs/1602.07332> (visited on 09/30/2026).
- [26]Wang et al. *DUST3R: Geometric 3D Vision Made Easy (Wang et al.)* Dec. 2023. URL: <https://arxiv.org/abs/2312.14132> (visited on 09/30/2026).
- [27]Kim et al. *Donut: OCR-free Document Understanding Transformer (Kim et al.)* Nov. 2021. URL: <https://arxiv.org/abs/2111.15664> (visited on 09/30/2026).
- [28]Lee et al. *Pix2Struct (Lee et al.)* Oct. 2022. URL: <https://arxiv.org/abs/2210.03347> (visited on 09/30/2026).
- [29]Blecher et al. *Nougat: Neural Optical Understanding for Academic Documents (Blecher et al.)* Aug. 2023. URL: <https://arxiv.org/abs/2308.13418> (visited on 09/30/2026).
- [30]Xu et al. *LayoutLM (Xu et al.)* Dec. 2019. URL: <https://arxiv.org/abs/1912.13318> (visited on 09/30/2026).
- [31]Huang et al. *LayoutLMv3 (Huang et al.)* Apr. 2022. URL: <https://arxiv.org/abs/2204.08387> (visited on 09/30/2026).
- [32]Wei et al. *General OCR Theory / GOT (Wei et al.)* Sept. 2024. URL: <https://arxiv.org/abs/2409.01704> (visited on 09/30/2026).
- [33]Qwen3-VL-Embedding and Qwen3-VL-Reranker. Jan. 2026. URL: <https://arxiv.org/abs/2601.04720> (visited on 09/30/2026).
- [34]Mathew et al. *DocVQA (Mathew et al.)* July 2020. URL: <https://arxiv.org/abs/2007.00398> (visited on 09/30/2026).
- [35]Masry et al. *ChartQA (Masry et al.)* Mar. 2022. URL: <https://arxiv.org/abs/2203.10244> (visited on 09/30/2026).
- [36]Dosovitskiy et al. *An Image is Worth 16x16 Words / ViT (Dosovitskiy et al.)* Oct. 2020. URL: <https://arxiv.org/abs/2010.11929> (visited on 09/30/2026).
- [37]Caron et al. *Emerging Properties in Self-Supervised Vision Transformers / DINO (Caron et al.)* Apr. 2021. URL: <https://arxiv.org/abs/2104.14294> (visited on 09/30/2026).
- [38]Zhai et al. *Sigmoid Loss for Language Image Pre-Training / SigLIP (Zhai et al.)* Mar. 2023. URL: <https://arxiv.org/abs/2303.15343> (visited on 09/30/2026).
- [39]Touvron et al. *DeiT (Touvron et al.)* Dec. 2020. URL: <https://arxiv.org/abs/2012.12877> (visited on 09/30/2026).
- [40]Liu et al. *Swin Transformer (Liu et al.)* Mar. 2021. URL: <https://arxiv.org/abs/2103.14030> (visited on 09/30/2026).
- [41]He et al. *Masked Autoencoders / MAE (He et al.)* Nov. 2021. URL: <https://arxiv.org/abs/2111.06377> (visited on 09/30/2026).
- [42]Oquab et al. *DINOv2 (Oquab et al.)* Apr. 2023. URL: <https://arxiv.org/abs/2304.07193> (visited on 09/30/2026).

- [43]Bai et al. *Qwen3-VL Technical Report (Bai et al.)* Nov. 2025. URL: <https://arxiv.org/abs/2511.21631> (visited on 09/30/2026).
- [44]Meta AI, 2025. *DINOv3 (Meta AI, 2025)*. Aug. 2025. URL: <https://arxiv.org/abs/2508.10104> (visited on 10/05/2026).
- [45]Zhai et al., 2025. *SigLIP 2 (Zhai et al., 2025)*. Feb. 2025. URL: <https://arxiv.org/abs/2502.14786> (visited on 10/05/2026).
- [46]Apple, 2024. *AIMv2 (Apple, 2024)*. Nov. 2024. URL: <https://arxiv.org/abs/2411.14402> (visited on 10/05/2026).
- [47]Radford et al. *Learning Transferable Visual Models / CLIP (Radford et al.)* Feb. 2021. URL: <https://arxiv.org/abs/2103.00020> (visited on 09/30/2026).
- [48]Antol et al. *VQA: Visual Question Answering (Antol et al.)* May 2015. URL: <https://arxiv.org/abs/1505.00468> (visited on 09/30/2026).
- [49]Vinyals et al. *Show and Tell (Vinyals et al.)* Nov. 2014. URL: <https://arxiv.org/abs/1411.4555> (visited on 09/30/2026).
- [50]Jia et al. *Scaling Up Visual and Vision-Language Representation Learning / ALIGN (Jia et al.)* Feb. 2021. URL: <https://arxiv.org/abs/2102.05918> (visited on 09/30/2026).
- [51]Plummer et al. *Flickr30k Entities (Plummer et al.)* Dec. 2015. URL: [https://openaccess.thecvf.com/content\\_iccv\\_2015/html/Plummer\\_Flickr30k\\_Entities\\_Collecting\\_ICCV\\_2015\\_paper.html](https://openaccess.thecvf.com/content_iccv_2015/html/Plummer_Flickr30k_Entities_Collecting_ICCV_2015_paper.html) (visited on 09/30/2026).
- [52]Li et al. *Grounded Language-Image Pre-training / GLIP (Li et al.)* Dec. 2021. URL: <https://arxiv.org/abs/2112.03857> (visited on 09/30/2026).
- [53]Liu et al. *Grounding DINO (Liu et al.)* Mar. 2023. URL: <https://arxiv.org/abs/2303.05499> (visited on 09/30/2026).
- [54]Yu et al. *Modeling Context in Referring Expressions / RefCOCO (Yu et al.)* Sept. 2016. URL: <https://aclanthology.org/D16-1212/> (visited on 09/30/2026).
- [55]Gupta et al. *LVIS: A Dataset for Large Vocabulary Instance Segmentation (Gupta et al.)* Aug. 2019. URL: <https://arxiv.org/abs/1908.03195> (visited on 09/30/2026).
- [56]Zareian et al. *Open-Vocabulary Object Detection Using Captions / OVR-CNN (Zareian et al.)* Nov. 2020. URL: <https://arxiv.org/abs/2011.10678> (visited on 09/30/2026).
- [57]Gu et al. *Open-vocabulary Object Detection via Vision and Language Knowledge Distillation / ViLD (Gu et al.)* Apr. 2021. URL: <https://arxiv.org/abs/2104.13921> (visited on 09/30/2026).
- [58]Zhong et al. *RegionCLIP (Zhong et al.)* Dec. 2021. URL: <https://arxiv.org/abs/2112.09106> (visited on 09/30/2026).
- [59]Zhou et al. *Detecting Twenty-thousand Classes using Image-level Supervision / Detic (Zhou et al.)* Jan. 2022. URL: <https://arxiv.org/abs/2201.02605> (visited on 09/30/2026).
- [60]Kamath et al. *MDETR (Kamath et al.)* Apr. 2021. URL: <https://arxiv.org/abs/2104.12763> (visited on 09/30/2026).
- [61]Minderer et al. *Simple Open-Vocabulary Object Detection with Vision Transformers / OWL-ViT (Minderer et al.)* May 2022. URL: <https://arxiv.org/abs/2205.06230> (visited on 09/30/2026).
- [62]Minderer et al. *Scaling Open-Vocabulary Object Detection / OWL-ST/OWLv2 (Minderer et al.)* June 2023. URL: <https://arxiv.org/abs/2306.09683> (visited on 09/30/2026).
- [63]Li et al. *Language-driven Semantic Segmentation / LSeg (Li et al.)* Jan. 2022. URL: <https://arxiv.org/abs/2201.03546> (visited on 09/30/2026).

- [64]Ghiassi et al. *Scaling Open-vocabulary Image Segmentation with Image-level Labels / OpenSeg* (Ghiassi et al.) Dec. 2021. URL: <https://arxiv.org/abs/2112.12143> (visited on 09/30/2026).
- [65]Zou et al. *Generalized Decoding for Pixel, Image, and Language / X-Decoder* (Zou et al.) June 2023. URL: [https://openaccess.thecvf.com/content/CVPR2023/papers/Zou\\_Generalized\\_Decoding\\_for\\_Pixel\\_Image\\_and\\_Language\\_CVPR\\_2023\\_paper.pdf](https://openaccess.thecvf.com/content/CVPR2023/papers/Zou_Generalized_Decoding_for_Pixel_Image_and_Language_CVPR_2023_paper.pdf) (visited on 09/30/2026).
- [66]Xu et al. *Open-Vocabulary Panoptic Segmentation with Text-to-Image Diffusion Models / ODISE* (Xu et al.) Mar. 2023. URL: <https://arxiv.org/abs/2303.04803> (visited on 09/30/2026).
- [67]Alayrac et al. *Flamingo* (Alayrac et al.) Apr. 2022. URL: <https://arxiv.org/abs/2204.14198> (visited on 09/30/2026).
- [68]Li et al. *BLIP-2* (Li et al.) Jan. 2023. URL: <https://arxiv.org/abs/2301.12597> (visited on 09/30/2026).
- [69]Tsimpoukelli et al. *Multimodal Few-Shot Learning with Frozen Language Models / Frozen* (Tsimpoukelli et al.) June 2021. URL: <https://arxiv.org/abs/2106.13884> (visited on 09/30/2026).
- [70]Dai et al. *InstructBLIP* (Dai et al.) May 2023. URL: <https://arxiv.org/abs/2305.06500> (visited on 09/30/2026).
- [71]Zhu et al. *MiniGPT-4* (Zhu et al.) Apr. 2023. URL: <https://arxiv.org/abs/2304.10592> (visited on 09/30/2026).
- [72]Liu et al. *Visual Instruction Tuning / LLaVA* (Liu et al.) Apr. 2023. URL: <https://arxiv.org/abs/2304.08485> (visited on 09/30/2026).
- [73]Deitke et al. *Molmo and PixMo* (Deitke et al.) Sept. 2024. URL: <https://arxiv.org/abs/2409.17146> (visited on 09/30/2026).
- [74]Xu et al. *Qwen3-Omni Technical Report* (Xu et al.) Sept. 2025. URL: <https://arxiv.org/abs/2509.17765> (visited on 09/30/2026).
- [75]Zhu et al. *InternVL3* (Zhu et al.) Apr. 2025. URL: <https://arxiv.org/abs/2504.10479> (visited on 09/30/2026).
- [76]Google, 2026-09-01. *Introducing agentic video understanding with Gemini* (Google, 2026-09-01). Sept. 2026. URL: <https://blog.google/innovation-and-ai/models-and-research/gemini-models/introducing-agentic-video-in-gemini/> (visited on 10/03/2026).
- [77]Bai et al. *Qwen2.5-VL Technical Report* (Bai et al.) Feb. 2025. URL: <https://arxiv.org/abs/2502.13923> (visited on 09/30/2026).
- [78]Radford et al. *Robust Speech Recognition via Large-Scale Weak Supervision / Whisper* (Radford et al.) Dec. 2022. URL: <https://arxiv.org/abs/2212.04356> (visited on 09/30/2026).
- [79]Chen et al. *BEATs: Audio Pre-Training with Acoustic Tokenizers* (Chen et al.) Dec. 2022. URL: <https://arxiv.org/abs/2212.09058> (visited on 09/30/2026).
- [80]Elizalde et al. *CLAP: Learning Audio Concepts From Natural Language Supervision* (Elizalde et al.) June 2022. URL: <https://arxiv.org/abs/2206.04769> (visited on 09/30/2026).
- [81]Clark et al. *Molmo2* (Clark et al.) Jan. 2026. URL: <https://arxiv.org/abs/2601.10611> (visited on 09/30/2026).
- [82]DeepMind. *Gemini 3.1 Pro model card* (DeepMind). Feb. 2026. URL: <https://deepmind.google/models/model-cards/gemini-3-1-pro/> (visited on 09/30/2026).
- [83]DeepMind. *Gemini 3.6 Flash model card* (DeepMind). July 2026. URL: <https://deepmind.google/models/model-cards/gemini-3-6-flash/> (visited on 09/30/2026).
- [84]code + weights. *QwenLM/Qwen3-VL repository* (code + weights). URL: <https://github.com/QwenLM/Qwen3-VL> (visited on 09/30/2026).

- [85]code + weights. *QwenLM/Qwen3-Omni repository (code + weights)*. URL: <https://github.com/QwenLM/Qwen3-Omni> (visited on 09/30/2026).
- [86]code + weights + data. *OpenGVLab/InternVL repository (code + weights + data)*. URL: <https://github.com/OpenGVLab/InternVL> (visited on 09/30/2026).
- [87]training + eval code. *allenai/molmo2 repository (training + eval code)*. URL: <https://github.com/allenai/molmo2> (visited on 09/30/2026).
- [88]Yue et al. *MMMU* (Yue et al.) Nov. 2023. URL: <https://arxiv.org/abs/2311.16502> (visited on 09/30/2026).
- [89]Guan et al. *HallusionBench* (Guan et al.) Oct. 2023. URL: <https://arxiv.org/abs/2310.14566> (visited on 09/30/2026).
- [90]Lu et al. *MathVista* (Lu et al.) Oct. 2023. URL: <https://arxiv.org/abs/2310.02255> (visited on 09/30/2026).
- [91]Li et al. *Evaluating Object Hallucination / POPE* (Li et al.) May 2023. URL: <https://arxiv.org/abs/2305.10355> (visited on 09/30/2026).
- [92]Liu et al. *MMBench* (Liu et al.) July 2023. URL: <https://arxiv.org/abs/2307.06281> (visited on 09/30/2026).
- [93]Yang et al. *VSI-Bench* (Yang et al.) Dec. 2024. URL: <https://arxiv.org/abs/2412.14171> (visited on 09/30/2026).
- [94]Fu et al. *Video-MME* (Fu et al.) May 2024. URL: <https://arxiv.org/abs/2405.21075> (visited on 09/30/2026).
- [95]Lin et al. *StreamingBench* (Lin et al.) Nov. 2024. URL: <https://arxiv.org/abs/2411.03628> (visited on 09/30/2026).
- [96]Zhang et al. *Flash-VStream* (Zhang et al.) June 2024. URL: <https://arxiv.org/abs/2406.08085> (visited on 09/30/2026).
- [97]Kay et al. *The Kinetics Human Action Video Dataset* (Kay et al.) May 2017. URL: <https://arxiv.org/abs/1705.06950> (visited on 09/30/2026).
- [98]Goyal et al. *Something-Something V1* (Goyal et al.) June 2017. URL: <https://arxiv.org/abs/1706.04261> (visited on 09/30/2026).
- [99]Grauman et al. *Ego4D* (Grauman et al.) Oct. 2021. URL: <https://arxiv.org/abs/2110.07058> (visited on 09/30/2026).
- [100]Wu et al. *LongVideoBench* (Wu et al.) July 2024. URL: <https://arxiv.org/abs/2407.15754> (visited on 09/30/2026).
- [101]Xie et al. *OSWorld* (Xie et al.) Apr. 2024. URL: <https://arxiv.org/abs/2404.07972> (visited on 09/30/2026).
- [102]Yuan et al. *OSWorld 2.0* (Yuan et al.) June 2026. URL: <https://arxiv.org/abs/2606.29537> (visited on 09/30/2026).
- [103]Cheng et al. *SeeClick / ScreenSpot* (Cheng et al.) Jan. 2024. URL: <https://arxiv.org/abs/2401.10935> (visited on 09/30/2026).
- [104]2024. *UGround (2024)*. Oct. 2024. URL: <https://arxiv.org/abs/2410.05243> (visited on 10/05/2026).
- [105]2025. *ScreenSpot-Pro (2025)*. Apr. 2025. URL: <https://arxiv.org/abs/2504.07981> (visited on 10/05/2026).
- [106]Driess et al. *PaLM-E* (Driess et al.) Mar. 2023. URL: <https://arxiv.org/abs/2303.03378> (visited on 09/30/2026).
- [107]Brohan/Zitkovich et al. *RT-2* (Brohan/Zitkovich et al.) July 2023. URL: <https://arxiv.org/abs/2307.15818> (visited on 09/30/2026).
- [108]Ahn et al. *Do As I Can, Not As I Say / SayCan* (Ahn et al.) Apr. 2022. URL: <https://arxiv.org/abs/2204.01691> (visited on 09/30/2026).

- [109]Brohan et al. *RT-1 (Brohan et al.)* Dec. 2022. URL: <https://arxiv.org/abs/2212.06817> (visited on 09/30/2026).
- [110]O’Neill et al. *Open X-Embodiment (O’Neill et al.)* Oct. 2023. URL: <https://arxiv.org/abs/2310.08864> (visited on 09/30/2026).
- [111]Kim et al. *OpenVLA (Kim et al.)* June 2024. URL: <https://arxiv.org/abs/2406.09246> (visited on 09/30/2026).
- [112]Physical Intelligence, 2024. *pi-zero (Physical Intelligence, 2024)*. Oct. 2024. URL: <https://arxiv.org/abs/2410.24164> (visited on 10/05/2026).
- [113]Pertsch et al., 2025. *FAST (Pertsch et al., 2025)*. Jan. 2025. URL: <https://arxiv.org/abs/2501.09747> (visited on 10/05/2026).
- [114]DeepMind. *Gemini Robotics 2 (DeepMind)*. July 2026. URL: <https://deepmind.google/models/gemini-robotics/> (visited on 09/30/2026).
- [115]DeepMind. *Gemini Robotics On-Device 2 model card (DeepMind)*. July 2026. URL: <https://deepmind.google/models/model-cards/gemini-robotics-on-device-2/> (visited on 09/30/2026).
- [116]LeCun et al. *Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture / I-JEPA (LeCun et al.)* Jan. 2023. URL: <https://arxiv.org/abs/2301.08243> (visited on 09/30/2026).
- [117]Bruce et al. *Genie: Generative Interactive Environments (Bruce et al.)* Feb. 2024. URL: <https://arxiv.org/abs/2402.15391> (visited on 09/30/2026).
- [118]Ha & Schmidhuber. *World Models (Ha & Schmidhuber)*. Mar. 2018. URL: <https://arxiv.org/abs/1803.10122> (visited on 09/30/2026).
- [119]Hafner et al. *Mastering Diverse Domains through World Models / DreamerV3 (Hafner et al.)* Jan. 2023. URL: <https://arxiv.org/abs/2301.04104> (visited on 09/30/2026).
- [120]Bardes et al. *Revisiting Feature Prediction / V-JEPA (Bardes et al.)* Feb. 2024. URL: <https://arxiv.org/abs/2404.08471> (visited on 09/30/2026).
- [121]Meta, 2025. *V-JEPA 2 / V-JEPA 2-AC (Meta, 2025)*. June 2025. URL: <https://arxiv.org/abs/2506.09985> (visited on 10/05/2026).
- [122]DeepMind blog. *Genie 3 (DeepMind blog)*. Aug. 2025. URL: <https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/> (visited on 09/30/2026).
- [123]DeepMind. *Genie 3 model page (DeepMind)*. Aug. 2025. URL: <https://deepmind.google/models/genie/> (visited on 09/30/2026).
- [124]Fu et al. *OCRBench v2 (Fu et al.)* Dec. 2024. URL: <https://arxiv.org/abs/2501.00321> (visited on 09/30/2026).