
Japanese Generative AI Technical Survey Special

SP-vision-multimodal-2026

Vision & Multimodal AI — 視覚表現から接地・推論・行動へ / Thematic survey as of
2026-09-30

Vision & Multimodal AI

視覚表現から接地・推論・行動へ。分類から位置・構造・時間・空間の表現へ、言語への
接地と複数モダリティの統合を経て、推論・予測・行動へ至る技術史。

Representation / Detection / Dense Perception / Alignment / Grounding / Fusion / Reasoning / Video / Action / Prediction

Editorial cutoff

Open history, evidence observed through 2026-09-30 UTC

Repository

eariver/japanese-generative-ai-survey

Build

LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する Thematic Longform Special。

本巻の問いと読み方

本巻の問いは、画像や映像を単に分類する段階から、対象の位置・構造・時間関係を認識し、言語概念へ接地し、複数モダリティを統合して推論し、予測や行動へ利用できる内部表現を形成する段階へ、どのように発展してきたのか、である。各段階で問うのは、次の計算に十分な世界の表現は何か、何が失われ、何が新たに操作可能になったかである。

層の見方

本巻は単一のモデル年代記ではなく、相互に関わる技術的問題の層として読む。すなわち表現、認識、位置特定と構造、言語アライメント、接地、マルチモーダル融合、時間と空間の状態、推論、行動と予測である。これらは時代ではなく、相互作用する問題層である。

比較の規律

条件の異なる数値を並べて優劣をつける読みは採らない。数値は測定条件・版・日付・測り手と組で読む。ベンダーの主張は帰属づきで引用し、独立した再現を待つ。未解決の事項は推測で補わない。

読者への道案内

第1節から第11節が知覚・接地・融合・推論・時間の歴史、第12節から第14節が画面操作・身体動作・予測という到達点の領域、第15節が評価の方法と収束の問いを扱う。各節末の読解上の境界が、その節の射程と留保を示す。

目次

本巻の問いと読み方	2
1 学んだ表現が土台になるとき	3
2 ボックスから集合予測、オープンボキャブラリーへ	4
3 指示に応える密な知覚	6
4 推論を支える空間と幾何	7
5 OCR から文書理解へ	8
6 Transformer と自己教師あり学習の基盤	10
7 画像と言語をつなぐアライメント	12
8 言葉をボックスとマスクに結ぶ接地	13
9 凍結した視覚・言語モデルを接続する	16
10 解像度と融合と時刻を問う	18
11 合成点を開き失敗を分ける	21
12 長尺と実時間の契約を分ける	22
13 画面操作は接地から状態管理へ	23
14 計画と言語と行動をつなぐ界面	25
15 予測する表現と生成する環境	27
16 測る契約と残る限界と開かれた収束	29
17 結び	32

1 学んだ表現が土台になるとき

REPRESENTATION

手書きの特徴量から ImageNet 規模の学習への転換を追う。AlexNet の容量と実装の組み合わせと ResNet の残差学習を読み、分類で鍛えた表現が検出とセグメンテーションの出発点になる筋を確認する。単一データの射程と学習レシピの読みの両義性を保つ。[1, 2]

手書きの特徴量で濃淡の勾配や輪郭の断片を組み立てる段階では、設計の質が人の経験に依存した。Neocognitron は特徴抽出を担う S 細胞相当の層と位置ずれを吸収する C 細胞相当の層を重ね、最終層の C 細胞が位置によらず刺激パターンに選択的に応答し、形状や大きさの小さな変化を許容すると述べた。畳み込みの階層の発想の出所として扱うのが本書の範囲であり、本文の入手に制限があるため仕組みの細部には立ち入らず、性能の主張はこの資料からは引き継がない。LeNet は畳み込みニューラルネットワークを勾配法で端から端まで学習させ、文書の文字認識に適用して、手書きの特徴量ではなく学習した階層で実務課題を解ける例を示した。画像を見る階層を学習で得る道がある点に、規模の転換の前史としての意義がある。こちらでも LeNet 論文の著者公開 PDF の文字コードの問題で本文の機械的な読み取りができないため、抄録水準に留めて文書画像の範囲の話として扱い、規模の主張は ImageNet 世代の資料に譲る。AlexNet 論文の著者らは、障害として二点を挙げた。すなわち、ラベル付きデータが小規模な点と、高解像度画像を扱う大規模 CNN の計算負荷である。これに対する組み合わせは、ImageNet のデータ規模、深さと幅を調整した容量と局所性・定常性を生かす畳み込みの前提、GPU で効率よく回る二次元畳み込みの実装、飽和しにくいユニット、過学習を抑える dropout であった。規模は 1.2M 枚の ImageNet 画像に対し、60M のパラメータと 650K のユニットをもつ 5 層の畳み込みと 3 層の全結合、1000 通りの softmax からなる深い CNN であり、ILSVRC-2010 で top-1 誤り 37.5%と top-5 誤り 17.0%、ILSVRC-2012 では top-5 で 15.3%を次点の 26.2%に対して示し、3GB の GTX 580 を 2 枚使って 5~6 日かけたと、モデル論文の著者測定として報告している。同論文は高速な GPU と大規模データがあ

れば結果はさらに伸びると結んでおり、本書ではここに大規模な教師あり学習を再利用可能な例にするという読みの根拠を置く。ただしこの読みは編集上の合成であり、ImageNet 単一の範囲を超える転移の主張は後継の記録に譲る。[3, 4, 1]

層を増やすと学習誤差そのものが上昇する劣化を、ResNet 論文の著者らは診断の起点に据えた。勾配の爆発や消失は初期値と正規化でほぼ解消した後も、素朴に深くしたモデルでは学習誤差が増え、これは試験時の悪化ではなく学習の停滞、すなわち過学習ではなく最適化の問題だと述べた。深い側が浅い側と同じ写像をたどれるなら悪化するはずがない、という恒等写像の論拠が診断の中心にある。そこで学習対象を $H(x)$ そのものから残差 $F(x)=H(x)-x$ へ置き換え、次元が一致する箇所のショートカット接続はパラメータなしの恒等写像とし、次元合わせが必要な箇所のみ式 2 の射影 W_s を置く。通り抜けできる分だけ各層は積み上げる差分に専念でき、 1×1 - 3×3 - 1×1 のボトルネックで計算量を抑えて 152 層で 11.3 GFLOPs と VGG-19 より軽い。結果もモデル論文の著者測定に属し、152 層単体で検証 top-5 誤り 4.49%、集成でテスト top-5 誤り 3.57%を示して ILSVRC 2015 の 1 位、COCO 検出で 6.0 ポイントの上積みを相対で 28%の伸びとして学習表現のみに帰し、ImageNet 検出・位置特定と COCO セグメンテーションでも 1 位と報告している。検出の伸びは 2015 年当時の Faster R-CNN 系列を基準にした評価条件での話であり、現在の評価軸での優劣は主張しない。[1, 2]

AlexNet の主張は ImageNet 単一の範囲にあり、別課題への転移は ResNet の記録が裏づけを与える構成になっている。COCO での上積みと各部門の 1 位は、分類で鍛えた表現が検出とセグメンテーションの出発点になる例であり、分類から検出への転移と並ぶもう一つの継承として読む。ただし深層化に際限はなく、CIFAR で 1202 層まで積むと学習誤差は 0.1%を切る一方でテストでは悪化し、maxout や dropout なしでは過学習が残ると著者ら自身が記している。深くできる点と深くして通用させる点は別であり、深さの拡大に正則化側の境がある点は開かれた問いとして残る。

同時代の highway network との対比は同時代の位置づけに留め、後に DeiT や Swin が学習手順側の読み直してモデルの形状の新規性の称賛を限定した点も併せて記す。本節は形状の新規性を称える読みと、データ規模と計算実装と学習の回し方で結果を動かす学習レシピの読みの双方を保ち、後者は同論文自身の結びに

支えられる編集上の合成として扱う。効率の用語は TS-001 の資産を借りるだけで本節では説き直さず、大量のラベル付き画像で鍛えた表現を出発点に載せる大規模教師ありの契約が見える形になった点を確認して、検出の節へ接続する。[1, 2]

本節の読解上の境界

この節の読解上の境界：本節の転移の主張は ImageNet という一つのデータの範囲に留まる。別課題への転換は後継の記録が担う。検出の伸びは 2015 年当時の条件の上での報告であり、現在の基準での優劣ではない。LeNet の機構の細部は抄録水準に留める。[1, 2, 3, 4]

2 ボックスから集合予測、オープンボキャブラリーへ

DETECTION

ボックスの位置と物の名を対にする検出の系譜を追う。領域提案から one-stage と two-stage の動作点、集合予測を経て言葉で指せるオープンボキャブラリーの手前までを見る。DINO 検出器の呼び分けを保ち、版と評価条件を明記して数値は著者測定として読む。[5, 6, 7]

検出の契約は、何が写るかにどこにあるかをボックスで対にさせる点にある。R-CNN はボトムアップの領域提案に CNN を適用し、VOC 2012 の mAP で 53.3%、相対で 30%超の伸びを示したと、モデル論文の著者らが報告している。当時は手作りの特徴量を組み合わせた複雑な集成でも VOC 検出の評価軸が頭打ちであり、その停滞を破る起点として読む。中心は二点で、位置の当たり付けを古典的な領域提案に任せて見分けを CNN に任せた点と、分類で事前に鍛えたモデルを検出ラベルの乏しい範囲にファインチューニングで引き継いだ点である。古典的手法と深層学習を対立させずに継いだ点が系譜の起点であり、分類で鍛えて検出に引き継ぐ手順は後の視覚の各課題に受け継がれる。多段処理は重く速度は今後の課題として残され、R-CNN 自体は後の基準では遅い仕組みである点を隠さない。Hoiem らの道具立てによる誤り分析は、その時代の評価条件のものとして読む。[5]

Faster R-CNN は two-stage の到達点であり、Region Proposal Network が画像全体の畳み込み特徴量を検出器と共有して提案の計算をほぼ無料にしたと、モデル論文の著者らが述べている。別立ての提案装置では

なく検出器が見た特徴マップの上で見るべき位置を同時に決め、VGG-16 で毎秒 5 コマ、画像あたり 300 提案で VOC 2007 と 2012、COCO の当時最上位に並び、ILSVRC と COCO の 2015 年 1 位の基盤になったと報告している。入出力の契約を明確にすると、完全畳み込みの RPN が各位置で物の輪郭と物らしさを予測し、どこを見るかというアテンションの役割をモデル自身が担う形である。ここで定まったアンカーと NMS の機械的な仕掛けが、後に DETR が外す前提であり、アンカーの代表値と NMS は人手で決めたまま残り、小さな物や縁の振る舞いは後継の資料に譲る。one-stage の系譜を YOLO 一種に縮めないため、SSD の枝をここに置く。SSD はボックスの空間を既定のボックスに離散化し、解像度の異なる特徴マップに振り分けて粗い特徴マップで大きな物を細かい特徴マップで小さな物を受けもつ。モデル論文の著者測定では SSD300 が VOC 2007 で 74.3~77.2% の mAP を Titan X で毎秒 59 コマ、SSD512 が 76.9~79.8% で Faster R-CNN を上回り 3 倍の速さと報告している。one-stage の速さと two-stage の精度の対立がここで崩れ始める一方、既定のボックスの敷き詰めと受容野の対応は同論文自身が今後の課題として残し、本書では系譜の欠けを補う薄い扱いに留めて仕組みの裁定は下さない。[8, 9]

YOLO は検出を、空間に区切ったボックスとクラス確率への回帰として一回の評価で解く動作点であり、提案と見分けを往復せず画像を一度見てボックスと名を同時に出す。モデル論文の著者測定では基本モデル

が毎秒 45 コマ、速いバリエーションが毎秒 155 コマで他の実時間級の 2 倍の mAP を示し、R-CNN 系より背景の誤検出が少なく位置の誤りが多いと報告している。速さと引き換えに位置が甘くなるのがこの動作点の特性であり、1 セル 2 ボックス 1 クラスの格子制約が近接物の数に上限を付け、群れた小さな物や珍しい縦横比、粗い特徴量、小さなボックスの IOU のぶれが苦手な誤りの主因は位置にあると述べている。自然画像から絵画への転移が DPM や R-CNN より良いという報告は、この動作点の汎用性の例である。精度は同世代の最上位には届かないと同論文自身が認め、後の YOLO 各版は別製品として版に縛った主張に留める。one-stage の精度の遅れを損失側から診断したのが RetinaNet であり、RetinaNet 論文の著者らによれば前景と背景の極端な不均衡こそ主因で、簡単な負例の寄与を $(1-\text{pt})^\gamma$ で抑える focal loss により、one-stage の速さを保ったまま two-stage の精度を超えたと報告している。損失の寄与に絞った成果であり、検出器側の形状の主張は検出器側の資料に譲り、本書では薄い扱いに留める。[10, 11]

DETR は検出を集合予測に書き換えてアンカーと NMS を外し、ハンガリアン法による二部マッチングの損失、すなわちクラスの前対数尤度と L1 と尺度不変の GIoU によるボックスの損失に、Transformer のエンコーダ・デコーダと学習した物体クエリと並列デコーディングを組み合わせた、モデル論文の著者らが述べている。予測の集合と正解の集合を一対一に対応づけてから損失を数えるため、代表値の敷き詰めも重なりの後始末も要らず、専用の仕掛けも特殊なライブラリも使わない点が転換である。同じ程度のパラメータで念入りに調整された Faster R-CNN と COCO 検証で互角、R50 で 42 AP、DC5-R101 で 44.9 AP、大きな物で +7.8 APL、小さな物で -5.5 APS、パノプティック拡張で 46 PQ と報告している。大きな物での伸びは全体を見る self-attention に帰され、小さな物での落ちはその裏返しの特性である。代償として 300~500 エポックの AdamW、16 枚の V100 で 3 日の

日程、補助のデコーディング損失の必須、クエリ枠の分業、NMS が不要と言えるのは後のデコーダ層からという重なりを抑え込みが明記され、小さな物の弱さと学習の重さは同論文自身が開いた課題として FPN 流の後継に譲る。この系譜の到達点が DINO 検出器であり、ノイズ除去のアンカーボックスの改良で R50・COCO で 12 エポック 49.4 AP、24 エポック 51.3 AP、DN-DETR から +6.0 と +2.7 AP、Objects365 で事前学習した SwinL では検証とテスト開発で 63.2 と 63.3 AP を並ぶ相手より小さなモデルとデータで出したと報告している。ここでの DINO は検出器であり自己教師ありの DINO とは別物として呼び分け、順位表の範囲の話として言葉との接地の振る舞いは Grounding DINO 側の資料に譲る。[6, 12]

YOLO-World はオープンボキャブラリーの検出を実時間の動作点へ適用拡張したものであり、付け替え可能な視覚言語の集約 RepVL-PAN と領域と文の対照学習による損失で、決まった語彙の外の言葉で指された物をボックスで捉える。モデル論文の著者測定では LVIS で 35.4 AP を V100 で毎秒 52 コマ、ゼロショットで出したと報告している。オープンボキャブラリーと実時間の両立がここで形になり、ファインチューニングしたバリエーションは検出とオープンボキャブラリーのインスタンスセグメンテーションに広がると述べている。O365 や LVIS 流の閉じた語彙でファインチューニングするとゼロショットの汎用が落ち、CLIP の汎用が 365 区分の追加学習で削れるという関係が報告され、細かく注釈したデータと疑似注釈のデータの混合事前学習が良いという所見は、何で学ぶかが振る舞いを決めるデータの契約の話として読む。YOLO の製品系列の混同を避けて版に縛った主張に留め、端末に載せる負担は動機の記録として記すだけで確かめた成果とは言わない。提案から動作点へ、動作点から集合予測へ、集合予測からオープンボキャブラリーへという順に本節の系譜を読み、ボックスを出す機械的な仕掛けの話が言葉で指せる物の話へ接続する手前までを射程とする。[7]

本節の読解上の境界

この節の読解上の境界: R-CNN の多段処理の重さは後の課題として残され、後の基準では遅い仕組みである。YOLO の精度は当時の最上位に届かないと論文自身が認めており、後の各版は別製品として扱う。版を外した主張はしない。端末搭載の負担は動機の記録であり、確かめた成果ではない。[5, 8, 10, 6, 12, 7, 9, 11]

3 指示に応える密な知覚

DENSE PERCEPTION

ボックスでは足りない画素の構造をどう捉えるか。分類からの転移、ボックスと画素の接続、指示に応える基盤、動画への拡張を契約の変化として読む。セマンティックセグメンテーションとインスタンスセグメンテーションの境を保ち、基盤の出来事と課題に縛られた装置の二重の読みを欠かさない。[13, 14, 15]

ボックスは物の居場所を示すが領域の形までは定めず、画素ごとの構造が要る所で密な予測の系譜が始まる。Fully Convolutional Networks は分類モデルを画素から画素へのモデルに書き換えて端から端まで学習させ、全結合層を畳み込みに置き換えて大きさの異なる入力から大きさに見合う地図を出す設計である。モデル論文の著者測定では AlexNet や VGG、GoogLeNet 級の分類器を FCN に仕立てて学習表現を引き継ぎ、粗い深層と細かい浅層をスキップで足し合わせて VOC 2012 で平均 IU 62.2%、相対で 2 割の伸びを 5 分の 1 秒を切る推論で出したと報告している。分類モデルは FCN の特別な場合と読み替えられ、分類からセグメンテーションへのファインチューニングという転移の契約がここで定まり、前節の分類から検出への転移と並ぶもう一つの継承である。輪郭は後の評価軸では粗く、磨き上げは後継の資料に譲る。U-Net は本書ではセグメンテーションの役割だけを担う位置づけであり、縮む経路と対称に広がる経路をスキップで結んで弾性変形のデータ拡張でごく少数の注釈から精密な位置決めを学習させ、縮めて文脈をつかみ広げて位置を戻す往復である。モデル論文の著者測定では ISBI の神経細胞スタックで滑走窓の CNN を上回り、2015 年の細胞追跡の部門で大差の 1 位、512 角のセグメンテーションを 1 秒未満、Titan で 10 時間の学習と報告している。医療画像の範囲の話であり一般の情景への転移は他の資料に譲り、拡散モデルのバックボーンとしての来歴は TS-002 の範囲として本書では扱わない。[13, 16]

Mask R-CNN はボックスの系譜と密な系譜の統合であり、Faster R-CNN にマスクの枝を並列に足して RoIAlign 級の位置合わせで検出とインスタンスマスクを同時に解いた。ボックスを出す枝と形を塗る枝が並走し、量子化のずれを抑えた位置合わせで画素と対

応づける。モデル論文の著者測定では毎秒 5 コマで小さな上乘せのまま、COCO の三部門、すなわちインスタンスとボックスと人物キーポイントのすべてで最上位に立ち、2016 年の単体の応募を小細工なしで上回ったと報告している。同じ枠組みが姿勢推定にも伸びる点は枠組みの汎用の例として読む一方、ボックスに依存した作りでありボックスに依存しない密な予測は FCN や SAM 側の資料に譲る。ボックスとは別に画素の契約そのものを言い直したのがパノプティックであり、セマンティックセグメンテーションとインスタンスセグメンテーションを一つの整合した出力にまとめ、すべてのクラスを覆う Panoptic Quality という指標を添えた。モデル論文の著者らによれば三つのデータでの人と機械の比べ直しが情景の統合的な読み直しを呼び戻したと報告し、契約を言い換える深さに留めて隠れた部分の扱いは射程の外とし、アモダ的な拡張は同論文自身が今後の課題として残している。

[17, 18]

Segment Anything は課題とモデルとデータを一まとめにした転換であり、プロンプトで指示できるセグメンテーションという課題、SAM というモデル、データエンジンで築いた SA-1B、すなわち 1100 万枚の許諾済み画像の上に 10 億超のマスクを載せたデータが一体で動く。点やボックスや文で指された所を切り出すという契約がモデルとデータの両輪で支えられ、モデル論文の著者測定では新しい分布や課題へのゼロショットの転移が従来の教師ありの成果と競うか上回る場合が多いと報告している。ここで二重の読みを欠かさない。一つは視覚の基盤の出来事としての読み、もう一つは課題に縛られた装置としての読みである。同論文自身の議論が示す構成の考え、すなわちプロンプトと組み合わせで一つのモデルが設計時に知らなかった使い回しに応えるという見立ては、DALL-E における CLIP の類推で語られ、決まった課題の対話型セグメンテーションとは大きな算法の構成要素になる点が違っていると述べている。ゼロショットの汎用は課題の範囲の中の話であり、専門のモデルに譲る反例は評価側の資料が裁くため、本節では二重の読みを保って優劣の裁定は下さない。[14]

SAM 2 はプロンプトで指示できるセグメンテーションを動画に伸ばし、密な知覚から時間の状態への拡張であるもので、プロンプトと予測をまたぐストリーミングのメモリと SA-V というデータエンジン、すなわち最大規模の動画セグメンテーションデータが中心である。時刻が進んでも指示の対象を保ち続けるために過去の予測を覚えて次の切り出しに生かし、モデル論文の著者測定では動画では対話が3分の1に減り、画像では SAM より6倍速く精度も高いと報告し、モデルとデータと学習のコードを公開したと述べている。

この対比は SAM との直接の比較条件での報告として読む。本書ではこの成果を時間の状態をどう持つかという設計の指し示しとして読み、その問いが後の節に効く点に位置づけの理由を置く。一方で配信の装置としての成否は別であり、オンラインの遅延や実地の速さの主張は Flash-VStream 側の資料に譲り、メモリの設計の範囲の話として受け取って実地の速さの根拠とは言わない。密な構造を切り出す話が時刻に沿って保つ話へ接続する、その接続点だけを本節の出口に置く。[14, 15]

本節の読解上の境界

この節の読解上の境界: 輪郭の粗さは後の基準での留保であり、磨き上げは後継に譲る。Mask R-CNN はボックスを前提とする作りのため、ボックスに依存しない密な予測は別の記録が担う。U-Net の話は医療画像の範囲に留まり、一般の情景への転移は語らない。[13, 17, 14, 15, 16, 18]

4 推論を支える空間と幾何

SPATIAL SUBSTRATE

名とボックスにはない奥行きと姿勢と関係を後の推論の例として置く。相対の深さ、身体配置、情景の関係、キャリブレーション不要の幾何の四つの例を見る。尺度の不定と人手の揺れの限りも含めて射程を明記し、四つの例は単独の概説ではなく後の推論が仮定する状態の目録として読む。[19, 20, 21, 22]

物の名とボックスだけでは後の推論が要する奥行きと立体が足りず、MiDaS は相対的な深さを野外で通用させる例である。モデル論文の著者らによれば、尺度とずれに頑健な目的関数でステレオやレーザ、構造光、3D 映画由来まで相容れない深さデータを混ぜ、素朴な混合をパレート最適な多目的の混合で上回り、補助課題で事前学習したエンコーダが効くと報告し、モデルを公開したと述べている。評価の契約が要点であり、一部のデータで学習して DIW や ETH3D、Sintel、KITTI、NYU、TUM を含む未見のデータで測るゼロショットの転移を野外の頑健さの指標に据え、見たことのない場面で通用するかを中心に置く。既存の深さデータこそ限りだと同論文自身が残して開いた問いとしており、相対の深さの範囲の話として尺度つきの主張は他の資料に譲り、2019 年当時の評価条件の話として読む。DUS3R はキャリブレーション不要の幾何の状態をモデルの出力として出す例であり、内部の値も姿勢も与えない画像対から点群地図を回帰し

て単眼と両眼の再構成を一本にし、全体の位置合わせで共通の枠に載せる。較正の数値を入力に要求せず対応する立体を出力として得る逆転であり、下流でカメラや深さや対応が取り出せ、単眼と多視点の深さと相対姿勢で当時の最上位、定番の Transformer のエンコーダ・デコーダで事前学習の資産を使うと報告している。ただし点群地図は不定の尺度までであり、幾何の制約を設計で明示的に課さず、整合した学習データの事前分布に頼ると明記している。[19, 22]

分類の特徴量だけでは身体は動かず、OpenPose は多人数の2次元姿勢を下から積む例である。手足の位置と向きを入れた2次元ベクトル場、すなわち Part Affinity Fields で四肢を表して貪欲な二部マッチングで組み立て、部位の点を追うのではなく四肢の流れの場でつながりを表す点が設計の中心である。人数によらず実時間で動き、場だけの洗練が実行速度を倍にして精度を約7%上げ、身体と足を合わせた検出が速さと部位ごとの精度を保ち、135 点のキーポイントの仕組みを公開したと、モデル論文の著者らが報告している。物中心の空間状態と対応づけ自体を表現にする実演が要点であり、何であるかではなくどう配置にあるかが要る課題の例として、分類の特徴量が行動を直接駆動できない理由を示す。2次元の姿勢の範囲であり3次元への持ち上げは扱わず、2019 年当時の計算機の

評価条件の話として読む。Visual Genome は関係の構造を一級に据えた例であり、Visual Genome 論文の著者らによれば 10 万超の画像に 1 枚あたり約 21 の物体、約 18 の属性、約 18 の関係、42 超の領域記述、約 17 の問答を載せ、WordNet の synset に正準化し、情景グラフの定式が検索と文生成を押し上げたと報告している。物と性質と関係を同じ表に載せて領域ごとの言葉を添える分厚い注釈であり、関係と属性を主役に据えた点が情景の構造の読み、同時に領域記述が後の言葉との接地のデータの源流になる。混み入った人手の揺れと正準化の限りは明記し、GoldG 流の来歴の主張は GLIP 側の資料に譲る。[20, 21]

ラベルにはないものがここでの主題であり、物の名のラベルは奥行きを定めずボックスのラベルは身体の向きを定めない。MiDaS の相対の深さと OpenPose の 2 次元姿勢は、その欠けを埋める状態の例であり、深さの状態は遮蔽の前後や床の広がりやを推論の下に敷き、姿勢の状態は手足の配置と人物の向きを行動の下に敷く。どちらが手前にあるかという順序が後の判断の前提になり、どう配置にあるかが後の動作の前提になり、後の検出や推論が当然のように仮定する空間がここで例として用意される。ボックスの入出力だけでは足りない分を状態の入出力が補う関係が空間の契約の

内実であり、深さは相対のまま姿勢は 2 次元のままという射程の明記と対で読む。トークンに刻んでも残るものは何かという問いに対し、奥行きの順序と身体の配置が残るべき状態だという整理が本節前半のまとめである。[19, 20]

関係と幾何がそろそろと情景は物の列挙ではなくなり、Visual Genome の関係と属性と DUS3R のキャリブレーション不要の点群地図はその例である。誰が何を持ち何の上にあるかという関係の状態と、見る位置が変わっても保たれる幾何の状態が後の接地と推論の下に敷かれ、言葉が指す相手を決める課題にも見えの奥行きを読む課題にも同じ例が効く。較正のパイプラインを要求せずモデルの出力として幾何を得る設計は統合や行動の節への接続点になり、数値を入れて解くのではなく学習したモデルが出す状態から始める逆転である。限りも明確にし、人手の揺れと正準化の難しさ、尺度の不定、学習済みの事前分布への依存は残り、NeRF や 3DGS、SLAM、MVS、3 次元検出への拡張はしない。後継は新しい契約を足さないため範囲から除く。四つの例は概説ではなく後の推論が仮定する状態の目録であり、密な知覚の節から言葉と推論の節へ渡る手前で空間と幾何の例を確認した。[21, 22]

本節の読解上の境界

この節の読解上の境界: 深さは相対の範囲に留まり、尺度つきの主張はしない。姿勢は 2 次元の範囲に留まり、3 次元への持ち上げは扱わない。いずれも 2019 年当時の条件の上での記録である。[19, 20, 21, 22]

5 OCR から文書理解へ

DOCUMENT INTELLIGENCE

文字起こしから配置と構造の読みへ。LayoutLM 系と OCR フリー系の系譜をたどり、画素だけを見る設計の制約と二つの特化型の失敗の姿を比べる。検索界面と二つの評価契約の許容を添え、順位付けは行わない。[23, 24, 25]

LayoutLM は文書理解に事前学習を持ち込んだ起点である。Xu らによれば、トークン埋め込み・レイアウト埋め込み・画像埋め込みを一つの Transformer に入れ、大量のラベルなしスキャン文書で自己教師あり学習する。書式理解・領収書理解・スキャン文書分類で評価し、先行の事前学習モデルを大きく上回ったと、

モデル論文の著者測定として報告している。転換の要点は、文字の並びだけでなく配置を教師信号に加えた点にある。欄と値の対応は語順だけでは決まらないため、配置込みの表現を先に学ぶ手順が対応づけを支える。ただし対象はベース版の範囲に限られ、画像側の扱いは浅い。論文は、より多くのデータと計算、画像埋め込みを含む LARGE 構成、新しいアーキテクチャと自己教師あり目的関数を試す方向を明示している。文書 AI をデータと計算の規模で読む見方はここに始まる。LayoutLMv3 はこの系譜の後継である。Huang らによれば、事前学習済み CNN や Faster R-CNN の視覚バックボーンを使わず、領域アノテーションも要

さない。視覚バックボーンを排した分、パラメータを節約する。テキストへのマスク言語モデル、画像へのマスク画像モデル、単語とパッチの対応づけを一組の目的関数として解くと、モデル論文の著者測定として報告している。文字中心と画像中心の双方の課題で汎用性と優位を示したとしている。画像モダリティの事前学習目的を外すと線形パッチ埋め込みは振るわず、色やトークンの再構成に変えると下流課題が落ちるというアブレーションが、目的関数の設計の効きを示す。より大きなデータと計算への拡張や few-shot とゼロショットの能力は将来課題であり、確立した成果ではない。[26, 27]

Donut は OCR を使う前提を外した分岐である。Kim らによれば、文書画像をエンドツーエンドの Transformer で直接、構造をもつ出力に写し、ページごとの OCR の計算コスト、文字列だけを返す硬さ、誤読が後段へ波及する連鎖の三つを取り除く。文書理解の課題で速度と精度の到達点に届いたと、モデル論文の著者測定として報告し、コードとモデルを公開している。言語や領域を切り替える工夫として SynthDoG という合成データ生成器を添え、実文書の収集を待たずに言語と体裁の組み合わせを起こせる。集めにくい言語や体裁にも、合成で手を伸ばす。ただし合成学習への依存が残り、合成で見ない汚れや崩れには弱いという限界が、領域を移すときの転移を縛る。事前学習とファインチューニングの効きは入力解像度に強く左右されると論文自体が述べる。細かい文字を読むための高解像度化は、トークン増による学習と推論の負荷と天秤にかかる。画素だけを見る設計では、高解像度化が系列長の制約にぶつかる。どこに何トークンを割くかの配分が、文書を読む設計の要点になる。この制約は、科学論文特化の後継が引き継ぐ。汎用の OCR 理論も別の見方で同じ制約に向き合う。[28]

Pix2Struct は画素だけを見る流れをスクリーンショットの構文理解へ広げた。Lee らによれば、マスクしたウェブのスクリーンショットから簡略 HTML を再構成する事前学習が、OCR と言語モデルとキャプションの信号を一つの課題に畳む。HTML の再構成は、文字と配置と要素名を同時に当てる課題である。入力の解像度を可変に保ち、画像の上に描いた文字で指示を与える。縦長の頁も横広の画面も、そのまま受ける。絵の中の文字が、絵への指示になる。文書と図

版と UI と自然画像にまたがる九つの課題のうち六つで、単一モデルとして初めて到達点に届いたと、モデル論文の著者測定として報告している。転換の要点は、読む対象を文書に限らず、モバイルアプリやボタンや書式を同じ純粹に視覚の理解の枠に入れた点にある。UI を文書の延長として扱う整理は画面操作の節へ渡すためのものであり、押す・遷移する議論は本節では行わない。高解像度化が系列長の制約になるという限界は Donut 系と共通であり、論文自体の議論として残す。文書検索の界面として、Qwen チームの報告によれば、Qwen3-VL-Embedding は視覚言語モデルを基盤にした検索パイプラインであり、埋め込みは多段階の対照事前学習からリランカ蒸留へ進み、Matryoshka 次元と 32K 入力と 2B・8B 構成をもつ。32K 入力で長い文書も切らずに受け、2B と 8B の二構成で運用点を分ける。8B が MMEB-V2 で 77.8 を得て 2026 年 1 月 8 日時点で 1 位に立ったとしているが、これはモデル論文の著者測定によるプレプリント時点の主張であり、独立した第三者再現はまだない。多言語 30 言語超の対応は Qwen3-VL から引き継ぐ。本節では検索は文書を読む主体の議論に従属させ、細部には立ち入らない。[23, 29]

Nougat は科学論文に絞った特化型の到達点である。Blecher らによれば、Donut の系譜を引く Swin エンコーダ・デコーダが科学論文の PDF をマークアップに変換し、本文と LaTeX 数式と表を一つの出力に載せる。数式の添字や表の桁揃えを、文字起こしの延長で直列化する。arXiv と PMC と IDL から作った学習ペアで学び、モデルとコードを公開している。機構の要点は、配置と数式と表構造を文字起こしの延長で直列化する点にある。汎用モデルが画面全体を読むのに対し、論文の体裁に強く寄せた入出力の契約をもつ。だからこそ失敗の姿がはっきり出る。同じ行や断片を繰り返し吐いて止まれなくなる繰り返しのモードがあり、研究論文の構造に偏るため他の文書では出来が落ちる。学習のほぼ全体が英語で、ラテン系言語の小さな試験しかない論文自体が述べる。比較の規律も明示する。自前の試験でのマークアップ一致を GROBID や pdf テキスト抽出と比べるだけで、他モデルとの数値優劣は付けない。評価の契約は DocVQA が定める。12K 超の文書画像に 50K の問いを載せ、九種の推論型に分け、八対一対一で割ると、ベンチマーク論文の著者による第三者測定として報告してい

る。指標は ANLS に正確度を添える。ANLS は文字の小さなずれを許容する指標であり、一字のずれで零にしないという許容と組で読む。素の正確度だけを置かず必ず ANLS で読むのは、OCR 部分文字列の上限が膨らむからである。抜き出して拾える問いは、読めたことにならない。人手の 94.36% に対し、LoRRA や M4C や BERT-QA といったベースラインとの差は、表や欄の対応を要する構造を読む問いで開く。データセットとコードとリーダーボードを公開し、WACV 2021 で発表した。汚染は中程度、言語先行の危うさは高いとされ、抜き出しの近道が残り、ウェブ文書の混入も避けがたい。[24, 30]

GOT は OCR-2.0 という理論を掲げる別系統の特化型モデルである。Wei らによれば、人工の光学的信号をすべて文字とみなし、580M の単一エンドツーエンドモデルで解く。80M の高圧縮エンコーダが 1024 画素を 256 トークンに畳み、長いコンテキストのデコーダが受ける。この圧縮により、長い文書を一つのモデルで受ける。素の出力と整形出力を切り替え、markdown や tikz や smiles や kern を書き分ける。領域を指定して対話的に読む OCR、解像度を動かす読み、複数ページの読みを備えると、モデル論文の著者測定として報告している。OCR-1.0 のパイプラインより構造が単純で、汎用視覚言語モデルより OCR に絞る分、報告した性能が上回るという位置づけは、自前の OCR-2.0 一式の中での主張として隔離する。同

じ手順で測った汎用モデルとの直接対決は見つかっていない。図表を読む契約は ChartQA が定める。9.6K の人手設問と 23.1K の生成設問を、目で見える読みと論理の読みに分け、緩和正確度で測ると、ベンチマーク論文の著者による第三者測定として報告している。緩和正確度の許容の意味は数値と切り離さず、許容の幅と組で読む。実世界の図表を対象とし、FigureQA や DVQA や PlotQA の合成前史を文脈に置く。作られた図の文脈を背負い、生の図に進む。報告時点の到達点は VisionTaPas で、Findings ACL 2022 で発表し、リポジトリを開く。[25, 31]

二つの特化型の比べは、数値の順位ではなく設計の選びで行う。Nougat は論文の体裁に寄せ、GOT は文字の理論に寄せる。Nougat の崩れは繰り返しと言語と構造の三つに現れ、GOT の工夫は圧縮と動的解像度と領域指定の三つに現れる。どちらが上かを定める材料は同一条件の対決の記録しかなく、その記録は見つかっていないため、本節は数値の順位を付けない。解像度の制約は両者に共通する。Nougat は Donut の系譜の制約を引き継ぎ、GOT は圧縮と動的読みで同じ制約に向き合う。制約の共有と向き合い方の分岐を、順位なしに残す。体裁への寄せと文字の理論の二流派が、同じ制約に別の見方で向き合ったことが、本節の記録である。どこで特化が崩れるかの記録が、汎用の節の設計に生きる。ANLS と緩和正確度の許容も数値と組で読み、許容を外した数比べはしない。[24, 25]

本節の読解上の境界

この節の読解上の境界: Nougat と GOT の評価は自前の試験の範囲に留まる。Nougat の繰り返し・言語・構造の偏りは論文自身の申告であり、GOT と汎用モデルの同一条件での直接対決は見つかっていないため優劣は決めない。検索モデルの順位は著者測定のプレプリント時点の主張であり、独立した再現はない。図表の数値は緩めた正確さの許容と組で読む。[26, 27, 28, 23, 24, 25, 29, 30, 31]

6 Transformer と自己教師あり学習の基盤

VISUAL FOUNDATIONS

畳み込みからパッチ系列へ。トークンの定式と階層と目的関数と蒸留を分け、視覚の基盤が言語と結ばれる前の仕組みと残る問いを整える。規模かレシピかの論点を添え、トークン化とアーキテクチャと目的関数と蒸留を分けて読む。効率の一般論には踏み込まない。[32, 33, 34]

Vision Transformer は畳み込みから系列への組み替えである。Dosovitskiy らによれば、画像をパッチに切り、パッチ系列に素の Transformer を載せ、パッチ切り出しのほかは画像固有の帰納バイアスをほぼ排する。仮定を外した分、データと計算で補う。大規模な事前学習と転移で CNN の到達点に並び、超えると、

モデル論文の著者測定として報告している。同じ到達度では CNN より少ない計算で学べるとも述べる。本巻の読み筋は効率ではなく、トークンの定式にある。画像を系列として扱う約束が、後の視覚と言語のトークン融合の前提になる。100B 級パラメータの時代を背景に置く。ただし大規模な事前学習への依存が残り、データが乏しい所では振るわない。DeiT はこの依存に対する学習レシピ側の答えである。Touvron らによれば、学習手順の改善と Transformer 専用の蒸留トークンでデータ効率を上げ、蒸留トークン経由で畳み込み教師モデルの教師信号を借りる。外部データなし・86M パラメータ・単一マシン 3 日弱で ImageNet top-1 の 83.1% に達し、蒸留で 85.2% まで伸び、転移も競ると、モデル論文の著者測定として報告している。畳み込みモデルが十年かけて積んだ構成と最適化の蓄積に対し、データ拡張と正則化の学習レシピを借りて目新しい仕掛けなしに並ぶ点が、規模かレシピかの論点になる。構成探索が過適合に陥りがちな例も引き、規模とレシピの論点を支える。ただし教師モデルへの依存が残り、先行事例として短く扱う。Swin Transformer は階層を保つ側の完全性を担う。Liu らによれば、局所ウィンドウとずらしによる窓間結合でアテンションを組み、画像寸法に線形の計算量で解く。ImageNet-1K top-1 で 87.3、COCO test-dev でボックス AP 58.7・マスク AP 51.1 と先行を 2.7 と 2.6 上回り、ADE20K で mIoU 53.5 と 3.2 上回ったと、モデル論文の著者測定として報告し、コードとモデルを開く。階層を要する検出や密な予測へ Transformer の適用範囲を広げる役割であり、本節では短く置く。[\[32, 35, 36\]](#)

MAE はラベルなしで学ぶマスク再構成の柱である。He らによれば、非対称のエンコーダ・デコーダを置き、エンコーダは見えるパッチだけを受け、軽いデコーダが欠けた所を戻す。75% を隠す高いマスク率で、学習を 3 倍超速めながら精度も上げたと、モデル論文の著者測定として報告している。符号化の量を絞る分、学習が速い。大きな容量のモデルほど伸びる。仕組みの要点は、見える所だけを符号化する点にある。隠す割合を上げると課題が難しくなり、表層の写しではなく使える表現が残る。易しい写しでは残らないものが、難しいマスク再構成では残る。目的関数の群では再構成の側に立ち、対照や蒸留とは別の流れである。ただし再構成と表現の読み分けが要る。画素を

戻せることが、そのまま下流課題の強さを意味しない。転移の主張には課題側の指標による根拠が要り、本節では仕組みの範囲に留める。[\[37\]](#)

DINO 自己教師ありは、ラベルなしの自己蒸留から立ち上がる。検出器の DINO とは同名別物であり、本節ではつねに自己教師ありと呼ぶ。Caron らによれば、ViT へのラベルなし自己蒸留が、教師あり ViT や畳み込みモデルに見られない創発の性質を生む。CLS アテンションマップに意味的セグメンテーションの情報が現れ、小さな ViT で ImageNet kNN top-1 の 78.3% に達したと、モデル論文の著者測定として報告している。モメンタムエンコーダとマルチクロップと小さなパッチが効き、ViT-Base では線形評価 top-1 の 80.1% に届く。仕組みの要点は、教師モデルなしに教師の役割を動かし続ける点にある。蒸留の群に属し、対照や再構成とは別の流れである。ただし創発の射程は区切る。アテンションに現れた片鱗が、そのまま検出のボックスになるとは限らない。DINOv2 はこの流れをスケーリングし、基盤の特徴に育てた。Oquab らによれば、自動で整えるデータパイプラインと拡張した学習で 1B 級 ViT を学び、小さなモデルへ蒸留する。人手のファインチューニングなしに汎用の特徴が弱教師ありの代替に迫り、画像と画素の多くのベンチマークで OpenCLIP を上回ったと、モデル論文の著者測定として報告している。汎用の特徴とプロンプトで指示できる界面は、基盤という同じ言葉で別物を指す。強い特徴と指示のインターフェースは別の契約である。ただし凍結評価の転移の範囲に留まり、凍結で測った強さがファインチューニング先の強さを約束しない。[\[33, 38\]](#)

SigLIP はアライメントの目的関数を組み替えた。Zhai らによれば、ペアごとのシグモイド損失で学び、大域ソフトマックス正規化を排する。パッチ規模と損失の結びを解き、1M 級パッチまで拡張できるが伸びは鈍り、32K で足り、小さなパッチでもよく働くと、モデル論文の著者測定として報告している。画像側を凍結した調整では、SigLiT が 4 枚の TPUv4 で 2 日かけ ImageNet ゼロショット 84.5% に達した。視覚エンコーダを凍結し、テキスト側のみを調整するものである。ICCV 2023 オーラルで発表し、モデルを開く。仕組みの要点は、正規化の大域性を捨て、各画像・テキスト対を独立に判定するシグモイド損失に置き換える点にある。目的関数の群に属し、定式や階層や

蒸留とは別の流れである。継承の事実もある。Qwen 側の報告によれば、SigLIP2-So400m が Qwen3-VL と Omni のエンコーダの中に続く。2026 年時点の再利用の事実として受け止める。ただし正確な引用対応は未確定のまま残る。損失の仕組みの記述は抄録頁の水準に留まり、正確な典拠は結ばれていない。結ばれていない引用は結ばれていないと書く。[34]

基盤の流れは視覚言語モデルのエンコーダに集まる。Qwen 側の報告によれば、SigLIP 系のエンコーダが Qwen3-VL と Omni のエンコーダの中に続く。再利用の事実は報告として受け止め、正確な典拠との対応の

なさも同時に記す。ViT がトークン化を定め、Swin がアーキテクチャの完全性を保ち、MAE が戻す目的関数を示し、DINO 自己教師ありが蒸留による創発を示し、SigLIP が一対判定の目的関数に組み替えた。トークン化とアーキテクチャと目的関数と蒸留の切り分けが、基盤の節の要点である。効率の一般論は別巻に譲り、本巻は表現の契約を読む。分けた整理が、次の節の入口になる。残る問いは三つである。大規模事前学習への依存、再構成と表現の読み分け、正確な典拠との対応のなさであり、次の節では接地の話を扱う。[38, 34]

本節の読解上の境界

この節の読解上の境界: ViT の到達は大規模な事前学習への依存の上であり、DeiT は学習手順の改善と蒸留でこの依存を緩和する。SigLIP の損失の仕組みの記述は抄録頁の水準に留まり、正確な引用対応は未確定のまま残る。[32, 37, 33, 38, 34, 35, 36]

7 画像と言語をつなぐアライメント

ALIGNMENT

決まった分類名から言葉で指せる画像の意味へ。400M ペアの学習が開いたゼロショット転送と検索の契約を整え、語の並びや帰属の読みが落ちる画像全体のアライメントの限界を次の節で扱う。全体の照合と位置の特定を混ぜない。評価指標の切り分けを守る。[39, 40]

CLIP は決まった分類名の教師信号から、言葉で指せる画像の意味への転換である。Radford らによれば、ウェブ由来の 4 億ペアでキャプション予測の事前学習を行い、自然言語で呼び出せる転移可能な表現を学ぶ。文と絵の大量の組を対照学習し、言葉を概念への言及の界面に育てる。ImageNet の 128 万枚のラベルを一つも使わず、教師あり ResNet-50 に並んだと、モデル論文の著者測定として報告している。OCR や動画の行動認識や位置推定や細粒度分類を含む 30 超のデータセットへゼロショット転送し、コードと重みを開く。転換の要点は、概念への言及の界面が言語になった点にある。あらかじめ定めたカテゴリの教師信号を、画像とテキストの教師信号に置き換えた。決まったカテゴリの固定クラス分類から、言葉の開いた呼び出しへの転換である。TS-003 の読み筋はこの呼び出し可能性であり、条件づけの再利用は生成を扱う

巻に譲る。この転換は無から生じたのではない。先行に Show and Tell がある。Vinyals らによれば、CNN エンコーダから RNN デコーダへ尤度学習で文を起こすエンドツーエンドのキャプション生成が、Pascal で BLEU-1 の 59 (当時 SOTA 25、人手約 69)、Flickr30k で 66、SBU で 28、COCO で BLEU-4 の 27.7 の SOTA に達したと、モデル論文の著者測定として報告している。絵を文にする道が先にあり、文で絵を呼ぶ道が後に続いた。小さな視覚表現から文を起こせることを示した先行であり、CLIP の唐突さを和らげる文脈である。ただし生成側の細部は生成を扱う巻がもち、本巻は先行の役割だけを記す。[41, 39]

VQA はキャプションより細かい画像理解を迫る課題の先行である。Antol らによれば、約 25 万枚の画像に約 76 万の問いと約 1000 万の答えを載せ、自由形式の開いた問いを立てる。絵に一文を添えるのではなく、絵への問いに応える。数や色や配置や関係を問う。汎用キャプションより細かい理解と込み入った推論を要し、短答と選択肢による自動評価を備えると、ベンチマーク論文の著者による第三者測定として報告している。課題の先行としての役割は、言語先行の近道が後に暴かれた場でもある点にある。画像を見ずに言葉の

癖だけで当たる振る舞いが見つかり、後の制御ペアによる診断の起点を共有する。評価方法の同一性を保ち、検索の数値で位置の優劣を語らない。評価条件の定めなしの数値は、意味をもたない。VQA-v2 の学習分割の混入と先行の悪用のしやすさが留保となり、学習分割と答えの抽出規則を数値と組で読む。CLIP の側の測り方はここで定める。ゼロショット転送と検索の契約であり、位置や領域を測る契約とは別物である。画像全体とテキストの意味対応づけをアライメントと呼び、後の節の操作と混ぜない。CLIP の到達点は画像水準の意味の呼び出し可能性であり、どこに何があるかの特定ではない。[42, 39]

ALIGN は雑音の多いウェブ規模で CLIP の流れをなぞるバリエーションである。Jia らによれば、10 億超の代替テキストペアに最小限の頻度洗浄だけを施し、規模で雑音を補う。丁寧な洗浄を排し、量で質の不足を埋める。デュアルエンコーダの対照アライメントで、SOTA の表現とゼロショット分類、Flickr30K と MSCOCO の検索 SOTA に届き、cross-attention 型を上回ったと、モデル論文の著者測定として報告している。

エンコーダを分けて照合する素朴な構成が、規模の前では込み入った構成を上回る。規模が雑音を補うという読みは、対照の裾野の広さの記録である。最小限の洗浄で足りるという主張は、バリエーションとしての位置にとどめ短く扱う。バリエーションとしての記録に留め、洗浄の免罪にはしない。CLIP の側の限りは論文自体が記す。Limitations の節があり、残る弱さを名指しする。画像全体とテキストの一括対応づけは、語の並びや帰属の読みを落とす。どの語がどの物に掛かるかの構造が、全体の照合では抜け落ちる。一括で照合する限り、掛かりは見えない。効率や規模への批判は後継の記録に譲り、SigLIP の目的関数の組み替えがその後継の対応であることは基盤の節に記した。4 億ペアの対照学習が、30 以上のデータセットへの転送を生んだ。ゼロショットと検索の数値は、位置特定の数値と並べて優劣を付けない。一括対応の限界が残るからこそ、任意の言葉を位置や領域へ結ぶ仕組みが要る。CLIP が開いた呼び出し可能性をどこに何があるかの特定へ延ばすことが、次の節の主題である。アライメントの到達を起点に接地の仕組みを扱うのが次の節である。[39, 40]

本節の読解上の境界

この節の読解上の境界: VQA の素の正確度は、学習分割の混入と言葉の癖で当たる問いの混入のため、そのまま読めたことにはならない。学習分割と答えの取り出し規則と組で読む。画像全体の照合は語の並びや掛かりの読みを落とし、この限界が次の接地の節への動機になる。[39, 41, 42, 40]

8 言葉をボックスとマスクに結ぶ接地

GROUNDING

任意の言葉をボックスとマスクと座標に結ぶ展開を、定式と蒸留と語彙と融合と自己学習とセグメンテーションの機構群でたどる。評価指標は契約ごとに分け、未見の主張は語彙空間と学習分割の定義に縛る。定式からセグメンテーションまでの六群を残し、数値の優劣は付けない。[43, 44, 45, 46]

オープンボキャブラリーへの展開は、課題と測り方の取り決めから始まる。Plummer らによれば、Flickr30k Entities は 158K のキャプションに 244K の共参照鎖と 276K のボックスを添え、領域とフレーズの対応を大規模に集めた最初のデータセットであり、フレーズ局所化という課題を立てたと、ベンチマーク論文の著者による第三者測定として報告している。同じ物を指す

言い回しの鎖と、その物のボックスを一組にする。検出に似るが訓練時にフレーズは未見だという位置づけが、決まったカテゴリの検出から開いたフレーズ集合への局所化への進みを示す。CCA 埋め込みのベースラインは Recall@1 で約 25% から、Fast R-CNN 特徴で約 50% に上がった。対応を手で与えた学習が与えない学習を上回るという教師信号の知見も置く。ただし人と動物に偏る領域差が残り、二値検索の使いには大域照合の拡張が要ると議論自体が区切る。指示表現の評価条件を定めるのは RefCOCO である。Yu らによれば、関係を含む曖昧な記述の下で単一の指示対象を言い分ける契約を RefCOCO $\cdot + \cdot g$ で定めると、ベンチマーク論文の著者による第三者測定として報告し

ている。合成の文脈モデル化で組み立てる。ファインチューニング後の REC とゼロショット REC は手順の違いであって、新しい節ではなく、ゲーム収集の表記は収集の癖を残す。三つ目の評価指標が LVIS である。Gupta らによれば、164K 画像に 1000 超の基本水準カテゴリで約 200 万マスクを載せ、Zipf の裾野をもつと、ベンチマーク論文の著者による第三者測定として報告している。レア・コモン・フリークエントの分割が LVIS-rare AP を OVD 評価の基準にし、ODinW を実世界・多様ドメインの補完的評価として添える。三つの評価指標は混ぜない。フレーズの Recall@K と RefCOCO の接地精度と LVIS-rare AP は別の契約である。レア分割の手順は使うたびに結び付け、ウェブ事前学習の隣接が未見の読みに響くと留保する。開世界検出の話題は脇に置く。[47, 48, 49]

OVR-CNN はオープンボキャブラリー検出を名指しした定式の起点である。Zareian らによれば、two-stage の枠組みで認識と位置特定を切り分ける。認識はキャプションから学び、V2L 投影（視覚から言語への投影）と接地・MLM・ITM 事前学習をオープンボキャブラリー VC の上で解く。位置特定はベースカテゴリのボックスから学ぶ。どこにあるかは決まったカテゴリで学び、何であるかはオープンボキャブラリーで学ぶ。27% mAP でゼロショット基線の 10%を離し、ベースカテゴリの精度は教師ありに迫り、弱教師ありの 26%を上回ったと、モデル論文の著者測定として報告している。定式の要点は、どこにあるかと何であるかの教師信号の出所を分けた点にある。出所の切り分けが、定式の名に値する。ただし開かれ方は埋め込みに縛られる。事前学習した単語埋め込みの範囲に限ると論文自体が断り、埋め込みの質の議論は蒸留の節に譲る。ViLD はこの定式の最初の蒸留の継承である。Gu らによれば、CLIP・ALIGN の教師モデルを two-stage の生徒モデルに蒸留する。ViLD-text の領域テキスト蒸留と ViLD-image の領域画像蒸留の二本立てである。LVIS-rare でマスク AP 16.1 (R50、教師あり対応を 3.8 上回る)、ALIGN 教師モデルで 26.3 に達したと、モデル論文の著者測定として報告している。直接転移で VOC 72.2 AP50、COCO 36.6、Objects365 11.8 を示し、COCO で OVR-CNN をノベル 4.8・全体 11.4 上回ったとし、コードを開く。OVR-CNN が出所を分けたのに対し、ViLD は画像全体の教師モデルを領域の生徒モデルに移す。教師モデルの取り替えが、

レアの評価値を押し上げる。ただし教師モデルに縛られる。教師モデルの質が生徒モデルの上限になり、LVIS-rare の評価値はレア分割の手順と一緒に記し、ウェブ由来の教師モデルが未見の読みに隣接するという留保を付ける。[43, 50]

蒸留による転移と領域事前学習は、別の仕組みとして両方残す。RegionCLIP は領域ずれの診断から始まる。Zhong らによれば、CLIP は画像全体とテキストを結ぶが、領域にはそのまま落ちない。そこで CLIP 教師モデルと雛形キャプションで疑似の領域テキストペアを起こし、領域表現を対照事前学習する。COCO と LVIS のノベルで先行を AP50 で 3.8、AP で 2.2 上回り、ゼロショット推論を支えると、モデル論文の著者測定として報告し、コードを開く。ViLD との違いはここにある。ViLD が検出器への蒸留で教師モデルを移すのに対し、RegionCLIP は領域表現自体を事前に組み替える。ただし疑似ラベルの雑音に縛られる。教師モデルの付けた仮の文には誤りが混じり、雛形への依存が残る。雛形の文型でしか領域を語れない。教師モデルの質と雛形に縛られる点は ViLD と共通であり、どちらも教師モデルの出力への依存という点で共通である。評価値は LVIS-rare と COCO ノベルの契約に結び付け、ウェブ由来の教師モデルが未見の読みに隣接すると留保する。[50, 51]

Detic は語彙への教師信号を画像水準ラベルで賄う流れである。Zhou らによれば、ImageNet-21K の画像水準教師信号で検出器の分類器を学ぶ。複雑な割り当てを排し、最大寸法の提案への割り当てで解く。オープンボキャブラリーの LVIS で全体 2.4・ノベル 8.3 の上積み、標準 LVIS で 41.7 mAP（全体とレア）に届き、ファインチューニングなしに汎化する初の 21K カテゴリ検出器だと、モデル論文の著者測定として報告し、コードを開く。二万超のカテゴリを、学び直しに指せる。仕組みの要点は、ボックスなしラベルを最大の提案に預ける割り切りにあり、語彙の広さをボックスの不足と引き替える。ただし割り当ての発見的選別に縛られる。画像の全ラベルを統計のモデルなしに同じ領域へ教師信号を与える点が、論文自体の限りである。大きい物に偏る割り当てが、小さい物の学びを痩せさせる。写る物の名も背景の名も、一つのボックスに載る。認識の教師の出所を変える流れとして、定式と蒸留の群の隣に置く。LVIS-rare の数値はレア分割の手順と一緒に記す。ウェブ事前学習の隣接

が未見の読みに響くという留保を付ける。[52]

GLIP は検出をフレーズの接地に言い換え、接地データの規模で支えた。Li らによれば、検出と接地の事前学習を一本にし、27M の接地データ（人手 3M とウェブ 24M、自己学習の接地ボックス）を用いる。COCO 画像を見ずにゼロショット COCO 49.8・LVIS 26.9 AP で教師あり基線を上回り、ファインチューニングで COCO val 60.8・test-dev 61.5、13 転移課題の 1 ショットで完全教師あり Dynamic Head に迫ったと、モデル論文の著者測定として報告し、コードを開く。言い換えの要点は、カテゴリの分類をフレーズとの対応に替えた点にある。ただし 27M という規模の主張は論文報告として記し、GoldG の内訳は根拠の深さの確認に譲る。MDETR は同じ接地の訴えを構成の側から担う早期融合の流れである。Kamath らによれば、生テキストクエリで条件づけた DETR を端から端まで解き、テキストと画像を早期に融合する。整合したフレーズ物体データ 131 万ペアで事前学習し、Flickr30k フレーズ接地と RefCOCO+ の REC と PhraseCut の RES で SOTA、GQA と CLEVR の VQA で競い、裾野の few-shot 検出を示すと、モデル論文の著者測定として報告し、コードとモデルを開く。一つの構成で四つの課題を賄う。GLIP と MDETR の分担はここにある。GLIP が言い換えをデータ規模で支えるのに対し、MDETR は変調多課題の構成で解く。ただしファインチューニング後の REC とゼロショット REC は手順の違いであって、新しい節ではない。接地の評価はフレーズ Recall@K と REC 精度に分け、LVIS の AP とは混ぜない。データの規模の流れから、構成の混ぜの流れへ進む。[44, 53]

融合方式は、後段融合の最小構成と密な融合に分かれる。OWL-ViT は後段融合の最小主義の流れである。Minderer らによれば、標準 ViT に対照の画像テキスト事前学習を施し、適応策と正則化を添えて端から端まで検出ファインチューニングする。追加モジュールなしで、学習手順のみを調整して検出へ適応させる。画像水準事前学習の規模とモデル寸法が検出を一貫して上げ、テキスト条件のゼロショット検出と画像条件の 1 ショット検出に強いと、モデル論文の著者測定として報告し、コードとモデルを開く。文で指す強さと、絵で示す強さの両立てである。ただし最小主義は到達の終わりではなく、規模の手順は OWL-ST 側の根拠が要る。Grounding DINO は密な融合の統一であ

る。Liu らによれば、DINO に接地事前学習（検出と接地とキャプションのデータ）を添え、特徴増強、言語誘導クエリ選択、cross-modality デコーダの三段階で密に融合する。COCO ゼロショット AP 52.5（ゼロショットは学習に試験分割を使わないという論文定義）、ODinW ゼロショット記録の平均 26.1 AP に達したと、モデル論文の著者測定として報告し、チェックポイントと推論コードを開く。REC も陽に評価し、将来のゼロショット REC に注意を促す。どの分割を見ないことにするかは定義が、ゼロショットの意味を決める。GLIP と Grounding DINO の分担はここにある。GLIP が言い換えの実務であるのに対し、こちらは融合設計の統一である。追加構成なしの転移と三段階の融合の対比である。ただし REC ゼロショットは注意を要する残された課題だとする論文自体の呼びかけを記す。ODinW の平均と COCO のゼロショット AP と REC 精度は別の契約であり、未見の言い方は学習分割の定義に縛る。[54, 45]

OWL-ST と OWLv2 は、ウェブ規模の自己学習でレアを押し上げた。Minderer らによれば、N グラム機械ラベル空間と弱い選別に、学習効率の改善（OWLv2）を添えた手順である。人手のボックス注釈なしにレアカテゴリで LVIS-rare 31.2%から 44.6%へ上げ、相対 43%の伸びだと、モデル論文の著者測定として報告している。仕組みの要点は、ラベル空間を機械に起こさせ、弱く選別して回す点にある。NeurIPS 2023 の本論文 PDF を機構の細部まで読んだ上で記す。ただしウェブ依存が残り、量の恵みと癖の混入は一組である。機械ラベル空間と人手ラベル空間の分析を論文自体が行い、未見の読みは空間の取り方で変わると断る。31.2%から 44.6%への伸びは、機械ラベル空間の下での伸びである。LVIS-rare の数値はレア分割の手順に結び付け、ウェブ事前学習の隣接が未見の読みに響くと添える。[46]

オープンボキャブラリーセグメンテーションの枝は、画素と言葉の照合から始まる。LSeg は画素テキスト照合の起点である。Li らによれば、テキストエンコーダのラベル埋め込みと Transformer の密な画素埋め込みを対照学習する。意味の近いラベルは埋め込みの領域を共有し、cat と furry が引き合う。再学習や追加の学習データなしに未見カテゴリへゼロショット汎化し、固定ラベルセグメンテーションモデルと競ると、モデル論文の著者測定として報告している。ただし起

点の射程に留まり、指示セグメンテーションまでの統一には X-Decoder 側の根拠が要る。X-Decoder は汎用と指示の統一である。Zou らによれば、疑似ラベルなしに汎用セグメンテーションと指示セグメンテーションと言語視覚課題を汎用デコーダでまとめ、七つのデータ集合でオープンボキャブラリーの SOTA に届いた。CVPR 本論文 PDF をデコーダ設計と課題被覆まで読んだ上で記す。ただし統一の射程は論文報告の範囲である。OpenSeg は区切ったバリエーションとして別に保つ。Ghiasi らによれば、語とマスクの照合の前にマスク提案を置く視覚グルーピング優先で、キャプション規模の教師信号を可能にし、PASCAL で LSeg を mIoU 19.9 上回ったと、モデル論文の著者測定として報告している。バリエーションの位置に留め、グルーピングの質への依存が残る。ODISE は拡散基盤の流れである。Xu らによれば、凍結したテキスト画像拡散と CLIP 識別基盤でオープンボキャブラリーのパノプティックセグメンテーションを解き、COCO 学習のみで ADE20K の PQ 23.4・mIoU 30.0 に届き、先行を 8.3 と 7.9 上回った。拡散内部表現が K-means 探索で意味にまとまると示し、コードとモデルを開き、CVPR 2023 ハイライトである。ただし拡散特徴への依存が残り、拡散基盤の細部には立ち入らない。起点と統一とバリエーションと拡散の四つを、セグメンテーションの枝の一群にまとめる。[55, 56, 57, 58]

全体を見渡す。GLIP の言い換えと Grounding DINO の融合と OWL-ST の自己学習は、別の群の仕組みであり、一本の展開に連なる。言い換えが検出の出力を語の指示に開き、融合が言語と画像の対応を三段で強め、自己学習がウェブの量でレアカテゴリをカバーする。いずれの数値も論文報告の言い方の下で記し、未見の言い方は語彙空間と学習分割の定義に縛る。GLIP のゼロショット AP と Grounding DINO の ODinW 平均と OWL-ST の LVIS-rare は別の契約であり、並べて優劣を付けない。定式の起点と蒸留による転移と語彙拡張と融合の二系統とスケールとセグメンテーションの枝の六群が、全体の整理である。起点が出所の切り分けを示し、転移が教師モデルの移し替えを示し、語彙拡張がボックスなしでの適用範囲の拡大を示し、融合が後段融合と密な融合を示し、スケールがボックスなしでのレアカテゴリのカバーを示し、セグメンテーションの枝が画素と言葉の照合のまとめを示す。数値は論文報告の言い方の下で記し、未見は語彙空間と分割の定義に縛り、評価指標は契約ごとに分ける。開くことと対応を強めることと適用範囲を広げることの三つが、全体の要点である。一つに畳まないことが、全体の保ち方である。報告の言い方と語彙空間の断りと契約ごとの評価指標を三つ組で残す。[44, 45, 46]

本節の読解上の境界

この節の読解上の境界: ウェブ由来の教師モデルやデータを使う以上、未見の言い方はラベル空間と学習分割の定義に縛られる。機械の空間での未見と人手の空間での未見は別物であり、数値はその定義と組で読む。レア分割の数値も分割の取り方の下での記録である。ファインチューニング後の言い分けとゼロショットの言い分けは同じ契約の別の手順であり、新しい節ではない。[47, 48, 43, 50, 51, 52, 44, 53, 54, 45, 46, 55, 56, 49, 57, 58]

9 凍結した視覚・言語モデルを接続する

BRIDGES

別々に学んだ画像と言語を凍結したままつなぐ接続が、視覚言語モデル (VLM) の出発点を作った。接頭辞、密な cross-attention、Q-Former、単層写像、端から端までの調整という世代の違いをたどり、開かれたデータへの到達を示す。[59, 60, 61]

別々に事前学習した画像エンコーダと言語モデルは、そのままでは視覚言語モデル (VLM) として質問応

答や説明文生成を行えない。Frozen はこの接続の一例を示した。画像エンコーダが連続埋め込みの接頭辞を出力し、凍結した自己回帰言語モデルがその接頭辞を条件に文を生成する。モデル論文の著者測定によれば、画像とテキストを交互に並べた例を与えるだけで、新しい物体の名称使用、質問応答、画像外知識の利用が現れたと報告している。この報告は概念実

証の範囲に留まると論文自身が明記しており、本節では前例として位置づける。Flamingo は接続を gated cross-attention の密な層に置き換えた。事前学習済みの画像専用モデルと言語専用モデルを各層で密に接続し、画像とテキストが混在するウェブ由来データで学習する。画像と短い動画を入力し、一つのモデルが少数の例から自由回答・選択式の質問応答と説明文生成を行う。モデル論文の著者測定によれば、課題ごとに 1000 倍のデータでファインチューニングしたモデルを上回り、少数例利用で最先端に届いたと報告している。一方で論文自身は言語モデルの弱さを引き継ぐと明記し、言語側の先入観がハルシネーションを生むと指摘する。この指摘は知覚と推論を分ける後の議論の起点となり、後の失敗分析が参照する。学習データは非公開であり、ここでは事実として記す。[62, 61]

Flamingo 型の密な接続は表現力がある一方、学習対象が重く閉じたデータに依存する。BLIP-2 は画像エンコーダと言語モデルの双方を凍結し、Q-Former だけを学習する設計を示した。Q-Former は学習可能なクエリベクトルで画像側から必要な情報だけを取り出す。手順は二つの学習段階からなる。第一段階では画像エンコーダを凍結したまま Q-Former が表現を学習し、第二段階では言語モデルを凍結したまま生成への接続を学習する。いずれの段階でも大規模な基盤は更新せず、接続部に限定して学習するため学習可能パラメータは大幅に減る。モデル論文の著者測定によれば、学習可能パラメータが 54 分の 1 の規模で Flamingo80B をゼロショット VQAv2 で 8.7 ポイント上回り、視覚言語課題で最先端に届いたと報告している。指示に従う画像説明の振る舞いも現れたとモデル論文の著者測定は報告している。Q-Former のクエリ選択は、密な cross-attention とも単層写像とも異なる。制約として二段階の管理と調整の手間は残り、論文自身も指示への仕上げは後継の指示チューニングが担うと位置づける。この報告値はモデル論文の著者測定として受け取り、独立した第三者再現の有無はここでは判断しない。[59]

InstructBLIP は BLIP-2 を基盤に視覚の指示チューニングを体系化した。公開の 26 データセットを指示形式に直し、指示を入力する Q-Former で学習する。クエリ自体が指示を読む点が前世代からの変更である。モデル論文の著者測定によれば、学習に含めない 13 課題群すべてでゼロショット最先端に届き、BLIP-2

や規模の大きい Flamingo を上回ったと報告している。画像付き ScienceQA では仕上げ後に 90.7%に達し、モデルはすべて公開された。評価の主張は学習に含めた課題と含めない課題を分ける手順の範囲に限られ、その外側への一般化は主張しない。指示データの配合の詳細は後の節の範囲であり、ここでは手順と結果に絞る。同じ時期の短い接続として MiniGPT-4 を位置づける。凍結した画像エンコーダと凍結した Vicuna を単層の写像で接続するだけで、Q-Former のようなクエリ選択は持たない。詳細な描写、略図からのウェブページ作成、物語や詩、調理手順の作成という組み合わせの振る舞いが現れたと、モデル論文の著者測定は報告している。短い説明文で整えてから詳細な描写で仕上げる二段階の選別が、繰り返しや断片化を抑えたモデル論文の著者測定は報告している。コードとモデルとデータは公開された。接続の役割に絞った短い扱いとし、接続の脆さの実証は評価側の根拠に譲る。[63, 64]

LLaVA は指示データの作り方を変え、視覚言語モデルの指示追従を押し広げた。公開課題の書き換えだけでは追従の幅が限られるという制約が出発点である。言語専用の GPT-4 が生成したマルチモーダル指示データを初めて用い、機械生成の指示応答を教師信号に据えた。画像エンコーダと言語モデルを端から端まで一緒に調整する点も世代の違いであり、凍結したまま接続部だけを学習する方式とは異なる。モデル論文の著者測定によれば、機械生成の指示追従では GPT-4 の評価に対する相対で 85.1%に達したと報告している。これは機械生成例で学び機械評価で測る閉じた条件での値である。GPT-4 との組み合わせでは ScienceQA で 92.53%の最先端に届いたとモデル論文の著者測定は報告しており、組み合わせ相手がある条件の値として読む。データとモデルとコードは公開された。評価軸として LLaVA-Bench を添え、論文自身が限界として記すラーメンの作例のような失敗を隠さない。合成した指示データへの依存は残り、機械生成例の癖がモデルの癖となる。論文自身の失敗開示は後のハルシネーション診断と連続する。単層写像の MiniGPT-4 とは端から端までの調整の有無が異なり、公開 26 データセットを直す InstructBLIP の方式とは教師信号の出所が異なる。指示データの配合の詳細は後の節に譲り、ここでは接続と仕上げの世代交代に絞る。[60]

接続の世代を締めくくるのは、開かれたデータに立つ Molmo の初代である。外部の視覚言語モデルに依存する限りデータの出所は閉じたままという制約が出発点である。PixMo と呼ぶ自前のデータに密な説明文と自由な一問一答、2次元の指さし出力 (pointing)、四種の合成データを収め、外部の視覚言語モデルには依存しない。自前の教師信号と調整した手順の組み合わせにより、72B 級で最上位に届いたとモデル論文の著者測定は報告している。具体的には Claude 3.5 Sonnet や Gemini 1.5 Pro と Flash を上回り、ベンチマークと人手の評価では GPT-4o に次ぐ位置につけたとモデル論文の著者測定は報告している。MetaCLIP

と OLMo による完全に開かれたバリエーションも用意し、重みとデータとコードを公開した。エンコーダの選択も比較に支えられる。初期の CLIP エンコーダを既定とし、三つの代替を比べたアブレーションが構成要素の選び方を示す。初代の範囲は画像中心であり、動画の主張は Molmo 2 の記録に譲る。系譜は、接頭辞で渡す Frozen、密に接続する Flamingo、クエリで選択する BLIP-2 の Q-Former、単層で接続する MiniGPT-4、端から端まで調整する LLaVA、開かれたデータで組み立てる Molmo である。各世代の接続部の方式を混同しない。凍結した構成要素を使い回す考え方は後の Qwen 系にも連続する。[59, 60, 65]

本節の読解上の境界

この節の読解上の境界: Flamingo の学習データは非公開の体制であり、閉じた条件の記録として読む。Frozen の記録は概念実証の範囲に留まり、前駆としての位置づけを超えない。[61, 59, 63, 60, 62, 64, 65]

10 解像度と融合と時刻を問う

FUSION

画像・動画・音声をトークンや状態の列に変える手順を、解像度と融合の深さと時刻合わせの三つの問いで整理する。音声は入力側だけを扱い、開かれた系と閉じた系を分け、数値は出所と条件を添えて読む。三つの問いを混同しない。[66, 67, 68]

一つ目の問いは解像度である。縮小してから読む方式では細部が落ち、文書や図表の読み取りが損なわれる。先行する Qwen2.5-VL は動的な解像度に対応する ViT を最初から学習し、ウィンドウアテンションで計算を抑えた。本来の細かさのまま受け止める点と、窓に区切って計算を抑える点が作り直しの要点である。モデル論文の著者測定によれば、動的な解像度と絶対時刻の符号化により数時間の動画から秒単位で出来事を探し当てたと報告している。ボックスや点による接地、定型の抜き出し、課題別の調整なしでの計算機操作や携帯端末の操作も同じ基盤に載ると報告している。ただし主張は先行の範囲に留まり、置き換え後の判断は Qwen3 側の根拠に譲る。後継の Qwen3-VL は三つの更新を組み合わせる。空間と時刻を合わせて扱う interleaved-MRoPE、ViT の複数層の特徴を重ねて視覚と言語の対応を密にする DeepStack、T-RoPE を進めて時刻を文面のタイムスタンプで明示する時間合わせである。一層だけではなく複数層を重ねる点と、

時刻を埋め込みに隠さず文面に書き出す点の変更である。モデル論文の著者測定によれば、256K の長いコンテキストをそのまま受け、書籍や数時間の動画を保ち、秒単位の索引づけに応じると報告している。密な 2B から 32B、Mixture-of-Experts (MoE) の 30B-A3B と 235B-A22B を用意し、指示版と思考版を分ける。純粋な文章理解の強さ、長いコンテキストの保持と想起と照合、MMMUE や視覚数学の推論を三つの柱として位置づけ、平方根の重みづけ直しが文章側を守りながらマルチモーダル側を伸ばすと説明する。いずれもベンダー測定の主張であり、トークンや設定の数値は設定に結びつく読みに留め、独立した第三者再現は残された課題として残す。条件の異なる数値を並べて優劣をつけない。[69, 66]

二つ目の問いは融合の深さであり、一つのモデル系列だけを追わない。InternVL3 は文章の言語モデルに後から視覚を継ぎ足すのではなく、マルチモーダルと文章を最初から一緒に事前学習する一段階の手順を取る。後付けの継ぎ足しでは接続部の調整が重くなるという制約が出発点である。モデル論文の著者測定によれば、一段階の学習により後付けの複雑さが解け、V2PE でマルチモーダルの長いコンテキストを伸ばし、SFT と MPO のポストトレーニングと

実行時のスケーリングを重ねたと報告している。1B から 78B のモデル群を用意し、78B では MMMU で 72.2 に達して公開の最先端に届き、4o や 3.5-Sonnet、Gemini-2.5-Pro と並び、純粋な言語側の保持も強いと報告している。この比較は報告時点の日付と結んだ読みに留め、モデル論文の著者測定として受け取る。重みと学習データは公開予定とされ、予定は予定として読む。Qwen の段階的な継ぎ足しとの対比、すなわち最初から一緒に学ぶか後から足すかという設計の違いが構造の要点である。検査のしやすさは Qwen3-VL のリポジトリが担う。dense 構成と MoE でエッジデバイスからクラウドまで、FP8 のバリエーション、Transformers や vLLM への対応、指示版と思考版、視覚エージェントによる画面操作、2次元と3次元の接地、256K から 1M への拡張が記される。三つの構成要素の積み重ねはコードの上で確かめられるが、重みだけでは評価の主張は立たない。コードは Apache 2.0 で公開が確認され、重みの許諾は未確定のまま残る。確認済みと未確定を分けて記す。版の結びつけは後の段階に譲り、説明文の宣伝的な表現は設計の根拠から切り分ける。[67, 70]

融合の問いには接地で測る比較軸も要る。対応の密さだけでは指し示す力は測れない。Molmo 2 は設計の到達点ではなく比較の軸として置く。論文自身の三つ組の表示では、オープンウェイト、蒸留なしのオープンデータ、オープンコードを掲げる。Molmo 2 論文の著者測定によれば、8B が公開級の短い動画や数え上げ、説明文で先頭に立ち、長い動画でも競ると報告している。具体的には動画の数え上げで 35.5 に対して Qwen3-VL が 29.6、指さしの F1 で 38.4 に対して Gemini 3 Pro が 20.0、追跡の J&F で 56.2 に対して 41.1 という同一条件の直接比較であり、数え上げと指さしと追跡という接地寄りの評価軸で測った値である。9 種の公開データには指さしと追跡の二種、説明文、質問応答が含まれ、完全に開かれた Olmo バリエーションもあり、2026 年 4 月の v4 が記される。ただし 8B と 4B は Qwen3 の基盤を使い回し、部分的な依存は開示される。価値は開放の度合いと接地で測る動画評価にあり、仕組みの新しさではない。論文自身が閉じた依存も明かす。Olmo バリエーションでも画像エンコーダの SigLIP 2 は閉じたデータに頼り、競える開かれたエンコーダがないことが共同体への呼びかけとして記される。データ生成の文章専用モデルも閉じており、

MathVista や MMMU の推論、10 分を超える長い動画の学習データでは後れることが結果の議論に記される。閉じた系は能力の比較に留める。Gemini 3.1 Pro は 1M のコンテキストで文章と画像と音声と動画を受け、MMMU-Pro と Video-MMMU の主張を手法の頁と 2026 年 2 月のモデルカードに記す。Gemini 3.6 Flash はトークンの効率寄りの位置づけで 2026 年 7 月のモデルカードに記される。いずれも能力と評価とデプロイの事実だけを借り、仕組みの根拠にはしない。数値はベンダー測定であり、日付と版の結びつけが必要である。[71, 72, 73]

三つ目の問いは時刻と音声であり、音声は入力側だけを扱う。生成側の合成は別巻に譲り、ここでは受け止めてトークン列へ変換する契約だけを扱う。Whisper は音声入力処理の前例である。68 万時間の多言語・多課題の弱い教師信号で学び、教師なしに近い転移で十分に教師ありの結果に迫り、人の正確さと頑健さに近づくモデル論文の著者測定は報告している。モデルと推論コードが公開され、頑健な処理の基盤となる。役割は音声認識の対象をトークンに変える契約に絞り、音声認識の範囲を超える主張は行わない。一般の音の主張には BEATs 側の根拠が必要である。BEATs は音全般の自己教師あり学習による音響表現学習を担う。音響トークナイザと音の自己教師あり学習を交互に鍛え、再構成ではなくマスクされた離散ラベルの予測で学ぶ。トークナイザは各周で教師の意味を受け継ぐ。モデル論文の著者測定では、AudioSet-2M で 50.6% の mAP を音のみで、ESC-50 で 98.1% に達し、データや変数の大きい先行を上回ったと報告している。分類の評価の範囲に留まり、融合の振る舞いにはオムニ側の根拠が必要である。CLAP は音側の呼び出し可能性を足す。言語と音声のデュアルエンコーダを対照学習で事前学習し、12.8 万組で学ぶ。モデル論文の著者測定によれば、音の出来事や音楽や音声認識の 16 課題・8 領域でゼロショットの最先端に届き、教師ありの 5 課題でも最先端に達したと報告している。CLIP との並びが明示され、画像側の CLIP に対する音側の答えとなる。ICASSP 2023 で発表された論文である。ただし 12.8 万組は CLIP 級の規模ではなく、後のオムニのエンコーダが比較を限定する。三者の契約は入力側に絞られ、後のオムニの組み合わせへの前例として読む。[74, 75, 76]

音声入力を組み合わせて時刻で合わせるのが Qwen3-

Omni である。Thinker-Talker の MoE で文章と画像と音声と動画にまたがる知覚と生成を担い、音声エンコーダを最初から学習する。考える側と話す側を分け、音声の入力側は作り直す。M-RoPE の系譜はここにつながり、TM-RoPE で絶対時刻を合わせ、音声と映像のずれを 80ms に抑える。相対ではなく絶対で合わせる点が要点である。モデル論文の著者測定によれば、40 分の音声認識と言語理解の例を受け、19 言語の音声理解と 10 言語の生成に応じると報告している。理論上 234ms で最初の音を返す流れに乗ると報告され、この 234ms は理論上のコールドスタートであり、実測のデプロイ値としては読まない。境界は明確である。Talker や Code2Wav の合成の細部は別巻の範囲に置き、ここでは入力のエンコーダと TM-RoPE の同期、入力側のストリーミング処理の契約だけを担う。劣化なしの主張はベンダー測定として受け取る。Whisper の音声からトークンへの契約、CLAP の音と言語の対応づけを前例とし、最初から学ぶ音声エンコーダと絶対時刻の同期が 40 分の事例と多言語の理解を支える。[68, 74, 76]

ストリーミング処理の契約はデプロイの姿で確かめる。Qwen3-Omni のリポジトリはストリーミング対応オムニのデプロイの姿を示し、作例集や実演を備える。Talker を止めた Thinker のみの運用が文書に記される。生成側を止め、受け止めて考える側だけで動かす運用であり、入力と同期の契約を生成から切り離して確かめる手がかりとなる。2025 年 9 月 26 日に話題の首位に立ったことは、プロジェクト自身の知らせとして記される出所の記述であり、技術の根拠ではない。重みとコードの許諾は未確定のまま残り、確認済みと未確定を分けて記す。Qwen3-Omni 本体の数値は設定に結びつく読みを守る。80ms の時刻合わせや

234ms の理論値、40 分の事例や 19 言語・10 言語の対応は、いずれもモデル論文の著者測定とベンダー測定として受け取り、独立した第三者再現を待つ。設定の異なる数値で優劣を競わない。入力側の保ち方、絶対時刻での音声と映像の結び、流れの中での問い応答という三点が、デプロイ面と仕様の記述で裏づけられる。三点を超える主張は行わない。版の特定は後の段階に譲る。[77, 68]

開放の度合いは二つのモデル系列で確かめる。InternVL のリポジトリは第二の系列の開放を示し、重みに加えて InternVL-Data の学習データを出す。1.0 から 3.5 までの系譜を論文の結び目でたどり、3.5-GPT-OSS 系で学習コードを開く。読み物の見出しは 3.5 系を記し、報告 2508.18265 の 241B-A28B 級と 2025 年 8 月 30 日の学習コードの公開が添えられるが、発見の集成は変わらない。ただし資料公開の細部の範囲は未確認であり、見出しの深さに留まる。molmo2 のリポジトリは全層の開放を見せる。データの用意、事前学習と SFT と長いコンテキストの SFT、評価の道具、vLLM による推論、チェックポイントの変換、MolmoPoint の拡張、モデル群の結び目が見出しからたどれる。コードは 2026 年 9 月 30 日に確認されたリポジトリ直下の LICENSE 文書により Apache 2.0 で公開が確認され、重みの許諾や公開データの有無、資料ごとの許諾と利用条件は未確定のまま残る。学術や非商用の第三者データの混入条件の整理は先送りとする。Molmo 2 の論文の三つ組と合わせると、オープンウェイトとデータとコードの側と、SigLIP 2 や文章専用モデルに頼る閉じた側との混在が残る。未確定は未確定と記すことが、開放の主張の正確さを保つ。[78, 79, 71]

本節の読解上の境界

この節の読解上の境界: ベンチマークの主張はベンダー測定であり、トークンや設定の数値は設定に結びつく読み留め、独立した再現は今後の課題として残す。234ms は理論上のコールドスタートであり、実測のデプロイ値ではない。Whisper の話は音声認識の範囲に留まり、音全般の主張はしない。BEATs の分類の強さは分類の範囲の記録であり、融合の振る舞いの根拠にはしない。[66, 68, 74, 75, 76, 67, 71, 69, 72, 73, 70, 77, 78, 79]

11 合成点を開き失敗を分ける

REASONING

一つの点数で賢さを語らず、知覚 (perception) と推論の違い、言語の先入観と根拠の利用を分けて測る。制御ペアの診断を中心に、投票と回転と視覚数学の道具の違いを示す。判定と汚染の作法を同行させ、合成点の読み替えを避ける。[80, 81, 82]

一つの合成点で賢さを語らないことが出発点である。合成点は多くの力を含む値であり、どこでつまづくかを示さない。MMMU は大学の試験や小テスト、教科書から集めた 1.15 万問の専門家課題であり、総合的な推論の評価条件となる。6 分野・30 科目・183 細目、図表や図解や地図や表や楽譜や化学構造を含む 30 種の異種画像を扱う。ベンチマーク論文の著者による第三者測定では、GPT-4V が 56%、Gemini Ultra が 59% に届き、なお余白が大きいと報告している。幅の広さは力である一方、合成点は汎用知能の根拠にはならない。補助手順の有無で点が動くため、アブレーションを添えない帰属は避ける。閉じたモデルでは汚染の見通しが利かず、学習時の混入を確かめられない。このため点を使うたびに、補助手順の切り分けと汚染の不透明さを合わせて記す。言語の先入観か根拠の利用かという分離は、ここでは要請として記し、実証は制御ペアに譲る。[81]

失敗を分ける中心の道具が HallusionBench であり、制御ペアによる診断と呼ぶ。346 枚の画像に 165 枚の独自収集と 181 枚の人手編集を含め、1129 問の専門家質問を対の構造で組む。対の片方はもとの画像、もう片方は人の手で直した画像であり、直しの前後で問いを組む。言葉のハルシネーションとは画像なしでも先入観で答える振る舞いであり、視覚の錯覚とは入力を読み取りを誤る振る舞いである。見ないで答える癖と見誤る癖は別の癖であり、二つを分けることで言語側の癖か根拠の使い方かを切り分ける。ベンチマーク論文の著者による第三者測定では、GPT-4V が対精度で 31.42%、他はすべて 16% 未満に留まったと報告している。これは 15 モデルの測定であり、対の両方で

正答した場合にのみ点が入る厳しい評価軸での値である。CVPR 2024 で発表された論文であり、コードは公開された。ただし手作りの小さな規模であり、広がり主張はできない。順位表として読まず、診断として読む。対になる補完が POPE である。物体のハルシネーションを初めて体系だてて調べ、投票型の POPE で安定にしなやかに測る。ベンチマーク論文の著者による第三者測定によれば、現れやすい物や一緒に現れる指示対象ほど幻を生みやすいと報告している。投票の範囲に限られ、開かれた応答の忠実さは制御ペアの道具が必要である。[80, 82]

回転と視覚数学は別の道具であり、混同しない。MMMBench は英中二言語の 3000 問超の選択式課題を 20 の能力軸で扱い、手順を整えて質を保つ。CircularEval と呼ぶ選択肢の回転で一貫性を確かめ、GPT-4 による選択肢の取り出しで弱い指示追従を吸収する。ベンチマーク論文の著者による第三者測定によれば、GPT-4 の取り出しは人手と 91.5% で一致すると報告している。v1.1 の質改訂を経て ECCV 2024 に載り、VLMEvalKit に組み込まれた。ただし判定への依存は点と一緒に記す。GPT-4 の判定と取り出しに頼る限り、点は単独では成立しない。対象言語も英中の範囲に限られる。MathVista は視覚数学を担う。28 資料群に IQTest や FunctionQA や PaperQA の新規を加えた 6141 例を集め、7 種の推論と 5 種の課題を交差させる。ベンチマーク論文の著者による第三者測定では、GPT-4V が 49.9%、Bard が 34.8%、人が 60.3% と報告している。ICLR 2024 で発表された論文である。知覚のつまづきか推論のつまづきかの帰属には、CoT や PoT や道具の有無の切り分けが使うたびに必要である。制御ペアの診断を基準に置くと四者の違いが明らかになる。投票型評価はハルシネーションの一次検査、制御ペアは言語と視覚の分離、回転は選択のぶれの吸収、視覚数学は図を読む推論の切り分けである。判定と汚染の注意を合わせて記し、合成点を賢さ一般に読み替えない。[80, 83, 84]

本節の読解上の境界

この節の読解上の境界: 合成点をもって賢さ一般を語らない。使うたびに補助手順の切り分けと汚染の不透明さを添える。制御ペアの診断は手作りの小さな規模であり、厳しい指標の診断として読む。投票は投票の範囲に留まり、自由な記述の忠実さは制御ペアの道具が担う。判定への依存は点と組で読み、英中の範囲を超えない。[80, 81, 82, 83, 84]

12 長尺と実時間の契約を分ける

VIDEO

録りためた動画の理解と、流れる映像への即応は別の契約で動く。順序と記憶と問い合わせの違いをたどり、枠数の効き方と未確定の部分を正直に残す。前例の資料から広さの評価、尋ね方の契約、実時間の仕組みへと進み、空間知能の未確定を添える。[85, 86, 87]

動画の理解は短い切り分けから始まった。Kinetics は 400 種の人の動作に 400 本超の 10 秒の YouTube 動画を添え、分類の範囲に絞る。時間的な位置の特定ではなく何の動作かという分類であり、大規模に最初から学ぶ条件と設計比べの場を兼ね、偏りや不均衡の分析を伴った。短い切り分けの範囲に留まり、時間の推論は後継に譲る。Something-Something V2 は順序に敏感な前例である。10 万超の動画に 174 種の文型の題目を添え、群衆が演じた身近な物理の理解を問う。順序を入れ替えると意味が変わる点が、時間の順序を探る原点となった。ICCV 2017 で発表された論文であり、文型の範囲に留まる短い扱いとする。Ego4D は一人称視点の資料の前例である。3670 時間の日常の動画を 931 人の装着者、74 地点、9 か国で集め、同意と匿名化の倫理を備える。音声や 3 次元メッシュや視線や立体視や複数カメラの部分集合を添え、過去と現在と未来の課題群として思い出しや手と物のやり取り、視聴覚の会話、予測を扱う。CVPR 2022 で発表された論文である。資料の範囲の主張に留まり、資料の強さと仕組みの強さは別の話として区別する。軌道に近い資料の系譜として二重の役割を担うが、ここでは時間と視聴覚の前例として読む。[88, 89, 87]

録りためた動画の理解は、長さとモダリティの広がりで測る。短い切り分けとは別の契約である。Video-MME は動画の視覚言語モデル向けに初めて全域を覆う評価であり、900 本の動画と 254 時間、2700 問を扱う。6 領域・30 細目、11 秒から 1 時間の長さ、字幕と音声のモダリティ、専門家の注釈を備える。ベ

ベンチマーク論文の著者による第三者測定では、商用で最良の Gemini 1.5 Pro が平均 75%、GPT-4o が 71.9% と報告している。画像のモデルにも動画のモデルにも当てはまる。版の結びつけは v3 の記録に置き、商用の数値はベンチマーク論文の著者による第三者測定として読む。Ego4D の一人称の蓄積を長尺側の資料として受け、長さとモダリティの広がりをつ一つの契約で測る。ここはオフラインの長いコンテキストの契約であり、流れる映像への即応とは別の評価軸として扱う。録りためたものと流れるものを混同しない。録りためた長さをどこまで保って答えるかが問われ、保つ長さと思い出す細かさが要点である。記憶の仕組みの主張は実時間の仕組みの節に譲り、ここでは広さの評価に絞る。[\[87, 90\]](#)

長い文脈の尋ね方には別の契約がある。広さを測る契約とは別に、尋ね方を測る契約がある。LongVideoBench は 3763 本の動画と字幕に 6678 問の人手の選択式を添え、17 の細かい区分で組む。referred-context と呼ぶ推論では、指された長い文脈を取り出して筋道を立てる。ベンチマーク論文の著者による第三者測定の見解では、枠を増やして初めて点が伸び、枠数の効き方が明らかになったと報告している。将来の長いコンテキストのモデルに向けた指し示しとして読む。長さの広さで測る評価とは取り替えが利かず、指された文脈の取り出しと推論という独自の契約に立つ。対して StreamingBench は流れる映像の評価の契約である。初めて流れる動画のマルチモーダルモデルを幅広く測り、900 本の動画と 4500 問、18 課題を三区分で扱う。即時の視覚、音声を含む源泉別、流れの中のやり取りと能動応答を含む文脈別の三区分である。流れの途中で時刻つきの問いを投げる。ベンチマーク論文の著者による第三者測定では、最良の Gemini 1.5 Pro が 67.07%、人が 91.66%と報告して

いる。コードとデータは公開された。ただし多くのモデルはオフライン変換で測られ、真のオンラインの点は実時間の仕組み側の根拠が必要である。視聴覚の評価の役割も兼ねる。録りためた長さで流れる即応を同じ評価軸に載せない。[91, 86]

流れる映像に即応する仕組みの中心が Flash-VStream である。録りためた長さを保つ仕組みとは別に、止めずに受け続ける仕組みが必要である。人の記憶の仕組みを手本に、極めて長い流れを実時間で受けながら、非同期の問いにも同時に答える。モデル論文の著者測定によれば、遅延とメモリ負荷を大きく抑えたと報告している。抑えた度合いの実数はモデル論文の著者測定として読む。VStream-QA を対の評価として添え、オンラインの流れの質問応答を測る。オフラインの評価での最先端の確認は汎用性の点検に留まる。コードとモデルと資料は利用できると記され、利用可能性の記述として読む。オンラインの入力と限りある記憶、保たれる時間的な状態、遅延とメモリ負荷のトレードオフを一つの仕組みで担う。VStream-QA は引用する前例として置き、SAM 2 の記憶は仕組みへの指し示しに留める。遅延とメモリの数値はモデル論文の著者測定であり、それを超えるデプロイの数値は未確定として残す。時刻つきの途中の問い、非同期の問い応

答、記憶の方針はオンラインの側に属し、オフライン変換の点と混同しない。枠数の効き方が鍵となる録りためた評価とは、保つものが異なる。[85, 86]

空間と時間の交差には未確定を残す。VSI-Bench は動画に基づく空間知能の評価であり、288 本の一人称動画に 5131 問を添え、ScanNet とその拡張と ARKitScenes に由来する。8 課題を配置と計測と時空間の三種で扱い、MCA と MRA の評価軸で測り、盲検の基準を添える。CoT では点が落ち、認知地図では点が伸びるという知見が記される。CVPR 2025 で発表された論文である。ただし紙面の読みは要旨の深さに留まり、本文の精読ではない。偏りを除いた部分集合の分析は後に譲り、視聴者由来の部分集合や行数の事実は記録の範囲の外に置く。ID の結びつけは記録の範囲で定めた。Flash-VStream の時間的な状態の保ち方と比べると、ここでは空間の配置と計測が主題であり、時刻合わせとは別の問いである。枠数の効き方は LongVideoBench の側に記し、流れの側では非同期の問いと記憶の方針を記す。オフラインの長いコンテキストとオンラインの流れを同じ主張に載せない約束を守り、偏りを除いた分析の先送りを隠さない。[85, 92]

本節の読解上の境界

この節の読解上の境界: 多くのモデルはオフライン変換で測られており、真のオンラインの点は実時間の仕組み側の記録が担う。遅延とメモリの数値は著者の報告に留まり、それを超えるデプロイの数値は未確定として残す。空間知能の評価の読みは要旨の深さに留まり、偏りを除いた分析は後に譲る。[87, 86, 85, 88, 89, 90, 91, 92]

13 画面操作は接地から状態管理へ

COMPUTER USE

実 OS 上で画面を操作するエージェントをどう評価するか。OSWorld の接地の制約と OSWorld 2.0 の状態管理の制約を対比し、要素位置の正確さと課題成否を分離する契約を整理する。クリックの正確さから長い作業の保持へ移った変化を追う。[93, 94, 95]

実 OS の画面を直接操作するエージェントの評価は、小規模な Web 課題では切り分けられないところから始まる。ボタン位置の誤りと手順全体の破綻を一つの成否に混ぜると、どこを直すべきかが見えなくなる。

OSWorld はこの切り分けのため、Ubuntu と Windows と macOS の実 OS 上に課題を置く初めてのスケールする評価環境として報告されている。机上の模擬ではなく、実際に動作する OS 上でエージェントを走らせる。課題は 369 件で、実在の Web アプリとデスクトップアプリ、ファイルの読み書き、複数アプリにまたがる作業を含み、課題ごとに初期設定と専用の評価スクリプトが用意される。判定は見た目の一致ではなく、実行後のファイルやアプリの状態が求める通りになったかで決まる。途中の操作が教科書通りでなくても、

求める状態に届けば成功とみなす点が、この評価の中心にある。同じ環境で対話しながら学ぶ使い方も想定され、試行と修正の往復を実 OS 上で回せる。コードと環境は公開され、NeurIPS 2024 で発表された。ベンチマーク論文の著者による測定では、人は 72.36% を達成したのに対し、最良のモデルは 12.24%にとどまったと報告されている。失敗の中心は二つある。一つは GUI 要素を座標に対応づける接地 (grounding) の弱さで、以後は接地と呼ぶ。スクリーンショットだけを見て押すべき要素の位置を定められない場合があり、画面の意味は捉えられても位置の指定がずれる。もう一つはアプリを使いこなす操作知識の不足で、どのメニューを開きどの順序で操作するかが身についていない。位置の正確さと課題の成否を一つの数値に混ぜると何が足りないかが見えなくなるため、別の評価条件で測るべきだというのが、この記録の読み方だ。この記録の射程は短い手順に限られ、長い手順の途中で状態を見失う現象は扱えない。[93]

OSWorld 2.0 は測定対象をクリックの正確さから長い作業の状態管理へ移した。課題は 108 件の長い手順で、人が要する時間の中央値は 1.6 時間に達すると報告されている。道具の呼び出し回数は、OSWorld 1.0 の約 30 回に対して約 318 回にのぼり、一回の操作では終わらず数百の操作を積み重ねて初めて完了する。課題には長い作業に特有のつまずきが織り込まれている。作業の途中で新しい情報が届き最初の手順を変更しなければならない場合、環境が動的に変わる場合、複数の出所を見比べて考えなければ答えが出ない場合、画面に書かれていない暗黙の状態を推測しなければならない場合、視覚的な位置を精密に合わせなければならない場合がある。実物に近い成果物と状態をもつ利用者像が用意され、安全性の報告も添えられるが、この報告は評価に付随する材料であり、運用方針そのものではない。ベンチマーク論文の著者による測定で最良だった構成は、Claude Opus 4.8 を最大の思考設定でバッチ化し 500 手順まで許したもので、二値の成否が 20.6%、部分点が 54.8%だったと報告されている。最後までやり切る割合は二割にとどまる一方、途中まで進める割合は半ばを超え、二値と部分点の開きが長い作業の現在の到達点を示す。GPT-5.5 はトークンを抑えた動作点で約 13%の横ばいを示したと報告され、費用を抑えた設定では伸びが頭打ちになる。これらの数値はベンチマーク論文の著者が測定したも

ので、モデルと設定と道具と手順数と版に結びつけて読む必要があり、条件を外して数値だけを比べることはできない。失敗の中心は GUI 操作やコードの書き損じから、制約を最後まで追いつけること、作業途中に届く情報への対応、暗黙の状態の回復、確認手順の省略防止へ移った。指示を出して押すことよりも、長い作業の状態を保ち続けることが制約になった。スクリーンショットを繰り返し入力する方式はトークンを多く消費するため、この制約は費用の制約でもある。

[94]

SeeClick と ScreenSpot は要素の位置を定める力を課題成否から切り分けて測るための記録だ。出発点にあるのは、スクリーンショットだけを見るエージェントは要素の位置特定でつまずくという診断で、画面は見えていても押すべき場所を指せない場合がある。対応として接地の事前学習と学習データの自動収集を組み合わせたと報告され、位置を指す力を直接鍛え、そのためのデータを機械的に集める。ScreenSpot は純粋な位置特定の条件として作られ、600 件を超えるスクリーンショットと 1200 件を超える指示からなり、モバイルとデスクトップと Web にまたがり、文字とアイコンやウィジェットを対象にする。測るのは課題の成否ではなく、指示された要素の位置を言い当てられるかだけであり、接地の弱さがどれほど縮んだかを切り分けて読める。ここで上がった位置特定の力は、MiniWeb や AITW、Mind2Web といったエージェント課題の遂行にも波及したと報告され、位置が定まることが課題全体の遂行を押し上げる筋道が見える。モデルとデータとコードは公開され、ACL 2024 で発表された。要素の位置を言い当てる正確さと課題を最後までやり遂げる成否は別の欄の数値であり、位置の条件で測った伸びをそのまま課題成否の伸びとして語ることはできない。後継と呼ばれる v2 や Pro 級が出れば、その時点で確かめ直す必要がある。[95]

三つの記録を並べると、Computer Use (コンピュータ操作) の評価は層をなす。最初にスクリーンショットが入力になり、次に画面の中の要素へ接地して押す場所を定め、定めた座標や道具で実際に操作し、最後に長い手順の状態を保ち続ける。ScreenSpot が要素の位置を言い当てる条件を担い、OSWorld が実 OS 上の短い課題の成否を担い、OSWorld 2.0 が長い手順の状態管理を担う。各段階の境目に別の評価が置かれ、境目ごとに制約が測られる。下の層が上がっても上の層

が自動で解けるわけではなく、位置が定まっても手順を見失えば課題は失敗し、手順を覚えても位置がずれば操作は空振りし、状態を保てても確認を省けば取り返しのつかない誤りに進む。OSWorld 1.0 と 2.0 は別の条件であり、1.0 の数値と 2.0 の数値を並べて優劣を語ることはできない。短い課題の成否と長い作業の成否は測っている対象が違い、条件の違う数値を並べて順位をつける読みはこの巻では採らない。長い作業ではスクリーンショットを送り続ける費用も無視できず、トークンの消費は手順数とともに積み上がり、

実運用の動作点を縛る。どこまで手順を許しどれだけ費用をかけるかが実運用の成否を分け、正確さと費用の両方を見て動作点を選ぶ必要がある。安全性の報告は評価に添えられた材料として読み、運用の可否を決める根拠ではなく測ったときの付帯情報として扱う。本節はエージェントの構成一般を論じず、Web 時代の先行事例は背景にとどめ、画面を見て要素に接地し座標や道具で操作し長い作業の状態を保つという一連の流れだけを扱う。[93, 94, 95]

本節の読解上の境界

この節の読解上の境界: OSWorld の記録は短い射程に留まり、長い作業の結論は 2.0 側の記録が担う。数値はモデルと設定と道具と手順数と版に結びつけて読む。[93, 94, 95]

14 計画と言語と行動をつなぐ界面

VLA

言葉の知識を身体の動きへつなぐ道筋をたどる。SayCan の分業から PaLM-E の一体の表現と RT-2 の行動トークン化を経て、開かれた実装と製品の到達点まで界面の変化を整理する。七つの記録を一つの系譜として読む。[96, 97, 98, 99]

出発点は分業だった。言葉を考える部分と身体を動かす部分を分けて組み合わせる。SayCan は凍結した大規模言語モデルの意味知識を言う側 (Say) に置き、学習済み技能の価値関数をできる側 (Can) に置いたと報告されている。言語モデルが計画を立て、ロボットの技能が手足と目として働き、言葉の提案と技能の実行可能性を掛け合わせる。言葉だけでは身体が動かず、技能だけでは手順が立たないため、言葉が指示を出し技能が現時点で実行できるかを返す。実機の移動マニピュレータによる台所の課題 101 件で確かめ、接地を与えた計画は与えない場合のほぼ二倍に達したと報告されている。凍結した言語モデルを変えずに技能の側で現実を受け持つ点が特徴で、CoRL 2022 で発表された。この記録は系譜のなかで計画側の先行事例という役割をもち、言語と知覚と行動を一つの表現にまとめていない。まとめる一手は PaLM-E の側が担い、そこで初めて分業と一体の違いが見える。この記録だけでは一体の表現の破綻は語れず、結合の内容は PaLM-E 側の記録が引き受ける。[96]

RT-1 は実機の実演データを集めて吸収する側の先行事例だ。Robotics Transformer と名づけられたこの取り組みは、課題を限定しない開かれた学習と容量の大きなアーキテクチャを組み合わせ、多様な実ロボットのデータを吸い上げたと報告されている。単一タスクへの特化だけを進めるのではなく、多くの作業の実演を一つのモデルに集め、狭い課題の達人ではなく広い作業の働き手を目指す。汎化はデータとモデルの大きさと多様性の関数として、実際に動くロボットの実際の作業の上で調べられ、大きく多様なデータが初見の場面での振る舞いを支える。系譜のなかでこの記録は軌道を条件づけて学習できる基盤を敷いた。実演の軌道 (trajectory) をトークンとして並べ、観測から行動への対応を学習できる形にした。以後は軌道と呼ぶ。行動の記録が言葉と同じ列に載ることで、次の定式化への道が開け、集めた列の質と量が後の結合の成否を縛る。この記録が語るのはデータの射程であり、方策の中身の組み立ては RT-2 側の記録が引き受ける。[100]

PaLM-E は言葉と身体を分ける設計を破った。視覚や状態推定といった連続した感覚モダリティを、交互に織り交ぜたマルチモーダルな文として流し込み、凍結から結合へと進む言語モデルと端から端まで一緒に学習したと報告されている。視覚と推論を別系統に分離せず、一つの文の続きとして扱い、画像が文節になり

身体の状態が文節になり言葉と交互に並ぶ。扱う内容は操作の計画と視覚質問応答と画像説明にまたがり、一つのモデルが身体の内容と視覚言語の内容を同時に引き受ける。PaLM-E-562B は視覚言語の汎用モデルとしても立ち、OK-VQA で最良の成績を収め、規模を大きくしても言語の力を保ったと報告されている。インターネットの視覚と言語とロボットの領域をまたぐ正の転移も報告され、Web で学んだ見方が身体の内容に効き、身体で学んだ手順が言葉の内容に効く。SayCan が計画側に言語を置いて技能と掛け合わせたのに対し、PaLM-E は感覚と言語を一つの表現にまとめて一緒に学習した点が対比になる。ただし 562B 級の規模での結合学習は費用と複雑さの点で再現の裾野を狭め、誰もが同じものを作れるわけではない。大きな到達点であると同時に重い到達点であり、独立した手で確かめ直しにくい条件でもある。[97]

Open X-Embodiment は機体をまたぐデータの条件を定めた記録だ。22 台のロボット、527 の技能、16 万件を超える課題を 21 機関から集めて標準化したと報告されている。機体が違って同じ形で学べるように整え、一つの研究所の流儀ではなく多くの機関の記録を同じ評価条件に載せる。異なる機体にまたがる (cross-embodiment) という言葉が指すのはこの整えで、以後は機体をまたぐと呼ぶ。RT-X という容量の大きなモデルは機体をまたぐ正の転移を示し、複数のロボットの振る舞いを押し上げたと報告され、一つの機体で学んだことが別の機体の役に立つ。ICRA 2024 で発表された。教師信号の面から見ると、この記録は身体の実演を集める側の到達点で、言葉の側の教師信号ではなく身体側の教師信号をまとめた。全巻の教師信号の系譜のなかで身体側の結節点として読む。ただし語るのはデータの条件であり方策の組み立てではなく、集めて整えたことの記録であり集めたものでどう動かすかの記録ではない。対象は操作の領域にとどまる。[101]

RT-2 は Vision-Language-Action (VLA) の定式化の起点だ。以後は VLA と呼ぶ。Web 規模の視覚言語モデルをロボットの軌道とインターネットの視覚言語課題と一緒にファインチューニングし、行動を言葉と同じ書式のテキストトークンで表したと報告されている。行動トークンがこの記録の中心で、動かし方が言葉の列に載ることで観測から行動への写像を一つの端から端までのモデルに収めた。視覚入力から行動出力ま

で一つのモデルで扱い、中間モジュールの分離を設けない。Web で学んだ知識が身体の動きに流れ込み、Web で見た物体の知識が目前の物体への対応に効き、Web で読んだ指示の知識が初見の命令への対応に効く。6000 回の試行による評価では、新しい物体や数字や絵柄の配置といった初見の命令への創発的な汎化が見られたと報告され、教えた通りの繰り返しではなく初見の指示への対応が現れる。数字の札を並べよという初見の命令にも絵柄の位置を決める指示にも応じ、大まかな大きさの判断も見られたという。RT-1 が敷いた実演の基盤の上に Web の知識を載せる一手が加わり、実演の列があってこそ言葉との結合が始まり、結合があってこそ Web の知識が身体に届く。ただしこの記録が定めるのは定式化の役割であり、実運用に載せる内容や評価の射程は到達点側の記録が引き受ける。[98]

OpenVLA はオープンウェイトで検証可能な VLA の事例である。Llama 2 に DINOv2 と SigLIP を合わせた視覚エンコーダを組み合わせた 70 億級の VLA で、97 万件の実演で学び、非公開の RT-2-X の 550 億級を 29 課題の埋め込み評価で 16.5 ポイント上回ったと報告されている。大きさは七分の一でありながら成否では上回り、重みの公開が確かめの裾野を広げ、効率の工夫が大きさの差を埋める。新しい課題への効率的なファインチューニングと複数課題にまたがる汎化も報告され、CoRL 2024 で発表された。ただし独立した評価の指標が乏しいという隔たりは残り、重みが開かれているため皆が確かめられるが、この記録が結びつける独立したベンチマークはない。開かれていることと独立に測られていることは別の内容であり、効率の主張も論文の報告として読む。Gemini Robotics 2 は両腕から全身の人型までの最も進んだ VLA と、実世界を理解して多段に計画する ER 2 と、端末で動く効率的な VLA の On-Device 2 からなり、計画と方策の分担が製品の形で示されたと報告されている。提供形態は提携と早期利用の形をとる。仕組みの中身や遅延や価格やトークンの事実は公開されておらず、能力と運用の範囲だけを語り、仕組みの根拠にはしない。On-Device 2 は Gemma に Robotics 1.5 の技術を組み込んだ VLA で、文と画像と固有感覚を入力し行動を出力し、信頼できる試用者に限って配られると報告されている。場面と指示と行動の汎化をシミュレーションと実機の両方で評価し、学習には TPU と JAX

と ML-Pathways を使ったと報告されている。モデルカードが示す限りでは、初見の場面への汎化と自由度の高い制御に限りがあり、安全の射程は両腕を中心とし、層をなす安全の方法が勧められている。モデルカードは更新されうるため日付と切り離さずに読み、いつのモデルカードかを外して能力を語ることはできない。ベンダーの頁は到達点の結果であり、仕組みの結果ではない。[99, 102, 103]

この系譜を通して見ると、表現と行動の界面が段階を追って変わった。SayCan は言語を計画側に置き身体の技能と掛け合わせ、言葉が手順を立て技能が実行可能性で裏打ちする。RT-1 は実演の軌道を集めて条件づけを可能にし、Open X-Embodiment は機体をまたぐデータの条件を整えた。PaLM-E は感覚と言語を一

つの表現にまとめて一緒に学習した。RT-2 は行動を言葉と同じ書式のトークンに載せ、観測から行動への写像を一つのモデルに収めた。OpenVLA はその定式をオープンウェイトで確かめ直し、小さくても届くことを示した。分業から一体へ、一体から行動の言語化へ、閉じた大きさから開かれた確かめへと進んだ。製品の到達点では計画と方策の分担が能力の水準で示され、考える側と動かす側の分け方が製品の形で現れた。ただし機体の動きや制御則の中身には踏み込まず、扱うのは表現と行動の界面だけだ。独立した評価の指標の乏しさも残り、オープンウェイトがあっても皆が共有する独立した測定はまだ結びついていない。言葉の知識が身体に届く筋道は見えたと、その確かめ方はまだ途上だ。[96, 97, 98, 99]

本節の読解上の境界

この節の読解上の境界: 独立した評価の指標の乏しさは残り、オープンウェイトがあっても独立に測られたことにはならない。仕組みの中身や遅延や価格やトークンの事実は公開されておらず、書かれていないものは補わない。到達点の記録はモデルカードの範囲に留まり、日付と結びつけて読む。[96, 100, 97, 101, 98, 99, 102, 103]

15 予測する表現と生成する環境

WORLD MODELS

予測する表現と生成する世界をどう分けて読むか。歴史的定式、潜在ダイナミクス、予測表現、生成的環境の四つの極を立て、系譜の混線なく測り方ごとに整理する。各極の測り方と射程を対応表として一望し、用語の混線を避けて読む。[104, 105, 106, 107]

起点に置くのは、強化学習の環境を生成のモデルで捉える歴史的定式だ。Ha と Schmidhuber の 2018 年の記録は、教師なしで縮めた時空の表現 (VAE と RNN) を基盤に小さな方策で動かす道を示したと報告されている。環境の見え方を縮めて覚え、その縮めの中で方策を育て、縮めた中なら試行を重ねる費用が軽い。夢の中で育てた方策を現実に戻す使い方も示され、対話版も公開された。この記録の版における位置は、あくまで歴史的な定式の起点であり、ここから三つの枝が分かれる。潜在ダイナミクスとモデルにもとづく決定の枝を Dreamer が継ぎ、予測表現の枝を JEPA と V-JEPA が継ぎ、対話的な生成の枝を Genie が継ぐ。継ぐとは同じ問いを別の仕方で引き受けることだ。

ただしどの向きにも直接の系譜は主張せず、Ha から Genie への技術の継承も含めない。似ていることと受け継いだことは別の内容だ。枝分かれの整理は、どれか一つの続きとして読む見方に代わるもので、排他的な続き物として読むではない。言葉の来歴を広く掘る内容は本節の射程の外に置き、定式の起点としての役割だけを語る。[106]

DreamerV3 は潜在ダイナミクスの側の対抗軸だ。一般の潜在ダイナミクス算法として、RSSM のワールドモデルと想像の中での方策改善を組み合わせ、正規化と釣り合いと変換の頑健さで固めたと報告されている。想像の中で試しては直し現実に戻して動かし、一つの設定のまま 150 件を超える課題にわたり専用の手法を上回った。課題ごとに作り替えるのではなく、一つの設計で多くの課題に向かう。人の実演も手本もなしに、Minecraft で初めてダイヤモンドを集めたことも報告されている。この記録の見せ場は課題の収益の伸びであり、見た目の忠実さではない。強化学習の指

標の範囲で読み、見た目の忠実さの読みは条件の外に置き、制御に効くかで測り見栄えでは測らない。読み崩しを防ぐため、この極の位置をここに明示する。DreamerV3 は潜在ダイナミクスであり、予測表現ではなく生成的環境でもない。収益の極に見た目の評価を持ち込んでではなく、制御の評価で測る極だ。[107]

I-JEPA は予測表現 (predictive representation) の起点だ。以後は予測表現と呼ぶ。生成せずに予測する。画像の自己教師あり学習を生成の経路を通さずに組み立て、絵を描き直す力を育てるのではなく絵の意味を言い当てる力を育てる。一つの文脈ブロックから目標ブロックの表現を予測し、見えている断片から見えていない部分の意味を言い当てる。設計の鍵は二つあり、意味の水準の目標と分散した文脈で、どこを見るかではなく何を狙いどこから支えるかが要点だ。画素の一致ではなく意味の水準での一致を狙い、支えは一か所ではなく散らばった文脈から取る。ViT-H/14 で ImageNet を 16 枚の A100 で 72 時間足らずで学び、生成型の先行手法より軽い計算で、線形評価や数え上げや深度の転移で強い結果を示したと報告されている。軽く学んで広く効き、重い生成の経路を回さずに表現の質で勝負する。ただしこの記録の極は画像の側にあり、動画への継承は V-JEPA の側の記録が引き受ける。画像の予測表現の記録に動画の結論を盛ってはならない。混線を避けるため、この極の位置をここに書き留める。I-JEPA は予測表現であり、潜在ダイナミクスではなく生成的環境でもない。[104]

V-JEPA は動画の自己教師あり学習を特徴の予測だけで組み立てる対抗軸だ。学習済みエンコーダも文も負例も再構成もその他の教師も使わず、公開の動画 200 万件だけで学んだと報告されている。他のエンコーダを借りず言葉の助けも借りず動画だけを見て学ぶ。凍結した基盤の使い回しの広さが特徴で、動きの課題と見た目の課題の両方に向かい、学んだ後の基盤を凍らせたまま多くの課題に使い回せる。動画だけを見て学んだ ViT-H/16 が K400 で 81.9、SSv2 で 72.2、IN1K で 77.9 に達したと報告され、動画の学びが画像の課題にも効く。コードは公開され、2026 年 8 月 24 日時点の版で読む。拡散型の画素デコーダはエンコーダを凍結したまま後から接地を確かめる調べにすぎず、生成の主張ではない。何を学んだかを絵に戻して確かめる手段であり、絵を作る力の根拠ではない。凍結したままの評価で生成のデコーダなしに転移することこそ、こ

の記録の見分けの根拠だ。計画に使う内容はこの記録の外に置き、方策や決定への使い道はダイナミクス側の記録が引き受ける。取り違えを防ぐため、この極の位置をここに示す。V-JEPA は予測表現であり、潜在ダイナミクスではなく生成的環境でもない。[108]

Genie は生成環境の起点だ。ラベルなしのインターネット動画から 110 億級の規模で対話的な生成環境を作った初めての記録だと報告されている。時空のトークナイザと自己回帰のダイナミクスと伸ばせる潜在行動モデルを組み合わせ、正解の行動ラベルなしに一コマずつ行動で操れるようにした。教えられた動きではなく、見た動画から潜ませた動きで操り、正解のラベルの助けを借りず動画の中に潜む動きを取り出す。見たことのない動画からの模倣でエージェントを育てる使い方が、基礎ワールドモデルの主張につながる。開かれた論文として出て、仕組みを読める形で出たことがこの記録の重みだ。ただし操れる細かさの内容は Genie 3 側の記録が引き受ける。Genie 3 は能力と運用の到達点としてだけ読む。文の指示から毎秒 24 コマの 720p でその場で動く世界を作り、数分規模の整合性と 1 分間の視覚記憶をもち、天候や物や登場人物といった世界の出来事を文で指示できると報告されている。SIMA エージェントの学習に目的を決めない模擬として使い、Genie 1 と 2 の系譜が名指され、研究用の限定公開という提供形態をとる。ベンダーが示す五つの限りも添えられ、エージェントの行動空間の狭さ、多エージェントの未解決、地理参照の実地のなさ、文字描画の条件つき、数分規模の長さだ。NeRF や 3DGS との対比はベンダーの見方として帰属づけて読み、採用はしない。仕組みは公開されておらず、整合性や SIMA の主張はベンダーの言い分として読む。ダイナミクス利用の独立した評価は結びついておらず、この隔たりは残る。製品面の頁は同じ能力と運用の事実を別の所在で結びつけ、単純な文から写實的でその場で歩ける環境を作り、Project Genie の試用の面をもつ。能力と運用の所在が二つあるだけで、主張の中身は一つだ。呼称は混ぜてはならず、歴史的定式と潜在ダイナミクスと予測表現と生成環境は別の分類だ。分類をまたいで呼ぶときはどの分類の内容かを言い添える。どの向きにも系譜を主張せず、Ha から Genie への技術の継承も含めない。[105, 109, 110]

四つの極を並べ直すとそれぞれの測り方が見える。歴史的定式は夢で育てて現実に戻す方法を示し、現実の

試行の代わりにモデルの中の試行で学ぶ。潜在ダイナミクスは想像の中で方策を磨き課題の収益で示し、見栄えではなくこなし具合で示す。予測表現は生成せずに表現を予測し、凍結したままの転移で示し、描き直さずに言い当て凍らせたまま使い回す。生成的環境は動画から操れる世界を作り、一コマずつの操作で示した。状態と目標と条件づけと画素と潜在と報酬と使い道は記録ごとに縛って読む。何を状態とし何を目標と

し何で条件づけ、画素で測るか潜在で測るか、報酬で測るかどこに使うかという記録ごとの縛りを外してはならない。収益の記録に見た目の結論を盛らず、転移の記録に生成の結論を盛らず、操作の記録に方策の結論を盛らない。測ったことだけを語り、測っていないことは語らない。分からないものは分からないと残す。収束の是非はこの節では決めず、一本化か分業かは全巻の測定の章に譲る。[106, 107, 104, 108]

本節の読解上の境界

この節の読解上の境界: Genie 3 は能力と運用の到達点としてだけ読み、ベンダーが示す五つの限りと組で読む。仕組みは公開されておらず、整合性やエージェント学習の主張はベンダーの言い分であり、ダイナミクス利用の独立した評価は結びついていない。潜在ダイナミクスの記録は強化学習の指標の範囲に留まり、見栄えの結論は盛らない。運転支援の参照は一次資料待ちであり、機構の根拠にはしない。[106, 107, 104, 108, 105, 109, 110]

16 測る契約と残る限界と開かれた収束

MEASUREMENT

何を測り何を測っていないのか。全巻の評価の契約を測り方ごとに整理し、ベンダー測定と独立した測定を分け、一本化か分業かの収束を未決の問いとして残す。汚染への備えと主張の強さの見分けを示す方法の章として読む。[111, 81, 72]

方法の起点に置くのは OCRBench v2 の汚染への備えだ。23 課題と 31 場面と 1 万件の検証済み QA と 6 種の指標に、1500 枚の非公開画像を添えたと報告されている。一つの指標ではなく複数の指標で測り、課題と場面の広さが読みの土台になる。公開と非公開の傾向が一致することが、漏えいへの備えの根拠になる。公開だけでは覚えていたのか解いたのかが分からず、非公開の一致があって初めて測定の意味が立つ。五つの限界の分類も添えられ、限界の宣言があって初めて測定が誠実になる。鍵の知見は見つける力と指す力の開きで、InternVL3-14B では位置付きの VQA が 78.3%に達する一方 IoU は 12.9%にとどまったと報告されている。分かっている指せず、答えられても位置を言えない場合があり、認識の成功が接地の成功を意味しない。多くの視覚言語モデルは 100 点満点で 50 を下回り、半ばにも届かないのが現在の到達点だ。旧版の v1 はこの版に置き換えられ、古い指標での読みは新しい指標で読み直す。数値はベンチマーク論文の著者が測定したものであり、非公開の中身は設計上

明かされない。明かさないことが備えの条件だ。本章は方法から入り、指標名を並べることが目的ではなく、OCRBench v2 は起点の一つであり章の中心ではない。条件の違う数値を並べて順位をつける読みは採らず、測定条件と結びつけて読み、測定範囲を超える断定はしない。[111]

文書と図表の評価は読みの条件が違う二つの契約だ。DocVQA は 1 万 2000 枚を超える文書画像に 5 万件の問いを載せ、九つの推論の型に分け、8 対 1 対 1 に割ったと報告されている。学習と検証と試験の分け方を外した読みはできない。指標は ANLS で、正確さと併せて読む。素の正確さだけでは読まず、OCR の部分一致の上限が水増しになるため、表記ゆれを吸収する指標でなければ読めたことにならない。LoRRA や M4C や BERT-QA といったベースラインに対し、人は 94.36%に達し、構造を読む問いが隔たりとして残ったと報告されている。どこに何が書いてあるかの構造が読みの核心で、字が読めても構造が読めなければ答えられない。WACV 2021 で発表され、データとコードと順位表が開かれた。抜き出しの近道への弱さと Web 文書の汚染も記録され、文の続きとして当てれば解けてしまう問いがあり、Web に転がっていた文書が混ざるおそれがある。ChartQA は人が作った 9600 件と機械が作った 2 万 3100 件の図表 QA

を、見た目の読みと筋道の読みの両方で測り、緩めた正確さの指標で読んだと報告されている。実世界の図表を対象にし、FigureQA や DVQA や PlotQA といった合成の先行は背景に置く。報告時点の最良は VisionTaPas だった。時点を外して最良を語ってはならない。Findings ACL 2022 で発表され、リポジトリが開かれた。緩めた正確さの許容の意味は数値と切り離せず、どこまで外れを許すかの約束が数値の意味を決める。文書は構造の読みであり図表は見た目と筋道の読みで、測る対象を取り違えてはならず、別の契約の数値で優劣を語らない。[30, 31]

ハルシネーションと根拠の使い方は別の道具で測る。MMMU は大学の試験や小テストや教科書から集めた 1 万 1500 件の専門的なマルチモーダル問いで、6 分野 30 科目 183 細分野と、図表や地図や表や楽譜や化学構造を含む 30 種の画像の型にまたがると報告されている。GPT-4V が 56%、Gemini Ultra が 59% で、伸びしろが大きく残った。合成の点数が知能一般の根拠になることはなく、一つの課題集合の点数を頭の良さ一般に読み替えてはならない。scaffold（補助的手順）のアブレーションと閉じたモデルの汚染の不透明は使うたびに言い添え、助けを借りた分の切り分けと漏えいの疑いの宣言が数値と一緒に示される。POPE は物体ハルシネーションの初の組織的な調べで、投票型の POPE で安定にしなやかに測り、よく出る物や連れ立って出る指示の物がハルシネーションを起こしやすいと報告されている。出やすいものほどないのに見える場合がある。ただし投票の射程にとどまり、あるかないかの問いかけの範囲でしか測っていない。自由な記述の忠実さは制御ペアの道具で測り、HallusionBench のような対の調べが引き受け、対でなければ見えない誤りを見る。MMBench は英中二言語の 3000 件を超える多肢選択を 20 の能力の軸に載せ、品質管理を施し、選択肢回転の一致（CircularEval）と GPT-4 による選択肢抽出で弱い指示追従に頑健にしたと報告されている。順番を回しても答えがぶれないかを見て、言い方のゆれを機械の抽出で吸収する。GPT-4 の抽出は人と 91.5% 一致する。v1.1 で質を直し、ECCV 2024 で発表され、VLMEvalKit に組み込まれた。判定と抽出への依存は数値と切り離せず、機械の判定を借りた分を隠してはならない。二言語といっても英中の範囲で、他の言葉への広がりはこの記録では語らない。幅の測定と投票型評価と英語・中国語の評

価範囲は別の契約で、道具ごとに測れることと測れないことが決まる。[81, 82, 83]

動画の評価は長さの幅と指示文脈の想起で契約が分かれる。Video-MME は 900 本 254 時間 2700 問の初の全域指標で、6 領域 30 細分野と 11 秒から 1 時間の長さにまたがり、字幕と音声のモダリティを添え、専門家が注釈したと報告されている。短い切り抜きから一時間の番組まで幅で測り、字幕と音声の助けも使える条件で測る。Gemini 1.5 Pro が商用モデルの最良で平均 75%、GPT-4o の 71.9% を上回ったというのは、ベンチマーク論文の著者による第三者測定だ。ベンダー測定ではなく、モデル論文の著者測定でもなく、独立した第三者再現でもないが、ベンダーの自己測定とは別の強さをもつ。画像と動画の視覚言語モデルの両方に掛かり、止まった絵のモデルも動く絵のモデルも同じ条件に載る。版は v3 の記録で縛り、版を外して数値を扱ってはならない。LongVideoBench は 3763 本の動画と字幕に 6678 件の人の多肢選択を載せ、17 の細かい分類で、指示された長い文脈を取り出して考える参照推論の課題を置いたと報告されている。見つけてから考える二段階の読みで、探すことと考えることを一つの課題に合わせる。知見はコマを増やして初めて伸びることで、枠数の感受性が将来の長い文脈のモデルへの位置づけになる。指示文脈の契約は長さの幅の契約と取り替えがきかず、長いものを広く測ることに指示されたものを取り出して考えることは別の内容だ。実時間の応答の契約はさらに別であり、溜めたものを考えることと流れるものに応じることは別の条件だ。幅で測る条件と想起で測る条件と実時間で測る条件は混ぜず、条件をまたいで結論を移してはならない。[90, 91]

画面操作の評価は層をなす契約の見本として本章に引き継ぐ。要素の位置を言い当てる条件と、実 OS 上の短い課題の成否の条件と、長い手順の状態管理の条件は別の指標だ。指すこととやり遂げることと保ち続けることは別の内容で、下の層の伸びを上層の伸びに読み替えてはならない。位置が定まっても手順を見失えば課題は失敗し、手順を覚えても位置がずれば操作は空振りし、状態を保てても確認を省けば取り返しのつかない誤りに進む。短い射程の成否と長い射程の成否は測っている対象が違い、条件の違う数値での優劣づけはしない。スクリーンショットを送り続ける費用も動作点を縛る条件として一緒に読み、正確さと費

用の両方を見て判断する。安全に関する記載は測定時の添付資料として位置づけ、運用可否の判断材料ではなく測定条件の一部として扱う。層を分けて測り層を混ぜて語らないことが、本章全体の読み方に通じる。

身体と世界の到達点は限りと一緒に読む。Gemini Robotics 2 は両腕から全身の人型までを射程とする最上位の VLA と、実世界理解に基づく多段計画を担う ER 2 と、端末動作の効率型 VLA である On-Device 2 で構成され、計画と方策の役割分担が製品形態で示されたと報告されている。考える側と動かす側の分け方が製品の形で現れ、提供は提携と早期利用の形をとる。内部構成や遅延や価格やトークンに関する事実は開示がなく、能力と運用の範囲に限定して読み、構成の根拠にはしない。ベンダー資料は到達水準の記録であり、構成の記録ではない。On-Device 2 は Gemma に Robotics 1.5 の技術を組み込んだ VLA で、文と画像と固有感覚を受けて行動を出し、信頼できる試用者に限って配られると報告されている。場面と指示と行動の汎化を模擬と実機の両方で評価し、学習には TPU と JAX と ML-Pathways を使ったと報告されている。モデルカードに記された範囲では、初見の場面への汎化と自由度の高い制御に限りがあり、安全の射程は両腕を中心とし、層をなす安全の方法が勧められている。モデルカードは更新されうるため日付と切り離さずに読む。Genie 3 は文の指示からその場で動く世界を作る到達点としてだけ読む。毎秒 24 コマの 720p で数分規模の整合性を保ち、1 分間の視覚記憶をもつと報告されている。天候や物や登場人物の出来事を文で指示でき、SIMA エージェントの学習に目的を決めない模擬として使う。ベンダーが示す五つの限りが添えられ、行動空間の狭さ、多エージェントの未解決、地理参照の実地のなさ、文字描画の条件つき、数分規模の長さだ。仕組みは公開されておらず、ダイナミクス利用の独立した評価は結びついていない。製品面の頁は同じ事実を別の所在で結びつけ、単純な文から写實的でその場で歩ける環境を作り、Project Genie の試用の面をもつ。能力と運用の事実は所在が二か所でも、読み取るべき中身は単一だ。到達点の結果は能力と運用の範囲にとどめ、仕組みの推測を混ぜない。[\[102, 103, 109, 110\]](#)

ベンダーの主張と独立した測定は強さの違う結果として分けて読む。Gemini 3.1 Pro は 100 万のコンテキストをもつ当初からのマルチモーダル代表例

で、文と画像と音声と動画を入力し、MMM-PRO と Video-MMMU のベンダー測定を方法の頁とともに載せたと報告されている。長いものを一度に見る力の代表例で、2026 年 2 月のモデルカードで読む。いつの頁かを外さない。役割の上限は明確で、能力とベンダーの評価と運用だけを語り、仕組みの根拠にはならない。版と日付の結びつけが使うたびに要り、結びつけを外した数値は扱わない。仕組みは明かされず、数値はベンダーが測定したものであり、モデルカードの中身は変わりうる。明かされないものは語らず、測り手の名を外さない。Gemini 3.6 Flash はトークン効率に位置づけた当初からのマルチモーダルモデルで、効率軸の比較相手になると報告されている。2026 年 7 月のモデルカードで読み、能力と運用の事実だけを語り、仕組みの内容は語らない。ベンダーの言い分として受け取り、独立した第三者再現とは分けて置く。長いものを一度に見る力と費用軸の効率は別の評価軸として読む。[\[72, 73\]](#)

費用と記憶と待ち時間の経済が実運用の動作点を決める。トークン効率に位置づけたモデルが効率軸の比較対象になり、端末で動く VLA がデプロイ形態の代表例になる。100 万のコンテキストは長いものを一度に見る力を示すが、長く見られることと長く覚えて使い続けられることは別の内容だ。文脈の長さや記憶の保持と応答の速さは別々の評価軸として扱い、一本に合わせない。画面操作ではスクリーンショットを送り続ける費用が手順数とともに積み上がり、費用を抑えた設定では長い作業の伸びが頭打ちになると報告されている。どこまで手順を許しどれだけ費用をかけるかが実運用の成否を分け、正確さと費用の両方を見て動作点を選ぶ。端末の側では文と画像と固有感覚を入力して行動を出す VLA が信頼できる試用者に限って配られ、提供範囲を絞ることが経済と安全の両方の条件になる。学習の基盤の名は報告されても費用や待ち時間の事実は明かされず、明かされていないものは語らず、語らない内容を事実として見積もらない。動作点の選び方が能力の内容と同じ重さをもち、何ができるかと同じだけいくらで動くかが問われる。信頼の面では非公開の一致が漏えいへの備えになり、公開と非公開の傾向の一致が測定の意味を支え、中身を明かさないことが備えの条件になる。誰が測ったか、いつ測ったか、どの範囲で測ったかを外さないことが出所の見分けて、測り手と時点と射程が出所の三点になる。

[72, 73, 103, 111]

教師信号と入出力の条件の年表が全巻を貫く二本の筋として本章に引き継ぐ。言葉の側の教師信号は見る力の育て方として積み重なり、身体側の教師信号は実演の軌道の集め方と機体をまたぐ整えに至った。言葉の年表と身体年表が並走し、どちらか一方の年表では全巻の進みは語れない。入出力の条件も段階を追って変わり、何を入力し何を出力し何で合否を決めるかの約束が章ごとに定め直された。部分一致の上限の扱い、許容の指標の意味、選択肢回転の一致、指示文脈の想起、行動の言語化、特徴の予測という定め直し

が、能力の伸びと同じだけの内容だった。測り方の更新なしに能力の伸びは語れない。集める内容と定める内容がモデルの進みを形づくる。

収束の問いは開いたまま残し、一本化か分業かの断定には全巻の結果は届かない。幅の測定には伸びしろが大きく残り、指す力には開きが残し、独立した指標には乏しさが残り、到達点の仕組みには明かされない部分が残る。測っていないことの断定を急がず、汚染への備えを固め、独立した測定を増やし、契約ごとの指標をそろえることが、次に測るべき内容の整理だ。

[81, 111]

本節の読解上の境界

この節の読解上の境界: 合成点をもって賢さ一般を語らず、使うたびに補助手順の切り分けと汚染の不透明さを添える。投票で測ったことを自由な記述の忠実さとして語らず、判定を借りた分は借りた分として残す。英中の範囲を超えず、版と日付と測り手を外さない。ベンダーが測った値は作り手の言い分として受け取り、独立の根拠と分け、変わりうる頁の断定を動かない事実にししない。ダイナミクス利用の独立した評価の不在など、測られていないことは語らず、収束の断定は出さない。[111, 30, 31, 81, 82, 83, 90, 91, 72, 73, 102, 103, 109, 110]

17 結び

SYNTHESIS

表現の学習と転移を起点に、検出の枠組み（提案・一点予測・集合予測）、密な構造化とプロンプト指示、文書の構造理解、系列としての視覚と自己教師あり学習、画像全体のアライメントから開かれた接地へ、個別に事前学習した構成要素の接続、解像度・融合・時刻の統合、ハルシネーションと根拠利用の診断、オフライン長文脈とオンラインストリーミングの分離、画面操作の接地と状態管理、身体をもつ行動の界面、歴史的定式・潜在ダイナミクス・予測表現・生成的環境の四極へと系譜が分かれ、評価の契約ごとに収束の問いへ集まる。閉じた製品は能力・デプロイの文脈に留め、機構の根拠にはしない。

モジュール構成と一体の事前学習、専門家と汎用モデル、密な注釈とウェブ規模の弱い教師信号、早期・後段・密な融合、凍結と共同学習、オフライン長文脈とオンライン状態保持、計画側の接地と一体の行動表現、潜在ダイナミクスと予測表現と生成的環境、ベン

ダー報告と独立評価が並行する競合関係にある。いずれも万能ではなく、条件・装置・予算・母集団で損得が変わる。

VLA の独立評価の不足、制御に使えるワールドモデルの評価の不在、同一条件での専門家・汎用モデル比較の不在、実デプロイの遅延・メモリ根拠の不足、最新ベンダー報告の独立再現の不足、SigLIP2 引用の特定の弱さは残る。概要水準の 5 件は概要の範囲に留める。運転支援の参照は一次資料待ちであり、機構の根拠にはしない。

概要・断片水準の 5 件は概要の範囲に留め、語りで格上げしない。閉じた製品は能力・デプロイのみで機構推論しない。条件の異なる数値の横断順位づけはしない。ベンダー主張は帰属づきで引用し独立再現を待つ。要旨・断片の事実はその水準でのみ用いる。内部の作業用語は読者文に出さない。

References

- [1]Krizhevsky, Sutskever, Hinton. *ImageNet Classification with Deep CNNs* (Krizhevsky, Sutskever, Hinton). Sept. 2012. URL: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks> (visited on 09/30/2026).
- [2]He et al. *Deep Residual Learning for Image Recognition* (He et al.) Dec. 2015. URL: <https://arxiv.org/abs/1512.03385> (visited on 09/30/2026).
- [3]Fukushima. *Neocognitron* (Fukushima). 1980. URL: <https://doi.org/10.1007/BF00344251> (visited on 09/30/2026).
- [4]LeCun et al. *Gradient-Based Learning Applied to Document Recognition* (LeCun et al.) Nov. 1998. URL: <http://yann.lecun.com/exdb/publis/pdf/lecun-98.pdf> (visited on 09/30/2026).
- [5]Girshick et al. *Rich feature hierarchies (R-CNN)* (Girshick et al.) Nov. 2013. URL: <https://arxiv.org/abs/1311.2524> (visited on 09/30/2026).
- [6]Carion et al. *End-to-End Object Detection with Transformers / DETR* (Carion et al.) May 2020. URL: <https://arxiv.org/abs/2005.12872> (visited on 09/30/2026).
- [7]Cheng et al. *YOLO-World: Real-Time Open-Vocabulary Object Detection* (Cheng et al.) Jan. 2024. URL: <https://arxiv.org/abs/2401.17270> (visited on 09/30/2026).
- [8]Ren et al. *Faster R-CNN* (Ren et al.) June 2015. URL: <https://arxiv.org/abs/1506.01497> (visited on 09/30/2026).
- [9]Liu et al. *SSD: Single Shot MultiBox Detector* (Liu et al.) Dec. 2015. URL: <https://arxiv.org/abs/1512.02325> (visited on 09/30/2026).
- [10]Redmon et al. *You Only Look Once* (Redmon et al.) June 2015. URL: <https://arxiv.org/abs/1506.02640> (visited on 09/30/2026).
- [11]Lin et al. *Focal Loss / RetinaNet* (Lin et al.) Aug. 2017. URL: <https://arxiv.org/abs/1708.02002> (visited on 09/30/2026).
- [12]Zhang et al. *DINO: DETR with Improved DeNoising Anchor Boxes* (Zhang et al.) Mar. 2022. URL: <https://arxiv.org/abs/2203.03605> (visited on 09/30/2026).
- [13]Long et al. *Fully Convolutional Networks for Semantic Segmentation* (Long et al.) Nov. 2014. URL: <https://arxiv.org/abs/1411.4038> (visited on 09/30/2026).
- [14]Kirillov et al. *Segment Anything* (Kirillov et al.) Apr. 2023. URL: <https://arxiv.org/abs/2304.02643> (visited on 09/30/2026).
- [15]Ravi et al. *SAM 2: Segment Anything in Images and Videos* (Ravi et al.) Aug. 2024. URL: <https://arxiv.org/abs/2408.00714> (visited on 09/30/2026).
- [16]Ronneberger et al. *U-Net* (Ronneberger et al.) May 2015. URL: <https://arxiv.org/abs/1505.04597> (visited on 09/30/2026).
- [17]He et al. *Mask R-CNN* (He et al.) Mar. 2017. URL: <https://arxiv.org/abs/1703.06870> (visited on 09/30/2026).
- [18]Kirillov et al. *Panoptic Segmentation* (Kirillov et al.) Jan. 2018. URL: <https://arxiv.org/abs/1801.00868> (visited on 09/30/2026).
- [19]Ranftl et al. *Towards Robust Monocular Depth Estimation / MiDaS* (Ranftl et al.) July 2019. URL: <https://arxiv.org/abs/1907.01341> (visited on 09/30/2026).
- [20]Cao et al. *OpenPose: Realtime Multi-Person 2D Pose* (Cao et al.) Dec. 2018. URL: <https://arxiv.org/abs/1812.08008> (visited on 09/30/2026).

- [21]Krishna et al. *Visual Genome* (Krishna et al.) Feb. 2016. URL: <https://arxiv.org/abs/1602.07332> (visited on 09/30/2026).
- [22]Wang et al. *DUST3R: Geometric 3D Vision Made Easy* (Wang et al.) Dec. 2023. URL: <https://arxiv.org/abs/2312.14132> (visited on 09/30/2026).
- [23]Lee et al. *Pix2Struct* (Lee et al.) Oct. 2022. URL: <https://arxiv.org/abs/2210.03347> (visited on 09/30/2026).
- [24]Blecher et al. *Nougat: Neural Optical Understanding for Academic Documents* (Blecher et al.) Aug. 2023. URL: <https://arxiv.org/abs/2308.13418> (visited on 09/30/2026).
- [25]Wei et al. *General OCR Theory / GOT* (Wei et al.) Sept. 2024. URL: <https://arxiv.org/abs/2409.01704> (visited on 09/30/2026).
- [26]Xu et al. *LayoutLM* (Xu et al.) Dec. 2019. URL: <https://arxiv.org/abs/1912.13318> (visited on 09/30/2026).
- [27]Huang et al. *LayoutLMv3* (Huang et al.) Apr. 2022. URL: <https://arxiv.org/abs/2204.08387> (visited on 09/30/2026).
- [28]Kim et al. *Donut: OCR-free Document Understanding Transformer* (Kim et al.) Nov. 2021. URL: <https://arxiv.org/abs/2111.15664> (visited on 09/30/2026).
- [29]*Qwen3-VL-Embedding and Qwen3-VL-Reranker*. Jan. 2026. URL: <https://arxiv.org/abs/2601.04720> (visited on 09/30/2026).
- [30]Mathew et al. *DocVQA* (Mathew et al.) July 2020. URL: <https://arxiv.org/abs/2007.00398> (visited on 09/30/2026).
- [31]Masry et al. *ChartQA* (Masry et al.) Mar. 2022. URL: <https://arxiv.org/abs/2203.10244> (visited on 09/30/2026).
- [32]Dosovitskiy et al. *An Image is Worth 16x16 Words / ViT* (Dosovitskiy et al.) Oct. 2020. URL: <https://arxiv.org/abs/2010.11929> (visited on 09/30/2026).
- [33]Caron et al. *Emerging Properties in Self-Supervised Vision Transformers / DINO* (Caron et al.) Apr. 2021. URL: <https://arxiv.org/abs/2104.14294> (visited on 09/30/2026).
- [34]Zhai et al. *Sigmoid Loss for Language Image Pre-Training / SigLIP* (Zhai et al.) Mar. 2023. URL: <https://arxiv.org/abs/2303.15343> (visited on 09/30/2026).
- [35]Touvron et al. *DeiT* (Touvron et al.) Dec. 2020. URL: <https://arxiv.org/abs/2012.12877> (visited on 09/30/2026).
- [36]Liu et al. *Swin Transformer* (Liu et al.) Mar. 2021. URL: <https://arxiv.org/abs/2103.14030> (visited on 09/30/2026).
- [37]He et al. *Masked Autoencoders / MAE* (He et al.) Nov. 2021. URL: <https://arxiv.org/abs/2111.06377> (visited on 09/30/2026).
- [38]Oquab et al. *DINOv2* (Oquab et al.) Apr. 2023. URL: <https://arxiv.org/abs/2304.07193> (visited on 09/30/2026).
- [39]Radford et al. *Learning Transferable Visual Models / CLIP* (Radford et al.) Feb. 2021. URL: <https://arxiv.org/abs/2103.00020> (visited on 09/30/2026).
- [40]Jia et al. *Scaling Up Visual and Vision-Language Representation Learning / ALIGN* (Jia et al.) Feb. 2021. URL: <https://arxiv.org/abs/2102.05918> (visited on 09/30/2026).
- [41]Vinyals et al. *Show and Tell* (Vinyals et al.) Nov. 2014. URL: <https://arxiv.org/abs/1411.4555> (visited on 09/30/2026).
- [42]Antol et al. *VQA: Visual Question Answering* (Antol et al.) May 2015. URL: <https://arxiv.org/abs/1505.00468> (visited on 09/30/2026).

- [43]Zareian et al. *Open-Vocabulary Object Detection Using Captions / OVR-CNN* (Zareian et al.) Nov. 2020. URL: <https://arxiv.org/abs/2011.10678> (visited on 09/30/2026).
- [44]Li et al. *Grounded Language-Image Pre-training / GLIP* (Li et al.) Dec. 2021. URL: <https://arxiv.org/abs/2112.03857> (visited on 09/30/2026).
- [45]Liu et al. *Grounding DINO* (Liu et al.) Mar. 2023. URL: <https://arxiv.org/abs/2303.05499> (visited on 09/30/2026).
- [46]Minderer et al. *Scaling Open-Vocabulary Object Detection / OWL-ST/OWLv2* (Minderer et al.) June 2023. URL: <https://arxiv.org/abs/2306.09683> (visited on 09/30/2026).
- [47]Plummer et al. *Flickr30k Entities* (Plummer et al.) Dec. 2015. URL: https://openaccess.thecvf.com/content_iccv_2015/html/Plummer_Flickr30k_Entities_Collecting_ICCV_2015_paper.html (visited on 09/30/2026).
- [48]Yu et al. *Modeling Context in Referring Expressions / RefCOCO* (Yu et al.) Sept. 2016. URL: <https://aclanthology.org/D16-1212/> (visited on 09/30/2026).
- [49]Gupta et al. *LVIS: A Dataset for Large Vocabulary Instance Segmentation* (Gupta et al.) Aug. 2019. URL: <https://arxiv.org/abs/1908.03195> (visited on 09/30/2026).
- [50]Gu et al. *Open-vocabulary Object Detection via Vision and Language Knowledge Distillation / ViLD* (Gu et al.) Apr. 2021. URL: <https://arxiv.org/abs/2104.13921> (visited on 09/30/2026).
- [51]Zhong et al. *RegionCLIP* (Zhong et al.) Dec. 2021. URL: <https://arxiv.org/abs/2112.09106> (visited on 09/30/2026).
- [52]Zhou et al. *Detecting Twenty-thousand Classes using Image-level Supervision / Detic* (Zhou et al.) Jan. 2022. URL: <https://arxiv.org/abs/2201.02605> (visited on 09/30/2026).
- [53]Kamath et al. *MDETR* (Kamath et al.) Apr. 2021. URL: <https://arxiv.org/abs/2104.12763> (visited on 09/30/2026).
- [54]Minderer et al. *Simple Open-Vocabulary Object Detection with Vision Transformers / OWL-ViT* (Minderer et al.) May 2022. URL: <https://arxiv.org/abs/2205.06230> (visited on 09/30/2026).
- [55]Li et al. *Language-driven Semantic Segmentation / LSeg* (Li et al.) Jan. 2022. URL: <https://arxiv.org/abs/2201.03546> (visited on 09/30/2026).
- [56]Zou et al. *Generalized Decoding for Pixel, Image, and Language / X-Decoder* (Zou et al.) June 2023. URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Zou_Generalized_Decoding_for_Pixel_Image_and_Language_CVPR_2023_paper.pdf (visited on 09/30/2026).
- [57]Ghiasi et al. *Scaling Open-vocabulary Image Segmentation with Image-level Labels / OpenSeg* (Ghiasi et al.) Dec. 2021. URL: <https://arxiv.org/abs/2112.12143> (visited on 09/30/2026).
- [58]Xu et al. *Open-Vocabulary Panoptic Segmentation with Text-to-Image Diffusion Models / ODISE* (Xu et al.) Mar. 2023. URL: <https://arxiv.org/abs/2303.04803> (visited on 09/30/2026).
- [59]Li et al. *BLIP-2* (Li et al.) Jan. 2023. URL: <https://arxiv.org/abs/2301.12597> (visited on 09/30/2026).
- [60]Liu et al. *Visual Instruction Tuning / LLaVA* (Liu et al.) Apr. 2023. URL: <https://arxiv.org/abs/2304.08485> (visited on 09/30/2026).
- [61]Alayrac et al. *Flamingo* (Alayrac et al.) Apr. 2022. URL: <https://arxiv.org/abs/2204.14198> (visited on 09/30/2026).
- [62]Tsimpoukelli et al. *Multimodal Few-Shot Learning with Frozen Language Models / Frozen* (Tsimpoukelli et al.) June 2021. URL: <https://arxiv.org/abs/2106.13884> (visited on 09/30/2026).
- [63]Dai et al. *InstructBLIP* (Dai et al.) May 2023. URL: <https://arxiv.org/abs/2305.06500> (visited on 09/30/2026).

- [64]Zhu et al. *MiniGPT-4 (Zhu et al.)* Apr. 2023. URL: <https://arxiv.org/abs/2304.10592> (visited on 09/30/2026).
- [65]Deitke et al. *Molmo and PixMo (Deitke et al.)* Sept. 2024. URL: <https://arxiv.org/abs/2409.17146> (visited on 09/30/2026).
- [66]Bai et al. *Qwen3-VL Technical Report (Bai et al.)* Nov. 2025. URL: <https://arxiv.org/abs/2511.21631> (visited on 09/30/2026).
- [67]Zhu et al. *InternVL3 (Zhu et al.)* Apr. 2025. URL: <https://arxiv.org/abs/2504.10479> (visited on 09/30/2026).
- [68]Xu et al. *Qwen3-Omni Technical Report (Xu et al.)* Sept. 2025. URL: <https://arxiv.org/abs/2509.17765> (visited on 09/30/2026).
- [69]Bai et al. *Qwen2.5-VL Technical Report (Bai et al.)* Feb. 2025. URL: <https://arxiv.org/abs/2502.13923> (visited on 09/30/2026).
- [70]code + weights. *QwenLM/Qwen3-VL repository (code + weights)*. URL: <https://github.com/QwenLM/Qwen3-VL> (visited on 09/30/2026).
- [71]Clark et al. *Molmo2 (Clark et al.)* Jan. 2026. URL: <https://arxiv.org/abs/2601.10611> (visited on 09/30/2026).
- [72]DeepMind. *Gemini 3.1 Pro model card (DeepMind)*. Feb. 2026. URL: <https://deepmind.google/models/model-cards/gemini-3-1-pro/> (visited on 09/30/2026).
- [73]DeepMind. *Gemini 3.6 Flash model card (DeepMind)*. July 2026. URL: <https://deepmind.google/models/model-cards/gemini-3-6-flash/> (visited on 09/30/2026).
- [74]Radford et al. *Robust Speech Recognition via Large-Scale Weak Supervision / Whisper (Radford et al.)* Dec. 2022. URL: <https://arxiv.org/abs/2212.04356> (visited on 09/30/2026).
- [75]Chen et al. *BEATs: Audio Pre-Training with Acoustic Tokenizers (Chen et al.)* Dec. 2022. URL: <https://arxiv.org/abs/2212.09058> (visited on 09/30/2026).
- [76]Elizalde et al. *CLAP: Learning Audio Concepts From Natural Language Supervision (Elizalde et al.)* June 2022. URL: <https://arxiv.org/abs/2206.04769> (visited on 09/30/2026).
- [77]code + weights. *QwenLM/Qwen3-Omni repository (code + weights)*. URL: <https://github.com/QwenLM/Qwen3-Omni> (visited on 09/30/2026).
- [78]code + weights + data. *OpenGVLab/InternVL repository (code + weights + data)*. URL: <https://github.com/OpenGVLab/InternVL> (visited on 09/30/2026).
- [79]training + eval code. *allenai/molmo2 repository (training + eval code)*. URL: <https://github.com/allenai/molmo2> (visited on 09/30/2026).
- [80]Guan et al. *HallusionBench (Guan et al.)* Oct. 2023. URL: <https://arxiv.org/abs/2310.14566> (visited on 09/30/2026).
- [81]Yue et al. *MMMU (Yue et al.)* Nov. 2023. URL: <https://arxiv.org/abs/2311.16502> (visited on 09/30/2026).
- [82]Li et al. *Evaluating Object Hallucination / POPE (Li et al.)* May 2023. URL: <https://arxiv.org/abs/2305.10355> (visited on 09/30/2026).
- [83]Liu et al. *MMBench (Liu et al.)* July 2023. URL: <https://arxiv.org/abs/2307.06281> (visited on 09/30/2026).
- [84]Lu et al. *MathVista (Lu et al.)* Oct. 2023. URL: <https://arxiv.org/abs/2310.02255> (visited on 09/30/2026).
- [85]Zhang et al. *Flash-VStream (Zhang et al.)* June 2024. URL: <https://arxiv.org/abs/2406.08085> (visited on 09/30/2026).
- [86]Lin et al. *StreamingBench (Lin et al.)* Nov. 2024. URL: <https://arxiv.org/abs/2411.03628> (visited on 09/30/2026).

- [87]Grauman et al. *Ego4D (Grauman et al.)* Oct. 2021. URL: <https://arxiv.org/abs/2110.07058> (visited on 09/30/2026).
- [88]Kay et al. *The Kinetics Human Action Video Dataset (Kay et al.)* May 2017. URL: <https://arxiv.org/abs/1705.06950> (visited on 09/30/2026).
- [89]Goyal et al. *Something-Something V2 (Goyal et al.)* June 2017. URL: <https://arxiv.org/abs/1706.04261> (visited on 09/30/2026).
- [90]Fu et al. *Video-MME (Fu et al.)* May 2024. URL: <https://arxiv.org/abs/2405.21075> (visited on 09/30/2026).
- [91]Wu et al. *LongVideoBench (Wu et al.)* July 2024. URL: <https://arxiv.org/abs/2407.15754> (visited on 09/30/2026).
- [92]Yang et al. *VSI-Bench (Yang et al.)* Dec. 2024. URL: <https://arxiv.org/abs/2412.14171> (visited on 09/30/2026).
- [93]Xie et al. *OSWorld (Xie et al.)* Apr. 2024. URL: <https://arxiv.org/abs/2404.07972> (visited on 09/30/2026).
- [94]Yuan et al. *OSWorld 2.0 (Yuan et al.)* June 2026. URL: <https://arxiv.org/abs/2606.29537> (visited on 09/30/2026).
- [95]Cheng et al. *SeeClick / ScreenSpot (Cheng et al.)* Jan. 2024. URL: <https://arxiv.org/abs/2401.10935> (visited on 09/30/2026).
- [96]Ahn et al. *Do As I Can, Not As I Say / SayCan (Ahn et al.)* Apr. 2022. URL: <https://arxiv.org/abs/2204.01691> (visited on 09/30/2026).
- [97]Driess et al. *PaLM-E (Driess et al.)* Mar. 2023. URL: <https://arxiv.org/abs/2303.03378> (visited on 09/30/2026).
- [98]Brohan/Zitkovich et al. *RT-2 (Brohan/Zitkovich et al.)* July 2023. URL: <https://arxiv.org/abs/2307.15818> (visited on 09/30/2026).
- [99]Kim et al. *OpenVLA (Kim et al.)* June 2024. URL: <https://arxiv.org/abs/2406.09246> (visited on 09/30/2026).
- [100]Brohan et al. *RT-1 (Brohan et al.)* Dec. 2022. URL: <https://arxiv.org/abs/2212.06817> (visited on 09/30/2026).
- [101]O'Neill et al. *Open X-Embodiment (O'Neill et al.)* Oct. 2023. URL: <https://arxiv.org/abs/2310.08864> (visited on 09/30/2026).
- [102]DeepMind. *Gemini Robotics 2 (DeepMind)*. July 2026. URL: <https://deepmind.google/models/gemini-robotics/> (visited on 09/30/2026).
- [103]DeepMind. *Gemini Robotics On-Device 2 model card (DeepMind)*. July 2026. URL: <https://deepmind.google/models/model-cards/gemini-robotics-on-device-2/> (visited on 09/30/2026).
- [104]LeCun et al. *Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture / I-JEPA (LeCun et al.)* Jan. 2023. URL: <https://arxiv.org/abs/2301.08243> (visited on 09/30/2026).
- [105]Bruce et al. *Genie: Generative Interactive Environments (Bruce et al.)* Feb. 2024. URL: <https://arxiv.org/abs/2402.15391> (visited on 09/30/2026).
- [106]Ha & Schmidhuber. *World Models (Ha & Schmidhuber)*. Mar. 2018. URL: <https://arxiv.org/abs/1803.10122> (visited on 09/30/2026).
- [107]Hafner et al. *Mastering Diverse Domains through World Models / DreamerV3 (Hafner et al.)* Jan. 2023. URL: <https://arxiv.org/abs/2301.04104> (visited on 09/30/2026).
- [108]Bardes et al. *Revisiting Feature Prediction / V-JEPA (Bardes et al.)* Feb. 2024. URL: <https://arxiv.org/abs/2404.08471> (visited on 09/30/2026).

- [109]DeepMind blog. *Genie 3 (DeepMind blog)*. Aug. 2025. URL: <https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/> (visited on 09/30/2026).
- [110]DeepMind. *Genie 3 model page (DeepMind)*. Aug. 2025. URL: <https://deepmind.google/models/genie/> (visited on 09/30/2026).
- [111]Fu et al. *OCRBench v2 (Fu et al.)* Dec. 2024. URL: <https://arxiv.org/abs/2501.00321> (visited on 09/30/2026).