

---

# Japanese Generative AI Technical Survey

2026-W33

2026-08-17

## モデルの利用条件まで動いた

W33 は、モデル/API の入口、実装 runtime、そして agent・multimodal を含む評価の粒度が同時に動いた週だった。使えること、動かせること、確かめられることを一つの線で読み直す。

[FEATURE: ACCESS SURFACES](#) / [DEEP DIVE: RUNTIME & INFERENCE](#) / [REVIEW: WHAT TO WATCH](#)

**Editorial cutoff** 2026-08-14 18:00 America/New\_York

**Repository** eariver/japanese-generative-ai-survey

**Build** LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

## Contents

- 1 Frontier Models & Access — モデル名ではなく入口を比較する
- 2 Cyber Access & Governance — 許可・経路・統治の境界
- 3 Serving & Runtime — モデルを運用へ変換する四層
- 4 Inference Systems Deep Dive — KV メモリと decoding
- 5 Agent Reliability — 成功率から失敗の場所へ
- 6 Multimodal & Media — capability を workflow で読む
- 7 Week in Review — 変化・意味・次の観測点

## This Week in AI

**入口が分岐した。** API preview、GA、open weights、partner channel が同じ週に並んだが、同じ種類の公開ではない。利用者がどの面から触れられるかを分けて読む必要がある。

**運用の層が前景化した。** serving framework、local runtime、front-end/cache、low-level kernel、KV 管理、decoding policy が、モデルを「使える」に変える条件として別々に動いた。

**評価単位が細くなった。** agent では interface、planning、function call、transaction、red teaming、skill を分離し、multimodal では理解・生成編集・runtime を混同しない設計が見えた。

### この号の読み方

通常本文の Editorial Cutoff は 2026-08-14 18:00 America/New\_York。本文の実質的な事実は、本号で採用した W33 記事素材が保持する範囲に限る。vendor、project、paper author の主張はそれぞれの主体に帰属させ、paper や release note の値を横断的な独立ベンチマークへ言い換えない。

編集上の軸： 今週のニュースを発表件数ではなく、**access**、**operation**、**proof** の三つの接続面から読む。

# 1 Frontier Models & Access

## ACCESS SURFACES

### モデルの強さより、どの入口で使えるか

W33 のモデル動向は、API preview、GA、open weights、partner channel という異なる access surface の同時進展として読む。ただし、速度値・詳細仕様・index-level 情報には未解決の境界が残る。

今週の入口は一つではない。DeepSeek の API changelog は 8 月 13 日の DeepSeek-V4-Pro の GA update を app、web、API 横断で記録し、Google の API changelog は Gemini 3.7 Flash の GA を同日付で記録する [1, 2, 3]。Qwen の first-party repository は、Qwen3.8-2.4T-A95B を 8 月 12 日、27B を 8 月 14 日に、Hugging Face Hub と ModelScope 経由で利用可能になったものとして記載している [4]。ここでは GA と open weights を同じ「発表」として数えず、利用者が触れる面の違いとして並べる。

#### 四つの access surface

|                           |             |                                                                                  |
|---------------------------|-------------|----------------------------------------------------------------------------------|
| <b>API view</b>           | <b>pre-</b> | GPT-5.6 Sol Ultrafast は API tier として記述されるが、preview と GA の切り分けは未解決 [5]。           |
| <b>GA API / app / web</b> |             | DeepSeek-V4-Pro と Gemini 3.7 Flash は、それぞれの first-party chronology で GA として記録される。 |
| <b>Open weights</b>       |             | Qwen3.8 は複数サイズが Hugging Face Hub と ModelScope 経由で記載される。                          |
| <b>API partner</b>        | <b>+</b>    | Grok 4.6 は API と partner availability を伴う release として記述される [6]。                  |

この表は同じ製品形態を意味するものではなく、確認できる deployment surface の比較である。モデルを取得できることと、特定の API、アプリ、web 面、partner 面で利用できることを一つの availability へ潰さない。

#### 未解決の境界

OpenAI の確認資料は Ultrafast を vendor-stated の速度主張とともに記述するが、preview と GA の分離、速度値の検証は残っている。GLM-5.3 は coding/cyber framing と 8 月 14 日の event date までは確認できる一方、direct page body がなく、benchmark、cybersecurity、local-weight timing の詳細は未解決である [7]。Gemini の API changelog と xAI の news index は chronology/context として扱い、詳細な technical authority を代替させない [3, 8]。

だから読者が問うべきなのは「新しいモデルが出たか」だけではない。どの access mode で、どの deployment surface から触れられ、どの部分が出典主体の主張として残り、どの部分がまだ検証待ちなのかである。dedicated event、chronology/index、context signal を一つの launch chronology に潰さないことが、この週の変化を正しく読む条件になる。

#### Source-backed boundary

X の community signal は関心の方向を示す文脈にとどめる。技術仕様、性能、互換性の根拠は first-party または paper/repository の記録に置き、X の反応から新しい launch や性能を推論しない [9]。

## 2 Cyber Access & Governance

### AUTHORIZED ACCESS

#### Cyber モデルの提供は、許可の設計から始まる

GPT-5.6-Cyber / Daybreak Red の動きは、一般向けモデル公開ではなく、authorized access、partner distribution、safeguard の境界を読む材料として整理する。

OpenAI の確認資料は、GPT-5.6-Cyber を Daybreak Red 経由で、authorized vulnerability research と security testing に利用できるものとして記述している [10]。ここで示されるのは「誰でも使える新モデル」ではなく、目的を限定した program access である。記事では、この主体と用途の帰属を保ったまま扱う。

同じ Daybreak でも、アクセス経路は一つではな

い。別の OpenAI 資料は Daybreak models を Amazon Bedrock 経由で enterprise security workflows に利用できるものとして記し、さらに approved Daybreak partners が frontier cyber models を authorized で governed な cybersecurity services に使う形も記述する [11, 12]。Bedrock や partner の記録は Daybreak の重複 launch ではなく、distribution と統治の補助線として置く。

#### 三つの範囲を分ける

|                           |                                                                                                   |
|---------------------------|---------------------------------------------------------------------------------------------------|
| <b>Model scope</b>        | GPT-5.6-Cyber / Daybreak Red として記述されたモデルの範囲。                                                      |
| <b>Access scope</b>       | vulnerability research、security testing、enterprise workflow、approved partner service という目的・経路の範囲。 |
| <b>Safeguard boundary</b> | 確認資料は authorized / governed という方向を示すが、具体的な safeguards と一般の model/API availability までは閉じていない。      |

この三分割は、利用可否を一語で答えないためのものだ。program access は、目的、主体、経路、統治条件を含む。したがって、その説明を一般提供の宣言へ拡張しない。Bedrock での availability も、記録が示す access route を超えて推測しない。

#### 次に見るべき境界

確認資料が示す authorized / governed という説明を超えて、具体的な safeguards、全モデルの範囲、一般の API availability を断定しない。次の観測点は、program access と一般提供を区別できるモデル範囲、Bedrock での availability 境界、そして safeguards の具体化である。

この章での問いは、「そのモデルは使えるか」から「誰が、どの目的で、どの経路を通り、どの統治条件の下で使えるか」へ移る。アクセスの制度設計そのものが、モデルの実用面を規定する。

## 3 Serving & Runtime

### IMPLEMENTATION LAYERS

モデルを「使える」に変える、四つの

## 実装層

vLLM、llama.cpp、SGLang、FlashInfer の動きは別々の release note ではない。serving framework、local runtime、front-end/cache、low-level kernel が、それぞれ異なる場所で運用の成立条件を動かしている。

同じ「support」でも、動かしている層が違う。

#### 四層の実装地図

|                                   |                                                                                                                                            |
|-----------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Full serving framework</b>     | vLLM v0.27.0 は Kimi K3 の full-stack support、新しい model integration、PyTorch/Triton upgrade、KV/offload・disaggregation・serving 機能をまとめて扱う [13]。 |
| <b>Local inference runtime</b>    | llama.cpp b10369 は Pocket-TTS support と convolution-to-GEMM 実装を追加する [14]。                                                                  |
| <b>Front-end / cache behavior</b> | SGLang v0.5.17 は Rust server front end、session-aware radix caching、serving/runtime 変更を記述する [15]。                                           |
| <b>Low-level kernel</b>           | FlashInfer v0.6.17 は MoE expert parallelism、SM12x FP4 fixes、unified MXFP4 APIs、decode coverage を記述する [16]。                                 |

この四層を分けると、availability が runtime support に依存する理由が見える。full-stack 側では vLLM がモデル統合と serving 機能を一つの更新に束ね、SGLang は front end と cache の側から運用面を支える。FlashInfer はその下で decode や低レベル実行を担い、llama.cpp は local runtime で別の利用面を開く。つまり、モデルを取得できることと、選んだ環境で継続的に運用できることは同じ条件ではない。

#### Release を層で読む

release note にある機能追加と性能改善を同じ強さの事実として読まない。とくに llama.cpp の timing figures は project-reported として扱い、vLLM、SGLang、FlashInfer の performance をここで独立測定結果へ拡張しない。今回の比較軸は「何層が変わったか」であり、数値の横比較ではない。

実運用での次の問いは、「モデルを持っているか」だけでは足りない。どの serving framework が統合し、どの local runtime が動かし、front end/cache が状態を扱い、kernel 層が decode を支えるのかを確認する必要がある。モデル競争の裏側で、実装競争が利用条件を組み替えている。

## 4 Inference Systems Deep Dive

### MEMORY / PREFETCH / DECODING

### 推論を速くする場所は、メモリか、先読みか、復号か

vToken、OasisKV、Ripple-Pivot Search は、同じ「高速化」でも別のボトルネックを動かす。KV の置き場所と生存管理、prefetch、diffusion LLM の decoding policy を共通の問いで比較する。

三つの提案は、推論の別々の詰まりを狙う。

#### 機構を同じ表に置く

|                                    |                                                                                                                                         |
|------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|
| <b>Memory placement / liveness</b> | vToken は logical token の生存と physical KV block を indirection で分離し、非同期 repacking を使う。paper は PagedAttention と CUDA Graph との互換性も記述する [17]。 |
| <b>Tiering / prefetch</b>          | OasisKV は HBM には relevant な KV だけを置き、より容量の大きい memory tier を使いながら lookahead sparse prefetching を行う [18]。                                 |
| <b>Decoding policy</b>             | Ripple-Pivot Search は mid-entropy pivot と lookahead evaluation を使う training-free の diffusion-LLM decoding method である [19]。              |

比較のポイントは、三つを一つの性能ランキングにすることではない。vToken と OasisKV は KV をどう生かし、どこに置き、どう先読みするかを変える。一方 Ripple-Pivot は、diffusion LLM が次の token を決める decoding policy そのものを変える。前者は memory system の配置・再利用、後者は生成手順の探索を動かすため、「速くする」の中身が異なる。

#### 評価値の帰属

OasisKV は vLLM 上の accuracy と throughput、Ripple-Pivot は三つの dLLM と四つの benchmark で speed と quality の結果を報告するが、今回確認できる範囲では、いずれも paper authors が報告した測定である。独立再現結果や横断的な同一条件の比較として言い換えない。

読者が「推論を速くする」と聞いたら、memory placement、prefetch、decoding policy のどこを変えたのかを先に確認したい。そうすれば、KV cache の運用を組み替える提案と、復号の探索を変える提案を、同じ指標だけで混同せずに済む。次の観測点は、各機構がどの runtime・モデル・評価条件で有効なのかを、論文の報告境界ごとに追うことである。

## 5 Agent Reliability

### FAILURE ATTRIBUTION

### Agent の評価を、成功率から失敗の場所へ

今週の agent 研究は、モデルの賢さを一つの数値で競うより、scaffolding、planning、tool call、transaction、red teaming、skill のどこで信頼性が崩れるかを測る方向へ進む。

評価対象を失敗の発生層でそろえる。

## 信頼性を層別に測る

|                                |                                                                                                                                                                                              |
|--------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Scaffolding / interface</b> | 七つの agent scaffolding と五つの language model を一つの software task で比較し、repository-state completion と scaffolding 依存の cost variation を見る [20]。                                                     |
| <b>Requirements / planning</b> | SWE-RPG は 163 tasks ・ 31 repositories で requirement と planning の参照を検証し、implicit requirement recovery を bottleneck として診断する [21]。                                                              |
| <b>Function call</b>           | PluginEval は deterministic validation、real API execution、adversarial negatives で fine-grained error attribution を行う [22]。                                                                    |
| <b>Transaction</b>             | Agentic Transaction は semantic atomicity、consistency、isolation、durability を agent system の設計対象として定義する [23]。                                                                                  |
| <b>Red teaming / skills</b>    | REDAgentBench は isolated sandbox と state/receipt verification で実行可能な攻撃測定を組み、SkillTriage の研究は loaded skill による failure と efficiency regression を paired differential analysis で帰属する [24, 25]。 |

この並べ方から見える共通点は、失敗を agent の内側の一つの能力へ押し込めないことだ。scaffolding は同じ model でも作業の進み方と cost を変え、requirements/planning は問題文に埋まった意図の回収を問う。function call は API を実際に通して誤りの種類を分解し、transaction 設計は長い処理の途中状態を守る。さらに red-team 環境は実行結果を検証し、skill 研究は追加された手順そのものが機能失敗や効率低下を生む可能性を測る。

したがって、成功率の大小だけでは信頼性の中身が分からない。completion check、implicit requirement、function-call error taxonomy、state/receipt、ACID semantics、skill-induced failure は、成功したかどうかの手前にある原因と再現条件を別々に記録する。こ

れらは各 paper が報告する benchmark や environment の範囲での結果であり、すべての agent や task へ一般化した主張としては扱わない。

## 読者の問い

「agent が賢いか」だけでなく、どの層を測り、どの状態を成功とし、失敗を interface、planning、tool call、transaction、red-team 環境、skill のどこへ帰属できるかを問う。評価がこの粒度まで下りれば、モデルの更新と system の設計変更を切り分けながら、再現可能な reliability の改善を追える。

## 6 Multimodal &amp; Media

## WORKFLOW SURFACES

## マルチモーダルを、モデル名ではなく workflow で読む

VideoGAIA、VoiceDesigner、ComfyUI は、理解・生成編集・実装 runtime という異なる接点を持つ。研究上の能力と実用 workflow を直結させず、どこまでつながるかを境界付きで見る。

三つの接点を同じ「multimodal capability」として潰さない。



## 理解・生成編集・runtime

|                  |                                                                                                                                                               |
|------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 理解・評価            | VideoGAIA は multi-turn、tool-augmented video understanding benchmark で、model-human co-designed の 271 tasks と各 instance の three-expert verification を記述する [26]。 |
| 生成・編集            | VoiceDesigner は hybrid data pipeline と diffusion transformer で text-to-voice generation と editing を unify すると記述されるが、詳細な baseline results は確認できる資料にはない [27]。   |
| Workflow runtime | ComfyUI v0.31.0 の release notes は Flux 3 video、Wan-Animate2、関連する generative-media support に加え、runtime と memory の変更を列挙する [28]。                                 |

共通するのは、単一の model ranking ではなく、workflow のどこを成立させるかという視点である。VideoGAIA は動画を理解する agent の multi-turn と tool use を評価する。VoiceDesigner は生成と編集を一つの model/data pipeline へ寄せる。ComfyUI は複数の media model を実際の制作環境へ組み込む runtime 側を更新する。この三つは、理解・生成編集・実装という連続した工程を照らす、確認できる資料は相互の直接的な interoperability までは示していない。

## 接続を急がない

VoiceDesigner については、generation/editing unification という著者の記述を、model や data contribution、baseline、evaluation、novelty が確定したという意味へ広げない。確認できる資料が部分的であるため、詳細な比較は未解決として残す。また、VideoGAIA の評価設計と ComfyUI の runtime support を、研究 model がそのまま制作 workflow で動く証拠とは扱わない。

次に見るべきなのは、理解・生成編集・runtime の接続点が実際に検証されるかである。VideoGAIA では tool protocol と human validation がどの範囲を測るか、VoiceDesigner では未提示の baseline と evaluation

がどこまで補われるか、ComfyUI では列挙された support がどの workflow で再現できるかを追う。現時点で確定できるのは、三つの層が同じ方向を向き始めたことまでである。

## 7 Week in Review

## WEEKLY SYNTHESIS

## 今週は、モデルの利用条件まで動いた

モデル/API の入口、runtime、agent・multimodal の測定が一つの連鎖として見え始めた。ここでは前六章の材料を、出来事の順番ではなく、利用条件がどこで変わったかという横断軸で読む。

## 今週何が変わったか

1. 入口が分岐した。API preview、GA API/app/web、open weights、partner channel が並び、モデルの存在と利用可能性を同じ語で扱えなくなった。Cyber の program access も含め、誰がどの目的でどの経路を通るかが availability の一部になった。
2. 運用の層が動いた。serving framework、local runtime、front-end/cache、low-level kernel が別々の実装面を更新し、KV の placement・prefetch や decoding policy まだが「モデルを動かす」条件として前景化した。
3. 確かめる単位が細かくなった。agent では scaffolding、requirements/planning、function call、transaction、red teaming、skill の失敗箇所を分け、multimodal では理解・生成編集・runtime の接点を分けて測る方向が見えた。

## なぜそれらが一緒に重要なのか

新しい access surface は、対応する runtime があって初めて運用へ届く。runtime の効率性は memory placement や decoding policy に左右され、agent や multimodal の実用性は、tool・状態・workflow を含む評価で初めて確かめられる。今週の変化は、モデルを手に入れる入口、動かし方、壊れ方の測り方が別々のニュースではなく、利用条件を構成する連鎖として見えるようになった点にある。

ただし、この連鎖は製品間の直接的な互換性を意味しない。各 release、paper、program record は固有の主体・環境・測定条件を持つ。したがって、access

の拡大を性能の向上へ、runtime の更新を全モデルの対応へ、細かな benchmark を一般の agent reliability へ自動的に変換してはいけない。

#### Weekly Community Movement — context only

X 上の community signal は、今週のモデルや runtime に対する関心の向きを補助的に見るための背景材料である。ここから新しい発売事実、性能結果、互換性を導かない。本文では X の反応を technical authority から分離し、確認可能な first-party、repository、paper の記録だけを実質的な根拠として扱う [9]。

### 次に何を見るべきか

次週以降は、連鎖のどこが実証されるかを追う。Ultrafast の preview と GA、速度値、GLM-5.3 の

direct-page ・ benchmark ・ cyber ・ local-weight timing、Daybreak の model/access scope と Bedrock 境界はまだ詳細化されていない。VoiceDesigner も model/data contribution、baseline、evaluation、novelty の捕捉が足りない。さらに、runtime や論文の評価は、それぞれのモデル・環境・条件から外へ一般化できるかを確認する必要がある。

#### Week in Review の境界

この章は、前六章がすでに扱う材料を横断して編集した独立章であり、新しい外部事実、candidate、source を追加していない。採用されなかった保留・除外対象を、総括だけで今週の実事へ復活させない。Profile Completeness が LIMITED であることも踏まえ、残存 limitations を次の観測点として残す。



## Source Notes / この号の読み方

本誌はニュース記事の引用集ではなく、**event chronology**、**technical evidence**、**community observation** を分離した **survey** として作成している。本文では、主張の主体と適用範囲を次のように読み分ける。

### Primary / Technical source

Official announcement、documentation、model card、paper、GitHub release 等。存在・chronology・仕様の核は、確認された first-party または paper/repository の記録に接続する。Vendor / author 自身の benchmark 値は、primary source であっても独立検証済み性能とは区別する。

### Claim Boundary

Vendor claim、author-reported metric、benchmark 条件、program access、未検証事項など、主張の適用範囲を本文から切り分ける。

### Community Observation

W33 の X signal は、関心の向きを見る context-only の補助材料である。X 上の technical claim の正しさや、本文にない発売・性能・互換性を保証しない。

### Issue Synthesis

Week in Review は前六章の既配置材料を横断する独立章であり、追加の candidate や外部事実を導入しない。

W33 本文の実質的な事実、本号で採用した七つの記事素材が保持する範囲に限る。引用 metadata は、引用先、source class、attribution、limitation、Evidence identity を保持するために使用した。本文の比較は、同じ尺度で測った性能ランキングではなく、access surface、implementation layer、evaluation boundary の差を示す編集上の整理である。

### Temporal and evidence boundary

通常本文の cutoff は 2026-08-14 18:00 America/New\_York。出典主体の主張、paper authors の報告、OSS project の release note、X/community の観測を相互に代替させない。未解決の点は未解決のまま次の観測点へ送る。

## References / Source Notes

- [1] *deepseek-api-updates*. Primary official API chronology; detailed technical scope remains bounded. URL: <https://api-docs.deepseek.com/updates/> (visited on 08/29/2026).
- [2] *Gemini 3.7 Flash*. Primary official source; GA chronology. Aug. 13, 2026. URL: <https://blog.google/innovation-and-ai/models-and-research/gemini-models/introducing-gemini-3-7-flash/> (visited on 08/29/2026).
- [3] *google-gemini-api-release-notes*. Primary official chronology source. URL: <https://ai.google.dev/gemini-api/docs/changelog> (visited on 08/29/2026).
- [4] *Qwen3.8*. First-party repository; open-weight availability surface retained. URL: <https://github.com/QwenLM/Qwen3.8> (visited on 08/29/2026).

- [5] *Previewing Ultrafast mode: GPT-5.6 Sol at up to 14X the speed*. Primary official source; vendor-stated speed and preview/GA boundary retained. Aug. 13, 2026. URL: <https://openai.com/index/previewing-ultrafast> (visited on 08/29/2026).
- [6] *Introducing Grok 4.6*. Primary official source; API and partner availability surface. Aug. 12, 2026. URL: <https://x.ai/news/grok-4-6> (visited on 08/29/2026).
- [7] *GLM-5.3: Frontier Coding with Emergent Cyber Capabilities*. Primary official source; direct-page and detailed benchmark boundaries retained. Aug. 14, 2026. URL: <https://z.ai/blog/glm-5.3> (visited on 08/29/2026).
- [8] *xai-news*. Primary official index; chronology/context only. URL: <https://x.ai/news> (visited on 08/29/2026).
- [9] *Post-merge W33 X community signal wave*. Repository-bound SOCIAL source; context-only community observation, not technical authority. URL: [Grok\\_X\\_SourseIntake/Weekly/2026-W33/weekly-x-2026-W33-postmerge-r1/grok-x-result.md](https://Grok_X_SourseIntake/Weekly/2026-W33/weekly-x-2026-W33-postmerge-r1/grok-x-result.md) (visited on 08/29/2026).
- [10] *Expanding Daybreak as the Cyber Defense Window Narrows*. Primary official source; authorized vulnerability research and security testing scope. Aug. 10, 2026. URL: <https://openai.com/index/expanding-daybreak-as-the-cyber-defense-window-narrows> (visited on 08/29/2026).
- [11] *Daybreak models are now available on AWS*. Primary official source; Amazon Bedrock route retained as distribution context. Aug. 11, 2026. URL: <https://openai.com/index/daybreak-models-are-now-available-on-aws> (visited on 08/29/2026).
- [12] *Putting frontier cyber models in more trusted hands*. Primary official source; approved partner and governance context. Aug. 10, 2026. URL: <https://openai.com/index/putting-frontier-cyber-models-in-more-trusted-hands> (visited on 08/29/2026).
- [13] *v0.27.0*. Primary repository release; implementation support surface. Aug. 10, 2026. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.27.0> (visited on 08/29/2026).
- [14] *b10369*. Primary repository release; project-reported timing remains attributed. Aug. 12, 2026. URL: <https://github.com/ggml-org/llama.cpp/releases/tag/b10369> (visited on 08/29/2026).
- [15] *v0.5.17*. Primary repository release; front-end and cache behavior. Aug. 8, 2026. URL: <https://github.com/sgl-project/sglang/releases/tag/v0.5.17> (visited on 08/29/2026).
- [16] *Release v0.6.17*. Primary repository release; low-level kernel and decode coverage. Aug. 11, 2026. URL: <https://github.com/flashinfer-ai/flashinfer/releases/tag/v0.6.17> (visited on 08/29/2026).
- [17] “vToken: Token-Level Virtualization for Reclaimable KV Caches”. In: (Aug. 13, 2026). Paper metadata; mechanisms and results remain author-reported. URL: <http://arxiv.org/abs/2608.13263v1> (visited on 08/29/2026).
- [18] “OasisKV: Scaling In-Decode KV Cache Beyond HBM with Lookahead Sparse Prefetching”. In: (Aug. 8, 2026). Paper metadata; mechanisms and results remain author-reported. URL: <http://arxiv.org/abs/2608.08097v1> (visited on 08/29/2026).
- [19] “Ripple-Pivot Search: Active Parallel Decoding for Diffusion Large Language Models”. In: (Aug. 12, 2026). Paper metadata; mechanisms and results remain author-reported. URL: <http://arxiv.org/abs/2608.11742v1> (visited on 08/29/2026).
- [20] “The Scaffolding Matters More Than the Interface: A Controlled Comparison of MCP and CLI Tool Use Across Seven Agent Scaffoldings, Five Language Models, and One Software Task”. In: (Aug. 9, 2026). Paper metadata; benchmark scope and results remain author-reported. URL: <http://arxiv.org/abs/2608.08654v1> (visited on 08/29/2026).
- [21] “A Unified Issue Resolution Benchmark for Requirement Clarification, Planning, and Code Generation for Coding Agents”. In: (Aug. 10, 2026). Paper metadata; benchmark scope and results remain author-reported. URL: <http://arxiv.org/abs/2608.09072v1> (visited on 08/29/2026).

- [22]“PluginEval: A Diagnostic Benchmark for Fine-Grained Error Attribution in Function Calling”. In: (Aug. 9, 2026). Paper metadata; benchmark scope and results remain author-reported. URL: <http://arxiv.org/abs/2608.08700v1> (visited on 08/29/2026).
- [23]“Agentic Transaction: Towards ACID-Compliant Agent Systems”. In: (Aug. 14, 2026). Paper metadata; conceptual and experimental claims remain bounded. URL: <http://arxiv.org/abs/2608.13900v1> (visited on 08/29/2026).
- [24]“REDAgentBench: Executable Red Teaming and Faithful Measurement of LLM Agent Systems”. In: (Aug. 11, 2026). Paper metadata; sandbox and measurement claims remain author-reported. URL: <http://arxiv.org/abs/2608.10669v1> (visited on 08/29/2026).
- [25]“Agent Skills Can Be Harmful: An Empirical Study of Skill-Induced Failures in LLM Agents”. In: (Aug. 12, 2026). Paper metadata; paired differential results remain author-reported. URL: <http://arxiv.org/abs/2608.11888v1> (visited on 08/29/2026).
- [26]“VideoGAIA: A Benchmark for General AI Assistants on Agentic Video Understanding”. In: (Aug. 12, 2026). Paper metadata; benchmark design and results remain author-reported. URL: <http://arxiv.org/abs/2608.14718v1> (visited on 08/29/2026).
- [27]“VoiceDesigner: Text-to-Voice Generation and Editing via Unified Diffusion Modeling and Data Augmentation”. In: (Aug. 12, 2026). Paper metadata; baseline and evaluation details remain unresolved in the accepted capture. URL: <http://arxiv.org/abs/2608.13613v1> (visited on 08/29/2026).
- [28]*v0.31.0*. Primary repository release; listed support is not direct interoperability proof. Aug. 8, 2026. URL: <https://github.com/Comfy-Org/ComfyUI/releases/tag/v0.31.0> (visited on 08/29/2026).