
Japanese Generative AI Technical Survey

2026-W34

2026-08-21

エージェントの本番化が進んだ週

支払いと操作、共同作業と検索が実装の姿で並び、統制と配備が実行の構えを決めた。モデルの賢さではなく、何がどこでいくらでどの条件のもと動くかが問われた。

[FEATURE: CONTROL PLANE](#) / [FEATURE: WORKFLOWS](#) / [REVIEW: WHAT TO WATCH](#)

Editorial cutoff 2026-08-14 18:00 - 2026-08-21 18:00 America/New_York

Repository [eariver/japanese-generative-ai-survey](#)

Build [LuaLaTeX](#) / [jlreq](#) / [LuaTeX-jā](#)

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

- 1 Agent Control Plane — 取引・操作・統制の土台
- 2 Agent Workflows — 共同作業と検索・ツールの作業面
- 3 Safety & Security Governance — 層別の統治
- 4 Model Economics & Distribution — 配備の条件
- 5 Creative Multimodal Production — 使う場への変化
- 6 Ecosystem & Infrastructure Economics — 結節点と計算
- 7 Week in Review — 変化・意味・次の観測点

This Week in AI

実行が本番に進んだ。 支払い、画面操作、共同の作業部屋、複数手順の検索が実装の選択肢として並び、方針・記憶・権限の統制とともに示された。

統制が構えになった。 利用者の振り分け、frontier の足止め、保存と透かし、攻撃連鎖の報告が別々の層として並び、できることと扱いの条件が裏表で進んだ。

配備が実用を分けた。 価格と期限、クロスリージョン推論や地域の扱い、ゲートウェイの統合と計算の約束が、土台の名と同じ重さで読みの対象になった。

この号の読み方

通常本文の基準時点は 2026-08-21 18:00 America/New_York。本号で参照する公開資料が示す範囲を超えて断定しない。提供元、プロジェクト、論文著者の主張はそれぞれの主体に帰属させ、条件の違う値を横断的な順位へ言い換えない。

読み解く軸： 今週の動きを**実行**、**統制**、**配備**の三つの接続面から読む。

1 エージェントが取引し、操作し、統制される場所

FEATURE: AGENT CONTROL PLANE

エージェントが取引し、操作し、統制される場所

エージェントが代金を支払い、画面を操作し、方針と記憶と権限のもとで長時間動くための土台が、今週は実装の姿で並んだ。

8月18日のAWSの発表によると、Bedrock AgentCoreの決済機能が一般提供となり、エージェントが有料APIやMCP、コンテンツを探して利用し、代金を支払うための実装面が用意された。HTTPの402応答をきっかけとする支払いフローや、CoinbaseとStripe Privyによるステーブルコインの財布、x402とMPPへの対応、利用量に応じた動的な価格指定、セッションごとの予算や有効期限を基盤側で強制する仕組みが説明されている。認証情報の分離や、実行の記録と監査の仕組みもあわせて示されている。ただし対応地域や法定通貨対応の見通し、加盟店網の規模は網羅的な一覧としては示されておらず、「大規模でも安全に取引できる」という表現は提供側の説明として受け止める必要がある。[1]

8月20日のAnthropicの発表では、Claudeの基盤上でコンピューター操作機能とスキル管理、ファイル管理の機能が一般提供となり、新しいブラウザー操作のツールが加わった。コンピューター操作は画面の見た目をもとに押す・入力する・スクロールする動作を続け、ブラウザー操作はページの部品構造を捉える点で区別されている。スキル管理はフォルダー単位の技能を版管理して提供側の実行環境で動かし、ファイル管理は一度上げた資料を番号で参照し、期限や上限、組織あたり1TBまでの枠が示されている。連続動作の速さや使い勝手の向上は提供側の説明であり、測定結果は示されていない。ファイルの保存範囲についても今回の一次資料だけでは断定しない。[2]

統制面では、ツールへの通信をゲートウェイで受け止めて評価し、自然文の文書からCedar方針を起こしてツールの定義と照合し、過不足を点検して記録に残す流れが示されている。8月20日のAWSの記事が扱うのは、この自然文からの方針作成と本番運用の文脈であり、8月6日の公開自体は今週の出来事

ではなく背景として位置づく。記憶の仕組みは会話以外のJSON形式の出来事や記録も最大100KBまで取り込み、意味・好み・要約・挿話の4方式で同じ流れに載せるとされる。利用者の権限情報をエージェント実行に引き継ぎ、本人に許された資料だけが見えるようにする実装例も示され、実行の外側で受け止める考え方が共通する。いずれも定常的な基盤の性質の記述であり、検証の完全性や振る舞い・品質への効果は提供側の説明の範囲を超えて断定しない。見本を超える本番対応は読者側の作業として残る。

[3, 4, 5, 6]

長時間の実行については、待ち時間に計算資源を空費せず、作業の合図で再開する方式や、外部機能との直結、durableな関数連携の考え方が示されている。費用や振る舞いの主張は仕事量により変わる目安であり、測定された節減額はない。一方、8月17日に杭州で示されたAlipayの構想は、店舗のページや商品、接客の流れをエージェント向けの技能やMCPのツールに変え、作成・編成・実行・運用を束ね、AHAと呼ばれる規約で相互運用につなげる内容である。加盟店数や生態系の規模は企業側の発表数字として区別し、決済や本人確認、危険管理、履行の実装細部は発表の範囲を超えて書き込まない。[7, 8]

読解上の境界

この節の読解上の境界: Regional availability, fiat-support roadmap, and merchant-ecosystem size are stated without exhaustive lists in captured bytes. / 'Agents transact safely at scale' is vendor framing; captured bytes support mechanisms, not outcomes. / Performance/latency improvement claims for multi-action turns are vendor-stated without benchmarks in captured bytes. / Files API is documented as not ZDR-eligible in secondary coverage; the captured first-party bodies do not state retention scope, so no retention claim is made here. / Docs describe steady-state platform properties, not a dated W34 release; the W34 delta is the observed enterprise-pattern currency, not a launch. / Merge into the AgentCore control-plane feature set is an editorial option, not a docs-stated fact. / Merchant-adoption figures and ecosystem scale claims are company-reported

without disclosed methodology in captured bytes. / Payments/identity/risk/fulfillment implementation details beyond the announcement level are not in captured bytes. / Cost/behavioral claims are pattern-level and workload-dependent; no measured savings in captured bytes. / How-to/sample scope: production hardening beyond the sample is reader work, not a stated guarantee. / Behavioral/quality effects undescribed beyond the feature statement. / Original Dogwood OSS release (Aug 6) is pre-window background; only the Aug 20 authoring/production-context follow-up is the W34 delta. / Validation-completeness claims are vendor-described without adversarial evaluation in captured bytes. / regional coverage / merchant scale / outcome claims where not exhaustively established / vendor-described safety or scalability is not independently demonstrated / supporting AWS policy/memory records may describe capability architecture rather than a distinct launch event

2 仕事場が一人用から共同用へ広がるとき

FEATURE: AGENT WORKFLOWS

仕事場が一人用から共同用へ広がる

相談部屋、開発環境、検索とツールの往復が同じ作業面に寄り、エージェントの仕事場が一人用から共同用へ広がった。

8月20日のSlackの変更記録によると、既存の会話から専用の作業部屋が生まれ、人とエージェントが同じ場所で作る形が示された。コード差分や部品の見え方、HTMLのプレビュー、キャンバスが部屋に載り、終われば保管されて監査の記録が残る。GitHubの記録によれば、Slack側の連携はエージェントの力をSlackに持ち込み、作業部屋で方針を追い、差分を見てプレビューを確かめながら繰り返す。Teams側の記録では、相談の流れ自体が皆で見て指示できる共同作業となり、引き継ぎには追加の承認を求められるとされる。いずれも記録の取得日付に依存する部分があり、提供範囲の細部は一次資料の範囲を超えて具体化しない。[9, 10, 11]

8月20日のMistralの記事は、検索を一度の問い合わせではなく、探す・開く・たどる・読む・絞るという複数手順の循環として描く。既存の索引の上で5種のツールを使い、見つけた内容を確認して問いを磨き、資料を開いて節をたどり、本文を読んでから答える。FinanceBenchとOfficeQA Proでの評価は既定の構成による提供側の報告であり、独立の再現はない。RunwayのMCP対応は、作業場の手順を会話から一覧・打開・調整・実行できるとする8月20日の記録であり、品質や限界の記述はない。Kimiのコディングツールは8月20日版で裏方作業の完了待ちをその場で扱い、13種の資料接続が加わり、8月18日版で複数技能の同時起動や待機命令、画面の整理、診断、Windowsでの早期停止が示された。ツールの振る舞いや品質への効果は機能の説明を超えて断定しない。[12, 13, 14]

開発の現場側では、JetBrains向けの企業管理によるプラグイン接続の統制や、MCPの許可・拒否の一覧、管理された計測や権限の扱いが記録されている。Googleの8月20日の記事は、条件を満たすGemini Enterpriseの加入でAntigravityが使える、管理者が有効化するとし、8月21日の雲の記事は開発環境の拡張やトークンの共用枠、上限、監査記録、サンドボックスやMCP、ブラウザーの制御を添える。日時の刻みは日付単位であり、加入条件の詳細は画面での確認に譲る。OpenAIの8月19日の記事は、Replitの無償の場がGPT-5.6 Lunaの力と価格性能で開かれるとし、値下げの経緯を理由に挙げる。無償の対象や上限、Luna自体の性能細部は示されず、値下げとの因果は提供側の語りとして区別する。macOSのデスクトップツールでは、iMessageやSMS、RCSを読み探してMessages経由で下書き・送信するコネクターや、既定で切られ選択制の操作履歴が示された。対応機種や仕事向け範囲の細部、プライバシーの扱いは記録の文面を超えて断定しない。8月14日の記録は日付のみであり、今週の変化は8月20日の拡張に置く。[15, 16, 17, 18, 19]

Grokの案内役の利用範囲は、SuperGrok PlusやCursorの上位・団体向けに広がり、従来の試行の層と区別される。8月21日17時29分36秒（協定時）のX上の公式の観測記録がこの拡張を伝えており、現在の案内ページの日付は8月26日に直された後のものである。本文の典拠として8月26日のページを

8 月 21 日の記録として扱わず、時期の根拠は X の観測と 8 月 21 日付の副次記録に置く。無償試用や企業向け順番待ちの細部はページの直し後の内容を含む可能性があり、断定しない。[20]

読解上の境界

この節の読解上の境界: FinanceBench/OfficeQA Pro figures are Mistral-reported with default-stack settings; no independent reproduction in captured bytes. / Availability/pricing/surface scope beyond the announcement post is not in captured bytes. / Enterprise rollout/plan availability specifics beyond 'live today' are not detailed in captured bytes. / Agent-output quality and review-burden claims are vendor framing, not measured in captured bytes. / Apple-silicon-only and Work/Codex-only scope per secondary detail was not separately verified in captured notes bytes; scope claims stay entry-bounded. / No Apple endorsement; local-automation mechanism per secondary reporting, not captured first-party. / Snapshot is dated by capture (Sep 8), not by a page dateline; W34 timing rests on the changelog-entry context plus Discovery observation. / Rollout/plan specifics beyond the entry are not in captured bytes. / Base Aug 14 entry is date-only vs W34 start; the clean W34 delta is the Aug 20 expansion. / Privacy properties beyond the notes text are not independently tested in captured bytes. / The captured page is dated Aug 26 (edited/re-dated after the event) and is never cited as Aug 21 exact-body authority; Aug 21 timing rests on the DailyX X observation plus secondary Aug 21 dating. / Free-trial and Enterprise-waitlist details on the current page may reflect post-Aug-21 edits. / Free Mode eligibility/limits and Luna performance specifics are not detailed in captured bytes. / Price-cut causality is vendor narrative, not audited. / Cloud-blog dating is Aug 21 without time; position vs 22:00Z cutoff is a stated precision limit, though the Aug 20 Antigravity post independently carries the bundle. / Plan-eligibility edge cases beyond Standard/Plus/emerging-market require con-

sole verification. / Snapshot capture-dated (Sep 8); entry-level dating vs W34 relies on changelog context plus Discovery observation. / Agent-workflow quality/limits are undescribed in the changelog entry. / Behavioral/quality effects of the new tools are undescribed beyond feature statements. / maker-reported benchmark figures for Agentic Search / Grok Bot Aug 21 / Aug 26 chronology provenance / GitHub Slack/Teams claim-text capture limitations where applicable / regional processing is NOT part of this package after Selection r2; it belongs to Package 4

3 安全と守りを一語に潰さない

SECURITY GOVERNANCE

安全と守りを一語に潰さない

利用者の振り分け、frontier の足止め、保存と透かし、攻撃連鎖の報告が、別々の統治の層として並んだ。

OpenAI の案内ページによると、18 歳未満と推定される利用者や、13 歳から 17 歳と申告した利用者は自動的に未成年向けの ChatGPT に振り分けられる。発達段階にそぐわない内容への触れ方を抑えつつ学びと創作を保つ配慮や、学びの型、保護者向けの管理、未成年向けの型の文書、安全性の青写真、年齢推定が支えとして挙げられている。推定や配慮の効き目は提供側の説明であり、独立の試験資料はない。ページ自体の発行日は本文から取り出せておらず、時期の根拠は 8 月 18 日の初認記録と内容に置く。[21]

8 月 18 日の Varonis の発表は、個人向け Copilot に関する 3 連鎖の問題を描く。細工されたエンドポイントによる自動実行、接続先応用からの収集と持ち出し、記憶への持続的な汚染である。同発表は 8 月 18 日に提供側が基盤側で直しを配り、対象は個人向けの利用面に限られ、野外での悪用は見られなかったとする。追跡番号 CVE-2026-24301 は研究側と MSRC 側で共通の整理番号として使われる。ただし MSRC 側の勧告本文は取得できておらず（取得時は動的な殻のみ）、深刻度や対象範囲の言い回しは研究側の帰属として扱い、提供側の断定に変換しない。悪用のしやすさの細部も研究側の記録を超えて独自

に確かめたものではない。一方、CISA の必須対応目録は、Ray のコード注入の弱点（CVE-2025-62593、遠隔実行の可能性、登録 8 月 17 日、対応期限 8 月 20 日）を目録の状態として示し、提供側の緩和策と 26-04 号の指示への言及を求める。目録は登録の事実を示すもので、悪用の広がりや直しの完全性は Ray 側の勧告や NVD の記録に譲り、ページの見た目は動的な殻のため機械可読の供給源で確かめる。[22, 23]

8 月 18 日の OpenAI の記事は、Astra と呼ばれる系が重大な cyber 能力の敷居に触れるかもしれないという初期の知見を受け、frontier の強化学習の一部を約 2 週間止め、最大級の予定実行を保留にしたと述べる。8 月 7 日に内部で旗が立ったことや、サンドボックス分離と通信の分離、自動の継続的な弱点探し、30 分を目安とする多段のモニタリング、より深い整合の工夫が対策として挙げられる。重大級の位置づけは「否定できない」という初期の表現であり、評価点や外部の確かめはない。モニタリングの負荷の 2 割という値は提供側の見積もりである。8 月 19 日の記事は、条件を満たす API 利用者向けに処理後の不保持を選べることや、内容に触れずに利用の型と深刻度だけの信号を出すモニタリングのパイロットを描く。後者はプレビュー段階であり、9 月に技術文書が出る予定の文章説明に留まる。不保持の対象境界や従来の通報の例外は方針の要約として扱う。Anthropic の 8 月 14 日の記事は、将来の Claude が生成文に透かしを含み、関与の見込みを推定できるようにし、欧州の法令対応として主要提供者と共に進めるとする。トークン選択の方式で品質への実害はないとされるが、頑健さや検出ツールの主張は提供側の説明であり、ページの日付は時刻なしのため週の区切りとの厳密な前後は断定しない。[24, 25, 26]

8 月 17 日の Brockman による随想は、Hugging Face の一件を転機として読み、技術的負債が欠陥を隠し、守る側が先に見つけて直さねばならないという守備側の経済を論じる。製品の発表や測定結果ではなく、提供側の主張として区別する。発見の端緒は配信の記録であり、本文で候補固有の確認を終えている。[27]

読解上の境界

この節の読解上の境界: Effectiveness of age estimation and safeguards is vendor-described; no independent test data in captured bytes. / Page publication date was not extracted from captured bytes; W34 timing rests on the Aug 18 first-observation record plus page content, not a captured dateline. / MSRC advisory bytes were not captured (retrieved page is a JS shell); vendor severity/product-scope wording is researcher-attributed, not vendor-quoted. / Exploitability details beyond the researcher's account are not independently tested in captured bytes. / KEV listing confirms catalog status only; exploitation scope and vendor-fix completeness require the Ray advisory/NVD record, not captured here. / The HTML catalog page retrieved alongside is a JS application shell without entries in captured bytes; verification rests on the machine-readable feed, not the rendered page. / Exact page publication time vs the Aug 14 22:00Z W34-start boundary is unresolved: the page carries a date only. / Watermark robustness/detection-tool claims are vendor-described; no independent test or detector in captured bytes. / Astra's Critical-tier status is vendor-described as preliminary ('cannot be ruled out' as of the post); no evaluation scores or external verification in captured bytes. / Monitoring-overhead (~20% of monitored inference compute) is an OpenAI estimate, not a measured result in captured bytes. / Private Safety Processing is a preview, not GA; architecture is prose-described with a technical white paper planned September 2026, not proven in captured bytes. / ZDR eligibility boundaries and the pre-existing CSAM-reporting carve-out are policy details summarized from the post, not legal text. / Thesis essay, not a product release or measured result; 'defender advantage' economics is vendor argument, not evidence. / RSS snapshot was the discovery lead; the linked article body now consumed here resolves the candidate-specific review. / age-estimation/safeguard effectiveness is vendor-described / independent exploit research と

vendor confirmation の区別 / pacing/security essays は technical narrative であり independent outcome evidence ではない / dateline/page-time precision limits where recorded

4 モデルより配備の週

MARKET TECHNICAL

モデルより配備の週

新しいモデルの名より、どこで使え、いくらで、どの地域の扱いで動くかが、今週の実用を左右した。

OpenAI のモデルページは、GPT-5.6 Sol の文トークンを 100 万あたり入力 4 ドル・一時保存 0.40 ドル・出力 20 ドルとし、入力 2 割・出力 3 割余りの下げと説明する。販促の価格は少なくとも 2026 年 11 月 21 日まで保たれるとされる。取得した変更記録と価格ページは、この 8 月 21 日の Sol の販促を 7 月 30 日の Terra・Luna の恒久下げと分けており、土台の発表と混同しない。販促後の価格や加入者向け与分の広がりには期限付き・順次展開の表現に留まり、9 月 3 日付の AWS 側の写しは週の典拠ではなく照合用の写しとして扱う。[28]

Qwen3.8-27B のリポジトリページは、2026 年 8 月 14 日に Hugging Face Hub と ModelScope で入手できるとし、リポジトリの所在と標準的なフレームワーク対応を示す。時刻は日付のみで週の区切りとの厳密な前後は断定せず、コーディング性能の比較は取得文の外の報告として一般化しない。Alibaba の Model Studio の一覧は、旗艦とされる kimi-k3 (2.8T 級) を 8 月 19 日の段に載せ、8 月 7 日の段と区別する。日付の刻みのみであり、構造の言い回しは提供側の表現として扱う。DeepSeek の更新ページは、8 月 13 日の V4-Pro の提供開始を背景に、8 月 16 日 16 時 (協定時) のピーク/オフピーク切替とオフピーク割引を今週の変化として載せ、V4-Pro と V4-Flash-Vision-Exp の型番を料金表に置く。新しい料金の数値は副次報告であり一次資料の確かめとして引かず、8 月 13 日の開始自体は背景に置く。Grok 4.6 の Bedrock 提供は 8 月 19 日の AWS の記事と xAI 側の案内が伝え、クロスリージョン推論や 50 万トークンのコンテキスト、4 段階の推論の深さ、同一の 2 ドル・6 ドル料金が示される。土台の Grok 4.6 自体は 8 月 12 日の背

景であり、Bedrock での配備が今週の変化である。Bedrock 固有の速さや振る舞いは取得文にない。[29, 30, 31, 32]

8 月 17 日の AWS の記事は、GPT-5.6 の Sol・Terra・Luna を bedrock-runtime に載せ、応答・会話・対話完了の 3 種の API と、地理・広域のクロスリージョン推論を添える。8 月 20 日の技術記事は 25 超の地域や地理・広域の型、一時保存、記録と課金の一本化を詳しくする。クロスリージョン推論による速さや費用の利点は構造の主張であり、仕事量での測定はない。地域ごとの可否は画面での確認に譲る。8 月 21 日の変更記録は、API の利用者が要求ごとに地域処理を選べ、広域の地理の鍵で接頭辞付きの領域を指定すると述べ、これを本節に置く。対象地域や条件の詳細は記録の文面を超えて詳述しない。[33, 34]

読解上の境界

この節の読解上の境界: Post-promo pricing and subscription-credit rollout scope are stated as time-bounded/rolling-out; not confirmed beyond the page text. / The AWS reduced-pricing mirror is dated Sep 3 (post-cutoff) and was captured only as a mirror, not as W34 authority. / Exact Aug 14 release time (vs 22:00Z boundary) is unresolved; repo news line is date-only. / Benchmark comparisons to frontier coding models are vendor/community-reported elsewhere, not in captured bytes. / Exact new tariff figures (\$0.66/\$1.98 off-peak etc.) are secondary-reported and not extracted from captured first-party bytes; do not cite as first-party-verified numbers. / Aug 13 GA is pre-window background; only the in-window pricing/access change is the W34 delta. / Throughput/cost advantages of cross-region routing are architectural claims without workload measurements in captured bytes. / Region-by-region availability must be checked in-console; not exhaustively listed in captured bytes. / Table gives date-level precision only; no clock times. / Parameter/architecture descriptors are Alibaba-stated. / Underlying Grok 4.6 model launched pre-window (Aug 12); only Bedrock distribution is the W34 delta. / Bedrock-specific benchmark/latency behavior is

unpublished in captured bytes. / Geography/eligibility boundaries beyond the entry text are not detailed in captured bytes. / exact Qwen release timing where unresolved / DeepSeek tariff figures relying partly on secondary reporting / provider availability is not equivalent to new model release / promotional pricing has a bounded validity period

5 作る機能から使う場へ

MULTIMODAL

作る機能から使う場へ

音・像・映像の動きはモデル名の列ではなく、使える場と移行の記録として読む。

8月20日のAdobeの記事は、Fireflyにおける音楽生成、音声生成、効果音生成の広範な提供を中心に置く。音楽は商用利用に安全なライセンス楽曲、音声はAdobeとElevenLabsの2系統、効果音は動きや間、勢いに合わせる内容として描かれる。「商用に安全」という言い回しは提供側の表現であり、利用条件や選択肢の同等性は実際の約款に譲る。品質や網羅の主張も提供側の説明であり、独自の検証はない。[35]

Googleの廃止ページは、Imagen 4の3つの一般提供のエンドポイントが2026年8月17日に止まり、gemini-3.1-flash-imageに置き換わるとする。Firebase側の移行案内は、全てのImagenモデルが開発者向けAPIとアプリケーション基盤を横断して同日に止まり、ツールの形態に破壊的な変わり目があると述べる。Vertex AI側のページには6月30日という別の日付が載るため、確かめの対象はGemini側の8月17日に置き、Vertex側の範囲は未確定として残す。当日の時刻の刻みは取得文にない。[36]

Pikaの8月14日のページは、映像から音を起こすSoundtrack、文から効果を起こすSFX、読み上げのSpeech、楽曲全体のMusicという4モデルのファミリーを示し、秒・分あたりの料金をAPI Club経由で載せる。競合比の倍率の主張は単位の揃わない提供側の報告であり、独自の確かめはない。8月18日のモデル別の記事はファミリー発表の詳細であり、4件の追加発表として数えない。AlibabaのModel Studioの

一覧は、高速な映像生成とされるwan3.0-video-primeを8月20日の段に載せ、8月6日の段と区別する。日付の刻みのみであり、能力の言い回しは提供側の表現である。後のRunway側の統合とは混同しない。DeepSeekの8月21日の変更記録は、実験的な映像理解モデルDeepSeek-V4-Flash-Vision-ExpをAPI上で出し、テキスト単体の性能は公式のV4-Flash並みで、モデル名の指定で使えるとする。同等性や数値の主張は提供側の説明であり、手法や外部の評価は取得文にない。[37, 38, 39]

読解上の境界

この節の読解上の境界: 'Commercially safe' is Adobe framing; license terms and ElevenLabs-option parity require the actual terms, not captured here. / Quality/coverage claims are vendor-stated without independent testing in captured bytes. / Date-level precision only. / Capability descriptors are Alibaba-stated. / Cost-multiple claims (9x/20x/10x/2x vs named rivals) are Pika-reported on non-normalized units; not independently verified. / Aug 18 per-model posts elaborate the Aug 14 family launch; they are not four additional launches. / Vertex AI surfaces carry a different documented date (June 30) for the same IDs; the Gemini-API Aug 17 date is the verified claim, Vertex scope unresolved. / Exact UTC cut-off moment on Aug 17 is unspecified in captured bytes. / Capability-parity and any benchmark figures are vendor-stated; methodology and independent evaluation are absent from captured bytes. / commercial-safety claims remain vendor framing / capability quality is not inferred from availability alone / migration/deprecation event and new-model launch are distinct identities

6 結節点と電力を押さえる動き

ECOSYSTEM

結節点と電力を押さえる動き

ゲートウェイの統合と8GW級の計算約束が、モデルの外側の構造変化を示した。

8月19日のStripeの報道室の記事は、モデルのゲー

トウェイとルーティング基盤である OpenRouter の取得合意を伝える。OpenRouter 側の関連記事は、同じ使命・名称・製品・道筋で運営を続け、1 日 10 兆トークン超と 400 超のモデルを挙げる。いずれも企業側の報告であり、手法の開示はない。取引の金額や条件は両方の一次資料のページに出ておらず、広く報じられる 70~80 億ドル台の数字は報道の数字として事実に取り込まない。[40]

8 月 17 日の OpenAI の記事は、オハイオ州パイク郡の PORTS-Pike の場で約 8GW-IT 規模の合意を SB Energy や NVIDIA、エネルギー省と結び、出来上がった容量が使えるようになる分だけ支払うとする。NVIDIA 側の関連発表は、計算利用の専用確保枠や、4.25GW 分の信用補完と 3.75GW 分の選択権、SB Energy 側の 15 億ドルの出資を述べる。初回の 800MW の 2028 年や利用者負担の保護、1050 億ドル台の資金の言い回しは予定や報道の範囲であり、完成の事実ではない。この約束から学習計算の性能やモデル発表への含意は導かない。二つの出来事はゲートウェイと計算の上下流として並べるが、直接の因果は作らない。[41]

読解上の境界

この節の読解上の境界: Transaction price/terms are not stated on either first-party page; widely reported \$7-8B figures are press-reported and were not consumed as facts. / Gateway scale figures (tokens/day, model counts) are company-reported without disclosed methodology in captured bytes. / Capacity timelines (first 800MW 2028), ratepayer protections, and \$105B financing figures beyond the \$1.5B investment are stated plans/coverage, not completed facts. / No training-compute performance or model-release implications follow from this infrastructure commitment. / company-reported scale figures / economic implications are analysis, not directly proven outcomes / contract/agreement capacity is not identical to deployed capacity

今週何が変わり、何が残ったか

支払いと操作、共同作業と検索が本番に進み、統制と配備が実行の構えを決めた週として総括する。

今週の中心は、エージェントが支払いや画面操作、共同の作業部屋、複数手順の検索まで、本番の場に進んだことである。代金の受け渡しやツールの使い分け、部屋での協働と監査、探して確かめて読む循環が、試用段階を超えて実装の選択肢として並んだ。

[1, 9, 12]

同時に、方針の作成と評価、権限の引き継ぎ、記憶の取り込み、利用者の振り分け、攻撃連鎖への備えが、付随の機能ではなく実行の構えの一部として現れた。できることの広がり、誰のものをどの条件で扱うかという統制が、同じ週に裏表として進んだ。研究側の報告は提供側の断定に置き換えず、効き目の確かめのない部分は確かめのないまま残す読み方が要る。[3, 21, 22]

実用を分けた第三の軸は配備である。販促の価格と期限、クロスリージョン推論や地域の扱い、ゲートウェイの統合と計算の約束が、土台の名と同じ重さで読みの対象になった。どこで使え、いくらで、どの扱いで動くかという条件が、今週は性能の話と切り離せない。[28, 33, 40]

次に見る点は、取引の統治、画面とブラウザーの操作の境界、共同作業の監査可能性、地域ごとの配備の経済、出来事への応答の備えである。今週取り上げなかった多くの背景研究を不存在とせず、手元の境界——期限付きの価格、レビュー段階のモニタリング、提供側の表現に留まる品質や規模の主張——を起点に、次の観測を待つ。[41, 25, 35]

この総括の読み方

この総括は既出の六節の横断であり、新しい事実の典拠を起こさない。今週取り上げなかった多くの背景研究を不存在としない。

7 Week in Review

WEEKLY SYNTHESIS

Sources & limitations

本号では、公式発表・documentation・model card・プロジェクトの release、更新記録、Model Studio の一覧を、それぞれの性質に合わせて読み分ける。公開情報が示す範囲と、まだ確かめられていない範囲を分けるためである。

公式・プロジェクト資料

提供条件、利用経路、機能、変更点を示す。提供元やプロジェクト自身が報告する速度・性能・規模の値は、独立測定の結果とは区別して読む。

更新記録・Model Studio の一覧

日付の刻みや対象範囲は記録の文面の範囲で扱い、日付のみの記録から時刻の前後を断定しない。

研究側の報告

独立の研究者による問題の報告は、提供側の断定に置き換えない。勧告本文が取得できていない部分は取得できていないまま残す。

まだ確かめる必要がある点

販促後の価格、プレビュー段階のモニタリング、対象境界、規模や品質の主張などは、公開情報が増えるまで断定しない。

本文では、各資料の主体、日付、提供経路をできるだけ明示した。異なる主体が報告した数値や、条件の違う値を同じ尺度の順位へ変換していない。

Temporal and claim boundary

本文の基準時点は 2026-08-21 18:00 America/New_York。公式資料、プロジェクトの release、研究者の報告は、それぞれ異なる範囲の主張を支える。提供元の値、研究者の記録、Model Studio の一覧は相互に代替できず、未解決の点は未解決のまま記載する。

References

- [1]AWS. *Amazon Bedrock AgentCore Payments*. URL: <https://aws.amazon.com/about-aws/whats-new/2026/08/bedrock-agentcore-payments-ga/> (visited on 08/21/2026).
- [2]Anthropic. *Claude Platform Computer Use / Skills / Files GA*. URL: <https://claude.com/blog/computer-use-skills-api-files-api> (visited on 08/21/2026).
- [3]AWS. *AgentCore governed tool-access patterns*. URL: <https://docs.aws.amazon.com/bedrock-agentcore/latest/devguide/policy.html> (visited on 08/21/2026).
- [4]AWS. *Dogwood natural-language policy authoring*. URL: <https://aws.amazon.com/blogs/machine-learning/authoring-dogwood-policies-from-natural-language-in-amazon-bedrock-agentcore/> (visited on 08/21/2026).
- [5]AWS. *AgentCore Memory JSON payloads*. URL: <https://aws.amazon.com/about-aws/whats-new/2026/08/agentcore-memory-json-payloads/> (visited on 08/21/2026).
- [6]AWS. *AgentCore user authorization context propagation*. URL: <https://aws.amazon.com/blogs/security/propagate-user-authorization-context-in-ai-agents-with-amazon-bedrock-agentcore> (visited on 08/21/2026).

- [7]AWS. *AgentCore async serverless patterns*. URL: <https://aws.amazon.com/blogs/machine-learning/asynchronous-patterns-for-calling-amazon-bedrock-agentcore-agents-in-serverless-pipelines/> (visited on 08/21/2026).
- [8]Ant Group / Alipay. *Alipay agentic commerce platform*. URL: <https://www.antgroup.com/en/news-media/press-releases/1786946400000> (visited on 08/21/2026).
- [9]Slack / Salesforce. *Slack Code channels*. URL: <https://docs.slack.dev/changelog/2026-08-20/slack-code> (visited on 08/21/2026).
- [10]GitHub. *GitHub Copilot in Slack*. URL: <https://docs.github.com/copilot/slack> (visited on 08/21/2026).
- [11]GitHub. *GitHub Copilot in Teams*. URL: <https://docs.github.com/copilot/teams> (visited on 08/21/2026).
- [12]Mistral AI. *Mistral Agentic Search*. URL: <https://mistral.ai/news/agentic-search/> (visited on 08/21/2026).
- [13]Runway. *Runway MCP Workflow Support*. URL: <https://runway.com/changelog> (visited on 08/21/2026).
- [14]Moonshot AI. *Kimi Code CLI v0.38.0/v0.37.0*. URL: <https://www.kimi.com/code/docs/en/kimi-code/whats-new.html> (visited on 08/21/2026).
- [15]GitHub. *GitHub Copilot for JetBrains enterprise settings*. URL: <https://docs.github.com/copilot/jetbrains> (visited on 08/21/2026).
- [16]Google. *Antigravity in Gemini Enterprise*. URL: <https://cloud.google.com/blog/products/ai-machine-learning/expanding-google-antigravity-for-enterprise-customers> (visited on 08/21/2026).
- [17]Replit / OpenAI. *Replit Free Mode on GPT-5.6 Luna*. URL: <https://openai.com/index/replit> (visited on 08/21/2026).
- [18]OpenAI. *ChatGPT Apple Messages plugin*. URL: <https://help.openai.com/en/articles/6825453-chatgpt-release-notes> (visited on 08/21/2026).
- [19]OpenAI. *ChatGPT Computer History*. URL: <https://help.openai.com/en/articles/6825453-chatgpt-release-notes> (visited on 08/21/2026).
- [20]xAI. *Grok Bot access expansion*. URL: <https://x.ai/news/grok-bot-more-plans> (visited on 08/21/2026).
- [21]OpenAI. *ChatGPT for Teens*. URL: <https://openai.com/index/chatgpt-for-teens> (visited on 08/21/2026).
- [22]Varonis / Microsoft. *CoSnitch CVE-2026-24301*. URL: <https://www.varonis.com/blog/cosnitch> (visited on 08/21/2026).
- [23]CISA. *Ray CVE-2025-62593 CISA KEV listing*. URL: https://www.cisa.gov/sites/default/files/feeds/known_exploited_vulnerabilities.json (visited on 08/21/2026).
- [24]OpenAI. *OpenAI frontier development pacing (Astra cyber)*. URL: <https://openai.com/index/pacing-model-development-cyber-capabilities/> (visited on 08/21/2026).
- [25]OpenAI. *OpenAI Zero Data Retention + Private Safety Processing*. URL: <https://openai.com/index/offering-zero-data-retention-for-frontier-models/> (visited on 08/21/2026).
- [26]Anthropic. *Claude text watermarking*. URL: <https://www.anthropic.com/news/claude-text-watermark> (visited on 08/21/2026).
- [27]OpenAI. *The Defender's Window*. URL: <https://openai.com/index/the-defenders-window> (visited on 08/21/2026).
- [28]OpenAI. *GPT-5.6 Sol promotional pricing*. URL: <https://developers.openai.com/api/docs/models/gpt-5.6-sol> (visited on 08/21/2026).
- [29]Alibaba Qwen. *Qwen3.8-27B*. URL: <https://github.com/QwenLM/Qwen3.8> (visited on 08/21/2026).
- [30]Alibaba Cloud. *Alibaba Model Studio kimi-k3 availability*. URL: <https://www.alibabacloud.com/help/en/model-studio/newly-released-models> (visited on 08/21/2026).

- [31]DeepSeek. *DeepSeek V4-Pro pricing/access change*. URL: https://api-docs.deepseek.com/quick_start/pricing (visited on 08/21/2026).
- [32]AWS / xAI. *Grok 4.6 on Amazon Bedrock*. URL: <https://aws.amazon.com/about-aws/whats-new/2026/08/amazon-bedrock-grok-4-6/> (visited on 08/21/2026).
- [33]AWS. *Bedrock GPT-5.6 cross-Region inference*. URL: <https://aws.amazon.com/about-aws/whats-new/2026/08/amazon-bedrock-cross-region-openai-v2/> (visited on 08/21/2026).
- [34]OpenAI. *OpenAI API regional processing*. URL: <https://developers.openai.com/api/docs/changelog> (visited on 08/21/2026).
- [35]Adobe. *Adobe Firefly audio tools*. URL: <https://blog.adobe.com/en/publish/2026/08/20/adobe-firefly-expands-its-creative-ai-studio-generate-music-speech-and-sound-effects-in-one-place> (visited on 08/21/2026).
- [36]Google. *Imagen API shutdown / Gemini Image migration*. URL: <https://ai.google.dev/gemini-api/docs/deprecations> (visited on 08/21/2026).
- [37]Pika. *Pika Audio model family*. URL: <https://experiment.pika.art/blog/pika-audio-models> (visited on 08/21/2026).
- [38]Alibaba Cloud. *Alibaba Model Studio wan3.0-video-prime availability*. URL: <https://www.alibabacloud.com/help/en/model-studio/newly-released-models> (visited on 08/21/2026).
- [39]DeepSeek. *DeepSeek-V4-Flash-Vision-Exp*. URL: <https://api-docs.deepseek.com/updates/> (visited on 08/21/2026).
- [40]Stripe / OpenRouter. *OpenRouter joining Stripe*. URL: <https://stripe.com/newsroom/news/stripe-agrees-to-acquire-openrouter> (visited on 08/21/2026).
- [41]OpenAI. *OpenAI PORTS-Pike infrastructure agreement*. URL: <https://openai.com/index/openai-joins-ports-pike-project/> (visited on 08/21/2026).