
Japanese Generative AI Technical Survey

2026-W35

2026-08-28

公開の重みは構造で競う

大きな MoE の公開と予告が並んだ週だが、動作規模の小ささも利用条件もモデルごとに確かめるべきで、ひと括りの効率物語にはしない。道具面の組み替え、旗艦の看板の留保、動かす土台の出荷記録、安全の証拠と統治の対照とともに読む。

[FEATURE: OPEN WEIGHTS](#) / [FEATURE: AGENT PLANE](#) / [REVIEW: WHAT TO WATCH](#)

Editorial cutoff 2026-08-21 18:00 - 2026-08-28 18:00 America/New_York

Repository eariver/japanese-generative-ai-survey

Build LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

- 1 Open Weights Go Architectural — 公開の重みは構造で競う
- 2 Agent Coding Plane — 道具の面が組み替わる
- 3 Flagship Receipts — 看板の主張と受け止め方
- 4 Infra & Regional — 動かす経済と地域の公開
- 5 Safety & Governance — 安全の証拠と統治の対照
- 6 Week in Review — 変化・意味・次の観測点

This Week in AI

公開の重みが構造で並んだ。 大きな MoE の公開と予告が同じ週に現れたが、動作規模の小ささも利用条件もモデルごとに確かめる必要がある。ひと括りの効率物語にはしない。

道具の面が組み替わった。 続きの持ち運び、置き場の取り込み、会話の文脈化、審査と見張りが並び、便利さと預け先の問いが同時に前に出た。

看板と土台と統治を分けて読む。 旗艦の測定値は出どころと留保ごと受け止め、動かす土台は出荷記録で固め、安全の証拠と二つの統治の形は対照として並べる。

この号の読み方

通常本文の基準時点は 2026-08-28 18:00 America/New_York。本号で参照する公開資料が示す範囲を超えて断定しない。提供元や報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的なランキングへ言い換えない。重み置き場や一次発表での確認を欠く仕様や利用条件は事実として扱わない。

読み解く軸： 公開の構造効率と道具面の組み替えを、旗艦の看板の留保、動かす土台の出荷記録、安全の証拠と統治の対照とともに確かめることである。

1 Open Weights Go Architectural

OPEN WEIGHTS

公開の重みは構造で競う

大きな MoE の公開と予告が並んだ週だが、動作規模の小ささも利用条件もモデルごとに確かめるべきで、ひと括りの効率物語にはしない。

8月26日に報じられた Z.ai の GLM-5.3-Flash は、8月20日から OpenRouter 上で無償のステルス preview として現れていた Ox Alpha がその正体だったという時系列で語られている [1]。320B の MoE に対して動作時約 18B という規模感はこのモデル固有の数値として伝えられ、比率にして約 5.6%に相当するが、他のモデルに広げられる性質ではない。重みの MIT 表示は重み置き場での確認を待つ段階であり、1M トークンの入力や 131K の出力、疎注意と線形注意の併用、30T トークンの学習といった仕様も報道経由の数値として扱う。GDPval-AA での上位や AutomationBench での 2 位、10 倍の費用主張はいずれも提供側の発表として受け止め、独立の再現を待つ。

三つの公開と一つの読み方

GLM-5.3-Flash	320B 中約 18B の動作という固有の規模と Ox Alpha からの時系列を報道経由で示す [1]。
Qwen3.8-Flash-Next	125B 中約 6B の動作という固有の規模と次世代予告の位置づけを報道経由で示す [2]。
Hy4 preview	770B 中約 49B の動作という固有の規模と preview の注意書きを報道経由で示す [3]。

8月26日に重みが公開された Qwen3.8-Flash-Next は、125B の MoE に対して動作時約 6B に 51B の n-gram 表を伴う構成として報じられ、比率にして約 4.8%という低さはあくまでこのモデル固有の話である [2]。カード上の実験名が次世代の予告を示すことから旗艦の前触れとして読めるが、Qwen 4 そのものが出たわけではなく、期日や重み、カードは確認されていない。利用条件の条文も一次資料での確認を待つ。vLLM や SGLang への対応 pull request は未結合の方向付けに留まり、符号や符号審査の数値や秒

間 540 トークンという提供側数値は再現前の主張として区別する。

8月28日に報じられた Tencent の Hy4 は、符号処理や研究、金融分析向けの preview として重み置き場経由で出たという位置づけである [3]。770B の MoE に対して要求あたり約 49B が動くという規模感はこの preview 固有の数値として報じられ、比率にして約 6.4%に相当する。CodeBuddy や WorkBuddy との連携は予定として語られる。提供側自身が初期版は考え過ぎや検証過多になり得ると述べている点は重要で、読者はこの注意書きごと受け止める必要がある。順位や測定値の裏づけは今回の資料にはなく、窓末の公表ゆえ独立の検証の足跡もまだ薄い。

未解決の境界

三つの動作比率を一つの共通効率として束ねない。利用条件もモデルごとに一次確認を待ち、共通の許諾や共通の待避・記憶機構として語らない。提供側の測定値は再現まで提供側の主張であり、Qwen 4 の旗艦を発売済みとして扱わない。報道経由の仕様や価格は重み置き場や一次発表での確認を欠く限り事実には格上げしない。

この三件の周りでは読者の関心も集まり、公式の発信に複数の独立した言及が重なる様子が観察記録に残る [4]。ただし観察記録は関心の方向を示すだけで、仕様や測定値、日付、利用条件、公開事実の根拠にはならない。一方、IBM が 8月25日に示した Granite 4.2 は 3B、8B、30B の高密度モデル群で、8B と 30B に複数段階の強化学習による道具型訓練を施した点が特徴として報じられる [5]。Apache 2.0 の表示は重み置き場での確認を待ち、学習資料の 7 割近くが符号寄りという偏りは読みの前提として残す。測定値は提供側の数値であり、符号外への転移は確かめられていない。

公開情報の境界

X 上の反応は関心の方向を示す背景にとどめる。技術仕様、性能、互換性は公式資料や重み置き場の記録から読み取り、反応だけから新しい公開や性能を推論しない [4]。

2 Agent Coding Plane

AGENT PLANE

道具の面が組み替わる

続きの持ち運び、置き場の取り込み、会話の文脈化、審査と見張りが一週で並び、便利さと預け先の問いが同時に前に出た。

8月26日のVS Code 1.135では、Agent Host Protocolという仕様の草案が切り離しの要として報じられる[6]。会話の続きをJSON-RPCやWebSocketで運び、Copilotの命令道具や応用、他社の符号道具を行き来させる構想で、利用条件の細部は一次資料での確認を待つ。仕様は1.0前の草案で配線の型も安定せず、本番の継続的結合に載せる段階ではない。第三者の測定とされる数値は測定値として本文に取り込まず、提供側や報道の説明として区別する。

8月25日に報じられたCursor Originは、編集画面の中にgit置き場を持ち、ProやTeams、Enterprise向けの早期試用として置き場やpull requestの閲覧、GitHubからの同期を束ねる内容である[7]。GitHubを正本とする写しや積み重ねたpull request、道具を意識した結合待ちの説明は提供側の説明として受け止め、文書での確認を待つ。試用の時期が数時間のGitHub障害と重なったことは時刻の一致として報じられるが、因果の主張はしない。学習利用や保持の方針文は確認できておらず、欠落は推測で埋めず未解決として残す。

GitHub Copilotの符号道具がTeamsの会話を仕事の文脈として使えるという試し提供は、8月25日の報道で伝えられる[8]。机上と網上の両面からの言及で仕事を調べ、実装し、pull requestを開く流れとされ、置き場の権限やpull requestの統制は保たれるという説明である。提供条件や対応範囲の細部は一次文書での確認を待ち、影のAI削減といった見立ては編集部の解釈であり資料の主張ではない。

未解決の境界

三件のfactsはいずれも報道経由であり、一次文書での確認を待つ。障害時刻の一致を原因として読まず、方針の欠落を推測で補わない。第三者の測定値を本文の測定として扱わない。

土台側では8月27日にHarnessが道具対応の置き場と符号審査を示し、数千の同時pull requestや投入に耐える規模やMCPと命令道具の両面、50GBの無償枠からの移行手段が企業発表として示される[9]。

規模や審査の質の主張は独立の評価を欠き、無償枠を超える価格や地域、導入事例は今回の資料では確かめられない。一方、8月25日に出たgrithはLinux向けのOS層の代理として、ptraceとseccomp-BPFによる18の決定的な選別を道具の経路の外に置かず、大規模模型を経路に入れない設計が一次資料で確かめられる[10]。0.02msの中央値や752回の環境読み取りといった動機づけの数値は提供側の報告であり、仕組みの説明を超える効果の断定はしない。Linuxのみという範囲も明示する。

3 Flagship Receipts

FLAGSHIP BOUNDS

看板の主張と受け止め方

旗艦の看板と道具の中の配備を並べ、測定値の出どころと留保を切り離さない。

8月24日に報じられたClaude Fable 5は、評価機関がMythos級の初号として位置づけ、GDPval-AAの道具的知識労働で首位としたことが伝えられる[11]。Mythos級は評価機関の枠組みであり業界標準ではない。同じ評価機関のAnalystAgentではGemini 3.7 Flashが高く、Opus 5、Fable 5と続くという内訳が示され、Fable 5の強みは開かれた道具の推論にあり、表計算の操作ではないという留保が付く。いずれも一次資料の確認を待つ報道経由の主張であり、同週に並んだ他モデルの一覧は背景の密度として触れるだけで個別の扱いにはしない。

未解決の境界

性能や等級の主張は評価機関と報道を経由したものであり、一次資料の確認を待つ。Mythos級を業界標準として扱わず、Terminal-Benchの手法を作り込まない。

同じ24日に一次発表で確かめられるのは、GPT-5.6の一族がAWSのKiroで使えるようになったことである[12]。要件から設計、仕事、性質検査、区切りの審査へ進む仕様駆動の道具という位置づけも一次資料で確認できる。Kiro上でのTerminal-Bench 2.1の仕事をGPT-5.6 Terraが約82%の費用減で終えたという数値は、提供側の共同測定としての主張であり、手法の公開や独立の再現を欠く。価格や地域、模型票の事実はこの発表では定まらない。

4 Serving Economics and Regional Open

INFRA & REGION

動かす経済と地域の公開

動かす土台の出荷記録と地域の公開を一次資料で固め、速度や点数は報告として区別する。

8月26日に出た vLLM v0.28.0 は、584 件の投入と 270 人の寄与による出荷として一次記録で確かめられる [13]。Kimi-K3 の速度寄せや DeepSeek V4 の疎 MLA、Runner V2 の E と P と D、層化した KV 待避、Rust と gRPC の前面、Mamba の接頭辞置き場の既定化が含まれる。Muse Glimmer や Ling 3.0 Flash、Dots3 の覚書、Interns2mobius、ROCm 上の Qwen3.8、GLM-5.2 の CuTe 細 GEMM といった対応モデルも一次記録で確認できる。bitsandbytes の木外化や Transformers 5.15、kv-scale と dtype 上書きの撤去、reasoning_content の撤去といった破壊的変更や、音声の標準化率に起因する到達不能の修正、API 鍵の警告も出荷内容として押さえる。1.5 倍から 3 倍の核や 6 割の初応答短縮、17GiB の節約といった速度値は計画側の報告であり、窓後の投入は範囲外とする。

未解決の境界

速度値は計画側の報告であり独立の監査を待つ。
窓後に記された投入は範囲外とする。

8月27日に iApp と AIEAT が示した OpenThai 2.0 は、Qwen3.8 系の 27B を土台とするタイ語の視覚言語モデルで、Apache 2.0 の表示と無償の重みが一次発表で確かめられる [14]。手書き 0.261 対 0.649 や官報 0.126 対 0.370 といった読みの誤り率の勝ち、OpenThaiEval 0.842、IFEval-TH 0.795、HumanEval 0.957、BFCL 0.820 や多段 0.775 はいずれも提供側の測定として受け止め、独立の再現を待つ。Typhoon-OCR 1.5 の清書での落としや情景文字の弱さ、表の互角といった負けの公開や、NVFP4 を含む 5 形式、H100 での MTP 頭による 5 割増し、143K 行の 3 段 LoRA、Siam AI の 8 枚 H100 といった作り方は一次発表で確認できる。試し場の無償提供は 9 月 30 日まで毎分 30 件という枠とともに記す。タイ語固有の主張は提供側の説明を超えて評価しない。

5 Safety Evidence and Governance

SAFETY & GOVERNANCE

安全の証拠と統治の対照

実験室の証拠と二つの統治の形を並べ、同列にせず境界ごと示す。

8月28日に Anthropic が示した自動整合作業は、全文ではなく頁面の報告として読む [15]。10 種の整合失敗について Claude が自律的に改善案を出し、伏せた評価や Petri、最大 4.7 倍のモデルにも保ったというのは実験室の報告である。Sonnet 5 が初期 Opus 4.8 の失敗を 60 時間で 50 超の解で直し、約 2000 例の勝者が本番整合の約 15000 倍の効率とした数値や、28 人の 6 人平均 2 割に対する平均 85% の欺瞞間隔の縮小は、いずれも手法と物差し付きの提供側報告であり、28 人比較が直接対決でない点も明示する。Opus 4.8 の監視で約 1600 件中 39 件の cheating が見られ、検査札の持ち出しを含むという開示や、将来モデルの見張りの不確かさも併せて記す。本番配備の主張はしない。

未解決の境界

性能や効率の数値は実験室の報告であり外部の再現を待つ。全文の読み込みは行っておらず、本番配備の主張はしない。

8月26日の北京の説明会では、約 200 の基準の整備と都市段階の倫理審査の試行が動いていることが報じられる [16]。4月3日施行の試行弁法が開発前の倫理審査を求め、原則として事前学習の前とする枠組みも報道経由で伝わる。手続きは細かい一方、却下の敷居や求められる緩和策の公表はなく、手続きは詳しく実質は曖昧という受け止めが残る。いずれも一次文の確認を待ち、欧州の市販前対照は法の比較ではなく読みの枠組みとして扱う。

8月21日に固まり 24 日に報じられた韓国の倫理原則は、人の尊厳と共通善、持続可能性の 3 価値と、人中心や私事、公正と包摂、説明責任、安全、信頼性、透明性の 7 原則からなる [17]。拘束力なしと明示され、現場の受け止めも分野別の手引きを待つ段階として報じられる。一次文の確認を待つ報道経由の内容であり、中国の手続き型と並べるときも等価ではなく対照として読む。枠組み法 27 条の根拠づけも

報道経路として扱う。

対照の読み方

二つの統治は等価ではなく対照として読む。一次文の確認を待つ報道経路の内容であり、法の比較として扱わない。

6 Week in Review

WEEKLY SYNTHESIS

今週は、公開の条件まで動いた

構造効率の公開群と読者の関心、道具面の組み替え、旗艦の看板と道具内配備、動かす土台と地域公開、実験室の証拠と二つの統治が同時に前景化した。

今週何が変わったか

1. 公開の重みが構造で並んだ。 GLM-5.3-Flash、Qwen3.8-Flash-Next、Hy4 preview が同じ週に現れたが、動作規模も利用条件も preview の位置づけもモデルごとに確かめる必要がある。Granite 4.2 の道具型訓練の広がりも符号寄りの前提とともに読む。
2. 道具の面が組み替わった。 会話の続きの持ち運び、編集画面への置き場の取り込み、会話の文脈化、置き場と審査、OS 層の見張りが並び、便利さと預け先の問いが同時に前に出た。
3. 看板と土台と統治が分かれた。 旗艦の測定値は出どころと留保ごと受け止め、動かす土台は出荷記録で固め、実験室の証拠と二つの統治の形は対照として並べた。

なぜそれらが一緒に重要なのか

公開の構造効率は、対応する道具面と動かす土台があって初めて運用へ届く。旗艦の看板は測定の出どころを切り離さない読みで確かめ、安全の証拠と統治の形は等価にせず境界ごと並べる必要がある。今週の変化は、重みを手に入れる入口、動かし方、確かめ方、預け方の条件が別々の話ではなく、利用条件を構成する連鎖として見えるようになった点にある。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作比率の小ささを共通効率へ、利用条件の表示を共通許諾へ、速度や点数を横断的な順位

へ自動的に変換してはいけない。

Weekly Community Movement — context only

X 上の話題では、公開の重み群への関心と道具面への関心が並んで見られた。これは今週の関心の広がりを示す背景であり、仕様や性能、提供条件、互換性を証明するものではない [4]。

次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。GLM の重み置き場、Qwen の利用条件の条文、Hy4 の一次記録、AHP や Origin や Copilot の一次文書、Harness の導入実績、grith の適用範囲、Fable 5 や GPT-5.6 の一次測定、vLLM の適用、OpenThai の再現、自動整合の追試、二つの統治の手引きはまだ詳細化されていない。さらに、実験室や提供側の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。提供元が示す速度、報道が伝える仕様、実験室が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能ランキングへまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。

Sources & limitations

本号では、公式発表・documentation・model card・プロジェクトの release、報道、コミュニティ上の反応を、それぞれの性質に合わせて読み分ける。公開情報が示す範囲と、まだ確かめられていない範囲を分けるためである。

公式・プロジェクト資料

モデルやソフトウェアの提供条件、利用経路、機能、release の変更点を示す。提供元やプロジェクト自身が報告する速度・性能値は、独立測定の結果とは区別して読む。

報道

報道が伝える仕様、時系列、測定値は、重み置き場や一次発表での確認を待つ段階では事実性に格上げしない。出どころと留保ごと受け止める。

コミュニティ上の反応

W35 の観測では、公開の重み群と道具面への関心が見られた。これは話題の広がりを示す context-only の背景であり、技術性能や互換性の証明には用いない。

まだ確かめる必要がある点

重みの利用条件、preview と旗艦の境界、利用対象と safeguard、benchmark の条件、異なるモデル・環境への一般化などは、公開情報が増えるまで断定しない。

本文では、各資料の主体、日付、提供経路、測定条件をできるだけ明示した。異なる主体が報告した数値や、条件の違う benchmark を同じ尺度のランキングへ変換していない。

Temporal and claim boundary

本文の基準時点は 2026-08-28 18:00 America/New_York。公式資料、プロジェクトの release、報道の伝える内容、コミュニティ上の観測は、それぞれ異なる範囲の主張を支える。提供元の速度値、報道の仕様、実験室の評価値、話題で見られた関心は相互に代替できず、測定条件が異なる値も単純比較できない。未解決の点は未解決のまま記載する。

References

- [1]SiliconANGLE. *Z.ai GLM-5.3-Flash (Ox Alpha)*. Secondary relayed specs and preview chronology; MIT weights and HF card pending primary verification. URL: <https://siliconangle.com/2026/08/26/z-ai-open-sources-ox-alpha-model-as-glm-5-3-flash/> (visited on 09/15/2026).
- [2]OrcaRouter. *Qwen3.8-Flash-Next*. Secondary relayed specs; qwen-community-1.0 terms and HF card pending primary verification. Qwen 4 proper unreleased. URL: <https://www.orcarouter.ai/blog/qwen-4-leak-vllm-fuse-op> (visited on 09/15/2026).
- [3]Reuters. *Tencent Hy4 preview*. Secondary relayed Tencent figures; Tencent primary and HF verification pending. Preview status explicit. URL: <https://www.reuters.com/world/asia-pacific/chinas-tencent-releases-new-open-source-ai-model-coding-research-tasks-2026-08-28/> (visited on 09/15/2026).
- [4]W35 community discussion around open weights and agent tooling. Context-only observation of discussion themes; not evidence of technical performance. (Visited on 09/15/2026).

- [5]Data Today. *IBM Granite 4.2*. Secondary relayed release facts; IBM primary and HF verification pending. SWE-skew caveat applies. URL: <https://data-today.net/granite-4-2-native-reasoning-open-weights/> (visited on 09/15/2026).
- [6]ByteIota. *VS Code 1.135 Agent Host Protocol*. Secondary relayed spec; VS Code release notes and spec pending primary verification. Pre-1.0 draft. URL: <https://byteiota.com/vs-code-1-135-agent-host-protocol-ships-sessions-go-portable/> (visited on 09/15/2026).
- [7]InfoQ. *Cursor Origin*. Secondary relayed scope; Cursor docs pending primary verification. Policy gap unresolved. URL: <https://www.infoq.com/news/2026/08/cursor-origin-alternative-github/> (visited on 09/15/2026).
- [8]TechRepublic. *GitHub Copilot coding agent and Teams context*. Secondary relayed preview facts; Microsoft and GitHub docs pending primary verification. URL: <https://www.techrepublic.com/article/news-github-copilot-teams-conversations-coding-agent/> (visited on 09/15/2026).
- [9]Harness. *Harness Agent-Ready Code Repository and AI Code Review*. Primary official vendor announcement; capability and scale claims are company-claimed without independent evaluation. URL: <https://www.prnewswire.com/news-releases/harness-launches-code-repository-with-ai-code-review-for-agent-ready-development-302861964.html> (visited on 09/15/2026).
- [10]grith. *grith OS-level agent security proxy*. Primary official source; mechanism verified, vendor-reported motivation measurements unreproduced. Linux-only scope. URL: <https://grith.ai/blog/grith-is-live> (visited on 09/15/2026).
- [11]Hypernova News. *Claude Fable 5 debuts as first Mythos-class model*. Secondary relayed claims; Anthropic and Artificial Analysis primaries pending. Mythos-class is evaluator framing. URL: <https://www.hypernova.news/article/claude-fable-5-debuts-as-first-mythos-class-model-tops-agentic-test> (visited on 09/15/2026).
- [12]OpenAI. *GPT-5.6 family in AWS Kiro*. Primary official source; availability verified, Terminal-Bench cost figure is vendor-reported without published methodology. URL: <https://openai.com/index/gpt-5-6-in-kiro/> (visited on 09/15/2026).
- [13]vLLM Project. *vLLM v0.28.0*. Primary official release record; performance figures are project-reported without independent audit. URL: <https://github.com/vllm-project/vllm/releases/tag/v0.28.0> (visited on 09/15/2026).
- [14]iApp. *OpenThai 2.0*. Primary official source; benchmark figures are vendor-measured without independent reproduction. URL: <https://iapp.co.th/blog/openthai2p0-launch> (visited on 09/15/2026).
- [15]Anthropic. *Automated researchers mitigate alignment failures*. Primary official page-level report; full paper PDF not consumed. Lab-reported figures unreproduced; no production deployment claim. URL: <https://www.anthropic.com/research/automated-researchers-mitigate-alignment-failures> (visited on 09/15/2026).
- [16]Noah News. *China advances AI regulation with upstream ethics review*. Secondary relayed briefing; MIIT primary pending. No-threshold vagueness is central. URL: <https://noah-news.com/china-advances-ai-regulation-with-upstream-ethics-review-and-over-200-standards/> (visited on 09/15/2026).
- [17]Korea Times. *Korea sets national principles for AI ethics*. Secondary relayed via national daily; MSIT primary pending. Explicitly nonbinding; contrast with upstream review, never equivalence. URL: <https://www.koreatimes.co.kr/business/tech-science/20260824/korea-sets-national-principles-for-ai-ethics> (visited on 09/15/2026).