
Japanese Generative AI Technical Survey

2026-W37

2026-09-11

効率が縦に伸びた一週間

金融向けの整え、独立の音声層、道具立ての束ね、効率旗艦の読み分け、符号の力、開かれた三方向を、脅威報告の物差しとともに読む。

FEATURE: VERTICAL EFFICIENCY / FEATURE: OPEN WEIGHTS / REVIEW: WHAT TO WATCH

Editorial cutoff 2026-09-04 18:00 - 2026-09-11 18:00 America/New_York

Repository eariver/japanese-generative-ai-survey

Build LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

- 1 Financial Services on Astra — 金融の現場へ、Astra とともに
- 2 A Separate Voice Layer — 声の層を切り出す
- 3 The Harness Plane Advances — 道具立てを束ねる
- 4 Efficient Flagship, Vendor-Framed — 効率の旗艦を、発表の範囲で読む
- 5 Coding Efficiency Pushes — 符号を書く力を、費用とともに
- 6 Open Weights Go Vertical — 開かれた重みは縦に伸びる
- 7 Threat Report in Context — 安全の目安を、事例の範囲で
- 8 Week in Review — 変化・意味・次の観測点

This Week in AI

基盤の層で効率が縦に伸びた。 9月10日の OpenAI の三つの出し分け（金融向けの整え、独立の音声層、道具立ての束ね）に、DeepSeek の効率旗艦、Cognition の符号と道具立て、開かれた三方向が重なった。

数値と日付は出どころごと受け止める。 比較の言い方は提供側の報告として扱い、9月14日の切り替えは先の話として分ける。Fusion の 39%は表の中の最大値であり、一律の改善ではない。公開時刻は 9 月 11 日 17 時（世界時）に通常窓と確かめた。

安全の物差しは事例の範囲で置く。 9月10日の脅威報告を今週の技術的な安全の目安とし、目立つ事例の留保とともに読む。公開投稿の反応は関心の向きを示す背景にとどめる。

この号の読み方

通常本文の基準は 2026-09-04 18:00 から 2026-09-11 18:00（いずれも America/New_York、終わりは含まない）。この範囲の出来事を通常の扱いとし、範囲前の持ち込み、締め切り後の速報、予告された先の運用は区別する。本号で参照する公開資料が示す範囲を超えて断定しない。提供元や報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的な順位へ言い換えない。重みの公開場所や一次発表で確認できない仕様や利用条件は事実として扱わない。

読み解く軸： 基盤の層で効率が縦に伸びたことを、金融の整え、声の層、道具立ての束ね、効率旗艦の読み分け、符号の力、開かれた三方向を、脅威報告の目安とともに資料の範囲で束ねることである。

1 Financial Services on Astra

FINANCIAL VERTICAL

金融の現場へ、Astra とともに

9月10日の発表を起点に、Astra を推論の核とする金融向けの整え方と、資料・評価・利用条件の留保を切り分けて示す。

9月10日、OpenAI は ChatGPT for Financial Services を示した [1]。ChatGPT Work の利用感覚を土台に、GPT-6 Astra の推論を調査や模型づくり、顧客向け資料の作成に結びつける内容で、Morgan Stanley と Evercore との協業で磨いたとされる。当面の標準は投資銀行と株式調査にある。内蔵資料として Dalooa、PitchBook、LSEG News、Crunchbase が挙がり、提供元の言葉として Fiscal.ai も添えられる。S&P Capital IQ や LSEG、MSCI、Dow Jones Factiva、Moody's との共通認証、50 を超える接続口が記される。管理側では Excel や Word、PowerPoint の雛形配布、SAML や SCIM、役割に応じた権限、暗号化や保存期間の設定など企業向けの統制が示される。金額や利用枠、地域の扱いは資料に見当たらず、本号では断定しない。資料の正確さや応答の速さの改善は提供側の説明として受け止める。

評価として掲げられるのは OfficeQA Pro の 69.9% で、GPT-5.6 Sol の 60.2% と並べられる [1]。米国債の広報誌など表や図、脚注をまたぐ探索を問う設計と説明されるが、OfficeQA や BoxBench、スライド作成の採点の細目は今回たどっておらず、抽出や判定の妥当性は確かめていない。いずれも提供側の表であり、独立の再現を待つ。Astra 自体の位置づけも、検索や推論、成果物の生成に強いという提供側の言い方として扱い、金融向けの一般的な優劣として広げない。この節の内容を GPT-Live-1 や Agents API の仕様として読み替えない。三つは別々の出し物である。

資料と評価の境界

金額、利用枠、地域の扱いは資料にない。評価の細目はたどっていない。数値は提供側の報告であり、独立の再現を待つ。

X / Community observation — context only

公開投稿では、9月10日の公式発信に独立の言及が重なる様子が観察される [2, 3]。うかがえるのは利用枠への当たりや使い比べへの関心の向きであり、仕様や測定値、料金、利用条件の根拠にはならない。締め切り後の投稿は文脈資料であり、通常の集計には含めない。

2 A Separate Voice Layer

VOICE FRONTIER

声の層を切り出す

9月10日の GPT-Live-1 を、Astra の詰め合わせではなく、背後の模型に委ねる独立の音声層として描く。

9月10日、OpenAI は API での GPT-Live-1 を示した [4]。聞き取りと発話を一つの模型で担う全二重の音声層で、深い推論や道具の呼び出しは背後の文章模型に委ねる組み立てである。背後には GPT-6 Astra のような自社模型も第三者の模型も置けるとされ、Astra の包みの一つとして扱わない。割り込みへの応答や無音・雑音のさばき、長い対話の保ち、電話での利用がうたわれる。開発側は調子や速さ、話しぶりを指示で整え、音声認識の書き起こしや読みの偏り付けを使えるとされる。対応する言語や方言、電話事業者の範囲は資料だけでは輪郭が定まらず、本号では言い切らない。

測定として示されるのは、Full Duplex Bench で GPT-Realtime-2.1 を 30 ポイント上回ること、Astra の中位設定と組んで Tau3 で首位に立つこと、12 を超える声色、利用者の声として割り込みの減少などである [4]。いずれも提供側のまとめであり、採点の取り方や比べた条件は今回たどっていない。料金は音声層として 1 分あたり 0.05 ドルと示され、背後の模型や道具立てと組み合わせて使う建て付けである。声色の特注は営業経由とされる。利用者の言葉は選ばれた紹介として扱い、導入の実証とは切り分ける。

音声層の境界

採点の細目はたどっていない。言語や電話の範囲は資料だけでは定まらない。利用者の言葉は選ばれた紹介である。

3 The Harness Plane Advances

AGENT HARNESS

道具立てを束ねる

9月10日の Agents API と、9月11日17時（世界時）に通常の範囲と確かめた Fusion を、試し段階の区別ごとと並べて読む。

9月10日、OpenAI は Agents API を公開試しとして示した [5]。Codex の道具立てと基盤を開発者に向けて束ねる内容で、仕事や模型、道具、環境を指定する一度の呼び出しで雲の上の代理人を起こせるとされる。例示では GPT-6 Astra が設定の一つとして示されるが、API 自体を Astra の API と呼ばない。環境は OpenAI が預かる砂場、自前の基盤、Blaxel や Cloudflare、Daytona、DigitalOcean、E2B、Modal、Oracle、Runloop、Vercel といった提携先から選べるとされる。長い対話の圧縮、道具の探索読み込みや並列・連鎖の呼び出し、文脈を分けた並列の子代理人、版で追える改善、開かれた Codex の符号が土台として示される。公開試しの範囲や一般提供の時期、速度や地域の上限は資料に見当たらない。提携の深さや私設網、守りの細目は提供側の説明にとどめ、利用者の言葉も選ばれた紹介として扱う。料金の上乗せはなく、符号や道具の利用分を払う建て付けとされる。

9月11日の Cognition の Fusion は、机上と命令行で動く並列の道具立てである [6]。先導が計画と見直しを担い、SWE-2 が実行を担う脇役に回る組み合わせで、各々が文脈を持って並走する。推奨は Fable 5.1 と SWE-2 の組み合わせとされる。公開時刻は一次頁の付随情報が2系統とも9月11日10時（米太平洋夏時間）を示し、世界時では9月11日17時となる。通常の終わりが同日22時（世界時）のため、5時間の余裕で通常の範囲に収まる。日付だけの推定は退け、この時刻を根拠とする。効率の見出しにある39%は表の中の最大値であり、一律の改善ではない。DeepSWE や Terminal-Bench、SWE-Atlas の問い答え、Vals の移行、FrontierCode の拡張で、点数をほぼ保ったまま費用を抑える行ごとの差分が示されるが、採点の取り方は提供側のまとめの範囲でしかたどっていない。試していない先導と脇役の組み合わせへの一般化は成立していない。

試し段階と効率の境界

一般提供の時期や速度・地域の上限は資料にない。39%は最大値であり一律ではない。採点の取り方は提供側のまとめの範囲である。

X / Community observation — context only

9月11日16時16分（世界時）の公式発信に、締め切り前の独立の反応が重なる様子が観察される [7, 8]。うかがえるのは音声付き開発環境への関心の向きであり、仕様や測定値の根拠にはならない。

4 Efficient Flagship, Vendor-Framed

EFFICIENT FLAGSHIP

効率の旗艦を、発表の範囲で読む

9月10日の DeepSeek V4.1-Flash を、他社超えの言い切りではなく提供側の報告として受け止め、9月14日の切り替えは先の話として分ける。

9月10日、DeepSeek は V4.1-Flash を示した [9]。5520億規模の混合専門家の構えて、入力で80億、出力で160億が働き、画像の理解を素で備え、100万の文脈を持つとされる。学び直しと強化学習の積み増しが添えられる。重みの置き場は MIT の許して開かれ、API では deepseek-flash として生きる。旧い V4-Flash や Vision-Exp は引退し、互換の経路が用意されるとされる。省く側の記憶域は HBM で4分の1、SSD で8分の1と説明され、代理人の費用に効くとされる。表や図の細目は取得の打ち切りでたどり切れておらず、採点の取り方は提供側のまとめとして扱う。給仕の対応は約束の段階であり、引擎側の時点の状態と切り分ける。

比較の言い方は慎重に扱う。提供側は複数の外部の手による試しを引きつつ、V4-Pro を含む旗艦群を上回ると述べるが、試した相手の名は明かされず、独立の再現もない [9]。本号では「V4.1-Flash が V4-Pro に勝つ」と言い切らず、提供側の報告として書き分ける。9月14日4時（世界時）に V4-Pro への求めを V4.1-Flash へ振り替える案内は、範囲の中の文書で予告された範囲の後の運用であり [10]、今週起きた出来事として書かない。範囲の中の料金改定（9月10日4時から有効、繁忙で半額の時間帯あり）は別に起きた事実として扱い、表の1符号あたりの値は図に

埋もれて取り切れていないことを添える。V4.1-Pro の出日は資料に見当たらない。

比較と日付の境界

比べた相手の名は明かされていない。9 月 14 日の振り替えは先の運用であり、今週の出来事ではない。表の細値は取り切れていない。

X / Community observation — context only

9 月 10 日 6 時 10 分（世界時）の公式発信に、独立の試しや計測の報告が重なる様子が観察される [11, 12]。うかがえるのは導入や計測への関心の向きであり、性能や費用の根拠にはならない。

5 Coding Efficiency Pushes

FRONTIER CODING

符号を書く力を、費用とともに

9 月 10 日の SWE-2 を、点数と手数、費用の三方から、提供側の表の範囲でたどる。

9 月 10 日、Cognition は SWE-2 を示した [13]。Kimi K3 (2.8 兆規模) を土台に強化学習を重ねた符号モデルで、FrontierCode 1.1 の主表で 50.0%、Fable 5.1 の 50.9% に 1 ポイント差まで迫りつつ 64% 安いとされる。Astra の 53.3% には数ポイント差で 4 分の 1 の費用という並べ方も示される。DeepSWE 1.1 で 73.0%、Terminal-Bench 2.1 で 92.8%、Terminal-Bench 4 で 27.3% が掲げられる。SWE-1.7 と比べた手数の少なさ (58% 減) や費用の少なさ (81% 減) も表にある。いずれも提供側が走らせたか集めた数値であり、独立の再現はない。費用は定価を前提に割引を織り込む計算で、仕事の偏りによる振れは提供側の説明として受け止める。K3 の伸びしろの解釈も提供側の読みとして扱う。

利用口は机上と命令行から始まり、網や Fusion へ広げる運びとされる [13]。手間の段階付けや道具立ての開示の添え書きがある。比べ方の添え書きでは、公開値のある組み合わせはそれを引き、なければ作り手の道具立てで測るとされ、Anthropic は Claude Code、OpenAI は Codex、xAI は Grok Build、開かれた重みは Devin の命令行とされる。手法の節 (罰則や報いの置き方、配り方、学びの資料) は提供側の記述として扱い、再走の証拠にはしない。

符号の測定の境界

数値は提供側が走らせたか集めたものであり、独立の再現はない。費用は定価前提の計算である。

6 Open Weights Go Vertical

OPEN VERTICAL

開かれた重みは縦に伸びる

9 月 7 日から 10 日の三つの公開を、手元の装置、訳し、絵と動画の三方向から、日付と許しの精度ごとに示す。

OpenBMB の MiniCPM5-2B は、手元や閉じた環境での利用を狙う 20 億級の密な模型である [14]。Llama 流の素直な構えて層は 42、文脈は 13 万あまり、Apache-2.0 の許しで開かれる。比べた中での平均 53.9、LiveCodeBench 69.1、AIME 86.5、MATH-500 94.6、SWE-bench Verified 46.4、GAIA 88.7、tau2 Telecom 97.1、BFCL 66.6 といった値は札の表であり、外部の再現はない。vLLM や SGLang、llama.cpp、Transformers で fork なしに動き、道具呼びの受け口や UltraData の一族の公開、強化学習と統合の伸びが添えられるが、量子化や機種ごとの振る舞いは提供側の説明にとどめる。9 月 7 日という日付は作り方や周辺の記録からの帰属であり、時刻の断定はしない。

9 月 10 日、Cohere は North Small Translate 1.0 を示した [15]。訳しに絞った混合専門家で全体 2180 億、働きは 250 億、入出力とも 1.6 万、50 を超える言語を支えるとされる。許しは研究用の CC BY-NC 4.0 で、商用には別の Vault の許しが要るとされる。RWS との協業、Hugging Face の置き場や文書、技術報告が添えられる。WMT26 の全言語で 83.60 (代理人流で 84.36)、DeepL や Google 訳、Gemma、GLM、Mistral との並べ方が示されるが、採点には GPT-5.6 Sol が判定に使われ、取り方や言語別の表は今回たどっていない。処理量や費用の内訳 (Gemma 31B 比 1.4 倍、長い文脈 48.9、仕事あたりの費用など) は社内の試しとして受け止める。

InclusionAI の Ling-3.0-flash-VL は、Ling-3.0-flash に絵と動画の理解を足した素の多様体模型である [16]。全体 1240 億、符号ごとに 55 億が働き、文脈は 25.6 万、絵と動画の入力を支え、MIT の許しで開かれるとされる。Artificial Analysis の知能指数で 42

(素の flash から 4 増し)、理解・推論・行動の三面や SGLang、vLLM の手引きが添えられるが、数値は札の報告であり独立の再現はない。置き場の生まれは 9 月 4 日、FP8 は 9 月 8 日、表の掲載は 9 月 10 日という周辺の記録で押さえ、時刻の断定はしない。動画の効き目は提供側の説明として扱う。

開かれた重みの境界

数値は札の報告であり、外部の再現はない。日付は帰属の精度ごと扱い、時刻の断定はしない。許しの範囲を事実には混ぜない。

X / Community observation — context only

手元の装置での試しや速度の報告が、9 月 7 日の公式発信の後に独立の手で重なる様子が観察される [17, 18]。うかがえるのは手元での動きへの関心の向きであり、性能や対応機種 of 根拠にはならない。

7 Threat Report Sets the Bound

SAFETY BOUND

安全の境界を、事例の範囲で

9 月 10 日の脅威報告を、今週の技術的な安全の目安として、目立つ事例の留保ごと置く。

9 月 10 日、Anthropic は 8 か月分（2025 年 12 月から 2026 年 8 月）の脅威報告を示した [19]。扱う harm は 7 領域で、対象のモデルは Haiku、Sonnet、Opus に限られ、蒸留の 1 件を除き Fable や Mythos 級は関わらないとされる。複雑な攻撃が必ずしも熟練を要さず、複数代理人の枠組みで自律の度が増し、人が狙いを定めて抜き取りを確かめる構図が示される。報告書の日付自体は通常範囲の出来事として扱う。

取り上げられるのは、ロシアの諜報作戦、場当たりの窃取集団、脆弱性の探索工房、AI 供給連鎖の窃取と転売などで、いずれも妨害と守りの強化、当局への共有が添えられる [19]。生物の研究に関わる 5 件も妨害した利用の中に数えられるが、兵器が生まれたとか意図が固まったという主張はしていない。いずれも提供側の調査報告であり、帰属は公開報道と整合的とされる範囲で受け止め、ここで独立に確かめない。全文の PDF や検出子の村は今回たどっておらず、抄録の範囲でしか読まない。9 月 11 日の時系

列にある蒸留の名指しの細目は範囲後の速報として切り分け、通常的事実には入れない。目立つ事例は全体の縮図ではないという留保を保つ。

安全の読み方の境界

全文や検出子はたどっていない。帰属は提供側の調査報告である。速報の細目は通常的事実に入れない。

8 Week in Review

WEEKLY SYNTHESIS

今週は、効率が縦に伸びた

金融の整え、声の分離、道具立ての前進、効率旗艦の提供側報告、符号の費用対効果、開かれた三方向、安全の目安が同時に前景化した。

今週何が変わったか

1. 金融の整え、声の層、道具立てが分かれて出た。
9 月 10 日の三つの出し物は、Astra を核とする金融向けの整え、背後に委ねる独立の音声層、Codex の道具立てを束ねる公開試しである。いずれも提供側の一次発表の範囲で読み、互いの仕様として混ぜない。
2. 効率旗艦と符号と道具立てが費用とともに示された。DeepSeek V4.1-Flash の他社超えは提供側の報告として受け止め、9 月 14 日の振り替えは先の運用として分ける。SWE-2 の点数と手数と費用、Fusion の行ごとの差分（39%は最大値、公開は 9 月 11 日 17 時（世界時）で通常範囲）は表の範囲でたどる。
3. 開かれた三方向と安全の目安が添えられた。
MiniCPM5-2B の手元狙い（9 月 7 日帰属）、North の訳し絞り（判定と許しの留保付き）、Ling の絵と動画（日付の段階付き）を、札の報告として切り分け、9 月 10 日の脅威報告を技術的な安全の目安として目立つ事例の留保ごと置く。

なぜそれらが一緒に重要なのか

効率を縦に伸ばす手つきが、基盤の層でそろって具体化した点にある。金融の垂直化、声の分離、道具立ての束ねは、同じ日の別々の出し分けであり、単一の Astra の物語に束ねられない。効率旗艦の比較、

符号の費用、道具立ての効率、開かれた三方向の数値は、それぞれ異なる主体と条件の報告であり、単一の効率や順位の物語に束ねられない。脅威報告の目安を添えることで、今週の伸びを安全の留保とともに読める。許しを事実せず、模型ごとの数値と利用条件、報告の出どころを切り離さない読みが条件になる。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作規模の小ささを共通効率へ、利用条件の表示を共通許諾へ、速度や点数を横断的な順位へ自動的に変換してはいけない。

Weekly Community Movement — context only

公開投稿では、金融や音声、道具立て、効率旗艦、符号、手元の模型への関心が、公式発信に独立の言及が重なる形で観察される。これは今週の関心の広がりを示す背景であり、仕様や性能、提供条件、互換性を証明するものではない。範囲前の持ち込み 1 件、締め切り後の速報 20 件は通常の集計には含めない。

次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。金融向けの金額や利用枠、地域の扱い、音声の言語や電話の範囲、Agents API の一般提供の時期や速度・地域の上限、V4.1-Pro の出日と振り替え後の動き、SWE-2 の再現、Fusion の試していない組み合わせ、MiniCPM の機種ごとの振る舞い、North の言語別の表、Ling の時刻の精度、脅威報告の全文や検出子はまだ詳細化されていない。さらに、実験室や提供側の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。提供元が示す速度、報道が伝える仕様、実験室が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能順位へまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。

Sources & Limitations

Primary sources consulted

9月10日のOpenAIの三つの一次発表（金融向け、GPT-Live-1、Agents API）、9月10日のDeepSeek V4.1-FlashとAPI文書、9月10日のCognition SWE-2、9月11日のFusion（公開時刻は9月11日17時（世界時）に通常の範囲と確認）、9月7日帰属のMiniCPM5-2B、9月10日のNorthと言語処理の技術報告、9月10日掲載のLing-3.0-flash-VL、9月10日のAnthropic脅威報告を範囲として読んだ。全文のPDFや検出子、採点の細目、図表の値は参照の打ち切りで取り切れていないものがあり、本号では主張しない。

Temporal boundary

通常の範囲は2026-09-04 18:00から2026-09-11 18:00（いずれもAmerica/New_York、終わりは含まない）。範囲前の持ち込み1件、締め切り後の速報20件は通常の集計には含めない。9月14日の振り替えは範囲の中の文書で予告された範囲の後の運用であり、今週の出来事ではない。Lingの置き場の生まれ（9月4日）、FP8（9月8日）、表の掲載（9月10日）は段階として押さえ、時刻の断定はしない。

Vendor-reported boundary

測定値や比較、費用、処理量、許しの説明は、提供側や札、提携先の報告として受け止め、独立の再現とは切り分ける。DeepSeekの他社超えは提供側の報告であり、試した相手の名は明かされていない。Fusionの39%は表の中の最大値である。Northの採点には判定模型が使われ、言語別の表はたどっていない。脅威報告の帰属は提供側の調査報告である。

Community observation boundary

公開投稿の台帳（45件の直接URL：通常24件、範囲前の持ち込み1件、速報20件）は関心の向きを示す背景であり、仕様や測定値、日付、利用条件、価格、許諾、構造、公開事実の根拠にはならない。行単位の台帳を正とし、要約文の数えに頼らない。

What was not elevated

噂の段階の話題は今週の技術的な出来事として取り上げない。二次的な言説は技術的な重みを持たせず、本号の主張には載せない。画像や動画の系統は調べた範囲では静かであり、存在しないことの証明とはしない。

References

- [1]OpenAI. *Introducing ChatGPT for Financial Services*. Primary official source; Financial Services on Astra with data, benchmark and governance bounds. Pricing, entitlement limits and region availability not stated. OfficeQA methodology not reviewed here. All benchmark figures vendor-reported without independent reproduction. URL: <https://openai.com/index/introducing-chatgpt-financial-services> (visited on 09/19/2026).
- [2]*OpenAI official post Sep 10*. Public direct post; ordinary-window official signal. Context-only observation of release attention, not evidence of specifications or measurements. URL: <https://x.com/OpenAI/status/2098118191029624911> (visited on 09/19/2026).

- [3] *Independent Astra usage note Sep 10*. Public direct post; ordinary-window independent observation. Context-only signal of usage attention, not evidence of specifications or measurements. URL: <https://x.com/cuicuihai/status/2098199705452974289> (visited on 09/19/2026).
- [4] OpenAI. *Build more natural voice experiences with GPT-Live-1 in the API*. Primary official source; separate full-duplex voice layer delegating to Astra or third-party backends, not an Astra package. Bench methodology, language and telephony scope not fully bounded. All eval figures vendor-reported. URL: <https://openai.com/index/introducing-gpt-live-1-in-the-api> (visited on 09/19/2026).
- [5] OpenAI. *Introducing the Agents API*. Primary official source; managed harness in public beta with Astra as configuration example, not proof the API is an Astra package. GA timeline, rate and region limits not stated. Partner and customer claims vendor-described. URL: <https://openai.com/index/introducing-the-agents-api> (visited on 09/19/2026).
- [6] Cognition. *Introducing Fusion in Devin Desktop and CLI*. Primary official source with first-party page metadata establishing 2026-09-11T17:00:00Z ordinary publication. Partnered evaluation vendor-presented. 39 percent is a table maximum, not uniform improvement. Untested pair generalization not established. URL: <https://cognition.com/blog/local-fusion> (visited on 09/19/2026).
- [7] Cognition official post Sep 11. Public direct post; ordinary-window official signal for coding and harness releases. Context-only observation, not evidence of scores or costs. URL: <https://x.com/cognition/status/2098445562404024343> (visited on 09/19/2026).
- [8] *Independent Devin Voice reaction Sep 10*. Public direct post; ordinary-window independent observation. Context-only signal of attention, not evidence of specifications. URL: https://x.com/Chris_Wozniczek/status/2098199592617783674 (visited on 09/19/2026).
- [9] DeepSeek. *Introducing DeepSeek-V4.1-Flash: smarter, faster, more efficient*. Primary official source; architecture and model claims as stated. Ahead-of-Pro comparison vendor-reported with unnamed third parties and no independent reproduction. Sep 14 routing is a future operation announced in-window. Benchmark methodology beyond vendor summary not reviewed here. URL: <https://www.deepseek.com/en/news/deepseek-v4-1-flash/> (visited on 09/19/2026).
- [10] DeepSeek. *DeepSeek API docs news 20260910*. Primary official docs; in-window pricing and economics separate from future Sep 14 routing. Per-token table values in images not fully reviewed here. V4.1-Pro launch date not in source. URL: <https://api-docs.deepseek.com/news/news260910/> (visited on 09/19/2026).
- [11] DeepSeek official post Sep 10. Public direct post; ordinary-window official signal. Context-only observation, not evidence of benchmarks or pricing. URL: https://x.com/deepseek_ai/status/2097930608790167907 (visited on 09/19/2026).
- [12] *Independent V4.1-Flash test note Sep 10*. Public direct post; ordinary-window independent observation. Context-only signal of testing attention, not independent verification of benchmarks. URL: <https://x.com/UnslothAI/status/2097947144351252497> (visited on 09/19/2026).
- [13] Cognition. *Introducing SWE-2: Pushing the Pareto Frontier*. Primary official source; benchmark and cost framing vendor-reported. Harness and methodology reproduction gaps remain. Cost figures assume list pricing with task-distribution sensitivity vendor-described. URL: <https://cognition.com/blog/swe-2> (visited on 09/19/2026).
- [14] OpenBMB. *MiniCPM5-2B model card*. Model-card source; card-reported benchmarks with on-device relevance. Independent reproduction absent. Release-day Sep 7 attribution from recipe and secondary coverage without hour precision. Quant and chip behavior vendor-described. URL: <https://huggingface.co/openbmb/MiniCPM5-2B> (visited on 09/19/2026).

- [15]Cohere. *Introducing North Small Translate*. Primary official source; judge-model evaluation bound with GPT-5.6-Sol as judge. CC BY-NC research license with separate production implications. Throughput and cost internal tests not independently verified. URL: <https://cohere.com/blog/north-small-translate> (visited on 09/19/2026).
- [16]InclusionAI. *Ling-3.0-flash-VL model card*. Model-card source; multimodal facts bounded. Benchmark results card-reported. Early publication-hour precision unresolved with Sep 4, Sep 8 and Sep 10 phasing establishing relevance. URL: <https://huggingface.co/inclusionAI/Ling-3.0-flash-VL> (visited on 09/19/2026).
- [17]*OpenBMB official post Sep 7*. Public direct post; ordinary-window official signal. Context-only observation, not evidence of benchmarks or device behavior. URL: <https://x.com/OpenBMB/status/2096970974247956501> (visited on 09/19/2026).
- [18]*Independent local inference note Sep 10*. Public direct post; ordinary-window independent observation of local speed. Context-only signal, not independent verification of card figures. URL: <https://x.com/0x7c0x80386/status/2098156035739648416> (visited on 09/19/2026).
- [19]Anthropic. *Detecting and countering misuse of AI: September 2026*. Primary official source; Sep 10 ordinary report. Notable examples not representative of all incidents. Investigations vendor-reported. Full PDF and indicators not reviewed here. Sep 11 naming detail excluded as late-breaking. URL: <https://www.anthropic.com/threat-intelligence-report-september-2026> (visited on 09/19/2026).