
Japanese Generative AI Technical Survey

2026-W37

2026-09-11

プラットフォームで効率が伸びた一週間

金融業務向けパッケージ、独立した音声レイヤー、エージェント実行基盤の整備、高効率モデルの読み分け、コーディングモデルのコスト性能、3 方向のオープンモデルを、脅威レポートの文脈とともに読む。

[FEATURE: VERTICAL EFFICIENCY](#) / [FEATURE: OPEN MODELS](#) / [REVIEW: WHAT TO WATCH](#)

Editorial cutoff 2026-09-04 18:00 - 2026-09-11 18:00 America/New_York

Repository eariver/japanese-generative-ai-survey

Build LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

- 1 Financial Services on Astra — 金融業務向け ChatGPT、Astra の推論を中核に
- 2 A Separate Voice Layer — GPT-Live-1、独立した音声レイヤーとして API に登場
- 3 The Harness Plane Advances — Agents API と Fusion、実行基盤の 2 つの動き
- 4 Efficient Flagship, Vendor-Framed — DeepSeek V4.1-Flash、発表の範囲で読む
- 5 Coding Efficiency Pushes — SWE-2、コーディング性能とコスト効率を両立
- 6 Open Models Go Vertical — オープンモデルの 3 方向
- 7 Threat Report in Context — 脅威レポートを技術的安全の文脈に
- 8 Week in Review — 変化・意味・次の観測点

This Week in AI

プラットフォームレイヤーで効率が伸びた。 9 月 10 日の OpenAI の 3 つの独立したリリース（金融業務向けパッケージ、独立した音声レイヤー、エージェント実行基盤）に、DeepSeek の高効率モデル、Cognition のコーディングモデルと実行基盤、3 方向のオープンモデルが重なった。

数値と日付は出どころごと受け止める。 性能比較はベンダー報告として扱い、9 月 14 日のルーティング変更は今後の運用として分ける。Fusion の 39% は評価表の中の最大値であり、一律の改善ではない。公開時刻は 9 月 11 日 17 時（世界時）に通常ウィンドウ内と確認した。

安全面の文脈は事例の範囲で置く。 9 月 10 日の脅威レポートを今週の技術的安全面を読み解く材料とし、代表的事例という留保とともに読む。公開投稿の反応は関心の方向を示す背景にとどめる。

この号の読み方

通常本文の対象期間は 2026-09-04 18:00 から 2026-09-11 18:00（いずれも America/New_York、終了時刻は含まない）。この範囲の出来事を通常の扱いとし、範囲前の持ち込み、締め切り後の速報、予告された今後の運用は区別する。本号で参照する公開資料が示す範囲を超えて断定しない。ベンダーや報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的な順位へ言い換えない。モデルの公開場所や一次発表で確認できない仕様や利用条件は事実として扱わない。

読み解く軸： プラットフォームレイヤーで効率が垂直方向に伸びたことを、金融業務向けパッケージ、独立した音声レイヤー、エージェント実行基盤の整備、高効率モデルのベンダー報告としての読み分け、コーディングモデルのコスト性能、3 方向のオープンモデルを、脅威レポートの技術的安全面の文脈とともに一次資料の範囲で束ねることである。

1 Financial Services on Astra

FINANCIAL VERTICAL

金融業務向け ChatGPT、Astra の推論を中核に

9 月 10 日発表の金融業務向けパッケージを、内蔵データと評価・ガバナンスの留保と切り分けて示す。

9 月 10 日、OpenAI は ChatGPT for Financial Services を発表した [1]。ChatGPT Work の操作感を土台に、GPT-6 Astra の推論能力をリサーチや財務モデリング、顧客向け資料作成に結びつける内容で、Morgan Stanley と Evercore との設計パートナーシップで磨いたとされる。当面の対象は投資銀行業務と株式リサーチである。内蔵データとして Dalooop、PitchBook、LSEG News、Crunchbase が挙がり、提供元の紹介では Fiscal.ai も添えられる。S&P Capital IQ や LSEG、MSCI、Dow Jones Factiva、Moody's とのシングルサインオン連携、50 を超えるコネクタが記される。管理側では Excel・Word・PowerPoint テンプレートの配布、SAML や SCIM、ロールベースのアクセス制御、暗号化や保存期間の設定などエンタープライズ向けのガバナンスが示される。価格や利用枠、提供地域は資料に見当たらず、本号では断定しない。データ精度や応答速度の改善はベンダー側の説明として受け止める。

評価として掲げられるのは OfficeQA Pro の 69.9% で、GPT-5.6 Sol の 60.2% と並べられる [1]。米国債ブレティンなど表・グラフ・脚注をまたぐ情報探索を問う設計と説明されるが、OfficeQA や BoxBench、スライド作成タスクの採点の詳細は本号の検証範囲外であり、サンプリングや判定の妥当性は独立に確認していない。いずれもベンダー側の数値であり、独立した再現を待つ。Astra 自体の位置づけも、検索・推論・成果物生成に強いというベンダー側の表現として扱い、金融向けの一般的な優劣として広げない。この節の内容を GPT-Live-1 や Agents API の仕様として読み替えない。3 つは独立したリリースである。

資料と評価の境界

価格、利用枠、提供地域は資料にない。評価の詳細は本号の検証範囲外である。数値はベンダー側の報告であり、独立した再現を待つ。

X / Community observation — context only

公開投稿では、9 月 10 日の公式発信に独立した言及が重なる様子が観察される [2, 3]。うかがえるのは利用枠への関心や使い比べへの注目であり、仕様やベンチマーク、料金、利用条件の根拠にはならない。締め切り後の投稿は文脈資料であり、通常の集計には含めない。

2 A Separate Voice Layer

VOICE FRONTIER

GPT-Live-1、独立した音声レイヤーとして API に登場

9 月 10 日の GPT-Live-1 を、Astra に同梱される機能ではなく、バックエンドのモデルに処理を委ねる独立した音声レイヤーとして描く。

9 月 10 日、OpenAI は API での GPT-Live-1 を提供した [4]。聞き取りと発話を単一モデルで担う全二重の音声レイヤーで、深い推論やツール呼び出しはバックエンドのテキストモデルに委ねる構成である。バックエンドには GPT-6 Astra のような自社モデルもサードパーティのモデルも置けるとされ、Astra のパッケージの一部として扱わない。割り込みへの応答や無音・雑音の処理、長時間セッションの維持、電話経由の利用がうたわれる。開発者はシステムプロンプトでトーンや速度、話し方を整え、音声認識のトランスクリプトやキーワードバイアスを使えるとされる。対応言語・方言や電話事業者の範囲は資料だけでは輪郭が定まらず、本号では言い切らない。

測定として示されるのは、Full Duplex Bench で GPT-Realtime-2.1 を 30 ポイント上回ること、Astra の中程度設定と組み合わせて Tau3 で首位に立つこと、12 を超える音声バリエーション、初期ユーザーの声として思考中の割り込み減少などである [4]。いずれもベンダー側のまとめであり、本号ではベンチマーク手法やサンプリング、比較条件の詳細な検証までは行わない。料金は音声レイヤーとして 1 分あたり 0.05 ドルと示され、バックエンドのモデルやエージェントハーネスと組み合わせて使う構成である。カスタム音声は営業経由とされる。ユーザー企業の言葉はベンダー側が選んだ紹介として扱い、導入実績の実証とは切り分ける。

音声レイヤーの境界

ベンチマークの詳細は本号の検証範囲外である。言語や電話の対応範囲は資料だけでは定まらない。ユーザー企業の言葉は選ばれた紹介である。

3 The Harness Plane Advances

AGENT HARNESS

Agents API と Fusion、実行基盤の 2 つの動き

9 月 10 日の Agents API パブリックベータと、9 月 11 日 17 時（世界時）に通常ウィンドウ内と確認した Fusion を、提供形態の区別とともに並べて読む。

9 月 10 日、OpenAI は Agents API をパブリックベータとして公開した [5]。Codex のエージェントハーネスと実行基盤を開発者向けに束ねる内容で、タスク・モデル・ツール・実行環境を指定する 1 回の API 呼び出しで本番利用可能なエージェントを起動できるとされる。例示では GPT-6 Astra が設定の一例として示されるが、API 自体を Astra の API とは呼ばない。実行環境は OpenAI が管理するサンドボックス、自社インフラ、Blaxel・Cloudflare・Daytona・DigitalOcean・E2B・Modal・Oracle・Runloop・Vercel といったパートナーから選べるとされる。長時間セッション向けのコンテキスト自動圧縮、必要に応じたツール定義の読み込みや並列・連結実行、独立したコンテキストを持つ並列サブエージェント、モデルリリースに合わせたバージョン管理、オープンソースの Codex ハーネスが土台として示される。パブリックベータの適用範囲や正式提供時期、レート制限・提供地域は資料に見当たらない。連携の深さや VPC・セキュリティの詳細はベンダー側の説明にとどめ、顧客の言葉も選ばれた紹介として扱う。API 利用の追加料金はなく、トークンとツールの利用分を支払う構成とされる。

9 月 11 日の Cognition の Fusion は、Devin Desktop と CLI で動く並列型のエージェントハーネスである [6]。リードエージェントが計画とレビューを担い、SWE-2 が実行役のサイドキックに回る組み合わせで、各エージェントが独自のコンテキストを持って並走する。推奨構成は Fable 5.1 と SWE-2 の組み合わせとされる。公開時刻は一次ページのメタデータ 2

系統がともに 9 月 11 日 10 時（米太平洋夏時間）を示し、世界時では 9 月 11 日 17 時となる。通常ウィンドウの終了が同日 22 時（世界時）のため、5 時間の余裕で通常ウィンドウに収まる。日付のみの推定は退け、この時刻を根拠とする。効率見出しの 39% は評価表の中の最大値であり、一律の改善ではない。DeepSWE や Terminal-Bench、SWE-Atlas Q&A、Vals 移行、FrontierCode 拡張で、スコアをほぼ保ったままコストを抑えるベンチマークごとの差分が示されるが、評価手法はベンダー側の説明の範囲で扱う。検証していないリード・サイドキックの組み合わせへの一般化は成立していない。

提供形態と効率の境界

正式提供時期やレート制限・提供地域は資料にない。39%は最大値であり一律ではない。評価手法はベンダー側のまとめの範囲である。

X / Community observation — context only

9 月 11 日 16 時 16 分（世界時）の公式発信に、締め切り前の独立した反応が重なる様子が観察される [7, 8]。うかがえるのは音声対応の開発環境への関心であり、仕様やベンチマークの根拠にはならない。

4 Efficient Flagship, Vendor-Framed

EFFICIENT FLAGSHIP

DeepSeek V4.1-Flash、発表の範囲で読む

9 月 10 日の DeepSeek V4.1-Flash を、上位モデル超えの断定ではなくベンダー報告として受け止め、9 月 14 日のルーティング変更は今後の運用として分ける。

9 月 10 日、DeepSeek は V4.1-Flash を発表した [9]。552B 規模の MoE（Mixture-of-Experts）で、新しい Causal Encoder-Decoder アーキテクチャにより入力処理で 8B、出力生成で 16B のパラメーターが動作し、ネイティブなマルチモーダル理解と 100 万トークンのコンテキストを持つとされる。事前学習の刷新と大規模な強化学習によるポストトレーニングが添えられる。モデルウェイトは MIT ライセンスで公開され、API では deepseek-flash として提供される。旧来の V4-Flash や Vision-Exp は廃止され、互換ルー

トが用意されるとされる。KV キャッシュは前世代比で HBM が 4 分の 1、SSD が 8 分の 1 と説明され、エージェント利用のコストに効くとされる。本号ではベンチマーク表・図の詳細な検証までは行っておらず、評価手法はベンダー側の説明の範囲で扱う。推論エンジン対応は今後の展開の段階であり、本号で確認した範囲と切り分ける。

性能比較の表現は慎重に扱う。ベンダー側は複数の外部組織によるテストを引きつつ、V4-Pro を含むフラグシップモデル群を上回ると述べるが、テスト主体の名称は明かされず、独立した再現もない [9]。本号では「V4.1-Flash が V4-Pro に勝つ」と断定せず、ベンダー報告として書き分ける。9 月 14 日 4 時（世界時）に V4-Pro 宛てリクエストを V4.1-Flash ヘルパーティングする案内は、ウィンドウ内の文書で予告されたウィンドウ後の運用であり [10]、今週発生した出来事として書かない。ウィンドウ内の料金改定（9 月 10 日 4 時から有効、ピーク外は半額の時間帯あり）は別に発生した事実として扱い、トークン単価表の詳細は本号の検証範囲外であることを添える。V4.1-Pro のリリース日は資料に見当たらない。

比較と日付の境界

テスト主体の名称は明かされていない。9 月 14 日の切り替えは今後の運用であり、今週の出来事ではない。単価表の詳細は本号の検証範囲外である。

X / Community observation — context only

9 月 10 日 6 時 10 分（世界時）の公式発信に、独立したテストや計測の報告が重なる様子が観察される [11, 12]。うかがえるのは導入や計測への関心であり、性能や料金の根拠にはならない。

5 Coding Efficiency Pushes

FRONTIER CODING

SWE-2、コーディング性能とコスト効率を両立

9 月 10 日の SWE-2 を、ベンチマークスコアとステップ数、コストの 3 方向から、ベンダー側の数値の範囲でたどる。

9 月 10 日、Cognition はコーディングモデル SWE-2

を発表した [13]。Kimi K3（2.8T パラメーター）をベースに強化学習を重ねたモデルで、FrontierCode 1.1 メインテーブルで 50.0%、Fable 5.1 の 50.9% に 1 ポイント差まで迫りながら 64% 低コストとされる。Astra の 53.3% には数ポイント差で 4 分の 1 のコストという対比も示される。DeepSWE 1.1 で 73.0%、Terminal-Bench 2.1 で 92.8%、Terminal-Bench 4 で 27.3% が掲げられる。SWE-1.7 との比較では平均ステップ数 58% 減・コスト 81% 減も示される。いずれもベンダー側が計測または収集した数値であり、独立した再現はない。コストは定価ベースに割引を織り込む計算で、タスク分布による変動はベンダー側の説明として受け止める。K3 の伸びしろに関する解釈もベンダー側の見方として扱う。

提供形態は Devin Desktop と CLI から始まり、Web と Fusion へ拡大する計画とされる [13]。タスク難易度の設定やハーネス開示の付録がある。比較方法の注記では、公開値のある組み合わせはその値を引き、なければ開発元のハーネスで計測するとされ、Anthropic は Claude Code、OpenAI は Codex、xAI は Grok Build、オープンモデルは Devin CLI とされる。学習手法の節（ペナルティや報酬設計、ロールアウト、学習データ）はベンダー側の記述として扱い、再実行の証拠にはしない。

コーディング評価の境界

数値はベンダー側が計測または収集したものであり、独立した再現はない。コストは定価ベースの計算である。

6 Open Models Go Vertical

OPEN VERTICAL

オープンモデルの 3 方向

9 月 7 日から 10 日の 3 件の公開を、オンデバイス用途、翻訳特化、画像・動画対応の 3 方向から、日付とライセンスの精度とともに示す。

OpenBMB の MiniCPM5-2B は、オンデバイスやローカル実行を狙う 20 億級の密な言語モデルである [14]。Llama 系の標準的な構成で 42 層、コンテキスト長は約 13 万トークン、Apache-2.0 ライセンスで公開される。同規模比較での平均 53.9、LiveCodeBench 69.1、AIME 86.5、MATH-500 94.6、

SWE-bench Verified 46.4、GAIA 88.7、tau2 Telecom 97.1、BFCL 66.6 といった値はモデルカードの数値であり、外部の再現はない。vLLM・SGLang・llama.cpp・Transformers でフォークなしに動作し、ツール呼び出しの受け口や UltraData ファミリーの公開、強化学習とモデル統合の改善が添えられるが、量子化やチップごとの性能はベンダー側の説明にとどめる。9月7日という日付はレシピ公開や周辺記録からの帰属であり、時刻レベルの断定はしない。

9月10日、CohereはNorth Small Translate 1.0を公開した [15]。翻訳に特化した MoE モデルで全体 218B、動作パラメーター 25B、入出力とも 16K トークン、50 以上の言語をサポートするとされる。ライセンスは研究用途の CC BY-NC 4.0 で、商用利用には別途 Vault ライセンスが必要とされる。RWS との協業、Hugging Face リポジトリやドキュメント、テクニカルレポートが添えられる。WMT26 全言語で 83.60（エージェント型で 84.36）、DeepL・Google 翻訳・Gemma・GLM・Mistral との対比が示されるが、評価には GPT-5.6 Sol が評価用モデルとして使われ、サンプリングや言語別の詳細表は本号の検証範囲外であり、独立した確認は行っていない。スループットやコストの内訳（Gemma 31B 比 1.4 倍、長文脈 48.9、タスクあたりコストなど）は社内計測として受け止める。

InclusionAI の Ling-3.0-flash-VL は、Ling-3.0-flash をベースに画像・動画理解を追加したネイティブマルチモーダルモデルである [16]。全体 124B、トークンあたり 5.5B が動作し、最大 256K トークンのコンテキスト、画像・動画入力に対応し、MIT ライセンスで公開されるとされる。Artificial Analysis Intelligence Index で 42（ベースの flash から 4 ポイント増）、理解・推論・行動の 3 軸評価や SGLang・vLLM 向け手順が添えられるが、数値はモデルカードの報告であり独立した再現はない。リポジトリ作成は9月4日、FP8版は9月8日、モデル紹介ページの掲載は9月10日という周辺記録で押さえ、時刻レベルの断定はしない。動画対応の有効性はベンダー側の説明として扱う。

オープンモデルの境界

数値はモデルカードの報告であり、外部の再現はない。日付は帰属の精度ごと扱い、時刻レベルの

断定はしない。ライセンス範囲を事実と混同しない。

X / Community observation — context only

オンデバイスでの試行や速度の報告が、9月7日の公式発信の後に独立した手で重なる様子が観察される [17, 18]。うかがえるのはローカル実行への関心であり、性能や対応チップの根拠にはならない。

7 Threat Report in Context

SAFETY BOUND

Anthropic 脅威レポート、8か月の悪用事例を技術的安全の文脈に

9月10日の脅威レポートを、今週の技術的安全面を読み解く材料として、代表的事例という留保とともに位置づける。

9月10日、Anthropicは8か月分(2025年12月から2026年8月)の脅威レポートを公開した [19]。対象の危害領域は7分野で、使用されたモデルはHaiku・Sonnet・Opusに限られ、蒸留の1件を除きFable・Mythos級は関与しないとされる。高度な攻撃が必ずしも高度な攻撃者を必要とせず、マルチエージェント構成で自律性が高まり、人間が標の設定と情報持ち出しの確認を担う構図が示される。レポート自体の公開日は通常ウィンドウ内の出来事として扱う。

取り上げられるのは、ロシア系とされる諜報活動、日和見的な窃取集団、脆弱性探索を請け負う組織、AI サプライチェーンの窃取・転売などで、いずれも検知後の無効化、防御強化、当局共有が添えられる [19]。生物学研究に関わる5件も無効化した悪用の中に数えられるが、生物兵器の製造や意図の確立を主張するものではない。いずれもベンダー側の調査報告であり、攻撃者帰属は公開報道と整合的とされる範囲で受け止め、ここで独自に検証しない。本号ではレポート要約の範囲を扱い、全文PDFやIOC（侵害指標）までは扱わない。9月11日の時系列にある蒸留関連の固有名詞の詳細はウィンドウ後の速報として切り分け、通常ウィンドウの事実には入れない。代表的事例は全体の縮図ではないという留保を保つ。

安全面の読み方の境界

全文や IOC は本号の扱う範囲外である。攻撃者帰属はベンダー側の調査報告である。速報の詳細は通常の事実に入れない。

8 Week in Review

WEEKLY SYNTHESIS

今週は、プラットフォームで効率が伸びた

金融業務向けパッケージ、音声レイヤーの分離、実行基盤の前進、高効率モデルのベンダー報告、コーディングのコスト性能、3方向のオープンモデル、安全面の文脈が同時に前景化した。

今週何が変わったか

1. **金融・音声・実行基盤が分かれて登場した。** 9月10日の3つの独立したリリースは、Astra を中核とする金融業務向けパッケージ、バックエンドに処理を委ねる独立した音声レイヤー、Codex のエージェントハーネスを束ねるパブリックベータの API である。いずれもベンダー側の一次発表の範囲で読み、互いの仕様として混ぜない。
2. **高効率モデルとコーディングモデルと実行基盤がコストとともに示された。** DeepSeek V4.1-Flash の上位モデル超えはベンダー報告として受け止め、9月14日のルーティング変更は今後の運用として分ける。SWE-2 のスコアとステップ数とコスト、Fusion のベンチマークごとの差分（39%は最大値、公開は9月11日17時（世界時）で通常範囲）は数値表の範囲でたどる。
3. **3方向のオープンモデルと安全面の文脈が添えられた。** MiniCPM5-2B のオンデバイス狙い（9月7日帰属）、North の翻訳特化（評価用モデルとライセンスの留保付き）、Ling の画像・動画対応（日付の段階付き）を、モデルカードの報告として切り分け、9月10日の脅威レポートを技術的安全面を読み解く材料として代表的事例の留保とともに置く。

なぜそれらが一緒に重要なのか

効率を垂直方向に伸ばす動きが、プラットフォームレイヤーでそろって具体化した点にある。金融業務の垂直統合、音声レイヤーの分離、実行基盤の整備は、同じ日の別々のリリースであり、単一の Astra の物語に束ねられない。高効率モデルの比較、コーディングのコスト、実行基盤の効率、3方向のオープンモデルの数値は、それぞれ異なる主体と条件の報告であり、単一の効率や順位の物語に束ねられない。脅威レポートの文脈を添えることで、今週の伸びを安全面の留保とともに読める。ライセンスを事実と混同せず、モデルごとの数値と利用条件、報告主体を切り離さない読みが条件になる。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作パラメーターの小ささを共通効率へ、利用条件の表示を共通ライセンスへ、速度やスコアを横断的な順位へ自動的に変換してはいけない。

Weekly Community Movement — context only

公開投稿では、金融・音声・実行基盤、高効率モデル、コーディング、オンデバイスのモデルへの関心が、公式発信に独立した言及が重なる形で観察される。これは今週の関心の広がりを示す背景であり、仕様や性能、提供条件、互換性を証明するものではない。範囲前の持ち込み1件、締め切り後の速報20件は通常の集計には含めない。

次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。金融業務向けの価格や利用枠、提供地域、音声の対応言語や電話の範囲、Agents API の正式提供時期やレート制限・提供地域、V4.1-Pro のリリース日と切り替え後の動き、SWE-2 の再現、Fusion の未検証の組み合わせ、MiniCPM のチップごとの動作、North の言語別詳細表、Ling の時刻精度、脅威レポートの全文や IOC はまだ詳細化されていない。さらに、ベンダーや研究機関の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。ベンダーが示す速度、報道が伝える仕様、研究機関が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能順位へまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。

Sources & Limitations

Primary sources consulted

9月10日のOpenAIの3件の一次発表（金融業務向け、GPT-Live-1、Agents API）、9月10日のDeepSeek V4.1-FlashとAPI文書、9月10日のCognition SWE-2、9月11日のFusion（公開時刻は9月11日17時（世界時）に通常の範囲と確認）、9月7日帰属のMiniCPM5-2B、9月10日のNorthと翻訳技術レポート、9月10日掲載のLing-3.0-flash-VL、9月10日のAnthropic 脅威レポートを範囲として読んだ。本号では全文PDFやIOC、ベンチマーク手法・図表の詳細までは扱わず、その範囲を超える主張は行わない。

Temporal boundary

通常の範囲は2026-09-04 18:00から2026-09-11 18:00（いずれもAmerica/New_York、終了時刻は含まない）。範囲前の持ち込み1件、締め切り後の速報20件は通常の集計には含めない。9月14日のルーティング変更は範囲内の文書で予告された範囲後の運用であり、今週の出来事ではない。Lingのリポジトリ作成（9月4日）、FP8版（9月8日）、モデル紹介ページの掲載（9月10日）は段階として押さえ、時刻レベルの断定はしない。

Vendor-reported boundary

測定値や比較、コスト、スループット、ライセンスの説明は、ベンダーやモデルカード、パートナー連携の報告として受け止め、独立した再現とは切り分ける。DeepSeekの上位モデル超えはベンダー報告であり、テスト主体の名称は明かされていない。Fusionの39%は評価表の中の最大値である。Northの評価には評価用モデルが使われ、言語別の詳細表は本号の検証範囲外であり、独立した確認は行っていない。脅威レポートの攻撃者帰属はベンダー側の調査報告である。

Community observation boundary

公開投稿の台帳（45件の直接URL：通常24件、範囲前の持ち込み1件、速報20件）は関心の方向を示す背景であり、仕様やベンチマーク、日付、利用条件、価格、ライセンス、アーキテクチャ、公開事実の根拠にはならない。行単位の台帳を正とし、要約文の数えに頼らない。

What was not elevated

噂の段階の話題は今週の技術的な出来事として取り上げない。二次的な言説は技術的な重みを持たせず、本号の主張には載せない。画像・動画系統は調べた範囲では静かであり、存在しないことの証明とはしない。

References

- [1]OpenAI. *Introducing ChatGPT for Financial Services*. Primary official source; Financial Services on Astra with data, benchmark and governance bounds. Pricing, entitlement limits and region availability not stated. OfficeQA methodology not reviewed here. All benchmark figures vendor-reported without independent reproduction. URL: <https://openai.com/index/introducing-chatgpt-financial-services> (visited on 09/19/2026).
- [2]*OpenAI official post Sep 10*. Public direct post; ordinary-window official signal. Context-only observation of release attention, not evidence of specifications or measurements. URL: <https://x.com/OpenAI/status/2098118191029624911> (visited on 09/19/2026).

- [3] *Independent Astra usage note Sep 10*. Public direct post; ordinary-window independent observation. Context-only signal of usage attention, not evidence of specifications or measurements. URL: <https://x.com/cuicuihai/status/2098199705452974289> (visited on 09/19/2026).
- [4] OpenAI. *Build more natural voice experiences with GPT-Live-1 in the API*. Primary official source; separate full-duplex voice layer delegating to Astra or third-party backends, not an Astra package. Bench methodology, language and telephony scope not fully bounded. All eval figures vendor-reported. URL: <https://openai.com/index/introducing-gpt-live-1-in-the-api> (visited on 09/19/2026).
- [5] OpenAI. *Introducing the Agents API*. Primary official source; managed harness in public beta with Astra as configuration example, not proof the API is an Astra package. GA timeline, rate and region limits not stated. Partner and customer claims vendor-described. URL: <https://openai.com/index/introducing-the-agents-api> (visited on 09/19/2026).
- [6] Cognition. *Introducing Fusion in Devin Desktop and CLI*. Primary official source with first-party page metadata establishing 2026-09-11T17:00:00Z ordinary publication. Partnered evaluation vendor-presented. 39 percent is a table maximum, not uniform improvement. Untested pair generalization not established. URL: <https://cognition.com/blog/local-fusion> (visited on 09/19/2026).
- [7] Cognition official post Sep 11. Public direct post; ordinary-window official signal for coding and harness releases. Context-only observation, not evidence of scores or costs. URL: <https://x.com/cognition/status/2098445562404024343> (visited on 09/19/2026).
- [8] *Independent Devin Voice reaction Sep 10*. Public direct post; ordinary-window independent observation. Context-only signal of attention, not evidence of specifications. URL: https://x.com/Chris_Wozniczek/status/2098199592617783674 (visited on 09/19/2026).
- [9] DeepSeek. *Introducing DeepSeek-V4.1-Flash: smarter, faster, more efficient*. Primary official source; architecture and model claims as stated. Ahead-of-Pro comparison vendor-reported with unnamed third parties and no independent reproduction. Sep 14 routing is a future operation announced in-window. Benchmark methodology beyond vendor summary not reviewed here. URL: <https://www.deepseek.com/en/news/deepseek-v4-1-flash/> (visited on 09/19/2026).
- [10] DeepSeek. *DeepSeek API docs news 20260910*. Primary official docs; in-window pricing and economics separate from future Sep 14 routing. Per-token table values in images not fully reviewed here. V4.1-Pro launch date not in source. URL: <https://api-docs.deepseek.com/news/news260910/> (visited on 09/19/2026).
- [11] DeepSeek official post Sep 10. Public direct post; ordinary-window official signal. Context-only observation, not evidence of benchmarks or pricing. URL: https://x.com/deepseek_ai/status/2097930608790167907 (visited on 09/19/2026).
- [12] *Independent V4.1-Flash test note Sep 10*. Public direct post; ordinary-window independent observation. Context-only signal of testing attention, not independent verification of benchmarks. URL: <https://x.com/UnslothAI/status/2097947144351252497> (visited on 09/19/2026).
- [13] Cognition. *Introducing SWE-2: Pushing the Pareto Frontier*. Primary official source; benchmark and cost framing vendor-reported. Harness and methodology reproduction gaps remain. Cost figures assume list pricing with task-distribution sensitivity vendor-described. URL: <https://cognition.com/blog/swe-2> (visited on 09/19/2026).
- [14] OpenBMB. *MiniCPM5-2B model card*. Model-card source; card-reported benchmarks with on-device relevance. Independent reproduction absent. Release-day Sep 7 attribution from recipe and secondary coverage without hour precision. Quant and chip behavior vendor-described. URL: <https://huggingface.co/openbmb/MiniCPM5-2B> (visited on 09/19/2026).

- [15]Cohere. *Introducing North Small Translate*. Primary official source; judge-model evaluation bound with GPT-5.6-Sol as judge. CC BY-NC research license with separate production implications. Throughput and cost internal tests not independently verified. URL: <https://cohere.com/blog/north-small-translate> (visited on 09/19/2026).
- [16]InclusionAI. *Ling-3.0-flash-VL model card*. Model-card source; multimodal facts bounded. Benchmark results card-reported. Early publication-hour precision unresolved with Sep 4, Sep 8 and Sep 10 phasing establishing relevance. URL: <https://huggingface.co/inclusionAI/Ling-3.0-flash-VL> (visited on 09/19/2026).
- [17]*OpenBMB official post Sep 7*. Public direct post; ordinary-window official signal. Context-only observation, not evidence of benchmarks or device behavior. URL: <https://x.com/OpenBMB/status/2096970974247956501> (visited on 09/19/2026).
- [18]*Independent local inference note Sep 10*. Public direct post; ordinary-window independent observation of local speed. Context-only signal, not independent verification of card figures. URL: <https://x.com/0x7c0x80386/status/2098156035739648416> (visited on 09/19/2026).
- [19]Anthropic. *Detecting and countering misuse of AI: September 2026*. Primary official source; Sep 10 ordinary report. Notable examples not representative of all incidents. Investigations vendor-reported. Full PDF and indicators not reviewed here. Sep 11 naming detail excluded as late-breaking. URL: <https://www.anthropic.com/threat-intelligence-report-september-2026> (visited on 09/19/2026).