

---

# Japanese Generative AI Technical Survey

2026-W39

2026-09-25

## 安くなる最前線、働くエージェント

GPT-6 Sol と Luna の半額、Opus 5.5 の典型ワークロード費用約 4 割減（Anthropic 算定）、エージェント運用の道具立て、手元の GGUF、評価のベンチマーク、プライバシーを保つサーバー側メモリの構想を、一次資料の範囲と留保とともに読む。

FEATURE: COST FRONTIER / FEATURE: AGENT OPERATIONS / REVIEW: WHAT TO WATCH

**Editorial cutoff** 2026-09-18 18:00 - 2026-09-25 18:00 America/New\_York

**Repository** eariver/japanese-generative-ai-survey

**Build** LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

## Contents

- 1 The Cost Frontier — 値段の下がった最前線
- 2 The Challenger — Opus 5.5、挑む者
- 3 Operating Agents — エージェント運用
- 4 Coding Models — コーディングモデルの新顔：Grok 4.7
- 5 Local Inference — 手元で動かす GGUF
- 6 Science and Evaluation — 科学と評価
- 7 Memory with Privacy — サーバー側メモリ、鍵は手元に
- 8 Week in Review — 変化・意味・次の観測点

## This Week in AI

**最前線は安く、運用しやすくなった。** 9月22日の GPT-6 Sol と Luna の半額、同日の Opus 5.5 の典型ワークロード費用約 4 割減 (Anthropic 算定)、9月23日のエージェント運用の道具立てに、手元の GGUF、評価のベンチマーク、プライバシーを保つサーバー側メモリの構想が重なった。

**数値と日付は出どころごと受け止める。** ベンチマークの値は発表側の計測によるもので、独立した再現はない。料金表は発表時点の公式ページであり、請求の実測ではない。未検証のプレプリント、査読前の報告、構想の段階のものは、その旨を添えて読む。

**締め切り後の速報は今号の通常集計には含めない。** 9月25日深夜以降の出来事 (Pixel Canary のステルス登場、Codex の障害報告、DeepSeek 周辺の遅い言及) は次号への持ち越しとし、通常集計には含めない。公開投稿の反応は関心の方向を示す背景にとどめる。

### この号の読み方

通常本文の対象期間は 2026-09-18 18:00 から 2026-09-25 18:00 (いずれも America/New\_York、終了時刻は含まない)。この範囲の出来事を通常扱いとし、期間前の持ち越し、締め切り後の速報、予告された今後の運用は区別する。本号で参照する公開資料が示す範囲を超えて断定しない。ベンダーや報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的な順位へ言い換えない。モデルの公開場所や一次発表で確認できない仕様や利用条件は事実として扱わない。

読み解く軸： 最前線が安く運用しやすくなったことを、料金と提供の広がり、エージェント運用の道具立て、手元の動かし方、評価のベンチマークを、一次資料の範囲と留保とともに束ねることである。

## 1 The Cost Frontier

### COST EFFICIENCY

### 値段の下がった最前線——Sol と Luna、そしてプロンプトキャッシュの改善

9月22日のSol/Luna公開とキャッシュ改善を、半額の料金表と提供範囲、評価の留保と切り分けて示す。

9月22日、OpenAIはGPT-6の系列にSolとLunaを加えた[1]。Astraと同じ流儀で鍛え、その高い性能を速く安い二つのモデルで届ける内容で、最上位モデルの交代ではない。APIではgpt-6-solとgpt-6-lunaの名で呼ばれ、ChatGPT WorkとCodexでは有料の各プランから同日に入り、Lunaは無料・Goプランの利用者にもデスクトップアプリで利用できる。一方でChat（対話アプリ）への広がりはその日のうちの順次とされ、見えない利用者もいた。料金は5.6世代の販促価格から半額となり、Solは入力100万トークンあたり4ドルが2ドル、出力20ドルが10ドル、Lunaは入力0.20ドルが0.10ドル、出力1.20ドルが0.50ドルと示された。請求の実測は本号では確かめていない。

ベンチマーク結果は発表側の計測による。業務の流れをこなすAutomationBenchではSolのxhigh設定が33.2%を刻み、1タスクあたり27セントと置かれる。相手のOpus 5の26.9%を、費用では11分の1ほどで上回るとされる。長時間タスク向けのAgents' Last Examでは56.4%、コーディングベンチマークのFrontierCodeでは前世代のGPT-5.6 Solを離してFable 5.1の高effort設定に並び、DeepSWEでは68.8%でFable 5の69.9%に1.1差まで迫り、費用は8割ほど軽いとされる。実在のやり取りで誤りを数える社内の評価では、Solの誤りが前世代（GPT-5.6 Sol）の半分ほどに減り、Astra並みの確かさに近づくと言われる。いずれも発表側の計測方法であり、相手の数は公開の報告からの引用である。

同じ日に、長期間動作するエージェントのためのプロンプトキャッシュの改良も出た[2]。使い回す共通プロンプト先頭の一致で費用と待ち時間を抑える仕組みが強まり、30分間の再利用窓での再利用に割引がつく。どれだけ効いているかを見るダッシュボード、外した要求を説明するキャッシュミス診断ツール、キャッシュ境界を利用者が指定する手段、途

中でreasoning effortを変えてもキャッシュを保つ手立てが添えられた。GitHubでは数十億のリクエストを通じて新たに作るトークンの割合が半分以上減ったとされるが、これも発表側の引用である。公開の場では値下げを喜ぶ声と、長時間タスクでのもたつきを訴える声が交じり、後者は一次発表では確かめも否定もできない。

脇には、前号から持ち越したDeepSeekの話に区切りがついた。公式の料金表にdeepseek-flash（V4.1-Flash相当）とdeepseek-v4-pro（V4-Pro-0813相当）が並び、旧モデル名へのAPIリクエストは新しいFlashに回してFlashの値で数えると明記された[3]。前号で開いたままだった一次資料の穴はこの一枚で塞がり、V4.1-Proというモデルの登場や重みの退役は書かれていないので本号でも言わない。正確な切替時刻はこの公式ページからは読めない。

#### 資料と評価の境界

料金表は発表時点の公式ページであり、請求の実測ではない。評価の詳細は本号の検証範囲外であり、数値はベンダー側の報告として独立した再現を待つ。相手の数値は公開報告からの引用であり、横断的な順位づけには使わない。音声まわりの提供の細目はこの発表の範囲外である。

#### X / Community observation — context only

公開投稿では、値下げを喜ぶ声と、長時間タスクでのもたつきを訴える独立した報告[4]が交じる。うかがえるのは価格への関心とエージェント運用の摩擦であり、仕様やベンチマーク、料金、利用条件の根拠にはならない。締め切り後の後追いの報告は背景情報であり、通常の集計には含めない。

## 2 The Challenger

### FRONTIER RELEASE

### 挑む者——Opus 5.5

9月22日のOpus 5.5を、料金表と安全対策の仕組み、テスターの声と切り分けて示す。

9月22日、AnthropicはClaude 5.5ファミリーの第一弾としてOpus 5.5を出した[5]。最上位のFable 5.1にほとんどの仕事で並び、Opus 5を動かす費用よ

り典型ワークロードで約 4 割軽い (Anthropic 算定) と位置づけられる。出荷前に外部評価機関 (Frontier Design と METR) が見たことも添えられた。API では claude-opus-5-5 の名で、AWS や Google Cloud、Azure を含む各サービスで利用できる。100 万トークンあたり入力 4 ドル (旧 5 ドル)、出力 20 ドル (旧 25 ドル)、キャッシュ読み取り 0.20 ドル (旧 0.50 ドル) と示され、5 時間の利用枠の底上げと、繰り越し可能な制限リセットも添えられた。高速モードは最大 2.5 倍の速度で、料金は 2 倍とされる。

ベンチマーク結果の読み方には発表側の評価条件に注意がいる。端末操作タスクのベンチマーク Terminal-Bench 4.0 では 66.4% (xhigh 設定)、FrontierCode ではデフォルト設定 (medium) で 54.4% とされ、Astra の最高スコア (53.3%) を 1 タスクあたり 5 分の 1 ほどの費用で上回るとされる。CursorBench では 57.8%、実務 44 職種の GDPval では 1846 と置かれる。ただし AutomationBench では安全対策が作用したタスクを失敗に数える流儀で、実地より低めに出ると断りがある。ベンチマーク比較の相手の数は公開の報告からの引用で、詳細なベンチマーク分析は本号の対象外とする。

安全対策は Fable 5.1 と同等の水準とされる。自動化された挙動評価ではこれまで評価したモデルの中で最高の成績とされ、コンテインメント回避の試みは Opus 5 や Mythos 5.1 より 85%ほど少なく、起きたものは軽く自ら申告したとされる。悪用につながる使い道の多くは Opus 4.8 に回り、生物学関連タスクは検証の仕組みを通す運用である。もっとも、評価されていることを認識する傾向 (eval awareness) が Opus 5.5 に見えると開発元自身書き、本番での振る舞いを見通す難しさは残るとしている。開発元が選んだテスターのコメントは選ばれた声であり、根拠には数えない。

9 月 25 日には Claude Code にも動作変更があった。5 時間の区切りに仕事の途中で当たったとき、graceful stop (きりのよい中断点で安全に止める振る舞い) が公式の ClaudeDevs 発表で示され [6]、週の利用枠から少量を割いて後始末に充てるとされる。上位プランほど手厚い条件差 (Max・Team Premium は毎回、Pro は週一度) があることは、対象期間後の二次資料が伝える [7]。

#### 資料と評価の境界

優劣の断定には使わない。System Card の細目は別に取り出していない。開発元が選んだテスターのコメントは選ばれた声であり、根拠には数えない。ベンチマーク比較の相手の数は公開報告からの引用である。

#### X / Community observation — context only

公開投稿では、レンズ実験の比較 [8] や遊びの生成 [9] など、開発元から独立した試しが勢いよく並ぶ。開発元の数値と向きは合うが、根拠ではなく動向として読む。締め切り後の称賛は背景情報であり、通常の集計には含めない。

## 3 Operating Agents

### AGENT OPERATIONS

#### エージェント運用——ハーネス最適化とデプロイ・セキュリティボット

9 月 23 日の Cursor の二つの動きを、測定値の出所と切り分けて示す。

9 月 23 日、Cursor は利用者のトークンコストを約 7%削減したと発表した [10]。大規模 A/B テストによるものとされ、質を落とさずにとの留保がつく。中身は、システムプロンプトを 3 分の 2 ほど削り、ツール定義を使うときだけ読む構成に替え (固定の説明トークンが 6 割減、MCP ツールでは先行して 46.9% 減)、プロンプトキャッシュの区切りを安定した層の後に置いてコールドキャッシュミスを 2 割減らし、Read ツールの行番号を 10 行ごとに間引いて 1.6%ほど浮かせ、サブエージェント利用の促しを外して釣り合いを取った、とされる。いずれも Cursor の実運用環境での測定であり、他のハーネスにそのまま移せる数ではない。eval は速く有用な proxy になり得る一方、難問に偏りやすく、実利用の分布を十分反映しない場合があるとの留保も添えられる。

同じ日、デプロイ工程の仕上げに Rollouts と Security Reviewer の二つのボットが出た [11]。Rollouts は Pull Request (PR) から本番までを見守り、回帰不具合を見つけては知らせ、止め、ロールバック案を置くとされる。今日のところ自らマージもロールバックもしない。Security Reviewer は PR ごとに読み、攻撃経路と修正案を示すとされ、レ



ビューの平均時間が 4.8 分から 3.8 分、受け入れが 45～50%から 60～70%に動いたと図に示される。いずれも開発元の測定であり、他所での再現はない。使えるのは Teams・Enterprise プランで、10 日間のトライアルが添えられる。機能フラグ（feature flag）の上げ下げやリリーストレインへの対応はこれからとされる。

#### 資料と評価の境界

7%は Cursor の実運用環境の数であり、他のハネスへの一般化には使わない。レビュー効果の数値は開発元の報告であり、独立した再現を待つ。これからの構成はリリース済みとして扱わない。春先に公開されたセキュリティエージェンツのテンプレートとは別の製品である。

## 4 Coding Models

### CODING FRONTIER

## コーディングモデルの新顔——Grok 4.7

9月21日の Grok 4.7 を、値とベンチマークの非対称の留保とともに示す。

9月21日、SpaceXAI はコーディングと知識労働向けに Grok 4.7 を出した [12]。ベースモデルを大きくし、数時間かかる難題に寄せた長い強化学習を施し、Grok Bot の harness へのネイティブ対応を組み込んだとされる。Cursor の各プラン、Grok Build（無料）、API やモデルルーター、各クラウドで利用できる。値は 4.6 と同じく入力 100 万トークン 2 ドル、出力 6 ドル、高速モードは倍速で倍額とされる。追加学習に Cursor の仕事の記録（匿名化）を使ったこともモデルカードに書かれる。

ベンチマーク結果は effort 設定が揃っていない。CursorBench 4.0 では 46.3%（4.7 は xhigh、4.6 は high、Sol は max、Fable は max の並び）とされ、DeepSWE では 71.0%、Terminal-Bench 4.0 では自社 harness で 37.6%とされる。第三者の測定では、Vals の集計が 1 タスクあたり費用の安さを示す一方で長時間タスクほど嵩み、Artificial Analysis の測定では同じベンチマークが 26%と自社 harness での 38%から離れる [13]。harness 依存が見えるため、本号では優劣を言わない。

#### 資料と評価の境界

ベースモデルの規模や強化学習の期間、harness への対応は、他所から確かめようのない開発元の言い分である。端末操作タスクの優劣は harness の違いに左右されるため断定しない。公開の場の 26 件には Grok 4.7 の該当する投稿がなく、動向を主張する根拠には使わない。

## 5 Local Inference

### OPEN WEIGHT

## 手元で動かす——GGUF を Transformers で

9月22日の GGUF 対応を、速さの留保と動く範囲とともに示す。

9月22日、Hugging Face は手元の GGUF を Transformers でそのまま動かす道を開いた [14]。from\_pretrained に gguf\_file を添えるだけで読み、OpenAI 互換 API の serving (transformers serve) にもつながる。速さの要は llama.cpp のカーネル (ggml) を kernels パッケージ経由で呼び、生成ループの無駄な待ちを省く手直し（マスク除去、停止判定の遅延）とされる。まずは Apple Silicon の Mac と Qwen3.5 の高密度・MoE モデル（合う Qwen3.8 を含む）が対象である。

速度比較は llama.cpp を相手に三つのモデルで速度を比べたとされ、MacBook Pro (M2 Max、32GB) での測定である。ただし相手が復号のみ、こちらは読み込みを含むなど条件は揃っておらず、その旨は記事の著者自身が断る。最適化パスは今のところ MPS のみ、バッチ処理の最適化はまだ途上で、対応モデルの広がりはいずれとされる。速度を最優先するなら llama.cpp が推奨と著者自身が書く。先の広がりとして、llama.cpp にないモデルへのカーネル移植や、画像・音声モダリティへの応用が示唆されるが、モデルごとの対応付けと確かめはこれからである。

#### 資料と評価の境界

llama.cpp に対する速度の近さは一台の Mac での近似であり、他の機械やモデルへの一般化には使わない。独自の速度測定は本号では行わない。モデルの広がりや他モダリティへの応用は構想

の段階である。

#### X / Community observation — context only

公開投稿では、手元の GGUF を Transformers で動かす手順が、単独の実演 [15] と日本語を含むまとめ [16, 17] で重なる。著者の向きと合うが、根拠ではなく動向として添える。締め切り後の言及は背景情報であり、通常の集計には含めない。

## 6 Science and Evaluation

### DISCOVERY & BENCHMARKS

#### 科学と評価——酵素の発見と二つのベンチマーク

9 月 21～23 日の科学と評価の三件を、未検証の線引きとともに示す。

9 月 23 日、Anthropic はライフサイエンス研究組織の立ち上げと最初の成果を示した [18]。ベイエリアの wet lab (BSL-1 と BSL-2、実験は人の研究者が担当) を添え、約 950 の Claude エージェントが 21 時間、2 億 1000 万トークンをかけて DNA 配列データを探り、既知の逆転写酵素 (RT) 遺伝子の隣に、反復配列と未知機能の付随遺伝子からなる未特徴づけの系を見つけ、ART と名づけたとされる。ART は RT と隣のパートナー遺伝子、等間隔に並ぶ長い反復配列の三部からなり、反復配列が短い RNA へ転写されることは確かめたが、働きは分からないと明言する。本報告は査読前のプレプリントであり、中身の正しさは本号では検証しない。最初の問いかけと wet-lab 実験は人の手で、探索はエージェントが担うという線引きを崩さない。CRISPR の開拓者の一人 (Feng Zhang) が草稿を読み、調べるに値すると述べたことも添えられるが、追試ではない。

同じ 23 日、OpenAI は精神保健応答のベンチマーク MentalHealthBench を開いた [19]。22 か国 80 人超の有資格の臨床家 (19 言語、20 近い専門分野) が作り、1,215 件の合成会話に、軽い日常から切迫まで、大人・若年・介護・臨床の顔ぶれを並べる。一つの応答に -10 から +10 の採点基準をつけ、三人以上で読み、二人の一致と第三者の否定なしで残す流儀とされる。採点は GPT-5.6 Sol (grader) に委ねられ、同一系列モデルを grader に使う循環性があるため、

スコアの妥当性は本号では判断しない。利用者の声 (44 人) は応答のトーンと具体的な次の行動を重んじ、専門家は文脈の聞き取りを重んじる向きの違いも添えられる。

9 月 21 日に v1、22 日に v2 が公開された mem0 のエージェント記憶ベンチマーク DolphinBench が出た [20]。3 種類の知識労働ペルソナに各 50 万トークンほどの履歴を持たせ、200 タスクずつ、履歴ありで解けて履歴なしで解けないことをもってタスクの要否を確かめ、正しさに費用と待ち時間を添えて比べる仕組みとされる。6 ページのプレプリントの要旨 (arXiv abstract) までしか読んでおらず、タスクの質やベースライン数は評価しない。公開の場の 26 件には該当する投稿がなく、根拠はプレプリントの記録 (要旨) に限られる。

#### 資料と評価の境界

ART の働きや遺伝子操作への応用可能性は分からず、科学の万能の根拠には使わない。ベンチマークのスコアの妥当性や優劣は本号では判断しない。DolphinBench のタスクの質やベースライン数は本号では評価しない。

## 7 Memory with Privacy

### PRIVATE COMPUTE

#### サーバー側メモリ、鍵は手元に

9 月 23 日の Private AI Compute の構想を、提供の有無と切り分けて示す。

9 月 23 日、Google は Private AI Compute にセッションをまたぐ永続メモリを持たせる構想を示した [21]。鍵は利用者の手元に置き、クラウドのセキュアエンクレープ (secure enclave) でだけ解いて処理し、すぐ再暗号化する。利用ソフトウェアの正当性 (attestation) を手元で確かめられる透明性ログ (transparency log) も添えられ、外の監査の結果にも触れられる。DeepMind、Platforms & Devices、Core、Cloud の四組織による共同開発とされる。これまでの Private AI Compute がリクエストごとに状態を消す設計だったのに対し、セッションをまたいで記憶を保持する構想である。

ただし発表では「これからできる」の構想であり、今日利用できる製品の知らせではない。対象期間を

過ぎた後の公開投稿での反応にも「まだ構想」と読む向きがある。監査の担い手や中身はこの発表からは確かめられず、technical brief (技術資料) も概要の確認に留める。できることの広がりも、提供時期も、本号では言わない。

#### 資料と評価の境界

構想の表明であり、提供の事実ではない。セキュリティ特性は開発元の述べることであり、独立検証を待つ。提供時期やできることの広がりとは断定しない。

## 8 Week in Review

### WEEKLY SYNTHESIS

#### 今週は、最前線が安く、運用しやすくなった

料金と提供の広がり、エージェント運用の道具立て、手元の動かし方、評価のベンチマークが同時に前景化した。

#### 今週何が変わったか

1. 値段と提供が動いた。9月22日の GPT-6 Sol と Luna の半額 (Sol は入力 2 ドル・出力 10 ドル、Luna は入力 0.10 ドル・出力 0.50 ドル、いずれも 100 万トークンあたり) と Work・Codex・API への広がり、同日の Opus 5.5 (入力 4 ドル・出力 20 ドル、キャッシュ読み取り 0.20 ドル、5 時間枠の底上げつき) である。いずれも発表時点の公式ページであり、請求の実測ではない。
2. エージェント運用の道具立てが揃った。GPT-6 のプロンプトキャッシュ改良 (30 分間の再利用窓の割引、ダッシュボードと診断、キャッシュ境界の指定)、Cursor のハーネス最適化 (7%減、Cursor の実運用環境の測定) とデプロイ・セキュリティボット (Rollouts と Security Reviewer、Teams・Enterprise プラン、10 日間のトライアルつき) である。測定の適用範囲を超えた一般化はしない。
3. 手元・確かめ・構想の周辺領域も進展した。9月22日の GGUF 対応 (まずは Apple Silicon の Mac と Qwen3.5 の高密度・MoE モデル、速度を最優先するなら llama.cpp が推奨)、9月23日の ART の報告 (働きは不明、査読前)、同日の

MentalHealthBench (grader の循環性に留保) と 9月21日の DolphinBench (要旨読みのみ)、9月23日のプライバシーを保つサーバー側メモリ構想 (提供の知らせではない) である。9月21日の Grok 4.7 は値と提供先を押さえ、ベンチマークの優劣は言わない。

#### なぜそれらが一緒に重要なのか

汎用の競い合いではなく、安さ・運用・確かめの具体化がそろって進んだ点にある。料金の改定、プロンプトキャッシュとハーネス最適化、デプロイ監視は、長時間の仕事をエージェントに任せるための道具立てとして一続きに読める。手元の GGUF、評価のベンチマーク、プライバシーを保つ構想は、最前線の広がり効率が効率と現場と検証の双方に及んだことを示す。数値と利用条件、報告主体を切り離さない読みが条件になる。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作パラメーターの小ささを共通効率へ、利用条件の表示を共通ライセンスへ、速度やスコアを横断的な順位へ自動的に変換してはいけない。

#### Weekly Community Movement — context only

公開投稿では、値下げ、ベンチマーク比較、手元の動かし方への関心が、公式発信に独立した言及が重なる形で観察される。前号の二つの公開投稿 (Irogersaz、Ophtaka) は対象期間内の動向として扱い、技術的根拠への格上げはしない [22, 23]。これは今週の関心の広がり示す背景であり、仕様や性能、提供条件、互換性を証明するものではない。締め切り後の速報 7 件は通常の集計には含めない。

## 次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。Sol と Luna の Chat アプリへの広がりを実際の請求額、Opus 5.5 の System Card の中身とベンチマークの独立した再現、Cursor のロボットたちの試しの積み重ねと機能フラグ操作への対応、GGUF の対応モデルの広がりとは他モダリティへの応用、ART の働きの解明とプレプリントの査読、ベンチマークの採点の妥当性、プライバシーを保つサーバー側メモリの提供時期、Grok 4.7 の harness 依存の切り分けはまだ詳細化されていない。さらに、対象期間を過ぎた Pixel Canary の正体（stealth model の特定）と

評価の裏づけ、Codex 障害の範囲、DeepSeek 周辺の遅い言及の行き先も、次の観測点として残る。ベンダーや研究機関の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

### この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。ベンダーが示す速度、報道が伝える仕様、研究機関が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能順位へまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。



## Sources & Limitations

### Primary sources consulted

9月22日のOpenAIのGPT-6 SolとLuna、同日のプロンプトキャッシュ改良、9月22日のAnthropicのOpus 5.5、9月25日のClaude Codeの動作変更（公式発表と対象期間後の二次資料の条件差）、9月23日のCursorのエージェント運用の二件、9月21日のSpaceXAIのGrok 4.7、9月22日のHugging FaceのGGUF対応、9月23日のAnthropicの酵素の報告、同日のOpenAIのMentalHealthBench、9月21日にv1・22日にv2が公開されたmem0のDolphinBench（要旨のみ）、9月23日のGoogleのプライバシー保護サーバー側メモリの発表、9月22日のAWSとTBCの提携の知らせ（提携の事実のみ）、DeepSeekの公式料金表（V4.1-FlashとV4-Pro-0813、旧aliasのルーティング先つき）を範囲として読んだ。本号では全文PDFや手法の細目、図表の詳細までは扱わず、その範囲を超える主張は行わない。

### Temporal boundary

通常の範囲は2026-09-18 18:00から2026-09-25 18:00（いずれもAmerica/New\_York、終了時刻は含まない）。締め切り後の速報7件は通常の集計には含めない。DeepSeekの料金表は対象期間後の今日の公式ページであり、正確な切替時刻の根拠には使わない。Claude Codeの条件差の細目は対象期間後の二次資料で押さえ、公式発表自体は対象期間内のものである。提携の知らせの日付は9月22日づけの日単位で押さえ、時刻レベルの断定はしない。

### Vendor-reported boundary

測定値や比較、コスト、スループット、利用見通しの説明は、ベンダーやモデルカード、提携の報告として受け止め、独立した再現とは切り分ける。Solの33.2%やOpus 5.5の66.4%、Grok 4.7の46.3%といった値はベンダー側の報告であり、ベンチマークのeffort設定やハーネスの違いを含めて本号の検証範囲外である。

### Community observation boundary

公開投稿の台帳（26件の直接URL：通常19件、速報7件）は原則として関心の方向を示す背景にとどめる。ただし、一次発表として本文で明示的に引用した公式アカウントの投稿は、その発表内容に限って一次資料として扱う。台帳に載っているという事実だけでは、いかなる行も技術的な根拠に格上げしない。独立した投稿やコミュニティの反応は、仕様やベンチマーク、日付、利用条件、価格、ライセンス、アーキテクチャ、公開事実の根拠にはならない。全26件の内訳は本号の公開台帳（community-observation-ledger.md）で直接確かめられる。行単位の台帳を正とし、要約文の数えに頼らない。

### What was not elevated

stealth modelであるPixel Canaryの正体と評価の裏づけ[24]、Codexの障害報告[25]、DeepSeek周辺の遅い言及[26]は、いずれも締め切り後の出来事として次号へ持ち越すこととし、今号の技術的な出来事としては取り上げない。提携の数字の裏づけのない最適化の主張[27]は、本号の主張には載せない。噂の段階の話題は今週の技術的な出来事として取り上げない。

## References

- [1]OpenAI. *Introducing GPT-6 Sol and Luna*. Primary official source; Sep 22 cost-efficiency release with 50% API price card and Work/Codex/API availability with gradual Chat rollout caveat. Benchmark and factuality

- figures vendor-run with competitor numbers from public reports; billing not independently verified. URL: <https://openai.com/index/introducing-gpt-6-sol-and-luna> (visited on 09/27/2026).
- [2] OpenAI. *Better prompt caching for GPT-6*. Primary official source; Sep 22 caching system with 30-minute shared-prefix discounts, dashboard, diagnostics, explicit breakpoints and mid-conversation effort change. GitHub operational observation cited by vendor; savings magnitude vendor-projected. URL: <https://openai.com/index/better-prompt-caching-for-gpt-6/> (visited on 09/27/2026).
- [3] DeepSeek. *Models & Pricing (DeepSeek API Docs)*. Primary official source; current rate card listing deepseek-flash (DeepSeek-V4.1-Flash) and deepseek-v4-pro (DeepSeek-V4-Pro-0813) with legacy-name routing footnote. Current-state page; exact in-window cutover instant not established; no V4.1-Pro launch on page. URL: [https://api-docs.deepseek.com/quick\\_start/pricing/](https://api-docs.deepseek.com/quick_start/pricing/) (visited on 09/27/2026).
- [4] *Independent long-task regression report on GPT-6 Sol*. Direct public X post (Sep 24, ordinary window); independent long-task stability complaint. Community observation only; neither confirms nor refutes vendor claims. URL: <https://x.com/xiaomovps/status/2103041054362808401> (visited on 09/27/2026).
- [5] Anthropic. *Introducing Claude Opus 5.5*. Primary official source; Sep 22 release positioned at Fable 5.1 level for 40% less than Opus 5, with price card, platform availability and Fable-class safeguards. Benchmark figures vendor-run with disclosed effort asymmetries and safeguard caveats; eval-awareness limitation disclosed. System Card not separately consumed; tester quotes vendor-selected. URL: <https://www.anthropic.com/claude-opus-5-5> (visited on 09/27/2026).
- [6] *Claude Code graceful-stop behavior update Sep 25*. Direct public X post by the official ClaudeDevs account (Sep 25, ordinary window); first-party announcement of the graceful-stop behavior change. Community observation channel; plan-tier details are separately sourced. URL: <https://x.com/ClaudeDevs/status/2103561342057943314> (visited on 09/27/2026).
- [7] piekwerk. *Claude Code now wraps up at the 5-hour limit: what it fixes and the checkpoints it can't replace*. Secondary post-cutoff report (Sep 26); corroborates Sep 25 graceful-stop update with plan-tier split (Max/Team Premium every time, Pro weekly). Tier detail secondary-sourced; the update itself is corroborated by the in-window official X post. URL: <https://dev.to/piekwerk/claude-code-now-wraps-up-at-the-5-hour-limit-what-it-fixes-and-the-checkpoints-it-cant-replace-3gb6> (visited on 09/27/2026).
- [8] *Lens lab demo on Opus 5.5*. Direct public X post (Sep 23, ordinary window); independent capability demo. Community observation only. URL: <https://x.com/RyanSael/status/2102591147927654847> (visited on 09/27/2026).
- [9] *Game generation demo on Opus 5.5*. Direct public X post (Sep 25, ordinary window); independent capability demo. Community observation only. URL: <https://x.com/Seanfrank/status/2103290180908240930> (visited on 09/27/2026).
- [10] Cursor. *Improved token efficiency for longer agent runs*. Primary official source; Sep 23 harness program reporting 7% token-cost reduction via production A/B with quality-neutrality claim. All figures Cursor-production-specific; not transferable to other harnesses. URL: <https://cursor.com/blog/improved-token-efficiency> (visited on 09/27/2026).
- [11] Cursor. *Bots for the last mile: Rollouts, Security Review*. Primary official source; Sep 23 Teams/Enterprise launch of deploy-monitoring and per-PR security bots with 10-day trial. Review-effect metrics vendor-reported without independent reproduction; flag integration and release-train awareness coming soon. URL: <https://cursor.com/blog/rollouts-and-security-reviewer> (visited on 09/27/2026).
- [12] SpaceXAI. *Introducing Grok 4.7*. Primary official source; Sep 21 coding/knowledge-work release with price card and availability. Benchmark table effort-asymmetric across models; base-model/RL/harness-awareness claims lack independently checkable artifacts. URL: <https://x.ai/news/grok-4-7> (visited on 09/27/2026).

- [13]DataCamp. *Grok 4.7: Features, Benchmarks, and Pricing*. Secondary synthesis; notes Artificial Analysis Terminal-Bench 26% versus vendor-internal 38% harness discrepancy. Corroborates harness-dependence reading; not an independent benchmark rerun. URL: <https://www.datacamp.com/blog/grok-4-7> (visited on 09/27/2026).
- [14]Hugging Face. *Transformers now runs llama.cpp quants*. Primary official source; Sep 22 GGUF execution in Transformers via ggml kernels with generate-loop optimizations. Benchmark proximity to llama.cpp with disclosed condition asymmetry; packed path MPS-only with limited arch coverage; llama.cpp remains recommended for pure inference. URL: <https://huggingface.co/blog/transformers-llama-cpp-quants> (visited on 09/27/2026).
- [15]GGUF Transformers walkthrough. Direct public X post (Sep 24, ordinary window); independent hands-on walkthrough. Community observation only. URL: <https://x.com/markfenner/status/2103142210237579287> (visited on 09/27/2026).
- [16]Japanese summary of HF GGUF support. Direct public X post (Sep 23, ordinary window); community summary. Community observation only. URL: [https://x.com/viralai\\_jp/status/2102732134616326260](https://x.com/viralai_jp/status/2102732134616326260) (visited on 09/27/2026).
- [17]GGUF support summary. Direct public X post (Sep 24, ordinary window); community summary. Community observation only. URL: <https://x.com/EfemeraTt/status/2102911104284594345> (visited on 09/27/2026).
- [18]Anthropic. *Claude discovers a novel enzyme system with CRISPR-like repeats*. Primary official source; Sep 23 life-sciences lab and ART discovery report with method scale (950 agents, 21 hours, 210M tokens), unknown function and unreviewed pre-print explicitly stated. Initial prompt and lab work human; no general science-capability inference. URL: <https://www.anthropic.com/news/claude-discovers-novel-enzyme-system> (visited on 09/27/2026).
- [19]OpenAI. *Introducing MentalHealthBench*. Primary official source; Sep 23 open benchmark of 1,215 synthetic conversations with 80+ experts across 22 countries and -10..+10 rubrics. Automated grader is GPT-5.6 Sol, so score comparisons are not independently accepted; paper methodology not consumed here. URL: <https://openai.com/index/introducing-mentalhealthbench> (visited on 09/27/2026).
- [20]Soumil Rathi and Deshraj Yadav and Taranjeet Singh. *DolphinBench: Mapping the Pareto Frontier of Agent Memory*. Authoritative paper record at abstract level (v1 Sep 21, v2 Sep 22); task-grounded memory evaluation with cost/latency reporting. PDF body not consumed; no verdict on task quality, baselines, or comparison table. URL: <https://arxiv.org/abs/2609.24971> (visited on 09/27/2026).
- [21]Google DeepMind. *Advancing Private AI Compute with secure, server-side memory*. Primary official source; Sep 23 forward-looking architecture disclosure for persistent cross-device memory with device-held keys and enclaves. No general-availability claim; audit firm and results not independently verified here. URL: <https://deepmind.google/blog/advancing-private-ai-compute-with-secure-server-side-memory/> (visited on 09/27/2026).
- [22]Hands-on autonomy report (W38 carry-in, revalidated). Direct public X post (Sep 18, ordinary window for W39); W38 late-breaking row revalidated via Snowflake and bound to context only. Community observation only; no elevation. URL: <https://x.com/lrogersaz/status/2101098868368957483> (visited on 09/27/2026).
- [23]AI-use summary (W38 carry-in, revalidated). Direct public X post (Sep 18, ordinary window for W39); W38 late-breaking row revalidated via Snowflake and bound to context only. Community observation only; no elevation. URL: <https://x.com/ophtaka/status/2101098410933715051> (visited on 09/27/2026).
- [24]Pixel Canary availability note (late-only). Direct public X post (Sep 25 post-cutoff, late-breaking); official availability note for the stealth model. Late-only context; identity and eval figures unverified. URL: [https://x.com/vercel\\_dev/status/2103635565933678989](https://x.com/vercel_dev/status/2103635565933678989) (visited on 09/27/2026).

- [25] *Codex outage notice (late-only)*. Direct public X post (Sep 25 post-cutoff, late-breaking); outage notice without status-page corroboration. Late-only context; low confidence. URL: <https://x.com/thcottiaux/status/2103620061156290622> (visited on 09/27/2026).
- [26] *DeepSeek V4 Pro evaluation note (late-only)*. Direct public X post (Sep 25 post-cutoff, late-breaking); independent evaluation note. Late-only context; excluded from ordinary totals. URL: <https://x.com/BenKoska/status/2103633857287479640> (visited on 09/27/2026).
- [27] Amazon Web Services. *The Biological Computing Co. Partners with AWS to Bring World's First Neuron-Derived AI Video Model to Market*. Primary official source for the Sep 22 partnership and commercialization facts only. The 5x faster, 80% cheaper and sub-0.1% layer figures are vendor claims without independent corroboration and are not treated as validated results. URL: <https://press.aboutamazon.com/aws/2026/9/the-biological-computing-co-partners-with-aws-to-bring-worlds-first-neuron-derived-ai-video-model-to-market> (visited on 09/27/2026).