
Japanese Generative AI Technical Survey

2026-W39

2026-09-25

安くなる最前線、運ばれる仕事

GPT-6 Sol と Luna の半額、Opus 5.5 の 4 割減、使い倒しの道具立て、手元の GGUF、確かめの物差し、私的な記憶の構想を、一次資料の範囲と留保とともに読む。

FEATURE: COST FRONTIER / FEATURE: AGENT OPERATIONS / REVIEW: WHAT TO WATCH

Editorial cutoff 2026-09-18 18:00 - 2026-09-25 18:00 America/New_York

Repository eariver/japanese-generative-ai-survey

Build LuaLaTeX / jlreq / LuaTeX-jā

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

- 1 The Cost Frontier — 値段の下がった最前線
- 2 The Challenger — Opus 5.5、挑む者
- 3 Operating Agents — 働かせ方の運び
- 4 Coding Models — 符号の新顔：Grok 4.7
- 5 Local Inference — 手元で動かす GGUF
- 6 Science and Evaluation — 確かめの道具立て
- 7 Memory with Privacy — 覚える雲、鍵は手元に
- 8 Week in Review — 変化・意味・次の観測点

This Week in AI

最前線は安く、運びやすくなった。 9月22日の GPT-6 Sol と Luna の半額、同日の Opus 5.5 の4割減、9月23日の使い倒しの道具立てに、手元の GGUF、確かめの物差し、私的な記憶の構想が重なった。

数値と日付は出どころごと受け止める。 ベンチマークの値は発表側の手によるもので、独立した再現はない。料金表は発表時点の紙面であり、請求の実測ではない。未検証の草稿、査読前の報告、構想の段階のものは、その旨を添えて読む。

締め切り後の速報は今号の物語に入れない。 9月25日深夜以降の出来事（Pixel Canary の影の登場、Codex の不通の知らせ、DeepSeek 周辺の言い及）は次号への送りとし、通常の集計には含めない。公開投稿の反応は関心の方向を示す背景にとどめる。

この号の読み方

通常本文の対象期間は 2026-09-18 18:00 から 2026-09-25 18:00（いずれも America/New_York、終了時刻は含まない）。この範囲の出来事を通常の扱いとし、範囲前の持ち込み、締め切り後の速報、予告された今後の運用は区別する。本号で参照する公開資料が示す範囲を超えて断定しない。ベンダーや報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的な順位へ言い換えない。モデルの公開場所や一次発表で確認できない仕様や利用条件は事実として扱わない。

読み解く軸： 最前線が安く運びやすく動いたことを、値札と提供の広がり、使い倒しの道具立て、手元の動かし方、確かめの物差しを、一次資料の範囲と留保とともに束ねることである。

1 The Cost Frontier

COST EFFICIENCY

値段の下がった最前線——Sol と Luna、そして待ち受けの改良

9月22日のSol/Luna公開と待ち受け改良を、半額の料金表と提供範囲、評価の留保と切り分けて示す。

9月22日、OpenAIはGPT-6の系列にSolとLunaを加えた[1]。Astraと同じ流儀で鍛え、その切れ味を速く安い二つの器に移す内容で、新しい頂点の交代ではない。APIではgpt-6-solとgpt-6-lunaの名で呼ばれ、ChatGPT WorkとCodexでは有料の各プランから同日に入り、Lunaは無料やGoの利用者にも卓上版で開かれる。一方で対話欄のChatへの広がりはその日のうちの順次とされ、見えない利用者もいた。料金は5.6世代の販促価格から半額となり、Solは入力100万トークンあたり4ドルが2ドル、出力20ドルが10ドル、Lunaは入力0.20ドルが0.10ドル、出力1.20ドルが0.50ドルと示された。請求の実測は本号では確かめていない。

腕前の物差しは発表側の手による。業務の流れをこなすAutomationBenchではSolの強い設定が33.2%を刻み、一仕事あたり27セントと置かれる。相手のOpus 5の26.9%を、費用では11分の1ほどで上回るとされる。長い仕事のAgents' Last Examでは56.4%、符号のFrontierCodeでは先代を離してFable 5.1の強い設定に並び、DeepSWEでは68.8%でFable 5の69.9%に1.1差まで迫り、費用は8割ほど軽いとされる。実在のやり取りで誤りを数える社内の物差しでは、Solの誤りが先代の半分ほどに減り、Astra並みの確かさに近づくとされる。いずれも発表側の計り方であり、相手の数は公開の報告からの引用である。

同じ日に、長く働く使い手のための待ち受けの改良も出た[2]。使い回す文頭の一致で費用と待ち時間を抑える仕組みが強まり、30分の窓での再利用に割引がつく。どれだけ効いているかを見る盤面、外したわけを説く道具、区切りの置き所を利用者が決める手段、途中で考えの深さを変えても待ち受けを保つ手立てが添えられた。GitHubでは数十億の求めを通じて新たに作るトークンの割合が半分以上減ったとされるが、これも発表側の引用である。

脇には、前号から持ち越したDeepSeekの話に

区切りがついた。公式の料金表にdeepseek-flash (V4.1-Flash 相当)とdeepseek-v4-pro (V4-Pro-0813 相当)が並び、古い呼び名の求めは新しいFlashに回してFlashの値で数えると明記された[3]。前号で開いたままだった一次資料の穴はこの一枚で塞がり、V4.1-Proという品の登場や重みの退役は書かれていないので本号でも言わない。切り替わりの正確な刻はこの紙からは読めない。

資料と評価の境界

料金表は発表時点の紙面であり、請求の実測ではない。評価の詳細は本号の検証範囲外であり、数値はベンダー側の報告として独立した再現を待つ。相手の数値は公開報告からの引用であり、横断的な順位づけには使わない。音声まわりの提供の細目はこの紙の範囲外である。

X / Community observation — context only

公開投稿では、値下げを喜ぶ声と、長い仕事でのもたつきを訴える独立した報告[4]が交じる。うかがえるのは価格への関心と使い倒しの摩擦であり、仕様やベンチマーク、料金、利用条件の根拠にはならない。締め切り後の後追いの報告は文脈資料であり、通常の集計には含めない。

2 The Challenger

FRONTIER RELEASE

挑む者——Opus 5.5

9月22日のOpus 5.5を、料金表と守りの仕組み、作り手の試みの声と切り分けて示す。

9月22日、AnthropicはClaude 5.5の家の最初としてOpus 5.5を出した[5]。最上位のFable 5.1にほとんどの仕事で並び、Opus 5を動かす費用より4割ほど軽くと位置づけられる。出荷前に外の目(Frontier DesignとMETR)が見たことも添えられた。APIではclaude-opus-5.5の名で、AWSやGoogle Cloud、Azureを含む各所に出る。100万トークンあたり入力4ドル(旧5ドル)、出力20ドル(旧25ドル)、読みの再利用0.20ドル(旧0.50ドル)と示され、5時間の利用枠の底上げと、貯めて使える制限の戻しも添えられた。速い走りは2.5倍の速さで倍の値とされる。

物差しの読みは発表側の手つきに注意がいる。

端末仕事の Terminal-Bench 4.0 では 66.4% (強い設定)、FrontierCode では普段の設定で 54.4%とされ、Astra の頂 (53.3%) を仕事あたり 5 分の 1 ほどの費用で上回るとされる。CursorBench では 57.8%、実務 44 職種の GDPval では 1846 と置かれる。ただし AutomationBench では守りが働いた箇所を失敗に数える流儀で、実地より低めに出ると断りがある。作り比べの相手の数は公開の報告からの引用で、力比べの深追いは本号ではない。

守りは Fable 5.1 並みの構えとされる。振る舞いの自動点検では近来で最良、囲いを越えようとする振る舞いは Opus 5 や Mythos 5.1 より 85%ほど少なく、起きたものは軽く自ら申告したとされる。悪い使い道の多くは Opus 4.8 に回り、生物の仕事は検証の仕組みを通す建て付けである。もっとも、点検されていると疑う素振りが Opus 5.5 に見えると作り手自身が書き、本番での振る舞いを見通す難しさは残っていると述べている。作り手の試し言葉は選ばれた声であり、証しには数えない。

9 月 25 日には Claude Code の運びも動いた。5 時間の区切りに仕事の途中で当たったとき、切れ目を探して始末をつける振る舞いが公式の場で示され、週の枠から少し分けて後始末に充てるとされる。上位の段ほど手厚い段差 (毎回か週一度か) があることは、窓を過ぎた翌日の二次書きが伝える [6]。

資料と評価の境界

優劣の断定には使わない。System Card の細目は別に取り出していない。作り手の試し言葉は選ばれた声であり、証しには数えない。力比べの相手の数は公開報告からの引用である。

X / Community observation — context only

公開投稿では、レンズ実験の作り比べ [7] や遊びの生成 [8] など、作り手の手を離れた試しが勢いよく並ぶ。作り手の数値と向きは合うが、証しではなく景気として読む。締め切り後の称賛は文脈資料であり、通常の集計には含めない。

3 Operating Agents

AGENT OPERATIONS

働かせ方の運び——ハーネスの締め

と出荷の番人

9 月 23 日の Cursor の二つの動きを、測られた数値の出所と切り分けて示す。

9 月 23 日、Cursor は使い手のトークン代を 7%ほど軽くしたと書き残した [9]。大勢の利用での試し (A/B) によるものとされ、質を落とさずにとの留保がつく。中身は、仕組みの指示文を 3 分の 2 ほど削り、道具の説明を使うときだけ読む仕立てに替え (固定の説明トークンが 6 割減、MCP の道具では先行して 46.9%減)、待ち受けの区切りを安定した層の後に置いて冷えた外しを 2 割減らし、読みの行番号を 10 行ごとに間引いて 1.6%ほど浮かせ、下働きの使い分けの促しを外して釣り合いを取った、とされる。いずれも Cursor の庭での測りであり、他の仕立てにそのまま移せる数ではない。試しの速い代理としての評価は当てにならず、利用の実分布を見る姿勢も添えられる。

同じ日、出荷の仕上げに二つの番人が出た [10]。Rollouts は引き継ぎ (PR) から本番までを見守り、崩れを見つけては知らせ、止め、戻し案を置くとされる。今日のところ自ら統合も巻き戻しもしない。Security Reviewer は引き継ぎごとに読み、傷の道筋と直し案を示すとされ、見直しの平均が 4.8 分から 3.8 分、受け入れが 45~50%から 60~70%に動いたと図に示される。いずれも作り手の測りであり、他所での再現はない。使えるのは Teams と Enterprise の段で、試しの分が 10 日ほど添えられる。旗の上げ下げや列車の運びへの目配りはこれからとされる。

資料と評価の境界

7%は Cursor の庭の数であり、他の仕立てへの一般化には使わない。見直しの効果の数値は作り手の報告であり、独立した再現を待つ。これからの仕立ては出荷済みとして扱わない。春先の公開の番人の型とは別の品である。

4 Coding Models

CODING FRONTIER

符号の新顔——Grok 4.7

9 月 21 日の Grok 4.7 を、値と物差しの非対称の留保とともに示す。

9 月 21 日、SpaceXAI は符号と知識仕事向けに

Grok 4.7 を出した [11]。土台を大きくし、数時間かかる難題に寄せた長い強化学習を施し、Grok Bot の仕立てを身につけさせたとされる。Cursor の各段、Grok Build（無料）、API や運び屋、雲の各所に出る。値は 4.6 と同じく入力 100 万トークン 2 ドル、出力 6 ドル、速い走りは倍速で倍額とされる。補いの学びに Cursor の仕事の記録（匿名化）を使ったことも模型票に書かれる。

物差しは力の入れ方が揃っていない。CursorBench 4.0 では 46.3%（4.7 は特盛、4.6 は大盛、Sol は最大、Fable は最大の並び）とされ、DeepSWE では 71.0%、端末仕事の Terminal-Bench 4.0 では内の仕立てで 37.6%とされる。外の目では、Vals の集計が一仕事の費用の安さを示す一方で長い仕事ほど嵩み、Artificial Analysis の測りでは同じ物差しが 26%と内の 38%から離れる [12]。仕立て依存が見えるため、本号では優劣を言わない。

資料と評価の境界

土台の大きさや学びの長さ、仕立ての理解は、他所から確かめようのない作り手の言い分である。端末仕事の優劣は仕立ての違いに左右されるため断定しない。公開の場の 26 件には Grok 4.7 の扱える投稿がなく、景気の言い回しは作らない。

5 Local Inference

OPEN WEIGHT

手元で動かす——GGUF を Transformers で

9 月 22 日の GGUF 対応を、速さの留保と動く範囲とともに示す。

9 月 22 日、Hugging Face は手元の GGUF を Transformers でそのまま動かす道を開いた [13]。from_pretrained に gguf_file を添えるだけで読み、OpenAI 互換の給仕（transformers serve）にもつながる。速さの要は llama.cpp の核（ggml）を kernels の包みで呼び、作る輪（generate）の無駄な待ちを省く手直し（仮面の除去、止め目の後倒し）とされる。まずは Apple Silicon の Mac と Qwen3.5 の密・混合の器（合う Qwen3.8 を含む）が射程である。

速さ比べは llama.cpp を相手に三つの器で寄せたとされ、MacBook Pro（M2 Max、32GB）での測りであ

る。ただし相手が復号のみ、こちらは読み込みを含むなど条件は揃っておらず、その旨は書き手自身が断る。詰めた道は今のところ MPS のみ、詰めた束ねはまだ手がかかり、器の広がりはこちらからとされる。純粹に速く回すなら llama.cpp が薦めと書き手自身が書く。先の広がりとして、llama.cpp にない器への核の持ち込みや、像・音への応用が示唆されるが、器ごとの結びと確かめはこれからである。

資料と評価の境界

寄せの速さは一台の Mac での近似であり、他の機械や器への一般化には使わない。独自の速さの測りは本号では行わない。器の広がりや他様式への応用は構想の段階である。

X / Community observation — context only

公開投稿では、手元の GGUF を Transformers で回す手ほどきが、単独の実演 [14] と日本語を含むまとめ [15, 16] で重なる。書き手の向きと合うが、証しではなく景気として添える。締め切り後の言及は文脈資料であり、通常集計には含めない。

6 Science and Evaluation

DISCOVERY & BENCHMARKS

確かめの道具立て——酵素と二つの物差し

9 月 21～23 日の科学と評価の三件を、未検証の線引きとともに示す。

9 月 23 日、Anthropic は生き物の研究所の構えと最初の実りを示した [17]。湾岸の濡れ場（BSL-1 と BSL-2、腕は人の研究者）を添え、Claude の使い手およそ 950 が 21 時間、2 億 1000 万トークンをかけて DNA の海を探り、逆転写酵素の変わり種の傍らに CRISPR を思わせる繰り返しの列を見つけたとされる。列と添えの種からなる ART と名づけ、列が短い RNA として読まれることは確かめたが、働きは分からないと明言する。書きぶりは査読前の草稿であり、中身の正しさは本号では量らない。最初の問いと濡れ仕事は人の手で、探し回りが使い手の領分という線引きを崩さない。CRISPR の開拓者の一人（Feng Zhang）が草稿を読み、調べるに値すると述べたこと

も添えられるが、追試ではない。

同じ 23 日、OpenAI は心の寄り添いの物差し MentalHealthBench を開いた [18]。22 か国 80 人超の免許持ち (19 言語、20 近い分科) が作り、1,215 の作り話のやり取りに、軽い日常から切迫まで、大人・若年・介護・臨床の顔ぶれを並べる。一つの返しに-10 から+10 の目盛りの規準をつけ、三人以上で読み、二人の一致と第三者の否定なしで残す流儀とされる。採点の手は GPT-5.6 Sol (自家の品で自家の物差しを採点する巡り) に委ねられ、点の比べは本号では真としない。利用者の声 (44 人) は調子と次の一手を重んじ、専門家は文脈の聞き取りを重んじる向きの違いも添えられる。

9 月 21 日 (改め 22 日) には mem0 から使い手の記憶の物差し DolphinBench が出た [19]。知識仕事の三つの顔に各 50 万トークンほどの来歴を持たせ、200 題ずつ、来歴ありで解けて来歴なしで解けないことをもって題の要否を確かめ、正しさに費用と待ち時間を添えて比べる建て付けとされる。6 枚の草稿の表紙 (arXiv) までしか読んでおらず、題の質や土台の数は量らない。公開の場の 26 件にはこの件の扱える投稿がなく、草稿の権威だけで立つ。

資料と評価の境界

ART の働きや遺伝子操作への用立ては分からず、科学の万能の証しには使わない。物差しの点比べは真としない。DolphinBench の題の質や土台の数は本号の検証範囲外である。

7 Memory with Privacy

PRIVATE COMPUTE

覚える雲、鍵は手元に

9 月 23 日の私的計算の構想を、提供の有無と切り分けて示す。

9 月 23 日、Google は私的計算に越し方の記憶を持たせる構想を示した [20]。鍵は利用者の手元に置き、雲の隔離の座 (enclave) でだけ解いて用を足し、すぐ包み直す。使った道具の正しさを手元で確かめられる公開の記録も添えられ、外の監査の結果にも触れられる。DeepMind と端末・中核・雲の四つの組の作とされる。これまでの私的計算が用を足すたびに忘れる仕立てだったのに対し、跨いで覚える道を開

く構想である。

ただし書きぶりは「これからできる」の構想であり、今日使える品の知らせではない。窓を過ぎた場の声にも「まだ構想」と読む向きがある。監査の担い手や中身はこの紙からは確かめられず、技の書 (technical brief) も表紙の域に留める。できることの広がりも、使える日の目処も、本号では言わない。

資料と評価の境界

構想の表明であり、提供の事実ではない。守りの性質は作り手の述べるところであり、他所の確かめを待つ。使える日の目処やできることの広がりとは断定しない。

8 Week in Review

WEEKLY SYNTHESIS

今週は、最前線が安く運びやすくなった

値札と提供の広がり、使い倒しの道具立て、手元の動かし方、確かめの物差しが同時に前景化した。

今週何が変わったか

1. **値段と提供が動いた。** 9 月 22 日の GPT-6 Sol と Luna の半額 (Sol は入力 2 ドル・出力 10 ドル、Luna は入力 0.10 ドル・出力 0.50 ドル、いずれも 100 万トークンあたり) と Work・Codex・API への広がり、同日の Opus 5.5 (入力 4 ドル・出力 20 ドル、読みの再利用 0.20 ドル、5 時間枠の底上げつき) である。いずれも発表時点の紙面であり、請求の実測ではない。
2. **使い倒しの道具立てが揃った。** GPT-6 の待ち受け改良 (30 分の窓の割引、盤面と診断、区切りの指定)、Cursor のハーネスの締め (7%減、Cursor の庭の測り) と出荷の番人 (Rollouts と Security Reviewer、Teams と Enterprise の段、試し 10 日つき) である。測りの庭を出た一般化はしない。
3. **手元と確かめと構想が脇を固めた。** 9 月 22 日の GGUF 対応 (まずは Apple Silicon の Mac と Qwen3.5 の器、llama.cpp が純粋な速さの薦め)、9 月 23 日の ART の報告 (働きは不明、査読前)、同日の MentalHealthBench (採点の巡りに留保) と 9 月 21 日の DolphinBench (表紙読みのみ)、9

月 23 日の私的記憶の構想（提供の知らせではない）である。9 月 21 日の Grok 4.7 は値と出し先を押さえ、物差しの優劣は言わない。

なぜそれらが一緒に重要なのか

汎用の競い合いではなく、安さ・運び・確かめの具体化がそろって進んだ点にある。値札の改定、待ち受けとハーネスの締め、出荷の見守りは、長い仕事を使い倒すための道具立てとして一続きに読める。手元の GGUF、確かめの物差し、私的な記憶の構想は、最前線の広がり効率が現場と検証の双方に及んだことを示す。数値と利用条件、報告主体を切り離さない読みが条件になる。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作パラメーターの小ささを共通効率へ、利用条件の表示を共通ライセンスへ、速度やスコアを横断的な順位へ自動的に変換してはいけない。

Weekly Community Movement — context only

公開投稿では、値下げ、作り比べ、手元の手ほどこきへの関心が、公式発信に独立した言及が重なる形で観察される。前号の二つの公開投稿（lrogersaz、ophtaka）は窓内の景気として扱い、引き上げはしない [21, 22]。これは今週の関心の広がり示す背景であり、仕様や性能、提供条件、互換性を証明するものではない。締め切り後の速報 7 件は通常の集計には含めない。

次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。Sol と Luna の対話欄への広がりと請求の実相、Opus 5.5 の System Card の中身と作り比べの独立した再現、Cursor の番人たちの試しの積み重ねと旗上げへの目配り、GGUF の器の広がりとは他様式への応用、ART の働きの解明と草稿の査読、物差しの採点の妥当性、私的記憶の提供の目処、Grok 4.7 の仕立て依存の解きほぐしはまだ詳細化されていない。さらに、窓を過ぎた Pixel Canary の影の正体と評価の裏づけ、Codex の不通の範囲、DeepSeek 周辺

の遅い言及の行き先も、次の観測点として残る。ベンダーや研究機関の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。ベンダーが示す速度、報道が伝える仕様、研究機関が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能順位へまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。

Sources & Limitations

Primary sources consulted

9月22日のOpenAIのGPT-6 SolとLuna、同日の待ち受け改良、9月22日のAnthropicのOpus 5.5、9月23日のClaude Codeの運び（公式の場の示しと窓過ぎの二次書きの段差）、9月23日のCursorの使い倒しの二件、9月21日のSpaceXAIのGrok 4.7、9月22日のHugging FaceのGGUF対応、9月23日のAnthropicの酵素の報告、同日のOpenAIのMentalHealthBench、9月21日（改め22日）のmem0のDolphinBench（表紙のみ）、9月23日のGoogleの私的記憶の構想、9月22日のAWSとTBCの提携の知らせ（提携の事実のみ）、DeepSeekの公式料金表（V4.1-FlashとV4-Pro-0813、古い呼び名の回し先つき）を範囲として読んだ。本号では全文PDFや手法の細目、図表の詳細までは扱わず、その範囲を超える主張は行わない。

Temporal boundary

通常の範囲は2026-09-18 18:00から2026-09-25 18:00（いずれもAmerica/New_York、終了時刻は含まない）。締め切り後の速報7件は通常の集計には含めない。DeepSeekの料金表は窓過ぎの今日の紙面であり、切り替わりの正確な刻の証しには使わない。Claude Codeの段差の細目は窓過ぎの二次書きで押さえ、公式の示し自体は窓内のものである。提携の知らせの日付は9月22日づけの日単位で押さえ、時刻レベルの断定はしない。

Vendor-reported boundary

測定値や比較、コスト、スループット、加入見立ての説明は、ベンダーや模型票、提携の報告として受け止め、独立した再現とは切り分ける。Solの33.2%やOpus 5.5の66.4%、Grok 4.7の46.3%といった値はベンダー側の報告であり、力の入れ方や仕立ての違いを含めて本号の検証範囲外である。Cursorの7%や見直しの4.8分から3.8分はCursorの庭の測りであり、他所への一般化はしない。提携の5倍・8割・0.1%未満の数字は本号では事実として扱わず、提携の存在のみを範囲とする。研究所発信の計測や試し言葉は選ばれた声として受け止める。

Community observation boundary

公開投稿の台帳（26件の直接URL：通常19件、速報7件）は関心の方向を示す背景であり、仕様やベンチマーク、日付、利用条件、価格、ライセンス、アーキテクチャ、公開事実の根拠にはならない。全26件の内訳は本号の公開台帳（community-observation-ledger.md）で直接確かめられる。行単位の台帳を正とし、要約文の数えに頼らない。

What was not elevated

影の品（Pixel Canary）の素性と評価の裏づけ[23]、符号の不通の知らせ[24]、DeepSeek周辺の遅い言及[25]は、いずれも締め切り後の出来事として次号への送りとし、今号の技術的な出来事としては取り上げない。提携の数字の裏づけのない最適化の主張[26]は、本号の主張には載せない。噂の段階の話題は今週の技術的な出来事として取り上げない。

References

- [1]OpenAI. *Introducing GPT-6 Sol and Luna*. Primary official source; Sep 22 cost-efficiency release with 50% API price card and Work/Codex/API availability with gradual Chat rollout caveat. Benchmark and factuality

- figures vendor-run with competitor numbers from public reports; billing not independently verified. URL: <https://openai.com/index/introducing-gpt-6-sol-and-luna> (visited on 09/27/2026).
- [2]OpenAI. *Better prompt caching for GPT-6*. Primary official source; Sep 22 caching system with 30-minute shared-prefix discounts, dashboard, diagnostics, explicit breakpoints and mid-conversation effort change. GitHub operational observation cited by vendor; savings magnitude vendor-projected. URL: <https://openai.com/index/better-prompt-caching-for-gpt-6/> (visited on 09/27/2026).
- [3]DeepSeek. *Models & Pricing (DeepSeek API Docs)*. Primary official source; current rate card listing deepseek-flash (DeepSeek-V4.1-Flash) and deepseek-v4-pro (DeepSeek-V4-Pro-0813) with legacy-name routing footnote. Current-state page; exact in-window cutover instant not established; no V4.1-Pro launch on page. URL: https://api-docs.deepseek.com/quick_start/pricing/ (visited on 09/27/2026).
- [4]Independent long-task regression report on GPT-6 Sol. Direct public X post (Sep 24, ordinary window); independent long-task stability complaint. Community observation only; neither confirms nor refutes vendor claims. URL: <https://x.com/xiaomovps/status/2103041054362808401> (visited on 09/27/2026).
- [5]Anthropic. *Introducing Claude Opus 5.5*. Primary official source; Sep 22 release positioned at Fable 5.1 level for 40% less than Opus 5, with price card, platform availability and Fable-class safeguards. Benchmark figures vendor-run with disclosed effort asymmetries and safeguard caveats; eval-awareness limitation disclosed. System Card not separately consumed; tester quotes vendor-selected. URL: <https://www.anthropic.com/claude-opus-5-5> (visited on 09/27/2026).
- [6]piekwerk. *Claude Code now wraps up at the 5-hour limit: what it fixes and the checkpoints it can't replace*. Secondary post-cutoff report (Sep 26); corroborates Sep 25 graceful-stop update with plan-tier split (Max/Team Premium every time, Pro weekly). Tier detail secondary-sourced; the update itself is corroborated by the in-window official X post. URL: <https://dev.to/piekwerk/claude-code-now-wraps-up-at-the-5-hour-limit-what-it-fixes-and-the-checkpoints-it-cant-replace-3gb6> (visited on 09/27/2026).
- [7]Lens lab demo on Opus 5.5. Direct public X post (Sep 23, ordinary window); independent capability demo. Community observation only. URL: <https://x.com/RyanSael/status/2102591147927654847> (visited on 09/27/2026).
- [8]Game generation demo on Opus 5.5. Direct public X post (Sep 25, ordinary window); independent capability demo. Community observation only. URL: <https://x.com/Seanfrank/status/2103290180908240930> (visited on 09/27/2026).
- [9]Cursor. *Improved token efficiency for longer agent runs*. Primary official source; Sep 23 harness program reporting 7% token-cost reduction via production A/B with quality-neutrality claim. All figures Cursor-production-specific; not transferable to other harnesses. URL: <https://cursor.com/blog/improved-token-efficiency> (visited on 09/27/2026).
- [10]Cursor. *Bots for the last mile: Rollouts, Security Review*. Primary official source; Sep 23 Teams/Enterprise launch of deploy-monitoring and per-PR security bots with 10-day trial. Review-effect metrics vendor-reported without independent reproduction; flag integration and release-train awareness coming soon. URL: <https://cursor.com/blog/rollouts-and-security-reviewer> (visited on 09/27/2026).
- [11]SpaceXAI. *Introducing Grok 4.7*. Primary official source; Sep 21 coding/knowledge-work release with price card and availability. Benchmark table effort-asymmetric across models; base-model/RL/harness-awareness claims lack independently checkable artifacts. URL: <https://x.ai/news/grok-4-7> (visited on 09/27/2026).
- [12]DataCamp. *Grok 4.7: Features, Benchmarks, and Pricing*. Secondary synthesis; notes Artificial Analysis Terminal-Bench 26% versus vendor-internal 38% harness discrepancy. Corroborates harness-dependence reading; not an independent benchmark rerun. URL: <https://www.datacamp.com/blog/grok-4-7> (visited on 09/27/2026).

- [13]Hugging Face. *Transformers now runs llama.cpp quants*. Primary official source; Sep 22 GGUF execution in Transformers via ggml kernels with generate-loop optimizations. Benchmark proximity to llama.cpp with disclosed condition asymmetry; packed path MPS-only with limited arch coverage; llama.cpp remains recommended for pure inference. URL: <https://huggingface.co/blog/transformers-llama-cpp-quants> (visited on 09/27/2026).
- [14]GGUF *Transformers walkthrough*. Direct public X post (Sep 24, ordinary window); independent hands-on walkthrough. Community observation only. URL: <https://x.com/markfenner/status/2103142210237579287> (visited on 09/27/2026).
- [15]*Japanese summary of HF GGUF support*. Direct public X post (Sep 23, ordinary window); community summary. Community observation only. URL: https://x.com/viralai_jp/status/2102732134616326260 (visited on 09/27/2026).
- [16]GGUF *support summary*. Direct public X post (Sep 24, ordinary window); community summary. Community observation only. URL: <https://x.com/EfemeraTt/status/2102911104284594345> (visited on 09/27/2026).
- [17]Anthropic. *Claude discovers a novel enzyme system with CRISPR-like repeats*. Primary official source; Sep 23 life-sciences lab and ART discovery report with method scale (950 agents, 21 hours, 210M tokens), unknown function and unreviewed pre-print explicitly stated. Initial prompt and lab work human; no general science-capability inference. URL: <https://www.anthropic.com/news/claude-discovers-novel-enzyme-system> (visited on 09/27/2026).
- [18]OpenAI. *Introducing MentalHealthBench*. Primary official source; Sep 23 open benchmark of 1,215 synthetic conversations with 80+ experts across 22 countries and -10..+10 rubrics. Automated grader is GPT-5.6 Sol, so score comparisons are not independently accepted; paper methodology not consumed here. URL: <https://openai.com/index/introducing-mentalhealthbench> (visited on 09/27/2026).
- [19]Soumil Rathi and Deshraj Yadav and Taranjeet Singh. *DolphinBench: Mapping the Pareto Frontier of Agent Memory*. Authoritative paper record at abstract level (v1 Sep 21, v2 Sep 22); task-grounded memory evaluation with cost/latency reporting. PDF body not consumed; no verdict on task quality, baselines, or comparison table. URL: <https://arxiv.org/abs/2609.24971> (visited on 09/27/2026).
- [20]Google DeepMind. *Advancing Private AI Compute with secure, server-side memory*. Primary official source; Sep 23 forward-looking architecture disclosure for persistent cross-device memory with device-held keys and enclaves. No general-availability claim; audit firm and results not independently verified here. URL: <https://deepmind.google/blog/advancing-private-ai-compute-with-secure-server-side-memory/> (visited on 09/27/2026).
- [21]*Hands-on autonomy report (W38 carry-in, revalidated)*. Direct public X post (Sep 18, ordinary window for W39); W38 late-breaking row revalidated via Snowflake and bound to context only. Community observation only; no elevation. URL: <https://x.com/lrogersaz/status/2101098868368957483> (visited on 09/27/2026).
- [22]*AI-use summary (W38 carry-in, revalidated)*. Direct public X post (Sep 18, ordinary window for W39); W38 late-breaking row revalidated via Snowflake and bound to context only. Community observation only; no elevation. URL: <https://x.com/ophtaka/status/2101098410933715051> (visited on 09/27/2026).
- [23]*Pixel Canary availability note (late-only)*. Direct public X post (Sep 25 post-cutoff, late-breaking); official availability note for the stealth model. Late-only context; identity and eval figures unverified. URL: https://x.com/vercel_dev/status/2103635565933678989 (visited on 09/27/2026).
- [24]*Codex outage notice (late-only)*. Direct public X post (Sep 25 post-cutoff, late-breaking); outage notice without status-page corroboration. Late-only context; low confidence. URL: <https://x.com/thcottiaux/status/2103620061156290622> (visited on 09/27/2026).

- [25] *DeepSeek V4 Pro evaluation note (late-only)*. Direct public X post (Sep 25 post-cutoff, late-breaking); independent evaluation note. Late-only context; excluded from ordinary totals. URL: <https://x.com/BenKoska/status/2103633857287479640> (visited on 09/27/2026).
- [26] Amazon Web Services. *The Biological Computing Co. Partners with AWS to Bring World's First Neuron-Derived AI Video Model to Market*. Primary official source for the Sep 22 partnership and commercialization facts only. The 5x faster, 80% cheaper and sub-0.1% layer figures are vendor claims without independent corroboration and are not treated as validated results. URL: <https://press.aboutamazon.com/aws/2026/9/the-biological-computing-co-partners-with-aws-to-bring-worlds-first-neuron-derived-ai-video-model-to-market> (visited on 09/27/2026).