Japanese Generative AI Technical Survey

2026-W40

2026-10-02

最前線の料金表、学習の仕組み

Sonnet 5.5 と GPT-6.1 Sol と Gemini 4 Argon の料金と提供条件、公開ウェイトの推論モデル、判断支援の 3 界面、DevDay の製品面、5 領域の安全性、ContextLM と Olmo-core 3 の学習の仕組み、評価基盤、マルチモーダルの提供現場、企業・業界動向を、一次資料の範囲と留保とともに読む。

FEATURE: FRONTIER PRICING / FEATURE: TRAINING METHODS / REVIEW: WHAT TO WATCH

Editorial cutoff	2026-09-25 18:00 - 2026-10-02 18:00 America/New_York
Repository	eariver/japanese-generative-ai-survey
Build	LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

1	Frontier Models — 最前線の料金表と提供条件
2	Open Reasoning — 公開ウェイトの推論モデル
3	Decision Inference — 判断支援の 3 界面
4	DevDay Surface — 働く窓口
5	Safety and Provenance — 安全性と来歴の 5 領域
6	Training Methods and Systems — 学習の仕組み
7	Evaluation Infrastructure — 評価基盤
8	Multimodal Serving — マルチモーダルの提供現場
9	Enterprise Digest — 企業・業界動向
10	Week in Review — 変化・意味・次の観測点

This Week in AI

最前線には料金表が並んだ。 9 月 28 日の Sonnet 5.5、9 月 29 日の GPT-6.1 Sol、9 月 30 日の Gemini 4 Argon に、公開ウェイトの推論モデル、判断支援の 3 界面、働く窓口、5 領域の安全性、学習の仕組み、評価基盤、マルチモーダルの提供現場、企業・業界動向が重なった。

数値と日付は出どころごとに受け止める。 ベンチマークの値はベンダー計測によるもので、独立した再現はない。料金表は発表時点の公式ページであり、請求額の実測ではない。記事の日付と評価スクリプトの到着、重みやコードの公開は別の事柄として切り分ける。未検証の事柄、査読前の報告、構想段階のものは、その旨を添えて読む。

載せないものは理由とともに記す。 素材的に重い 2 件のホスト記事は、一次資料の受け入れ整理が終わっていないため今号の章には載せない。締め切り後の速報は次号へ送り、通常の集計には含めない。公開投稿の反応は関心の方向を示す背景にとどめる。

この号の読み方

通常本文の対象期間は 2026-09-25 18:00 から 2026-10-02 18:00（いずれも America/New_York、終了時刻は含まない）。この範囲の出来事を通常の扱いとし、期間前の持ち越し、締め切り後の速報、予告された今後の運用は区別する。本号で参照する公開資料が示す範囲を超えて断定しない。ベンダーや報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的な順位へ言い換えない。モデルの公開場所や一次発表で確認できない仕様や利用条件は事実として扱わない。

読み解く軸： 料金と提供形態、公開ウェイトとライセンスの切り分け、ベンダー計測の帰属、記事の日付とスクリプト到着の切り分けを、一次資料の範囲と留保とともに束ねることである。

1 Frontier Models

FRONTIER PRICING

最前線の料金表と提供条件——Sonnet 5.5、GPT-6.1 Sol、Gemini 4 Argon

9 月 28 日から 30 日に 3 モデルが並んだ。料金表・提供形態・ベンダー計測のベンチマークを切り分けて読む。

Anthropic は 9 月 28 日、Claude Sonnet 5.5 をリリースした [1]。Claude 5.5 ファミリーの 2 番目のモデルで、対象期間より前の Opus 5.5（9 月 22 日）を補う位置づけであり、最上位の交代ではない。料金は Sonnet 5 と同額の公称価格で、入力 100 万トークンあたり 2 ドル、出力 10 ドル、キャッシュ読み取り 0.20 ドルとされる。ベンダーによれば、トークン削減によってタスクあたり最大 3 割安く、出力速度も 3 割以上速いとされる。提供面ではコンテキスト 100 万トークン、最大出力 128K、API 名 claude-sonnet-5-5、AWS Bedrock・Google Cloud・Azure 対応、ゼロデータ保持が示される。いずれも発表時点の公式ページの内容であり、請求額の実測ではない。

ベンチマークはすべてベンダー計測であり、条件も努力量も異なるため、横断的な優劣表にはしない。Terminal-Bench 4.0 で 70.6%（Sonnet 5 の 10.3%から大幅に伸びたとされる）、FrontierCode 1.1 Main で 46.2% Max、CursorBench 4.0 で 55.5%、GDPval-AA で 1844（Opus 5.5 の 1846 に並ぶとされる）、OSWorld 2.1 partial で 80.1%、Chartography で 61.6%と置かれる。安全側の構えは Opus 5.5 級のサイバー系セーフガードとフォールバック、生物系は Sonnet 5 と同等、推論抽出分類器と思考過程の保持が添えられるとされる。独立した再現はなく、相手モデルの数値は公開報告からの引用として読む。

OpenAI は 9 月 29 日、GPT-6.1 Sol をリリースした [2]。料金表は変更履歴との突き合わせ済みで、入力 100 万トークンあたり 2 ドル、出力 10 ドル、キャッシュ読み取り 0.10 ドルとされる。ベンダー側の性能差分は発表者の計測として帰属させる。高速化を示唆する Ultrafast の soon 表示は今号の対象に含めない。日付は日の単位までしか確定しない。

Google は 9 月 30 日、Gemini 4 Argon を発表した [3]。100 万という枠は出力トークンの上限であり（64K からの拡大とされる）、入力コンテキストの大きさや API 提供の広がり、展開範囲の広さをこの文言から推し量ってはならない。モデル文書による確認は積み残しである。導入価格は入力 2 ドル・出力 10 ドルで 95%割引、導入後は入力 4 ドル・出力 20 ドルとされる。ベンダー側の到達点として DeepSWE 77.9%、AutomationBench 51.3%、LVBench 91.7%、CWE 68%タイが置かれ、テスター限定の構えとされる。三者を比べると、今週の最前線は世代交代ではなく料金と提供形態の競争だったことがわかる。

	料金（100 万トークン）	提供と計測
Sonnet 5.5	入力 2 ドル・出力 10 ドル・読取 0.20 ドル	1M context・128K 出力・3 クラウド。TB 70.6%等はベンダー計測
GPT-6.1 Sol	入力 2 ドル・出力 10 ドル・読取 0.10 ドル	変更履歴突き合わせ済み。性能差分は発表者計測
Gemini 4 Argon	導入 2/10 ドル（95%割引）・以後 4/20 ドル	出力 100 万上限のみ確定。DeepSWE 77.9%等はベンダー・テスター限定

表 1　3 モデルの料金・提供・計測の切り分け。いずれも発表時点の公式ページで、請求実測・独立再現はない。

資料と評価の境界

料金表は発表時点の公式ページであり、請求額の実測ではない。評価の詳細は本号の検証範囲外であり、数値はベンダー側の報告として独立した再現を待つ。相手の数値は公開報告からの引用であり、横断的な順位づけには使わない。出力 100 万の枠を入力や到達済み推論と読み替えない。

2 Open Reasoning

JAPANESE OPEN WEIGHTS

公開ウェイトの推論モデル——Holo4 の 2 機種と ELYZA Thinking の日本語特化

汎用と日本語特化の 2 系統。ライセンスの切り分け、重みの特定、ベンチマークの分母をそろえて読む。

H Company は 9 月 28 日、エージェント向けモデル Holo4 の 2 機種をリリースした [4]。27B の高密モデルと 35B-A3B の Mixture-of-Experts モデルは名称が

似ていても別物として扱う。高密モデルは研究・非商用ライセンス、MoE モデルは Apache-2.0 であり、この切り分けを取り違えると利用可否の判断が崩れる。OSWorld で 85.2%と 80.8%、OSWorld2 で 61.7%と 30.9%と置かれるが、非公開評価セットの扱いは積み残しで、独立した再現はない。Holo4 Nano は下位機種であり、別の今週の出来事にはしない。

ELYZA は 10 月 2 日、Thinking LLM-jp-4 の 2 機種を公開した [5]。33B モデルが 61.69、日本語 62.18、MoE モデルが 58.46、日本語 59.61 で、日本語に寄せた手法と完全な表をそろえ、発表者の計測として分母つきで載せる。重みはコミット SHA で特定し（33B は 6ca556b2ddc4642580752b3a1ae2d7e768、MoE は 5260ecc249f32ef5005ef940c78f41）、ライセンスは Apache-2.0 である。軌跡表示盤と言語モデル用データセットへの言及はあるが、再生実行まではしていない。

読み分けの要点は、汎用エージェント用途の Holo4 と日本語特化の ELYZA という方法の違いにある。Holo4 は OSWorld 系の汎用操作ベンチマーク、ELYZA は日本語を含む言語別スコアで測られており、物差しが違うため単純な横並びの優劣にはしない。手法・分母・ライセンス・重みの特定可能性をそろえた比較表を添える。

	Holo4（汎用）	ELYZA Thinking（日本語特化）
機種とライセンス	27B 高密（研究・非商用）と 35B-A3B MoE（Apache-2.0）	33B と MoE（いずれも Apache-2.0、SHA 特定）
ベンチマーク	OSWorld 85.2/80.8・OSWorld2 61.7/30.9（発表者、私的セット積み残し）	33B が 61.69/日本語 62.18・MoE が 58.46/日本語 59.61（発表者、完全な表）

表 2　Holo4 と ELYZA の切り分け。物差しが異なるため横断順位にはしない。

資料と評価の境界

2 機種ずつの区別と許諾の違いは利用の前提であり、取り違えない。公開の物差しは発表側の計測であり、私的な評価集合の話は積み残し、独立の再現はない。再生の軌跡を見る盤面の言及は再走の証拠ではない。

3　Decision Inference

INTERFACES AND WEIGHTS

判断支援の 3 界面——Ollama の API、Clef の重みと API、Strands Decider の pointer head

9 月 29 日のインターフェースと 10 月 1 日の重み・モデルを混ぜない。入力と出力、測定条件、ライセンスを面ごとに読む。

Ollama は 9 月 29 日、v0.35 で判断支援モデル向けのインターフェースを開けた [6]。/v1/systemone という API に、Nimble 9B と Tev1 の 4B・0.8B モデルが並ぶ。ブログ本文は通読済みの範囲の話である。91 ミリ秒という数値は単一事例の例示であって、普遍的な性能ではない。ここは新しいモデルの登場ではなくインターフェースの話として読む。レジストリや API 文書の差分は積み残しである。

Cloudflare は 10 月 1 日 15 時 34 分 02 秒（UTC）に Clef をリリースした [7]。重みは Apache-2.0 ライセンスで公開され、Jev API、6 万 4 千トークンのコンテキストと画像入力、入力 0.24 ドル・出力 0.09 ドルの料金が並ぶ。入力は意思決定タスクの記述と画像、出力は判断結果と根拠という構成である。Jev Index の先行結果やレイテンシはベンダーが主催するデモ環境での計測であり、独立した再現ではない。重み配布ページの存在は確認したが、重みファイルの取得まではしていない。Ollama のインターフェースや Strands のモデルと数値・レイテンシ・ライセンスを混ぜない。

Strands は 10 月 1 日、Decider 2B をリリースした [8]。Qwen3.5-2B ベースに pointer head と r16 LoRA を添えた構成で、ベンダー帰属つきの JevBench 結果とレイテンシ、Apache-2.0 ライセンスの三重確認が示される。重み配布ページの版は v19 で固定する。先頭表示が古い版の様相を見せる配布ページの癖があるため、版の管理は欠かさない。ハイブリッドエージェント向けという位置づけはベンダーの助言として読む。

時系列の整理として、9 月 29 日は Ollama のインターフェース公開、10 月 1 日は Clef の重み・API 公開と Strands Decider 2B のモデル公開である。入力・出力・測定条件・ライセンスの 4 点を面ごとに切り分けると、3 者は判断支援という同じ層にいながら技術面が重ならないことがわかる。

資料と評価の境界

インターフェースの話と重みの話とモデルの話は別の面であり、数値や許諾や待ち時間を混ぜない。91 ミリ秒は一点の例示であり、普遍の速さではない。Jev 指数や待ち時間はベンダーが主催するデモの計測であり、独立の再現ではない。重みの中身の取得や文書の差分は積み残しである。

4 DevDay Surface

PRODUCT SURFACE

DevDay の製品面——コンピューター操作 API、常駐エージェント dots、発表の束ね

変更履歴の文言の範囲で読む。何が出荷されたかの記録であり、信頼性の証拠ではない。

OpenAI の Agents API に、ホスト型ブラウザーでのコンピューター操作機能が加わった [9]。人が預かる計算機を、認可やサインインの始末を利用者側の手続きに任せて操るもので、API と Codex、Work の Pro500 や Enterprise プランとの組み合わせで提供される。変更履歴の逐語が根拠であり、利用方法は読み取れるが、ここからブラウザーの安全性や信頼性を引き出してはならない。操作手順の解説文書は未読である。

dots は、Astra の技術を土台とする常駐型エージェントという位置づけである [10]。クラウド上のコンピューターとブラウザー、4000 超のプラグイン、読み取り専用の先回り動作、自動レビューが並ぶ。Pro や Biz-Premium と Enterprise・Edu のベータ提供の組み合わせも示される。製品説明の範囲として読み、測定された成果とは切り分ける。

DevDay の発表の束ねは、30 番目の見出しにはしない [11]。Ultrafast プラン、Decisions プレビュー、エージェントのコンピューター操作、Codex ファミリー、プラグインや Space や Pro500 やマーケットプレイスが一束になった目録であり、支えとして小さく載せる。見出しに立てれば製品カタログの羅列になるだけである。

資料と評価の境界

変更履歴は、何が出荷されたかの記録であり、見守りや確からしさの証拠ではない。操作手順の解説文書は未読である。製品説明の文言を測定された成果と読み替えない。束ねは支えであり、見出しにはしない。

5 Safety and Provenance

SAFETY

安全性と来歴の 5 領域——来歴評価、公開ガードレール、透かし、指針、認可仕様

5 つの独立した領域を別々に読む。単一の安全性スコアには束ねない。

ProvenanceGuard は、今週のチームブログ記事に載った出来事と、対象期間より前の 4 著者の論文（v1 と 7 月 26 日の v2）だけで読む [12]。v3 の有無については何も言わない。ルーティングと自然言語推論、帰属づけと許可・遮断、RARR という構成で、281 件の追跡のうち 138 件と 139 件を検出し、F1 スコアで 0.802 と 0.858、複数情報源の組み合わせで 0.846、0.503、0.229 と置かれる。ベースラインとの比較は支えに回し、修復やフォールバック、半々のプローブも添える。これは帰属関係を評価する層の話であり、実行規制や電子透かしの話と混ぜない。

測定値の読み方に注意が要る。281 件という母数、F1 の 2 条件、複数情報源の 3 条件は、それぞれ別の実験設定の数値であり、一つの優劣に畳んではならない。図表はテキストの仮置きとして読み、5.4 節以降や付録の範囲を超えた部分は未読である。コードやポスター、リポジトリの変更提案は開いていない。来歴評価という機能に限った読みとする。

NVIDIA の Open Agent Safety Platform は、公開されたエージェント見守りのリファレンスアーキテクチャである [13]。OpenShell の OSS ランタイムは広く提供され、Sentry の BlueField-4 リファレンス構成はミリ秒単位の隔離と DOCA による計測を添える。Vera 向けに最適化し、Arm や Intel にも拡張可能とされる。参照構成の文書として読み、どの環境でも動作する証拠にはしない。

SynthID Bio は、タンパク質に電子透かしを埋め

込み、実験室試験で機能を保ったという報告である [14]。3 つの標的で確かめ、9 月 30 日の Nature 論文が根拠で、10 月 1 日の X 投稿は関心の広がりを示すにすぎない。コードもデータも重みも公開された。バイオセキュリティ層の話題として読む。

残る 2 件は小さく添える。最前線モデルの学習向け安全事例集は、アライメントと封じ込めと監視に運用と事後対応を添えた指針文書であり、実証の報告ではない [15]。Workers OAuth Provider v1 は、分割された API と 2026 年 7 月 28 日の MCP 認証、段階的スコープ引き上げの仕様の話題で、仕様への準拠と脅威への耐性は別の事柄である [16]。索引の入り口まで読んだ範囲の話とする。

資料と評価の境界

5 つの領域は独立であり、単一の安全性スコアには束ねない。論文の版は v2 までに留め、v3 の有無は言わない。構想の文書を動作の証拠に、指針の文書を実証に、仕様準拠を脅威への耐性に読み替えない。X の日付は関心の広がりであり、根拠の日付ではない。

6 Training Methods and Systems

TRAINING

学習の仕組み——ContextLM の方程式と Olmo-core 3 の分散学習

編集可能なコンテキストファイルと専門家混合モデルの仕組みを、式と分母と実験条件つきで読む。今号の技術的な読みどころである。

ContextLM は、コンテキストを Bash と同期する編集可能なファイルとして扱う [17]。接頭辞再利用の計算量を FLOPs という物差しで測る。式 3 の定義は、最初の不一致以降のトークンの再プリフィル計算量と新規生成トークンのデコード計算量の合計であり、壁時間でもキャッシュヒット率でもない。一致した接頭辞部分は課金されないという約束が要点である。ここを外すと後の削減率の話がすべてずれる。

式 5 はスキル進化ループの記述である。モデルの重みは固定したまま、スキル文書 s を最適化し、学習用・開発用・ホールドアウトの 3 分割で運用し、ホールドアウトでは一度だけ評価する。持ち越し精度の改善は最大で 35.9 ポイントと置かれる。式の本体は次の最適化目的であり、コンテキスト内に技を置く流儀である。

$$s^{*} = \arg\max_{s} E_{x \sim D}[R(\tau(x; s))]$$

式 6 は別の強化学習であり、成功軌跡が 2 本に満たない群では効率項だけが沈黙し、成否項は残る。成功者の中を推論コスト順に並べ替える仕掛けであり、正誤の判定そのものは成否項が担う。式 4 は検証済みのとおりで動かない。接頭辞再利用の定義式と効率項の式をここに固める。

$$\mathrm{FLOPs}_{\mathrm{prefix-reuse}} = \mathrm{FLOPs}_{\mathrm{prefill}} + \mathrm{FLOPs}_{\mathrm{decode}}$$

$$A_i^{\mathrm{eff}} = \mathrm{clip}((\bar{c}_g - c_i)/\bar{c}_g, -1, 1)$$

式 5 の全文引用の範囲を超える細目は扱わない。

数値の土台は混ぜない。BCP は 59.4%で相対 11.4%の改善、向かう先は Codex 流要約という最強のベースラインである。接頭辞再利用の削減は同ベースラインに 21.5%、MEM1 に 28.9%で、両者は統合しない。TB2.1 は同等精度で 7 割の計算量、TBLite は 73.7 対 67.0 で 9 割 1 分の計算量で、土台は同じ Codex 流である。EdgeBench の 12 時間 10 タスクは正答率 5%向上・計算量 59%削減、スウォームは 65%向上、オンライン強化学習は Qwen3.5-9B で 28.8 から 42.5 へと 13.7 ポイント改善、同一手順の Codex 要約ハーネス比で 0.4 ポイント・38.8%削減と置かれる。いずれも論文の主張であり、許諾は論文が BY-4.0、リポジトリが BY-NC-4.0 である。

指標	数値と土台（すべて論文の主張）
BCP	59.4%・相対+11.4% 対 Codex 流要約
FLOPs 削減	21.5%対同左・28.9%対 MEM1（統合しない）
TB2.1 / TBLite	同等精度で計算量 70%・73.7 対 67.0 で計算量 91%、いずれも対 Codex 流
EdgeBench / RL	+5%・計算量 59%削減、28.8 → 42.5（表 2 土台）

表 3　ContextLM の主要数値と土台の切り分け。独立再現ではない。

Olmo-core 3 は、専門家混合モデルの分散学習基盤である [18]。DDP に専門家を常駐させ、GPU 上で expert routing を決めて並べ替えの余分を抑え、grouped-GEMM と MXFP8 で固める。MXFP8 の効果は B300 4 枚の均一負荷という統制された構成での話で、エンドツーエンドの学習スループットが 21%伸び、103GiB が 95GiB に減ると置かれる。他の構成への一般化はしない。専門家を 8 から 128 に増やし、

トークンあたり 4 専門家（能動約 3.2B）で動かしても、スループットは 5%も落ちない。8 枚 B300 の予備試験では旧実装の約 2.7 倍と置かれる。

測定の置き場は 3 つに分ける。47B は実測値、1.2T はルーティング条件（能動 58.36B・512 GPU・最大 858TFLOP/s/GPU、ランダムルーティング下のシステム測定であり、モデル品質の主張ではない）、2.38T は短時間の容量試験である。3 つを一つの規模に束ねてはならない。うまくいかなかった実験も載せる。ルーティング均一化スコアは失敗に終わり、測定方法論への戒めとして残る。報告書本体は未取得であり、論文付録や図の言及のない中身は扱わない。

資料と評価の境界

式の読みは一次資料の範囲であり、全文引用の範囲を超える細目は扱わない。数の土台は混ぜず、相対と差分、論文とリポジトリの許諾を切り分ける。3 つの規模は別の置き場であり、一つに束ねない。報告書本体や付録の言及のない中身は扱わない。

7 Evaluation Infrastructure

EVALUATION

評価基盤——AgentPerf の再実行、OpenTTS の測定手順、RL 環境置き場

評価台とモデルを取り違えない。測定手順・到着時期・版の留めを正確に読む。

AA-AgentPerf-Local は、手元で実行するオープンな再実行ベンチマークである [19]。実軌跡を Spark や 5090 や Halo や M5Pro でなぞり直す。実行構成は 14 通りすべてが仮説的と明記され、発表者の計測として置く。サービングの話に限る品であり、エージェントの賢さの話ではない。帯域制約ルーフラインとの比較は理論上限線に対する成功群の嵩上げ（Qwen3.8-27B で 3 割から 120%ほど、構成による幅）であって、仕様なしの対照ではない。一人で実行する手元環境と、混雑時の本番環境（メガワットあたりのエージェント数という別の物差し、6 月 12 日の別の記事）は方法も指標も別物であり、数値の貸し借りはしない。依存関係は明示する。

Open TTS Leaderboard は、多言語・声クローニングの客観評価基盤であり、新しい音声モデルではない [20]。英語の巨視的平均の単語誤り率、多言語の文字誤り率、RTFx（バッチ化オフライン推論、H200）と TTFA と SIM を、Seed-TTS と CV3 の上で測る。TTFA 手順は一句ごとに検証済みで、同じ英語 50 プロンプト、バッチサイズ 1、最初の 3 走をウォームアップに除き、残りの中央値、H200 の表示が既定で、CPU の小規模な増加集合も添う。人の好みは測っていないとブログが明記する。比較はスナップショット時点の話であり、普遍の順位にはしない。

到着時期の切り分けは欠かさない。場と物差しの本体は今週にあるが、評価スクリプトは 9 月 30 日の記事では「まもなく公開」という未来形である。リポジトリの初の評価スクリプトの固まりは 10 月 7 日 14 時 53 分 41 秒（UTC）と確認した。対象期間の締め切り（10 月 2 日 22 時 UTC）の時点ではリポジトリにスクリプトはなく、9 月 15 日のリポジトリ作成をもって公開と読んではならない。調べたリポジトリの範囲の話であり、どこにも公開されていないことの証拠ではない。

RL Environments Hub は、強化学習環境のタスクセット目録である [21]。rl-environment フィルターと 4 つのフレームワークタグ（harbor・verifiers・openenv・nemo-gym）、枠ごとの実行例が並ぶ。タスクセットのデータと実行時・報酬の切り分けを保ち、新しいリポジトリ型はなく、タグは互換性の宣言であって変換や起動の話ではない。フレームワークの版固定（harbor==0.21.0 など）がタスクセット全体を固定するかのように読んではならない。タスクセットのリビジョンや選択基準、実行基盤の固定は未確定として明記する。再現用の種の固定も、固定できない所はできないと書く。

資料と評価の境界

評価台の話とモデルの話は別であり、運びの話を使い手の賢さに読み替えない。屋根線の比較は上限線への嵩上げであり、仕様なしの対照ではない。スクリプトの到着とリポジトリの作成は別の事柄であり、未来形を公開済みと読まない。枠の版固定を束ね全体の固定と読まない。

8 Multimodal Serving

MULTIMODAL

マルチモーダルの提供現場——画像・映像・音声・可観測性

デモ測定はデモのままに読む。料金と解像度、測定項目と実行条件、時系列の正しさを添える。

Black Forest Labs は 10 月 1 日、FLUX 3 の画像 SKU を出した [22]。絵の勘所は 0 から 1000 のグリッドで置くバウンディングボックスで、全体の説明文と箱ごとの指示例、箱単位の多段階編集という運びである。7 月 23 日のマルチモーダル基盤発表（早期アクセス、映像優先、画像は後数週）は別の出来事であり、混ぜない。X の 10 月 1 日の投稿は関心の広がりを示すにすぎず、単独の典拠にはしない。

解像度	料金（10 月 1 日リリースノート、計算機の既定は 1k）
768 正方形	0.041 ドル
1k	0.048 ドル
2k	0.100 ドル
4k	0.607 ドル

表 4　FLUX 3 の解像度別料金。開始特価は 10 月 1 日 15 時 UTC から 8 日まで半額（見出し帯から確認、開示済み）。料金は発表時点の文書の内容である。

NVIDIA の VSS Blueprint 3.3 は 9 月 29 日のリファレンスアーキテクチャである [23]。Build Vision Agent スキル（vss-build-vision-ai）と Adaptive EVS（コサイン類似度のパッチ枝刈りとイベントバッチ処理）を添え、VLM と RAG と MCP の映像ワークフローを扱う。ボトリングラインのデモでは、RTX PRO 6000 2 枚で 30 分に満たない導入、警告レイテンシ 17%減（1021 から 844 ミリ秒）、同時配信 46%増（13 から 19 本）、60 分要約の約半分の時間と VLM トークン 80%減（Cosmos 3 Super FP8）と置かれる。結果は構成により変わると明記される。生成映像の基盤モデルではなく参照構成の文書として読む。

時系列の正しさが要る。NVIDIA は 10 月 1 日 9 時 00 分 PDT（UTC で同日 16 時）のライブ配信を 9 月 29 日に事前告知しており、この日時は対象期間の締め切り（10 月 2 日 22 時 UTC）より前、すなわち期間内である。告知するのは配信予定であって、配信の実施内容や追加成果を独立検証したものではない。従来の下流分類にあった対象期間後の扱いは誤りであり、本稿では期間内の事前告知として読む。承認済みアーキテクチャと受理済み証拠の文言自体は改変しない。

Nemotron のサウジアラビア方言適応は、チュートリアル範囲の報告である [24]。NeMo の手で Najdi と Hijazi を 133.7 時間、単語誤り率は 55.05%から 29.96%へ、英語は維持し、24 層の深さの検討やビーム 8・800 ミリ秒の追加、8 話者までの話者分離の拡張も添う。評価は SADA と FLEURS の分割ごとの話であり、どの方言にもどの運用にも通じる話ではない。発表者の計測として読む。関連するノートブックやスキル、話者分離のブログへの言及はあるが、内容の取得まではしていない。

脇の 2 件は小さく添える。NeMo Relay は、ATOF と ATIF と OTel-Phoenix による計装に Hermes チュートリアル（VALUE=42、COLT 2026）と ToolPerf の 108 走の事例を添えたもので、道具立ての話であり、信頼性の証拠ではない [25]。実網での実行は試してあって順位ではない。Ross は、MCP と知識ベースとスキルと作例、Vivado と Vitis と ROCm、相手を選ばない構成で、提供開始済みと月次の歩みとされる [26]。高速化の売り文句は未測定の触れ込みであり、チュートリアル程度の重要性として埋め込みの注記に留める。

資料と評価の境界

デモの計測はデモのままに読み、効率の一般や確からしさの証拠に広げない。半額の帯は見出しの催しであり、土台の話と混ぜない。配信予定の事前告知と実施内容の検証は別の事柄であり、後者は未検証とする。分け目ごとの話を普遍に広げない。速さの売り文句は未測定の触れ込みである。

9　Enterprise Digest

INDUSTRY

企業・業界動向——確定契約と提供条件

製品の話題ではない。契約の確定と提供条件だけを短く載せる。

AMD と World Labs は、買収の確定契約を結んだという発表である [27]。完了の報告ではなく、空間モデルという筋書きが添えられる。評価額の話は検証していない。モデルの新登場として読んではならない。企業・業界の出来事として短く載せる。

Cloudflare の AI Search は、提供条件の文書である[28]。ハイブリッド検索が既定で、Workers AI が含まれ、マルチモーダルと画像検索、走査 PDF の OCR（10MiB と 4MiB）、11 月 1 日の課金が並ぶ。ベンチマークの話題ではなく、提供の約束として読む。

資料と評価の境界

契約の確定と完了は別の事柄であり、評価額の話は検証していない。提供条件をベンチマークの話題に読み替えない。

10 Week in Review

WEEKLY SYNTHESIS

今週は、料金表と学習の仕組みが並んだ

料金と提供形態、公開ウェイトとライセンス、判断支援の分化、製品面、安全性、学習と評価、提供現場が同時に前景化した。

今週何が変わったか

1. **料金表と提供条件が動いた。** 9 月 28 日の Sonnet 5.5、9 月 29 日の GPT-6.1 Sol（入力 2 ドル・出力 10 ドル・キャッシュ読み取り 0.10 ドル、100 万トークンあたり）、9 月 30 日の Gemini 4 Argon（出力 100 万トークンの上限、導入価格とテスター限定）である。いずれも発表時点の公式ページであり、請求額の実測ではない。
2. **公開ウェイトの推論モデルが 2 系統になった。** Holo4 の汎用 2 機種（ライセンスの切り分けつき）と ELYZA の日本語特化 2 機種（SHA 特定・Apache-2.0・分母つきの表）である。軌跡の再生実行まではしていない。
3. **判断支援の界面が分かれた。** 9 月 29 日の Ollama のインターフェース、10 月 1 日の Clef の重みと API、Strands Decider 2B のモデルで、数値や許諾の混ぜ合わせはしない。DevDay の窓口は変更履歴の文言のままに読む。
4. **安全性は 5 領域である。** 来歴評価、公開ガードレール、透かし、指針、認可仕様を別々に読む。単一の安全性スコアには束ねない。
5. **学習と評価が深掘りになった。** ContextLM の式と分母と土台、Olmo-core 3 の仕組みと 3 つの置き場、AgentPerf の再実行、OpenTTS の物差しとスクリプト到着、RL 環境置き場の目録である。提供現場はデモ測定のままに読む。

なぜそれらが一緒に重要なのか

料金の競争と公開ウェイト、判断支援層の分化、働く窓口の製品説明、安全性の分離、学習の手筋と評価基盤の具体化がそろって進んだ点にある。数値と利用条件、報告主体を切り離さない読みが条件になる。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作パラメーターの小ささを共通効率へ、利用条件の表示を共通ライセンスへ、速度やスコアを横断的な順位へ自動的に変換してはいけない。

Weekly Community Movement — context only

公開投稿では、最前線の料金、公開ウェイト、判断支援層への関心が、公式発信に独立した言及が重なる形で観察される。これは今週の関心の広がりを示す背景であり、仕様や性能、提供条件、互換性を証明するものではない。締め切り後の速報は通常の集計には含めない。

次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。Argon の出力枠の運用実態と請求額、Sol の Ultrafast の提供、Holo4 の非公開評価セットの開示と独立した再現、ELYZA の軌跡の再実行、Clef の重みの中身と Jev 指数の独立した確かめ、Strands の配布ページの版の動き、dots の試しの積み重ね、ProvenanceGuard の v3 をめぐる動き、SynthID Bio の符号や資料の利用、ContextLM の報告書本体の公開、Olmo-core 3 の付録の開示、AgentPerf の構成の広がり、OpenTTS のスクリプト到着後の再評価、FLUX の催し後の料金、VSS の集まり後の文書、Nemotron の分け目を超えた話題、World Labs の契約の行き先、AI Search の課金後の運用はまだ詳細化されていない。さらに、載せなかった 2 件のホスト記事の一次資料の受け入れ整理の行き先も、次の観測点として残る。ベンダーや研究機関の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。ベンダーが示す速度、報道が伝える仕様、研究機関が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能順位へまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。

Sources & Limitations

Primary sources consulted

9 月 28 日の Anthropic の Sonnet 5.5、9 月 29 日の OpenAI の GPT-6.1 Sol、9 月 30 日の Google の Gemini 4 Argon、9 月 28 日の H Company の Holo4、10 月 2 日の ELYZA の Thinking LLM-jp-4、9 月 29 日の Ollama の v0.35、同日の OpenAI の Agents API のコンピューター操作機能と dots と DevDay の発表の束ね、9 月 29 日の ProvenanceGuard のチームブログ記事、9 月 28 日の NVIDIA の Open Agent Safety Platform、9 月 30 日の SynthID Bio、9 月 28 日の OpenAI の安全事例集、10 月 1 日の Cloudflare の OAuth Provider v1、9 月 29 日の Context Language Models（arXiv v1 と r16 一次注記つき）、10 月 1 日の Olmo-core 3、9 月 29 日の AA-AgentPerf-Local、9 月 30 日の Open TTS Leaderboard、9 月 28 日の Hugging Face の RL Environments Hub、10 月 1 日の FLUX 3、同日の VSS Blueprint 3.3（9 月 29 日の事前告知つき）、9 月 30 日の Nemotron のサウジアラビア方言適応と NeMo Relay と AMD Ross、9 月 28 日の AMD と World Labs の確定契約、10 月 1 日の Cloudflare の AI Search、10 月 1 日の Clef と Strands Decider 2B を範囲として読んだ。本号では全文 PDF や手法の細目、図表の詳細までは扱わず、その範囲を超える主張は行わない。

Temporal boundary

通常の範囲は 2026-09-25 18:00 から 2026-10-02 18:00（いずれも America/New_York、終了時刻は含まない）。VSS の 10 月 1 日 9 時 00 分 PDT の事前告知は、UTC で同日 16 時にあたり対象期間内である。10 月 7 日のスクリプト到着、10 月 8 日までの半額の終わりは範囲の区切りとともに読む。リポジトリの作成をもってスクリプトの公開と読まない。日付は日の単位のものが多く、時刻レベルの断定は確かめたものに限る。

Vendor-reported boundary

測定値や比較、コスト、スループット、利用見通しの説明は、ベンダーやモデルの配布元、提携の報告として受け止め、独立した再現とは切り分ける。Sonnet 5.5 の 70.6%や 1844、Sol の料金表、Argon の到達点、Holo4 や ELYZA の表、Clef や Strands の待ち時間、VSS や音声認識のデモ測定といった値はベンダー側の報告であり、条件の違いを含めて本号の検証範囲外である。

Community observation boundary

公開投稿の台帳は原則として関心の方向を示す背景にとどめる。ただし、一次発表として本文で明示的に引用した公式アカウントの投稿は、その発表内容に限って一次資料として扱う。台帳に載っているという事実だけでは、いかなる行も技術的な根拠に格上げしない。独立した投稿やコミュニティの反応は、仕様やベンチマーク、日付、利用条件、価格、ライセンス、アーキテクチャ、公開事実の根拠にはならない。全行の内訳は本号の公開台帳（community-observation-ledger.md）で直接確かめられる。行単位の台帳を正とし、要約文の数えに頼らない。

What was not elevated

2 件のホスト記事（AstaBrief と AutoSynthData）は、一次資料の受け入れ整理が終わっていないため今号の章には載せない。いずれも対象期間内の素材的に重い品であることは認め、載せない理由を隠さない。64GB の品の第三者の入手方法は未来の話として、今号の品にはしない。収集の台帳そのものは方法論の覚えに残し、物語には入れない。対象期間より前の論文 1 件は文脈としてのみ扱う。噂の段階の話題は今週の技術的な出来事として取り上げない。

References

[1]Anthropic. *Claude Sonnet 5.5*. Primary official source; Sep 28 release with price card and safeguard posture. Terminal-Bench 70.6% and GDPval-AA 1844 vendor-reported, attributed; no independent reproduction. URL: https://anthropic.com/claude-sonnet-5-5 (visited on 10/10/2026).

[2]OpenAI. *Introducing GPT-6.1 Sol*. Primary official source; Sep 29 model with verified price card (2/10/0.10 USD per 1M tokens) cross-checked against changelog. Vendor benchmark deltas attributed; Ultrafast-soon excluded. URL: https://openai.com/index/introducing-gpt-6-1-sol/ (visited on 10/10/2026).

[3]Google. *Gemini 4 Argon*. Primary official source; Sep 30 model. Source-precise 1M OUTPUT-token limit (never input or GA inference); intro pricing and vendor SOTAs attributed; tester-only posture. URL: https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-4-argon/ (visited on 10/10/2026).

[4]H Company. *Holo4 Agent Models*. Primary official source; Sep 28 pair: 27B dense (research-noncommercial) vs 35B-A3B MoE (Apache-2.0), kept split. OSWorld 85.2/80.8 and OSWorld2 61.7/30.9 publisher-run; private-set eval pending; no independent reproduction. URL: https://hcompany.ai/newsroom/holo4 (visited on 10/10/2026).

[5]ELYZA. *ELYZA Thinking LLM-jp-4 Models*. Primary official source; Oct 2 eligible pair with pinned SHAs, Apache-2.0: 33B 61.69/JA62.18 and MoE 58.46/JA59.61 with JA-localized method and complete tables, publisher-measured. Trajectory replay not executed. URL: https://huggingface.co/elyza/ELYZA-Thinking-1.0-llm-jp-4-33b/blob/6ca556b2ddc4642580752b3a1ae2d7e768 (visited on 10/10/2026).

[6]Ollama. *Ollama Now Supports Jev-Style Decision Models*. Primary official source; Sep 29 v0.35 systemone interface with Nimble 9B and Tev1 4B/0.8B (blog fully read). 91ms single-example illustrative, not universal. Interface, not a model release. URL: https://ollama.com/blog/ollama-now-supports-jev-style-decision-models (visited on 10/10/2026).

[7]Cloudflare. *Clef Decision Models*. Primary official source; Oct 1 15:34:02Z release: Apache-2.0 weights, Jev API, 64K context plus vision, 0.24/0.09 USD. Jev-Index lead and latencies vendor-measured at vendor-hosted demo; weight files not downloaded. URL: https://blog.cloudflare.com/clef-decision-models/ (visited on 10/10/2026).

[8]Strands. *Introducing Strands Decider*. Primary official source; Oct 1 Decider 2B (Qwen3.5-2B plus pointer head plus r16 LoRA). JevBench and latency vendor-attributed; Apache-2.0 triple-confirmed; Hub v19 pin with head-shows-v1-era discipline. URL: https://strandsagents.com/blog/introducing-strands-decider/ (visited on 10/10/2026).

[9]OpenAI. *API Changelog: Computer Use*. Primary official source; hosted-browser computer use with application-handled approvals and sign-in, changelog-verbatim. API plus Codex and Work Pro500 and Enterprise. No safety inference from changelog; guide docs unopened. URL: https://developers.openai.com/api/docs/changelog (visited on 10/10/2026).

[10]OpenAI. *Introducing Dots*. Primary official source; Astra-powered always-on agents (cloud computer and browser, 4000+ plugins, read-only proactivity, auto-review). Pro and Biz-Premium plus Enterprise and Edu beta. Product description, not measured outcome. URL: https://openai.com/index/introducing-dots/ (visited on 10/10/2026).

[11]OpenAI. *DevDay 2026 Recap*. Primary official source; announcement bundle (Ultrafast tier, Decisions preview, Agents computer use, Codex family, plugins and Space and Pro500 and Marketplace). Bundle hub as supporting spine, never a headline. URL: https://openai.com/index/devday-2026-recap/ (visited on 10/10/2026).

[12]ProvenanceGuard Team. *Getting the Source Right, Not Just the Fact Source*. Primary official source; W40 team-blog event plus pre-window paper v1 and v2 (Jul 26, four authors; NO v3 asserted): routing plus NLI plus attribution plus allow and block plus RARR; 281 traces, 138 and 139 caught, F1 0.802 and 0.858; multi-source 0.846, 0.503, 0.229. Baselines support-only. URL: https://huggingface.co/blog/MultiverseComputingCAI/getting-the-source-right-not-just-the-fact-source (visited on 10/10/2026).

[13]NVIDIA. *Open Agent Safety Platform*. Primary official source; Sep 28 reference architecture: OpenShell OSS runtime (broadly available) plus Sentry BlueField-4 reference (millisecond quarantine, DOCA). Vera-optimized, Arm and Intel-extendable. No platform-availability claim. URL: https://nvidianews.nvidia.com/news/open-agent-safety-platform (visited on 10/10/2026).

[14]Google DeepMind. *Introducing SynthID Bio*. Primary official source; protein watermarking preserving lab-tested function on 3 targets; Nature paper Sep 30 (X Oct 1 is momentum only); code, data and weights released. Biosecurity layer, not a capability claim. URL: https://deepmind.google/blog/introducing-synthid-bio/ (visited on 10/10/2026).

[15]OpenAI. *Towards Safety Cases for Frontier AI Training*. Primary official source; aspirational safety-case guidelines for frontier RL training (alignment, containment, monitoring plus ops plus incident). Guidance document, not empirical demonstration. URL: https://openai.com/index/towards-safety-cases-for-frontier-ai-training/ (visited on 10/10/2026).

[16]Cloudflare. *Workers OAuth Provider v1*. Primary official source; OAuth Provider v1 split API plus MCP 2026-07-28 auth plus step-up scope (index entry read). Spec adherence is not threat resistance. URL: https://developers.cloudflare.com/changelog/product-group/developer-platform/ (visited on 10/10/2026).

[17]ContextLM Authors. *Context Language Models*. Primary research source; arXiv v1 section 4.2 Eq.5 verified (exact objective, symbols, fixed-weight train, development and held-out procedure). Eq.6 RL parameter training separate. Paper BY-4.0, repo BY-NC-4.0. Report body and appendices beyond retrieved scope unclaimed. URL: https://arxiv.org/abs/2609.37725 (visited on 10/10/2026).

[18]Ai2. *Olmo-core 3*. Primary official source; Oct 1 MoE systems: DDP resident experts with GPU-resident routing, grouped-GEMM, MXFP8 controlled B300x4 (+21%, 103 to 95 GiB, uniform load). 47B measured vs 1.2T routing vs 2.38T capacity kept separate; negatives documented; report body unretrieved. URL: https://allenai.org/blog/olmocore3 (visited on 10/10/2026).

[19]Artificial Analysis. *AA-AgentPerf-Local*. Primary official source; open local-serving benchmark replaying real trajectories (Spark, 5090, Halo, M5Pro; 14 speculative configs; publisher-measured). Serving-only scope; bandwidth-constraint roofline comparison; local single-user vs production-concurrent kept separate. URL: https://artificialanalysis.ai/articles/aa-agentperf-local (visited on 10/10/2026).

[20]Hugging Face. *Open TTS Leaderboard*. Primary official source; Sep 30 objective multilingual and voice-cloning evaluation platform (WER, CER, RTFx, TTFA, SIM over Seed-TTS plus CV3; Spaces plus scripts). TTFA protocol 50 prompts, batch 1, 3 warm-ups excluded, median, H200 default, each clause verified. Eval scripts future-as-of-Sep-30 vs first repo commit Oct 7; platform, not a model; no human-preference proof. URL: https://huggingface.co/blog/open-tts-leaderboard (visited on 10/10/2026).

[21]Hugging Face. *Welcome RL Environments to the Hub*. Primary official source; Sep 28 taskset catalog with rl-environment filter plus 4 framework tags and per-framework snippets. Taskset data vs runtime and reward kept separate; tag declares compatibility (no conversion or launch); framework pins do not pin taskset revisions. URL: https://huggingface.co/blog/rl-environments (visited on 10/10/2026).

[22]Black Forest Labs. *FLUX 3 Image*. Primary official source; Oct 1 BBox layout plus per-box multi-step edits; per-resolution 0.041, 0.048, 0.100, 0.607 USD plus 50%-off Oct 1 15:00 UTC to Oct 8 (banner via index, disclosed). Jul 23 foundation kept distinct. URL: https://bfl.ai/models/flux-3-image (visited on 10/10/2026).

[23]NVIDIA. *VSS Blueprint 3.3*. Primary official source; reference architecture: Build Vision Agent skill (under-30min demo on 2x RTX PRO 6000) plus Adaptive EVS vendor-demo 17%, +46%, -80% on stated config with variance caveat. Not a foundation model; Oct 1 9am PDT advance notice in-window (delivery unverified). URL: https://developer.nvidia.com/blog/lower-the-cost-of-building-and-running-visual-ai-agents-with-nvidi (visited on 10/10/2026).

[24]NVIDIA. *Nemotron Saudi Arabic ASR Adaptation*. Primary official source; Najdi and Hijazi via NeMo (133.7h; WER 55.05% to 29.96%; English retained; 24-layer depth study; beam-8 plus 800ms; 8-speaker diarization extension). SADA and FLEURS split-specific tutorial scope; publisher-measured. URL: https://developer.nvidia.com/blog/?p=122986 (visited on 10/10/2026).

[25]NVIDIA. *Tracing Agent Harness Behavior with NVIDIA NeMo Relay*. Primary official source; ATOF and ATIF and OTel-Phoenix tracing plus Hermes tutorial (VALUE 42, COLT 2026) plus ToolPerf 108-run case study. Instrumentation and tutorial, not reliability proof; companion repo unopened. URL: https://developer.nvidia.com/blog/tracing-agent-harness-behavior-with-nvidia-nemo-relay/ (visited on 10/10/2026).

[26]AMD. *AMD Ross Agentic AI Embedded Design Development*. Primary official source; Ross agent (MCP, KB, skills, examples; Vivado, Vitis, ROCm; client-agnostic; available-now plus monthly cadence). Acceleration UNMEASURED promotional; tutorial-grade materiality; embedded note only. URL: https://newsroom.amd.com/news/amd-ross-agentic-ai-embedded-design-development/ (visited on 10/10/2026).

[27]AMD. *AMD to Acquire World Labs*. Primary official source; DEFINITIVE AGREEMENT (not close) with spatial-model rationale; valuation unvalidated. Corporate event, not model news. URL: https://newsroom.amd.com/news/amd-acquire-world-labs/ (visited on 10/10/2026).

[28]Cloudflare. *AI Search Generally Available*. Primary official source; hybrid-retrieval default, Workers AI included, multimodal plus image search, scanned-PDF OCR (10MiB and 4MiB), billing Nov 1. Service terms, not model benchmark. URL: https://developers.cloudflare.com/changelog/post/2026-10-01-ai-search-generally-available/ (visited on 10/10/2026).