Japanese Generative AI Technical Survey

2026-W41

2026-10-09

測られた提供条件、確かめられた範囲

GPT-6 と Haiku 5.5 の提供条件と料金区分、検証済み API と観測・告知の層別、公開言明と取得実態の重み 7 件、画像モデルの仕様カード、透かしの数値と検証の射程、制度・公開・模擬の境界線を、一次資料の範囲と留保とともに読む。

FEATURE: FRONTIER TERMS / FEATURE: OPEN WEIGHTS / REVIEW: WHAT TO WATCH

Editorial cutoff	2026-10-02 18:00 - 2026-10-09 18:00 America/New_York
Repository	eariver/japanese-generative-ai-survey
Build	LuaLaTeX / jlreq / LuaTeX-ja

一次情報・論文・OSS・X 上の技術反応を分離し、検証可能な Evidence chain として編成する週刊 Technical Survey。

Contents

1	Frontier Models — GPT-6 と Haiku 5.5 の提供条件
2	Agent Infrastructure — 検証済み API と観測・告知の層別
3	Open Weights and Audio — 公開言明と取得実態の 7 件
4	Image Model Card — Nano Banana 2.1 の仕様読み
5	Provenance and Watermarks — textGrain と SynthID の対置
6	Safety and Science — 制度・公開・模擬の境界線
7	Community Movement — 公開投稿の関心と限界
8	Week in Review — 提供条件と検証範囲の総括

This Week in AI

提供条件が具体化した。 10 月 7 日の GPT-6 と Intelligent UI、10 月 7 日の Haiku 5.5、10 月 6 日の Decisions API beta と 10 月 8 日の Ultrafast tier、10 月 3 日の Kolibri と 10 月 7 日の d1、10 月 6 日の EmbeddingGemma 2、10 月 5 日の Beam と 10 月 6 日の Mistral Large 4、10 月 9 日の Clef-omni と 10 月 5 日の Nova Sonic、10 月 6 日の Nano Banana カードと 10 月 5 日の textGrain、10 月 7 日の SynthID 拡張、10 月 8 日の Cyber Mission と 10 月 6 日の数学公開・Ironclad 模擬が並んだ。

数値と日付は出どころごとに受け止める。 ベンチマークの値はベンダー計測によるもので、独立した再現はない。料金表は発表時点の公式ページであり、請求額の実測ではない。公開の言明と配布先の提示、実ファイルの取得、重みの公開完了は別の事柄として切り分ける。透かしの検出率と回答品質、検証の射程と効き目は混ぜない。未検証の事柄、査読前の報告、構想段階のものは、その旨を添えて読む。

載せないものは理由とともに記す。 持ち越しの 4 件は新しい日付のある証拠がなく今号の章には載せない。締め切り後の速報は次号へ送り、通常の集計には含めない。公開投稿の反応は関心の方向を示す背景にとどめる。

この号の読み方

通常本文の対象期間は 2026-10-02 18:00 から 2026-10-09 18:00（いずれも America/New_York、終了時刻は含まない）。この範囲の出来事を通常の扱いとし、期間前の持ち越し、締め切り後の速報、予告された今後の運用は区別する。本号で参照する公開資料が示す範囲を超えて断定しない。ベンダーや報道が伝える数値はそれぞれの主体に帰属させ、条件の違う測定値を横断的な順位へ言い換えない。モデルの公開場所や一次発表で確認できない仕様や利用条件は事実として扱わない。

読み解く軸： 提供条件の確定と検証範囲の確定、公開言明と実取得の切り分け、ベンダー計測の帰属、透かし検出と検証射程の分離を、一次資料の範囲と留保とともに束ねることである。

1 Frontier Models

FRONTIER

提供条件が具体化した最前線——GPT-6 と Haiku 5.5

GPT-6 の提供階層と Haiku 5.5 の料金区分が具体化した。開始遅延の定義と二段階料金の読み方が実務の分かれ目になる。

有料も無料も、新しい顔ぶれ——GPT-6 と Haiku 5.5 の提供条件を読み解く

OpenAI は 10 月 7 日、GPT-6 と新しい対話インターフェース Intelligent UI の提供を開始した。対象は Plus、Pro、Business、Enterprise の有料プランで、利用場所は Chat タブに限られる。翌 10 月 8 日には Free と Go プランにも展開された。ここでモデル割り当ての関係が重要になる。有料プランには Sol、Free と Go には Luna が割り当てられ、同じ GPT-6 の看板のもとで提供されるモデルが利用者層によって分かれている。いずれも発行元の提供ページに明記された範囲の事実であり、料金体系そのものはこのページには掲載されていない。[1]

この tier 分けは単なる価格差ではない。Chat タブ限定という提供面の指定と、Sol ／ Luna というモデル名の対応が同時に示されている点が技術的に意味を持つ。利用者が触れるのは抽象的な「GPT-6」ではなく、プランごとに異なる推論モデルだからだ。提供条件の読み取りでは、モデル名・提供日・利用場所の三点を切り離さずに押さえる必要がある。これらはいずれも提供ページの記述をそのまま受け取ったもので、第三者による検証を経た数値ではない。[1] [1][2]

GPT-6 の発表で最も誤読しやすいのが「44%高速化」という数字だ。提供ページの記述を正確に読むと、これは GPT-6 Instant と 5.6 Instant を web 検索質問のサブセットで比べたとき、回答の開始が 44%早まったという発行元測定である。仕組みは思考と回答を交互に進めるインターリーブ方式によるもので、最終回答が出そろうまでの壁時計時間（wall-time）が 44%縮んだという主張ではない。開始遅延と全体遅延は別の量であり、提供ページは前者だけを測っている。この time-to-start 限定は本記事全体で維持する。[1]

項目	内容
GPT-6 ＋ Intelligent UI	提供開始：10 月 7 日（有料 4 プラン、Chat タブ）／ 10 月 8 日（Free・Go）；モデル割当：有料 Sol、無料 Luna；遅延の定義：回答開始時間（インターリーブ思考・回答方式による）；料金：本ページに記載なし
Claude Haiku 5.5	提供開始：10 月 7 日；料金：10 万 token 境界の二段階料金（100 万 token 当たり）。10 万以下は入力$0.10・出力$0.50・cache-read $0.01・cache-write（5 分）$0.125、10 万超は入力$0.50・出力$2.50・cache-read $0.05・cache-write（5 分）$0.625。Sonnet 5.5 の cache-read 半額（$0.20 →$0.10）。実際の請求額には使用量が必要（料金表の推定額と個別の実請求額は別）；ベンチマーク：発行元計測表（GDPval 1620、OSWorld2.1 72.4%、HLE 45.9 ／ 57.4、TB4 39.2%。各評価の対象・条件・尺度は取得本文に示されていない）；system-card 全文は未取得
Ultrafast tier（関連）：gpt-6.1-sol 向け Responses API の service_tier、詳細はエージェント基盤の記事で扱う。	

表 1 比較表：フロンティア 2 件の提供条件と遅延定義

この区別は実務に直結する。体感のキレを左右する初動の速さは改善していても、長い回答全体の所要時間が同じ比率で縮む保証はどこにも書かれていない。壁時計時間の短縮を示す数値は提供ページに存在しない。system-card の数値も列挙されておらず、料金も同ページにない。開始遅延の改善として評価し、全体遅延の主張として扱わないことが正確な読み方だ。[1]

Haiku 5.5 の二段階料金——10 万 token の境界線

Anthropic は 10 月 7 日、Claude Haiku 5.5 を公開した。料金設計の要点は 10 万 token を境とする二段階制で、100 万 token 当たりの単価が示されている。10 万以下では入力$0.10、出力$0.50、cache-read $0.01、cache-write（5 分）$0.125 とされる。10 万超では入力$0.50、出力$2.50、cache-read $0.05、cache-write（5 分）$0.625 とされる。同時に Sonnet 5.5 の cache-read 料金が$0.20 から$0.10 へ半額化された。ここで分けておきたいのは、入力・出力・cache-read・cache-write という料金区分の違いだ。確認した料金表は 100 万 token 当たりの単価であり、実際の請求額には使用量が必要になる。料金区分の確認と費用の金額計算は別の作業として扱いたい。[2]

Sonnet の cache-read 半額化は、Haiku 単体の話題を超えて上位モデルの運用費に波及する。キャッ

シュ読み取りを多用するリトリーバル拡張生成や反復推論では、入力 token の実効単価が下がる方向に働く。ただし、どのワークロードでどれだけ効くかを示す実測は公開ページになく、各自の利用形態での検証が残る。価格表の読み取りとしては確定情報、効果の見積もりとしては未検証という二層で受け止めるのが正確だ。[2]

性能面では、GDPval 1620、OSWorld2.1 で 72.4%、HLE で 45.9 および 57.4、TB4 で 39.2%というベンチマーク表が示されている。これらはすべて発行元による測定であり、独立した第三者の再現を経ていない。さらに、取得本文が示すのは評価名と数値のみで、GDPval が何を、OSWorld が何を、HLE と TB4 が何を測るのか、実験条件や尺度は示されていない。表の数値をモデルの優劣の確定と読むのは時期尚早で、あくまで発行元が自社条件で測った申告値として扱うべきだ。評価対象の説明と条件の開示は system-card 側の取得待ちであり、現時点では不明とする。[2]

Haiku の測定条件の詳細は system-card 側にしかない可能性があるが、その全文評価やプラットフォーム別の識別子までは取得していない。ベンチ表の行間にある条件の深掘りは system-card 取得後の課題として残る。現時点では測定条件の留保付きで表を引用するのが限度だ。[2]

両者の確認状況は対照的だ。GPT-6 側は提供階層・提供日・モデル割当・開始遅延の定義が確定し、料金と system-card 数値は未確認である。Haiku 側は二段階料金表（100 万 token 当たりの 4 区分）とベンチ表の値が確定し、system-card 全文・測定条件が未確認である。提供条件の層では GPT-6 が厚く、価格表の層では Haiku が厚いという違いを保ったまま読み分けることが、誤読を防ぐ近道だ。[1][2]

今週を象徴するのは、2 社がそろって利用条件の具体化を進めてきたことだ。GPT-6 は提供階層と開始遅延の定義で、Haiku 5.5 は二段階料金と申告ベンチ表で、それぞれ開発者の意思決定に直結する材料を置いた。どちらも能力の飛躍をうたう発表ではなく、利用条件の確定に重心がある。ただし価格の確定度は非対称で、Haiku の料金表は数値付きで確定する一方、GPT-6 の料金は未確認のまま残る。地味に見えるが、実務への効き目はこうした確定情報のほうが大きい。[1][2]

残る未確認事項を整理する。GPT-6 側は料金と system-card 数値、Haiku 側は system-card 全文とプラットフォーム別識別子が未取得である。ベンチマーク類はすべて独立再現待ちで、本号はいずれも発行元測定として明示した。評価対象の説明がないベンチ表は、追試の出発点としても条件不足であり、system-card の開示が次の条件になる。[1][2]

日本の読者にとっての要点は三つだ。第一に、利用プランとモデルの対応を確認してから試すこと。第二に、44%の意味を取り違えて調達判断をしないこと。第三に、自タスクの token 量が Haiku の 10 万 token 境界のどちら側に該当するかを確認し、確認した料金表（100 万 token 当たり）と使用量と合わせて試算すること。料金表からの推定額と使用者個別の実請求額は別のものとして扱いたい。[1][2]

> **Note**
>
> 本記事の数値はすべて発行元の申告値であり、独立した再現測定ではない。料金表は公開ページの記載を引用し、100 万 token 当たりの単価を示す。実際の請求額には使用量が必要である。

2 Agent Infrastructure

AGENTS

確かめられた API と、まだ観測の段階——エージェント基盤の三層

Decisions API の beta 公開を軸に、フォーラム観測と告知 stub を層別して整理する。

API が先に、発表はあとから——エージェント基盤週の読み分け

OpenAI は 10 月 6 日の changelog で、Decisions API の公開 beta を記した。エンドポイントは v1/decisions で、結び付けられるモデルは gpt-6-luna である。この API の機能は、テキストや画像を型付き回答（typed answers）に変換することだ。自由文の応答ではなく、型の定まった回答形式で返すための接点であり、エージェントの判断処理を組み込む用途に位置づけられる。2026 年 10 月 6 日の公開 beta 開始により、開発者がこの API を試用できるようになった。ガイドや料金ページは未取得であり、API の存在と beta 状態の確定が本記事の対象である。[3]

同じエントリには、Responses API と比べて 10 倍高速という記述がある。ここは慎重に扱う。測定方

法はページ上に存在せず、何をもって 10 倍としたかが分からない。入力のみ$0.10/M という料金情報も changelog 本体にはなく、二次的なコミュニティ投稿由来の未確認情報にとどまる。API の存在と機能は確定事実、速度と料金は未確定という二層で受け止めるのが正確だ。[3]

フォーラム発の決定モデル——Perplexity の二件

Perplexity は 10 月 6 日 21 時 11 分（UTC）の発行元フォーラムで、pplx-decider-v1.1-27b を発表した。うたわれるのはオープンウェイトのマルチモーダル決定モデルで、HF の Decision Index で 0.3 世代の首位、入力$0.02/M（v1 の半額）という条件が添えられている。さらに 10 月 9 日付の Decision Bench では 94.5% ／ 1071 件、$0.017/1000 決定というベンダー数値が出ている。いずれもフォーラムとベンチ発表の言明であり、HF の README や表本体は未取得だ。[4]

決定モデルの系譜で見ると、27b という題名以上の総パラメータや有効パラメータ、ライセンスの SPDX、HF リポジトリの URL はスレッド本文にない。Decision Index や Bench の数値は母集団の一部（1071 件）は分かるものの、運営方法や再現条件は不明だ。changelog で確認された Decisions API と、フォーラムで観測された decider を混同してはならない。前者は検証済みの接点、後者は観測段階の brief である。[4]

翌 10 月 7 日には同じフォーラムで pplx-embed-v2-late ペアが発表された。late-interaction 方式の埋め込みモデル 2 種で、最前線級かつ HF 公開とされる。ただし仕様もリポジトリの所在もスレッド本文になく、HF 公開の言明もリポジトリ一覧での裏付けがない。単独記事にできる厚みはなく、本号では Perplexity 二件の一行比較対象として扱う。具体的内容の確認は次号以降の課題だ。[5]

遅延と基盤——Ultrafast tier の位置づけ

10 月 8 日の changelog には、gpt-6.1-sol 向けの service_tier「ultrafast」が Responses API 上に記された。適用はレート制限付きの全利用者で、提供範囲はグローバルに加えて米国・欧州のレジデンシー対応が含まれる。目的は出力 token 間の遅延短縮であり、P1 で扱った回答開始時間とも、最終回答の壁時計時間とも別の量だ。tier・対象モデル・API・提供範囲の四点は確定情報として表にできる。[6]

一方で、どれだけ速くなるかを示す遅延の実測値はページ上にない。料金も本文にインライン表示はなく、リンク先の参照にとどまる。つまり Ultrafast は「速くなる仕組みの提供開始」という制度的事実であり、「何ミリ秒縮んだ」という性能事実ではない。この区別を守れば、誤った調達判断を防げる。[6]

比較欄——Gemini の企業向けエージェント発表

Google は 10 月 8 日の Gemini at Work 2026 で、汎用仕事エージェントを発表した。プロンプト欄、スキルやツール、コスト管理、企業ガバナンスという要素が箇条書きで示されている。ただし公開されたのは stub 段階の告知であり、GA 時期、SKU、料金、地域、Workspace と Cloud の区分はいずれも stub ページにない。展開の詳細は Cloud blog に委ねられ、未取得である。[7]

顧客事例の数字も発行元の言明のままで再検証されていない。Decisions API の changelog と対比すると差は鮮明だ。片方はエンドポイントとモデル割当まで確定した検証済み接点、もう片方は告知の存在だけが確定した stub である。本号では後者を比較欄に限定し、ローンチ記事にはしない。Cloud blog の取得が次の条件になる。[7]

エージェント基盤週の構図をまとめると、検証済み・観測・告知の三層になる。検証済みは Decisions と Ultrafast の changelog 二件、観測は Perplexity のフォーラム二件、告知は Gemini の stub 一件だ。層を混ぜて「エージェント新時代」といった総括をしないことが、今週の正確さの核心である。[3][6]

beta 表示の意味も確認しておく。Decisions API の beta は、仕様の変更がありうる段階という宣言であり、安定版の保証ではない。試用はできるが、本番組み込みの判断には変更可能性の織り込みが要る。ガイドや料金ページは未取得であり、速度の測定方法も不明なため、性能と費用の見積もりは確定しない。[3]

日本の開発者への要点は、2026 年 10 月 6 日と 8 日の changelog で公開された Decisions beta と Ultrafast tier の二接点が試せる段階にあり、Perplexity 二件は仕様確認待ち、Gemini は続報待ちということだ。試せるものから試し、待つべきものは待つ。この順序づけが今週の実利になる。[3][6]

Note

changelog 二件は逐語確認済み。速度・料金・ベンチ数値は発行元言明または未確認であり、独立再現なし。

3 Open Weights and Audio

OPEN WEIGHTS

公開の言明と取得の実態で仕分ける——重み・音声 7 件

ダウンロードの可否とライセンス確認の有無を軸に、7 件の重み・音声提供を一覧化する。

公開の言明と取得の実態で仕分ける——重み・音声 7 件

今週のオープンウェイト周辺は、規模の競争ではなく公開状態の差で読むべき週だ。Aleph Alpha の Kolibri は 10 月 3 日に 78B ／ 3B の MoE 構成で公開され、コンテキスト 100 万 token、ライセンス Apache-2.0、HF の Aleph-Alpha ／ Kolibri-1 で取得可能とされる。学習 20T token、計算資源 768 基の B200 という条件も添えられている。いずれも発行元の公開ページの記述であり、配布場所まで含めた具体性がある。[8]

性能面では AIME 2026 で 96.0、GPQA で 84.3 といったベンダー数値が示されている。これらは発行元が自社条件で測った申告値で、独立再現はない。ただし公開ページの表は途中で取得が途切れており、表の残部は未確認である。規模と条件の層では語れるが、評価の全容は留保付きになる。[8]

小型の決定モデルでは、Liquid AI の d1-3B と d1-omni-600M が、2026 年 10 月 7 日の発表で取得可能とされた。Decision Index は 48.57 と 15.95、RTX4090 上で 8 ミリ秒というベンダー数値が添えられている。600M 級のオムニモデルと 8 ミリ秒という遅延の組み合わせは、端末側での実行を考える開発者には具体的な検討材料だ。ただし Index の運営方法や測定条件は不明で、価格とライセンスの SPDX も取得本文にない。[9]

Kolibri の大型 MoE と d1 の小型決定モデルは、対照的な二極として読める。片方は 100 万 token 級の文脈を抱える巨体、もう片方はミリ秒応答の小体だ。Decision Index のような独自指標は、異なる規模のモデルを決定タスクの軸で比べる試みだが、指標自体の方法が不明なため、順位の確定には使えない。規模の提示としては有益、評価の確定としては未熟という二層で受け止めたい。[9]

埋め込みの更新——EmbeddingGemma 2 の仕様箱

Google は 10 月 6 日のブログで EmbeddingGemma 2 を公開した。全体 740M parameters の構成で、内訳はテキスト専用 270M、画像用 170M、音声用 300M の 3 エンコーダからなる。テキスト、コード、画像、映像、音声を共通の埋め込み空間で扱う設計で、768 次元の MRL（Matryoshka）表現を持ち、128・256・512 次元への短縮が可能とされる。コンテキストは 8000 token で、音声は最大 5.5 分、画像は最大 29 枚、映像は最大 58 フレームが目安として示されている。ライセンスは Apache-2.0、取得場所は HF の google ／ embeddinggemma-2 と Kaggle とされる。MRL 短縮の実用的な意味は、検索インデックスの容量や計算負荷の調整にある。短い次元で候補を絞り、長い次元で再評価するといった使い分けが考えられるが、これは実務上の応用例であり、開発元がその構成の優位性を実証したという意味ではない。次元数と MRL 対応、コンテキスト長の三点はそのまま設計条件になる。[10]

検索・コード検索の指標として MTEB-Code で＋9.92 というベンダー数値が出ているが、全指標はモデルカード側に委ねられ、そのカード本体は取得タイムアウトで未取得だ。アーキテクチャ表も断片しかなく、学習や評価の方法は分からない。仕様箱としての記事は成立するが、検索リーダーとしての優劣判断はカード取得待ちになる。[10]

比較対象——まだ取得が確定しない二件

Reflection の Beam は 10 月 5 日発表（10 月 8 日更新）の 501B ／ 23B MoE で、重み・報告・カードは発表時点では 2026 年 10 月後半の公開予定とされ、ライセンスは Apache-2.0 の意向、現状は早期アクセス登録のみだ。ベンダー数値として DeepSWE 44.4、TB2.1 で 80.1、AIME で 97.8、学習 23.8T token、GB300 級での RL 規模が添えられている。規模の提示は大きいが、取得が確定したものは何もない段階であり、Kolibri との対比で「公開済み対予告」の構図を作る比較対象にとどめる。[11]

Mistral Large 4 は 10 月 6 日のブログと docs で、有

効 520 億・総計 1〜1.05 兆、コンテキスト 100 万、プレビュー API は発表日から提供、重みは 2026 年 10 月末、セール価格は入力・出力 100 万 token 当たり $0.68 ／$2.09 とされる。API としては発表日から試せる段階だが、重みとしては 2026 年 10 月末待ちだ。ここで二つの区別を守りたい。第一に、有効 520 億と総計 1.05 兆は別の量であり、前者が 1 token ごとの演算に寄与する規模、後者が保持メモリの目安になる。第二に、一部の二次記録には 49B active という数値があるが、対応する原 X 投稿は直接確認できていない。Mistral 公式 docs では 52B active と記載されているため、本文では 52B を一次資料に基づく値として扱う。二つの数値を同等の確実性で並記はしない。公式ピンは 52B という区別を崩さず、裁定はしない。[12]

音声の二件——Clef-omni と Nova Sonic

Cloudflare の Clef-omni は、公開日時の確認が明確な好例でもある。Clef-omni の公開時刻は、発行元ブログに記録された公開日時のメタデータに基づく。2026 年 10 月 9 日 18 時 27 分 34 秒（UTC）の記録があり、SNS 上の後続投稿日時とは別の扱いになる。SNS 上の後続投稿日時は、モデルの公開日時を直接示すものではない。[13]

仕様としては Qwen3-Omni-30B-A3B の MoE で、omni 料金$0.15 ／ M、flash の値下げ$0.09 →$0.038、HF での重み公開、ベンダーベンチが添えられている。ただし HF のダウンロード実績とライセンス SPDX は未検証で、発行者の公開言明と実際に取得されたファイルは別物だ。料金と仕様の層では語れるが、取得の層では未確認という留保が付く。[13]

AWS の Nova 2.5 Sonic は 10 月 5 日に音声対音声で一般提供（GA）となった。Bedrock の 4 リージョン（米東・米西・北欧・東京含むアジア太平洋北東）で利用でき、コンテキスト 25.6 万、前世代と同等料金とされる。GA はプレビューではなく本提供の段階を指し、対象地域の確定が今回の到達内容だ。ただし料金の数値は本文になく、ベンチマークやライセンス条項もない。価格と品質の判断は材料待ちであり、GA の確定と支払い条件の確定は別の事柄として扱う。[14]
[8][9][10][11][12][13][14]

この表の読み方が本記事の核心だ。発行者の公開表明、配布先の発行元による提示、その提示先の実

項目	内容
Kolibri	ライセンス表記：Apache-2.0（言明）；配布場所：HF Aleph-Alpha ／ Kolibri-1（言明）；実ファイルの取得確認：言明場所の提示のみ、SPDX・実ダウンロード未検証；状態：公開言明あり（表残部未取得）
Liquid d1	ライセンス表記：SPDX なし；配布場所：HF LiquidAI/d1-3b 等（言明）；実ファイルの取得確認：未検証；状態：取得可能との言明あり
EmbeddingGemma 2	ライセンス表記：Apache-2.0（言明）；配布場所：HF ＋ Kaggle（言明）；実ファイルの取得確認：カード未取得；状態：公開言明あり、詳細はカード待ち
Beam	ライセンス表記：Apache-2.0 意向；配布場所：なし；実ファイルの取得確認：不可；状態：発表時点で 2026 年 10 月後半の公開予定、早期登録のみ
Mistral Large 4	ライセンス表記：WEIGHTS タブ未取得；配布場所：プレビュー API あり；実ファイルの取得確認：不可；状態：API は発表日から提供、重みは 2026 年 10 月末
Clef-omni	ライセンス表記：SPDX なし；配布場所：HF（言明・リンク）；実ファイルの取得確認：未検証；状態：公開言明あり、時刻確定済み
Nova Sonic	ライセンス表記：本文なし；配布場所：Bedrock 4 リージョン；実ファイルの取得確認：対象外（API 提供）；状態：GA、料金数値なし

表 2　比較表：重み・音声 7 件の公開状態

在確認、重みファイルの取得成功は四つの別の段階であり、今回確認した資料から裏付けられるのは、発行元による公開表明と配布先の提示までである。たとえば HF のリポジトリ名が示されていても、その提示先の実在確認と重みファイルの取得がなければ、利用許諾の判断は下せない。試用はできても商用組み込みの判断は時期尚早ということになる。[8][11][12][13]

規模の読み方も整理する。MoE の total と active は別の量だ。各モデルの total ／ active パラメータ数は、Kolibri が約 78.1B ／約 3.46B、Beam が 501B ／ 23B、Mistral Large 4 が 1.05T ／ 52B である。total はモデル全体の重み規模で、保持に必要なメモリの目安になる。active は token 処理時に主として利用されるパラメータ規模で、推論時の演算コストの目安になる。ただし、active 数だけで実際の FLOPs や処理速度が確定するわけではない。量子化の有無、実装、ルーティング方式、ハードウェアの違いで変わるため、規模表とベンチ表を別々の表として扱い、混ぜて総合ランキングを作らないことが正確さの条件になる。[8][11][12]

配布場所の確認手順も示しておく。HF のリポジトリ名が示されていても、ライセンス条項ファイルの有無と重みファイルの一覧を確認するまでは、利用許諾の判断は下せない。Clef-omni のようにリンクが示されていても、実ファイルの取得確認がなければ言明の段階にとどまる。確認の四段階——発行元による公開表明、発行元による配布先の提示、その提示先の実在確認、重みファイルの取得成功——を踏むことが、オープンウェイト利用の基本動作になる。ライセンス条項の確認は、単なる配布先提示やダウンロード成功とは別に必要だ。[8][13]

音声二件の対比も述べておく。Nova はサービスとしての GA、Clef は重み公開言明付きのオムニ発表で、提供形態が異なる。料金は Nova が数値なし、Clef が言明値ありと逆転しているが、いずれも確定した支払い条件ではない。対象地域の確定（Nova の 4 リージョン）とプレビュー段階の区別（Mistral の API 先行）も含め、提供形態の確認から始めるのが順序だ。[14][13][12][11]

日本の開発者への要点は、取得可能とされるのは Kolibri と d1、仕様確認の段階なのは EmbeddingGemma、音声は Nova の GA と Clef の言明という仕分けだ。重みの公開予定は分かれており、Beam は発表時点で 2026 年 10 月後半の公開予定、Mistral Large 4 は発表時点で 2026 年 10 月末の公開予定とされた。発表予定を実際の公開完了と同一視してはならない。いずれも発行元の表明に基づく仕分けであり、実ファイルの取得確認はこれからだ。表明の段階で検証を進め、取得の段階で利用判断に移る。この順序づけが今週の実利になる。[8][9][10][14][13][11][12]

Note

公開表明・配布場所・実ファイル取得は別の段階として扱った。価格・ベンチ数値は発行元申告であり、独立再現なし。

4 Image Model Card

IMAGE

仕様で語る画像モデル——Nano Banana 2.1 カード読み

DeepMind のモデルカードが示す入出力 token 上限と提供形態を、Elo 値の留保付きで整理する。

画像生成の仕様書を読む——Nano Banana 2.1 のモデルカード

Google DeepMind は 10 月 6 日付のモデルカードで、Nano Banana 2.1 の仕様を公開した。系列は Gemini 3 系統で、基盤は 3.6 Flash とされる。入出力の上限は token 数で示されている。入力は最大 100 万 token のコンテキスト窓、出力は画像が 4K token、テキストが 64K token で、提供先は Gemini App、Google AI Studio、Gemini API、Google 検索の AI Mode、Google 広告、Google Flow、Google Stitch の 7 チャネルだ。ここで注意したいのは、画像の「4K token」が出力 token 数の上限であり、画素解像度や画像寸法の上限ではないことだ。token 数と解像度は別の概念であり、画素数や寸法の上限は取得したカードの範囲からは確認できない。いずれもモデルカードの記載をそのまま受け取った発行元情報である。[15]

評価面では、T2I Overall Preference のベンダー横並び（side-by-side）評価として 1050±14（Thinking 条件）という値が示されている。これは発行元が自社条件で測った相対評価であり、公開アリーナでの独立評価ではない。DailyX 経由の二次記録にあるアリーナ得点の根拠は未解決のままであり、カードの値と同一視できない。ランキングの確定と読むのは

誤りで、発行元測定の相対値として扱うべきだ。[15]

Nano Banana 2.1 の技術仕様は、DeepMind のモデルカードに記された範囲で確認できる。公式ブログ記事の有無は、公開資料からは確認できていない。ただし、公式ブログがウェブ上に存在しないとは断定できない。技術仕様はモデルカードを根拠に扱い、ブログ記事の内容は未確認として区別する。[15]

不足情報も明示する。価格とライセンス条項は確認できておらず、技術資料ページも未取得である。知識カットオフは基盤の Gemini 3.6 Flash について 2026 年 3 月とされる。カード記載の範囲を超える運用条件の判断には、まだ材料が足りない。[15]

クリエイター向けの実務判断としては、入出力 token 数の上限と 7 つの提供先を制作パイプラインの制約条件として使える段階にある。一方で、品質の序列づけや商用条件の見積もりには、まだ材料が足りない。仕様の骨格はカードで読み取れる一方、運用条件の判断には追加資料の取得が要る。[15]

Note

仕様値と Elo 値（1050±14、Thinking 条件）はモデルカードの発行元記載。画像の 4K は出力 token 数であり解像度ではない。価格・ライセンス・技術資料は未確認。

5 Provenance and Watermarks

PROVENANCE

測られた透かしと示された射程——来歴保証の二枚看板

textGrain の検出率動作点と編集耐性、SynthID ポータルの検証範囲と申告規模を、等価化せずに対置する。

測られた透かし、示された範囲——来歴保証週の二枚看板

OpenAI は 10 月 5 日のブログで、EU 向けテキスト来歴技術 textGrain を公開した。方式はモデルの語選択に不可視の統計信号を加える透かしで、API では世界の利用者が即時オプトインできる。EU の ChatGPT と Codex の出力への付与は数週間以内、検出器の利用申請も開かれており、承認された研究者と専門機関に限って提供される。公開範囲と検出条件の確定が本記事の対象である。[16]

測定値の読み方を正確に押さえる。以下はいずれも発行元の実験結果であり、第三者の独立再現ではない。まず誤検出率（FPR）と検出率は別の量だ。目標 FPR 1%という条件のもとで、透かし入り文章の検出率は 200 token 級で約 80%、400 token 級で約 95%とされる。条件は心理学・ELI5 系の文章であり、数学領域では検出率が大きく低下するという留保が付く。token 長が伸びるほど検出が安定する関係が示されているが、これは同じ記録の中での 200 と 400 の対比であり、母集団の異なる数値と混ぜてはならない。[16]

編集耐性は別の実験として読む。こちらも発行元の申告値であり、独立再現はない。400 token 級文章での類義語置換の評価では、置換なしで約 92%、10%置換で約 66%、25%置換で約 17%という検出率の低下が示されている。置換率が上がるほど検出が落ちる関係が具体的な三点で分かる。ただし、この三点は編集耐性評価の母集団であり、前段の約 95%（400 token 級の検出率）と同じ測定母集団であるとは断定しない。条件の異なる数値を一つの頑健性指標に束ねないことが正確さの条件だ。[16]

置換率 0%	検出率 約 92%
置換率 10%	検出率 約 66%
置換率 25%	検出率 約 17%

表 3　類義語置換による編集耐性（400 token 級、発行元測定）。条件注記：400 token 文章に対する類義語置換試験の発行元申告値。前段の FPR 1%での検出率評価との母集団・測定条件の同一性は未確認。

[16]

検出器の研究者限定という提供形態も技術的に意味がある。誰でも試せる公開物ではなく、利用申請を通った研究者に限られる。検証の再現はこのゲートの内側でしか進まないため、日本の研究者が追試するには申請手続きが前提になる。API 側のオプトインが即時であるのと対照的に、検出側の検証は閉じた回路で回る設計だ。[16]

手法の詳細には明確な上限がある。技術報告の PDF はリンクされているが未読で、著者や手法の詳細は二手情報の範囲にとどまる。論文内部の主張に踏み込んだ解説は扱わない。対象モデル一覧、価格、ライセンス条文も未確認だ。品質表（Astra 系の複数ベンチと BrowseComp、HealthBench、GPQA 等の数値）はブログ掲載分として参照できるが、その測定条件の深掘りは PDF 取得後の課題になる。[16]

品質への影響も数値で示されている。Astra max 条件での 8 ベンチについて、透かしなしテキストと透かしありテキストの二列が並び、AA Index で 49.57 ポイントと 49.76 ポイント、AutomationBench で 34.09%と 34.86%、DeepSWE v1.1 で 72.80%と 71.68%、Terminal-Bench 4.0 で 53.90%と 56.06%、同 Science 0.1 で 56.90%と 60.00%、BrowseComp で 87.92%と 87.35%、HealthBench Professional で 64.27%と 64.60%、GPQA Diamond で 94.44%と 93.94%とされる。列の対応は公式ブログ本文の見出しによる。差はいずれも小さく、発行元は透かしの有無で意味のある性能差は見られないと述べている。ただし、これらは回答品質の評価であり、前段の透かし検出率とは別の評価軸だ。検出の確かさと回答の質を混ぜて読んではならない。数値はいずれも発行元申告であり、独立再現はない。[16]

評価	透かしなしテキスト	透かしありテキスト
AA Index（ポイント）	49.57	49.76
AutomationBench	34.09%	34.86%
DeepSWE v1.1	72.80%	71.68%
Terminal-Bench 4.0	53.90%	56.06%
Terminal-Bench Science 0.1	56.90%	60.00%
BrowseComp	87.92%	87.35%
HealthBench Professional	64.27%	64.60%
GPQA Diamond	94.44%	93.94%

表 4　品質比較表：透かし有無のベンチ値（Astra max、発行元申告）。注：AA Index の単位はポイント、その他の 7 指標は%。透かしなし／ありの両列は Astra max 条件での発行元測定値。独立した再現は確認されていない。

[16]

検証ポータルの射程——SynthID の範囲表

Google は 10 月 7 日のブログで、SynthID の公開検証ポータルの拡張を示した。英語でグローバルに、10 月 7 日から利用できる。公式ブログで検証対象として示されているのは画像・映像・音声であり、テキストへの対応は公表資料で確認できない。パートナーには OpenAI、NVIDIA、Kakao が名を連ね、Apple も近日とされる。規模の申告値として、画像・映像で 1800 億件以上、音声で 24 万年分という数が示されている。[17]

ポータル本体の検証可能性には留保がある。synthid.com は表示の確認ができておらず、対応形式や料金、ライセンス条項は確認できない。公表資料では、検出精度を示す評価数値は確認できなかった。つまりポータルの「射程」はブログの記述としては確定するが、「効き目」の測定は確認できないということだ。パートナーの適用範囲もベンダー言明であり、裏付けはない。[17]

ここで混同してはならないのは、textGrain の数値と SynthID の範囲が別の様式の事実だということだ。前者はテキスト透かしの検出率という測定値、後者は画像・映像・音声の検証射程という範囲の宣言である。テキストの頑健性が他モダリティの検証性能に転用できるわけでも、その逆でもない。両者を一つの「来歴保証性能」として語るのは、根拠のない等価化になる。[16][17]

項目	内容
textGrain	対象：テキスト；利用制限：API 即時オプトイン、EU 展開は数週間以内、検出器は研究者限定；仕組み・確認範囲：統計透かし、FPR 1%・200 token 約 80%・400 token 約 95%・類義語置換表はブログ記載の発行元測定、技術報告 PDF 未読
SynthID ポータル	対象：Google または対象パートナー由来の画像・映像・音声（公式ブログで示された範囲。テキストへの対応は公表資料で確認できない）；利用制限：2026 年 10 月 7 日から英語で世界向けに提供；仕組み・確認範囲：検証ポータルの射程はブログ記載の範囲で確定、申告規模は画像・映像 1800 億件以上・音声 24 万年分、精度を示す評価数値は公表資料に示されておらず、ポータル本体の表示確認はできていない

表 5　比較表：来歴保証二件の射程と確認状態

[16][17]

規模の数字の読み方も整理する。1800 億件や 24 万年分は、透かし処理されたコンテンツの規模に関する発行元の主張であり、検出精度の実績でも独立に検証された処理量でもない。規模の大きさと検証の確かさは別の量だ。本記事では規模を申告値として紹介し、精度の判断には使わない。[17]

政策的な読みどころも述べておく。EU 先行の透かし運用と研究者限定の検出器という組み合わせは、日本の政策・研究の読者にとって直接の参照点になる。Kakao の名がパートナーにあることは、アジア域での適用の手がかりだ。ただし、いずれも制度の存在の確定であり、効果の実証ではない。この区別を守って参照したい。[16][17]

パートナー適用の未検証も明示する。OpenAI や NVIDIA 由来の検証が実際にどの範囲で動くかは、取得による裏付けがない。ブログの射程表をそのま

ま運用計画に写すのではなく、自前の検証で確かめる段階が残る。[17]

来歴保証週の内容をまとめると、テキスト側は検出率の動作点と編集耐性の三点、画像・映像・音声側は検証射程と申告規模ということになる。測定条件の違いを保ったまま読み分けることが、実務での誤用を防ぐ近道だ。[16][17]

Note

textGrain の数値はブログ記載の発行元測定の読み取り、SynthID の範囲と規模はブログ申告。いずれも独立再現なし。技術報告 PDF は未読。

6 Safety and Science

SAFETY

守りの制度、探究の公開、模擬の測定――三件の境界線

サイバー計画の発足、数学成果の公開、模擬評価の三件を、効果・入手・実環境の未確定とともに整理する。

守りと探究の三件――実測なき期待と未公開の成果

Anthropic は 10 月 8 日、Cyber Mission を開始した。柱は二つで、11 社の創設パートナーを擁する CIDP と、OSS Scanner という無償のオプトイン検査器だ。Scanner はモデル生成の概念実証レポートを出し、人間の査読を挟まず、真陽性率 90%超を見込むとされる。制度の発足としては確定情報であり、参加条件と提供形態の層では具体的に語れる。[18]

ただし期待と実測は別物だ。90%超は見込みの数字であり、測定された成果ではない。Scanner 本体の詳細投稿も CIDP の申込フォーム内部も未取得で、実際にどれだけ守れるかは未知数だ。制度の存在を効果の実証と読み替えないことが、この記事の第一の留保になる。[18]

数学の成果公開――モデルは出さず、中身を出す

OpenAI は 10 月 6 日、社内の最前線モデル（名称非公開）に由来する広範な数学成果を公開した。GitHub の openai ／ math リポジトリ、Lean による部分形式化、10 件の推論要約、Pro 利用での計算統計（平均約 3 時間）が列挙されている。成果物の公開としては確定情報であり、形式化の範囲と要約の存在は開発者・研究者の参照点になる。[19]

ここで区別すべきは、成果の公開とモデルの公開だ。モデル本体は未公開で、責任ある公開に向けた作業が継続中とされ、期日はない。リポジトリの内容物や論文数、Lean ファイルの数え上げも未列挙で、ライセンスもページにない。数学の前進として読むべきもので、モデル入手の見通しとして読むべきものではない。[19]

模擬で測る――Ironclad のコンピュータ利用評価

OpenAI と Ironclad の 10 月 6 日の研究は、11 件の契約タスクによるコンピュータ利用の評価だ。条件は EDGAR 模擬で、顧客・社内・非公開データは使われていない。結果は成功率で Astra Max 55.0%に対し Sol High 41.6%、差は 13.4 ポイント、相対改善率は約 32%とされる。所要時間は 37.0 分から 19.2 分へほぼ半減（約 48%減）とされる。いずれも模擬条件でのベンダー測定であり、暫定的な研究段階の数字だ。絶対差と相対差の書き分けに注意したい。13.4 ポイントは二つの成功率の差、約 32%は低い方を基準にした相対の伸びであり、別の量だ。[20]

模擬の意味を正確に押さえたい。EDGAR 模擬の契約タスクという母集団は既知だが、採点ルーブリックやタスク別の得点、強化学習の詳細はページにない。実環境への導入効果として読むのは誤りで、あくまで模擬条件での相対比較だ。Ironclad の製品発表は本ページ外の別事象であり、混同してはならない。[20]

三件を通覧すると、共通するのは「確定した制度・公開・模擬」と「未確定の効果・入手・実環境」という二層構造だ。Cyber は制度確定・効果未測定、数学は成果確定・モデル未公開、Ironclad は模擬確定・実環境未測定という対応になる。この対応表自体が本記事の読みどころであり、三件を一つの総合性能ランキングにまとめることはしない。模擬評価から判断できるのは、模擬条件の範囲での相対比較までであり、導入効果の予測ではない。[18][19][20]

未取得の三点をまとめて示す。Scanner 詳細と申込内部、リポジトリの数え上げとライセンス、ルーブリックとタスク別得点である。いずれも次の取材・取得の条件であり、推測での穴埋めはしない。囲いの中の事実と囲いの外の未知を分けて示すことが、安全と科学の主題に対する正確さだ。[18][19][20]

実務への含意は控えめに述べる。セキュリティ担当者は Scanner の無償オプトインを試用候補に載せられる段階にあり、数学・自動化の関心層はリポジトリと模擬条件を参照点にできる段階にある。いずれも導入判断ではなく、次の検証への入口だ。[18][19][20]

Note

期待性能と実測、成果公開とモデル公開、模擬と実環境をそれぞれ区別した。成功率の差は 13.4 ポイント、相対改善は約 32%。いずれも独立再現なし。

7 Community Movement

COMMUNITY

公式発表の到着記録と、確認できなかった独立検証

14 件の公開投稿はすべて発行元告知であり、独立した技術検証の到着は確認できない。

公式発表は 5 領域に集中した。最前線の提供条件（GPT-6、Haiku 5.5）、数学成果の公開、安全の制度発足（Cyber Mission と基盤防衛・検査器）、公開ウェイトの予告（Mistral Large 4、Beam）、音声・画像の提供（Nano Banana 2.1、EmbeddingGemma 2）である [1][19][2][18][12][11][15][10]。いずれも発行元による発表の到着であり、仕様や性能、提供条件の独立した裏付けではない。

14 件の内訳は、通常期間内 12 件と締め切り後 2 件である [1][19][2][18][12][11][15][10][13]。件数の水増しはせず、リンク総数と期間内訳を分けて示す。行単位の台帳を正とし、要約文の数えに頼らない。締め切り後の 2 件（10 月 9 日 22 時 04 分の動作報告、同日 23 時 11 分の Clef-omni 拡張告知）は通常の集計には含めない [13]。Clef-omni の公開時刻の根拠は発行元ブログの記録であり、投稿日時は公開日時の根拠にはならない。

Weekly Community Movement — context only

今号の公開投稿 14 件はすべて発行元公式であり、独立・一般利用者の技術投稿は 0 件である。公式発表の到着は確認できるが、独立した再現、導入確認、評価、批評の到着は確認できない。発表件数から技術コミュニティの支持や性能評価を推定できない。締め切り後の速報は通常の集計には含めない。

独立した技術検証、採用報告、再現報告、批評は確認されていない。保存済みの公開投稿資料には利用者や第三者の反応（祝意、ベンチ開始の表明、利用可能性の報告など）が含まれるが、いずれも関心の表明であって、仕様や性能、提供条件の検証ではない。重みの入手確認や局所実行の報告、評価の再実行など、高信号の独立確認は見当たらない。Ultrafast と Decisions、Ironclad に対応する発行元投稿は期間内に見当たらず、手引きや研究ページの確認が根拠になる [6][3][20]。Gemini 仕事エージェントに対応する一次投稿は見当たらない [7]。Vercel や Pixel Canary は期間前の文脈のみであり、日本語特化の公式投稿は第三者報道のみで公式到着はない。音声・映像生成の新規公開、serving 系の主版更新も期間内の一次到着はない。

発表件数から技術コミュニティの支持や性能評価を推定できない。公式投稿が多いことは、発行元が発表したという事実を示すだけで、独立した利用者が試し、測り、採用したことを示さない。Mistral の 49B 表記と 52B 文書の差は、告知の存在と文書記載の差であって、重み実体の確認ではない [12]。Nano Banana に関する利用可能性の報告は、新規公開の告知ではない [15]。Beam への祝意表明は反応であって、仕様の裏付けではない [11]。いずれも一次発表として本文で明示的に引用した公式投稿の発表内容に限って一次資料として扱い、台帳に載っているという事実だけでは技術的な根拠に格上げしない。

今後確認すべきは、一次的な実装・評価記録である。重み実体の取得確認と許諾条項、局所実行や推論基盤での動作報告、評価の独立した再実行、料金の請求実態、検出器や検査器の第三者評価、技術報告 PDF の取得後の精査が次の観測点になる。根拠が足りない動向は無理に記事化せず、限定的に示すにとどめる。全行の内訳は本号の公開台帳で直接確かめられる。

8 Week in Review

WEEKLY SYNTHESIS

今週は、測られた提供条件が並んだ

提供階層と料金区分、検証済み接点と観測・告知、公開言明と取得実態、仕様カード、透かし数値と検証射程、制度・公開・模擬が同時に確定した。

今週何が変わったか

1. **最前線の提供条件が具体化した。** 10 月 7 日の GPT-6 と Intelligent UI は有料 4 プランと Free・Go の提供階層、Sol と Luna の割当、回答開始時間としての 44%の定義が確定した [1]。10 月 7 日の Haiku 5.5 は 10 万 token 境界の二段階料金表（100 万 token 当たりの 4 区分）、発行元計測のベンチ表が確定した [2]。GPT-6 の料金体系や system-card 全文は未確認であり、提供条件の確定と費用・評価の確定は別の層である。
2. **エージェント基盤は三層に分かれた。** 10 月 6 日の Decisions API beta と 10 月 8 日の Ultrafast tier は changelog で確認された接点である [3][6]。10 月 6 日から 7 日の Perplexity 二件はフォーラム観測の段階であり、仕様や配布場所は未確認である [4][5]。10 月 8 日の Gemini 仕事エージェントは告知の存在だけが確定した段階であり、提供時期や料金、地域は未確認である [7]。
3. **重みは公開言明と取得実態で仕分けられた。** 10 月 3 日の Kolibri（78B ／ 3B）、10 月 7 日の d1-3B と d1-omni-600M、10 月 6 日の EmbeddingGemma 2 は取得可能との言明がある [8][9][10]。10 月 5 日の Beam は 10 月後半の公開予定、10 月 6 日の Mistral Large 4 は 10 月末の重み公開とされ、発表時点では取得できない [11][12]。10 月 9 日の Clef-omni は公開時刻が確定し、重み言明はあるが実取得は未検証である [13]。10 月 5 日の Nova Sonic は音声対音声の本提供であり、重みの話題ではない [14]。
4. **画像モデルは仕様で読める段階になった。** 10 月 6 日付の Nano Banana 2.1 カードは入出力 token 上限と 7 提供先、2026 年 3 月の知識期限、1050±14（Thinking 条件）の発行元横並び値を示す [15]。画像の 4K は出力 token 数であり解像度ではない。価格やライセンス条項、技術資料は未確認であり、仕様の骨格と運用条件は別の層である。
5. **来歴保証は数値と範囲の対置になった。** 10 月 5 日の textGrain は FPR 1%での 200 token 約 80%・400 token 約 95%、類義語置換の三点、Astra 条件の品質 8 ベンチという発行元測定である [16]。10 月 7 日の SynthID 拡張は画像・映像・音声の検証射程と申告規模の確定であり、精度の評価数値は示されていない [17]。透かしの頑健性と検証の効き目は相互に転用できない。
6. **守りと探究は境界線の確認になった。** 10 月 8 日の Cyber Mission は 11 社の創設提携と無償検査器の制度発足であり、90%超は見込みであって実測ではない [18]。10 月 6 日の数学公開は成果物の公開であり、モデル本体は未公開である [19]。10 月 6 日の Ironclad 評価は 11 件の模擬契約での相対比較であり、実環境の導入効果ではない [20]。

なぜそれらが一緒に重要なのか

発表された提供条件と検証済みの性能を区別することが、今週の実務判断に直結する点にある。GPT-6 の 44%は回答開始の速さであって全体の短縮ではなく、Haiku の二段階料金表は料金区分の確定であって実請求額の確定ではない [1][2]。Decisions と Ultrafast は接点の存在が確定し、速度と料金の実測は未確定である [3][6]。MoE の規模では、Kolibri の約 78.1B ／約 3.46B、Beam の 501B ／ 23B、Mistral Large 4 の 1.05T ／ 52B という総量と有効量の区別が、保持メモリの目安と推論演算の目安の区別になる [8][11][12]。有効量だけで処理速度は確定せず、量子化や実装、配線方式、機材で変わるため、規模表とベンチ表を混ぜて順位は作らない。公開ウェイトでは、Kolibri と d1 の取得可能言明と、Beam と Mistral の公開予定の区別が、試用と商用組み込み判断の分かれ目になる [8][9][11][12]。発行元の公開表明、配布先の提示、実在確認、重み取得の四段階を踏むことが、許諾判断の順序になる。来歴保証では、textGrain の検出動作点と編集耐性、品質影響の三軸と、SynthID の検証射程と申告規模の区別が、誤用防止の近道になる [16][17]。評価条件では、Haiku や Kolibri、Beam のベンチ表も、Nano Banana の横並び値も、Ironclad の模擬相対値も、いずれも発行元条件での測定であって独立再現ではない [2][8][11][15][20]。

この連鎖は製品間の直接的な互換性を意味しない。各公開、報道、一次記録は固有の主体・環境・測定条件を持つ。動作条件の小ささを共通効率へ、利用条件の表示を共通許諾へ、速度や得点を横断的な順位へ自動的に変換してはいけない。

次に何を見るべきか

次週以降は、この連鎖のどこがさらに具体化するかを追う。GPT-6 の料金と system-card、Haiku の system-card 全文と測定条件、Decisions の手引きと料金、Ultrafast の実測、Perplexity 二件の仕様と配布場所、Gemini の Cloud 側続報、Kolibri 表残部と d1 の運営方法、EmbeddingGemma 2 のカード本体、Beam と Mistral Large 4 の重み実体、Clef-omni の実取得と許諾条項、Nova Sonic の料金数値、Nano Banana の運用条件、textGrain の技術報告 PDF、SynthID の精度評価、Scanner 詳細と申込内部、数学リポジトリの数え上げと利用条件、Ironclad の採点内訳はまだ詳細化されていない。さらに、載せなかった持ち越し 4 件の新しい日付のある証拠の行き先も、次の観測点として残る。ベンダーや研究機関の数値が、それぞれの条件から外へ一般化できるかを確認する必要がある。

この総括の読み方

各項目の公開条件、報告主体、測定環境は同じではない。ベンダーが示す速度、報道が伝える仕様、研究機関が報告する評価、話題で見られた関心は、それぞれ異なる種類の情報であり、単純な性能順位へまとめられない。未確定の点は、次の公開更新や再現可能な評価で確かめるべき観測点として残る。

Sources & Limitations

Primary sources consulted

10 月 7 日の OpenAI の GPT-6 と Intelligent UI、10 月 7 日の Anthropic の Haiku 5.5、10 月 6 日の OpenAI の Decisions API beta と 10 月 6 日から 7 日の Perplexity の決定・埋め込み、10 月 8 日の Ultrafast tier と Gemini 仕事エージェント、10 月 3 日の Aleph Alpha の Kolibri と 10 月 7 日の Liquid の d1、10 月 6 日の EmbeddingGemma 2 と Reflection の Beam（10 月 8 日更新）と Mistral Large 4、10 月 9 日の Cloudflare の Clef-omni と 10 月 5 日の Nova Sonic、10 月 6 日の Nano Banana 2.1 カード、10 月 5 日の OpenAI の textGrain と 10 月 7 日の SynthID 拡張、10 月 8 日の Anthropic の Cyber Mission と 10 月 6 日の OpenAI の数学公開・Ironclad 模擬を範囲として読んだ。本号では全文 PDF や手法の細目、図表の詳細までは扱わず、その範囲を超える主張は行わない。

Temporal boundary

通常の範囲は 2026-10-02 18:00 から 2026-10-09 18:00（いずれも America/New_York、終了時刻は含まない）。10 月 9 日 22 時 04 分（UTC）の意図せざる動作報告と同日 23 時 11 分（UTC）の Clef-omni 拡張告知は範囲の区切りとともに読む。リポジトリの作成をもって重みの公開完了と読まない。日付は日の単位のものが多く、時刻レベルの断定は確かめたものに限る。

Vendor-reported boundary

測定値や比較、コスト、スループット、利用見通しの説明は、ベンダーやモデルの配布元、提携の報告として受け止め、独立した再現とは切り分ける。GPT-6 の 44%や Haiku の料金表とベンチ表、Decisions の 10 倍表記、Perplexity の指数と単価、Ultrafast の提供範囲、Kolibri や Beam、Mistral の規模とベンチ、Nano Banana の横並び値、textGrain の検出率と品質表、SynthID の規模、Cyber の見込み値、数学の計算統計、Ironclad の模擬相対値といった値はベンダー側の報告であり、条件の違いを含めて本号の検証範囲外である。

Community observation boundary

公開投稿の台帳は原則として関心の方向を示す背景にとどめる。ただし、一次発表として本文で明示的に引用した公式アカウントの投稿は、その発表内容に限って一次資料として扱う。台帳に載っているという事実だけでは、いかなる行も技術的な根拠に格上げしない。独立した投稿やコミュニティの反応は、仕様やベンチマーク、日付、利用条件、価格、ライセンス、アーキテクチャ、公開事実の根拠にはならない。全行の内訳は本号の公開台帳で直接確かめられる。行単位の台帳を正とし、要約文の数えに頼らない。

What was not elevated

持ち越しの 4 件は、新しい日付のある証拠がなく今号の章には載せない。いずれも対象期間内の素材的に重い品であることは認め、載せない理由を隠さない。Drex や StepFun、Decision-1 等の高関心の持ち越しは未解決のまま残し、次号の取得対象とする。textGrain 技術報告 PDF、Beam と Mistral の重み、system-card 全文、料金・ライセンス条項も取得対象である。収集の台帳そのものは方法論の覚えに残し、物語には入れない。噂の段階の話題は今週の技術的な出来事として取り上げない。

References

[1]OpenAI. *GPT-6 and Intelligent UI for everyone*. Primary official source; Oct 7 rollout of GPT-6 with Intelligent UI (Plus/Pro/Business/Enterprise in Chat tab, Free/Go from Oct 8; Sol for paid, Luna for Free/Go). 44%

figure is vendor-measured time-to-start on web-search questions, not wall-time; no final-answer latency number. Pricing absent on page. Oct. 7, 2026. URL: https://openai.com/index/gpt-6-for-everyone/ (visited on 10/14/2026).

[2]Anthropic. *Claude Haiku 5.5*. Primary official source; Oct 7 Haiku 5.5 two-tier price table per 1M tokens (up to/over 100k: Input $0.10/$0.50, Output $0.50/$2.50, Cache read $0.01/$0.05, Cache write $0.125/$0.625) plus Sonnet 5.5 cache-read halving ($0.20 to $0.10). Billed amount additionally needs usage; table estimate and individual bill are distinct. Vendor benchmark table publisher-measured (GDPval 1620, OSWorld2.1 72.4%, HLE 45.9/57.4, TB4 39.2%); system-card full evals unfetched; independent reproduction pending. Oct. 7, 2026. URL: https://www.anthropic.com/claude-haiku-5-5 (visited on 10/14/2026).

[3]OpenAI. *API Changelog: Decisions API Beta*. Primary official source; Oct 6 changelog listing entry (beta, gpt-6-luna binding, v1/decisions path, typed answers). Listing URL; per-entry fragment not established. 10x figure vendor-claimed with methodology absent; guides and pricing pages unfetched. Oct. 6, 2026. URL: https://developers.openai.com/api/docs/changelog (visited on 10/13/2026).

[4]Perplexity. *Perplexity Decider Announcement*. Primary forum source; category listing (individual permalink not established). Oct 6 forum brief for pplx-decider-v1.1-27b with Decision Index and Bench figures as forum-stated. HF README, params beyond title, license and repo URLs unfetched. Oct. 6, 2026. URL: https://community.perplexity.ai/c/announcements/9 (visited on 10/13/2026).

[5]Perplexity. *Perplexity Embed Late Pair Announcement*. Primary forum source; Oct 7 late-interaction embed pair as one-line comparator. Specs and repo paths unfetched; no standalone treatment. Oct. 7, 2026. URL: https://community.perplexity.ai/t/6296 (visited on 10/13/2026).

[6]OpenAI. *API Changelog: Ultrafast Tier*. Primary official source; Oct 8 changelog listing entry (service-tier ultrafast for gpt-6.1-sol on Responses API, all-users-with-limits, global plus US/EU residency, inter-token-latency purpose). Listing URL; per-entry fragment not established. No on-page latency numbers. Oct. 8, 2026. URL: https://developers.openai.com/api/docs/changelog (visited on 10/13/2026).

[7]Google. *Gemini at Work 2026*. Primary official source; Oct 8 announcement bullets (prompt field, skills/tools, cost controls, governance). GA date, SKU, pricing, region and Workspace-versus-Cloud split unfetched; customer figures vendor-stated. Oct. 8, 2026. URL: https://blog.google/products/workspace/gemini-at-work-2026/ (visited on 10/13/2026).

[8]Aleph Alpha. *Kolibri Has Landed: A Sovereign Open-Weight Model*. Primary official source; Oct 3 Kolibri 78B/3B MoE (1M context, Apache-2.0, HF path, 20T tokens, 768xB200). Vendor benches (AIME 2026 96.0, GPQA 84.3) attributed; fetch truncated past tables. Oct. 3, 2026. URL: https://aleph-alpha.com/en/blog/kolibri-has-landed-a-sovereign-open-weight-model (visited on 10/13/2026).

[9]Liquid AI. *d1 Open Decision Models*. Primary official source; Oct 7 d1-3B and d1-omni-600M with Decision Index figures and 8ms RTX4090 vendor caveat. License SPDX absent; small-decision contrast to Kolibri scale. Oct. 7, 2026. URL: https://liquid.ai/blog/d1-open (visited on 10/13/2026).

[10]Google. *EmbeddingGemma 2*. Primary official source; Oct 6 EmbeddingGemma 2 (740M split, 768-d MRL, 8K context, Apache-2.0, HF plus Kaggle, MTEB-Code vendor figure). Model-card bytes unfetched; architecture snippet-only. Oct. 6, 2026. URL: https://blog.google/innovation-and-ai/technology/developers-tools/embeddinggemma-2/ (visited on 10/13/2026).

[11]Reflection AI. *Introducing Beam*. Primary official source; Oct 5 Beam 501B/23B MoE preview (Apache-2.0 intent, weights later in October, vendor benches DeepSWE 44.4, TB2.1 80.1, AIME 97.8). Updated Oct 8; weights not downloadable at announcement. Oct. 5, 2026. URL: https://reflection.ai/blog/introducing-beam (visited on 10/13/2026).

[12]Mistral AI. *Mistral Large 4*. Primary official source with docs; Oct 6 Large 4 (52B active per docs, 1M context, preview API today, weights end of October, sale pricing). 49B-X versus 52B-docs disagreement preserved unresolved. Oct. 6, 2026. URL: https://mistral.ai/news/mistral-large-4/ (visited on 10/13/2026).

[13]Cloudflare. *Clef-omni adds audio and video input, Clef-flash is now cheaper, and Clef is faster*. Primary official source; Oct 9 Clef-omni (JSON-LD 18:27:34Z, Qwen3-Omni-30B-A3B MoE, omni/flash pricing, HF link stated). HF download and SPDX unverified; post-cutoff X 23:11Z is not the event clock. Oct. 9, 2026. URL: https://developers.cloudflare.com/changelog/post/2026-10-09-clef-omni-workers-ai (visited on 10/14/2026).

[14]Amazon Web Services. *Amazon Nova 2.5 Sonic*. Primary official source; Oct 5 Nova 2.5 Sonic speech-to-speech GA (four Bedrock regions including ap-northeast-1, 256K context, same-as-predecessor pricing with no numerics). Oct. 5, 2026. URL: https://aws.amazon.com/about-aws/whats-new/2026/10/amazon-nova-2-5-Sonic (visited on 10/13/2026).

[15]Google DeepMind. *Nano Banana 2.1 Model Card*. Primary official source; Oct 6 model card (Gemini 3 line, 1M input context, 4K image-output tokens vs 64K text, seven channels, 2026-03 cutoff for 3.6 Flash). Vendor side-by-side Elo 1050+/-14 Thinking; arena-score basis unresolved; pricing/license absent. Oct. 6, 2026. URL: https://deepmind.google/models/model-cards/nano-banana-2-1/ (visited on 10/13/2026).

[16]OpenAI. *Our approach to EU text provenance rules*. Primary official source; Oct 5 textGrain statistical watermark (API opt-in now, EU ChatGPT/Codex coming weeks, researcher-gated detector). 1% FPR with 80% at 200 tokens and 95% at 400 tokens, edit-weakening triple, Astra quality table; vendor-run with independent reproduction pending; report PDF unread. Oct. 5, 2026. URL: https://openai.com/index/eu-text-provenance/ (visited on 10/14/2026).

[17]Google DeepMind. *We're making it easier to identify AI-generated content globally*. Primary official source; Oct 7 announcement explicitly covers images, video and audio from Google or supported partners (named partners plus soon-Apple, vendor scale counts); text support is not established by this announcement. Portal display unverifiable; detection-accuracy benchmarks absent. Oct. 7, 2026. URL: https://blog.google/innovation-and-ai/models-and-research/google-deepmind/synth-id-ai-content/ (visited on 10/13/2026).

[18]Anthropic. *Anthropic Cyber Mission*. Primary official source; Oct 8 Cyber Mission (11 founding partners, CIDP plus free opt-in OSS Scanner, expected 90%+ true-positive figure). Scanner post and form internals unfetched; no measured outcomes. Oct. 8, 2026. URL: https://www.anthropic.com/news/anthropic-cyber-mission (visited on 10/13/2026).

[19]OpenAI. *Sharing AI Progress in Mathematics*. Primary official source with repo; Oct 6 frontier-model mathematics results without model identity (repo plus Lean partial formalizations, reasoning summaries, average compute). File counts and licenses unenumerated; model not released. Oct. 6, 2026. URL: https://openai.com/index/sharing-ai-progress-in-mathematics/ (visited on 10/13/2026).

[20]OpenAI. *Advancing Computer Use with Ironclad*. Primary official source; Oct 6 simulated evaluation (eleven EDGAR-simulated contracting tasks, vendor accuracy and time deltas as simulated estimates). Rubric, per-task and training details absent; Ironclad-product separation noted. Oct. 6, 2026. URL: https://openai.com/index/advancing-computer-use-with-ironclad/ (visited on 10/13/2026).